

Et si votre **professeur** était
une **IA** !...



Chat...
g...



**M. Faouzi
BOUFARÈS**



Faouz - IA



**PLUTÔT NON,
MAIS UN PETIT OUI**

NON

**SURTOUT NON,
MAIS UN PEU OUI**

UNIVERSITÉ
SORBONNE
PARIS NORD



LaMSN, Confiance & Éthique Numériques

$$D = Data^{MetaData} \times Data^{Quality}$$

À la question : Peut-on faire confiance aux données brutes ?

La réponse est : plutôt **NON!**



Le pourquoi ? → La **qualité** est très **mauvaise** !

Données Massives, Hétérogènes et Distribuées

→ Quasi Absence de Méta-Données, Sémantique

C'est peut-être très **difficile** ou même **irréalisable** de **détecter** et **corriger** **automatiquement** les **anomalies** et de l'**expliquer** !

Complexités spécifiques : à la **langue**, au **métier**, au **domaine** représenté...



دَارُ الْحِكْمَةِ



House of Wisdom, Maison de la Sagesse

عبارة تعبر عن مكان يُعتنى فيه بالعلم والمعرفة.
هذا الاسم ارتبط تاريخياً بمكتبة شهيرة ومركز علمي في بغداد خلال العصر العباسي،
وكان رمزاً للازدهار الثقافي والفكري، حيث
اجتمع العلماء من مختلف التخصصات لترجمة الكتب وتطوير العلوم.

دَارُ الْحِكْمَةِ

- ♦ **حِكَم** est le pluriel de **حِكْمَة** (hikma), qui signifie « sagesse ».

Mot en français	Traduction en Arabe SANS chakl (voyelles courtes)	Traduction en Arabe AVEC chakl
L'arbitre	الحكم	أَلْحَكَمُ
Les sagesse	الحكم	أَلْحِكَمُ
Le jugement	الحكم	أَلْحُكَمُ

La qualité
se **mesure**,
se **joue** et
se **cache**
dans les
détails !

Complexités spécifiques à une langue telle que la langue arabe

Mots avec ou sans diacritiques.

Multiples façons d'écrire un même nom (exemple : محمد vs محمّد).

Utilisation ou non du hamza (ء) ou du alif maqṣūra (ى).

Les noms arabes translittérés en lettres latines peuvent varier (exemple : "Mohamed", "Muhammad", "Mohammed").

Data, Données

THINK-SMARTER
CLOUD-COMPUTING
BUSINESS-INTELLIGENCE
DATA-BASE
DATA-MINING
DATA-WAREHOUSE
SCIENCE
Dark-Data
Data-Anonymization
MASTER-DATA-MANAGEMENT
DATA-GOVERNANCE
THINK-BIGGER
Data-Lake
THINKING-DIFFERENTLY
BIG-DATA
Open-Data
Data-Repository
DATA-CENTER
PREDICTION
Data-Confidentiality
La-Data-e(s)-t-le-futur



Avant propos ?

**Data, Data Set,
Table**


Extraction

Data Manipulations

Requêtes,
Rapports, Tableaux de Bord,
Tableaux Croisés Dynamiques,
Prédictions, Recommandations...

Graphiques

Data Visualisations




**Data, Data Sets,
Tables**

Extraction

Data Manipulations

Requêtes,
Rapports, Tableaux de Bord,
Tableaux Croisés Dynamiques,
Prédictions, Recommandations
Graphiques

Data Visualisations



Avant propos ?

ID Patient	Age Patient	Groupe-Sanguin Patient
P001	17	A+
P002	22	A+
P003	25	B+
P004	55	B-
P005	66	O+
P006		
P007		
P008		
P009		
P010		
P011		
P012		
P013	-13	A



ID Patient	Age Patient	Groupe-Sanguin Patient
P001	17	A+
P002	22	A+
P003	25	B+
P004	55	B-
P005	66	O+
P006	77	A+
P007	777	X
P008	18	B+
P009	33	B+
P010	44	A-
P011	11	AB+
P012	12	AB+
P013	-13	A

Calcule la moyenne des **âges des patients** de la série de valeurs ci-dessous :

Age_Patient : → → 17 22 25 55 66 77 777 18 33 44 11 12 -13

L'âge moyen des **valeurs valides** dans la série "Age_Patient", en excluant les **valeurs aberrantes** (777 et -13), est d'environ 34,55 ans.



ChatGPT

Absence de sémantique dans tous les outils !



ChatGPT

Avant propos ?

Calcule la moyenne des **âges des chats** de la série de valeurs ci-dessous :

Age_chat : → → 17 22 25 55 66 77 777 18 33 44 11 12 -13

✂ Étapes de nettoyage (prétraitement) :

On applique une règle réaliste pour les chats :

- **Âge minimal** : 0 an
- **Âge maximal** : ~25 ans (au-delà, considéré comme anomalie!)

● Valeurs à exclure (**VALEURS ABERRANTES**) :

- **777** (trop élevé pour un chat) ; **-13** (âge négatif)
- **55, 66, 77** (improbables) ; 33, 44 !

✓ Liste propre (valeurs valides) : 17, 22, 25, 18, 33, 44, 11, 12

Moyenne = $182 / 8 = 22,75$ ans



ChatGPT

Avant propos ?

ANOMALIES
dans les **données** !

ID_Patient	Age_Patient	Groupe-Sanguin_Patient
P001	17	A+
P002	22	A+
P003	25	B+
P004	55	B-
P005	66	O+
P006	77	A+
P007	777	X
P008	18	B+
P009	33	B+
P010	44	A-
P011	11	AB+
P012	12	AB+
P013	-13	A

Extraction



Groupe Sanguin	Nombre de Patients	Moyenne d'âge	Âge minimal	Âge maximal
A	1	3	3	3
A-	1	44	44	44
A+	3	38,6666667	17	77
AB+	2	11,5	11	12
B-	1	55	55	55
B+	3	25,3333333	18	33
O+	1	66	66	66
X	1			
Total général	13			

ANOMALIES
dans les
résultats obtenus !

Confiance ?
Véracité ?

Qualité ?

Quelles sont les ANOMALIES ? Quels SENS ?

Quelles sont les causes des ANOMALIES ?

Données initiales ;
Outils de gestion des données (DBMS, ETL) ;
Outils de calcul.



ID_Patient	Age_Patient	Groupe-Sanguin_Patient
P001	17	A+
P002	22	A+
P003	25	B+
P004	55	B-
P005	66	O+
P006	77	A+
P007	777	X
P008	18	B+
P009	33	B+
P010	44	A-
P011	11	AB+
P012	12	AB+
P013	-13	A

Avant propos ?



Analyse de
l'image →



ChatGPT

Nigéria	Abuja
Ouganda	Kampala
Rwanda	
Sao Tomé-et-Principe	Sao Tomé
Sénégal	
Seychelles	Victoria
Sierra Leone	Freetown
Somalie	Mogadiscio
Soudan	
Soudan du Sud	Djouba
Tanzanie	Dodoma
Tchad	N'Djaména
Togo	Lomé
Tunisie	
Zambie	Lusaka

Sémantique entre les colonnes
DF : Pays → Capitale

Cette image contient une liste de pays d'Afrique et leurs capitales respectives. Certaines cases de la colonne des capitales sont laissées vides. Je vais compléter les valeurs manquantes pour les capitales :

1. Soudan - Khartoum
2. Tunisie - Tunis
3. Zimbabwe - Harare

Traitement (±automatique) de certaines VALEURS MANQUANTES selon la sémantique !

Voici la liste corrigée avec les capitales manquantes ajoutées. Si vous avez besoin d'une version tabulaire ou d'autres informations, je peux les fournir.



Avant propos ?



Qualité des Données : Elimination des DOUBLES et/ou des SIMILAIRES !

Doubles ? Similaires ? <> Vrais - Faux (Faux - Vrais) amis ! <> Quelle valeur garder ?



+++


**Sémantique entre les lignes
Doubles / Similaires**

Avant propos ?


Plusieurs types d'anomalies

(Intra-Colonne, Inter-Colonnes et Inter-Lignes)


Pour résumer, nos objectifs sont d'introduire les concepts de **contexte** et de **sémantique** dans la gestion des données.



Comment **détecter**
automatiquement les
données **anormales** ?



Comment **corriger automatiquement**
ces anomalies **sans en créer de nouvelles** ?



Par exemple, pour détecter automatiquement les données aberrantes, plusieurs méthodes existent (statistiques ; apprentissage automatique ; séries temporelles (si les données sont chronologiques) et des méthodes basées sur des règles.

Plan


- **1. INTRODUCTION** : Niveaux d'Évaluation de la Qualité des Données
- **2. EXEMPLE** : Des données médicales à modéliser & à traiter
 - 2.1. Niveau 1 : Architecture
 - 2.2. Niveau 2 : Remplissage
 - 2.3. Niveau 3 : Exploitation
- **3. CONCLUSION** : Données + Méta-Données
 - 3.1. Perception syntaxique
 - 3.2. Perception sémantique

1. INTRODUCTION : ... des Données... aux Décideurs... !

La Donnée Qu'est-ce que c'est ? Qu'est-ce que l'on va en faire ? Quel degré de **confiance** ?

La qualité des données est la clé d'un processus décisionnel efficace !

Plus la **qualité** des données utilisées dans un processus décisionnel est **élevée**, plus les **décisions** prises sont **pertinentes**, **éclairées** et **objectives**.



3 Niveaux d'Évaluation de la Qualité des Données

1. INTRODUCTION : ... des Données... aux Décideurs... !

La Donnée Qu'est-ce que c'est ? Qu'est-ce que l'on va en faire ? Quel degré de **confiance** ?

Trois Niveaux d'Évaluation de la Qualité des Données



Niveau 1 : **Architecture BD** (**Conception** et **Construction**)



Niveau 2 : **Remplissage BD** (**Données** et **Méta-Données**)



Niveau 3 : **Exploitation BD** (**Résultats, Extractions**)

1. INTRODUCTION : 3 Niveaux d'Évaluation de la Qualité des Données

La Donnée Qu'est-ce que c'est ? Qu'est-ce que l'on va en faire ? Quel degré de **confiance** ?



Niveau 1 : Architecture
du « Bâtiment, Conteneur = **BD** »
Conception et **Construction**

Questions ?

L'**architecture** est-elle **fiable**,
robuste, fonctionnelle, normalisée,
durable, sécurisée et adaptable ?

Confiance ?

1. INTRODUCTION : 3 Niveaux d'Évaluation de la Qualité des Données

La Donnée Qu'est-ce que c'est ? Qu'est-ce que l'on va en faire ? Quel degré de **confiance** ?



Niveau 1 : **Architecture** du « Bâtiment, Conteneur = **BD** » **Conception** et **Construction**

Critères à évaluer :

Règles de normalisation (schéma relationnel ou autre type de schéma **Non relationnel**).

Règles de validation (unicité, non-nullité, etc.).

Intégrité référentielle (clés primaires étrangères).

Indexation et optimisation des performances.

Confiance, Fiabilité des structures !

1. INTRODUCTION : 3 Niveaux d'Évaluation de la Qualité des Données

La Donnée Qu'est-ce que c'est ? Qu'est-ce que l'on va en faire ? Quel degré de **confiance** ?



Niveau 2 : Remplissage
du « Bâtiment, Conteneur = **BD** »
Données et **Méta-Données**




Questions ?

Quelles sont les **règles** pour y **entrer** ?

Qui/Quoi rentre ?

Confiance ?




1. INTRODUCTION : 3 Niveaux d'Évaluation de la Qualité des Données

La Donnée Qu'est-ce que c'est ? Qu'est-ce que l'on va en faire ? Quel degré de **confiance** ?

Datalogue : Diagnostiquer !

(...Cardiologue, Neurologue, Gastrologue...)



Niveau 2 : Remplissage

du « Bâtiment, Conteneur = **BD** »

Données et **Méta-Données**

Critères à évaluer :

Complétude : Colonnes critiques remplies,
gestion des **données manquantes**.

Exactitude et validité : Formats standards, validation sémantique.

Cohérence : Absence de conflits logiques, gestion des **doublons & similaires**.

Confiance, Fiabilité des contenus !

1. INTRODUCTION : 3 Niveaux d'Évaluation de la Qualité des Données

La Donnée Qu'est-ce que c'est ? Qu'est-ce que l'on va en faire ? Quel degré de **confiance** ?



Niveau 3 : Exploitation
du « Bâtiment, Conteneur = **BD** »
Résultats, Extractions



Questions ?

Quelles sont les **requêtes** pour extraire ?

Qui/Quoi sort ?


Sûrs, Exhaustifs, Fiables ?

Confiance ?



1. INTRODUCTION : 3 Niveaux d'Évaluation de la Qualité des Données

La Donnée Qu'est-ce que c'est ? Qu'est-ce que l'on va en faire ? Quel degré de **confiance** ?



Niveau 3 : Exploitation
du « Bâtiment, Conteneur = **BD** »
Recherche intelligente des résultats

Critères à évaluer :

Robustesse des requêtes : tolérance aux **erreurs de saisie** (distances de similarité).

Contextualisation des résultats : **suggestions équivalentes (synonymie)** et contextuelles.

Optimisation des performances : gestion des requêtes lourdes.

Confiance, Fiabilité des résultats !

New **Control_Find/ctrl_f**

$\frac{x}{y}$ e^x $\sqrt[n]{x}$ $\int_{-x}^x$ $\sum_{i=0}^n$

1. INTRODUCTION : 3 Niveaux d'Évaluation de la Qualité des Données

La Donnée Qu'est-ce que c'est ? Qu'est-ce que l'on va en faire ? Quel degré de **confiance** ?




Construire un **Système de Notation**
de la **Qualité des Données**
qui **instaure la confiance** !



Définir un **Score Global**



- **Architecture (30%)** : Respect des règles de conception.
- **Qualité des Données (50%)** : Complétude, validité, cohérence.
- **Exploitation (20%)** : Robustesse et performance des recherches.
- **Représentation** : Échelle de 0 à 100, Tableau de bord des forces et faiblesses.



ID	NOM	PRENOM	GENRE	STAT	NIF	DN	VN	PN	DM	MEL	TAIL	PROMO	M2	BDA	DWH	JAVA	ENG	DL	RN	FT	DN2
E1	RAMA	Inès	F	M	ETINCELLE	12/09/1991	Barcelone	Espagne	10/10/2018	inès.rame@gmail.com	171 cm	2017	EID2	18	16	13	10	7	11	5	12/09/1991
E2	TRAIFOR	Adam	M	C	!	28/07/1994	Paris	France	12/12/2018	adam.traifor@gmail.com	1.89 m	2017	EID2	12	1300000000	9	15	10	12		28/07/1994
E3	NISSAN	Milame	M	D	!	?	Paris	?	11/11/1991	milame.nissan@gmail.com	165 cm	2017	EID2	13	11	7	11	9	10		?
E4	RENO	Aline	F	M	?	18/12/1984	Paris	France	18/12/1984	aline.reno@gmail.com	188	2017	PLS			13	12		15		18/12/1984
E5	FIATE	Editte	?	?	SIATE	02/01/1998	Rome	Italie	19/09/2018	editte.fiate@gmail.com	1.92m	2017	PLS			11	10		11	16	02/01/1998
E6	MERZEDES	?	F	M	BLENZ	24/10/1998	Munich	Allemagne	19/09/2018	MERZEDES@hotmail.com	1660 mm	2018	EID2	14	16	14	15	11	16	10	24/10/1998
E7	BEYEMEVE	Aimé	M	M	!	?	Munich	Allemagne	?	Aimé.BEYEMEVE@lap.fr	1.89 m	2018	EID2	9	12		11	11		15	?
E8	FORD	Varissa	?	?	?	25/01/1990	Pékin	?	?	harissa.ford@yahoo.fr	1.89 m	2018	EID2	11	11	6	16	13	14		25/01/1990
E9	MINI	?	?	?	?	?	?	?	?	ostine.mini@yahoo.fr	1.77 m	2018	EID2	17	14	0,00000005	10	7	16		11/10/1995
E10	FERRARI	Ala	M	C	!	19/09/1958	?	?	?	ala.ferrari@yahoo.fr	1234567890	2018	EID2	17			16	12	9	13	19/09/1958
E11	LONDRE	Bobby	M	C	!	10/09/1958	Londre	RU	?	bobby.londre@yahoo.fr	0	2018	EID2	17			13	10	9	10	20/09/1958
E12	LONDRE	Lee	F	V	!	22/09/1958	London	UK	?	ostine.mini@gmail.com	0	2018	PLS			10	11				21/09/1958
E13	SUZUKI	Lee	F	V	!	22/09/1958	Beijing	China	?	lee.suzuki@gmail.com	0	2018	PLS		1300000000	16	12				22/09/1958
E14	COOK	Thom	M	C	!	17/09/1958	London	UK	?	thom.cook@gmail.com	0	2018	PLS				15		12		17/09/1958
E15	LONDRE	J.	M	C	!	16/10/1996	London	England	17/10/2017	j.londres@gmail.com	171 cm	2018	PLS				11				16/10/1996
E16	LONDRE	J.	M	C	!	17/10/1996	London	England	17/10/2017	j.londres@gmail.com	1.89 m	2018	PLS				11	14		17	17/10/1996
E17	LONDRE	J.	M	C	!	20/11/1994	London	England	17/10/2017	j.londres@gmail.com	1.89 m	2018	PLS				11			15	20/11/1994
E18	LONDRE	J.	M	C	!	20/11/1994	London	England	17/10/2017	j.londres@gmail.com	1.89 m	2018	PLS				11				?
E19	ABANDON	Obsolette	F	M	BEN OIT	18/02/1900	Paris	France	22/02/2019	obsolette.abandon@gmail.com	1.92m	2018	PLS			11	14				18/02/1900
E20	TRON PEU	Donald	M	M	!	17/09/1900	Paris	FR	22/02/2019	donald.tron.peu@gmail.com	1.92m	2018	PLS			11	14		18		17/09/1900

2. EXEMPLE : Des données médicales à modéliser & à traiter?

... Patients, Médicaments, Historique/suivi de la prise de médicaments...



Niveau 1 : Architecture de la BD

Problématique de la conception d'une base de données

- * **organiser** des données hétérogènes,
- * **établir** des relations cohérentes entre elles et
- * **gérer** la complexité croissante de l'information.



Conception de BD


Architecture de BD

Structure de Données



Schéma de Données

Ensembles de données

Vues




Données **MULTIMODALES**
Base de Données



Formalismes de modélisation
UML, EER


Règles de construction
Qualité du schéma de données



EDON_DWH-ServicesHôpital = {BDi, i=1,h} EDON_DWH-Hôpitaux = {BDi, i=1,h}

2. EXEMPLE : Des données médicales à modéliser & à traiter?

... Patients, Médicaments, Historique/suivi de la prise de médicaments...



Niveau 1 : Architecture de la BD

Y-a-t-il des anomalies et pourquoi dans ce schéma de BD ?

Conception de BD


Architecture de BD

Structure de Données

Schéma de Données

Ensembles de données

Vues




Formalismes de modélisation
UML, EER

Règles de construction
Qualité du schéma de données

2. EXEMPLE : Des données médicales à modéliser & à traiter?

... Patients, Médicaments, Historique/suivi de la prise de médicaments...



Niveau 1 : Architecture de la BD

Données Structurées (Données relationnelles, SQL, CSV...)

Patients

IdP	GenreP	NomP	
p1	H	Traifor	
p2	F	Lamalade	05/05/55-20/02/20
p3			
p4			
e1	H		24/12/2024

Médicaments

IdM	NomM	...
m1	Irbésartan EG	
m2	Abiratéron UPC	
m3	Doxycycline	
m4	Amoxicilline	
m5	Calmacide	

Consommer

IdP	IdM	...
p1	m1	
p1	m2	
p2	m3	09/09/2019...
p2	m4	09/09/2019...
p2	m2	14/07/2020...

Formalismes de modélisation
Modèles Relationnel, NON-relationnel

Règles de construction
Qualité du schéma de données

Normalisation/...3FN

Pas de normal.


SGBD	SGBD
Relationnel	NON Relationnel
BD	BD
Oracle	MongoDB
DB2	Cassandra
MySQL	...
SQLServer	...

Données NON-Structurées (NOSQL, JSON...)

Patients

IdP	NomP	...		
p1	H	Médicaments		
	Traifor	IdM	NomM	DD, DF, Q
		m1	Irbésartan EG	
p2	F	Médicaments		
	Lamalade	IdM	NomM	
	05/05/1955	m3	Doxycycline	e1, H, 24/12/2024
	20/02/2020	m4	Amoxicilline	e2
		m2	Abiratéron UPC	

SGBD Graphe / BD



2. EXEMPLE : Des données médicales à modéliser & à traiter?

... Patients, Médicaments, Historique/suivi de la prise de médicaments...


Niveau 2 : Mise-à-jour des données

Problématique des **Insertions, Modifications et Suppressions des données** dans la BD
Homogénéiser les données (format...), **traiter** les valeurs **manquantes** et **gérer** (détecter et corriger) les anomalies. → **Créer et gérer des métadonnées.**

Construire des
MÉTADONNÉES



Construire des **RÈGLES**
DE VALIDATION,



Illustrer clairement les transformations
des **DONNÉES INVALIDES**
en **DONNÉES CORRECTES**
(Détection & Correction des anomalies ?).

2. EXEMPLE : Des données médicales à modéliser & à traiter?

... Patients, Médicaments, Historique/suivi de la prise de médicaments...

Niveau 2 : Mise-à-jour des données

Y-a-t-il des anomalies et pourquoi dans cette BD ?

Données Structurées (Données relationnelles, SQL, CSV...)

Patients

IdP	GenreP	NomP	
p1	H	Traifor	
p2	F	Lamalade	05/05/55-20/02/20
p3			
p4			
e1	H		24/12/2024

Médicaments

IdM	NomM	...
m1	Irbésartan EG	
m2	Abiratérone UPC	
m3	Doxycycline	
m4	Amoxicilline	
m5	Calmacide	

Consommer

IdP	IdM	DDC...
p1	m1	
p1	m2	
p2	m3	09/09/2019...
p2	m4	09/09/2019...
p2	m2	14/07/2020...

SGBD
relationnel
BD

Oracle
DB2
MySQL
SQLServer
...

Civilité Nom Prénom

M. Traifor Adam
Mme Lamalade Clémence

Nom

Ad@m

Parent ; Enfants

p2 ; e1, e2

Email

clémence.lamalade@gmail.com

Données INVALIDES !



Méta-Données : Règles de conception

Valeurs atomiques
Normalisation (1FN, 2FN, 3FN...)
Références (Clés primaires et étrangères)

Méta-Données : Règles (Expressions régulières, RegEx i)

RegEx 1 (Alphabétique avec -) : ^[[[:alpha:]]-]+\$
RegEx 2 (Email) : ^[A-Za-z]+[A-Za-z0-9.]+@[A-Za-z0-9.]+\.[A-Za-z]{2,4}\$
RegEx 3 (Téléphone) : ^((\+) [0]{2})((3){2}))([1-9]([0-9]{8})\$

Syntaxe
+++
Sémantique



2. EXEMPLE : Des données médicales à modéliser & à traiter?

... Patients, Médicaments, Historique/suivi de la prise de médicaments...

Niveau 2 : Mise-à-jour des données



Patients

IdP	GenreP	NomP	
p2	F	Lamalade	...20/02/2020

Médicaments

IdM	NomM	...
m2	Abiratérone UPC	

Consommer

IdP	IdM	...
p2	m2	14/07/2020...



La patiente (GenreP = "F") identifiée par le numéro p2 (NomP = "Lamalade") a consommé le médicament identifié par le numéro m2 (NomM = "Abiratérone UPC") entre le 14/07/2020 et le 14/07/2024

Ces données contiennent **PLUSIEURS ANOMALIES !**

Explications :

La patiente Mme **Lamalade** est une **femme** !

Le médicament **Abiratérone** UPC est administré pour les **hommes** car il traite de la **prostate** !

La patiente Mme Lamalade est décédée le **20/02/2020**.

Il est dit quelle a **consommé** un médicament, **après son décès**, entre le **14/07/2020** et le **14/07/2024** !

2. EXEMPLE : Des données médicales à modéliser & à traiter?

... Patients, Médicaments, Historique/suivi de la prise de médicaments...

Niveau 2 : Mise-à-jour des données

Données Structurées (Données relationnelles, SQL, CSV...)

Patients

IdP	GenreP	NomP	
p2	F	Lamalade	

Médicaments

IdM	NomM	...
m3	Doxycycline	
m4	Amoxicilline	

Consommer

IdP	IdM	DDC...
p2	m3	09/09/2019...
p2	m4	09/09/2019...

La patiente identifiée par le numéro p2 (NomP = "Lamalade") a consommé les médicaments identifiés par les numéros m3 (NomM = "Doxycycline") et m4 (NomM = "Amoxicilline") à partir du 09/09/2019 c'est-à-dire **en même temps**.

Ces données contiennent **PLUSIEURS ANOMALIES !**

Explications :

Les médicaments **identifiés** par les numéros m3 (NomM = "Doxycycline") et m4 (NomM = "Amoxicilline") consommés par la patiente Mme Lamalade ne se prennent pas en **même temps**.

2. EXEMPLE : Des données médicales à modéliser & à traiter?

... Patients, Médicaments, Historique/suivi de la prise de médicaments...


Niveau 2 : Mise-à-jour des données

Médicaments				
IdM	NomM	...		NomL
m1	NomMed1			Boiron
m2	NomMed2			Johnson & Johnson
m3	NomMed3			Laboratoires Pierre Fabre
m4	NomMed4			Johnson & Johnson
m5	NomMed5			Pfizer
m6	NomMed6			Johnson-Johnson
m7	NomMed7			Pierre Fabre
m8	NomMed8			Sandoz
m9	NomMed9			Sandoz
m10	NomMed10			Sandos
m11	NomMed11			GlaxoSmithKline (GSK)
m12	NomMed12			GlaxoSmithKline



Médicaments				
IdM	NomM	...	IdL	NomL
m1	NomMed1		L005	Boiron
m2	NomMed2		L002	Johnson & Johnson
m3	NomMed3		L006	Laboratoires Pierre Fabre
m4	NomMed4		L002	Johnson & Johnson
m5	NomMed5		L003	Pfizer
m6	NomMed6		L002	Johnson-Johnson
m7	NomMed7		L006	Pierre Fabre
m8	NomMed8		L013	Sandoz
m9	NomMed9		L013	Sandoz
m10	NomMed10		L013	Sandos
m11	NomMed11		L010	GlaxoSmithKline (GSK)
m12	NomMed12		L010	GlaxoSmithKline

Dépendances sémantiques entre les colonnes
Graphe des DF



NON 3FN !

2. EXEMPLE : Des données médicales à modéliser & à traiter?

... Patients, Médicaments, Historique/suivi de la prise de médicaments...

Niveau 2 : Mise-à-jour des données

Médicaments			
IdM	NomM	...	IdL
m1	NomMed1		L005
m2	NomMed2		L002
m3	NomMed3		L006
m4	NomMed4		L002
m5	NomMed5		L003
m6	NomMed6		L002
m7	NomMed7		L006
m8	NomMed8		L013
m9	NomMed9		L013
m10	NomMed10		L013
m11	NomMed11		L010
m12	NomMed12		L010



3FN !

+

Enrichissement de la BD

Laboratoires				
IdL	NomL	PaysL	AnnéeCréationL	SpécialiséL
L001	Merck	Allemagne	1668	Vaccins, maladies respiratoires, VIH
L002	Johnson & Johnson	États-Unis	1886	Produits chimiques, oncologie, immunologie
L003	Pfizer	États-Unis	1849	Vaccins, traitements innovants en oncologie et m
L004	Biogaran	France	1996	Médicaments génériques
L005	Boiron	France	1932	Médicaments homéopathiques
L006	Laboratoires Pierre Fabre	France	1962	Dermatologie, oncologie, santé familiale
L007	Sanofi	France	1973	Médicaments innovants, vaccins, génériques
L008	Servier	France	1954	Traitement des maladies chroniques (cardiologie,
L009	AstraZeneca	Royaume-Uni	1999	Produits pharmaceutiques, dispositifs médicaux,
L010	GlaxoSmithKline (GSK)	Royaume-Uni	2000	Maladies cardiovasculaires, oncologie, respiratoi
L011	Novartis	Suisse	1996	Oncologie, ophtalmologie, médicaments génériqu
L012	Roche	Suisse	1896	Diagnostics, oncologie, maladies rares
L013	Sandoz	Suisse	1886	Médicaments génériques et les biosimilaires
L014	Unimed	Tunisie	1989	Solutions injectables stériles (les domaines de l'a

2. EXEMPLE : Des données médicales à modéliser & à traiter?

... Patients, Médicaments, Historique/suivi de la prise de médicaments...

Niveau 3 : Recherche & Exploitation des données

Problématique de la recherche et l'exploitation des données dans la BD,

Ces recherches et exploitations sont-elles **robustes**, **tolérantes** aux **erreurs** et capables de s'adapter aux formulations imparfaites.

Y-a-t-il des anomalies et pourquoi dans ces réponses?



New ctrl_f : **Abirateron /ou/ Abyrathérone**



Résultats de la recherche : Équivalents d'Abiratérone UPC :

1. Zytiga (Janssen-Cilag) :

Description : C'est le médicament de référence (princeps) à base d'acétate d'abiratérone.

Indication : Utilisé pour le traitement du cancer de la prostate métastatique résistant à la castration, souvent en association avec la prednisone ou la prednisolone.

2. Autres génériques d'abiratérone disponibles :

Plusieurs laboratoires produisent des versions génériques de l'acétate d'abiratérone, qui sont équivalents au Zytiga en termes de composition et de biodisponibilité. Parmi eux :

Abiraterone Accord (Accord Healthcare). **Abiraterone Zentiva** (Zentiva).

Abiraterone Sandoz (Sandoz). **Abiraterone Teva** (Teva Pharmaceuticals).



2. EXEMPLE : Des données médicales à modéliser & à traiter?

... Patients, Médicaments, Historique/suivi de la prise de médicaments...

Niveau 3 : Recherche & Exploitation des données



New ctrl_f : **dollipran /ou/ Dolliprane 500**



Résultats de la recherche : Équivalents du Doliprane 500 mg :

1. Efferalgan 500 mg
2. Dafalgan 500 mg
3. Paracétamol 500 mg (Labo. Mylan, Sandoz, Biogaran, Zentiva, etc).
4. Tylenol 500 mg (international)



Les équivalents en **anglais** (ou autre **langue**) des médicaments mentionnés, tous à base de **paracétamol (acetaminophen)** :

- **Doliprane 500 mg** : Paracetamol 500 mg (common name in the UK) or Acetaminophen 500 mg (USA).
- **Efferalgan 500 mg** : Effervescent Acetaminophen 500 mg (common in international markets).
- **Dafalgan 500 mg** : Acetaminophen 500 mg (marketed under this name in some European countries).
- **Paracétamol 500 mg** : Generic Paracetamol or Acetaminophen 500 mg (depending on region).
- **Tylenol 500 mg** : Tylenol Extra Strength 500 mg (well-known international brand in the USA and other countries).

Aux États-Unis, le **paracétamol** est toujours référencé comme **acetaminophen**.

2. EXEMPLE : Des données médicales à modéliser & à traiter?

... Patients, Médicaments, Historique/suivi de la prise de médicaments...

Niveau 3 : Recherche & Exploitation des données



New **ctrl_f** : **poser BI** (outils de Visualisation des données, data Viz) 🔍 ▼



Résultats de la recherche : (Suggestions/Alternatives) à **poser BI** :

Power BI

Tableau

Excel



New **ctrl_f** : **Oracle** (outils de gestion des données, DBMS, SGBD) 🔍 ▼



Résultats de la recherche : (Suggestions/Alternatives) à **Oracle** :

PostgreSQL

MySQL

DB2


SQL-Server

MongoDB

2. EXEMPLE : Des données médicales à modéliser & à traiter?

... Patients, Médicaments, Historique/suivi de la prise de médicaments...

Niveau 3 : Recherche & Exploitation des données



Les **calculs** numériques (AVG, MIN, MAX ...) et/ou **analyses**, devraient intégrer des mécanismes pour traiter (exclure automatiquement) les **valeurs INVALIDES** telles que les valeurs **aberrantes** ?!.

2. EXEMPLE : Des données médicales à modéliser & à traiter?

... Patients, Médicaments, Historique/suivi de la prise de médicaments...


Niveau 3 : Recherche & Exploitation des données

Plusieurs méthodes pour effectuer des recherches avancées de texte :

Recherche par calcul de distance de similarité (comparaisons lexicographique et phonétique)

Recherche sémantique : Plutôt que de dépendre strictement de correspondances de mots ou d'expressions, la recherche sémantique vise à comprendre le sens du texte. Utilisation des modèles de **traitement automatique du langage naturel (NLP)**.

Recherche par similarité de vecteurs de mots : utiliser des **représentations vectorielles de mots (Word Embeddings)**.





2. EXEMPLE : Des données médicales à modéliser & à traiter?

Patients Médicaments Historique/suivi de la prise de médicaments...



Enrichissement & Correction de la structure de la BD



3. CONCLUSION : Données, Méta-Données et Qualité des Données

Données Structurées ou NON-Structurées (Relationnelles, CSV, JSON) ?

La Donnée Qu'est-ce que c'est ? Qu'est-ce que l'on va en faire ? Quel degré de **confiance** ?

De nos jours, la plus grande partie des échanges de données se fait aux formats **CSV** ou **JSON** (source d'anomalies) !

Perception Syntaxique des données

Data Source DS (A table, A CSV file...)							
Column Identifier	Column 1	Column 2	Column 3	...	Column j	...	Column N
Meta-Data (Very detailed data description)							
Domain, Data Type →→→	Number	Date	String	...	String	...	Date
	Integer	Hour	Character	...	Length (L)	...	Format DMY
	Real	Date & Hour	Text	...		...	Format YMD
Rules, Constraints →→→	Rules	Rules	Rules		Upper, Lower		≤ ≥
Quantitative & Qualitative Data							
Line 1, Record 1, Row 1 →→→	Value 11	Value 12	Each column should have a domain of definition (a data type) and explicit writing rules; these are the metadata used to validate the data within the column (intra-column).		Value 1j		Value 1N
Line 2, Tuple 2, Object 2 →→→	Value 21	Value 22			VALID Data, Values		Value 2N
	...	...					...
Line i, Record i, Row i →→→	Value i1	Value i2			Value ij		Value iN
	...	...			INVALID Values		...
			? Intra-column anomalies		OUTLIERS & outdated Values		
					MISSING & inapplicable Values		
Line L-1 →→→							
Line L →→→	Value L1	Value L2					Value LN

3. CONCLUSION : Données, Méta-Données et Qualité des Données




Données Structurées ou NON-Structurées (Relationnelles, CSV, JSON) ?

La Donnée Qu'est-ce que c'est ? Qu'est-ce que l'on va en faire ? Quel degré de **confiance** ?

Data Source DS (A table, A CSV file...)							
Column Identifier	Column 1	Column 2	Column 3	...	Column j	...	Column N
	Meta-Data (Very detailed data description)						
Rules, Constraints →→→	Explicitly define (or extract) inter-column relationship such as order relations, functional dependencies						? ↔
	or any other logical rules expressing semantic constraints.						
Rules, Constraints →→→	Rules	Rules	Rules		Upper, Lower		≤ ≥
Quantitative & Qualitative Data							
Line 1, Record 1, Row 1 →→→			Each column should have a domain of definition (a data type) and explicit writing rules; these are the metadata used to validate the data within the column (intra-column).		Value 1j		Value 1N
Line 2, Tuple 2, Object 2 →→→					VALID Data, Values		Value 2N
							...
Line i, Record i, Row i →→→	Value i1	Value i2			Value ij		Value iN
	Inter-column anomalies				INVALID Values		...
	? ↔ inter-column relationship order relations functional dependencies				OUTLIERS & outdated Values		
				MISSING & inapplicable Values			
Line L-1 →→→							
Line L →→→							Value LN

Perceptions Syntaxique & Sémantique des données

Dépendances sémantiques entre les colonnes
Graphe des DF



3. CONCLUSION : Données, Méta-Données et Qualité des Données

Données Structurées ou NON-Structurées (Relationnelles, CSV, JSON) ?

La Donnée Qu'est-ce que c'est ? Qu'est-ce que l'on va en faire ? Quel degré de **confiance** ?

Data Source DS (A table, A CSV file...)						
Column Identifier	Column 1	Column 2	Column 3	...	Column j	... Column N
	Meta-Data (Very detailed data description)					
	Explicitly define deduplication rules					
Rules, Constraints →→→	inter-row rules for duplicates or similar entries.					
	Select similarity distance algorithms and specify a similarity threshold.					
Rules, Constraints →→→	Rules	Rules	Rules		Upper, Lower	≤ > ≥
Quantitative & Qualitative Data						
Line 1, Record 1, Row 1 →→→			Each column should have a domain of definition (a data type) and explicit writing rules; these are the metadata used to validate the data within the column (intra-column).		Value 1j	Value 1N
Line 2, Tuple 2, Object 2 →→→					VALID Data, Values	Value 2N
					...	...
Line i, Record i, Row i →→→	Value i1	Value i2			Value ij	Value iN
	Inter-row anomalies				INVALID Values	...
	deduplication rules				OUTLIERS & outdated Values	
	inter-row rules					
	duplicates or similar entries				MISSING & inapplicable Values	
Line L-1 →→→						Value LN
Line L →→→						

Préciser :

- Algorithmes de **dédoublonnage, similarité**
- **Clé** de blocage/dédoublonnage
- Algorithmes de calcul de **distance de similarité** (s'écrit comme, **Levenshtein** -EditDistance, **Jaro-Winkler**, **Qgram**, se prononce comme, **Soundex**, **Metaphone**, Noutq نطق & Sawtex صَوْتِك)
- **Seuil** de similarité
- Traitement des **valeurs manquantes** %comparaisons

Perceptions Syntaxique & Sémantique des données

3. CONCLUSION : Un outil, intelligent, pour restaurer la confiance !

Données Structurées ou NON-Structurées (Relationnelles, CSV, JSON) ?


La Donnée Qu'est-ce que c'est ? Qu'est-ce que l'on va en faire ? Quel degré de confiance ?



Syntaxe

Sémantique

E1:RAMA;inès;F;M;ETINCELLE;12/09/1991;Barcelone;Espagne;10/10/2018;inès.rama@gmail.com;171 cm;2017;EID2;18;16;13;10;7;11;5;12/09/1991
E2:TRAIFOR;Adam;M;C;28/07/1994;Paris;France;12/12/2018;adam.traifor@gmail.com;1.89 m;2017;EID2;12;13;00000000;15;10;12;28/07/1994
E3:NISSAN;Miame;M;D;7;Paris;11/11/1991;miamie.nissan@gmail.com;165 cm;2017;EID2;13;11;7;11;9;10;7
E4:RENO;Aline;F;V;18/12/1984;Paris;France;18/12/1984;aline.reno@gmail.com;188 cm;2017;PLS;13;12;15;18/12/1984
E5:FIATE;Edite;F;M;24/10/1998;Rome;Italie;19/09/2018;edite.fiate@gmail.com;1.92m;2017;PLS;14;16;11;16;10;24/10/1998
E6:MERZEDES;?;F;M;24/10/1998;Munich;Allemagne;19/09/2018;MERZEDES@hotmail.com;1660 mm;2018;EID2;14;16;14;15;11;16;10;24/10/1998
E7:BEYEMEV;Aimé;M;M;?;Munich;Allemagne;?;Aimé.BEYEMEV@lign.fr;1.89 m;2018;EID2;9;12;11;11;15;7
E8:FORD;Harissa;F;M;25/01/1990;Pékin;?;?;harissa.ford@yahoo.fr;1.89 m;2018;EID2;11;11;6;16;13;14;25/01/1990
E9:MINI;Ostine;F;M;11/10/1995;?;Royaume-Uni;?;ostine.mini@yahoo.fr;1.77 m;2018;EID2;17;14;0,00000005;10;7;16;11/10/1995
E10:FERRARI;Ala;M;C;19/09/1958;?;?;ala.ferrari@yahoo.fr;1234567890;2018;EID2;17;16;12;9;13;19/09/1958
E11:LONDRE;Boby;M;C;20/09/1958;Londre;RU;?;boby.londre@yahoo.fr;0;2018;EID2;17;13;10;9;10;20/09/1958
E12:LONDON;Elisabeth;F;?;LONDON;21/09/1958;London;United-Kingdom;?;elisabeth.london@gmail.com;10;2018;PLS;10;11;21/09/1958
E13:SUZUQUI;Lee;F;V;22/09/1958;Beijing;China;?;lee.suzuqui@gmail.com;0;2018;PLS;16;12;22/09/1958
E14:COOK;Thom;M;C;17/09/1958;London;UK;?;thom.cook@gmail.com;0;2018;PLS;15;12;17/09/1958
E15:LONDRES;John;M;C;16/10/1996;London;UK;?;john.londres@gmail.com;171 cm;2018;PLS;12;14;16/10/1996
E16:LONDRES;J.;M;C;17/10/1996;London;England;17/10/2017;j.londres@gmail.com;1.89 m;2018;PLS;11;14;17/10/1996
E17:LONDRES;Jane;F;C;20/11/1994;London;England;17/10/2017;jane.londres@gmail.com;165 cm;2018;PLS;11;15;20/11/1994
E18:LONDRES;J.;F;C;?;London;United-Kingdom;17/10/2017;j.londres@gmail.com;188 cm;2018;PLS;-1300000000;-1300000000;14;?;?
E19:ABANDON;Obsolète;F;M;BEN OIT;18/02/1900;Paris;Franca;22/02/2019;obsolète.abandon@gmail.com;1.92m;2018;PLS;11;14;18/02/1900
E20:TRON PEU;Donald;M;M;17/09/1900;Paris;FR;22/02/2019;donaald.tron peu@gmail.com;1.92m;2018;PLS;11;14;18/02/1900




ID	NOM	PRENOM	SEXE	STATUT	NIF	DN	VN	PN	DM	MEL	TAIL	PROMO	M2	BDA	DWH	JAVA	ENG	DL	RN	FT	DN2
E1	RAMA	Inès	M		ETINCELLE	12/09/1991	Barcelone	Espagne	10/10/2018	inès.rama@gmail.com	171 cm	2017	EID2	18	16	13	10	7	11	5	12/09/1991
E2	TRAIFOR	Adam	M		!	28/07/1994	Paris	France	12/12/2018	adam.traifor@gmail.com	1.89 m	2017	EID2	12	1300000000	9	15	10	12		28/07/1994
E3	NISSAN	Miame	M		?	?	Paris	?	11/11/1991	miamie.nissan@gmail.com	165 cm	2017	EID2	13	11	7	11	9	10		?
E4	RENO	Aline	F		!	18/12/1984	Paris	France	18/12/1984	aline.reno@gmail.com	188	2017	PLS			13	12		15		18/12/1984
E5	FIATE	Edite	F		?	24/10/1998	Rome	Italie	19/09/2018	edite.fiate@gmail.com	1.92m	2017	PLS			11	10		11	16	02/01/1998
E6	MERZEDES	?	F	M	BLENZ	24/10/1998	Munich	Allemagne	19/09/2018	?MERZEDES@hotmail.com	1660 mm	2018	EID2	14	16	14	15	11	16	10	24/10/1998
E7	BEYEMEV	Aimé	M	M	!	?	Munich	Allemagne	?	Aimé.BEYEMEV@lign.fr	1.89 m	2018	EID2	9	12		11	11		15	?
E8	FORD	Harissa	F		?	25/01/1990	Pékin	?	?	harissa.ford@yahoo.fr	1.89 m	2018	EID2	11	11	6	16	13		14	25/01/1990
E9	MINI	Ostine	F	M	CAR	11/10/1995	" "	Royaume-Uni	?	ostine.mini@yahoo.fr	1.77 m	2018	EID2	17	14	0,00000005	10	7	16		11/10/1995
E10	FERRARI	Ala	M	C	!	19/09/1958	?	?	?	ala.ferrari@yahoo.fr	1234567890	2018	EID2	17		16	12	9	13		19/09/1958
E11	LONDRE	Boby	M	C	!	20/09/1958	Londre	RU	?	boby.londre@yahoo.fr	0	2018	EID2	17		13	10	9	10		20/09/1958
E12	LONDON	Elisabeth	F		?	LONDON	21/09/1958	London	United-Kingdom	?	elisabeth.london@gmail.com	10	2018	PLS		10	11				21/09/1958
E13	SUZUQUI	Lee	F	V	!	22/09/1958	Beijing	China	?	lee.suzuqui@gmail.com	0	2018	PLS		1300000000	16	12				22/09/1958
E14	COOK	Thom	M	C	!	17/09/1958	London	UK	?	thom.cook@gmail.com	0	2018	PLS				15			12	17/09/1958
E15	LONDRES	John	M	C	!	16/10/1996	London	UK	?	john.londres@gmail.com	171 cm	2018	PLS				12				16/10/1996
E16	LONDRES	J.	M	C	!	17/10/1996	London	England	17/10/2017	j.londres@gmail.com	1.89 m	2018	PLS			11	14			17	17/10/1996
E17	LONDRES	Jane	F	C	!	20/11/1994	London	England	17/10/2017	jane.londres@gmail.com	165 cm	2018	PLS			11				15	20/11/1994
E18	LONDRES	J.	F	C	!	?	London	United-Kingdom	17/10/2017	j.londres@gmail.com	188 cm	2018	PLS		-1300000000	-1300000000	14				?
E19	ABANDON	Obsolète	F	M	BEN OIT	18/02/1900	Paris	Franca	22/02/2019	obsolète.abandon@gmail.com	1.92m	2018	PLS			11	14				18/02/1900
E20	TRON PEU	Donald	M	M	!	17/09/1900	Paris	FR	22/02/2019	donaald.tron peu@gmail.com	1.92m	2018	PLS			11	14			18	17/09/1900

3. CONCLUSION : Données, Méta-Données et Qualité des Données

Données Structurées ou NON-Structurées (Relationnelles, CSV, JSON) ?

La Donnée Qu'est-ce que c'est ? Qu'est-ce que l'on va en faire ? Quel degré de **confiance** ?



*Think
Bigger, Differently & Smarter
by
using correct DATA*

Thats' all falks !!!


M. Faouzi BOUFARES

faouzi.boufares@sorbonne-paris-nord.fr


<http://www.lipn.univ-paris13.fr/~boufares/>

Laboratoire d'Informatique de Paris Nord (LIPN)

Université Sorbonne Paris Nord - FRANCE



Thats' all folks !!!



The End : Thanks for your attention

Fin : Merci de votre attention

النهاية : شكرا لحسن إنتباهكم

Fin : Gracias por su atención

Ende : Danke für Ihre Aufmerksamkeit

Конец : Спасибо за ваше внимание

結束 : 感謝您的關注

M. Faouzi BOUFARES

faouzi.boufares@sorbonne-paris-nord.fr

LaMSN


Université Sorbonne Paris Nord - FRANCE

<http://www.lipn.univ-paris13.fr/~boufares/>

Laboratoire d'Informatique de Paris Nord (LIPN)

M. F. Boufarès

46



DATA+AI & The Future

Est-ce qu'il faut en avoir peur ?

EAO, CAO, FAO, PAO... !

VAR (*Video Assistant Referees*)...

