



La Donnée e-s-t le Monde de Demain

Data is-and the Future

*The Data Science, The Data Scientist, The Data Engineer, The Data Manager
Data Engineering And Machine Learning*

Dr. M. Faouzi BOUFARES

faouzi.boufares@sorbonne-paris-nord.fr

boufares@lipn.univ-paris13.fr


<http://www.lipn.univ-paris13.fr/~boufares/>



Laboratoire d'Informatique de Paris Nord (**LIPN**)

La Maison des Sciences Numériques (**MSN**)

Université Sorbonne Paris Nord – France (**USPN**)



#USPN

www.univ-sorbonne-paris-nord.fr





دَارُ الْحِكْمَةِ



House of Wisdom, Maison de la Sagesse

عبارة تعبر عن مكان يُعنى فيه بالعلم والمعرفة.

هذا الاسم ارتبط تاريخياً بمكتبة شهيرة ومركز علمي في بغداد خلال العصر العباسي، وكان رمزاً للازدهار الثقافي والفكري، حيث اجتمع العلماء من مختلف التخصصات لترجمة الكتب وتطوير العلوم.

Données = Data ?

DoD : des Données aux Décideurs !

Bases de Données Avancées, Introduction

+++

Entrepôts de Données, Introduction



M. Faouzi BOUFARES

boufares@lipn.univ-paris13.fr

<http://www.lipn.univ-paris13.fr/~boufares/>

Bureau Y204

Laboratoire d'Informatique de Paris Nord

LIPN – UMR 7030 du CNRS

La MSN, A3

Université Sorbonne Paris Nord

Institut Galilée

99, Avenue J.B. Clément

F-93430 Villetaneuse FRANCE

www.univ-paris13.fr

faouzi.boufares@sorbonne-paris-nord.fr



Base de **Données** (Database) ; Entrepôt de **Données** (Data Warehouse) ;
Lac de **Données** (Data Lake) ; **Données** de Référence (Master Data) ;

BI (Business Intelligence) et AI (Artificial Intelligence)

Les données = Data

Qu'est-ce que c'est ?

Quels **types** ?

Quelles **contraintes** ?

Quel **Sens** ?

Quelle **Validité** ?

Quelles **structures** ?

Temps / Durée de vie !

ORACLE

Collecte,
Assemblage,
Intégration,
Homogénéisation,
Correction !
Bases, Entrepôts,
Magasins, Lacs,...




Traitement,
Exploitation,
Exploration,
Utilisation,
Visualisation,
Apprentissage !

SQL & PL/SQL



C++, Java, Python ... PHP, ...

Hadoop, Spark ...



R



Données = Data ?


DoD : des Données aux Décideurs !

MACHINE LEARNING: From DATA to DECISIONS


UNDERSTANDING DATA



Collecting, Assembling,
Integrating data
Data cleaning




Data processing
PREDICTION, DEDUCTION,
CAUSAL INFERENCE,
DECISION MAKING




Think Bigger, Differently & Smarter by using correct DATA





... Quelques outils qui manipulent les Données ...

Traitement, Intégration & Exploitation des données ; Certains outils du marché




...Des questions sur La Data, Les Données?...



Data INTEGRATION TO *Think Bigger, Differently & Smarter*

Zone de préparation




Intégration

ETL - ELT


MDM

Zone de stockage de données massives



**The better the quality of the data,
the better it can be used for analyses**

Zone de présentation



...Des questions sur La Data, Les Données?...



Data INTEGRATION TO *Think Bigger, Differently & Smarter*

Préparation des données (Data Preparation ; Data Prep)

The standard definition of **data preparation** is:

"The process of gathering, combining, structuring, and organizing data."

La définition standard de la **préparation des données** est la suivante :

"Le processus de collecte, de combinaison, de structuration et d'organisation des données".


Préparation des données (Data Preparation ; Data Prep)

Au stade de la préparation des données, on convertit tout format de données dans un format natif, on exécute des utilitaires pour nettoyer les données, on dédoubleonne (On s'occupe de la déduplication des enregistrements de la base de données) et on charge les données dans tout autre format souhaité...

De nombreux utilitaires sont utilisés pour nettoyer, organiser et normaliser les données.




... Quelques mots clés sur la Donnée ... DATA



Gouvernance des Données

Gouvernance des données = Data Governance :

ensemble de politiques, processus et responsabilités qui encadrent la **qualité, la sécurité, l'accessibilité** et l'**usage des données** dans une organisation



... Des Données ... Aux décideurs !

La **BI « Business Intelligence »** vise à extraire des informations des « Données de Base ou BD » de l'entreprise, à concevoir et construire : des entrepôts de données (Data WareHouses) et des magasins de données (Data Marts) et éventuellement des « Données de Référence, Master Data » ou encore des « lacs de données, Data Lakes » avec comme objectif de développer **des outils d'aide à la décision** tels que des tableaux de bord !

Plusieurs grandes étapes : Extraction ; Stockage & Exposition ; Analyse (Reporting, Data Mining, Analyse Multidimensionnelle avec des CUBE OLAP et des tableaux de bord)

Afin d'améliorer les performances de temps de réponse (temps réel) et de calculs

On peut utiliser des frameworks de type Big Data... → Le **Cloud Computing**... et **Grille de Calcul** !

*Think **Bigger**,
Differently & **Smarter**
by using correct
DATA*



BI (Business Intelligence) et **AI (Artificial Intelligence)** sont deux concepts complémentaires qui jouent un rôle clé dans la gestion et l'analyse des données dans les entreprises.

BI (Business Intelligence) : La **BI** désigne les technologies, outils et pratiques utilisés pour **collecter**, **analyser** et **présenter** les données d'une entreprise afin d'**aider à la prise de décision**.

Objectifs :

- Fournir des rapports et tableaux de bord pour visualiser les performances.
- Aider à identifier les tendances, opportunités et risques.
- Faciliter les décisions basées sur les données (data-driven decisions).

Composants clés :

- **ETL (Extract, Transform, Load)** : Processus d'intégration des données.
- **Outils BI** : Power BI, Tableau, QlikView, etc.
- **Tableaux de bord et reporting** : Interfaces visuelles pour interpréter les données.

Exemple :

Un tableau de bord qui montre les ventes par région pour permettre à un directeur commercial de réorienter ses efforts là où les performances sont faibles.

BI (Business Intelligence) et **AI (Artificial Intelligence)** sont deux concepts complémentaires qui jouent un rôle clé dans la gestion et l'analyse des données dans les entreprises.

AI (Artificial Intelligence) : L'IA est un domaine de l'informatique qui vise à créer des systèmes capables de simuler l'intelligence humaine, comme **apprendre**, **raisonner** et résoudre des problèmes.

Objectifs :

- Automatiser des tâches complexes.
- **Prédire** des résultats futurs à partir de données historiques.
- Réaliser des analyses plus avancées grâce à l'apprentissage automatique (Machine Learning) et à l'apprentissage profond (Deep Learning).

Composants clés :

- **Machine Learning (ML)** : Modèles pour apprendre à partir des données.
- **Traitement du langage naturel (NLP)** : Compréhension et génération de langage humain.
- **Vision par ordinateur** : Analyse des images et vidéos.

Exemple :

Un système d'IA qui prédit les ventes d'un produit en fonction des tendances historiques et des conditions actuelles du marché.

BI (Business Intelligence) et **AI (Artificial Intelligence)** sont deux concepts complémentaires qui jouent un rôle clé dans la gestion et l'analyse des données dans les entreprises.


Complémentarité BI & AI

- La BI se concentre sur **l'analyse descriptive** (ce qui s'est passé) et l'analyse diagnostique (pourquoi cela s'est produit).
- L'IA permet d'aller plus loin avec **l'analyse prédictive** (ce qui va se passer) et **l'analyse prescriptive** (que devrions-nous faire).

Exemple d'intégration BI & AI :

Dans un outil de BI, des algorithmes d'IA pourraient être utilisés pour suggérer des stratégies en fonction des performances passées ou pour automatiser l'analyse des anomalies dans les données.

Les **décisions**, au sein d'une organisation, s'appuient sur **deux** types de **données rassemblées** : **Internes** (systèmes organisationnels) et **Externes** (provenant du web ou de sources tierces).



L'assemblage (**intégration**) des données devrait garantir des **données valides, complètes, homogènes et non contradictoires** (des données de **BONNE** qualité) pour des décisions éclairées [AI & BI = (A & B) I].

Données = Data ?


DoD : des Données aux Décideurs !

MACHINE LEARNING: From DATA to DECISIONS


UNDERSTANDING DATA



Collecting, Assembling,
Integrating data
Data cleaning






Data processing
PREDICTION, DEDUCTION,
CAUSAL INFERENCE,
DECISION MAKING



Think Bigger, Differently & Smarter by using correct DATA



Smart



BD-DB ; ED-DW-DL ; BigData

Exploration Informatique des Données et Décisionnel

PLAN BDA/ED

Introduction (Bases et Entrepôts de Données, Big-Data) :

La DATA (la Donnée)... !!! ; Introduction sur les données, leurs collectes et leurs traitements

(Quelques outils qui manipulent les Données ; Traitement des Données ; Quelques mots clés sur la Donnée ... DATA)

Catégories et Type de données ; Historique ; Nouveaux besoins, **SQL Avancé (Create, ..., Select..., Merge...)**

Conception & Modélisation des Bases et des Entrepôts de Données

Méta-Modélisation, Formalismes utilisés (ER, **EER, UML**, ...)

Expression & Cohérence des **contraintes** (**SQL_{2/3/...n}**, **PL/SQL**, OCL, **NoSQL...**)

Intégration de données ; différents types de **schémas**

Implantation (Implémentation) des Données

Relationnel-étendu, Orienté Objet (de **UML à SQL_{2/3/...n}**, JDBC, Java, **PL/SQL J...**)

Optimisation de Requêtes, Evaluation de Requêtes

Architecture de SGBD, **Administration** de BD

Qualité, Intégrité, Sécurité, Confidentialité, Anonymisation des données

Autres (BigData, Bases de Données, Entrepôts de données, Lacs de données, Master Data, Données structurées, Données NON structurées XML)

Gros volumes de données / **Entrepôts de données** / **Données Multi-Dimensionnelles** / **Référentiel** de données

Données Homogènes & **Hétérogènes**,

Données distribuées, Données Réparties, Données du Web, Données de type documents (**NON structurées**), ...

Lac de Données, Big Data, Masses de données, **Open Data**

Outils : Power AMC, Oracle, Talend, Business Objects, Tableau, Excel, MongoDB, MySQL, Hadoop/Spark...

Aujourd'hui, j'arrête de fumer !


Le TABAC t'ABAT !

**FUMER NUIT GRAVEMENT À TA SANTÉ ET
À CELLE DE TON ENTOURAGE !**

M T Dents !

SMILE and the World SMILES with you !





Sais-tu que ?

SIX NEUF

Ce n'est pas parce que tu as raison, que moi j'ai tort...
C'est juste que tu n'as pas le même point de vue que moi

f t d /SaisTuQuee

Le problème dont souffrent beaucoup de gens
The problem that many people are suffering

المشكلة التي يعانيها كثير من الناس



Donnée = Data !



Plusieurs nouveaux métiers en informatique

*Data Administrator,
Data Engineer, Data Manager,
Spécialiste Business Intelligence
Data Scientists...
Machine Learning Engineer...*



DATALOGUE ... en informatique !
(Cardiologie, Radiologie, Pneumologie, Psychologie... en médecine...)



Data Dealer !!!???

Dr. M. Faouzi BOUFARES

faouzi.boufares@sorbonne-paris-nord.fr

boufares@lipn.univ-paris13.fr

<http://www.lipn.univ-paris13.fr/~boufares/>

Laboratoire d'Informatique de Paris Nord (**LIPN**)


La Maison des Sciences Numériques (**MSN**)

Université Sorbonne Paris Nord – France (**USPN**)

1. La DATA [la (les) Donnée(s)]... !!!

Introduction sur les données, leurs collectes et leurs traitements

*Think **Bigger**, Differently & **Smarter** by using correct
DATA*




Smart



... Quelques outils qui manipulent les Données ...

... Traitement des Données ...



... Quelques outils qui manipulent les Données ...

... Traitement des Données ...




Brij Kishore Pandey




Save For Later

Types of Databases




... Quelques outils qui manipulent les Données ...

... Traitement des Données ...



... Quelques outils qui manipulent les Données ...

Traitement, Intégration & Exploitation des données ; Certains outils du marché




... Quelques mots clés sur la Donnée ... DATA

Smart

DB
DWH
DL
BI
CC
BD
MDM
DD
DM
ML
PR
OD
DC
DS

I
N
J
E
C
T
I
O
N
S
Q
L
D
A
T
A
D
E
A
L
E
R



Think Bigger, Differently & Smarter by using correct DATA



... Quelques mots clés sur la Donnée ... DATA



Data Science...
Data Scientist...

Expertise dans un domaine :


Un métier →

Médecine, Biologie, Géologie,
Finance, Marketing,
Ressources Humaines, Sport...

Expertise numérique en :

Analyses de données,
Statistiques, Probabilités,
Mathématiques...

Aux Décisions
de qualité !



Des Données
de qualité !

La
DATA
(la Donnée)
e(s)t le monde
de demain...
!!!

Think Bigger,
Differently &
Smarter by
using
DATA

Grande Expertise en Données (Gestion, Administration Exploration, Ingénierie)

Data Engineering,
Data & Knowledge Engineering,
Data Bases,
Data Integration,
Data Quality, Data profiling
Data WareHouses, Data Marts, Data Lakes,
Master Data, Golden Record,
Distributed Data, Heterogeneous Data,
Structured, Semi-Structured & UnStructured Data,
Big Data,
Cloud Computing, Web Services,
Data Center, Data Governance,
Open Data, Data Repository
Dark Data, Data Anonymisation, RGPD
Business Intelligence,
Data Visualization,
Data Mining, Machine Learning, Deep Learning
Prediction, Recommendation...
ETL, ELT, MDM, BI...




... Quelques mots clés sur la Donnée ... DATA


Collecte de la donnée Enrichissement de la données	Base de Données	Data Base
	Intégration de Données	Data Integration
	Qualité des Données	Data Quality
	Entrepôt de Données	Data WareHouse
	Lac de Données	Data Lake
	Masse de Données	Big Data
	Référentiel de Données	Master Data
	Données dormantes, Données ouvertes	Dark Data, Open Data
	Centre d'accueil des données	Data Center
	General Data Protection Regulation (GDPR)	
Traitement de la donnée	Informatique décisionnelle	Business Intelligence
	Fouille de Données	Data Mining
	Prédiction/Anticipation/Recommandation	Prediction/Recommandation
	Intelligence Artificielle, Apprentissage profond	Machine Learning, Deep Learning
	Apprentissage Automatique	Machine Learning
	Règlement Général sur la Protection des Données (RGPD)	
Nouveaux Métiers	Corriger, Enrichir et Visualiser les données	Correct, Enrich and Visualize data
	Calculer sans limite	Cloud Computing
	La science des données	Data Science
	Ingénieur des données	Data Scientist

Ingénierie des données
Data engineering

Ingénierie des connaissances
Knowledge Engineering



... Quelques mots clés sur la Science des Données ... DATA SCIENCE



*Comprendre le passé
pour anticiper sur le futur !
Understanding the past
to anticipate the future!*

Expertise in a domain (a profession, a trade, a business)
Expertise dans un domaine (un métier, une profession)

Medicine, Pharmacy, Biology, Chemistry, Geology, Finance, Marketing, Human Resources ...
Médecine, Pharmacie, Biologie, Chimie, Géologie, Finances, Marketing, Ressources Humaines ...

**Think Bigger, Differently
& Smarter by using correct
DATA**

Smart



... Les Données & leurs traitements ...



... ???

Les données et leurs traitements intelligents constituent un nouvel outil d'aide à la décision dans quasiment tous les domaines et tous les secteurs d'activité !

Comment exploiter-explorer automatiquement les données afin d'expliquer des phénomènes ?

Comment apprendre automatiquement à partir des données et des observations ?

Comment ... ? Prédire, Prévoir, Prévenir, Calculer un Risque, Diagnostiquer, Recommander...

Une nouvelle science ; De nouveaux métiers



*Think **Bigger**,
Differently & **Smarter**
by using correct **DATA***

... Les Données & leurs traitements ...

Think Bigger,
Differently & Smarter
by using correct DATA



Une nouvelle science ; De nouveaux métiers

A l'ère du déluge des données, la qualité des données est plus que jamais à l'ordre du jour :

(données de productions ; données du Web ; données ouvertes -*Open Data*- ; données dormantes non encore utilisées -*Dark Data*- beaucoup de données textuelles non structurées documentaires ; les *Big Data* ; ...).

En effet, de nos jours, tout type d'organisation a besoin **d'intégrer (collecter, assembler) des données** en provenance de **diverses sources distribuées, hétérogènes et de qualités variables**.

Le plus souvent, les **descriptifs des données**, dans les sources, sont **mal renseignés** voire **inexistants**.

Par conséquent, **l'assemblage des données peut être dénué de tout sens** et le **résultat obtenu peut contenir de nombreuses anomalies**.




... Les Données & leurs traitements ...

Une nouvelle science ; De nouveaux métiers



- **Données internes** (Opérationnelles de production)
 - Bases de données (Structurées et Non structurées)
 - Fichiers (Plats, Textes, CSV, PDF...)
 - Applications (Paye, Gestion des RH, Commandes & Facturations...)
- **Données externes** (Web, Open Data, Dark Data, ...)
- **Caractéristiques** de ces données
 - Distribuées
 - Hétérogènes (systèmes et structures de données différents)
 - Détaillées (peu ou pas adaptées à l'analyse)
 - Qualité très variable (plutôt mauvaise, plusieurs anomalies)



...Des questions sur la Data, Les Données?...



Qu'est-ce une donnée ?

Comment la collecter ?

(Comment l'avoir, à quelle fréquence/vitesse ? Quel est son type ?
Est-elle pertinente ? Est-elle Obsolète ?...)

*Think **Bigger**, Differently
& **Smarter** by using correct
DATA*

Quelle est sa qualité ? (Des données de bonne qualité engendrent des décisions de qualité)

Comment va-t-on la gérer automatiquement ? Comment va-t-on la stocker et où la stocker ?

Quel droit (Qui fait quoi et Quand ?, Quelles sont les conséquences ?) ; Sécurité, Confidentialité, Anonymisation, Piratage (RGPD) !

Qu'est-ce que l'on va en faire ? Quel est (serait) le retour sur investissement (ROI) ?

Comment la traiter (Comment l'exploiter ?, Comment la transformer ?)

Comment apprendre à partir des données ? → De la donnée au Savoir, à l'information, à la connaissance, à la décision ?



Peut-on faire confiance aux données brutes ?

Etant donné une Source de Données CSV, JSON, Contient-elle des **anomalies**, Comment évaluer **sa qualité**, sa valeur, son **score** ? (Given a CSV or JSON Data Source, does it contain anomalies, how to evaluate its quality, its value, its score?)



[DATA & QUALI-SCORE ?]

A CSV File , A Table, A Data Source, A Data Base	
LIONEL;M;A+;Barcelona;SPAIN;1;messi@gmail.com	
AD@MA;M;A+;barcelona;SPAIN;1;ad@ma@gmail.com	
EVE;F;B+;Paris;FRANCE;2;eve@gmail.com	
ISABELLE;f;O-;Paris;France ;4;bon@hotmail.com	
James;M;;Londre;;3;blonde@hotmail.com	
CHARLIE;;AB+;London;UNITED KINGDOM;;chapple1@hotmail.com	
KILIAN ;M;A++;Paris;---;3;m'ba-p@gmail.com	
Karim;M;A;Madrid;SPAIN;4;lebonfoot@yahoo.fr	
ADAM;M;a+;paris;ITALY;1000;adam@yahoo	
LEE;m;x;Seoul;SOUTH KOREA;3;moon@gmail.com	
ZHANG;F;B+;Pékin;CHINE ;2;ziyiyizi@gmail.com	
GONG;F;O+;Beijing;CHINA;3;li-li@gmail.com	
AAA;;a+;Beijing;CHINA;;messi@gmail.com	
CHARLO;M;AB+;London;UK;3;chaplin@hotmail.com	
NomStar;S;GS;Vil;Pays;CA;Mel	
The original data source that can contain anoamlies (dirty data)	
Liste des STARS de Cinéma & de Football	
List of Movie & Football STARS	

... ???

Les données **CORRECTES (SANS ANOMLIE)** et leurs **traitements intelligents** constituent un nouvel **outil d'aide à la décision** dans quasiment tous les domaines et **tous les secteurs d'activité** !

Comment **exploiter-explorer au mieux** les données afin d'**expliquer des phénomènes** ?

Comment **apprendre automatiquement (Intelligence Artificielle)** à partir des données et des observations ?

Comment **Prédire, Prévoir, Prévenir, Calculer un Risque, Diagnostiquer, Recommander ... ?**



La donnée e(s)t le monde du futur ! Les données changent la donne !	
Think by using	Bigger
	Differently
	Smarter
	Correct
	Data



Peut-on faire confiance aux données brutes ?

Etant donné une Source de Données CSV, Contient-elle des **anomalies**, Comment évaluer **sa qualité**, sa valeur, son **score** ?
Given a CSV Data Source, does it contain anomalies, how to evaluate its quality, its value, its score?


Données CSV éclatées en colonnes... à la découvertes des anomalies (erreurs?) !

A CSV File , A Table, A Data Source, A Data Base						
LIONEL;M;A+;Barcelona;SPAIN;1;messi@AD@MA;M;A+;barcelona;SPAIN;1;ad@nEVE;F;B+;Paris;FRANCE;2;eve@gmail.comISABELLE;f;O-;Paris;France ;4;bon@hotmail.comJames;M;;Londre;;3;blonde@hotmail.coCHARLIE;;AB+;London;UNITED KINGDOMKILIAN ;M;A++;Paris;---;3;m'ba-p@gmKarim;M;A;Madrid;SPAIN;4;lebonfoot@ADAM;M;a+;paris;ITALY;1000;adam@yLEE;m;x;Seoul;SOUTH KOREA;3;moon@gZHANG;F;B+;Pékin;CHINE ;2;ziyiyizi@gmGONG;F;O+;Beijing;CHINA;3;li-li@gmail.cAAA;;a+;Beijing;CHINA;messi@gmail.coCHARLO;M;AB+;London;UK;3;chaplin@h	A CSV File , A Table, A Data Source, A Data Base					
LIONEL	M	A+	Barcelona	SPAIN		1 messi@gmail.com
AD@MA	M	A+	barcelona	SPAIN		1 ad@ma@gmail.com
EVE	F	B+	Paris	FRANCE		2 eve@gmail.com
ISABELLE	f	O-	Paris	France		4 bon@hotmail.com
James	M		Londre			3 blonde@hotmail.com
CHARLIE		AB+	London	UNITED KINGDOM		chapple1@hotmail.com
KILIAN	M	A++	Paris	---		3 m'ba-p@gmail.com
Karim	M	A	Madrid	SPAIN		4 lebonfoot@yahoo.fr
ADAM	M	a+	paris	ITALY	1000	adam@yahoo
LEE	m	x	Seoul	SOUTH KOREA		3 moon@gmail.com
ZHANG	F	B+	Pékin	CHINE		2 ziyiyizi@gmail.com
GONG	F	O+	Beijing	CHINA		3 li-li@gmail.com
AAA		a+	Beijing	CHINA		messi@gmail.com
CHARLO	M	AB+	London	UK		3 chaplin@hotmail.com
NomStar	S	GS	Vil	Pays	CA	Mel
The original data source that can contain anomalies (dirty data)						
Liste des STARS de Cinéma & de Football List of Movie & Football STARS						




... Des questions sur La Data, Les Données ? ...

Think *Bigger*, *Differently*
& *Smarter* by using
correct *DATA*



How to **detect**,
automatically,
the **abnormal** data ?



How to **correct**, **automatically**,
these **anomalies** without creating
new ones?



...Des questions sur La Data, Les Données?...

Think **Bigger**, **Differently**
& **Smarter** by using
correct **DATA**




Anomalies détectées

Attention aux Mises à Jour


Anomalies corrigées



How to **detect**,
automatically,
the **abnormal** data ?



How to **correct**, **automatically**,
these **anomalies** without creating
new ones?



...Des questions sur La Data, Les Données?...





Think **Bigger**,
Differently
& **Smarter** by
using correct
DATA

C1	C2	C3	C4	C5	C6	C7	C8	C9
Id1	M. Adam SERAFOUB	M	19-juin-2001	A+	Paris	France	2 000 €	adam.serafoub@gmail.com
Id2	Mme Inès BEN	F	22-novembre-1999	B+	Londres	Royaume-Uni	3 000 €	inès.ben@gmail.com
Id3	Mme Clémence RAHMA	F	16-octobre-1996	A+	Paris	France	2 000 €	clémence.rahma@gmail.com
Id4	M. Alex LEGRAND	M	17-septembre-1987	AB+	Paris	France	3 000 €	alex.legrand@gmail.com
Id5	M. Lilian M BA P	M	18-septembre-1987	AB+	Paris		10 000 €	lilian.m ba p@gmail.com
Id6	M. Lionel MAICI	F	25-décembre-1985	O+	Barcelone	Espagne	12 000 €	maicimainon@hotmail.com
Id	PrenomNOM	Genre	DateNaissance	GrpSanguin	VilleNaissance	PaysNaissance	CA	Email

Pays	Total du chiffre d'affaires
Espagne	12 000 €
France	7 000 €
Royaume-Uni	3 000 €
(vide)	10 000 €
Total général	32 000 €

Sexe	Total du chiffre d'affaires
F	17 000 €
M	15 000 €
Total général	32 000 €



...Des questions sur La Data, Les Données?...



Think **Bigger**,
Differently
& **Smarter** by
using **correct**
DATA


C1	C2	C3	C4	C5	C6	C7	C8	C9
Id1	M. Adam SERAFOUB	M	19-juin-2001	A+	Paris	France	2 000 €	adam.serafoub@gmail.com
Id2	Mme Inès BEN	F	22-novembre-1999	B+	Londres	Royaume-Uni	3 000 €	inès.ben@gmail.com
Id3	Mme Clémence RAHMA	F	16-octobre-1996	A+	Paris	France	2 000 €	clémence.rahma@gmail.com
Id4	M. Alex LEGRAND	M	17-septembre-1987	AB+	Paris	France	3 000 €	alex.legrand@gmail.com
Id5	M. Lilian M BA P	M	18-septembre-1987	AB+	Paris	France	10 000 €	lilian.m ba p@gmail.com
Id6	M. Lionel MAICI	M	25-décembre-1985	O+	Barcelone	Espagne	12 000 €	maicimainon@hotmail.com
Id	PrenomNOM	Genre	DateNaissance	GrpSanguin	VilleNaissance	PaysNaissance	CA	Email

Pays	Total du chiffre d'affaires
Espagne	12000
France	17000
Royaume-Uni	3000
Total général	32000

Sexe	Total du chiffre d'affaires
F	5 000 €
M	27 000 €
Total général	32000

Total du chiffre d'affaires


Total du chiffre d'affaires par pays



C. ▾

Total du chiffre d'affaires

Total du chiffre d'affaires par sexe



...Des questions sur Les Données, La Data?...



Think **Bigger**,
Differently
& **Smarter** by
using **correct**
DATA

Meta-Data
Dictionaries

Dr. Smart DATA

DB : Data Base

DS : Data Source

CSV X

Data Base Checklist

☒	Normal Forms
☐	Missing Values
☒	Heterogeneity
☒	Functional Dependencies
☒	Analysis Metrics
☐	 Duplicates

DATALOGUE

QUALI-SCORE

A B C D E

Smart DATA

iDQMS: an Intelligent Data Quality Management System

Think **Bigger**, Differently & **Smarter**
by using **correct** DATA

A B C D E

QUALI-SCORE

Smart DATA

iDQMS : intelligent Data Quality Management System




...Des questions sur La Data, Les Données?...



Data INTEGRATION TO *Think Bigger, Differently & Smarter*

Zone de préparation




Intégration


ETL - ELT

MDM

Zone de stockage de données massives



Zone de présentation




**The better the quality of the data,
the better it can be used for analyses**



... Les nouveaux métiers de la Data ! ...

... Data Science & Data Scientist ...

Des Données aux Décideurs ; L'ingénierie des données



*Think **Bigger**,
Differently & **Smarter**
by using correct
DATA*



... Les Données et le Cloud ...

Smart



Les données sont **Massives**, **Hétérogènes** et **Distribuées**.




Big Data (BD) + Cloud Computing (CC)

=

Thinking Differently, Bigger and Smarter (TDBS)

BD + CC = TDBS




... Les Données ... Big Data – Les n V...




Les données sont **Massives**, Hétérogènes et **Distribuées**.

Les données peuvent être de Qualité très variable (plutôt mauvaise ; plusieurs anomalies).



	From...	...to
Volume	Internal (terabyte)	External (petabyte)
Velocity	Batch	Real time
Variety	Structured	Unstructured
Visualization	Static	Dynamic
Value creation	Reporting and compliance	Strategic asset / Competitive advantage





... Les n V... n=3, 4, 5 ou plus ?



... Les Données ... Big Data – Les n V...


La Donnée et sa Qualité



... Des Données ... Aux décideurs !

Qualité des données et décisionnel !

Smart




... Des Données ... Aux décideurs !

Rassembler des **Données** de Qualité

Donner un sens aux données rassemblées

Enrichir les données...



Explorer des Données Massives

Intelligence Artificielle, Apprentissage, Fouille



Prendre les Bonnes **Décisions**

Data Scientist !

*Think **Bigger**, **Differently** & **Smarter**
by using correct **DATA***

... Des Données ... Aux décideurs !

Expert en Gestion des Données

(Data Base, Data WareHouse, Data Lake, Big Data...)


**Expert en Analyse de Données
et en Statistiques**

**Expert dans un domaine d'activité
(Un métier : Médecine, Biologie,
Finance, Tourisme, Sport &
Football...)**

Data Scientist !

*Think **Bigger**,
Differently & **Smarter**
by using correct
DATA*

... Des Données ... Aux décideurs !



Le rôle du Data Scientist !



BD (Bases de Données) + ED
(Entrepôts de Données) + LD (Lac
de Données) ; Référentiel de
Données, Big-Data (Grosses
Masses de Données)

Des **Données**

Smart

ML (Machine Learning)
Apprentissage, **DL** (Deep Learning) ;
FD (Fouille de données),



Extraction d'Informations et de Connaissances

*Aider à la prise de décision,
Diagnostiquer, Comprendre des phénomènes,
Classifier,
Etudier les risques, Améliorer la gestion,
Prévenir, Guider, Recommander ...*

Aux **Décideurs**


Rassembler-Intégrer les données ...!

Au niveau organisationnel → Un seul référentiel des données (Master Data) !



... Intégration de Données ...

Smart



Comment

Fusionner/Assembler/Intégrer

toutes ces BD, toutes ces données ?


Quels sont les problèmes ?

- Quel **sens** (sémantique) ?
- Quelle **Qualité** ?
- Quel est l'objectif (quel **but**) ?




... Intégration de Données ...

Smart



... Intégration de Données ...

Smart



... Intégration de Données ...



Donner un SENS aux données rassemblées... Attention aux anomalies!

**Conformes à
la sémantique
supposée**

Cohérentes

Sans faute
d'orthographe

Sans doublon
ni similaire

Complètes

Fiables


Non nulles

Non
aberrantes

À jour
Non obsolètes



... Intégration de Données ...



Donner un SENS aux données rassemblées

De nombreuses questions, relatives à la **qualité**, doivent être posées au cours du **processus d'intégration** :

- * **Compatibilité** des types de données (**syntaxique**)
- * **Compatibilité sémantique**
- * Les contraintes sur les données
- * Transformer / Corriger / Nettoyer / Valider des données
- * Enrichir / Compléter les données
- * Gérer les dépendances sémantiques
- * Gérer les Doubles & les Similaires
- * Gérer les métadonnées

→ **Comment le savoir ?**

→ La **syntaxe** oui mais plus de **sémantique** !

... Intégration de Données ...


Smart

Données Hétérogènes ;
Niveaux de descriptions différents ; Peu ou pas du tout de description ;
Absence de sémantique ; Qualité variable... !

E1;RAMA;Inès;F;M;ETINCELLE;12/09/1991;Barcelone;Espagne;10/10/2018;inès.rama@gmail.com;171 cm;2017;EID2;18;16;13;10;7;11;5;12/09/1991
E2;TRAIFOR;Adam;M;C;1;28/07/1994;Paris;France;12/12/2018;adam.traifor@gmail.com;1.89 m;2017;EID2;12;1300000000;9;15;10;12;28/07/1994
E3;NISSAN;Miam;M;D;1;11/11/1991;miam.nissan@gmail.com;165 cm;2017;EID2;13;11;7;11;9;10;?
E4;RENO;Aline;F;M;1;18/12/1984;Paris;France;18/12/1984;aline.reno@gmail.com;188;2017;PLS;13;12;15;18/12/1984
E5;FIATE;Edite;F;M;SIATE;02/01/1998;Rome;Italie;19/09/2018;edite.fiate@gmail.com;1.92m;2017;PLS;11;10;11;16;02/01/1998
E6;MERZEDES;F;M;BLENZ;24/10/1998;Munich;Allemagne;19/09/2018;MERZEDES@hotmail.com;1660 mm;2018;EID2;14;16;14;15;11;16;10
E7;BEYEMEV;Aimé;M;M;1;Munich;Allemagne;Aimé.BEYEMEV@lpln.fr;1.89 m;2018;EID2;9;12;11;11;15;?
E8;FORD;Harissa;F;M;Pékin;25/01/1990;Pékin;France;11/10/1995;harissa.ford@yahoo.fr;1.89 m;2018;EID2;17;14;0;00000005;10;7;16;11/10/1995
E9;MINI;Ostine;F;M;CAR;11/10/1995;Royaume-Uni;Ostine.mini@yahoo.fr;1.77 m;2018;EID2;17;14;0;00000005;10;7;16;11/10/1995
E10;FERRARI;Ala;M;C;1;19/09/1958;Ala.ferrari@yahoo.fr;1234567890;2018;EID2;17;16;12;9;13;19/09/1958
E11;LONDRE;Boby;M;C;1;20/09/1958;Londre;RU;Boby.londre@yahoo.fr;0;2018;EID2;17;13;10;9;10;20/09/1958
E12;LONDON;Elisabeth;F;LONDON;21/09/1958;London;United-Kingdom;elisabeth.london@gmail.com;0;2018;PLS;10;11;21/09/1958
E13;SUZUKI;Lee;F;V;22/09/1958;Beijing;China;lee.suzuki@gmail.com;0;2018;PLS;1300000000;16;12;22/09/1958
E14;COOK;Thom;M;C;1;17/09/1958;London;UK;thom.cook@gmail.com;0;2018;PLS;15;12;17/09/1958
E15;LONDRES;John;M;C;1;16/10/1996;London;UK;john.londres@gmail.com;171 cm;2018;PLS;12;16;10/1996
E16;LONDRES;J;M;C;1;17/10/1996;London;England;17/10/2017;j.londres@gmail.com;1.89 m;2018;PLS;11;14;17;17/10/1996
E17;LONDRES;Jane;F;C;1;20/11/1994;London;England;17/10/2017;jane.londres@gmail.com;165 cm;2018;PLS;11;15;20/11/1994
E18;LONDRES;J;F;C;1;LONDON;17/10/2017;j.londres@gmail.com;188 cm;2018;PLS;1300000000;1300000000;14;?
E19;ABANDON;Obsolète;F;M;BEN OIT;18/02/1900;Paris;France;22/02/2019;obsolète.abandon@gmail.com;1.92m;2018;PLS;11;14;18/02/1900
E20;TRON PEU;Donald;M;M;1;17/09/1900;Paris;FR;22/02/2019;donald.tron peu@gmail.com;1.92m;2018;PLS;11;14;18/09/1900



ID	NOM	PRENOM	GENRE	STATF	NIF	DN	VN	PN	DM	MEL	TAIL	PROMO	M2	BDA	DWH	JAVA	ENG	DL	RN	FT	DN2
E1	RAMA	Inès	F	M	ETINCELLE	12/09/1991	Barcelone	Espagne	10/10/2018	inès.rama@gmail.com	171 cm	2017	EID2	18	16	13	10	7	11	5	12/09/1991
E2	TRAIFOR	Adam	M	C	1	28/07/1994	Paris	France	12/12/2018	adam.traifor@gmail.com	1.89 m	2017	EID2	12	1.3E+09	9	15	10	12	28/07/1994	
E3	NISSAN	Miamie	M	D	1	?	Paris	?	11/11/1991	miamie.nissan@gmail.com	165 cm	2017	EID2	13	11	7	11	9	10	?	?
		Aline	F	M	?	18/12/1984	Paris	France	18/12/1984	aline.reno@gmail.com	188	2017	PLS			13	12	15		18/12/1984	
		Editte	F	?	SIATE	02/01/1998	Rome	Italie	19/09/2018	edite.fiate@gmail.com	1.92m	2017	PLS			11	10		11	16	02/01/1998
		?	F	M	BLENZ	24/10/1998	Munich	Allemagne	19/09/2018	?MERZEDES@hotmail.com	1660 mm	2018	EID2	14	16	14	15	11	16	10	24/10/1998
		Aimé	M	M	1	?	Munich	Allemagne	?	?	?	?	?	?	?	?	?	?	?	?	1990
		Harissa	?	?	?	25/01/1990	Pékin	?	?	?	?	?	?	?	?	?	?	?	?	?	1995
		Ostine	F	M	CAR	11/10/1995	?	Royaume-Uni	?	?	?	?	?	?	?	?	?	?	?	?	1956
		Ala	M	C	1	19/09/1958	?	?	?	?	?	?	?	?	?	?	?	?	?	?	1956
E11	LONDRE	Boby	M	C	1	20/09/1958	Londre	RU	?	?	?	?	?	?	?	?	?	?	?	?	1956
E12	LONDON	Elisabeth	F	?	LONDON	21/09/1958	London	United-Kingdom	?	?	?	?	?	?	?	?	?	?	?	?	1958
E13	SUZUKI	Lee	F	V	?	22/09/1958	Beijing	China	?	?	?	?	?	?	?	?	?	?	?	?	1958
E14	COOK	Thom	M	C	1	17/09/1958	London	UK	?	?	?	?	?	?	?	?	?	?	?	?	1958
E15	LONDRES	John	M	C	1	16/10/1996	London	UK	?	?	?	?	?	?	?	?	?	?	?	?	1996
E16	LONDRES	J	M	C	1	17/10/1996	London	England	17/10/2017	j.londres@gmail.com	1.89 m	2018	PLS	11	14	17	17	10	1996	1996	
E17	LONDRES	Jane	F	C	1	20/11/1994	London	England	17/10/2017	jane.londres@gmail.com	165 cm	2018	PLS	11	15	20	11	1994	1994	1994	
E18	LONDRES	J	F	C	1	?	London	United-Kingdom	17/10/2017	j.londres@gmail.com	188 cm	2018	PLS	1300000000	1300000000	14	?	?	?	?	1900
E19	ABANDON	Obsolète	F	M	BEN OIT	18/02/1900	Paris	France	22/02/2019	obsolète.abandon@gmail.com	1.92m	2018	PLS	11	14	18	02	1900	1900	1900	
E20	TRON PEU	Donald	M	M	1	17/09/1900	Paris	FR	22/02/2019	d	?	?	?	?	?	?	?	?	?	?	1900



Quel est le sens de chaque colonne ?
Y-a-t-il des erreurs syntaxiques et sémantiques dans les colonnes ?
Y-a-t-il des liens sémantiques entre les colonnes (dépendances)?
Y-a-t-il de la cohérence/incohérence entre les colonnes ?
Y-a-t-il des liens sémantiques entre les lignes (doublons, similaires) ? ...

Comment le savoir ? Comment les détecter et les corriger automatiquement ?



...Des questions sur Les Données, La Data?...



Think **Bigger**,
Differently
& **Smarter** by
using **correct**
DATA

Meta-Data
Dictionaries

DB : Data Base
DS : Data Source

CSV X

Dr. Smart DATA

Data Base Checklist

☒	Normal Forms
☐	Missing Values
☒	Heterogeneity
☒	Functional Dependencies
☒	Analysis Metrics
☐	Duplicates

DATALOGUE

QUALI-SCORE

ABCDE

Smart DATA

iDQMS: an Intelligent Data Quality Management System

Think **Bigger**, Differently & **Smarter**
by using **correct** DATA

ABCDE

QUALI-SCORE

Smart DATA

iDQMS : intelligent Data Quality Management System



Donner un sens aux Données rassemblées!... Anomalies!



Des anomalies lors
de l'intégration des
données :

**Données
incorrectes**

Doublons

Similaires

Valeurs nulles

Etc...



BD1-Cli						
NomCli	PrénomCli	Catégorie	Score	Type	Adresse	Mail
C(20)	C(20)	F, M	[0..20]	1, 2, 3	C(150)	C(200)

Le Bon	Adam	M	19	1	2, r de la Paix 75008 Paris France	adm@yahoo.fr
Clément	Clémence	F	16	2	5, r de Belleville 75019 Pari Franc	cc@gmail.fr
Premier	Inès	F	7	2	27, r de la Paix 75008 Paris	tti@yahoo.fr

BD2-Clients						
Nom	Prénom	Sexe	Note	CatégSoc	AdrPays	Courriel
C(30)	C(30)	N(1) !	[0..10]	A, B, C, D, E	C(50)	C(100)

Le Bon	Adamo	1	9	A	France	adm@yahoo.fr
Clément	Lina	0	7	E	France	clina@orange.fr
First	Inès	0	3	A	Espagne	cmoi@gmail.com
Adem	LeBon	1	8	A	France	adm@yahoo.fr

ED Résultat de l'intégration Cli-Clients						
Nom	Prénom	Sexe	Score	CatégSoc	Pays	Mail
C(20)	C(20)	F, M	[0..20]	1, 2, 3	C(150)	C(200)
C(30)	C(30)	N(1) ! 0,1	[0..10]	A, B, C, D, E	C(50)	C(100)

Le Bon	Adam	M	19	1	2, r de la Paix 75008 Paris France	adm@yahoo.fr
Clément	Clémence	F	16	2	5, r de Belleville 75019 Pari Franc	cc@gmail.fr
Premier	Inès	F	7	2	27, r de la Paix 75008 Paris	tti@yahoo.fr
Le Bon	Adamo	1	9	A	France	adm@yahoo.fr
Clément	Lina	0	7	E	France	clina@orange.fr
First	Inès	0	3	A	Espagne	cmoi@gmail.com
Adem	LeBon	1	8	A	France	adm@yahoo.fr



Donner un sens aux Données rassemblées! ... Anomalies!

 Plusieurs types d'anomalies dans les données (>50% d'anomalies)

Intra-Colonne, Inter-Colonnes et Inter-Lignes

Clients						
	Nom Prénom	Téléphone	Mail	Catégorie	Ville	Chiffre d'affaires
t1	Le Bon Adam	0653545577	adam@yahoo.fr	1	Londres	1000
t2	Le Bon A.	0653545555	-	1	London	2000 £
t3	Grande Clémence	0607080911	clemence@gmail.com	2	Epinay sur seine	1000
t4	Adam LeBon	0653545555	adam@yahoo.fr			
t5	Grande Clémence	607080911	clemence@gmail.com	2	Epinay / seine	1000
t6	Le Bon	0653545577	adam@yahoo.fr	1	Londres	-
t7	Belle Inès	0708091122	belleines@yhoo.fr	3	Epinay-Villetaneuse	3000
t8	Rahma Adam	-	-	3	Epinay-sur-seine	1000
t9	Riche Emir	0908070605	-	3	Qatar	20000000000
t10	Traifor Eve	0666622223	traifor@up13.fr	1	Pékin	1000
t11	Traifor Eve	0666622223	traifor@up13.fr	1	Beijing	1000
t12	LeBon Adel	0653545599	alebon@up13.fr	1	Paris	-
t13	LeBon Adem	-	adam@obsolete.uk	1	Londre	-



Des SIMILAIRES

Des DOUBLONS



Des données obsolètes



Donnée NON Standard

Donnée NON Standard

Donnée NON Valide



Des valeurs aberrantes

- Les algorithmes, pour les corriger, **sont très coûteux en terme de temps de réponse**
- Comment savoir ? Ce qu'il y a à corriger / Ce qu'il faut corriger / Comment corriger ?



Donner un sens aux Données rassemblées! ... Anomalies!



Qualité des Données : **Elimination des doubles et des similaires**

Doubles ? Similaires ? <<<>>>>> **Vrais - Faux amis !** <<<>>>>> **Faux - Vrais amis !**

BD ACM →→→ ID;Title;Authors;Venue;Year

564753;A compact B-tree;Peter Bumbulis, Ivan T. Bowman;International Conference on Management of Data;2002

872806;A theory of redo recovery;David Lomet, Mark Tuttle;International Conference on Management of Data;2003

BD DBLP →→→ ID;Title;Authors;Venue;Year

conf/sigmod/BumbulisB02;A compact B-tree;Ivan T. Bowman, Peter Bumbulis;SIGMOD Conference;2002

conf/sigmod/LometT03;A Theory of Redo Recovery;Mark R. Tuttle, David B. Lomet;
SIGMOD Conference;2003

conf/sigmod/DraperHW01;The Nimble Integration Engine;Daniel S. Weld, Alon Y. Halevy, Denise Draper;SIGMOD
Conference ;2001

Attention

**Exemple d'intégration de données dans le domaine de la bibliographie.
Traitement des doubles et des similaires**



Donner un sens aux Données rassemblées! ... Anomalies!

 **Qualité des Données : Elimination des doubles et des similaires**

Doubles ? Similaires ? <<<>>>> Vrais - Faux amis ! <<<>>>> Faux - Vrais amis !



Des questions sur La Data, Les Données?...



Think Bigger,
Differently
& Smarter
using DAT

Smart DATA
idOMS : intelligent Data Quality Management System

M. F. B.

DIAGNOSTIC OF DATA SOURCE

CLIENTS

	A	B	C	D	E	F	G	H	I	J	K	L
1	C001	Madame	CLEM@ENT	EVE	1	18	BOULEVARD FOCH	91000	EPINAY-SUR-ORGE	FRANCE	eve.clement@gmail.com	+33777889911
2	C002	Madame	LESEUL	M@RIE	1	17	AVENUE D'ITALIE	75013	PARIS	FRANCE	marieleseul@yahoo.fr	0617586565
3	C003	Madame	UNIQUE	Marine	2	77	RUE DE LA LIBERTE	13001	MARCHEILLE	FRANCE	munique@gmail.com	+33717889922
4	C004	Madame	CLEMENCE	EVELYNE	3	88	BOULEVARD FOCH	93800	EPINAY-SUR-SEINE	FRANCE	clemence.evelyne@gmail.com	+33777889933
5	C005	Madame	FORT	Jeanne	3	55	RUE DU JAPON	94310	ORLY-VILLE	FRANCE	jfort\@hotmail.fr	+33777889944
6	C006	Mademoiselle	LE BON	Clémence	1	18	BOULEVARD FOCH	93800	EPINAY-SUR-SEINE	FRANCE	clemence.le.bon@cfo.fr	+33777889955
7	C007	Mademoiselle	TRAIFOR	Alice	2	6	RUE DE LA ROSIERE	75015	PARIS	FRANCE	alice.traifor@yahoo.fr	+33777889966
8	C008	Monsieur	VIVANT	JEAN-BAPTISTE	1	13	RUE DE LA PAIX	93800	EPINAY-SUR-SEINE	FRANCE	jeanbaptiste@	607
9	C009	Monsieur	CLEMENCE	Alexandre	1	5	RUE DE BELLEVILLE	75019	PARIS	FRANCE	alexandre.clemence@up13.fr	+33149404071
10	C010	Monsieur	TRAIFOR	Alexandre	1	17	AVENUE FOCH	75016	PARIS	FRA	alexandre.traifor@up13.fr	6070809
11	C011	Monsieur	PREMIER	JOS//EPH	2	77	RUE DE LA LIBERTE	13001	MARCHEILLE	FRANCE	josef@premier	+33777889977
12	C012	Monsieur	CLEMENT	Adam	2	13	AVENUE JEAN BAPTISTE CLEMENT	9430	VILLETANEUSE	FRANCE	adam.clement@gmail.com	+33149404072
13	C013	Monsieur	FORT	Gabriel	5	1	AVENUE DE CARTAGE	99000	TUNIS	TUNISIE	gabriel.fort@yahoo.fr	+21624801777
14	C014	Monsieur	ADAM	DAVID	5	1	AVENUE DE ROME	99001	ROME	ITALIE	david.adame@gmail.com	
15	C015	Monsieur	Labsent	pala	7	1	rue des absents	0	BAGDAD	IRAQ	pala-labsent@paici	
16	C016	Madame	obsolete	kadym	7	1	rue des anciens	0	CARTHAGE	IFRIQIA	inexistant	inexistant
17	C017	Madame	RAHYM	Karym	1	1	RUE DES GENTILS	1000	CARTHAGE	TUNISIE	karym.rahym@gmail.com	+21624808444
18	C018	Madame	GENIE	ADAM	3	8	BOULEVARD FOCH	93800	EPINAY SUR SEINE	FRANCE	adam.genie@gmail.com	+33777889911
19	C118	Madame	GENIE	Adam	3	8	BOULEVARD FOCH	93800	EPINAY SUR SEINE	FRANCE	adam.genie@gmail.com	+33777889911
20	C119	Madame	UNE	Marie	1	17	AVENUE D'ITALIE	75013	PARIS	FRANCE	marieune@gmail.com	0617586575
21	C120	Madame	1	MARIE	1	17	AVENUE D'ITALIE	75013	PARIS	FRANCE	MARIEUNE@GMAIL.COM	0617586575
22	C121	Monsieur	2 PAR 2	Girard	1	27	AVENUE D'ITALIE	75013	PARIS	FRANCE	2PAR2@GMAIL.COM	0617586577
23	C122	Monsieur	DE PAR DE	GIRARD	1	27	AVENUE D'ITALIE	75013	PARIS	FRANCE	2PAR2@GMAIL.COM	0617586577
24	C123	Monsieur	DE PAR DE	GIRARD	1	27	AVENUE D'ITALIE	75013	PARIS	FRANCE	2PAR2@GMAIL.COM	0617586577
25	C124	Monsieur	DE PAR DE	Girard	1	27	AVENUE D'ITALIE	75013	PARIS	FRANCE	2PAR2@GMAIL.COM	0617586577

Evaluation de la Qualité de la source de données

Données
inValides;
145; 48%

Données
VALIDES;
155; 52%



Smart



64

... Les catégories des Données ...

Smart

Les données, de nos jours, sont **Massives**, **Hétérogènes** et **Distribuées**.




Les données peuvent être de **Qualité** très variable

(plutôt mauvaise ; **plusieurs anomalies**).

Les données peuvent être :

- **Structurées**
- **Semi-Structurées**
- **NON-structurées**



Les Données ... Une vieille histoire ! ...

Historique des types, des modèles et des systèmes de Gestion !

Vers de nouvelles générations de Systèmes de Gestion de Données !?
Quelle génération ??? 3^e, 4^e, 5^e ... ou Nième !!!

Système de Gestion de Bases de Données (SGBD) ; **Data Base Management System (DBMS)**

Base de Données (BD) ; **Data Base (DB)**

Entrepôt de Données (ED) ; **Data WareHouse (DWH)**

Magasin de Données (MD) ; **Data Mart (DM)**

Lac de Données (MD) ; **Data Lake (DL)**

Grosses Masses de Données ; **Big Data**

BD Avancées !!! BD : Documentaire ; Multimédia ; XML ...

BD déductive ; Distribuée ; Répartie ; Floue ; Multidimensionnelle ...

BD SQL ! ; BD NoSQL !!!

Données hétérogènes (Structurées et NON-Structurées :

Types (Simple prédéfini par le système ou **Complexe** défini par l'utilisateur),

Modèles (Relationnel, Relationnel-Etendu, Relationnel-Objet, Objet, XML, Texte, Multimédia, Document, NON relationnel...),

Catégories (Structurée, semi-structurée, NON structurée)

Qualité (Valeurs en double ou similaires, valeurs aberrantes, valeurs nulles...)

Systèmes (SGBD) : Relationnels, Déductifs, Actifs, Répartis, Documentaires, NON relationnels...

Les Données .. Une vieille histoire ! ..

L'Histoire des SGBD peut être résumée en distinguant plusieurs types d'applications et de nouveaux besoins...

Les nouveaux besoins : BD/DB – ED/DW – LD/LD... – BD → FD/DM/ML :

Volume de données

Types de données

Applications intelligentes sur les données (Data)

Big Data + Cloud Computing : Thinking Differently, Bigger and Smarter

Prédiction, Recommandation, Conseil... Apprentissage → Temps réel

Applications d'analyses sur les données (Les Bases et Entrepôts de données)

Informatique décisionnelle, Business Intelligence (BI)

(OLTP : < 10 secondes) (OLAP < 1 heure)

(MV : agrégation,...) (**Batch** : Quotidien ou mensuel < 1h)

Grosse volumétrie : travail d'optimisation et suivi des activités de l'entrepôt est nécessaire :
par expérience certains traitements ne finissent pas au bout de quelques jours ;
ce qui nécessite des modifications (techniques et fonctionnelles)

Applications BD : Gestion des risques, Analyse des ventes (Batch : < 1 heure)

Applications BD : Paie, Marketing, Financière (OLTP: quelques secondes) (Batch : < 1 heure)

Performance

Les Données .. Une vieille histoire ! ..

L'Histoire des SGBD peut être résumée en distinguant plusieurs types d'applications et de nouveaux besoins...

Les nouveaux besoins : BD/DB – ED/DW – LD/LD... – BD → FD/DM/ML :

Volume de données

Types de données

Apprentissage Artificiel, ... Fouille des données ,

(Analyse du comportement des clients, Diagnostic, conseil, Recommandation, ...)

Entrepôts de données (grosses masses de données)

Intégration de plusieurs systèmes d'information nationaux et internationaux

(milliers de tables de quelques millions de lignes ; milliards de lignes : >>> 1000 GO, TO, PO, ZO)

Applications : Gestion des risques, Analyse des ventes

(100 tables de quelques millions de lignes) 2 GO

Bases de Données

Intégration de Données

MASSES DE DONNEES

Entrepôts, Magasins, Lacs de Données

Applications : Paie, Marketing, Financière

(50 tables de quelques milliers de lignes) 50 MO

Performance

1 Mo (MégaOctets) = 10^6 Octets ; 1 Go (GigaOctets) = 10^9 Octets ; 1 To (TéraOctets) = 10^{12} Octets ;


1 Po (PétaOctets) = 10^{15} Octets ; 1 Eo (ExaOctets) = 10^{18} Octets ; 1 Zo (ZettaOctets) = 10^{21} Octets ; 1 Yo (YottaOctets) = 10^{24} Octets ;

Exemple de grandeur : 1 ExaOctet = 10^{18} Octets = 1,15 milliard de milliards d'octets !!! C'est énorme




Les Données .. Une vieille histoire ! ..

L'Histoire des SGBD peut être résumée en distinguant plusieurs générations :



Les Données .. Une vieille histoire ! ..

L'Histoire des SGBD peut être résumée en distinguant plusieurs générations :



Les Données ... Une vieille histoire ! ...

Les différentes *structures* de données, les *différentes* catégories de données

SQL



Table / Relation			
Colonne 1	Colonne 2	...	Colonne N

Structure de Données tabulaire / relationnelle
Données **STRUCTUREES** en colonnes *simples* et complexes

Table 1 / Relation 1			
Colonne 11	Colonne 12	...	Colonne 1N

Table 2 / Relation 2		
Colonne 21	...	Colonne 2M

Structure de Données tabulaire / relationnelle
Données **STRUCTUREES** en colonnes *simples*



Structure HIERARCHIQUE des Données

Type de données

COMPLEXES

Texte

Image

Son

Vidéo


Document

...

D. Structurées et

D. NON Structurées

No-SQL




Performance, Puissance, Cohérence

... Les Données ... Historique des types ... !

Les principaux types de données Oracle sont :




SQL



... Les Données ... Historique des types... !

Les différentes *structures* de données, les *différentes* catégories de données




Les différents types de Bases de Données

SQL 2 vs SQL3

Élaboration du schéma Logique



Formalisme ER

Diagramme ER



Formalisme UML

Diagramme de Classes



SQL2


SQL3

SQL OO


Les différents types de Bases de Données

SQL 2 vs SQL3

Une table imbriquée (NESTED TABLE) est une collection **non ordonnée** et **non limitée** d'éléments de même type.



1 table qui contient une colonne (table) : Association du type 1-N



??? 1 ou plusieurs tables : Association du type N-N

Cours

Numc	Titre	Professeurs		Formations	
		Nom	Spécialité	Filière	Horaire

Les **propriétés ACID**, dans les bases de données relationnelles sont les quatre principaux attributs d'une transaction de données (la spécification des quatre buts à atteindre pour toute transaction). **ACID : Atomicity (atomicité), Consistency (cohérence), Isolation (isolation), Durability (durabilité).**

- (1) **Atomicité** signifie que les mises à jour de la base de données doivent être "atomiques", à savoir qu'elles doivent être totalement réalisées ou pas du tout.
- (2) **Cohérence** signifie que les modifications apportées à la base doivent être valides, en accord avec l'ensemble de la base et de ses contraintes d'intégrité. S'il arrive qu'un changement risque de perturber l'intégrité des données, alors soit le système doit modifier les données dépendantes, soit la transaction doit être interdite.
- (3) **Isolation** signifie que les transactions lancées au même moment ne doivent jamais interférer entre elles, ni même agir selon le fonctionnement de chacune.
- (4) **Durabilité** signifie que toutes les transactions sont lancées de manière définitive. Une base ne doit pas afficher le succès d'une transaction, pour ensuite remettre les données modifiées dans leur état initial. Pour ce faire, toute transaction est sauvegardée dans un fichier journal, afin que, dans le cas où un problème survient empêchant sa validation complète, celle-ci puisse être correctement terminée lors de la disponibilité du système.

Les différents types de Bases de Données NoSQL

SQL versus No-SQL

SQL VS NoSQL : Le terme de **Bases de Données NoSQL (BD Not only SQL)** regroupe des solutions, plus ou moins récentes, de représentation des données. Ces solutions se différencient du modèle relationnel des données (nommé à tort BD SQL) par une logique de représentation des données différente. Les principaux avantages de ces solutions sont, d'une part, leur capacité de traiter de très gros volumes de données (Big Data), et d'autre part, lorsque ces dernières ont des structures qui varient.

Le terme de BD NoSQL gagnerait à être remplacé par le terme de BD « non relationnelle » c'est-à-dire dont la structure n'est pas définie à l'avance et varie d'un objet représenté à un autre. On pourrait parler de données NON Structurées.

Le terme de **BD SQL signifie que les données sont structurées selon le modèle relationnel** (un ensemble de colonnes ou attributs regroupées en tables ou classes ; les tables peuvent être reliées entre elles avec les concepts de clés primaires et étrangères). On parle de données structurées lorsque : (i) La structure n'évolue pas ou évolue très peu dans le temps, (ii) La structure ne varie pas d'un objet à l'autre.

Les BD non relationnelles (BD NoSQL) ne visent pas à remplacer les BD relationnelles (BD SQL) mais plutôt à les compléter (il faudrait les faire cohabiter).

Les différents types de Bases de Données NoSQL

SQL versus No-SQL

Avantage des BD non relationnelles :

Les BD non relationnelles sont bien adaptées aux **traitements de données massives, peu structurées et/ou ayant une structure changeante**.

Un des premiers acteurs économiques qui a fait la promotion de ce type de gestion de données est Google. Il s'est basé sur (1) un système de **gestion de fichiers distribués** ; (2) un système de BD orientée colonnes ; et (3) un système de **mise en parallèle des traitements** nommé **MapReduce**.

Les **BD non relationnelles** constituent une autre (différente des **BD relationnelles**) manière de représenter l'information.

Elles s'affranchissent des contraintes dites ACID (Atomicité, Cohérence, Isolation, Durabilité) et fournissent **une architecture technique où il suffirait de rajouter des serveurs pour peut-être gagner en performance**.

Les différents types de Bases de Données NoSQL

SQL versus No-SQL

Les différents types de BD non relationnelles : On distingue plusieurs représentations de **BD non relationnelles** qui permettent de stocker les informations de la façon la mieux adaptée (=> différents types de **BD NoSQL**) :


- type « **Clé-valeur / Key-value** » : Il s'agit de la représentation la plus simple (basique). Chaque objet est identifié par une clé unique constituant la seule manière de le requêter ;
- type « **Document / Document** » : Une représentation qui ajoute au modèle clé-valeur, l'association d'une valeur complexe qui nécessiterait des jointures en termes relationnels ;
[Exemples de systèmes : MongoDB ; CouchDB...]
- type « **Colonne / Column** » : Une autre évolution du modèle clé-valeur qui permet de disposer de plusieurs valeurs sur une même ligne, de stocker des relations « one-to-many » ;
[Exemples de systèmes : HBase ; Cassandra...]
- type « **Graphe / Graph** » : Une représentation qui permet la modélisation, le stockage et la manipulation de données très complexes liées par des relations variées (gestion des relations multiples entre les objets adaptés aux données issues de réseaux sociaux par exemple). [Exemples : Neo4j ; OrientDB ...]

Les différents types de Bases de Données NoSQL

SQL versus No-SQL

BD NoSQL Clé-Valeur / Key-Value

Chaque **objet** est identifié par **une clé unique**
C'est la seule façon de le requêter (de le retrouver)




La **structure** de l'**objet** est **libre**

Elle est laissée à la charge du développeur de l'application (XML, SJON, ...)

La base ne gère généralement que des chaînes de caractères

BD NoSQL Graphe / Graph



BD NoSQL Colonne / Column

	Key	Column	Value
Collection Famille Table	Clé1	Col1	Val11
	Clé1	Col2	Val12
	Clé1	Col3	Val13
	Clé2	Col1	Val21
	Clé2	Col2	Val22
	Clé3	Col1	Val31
	Clé3	Col3	Val33
	Clé3	Col4	Val34
	Clé3	Col5	Val35

BD NoSQL Document / Document

	Key	Column	Value
Collection Famille Table	Clé1	Col1	Val11
	Clé1	Col2	Val12
	Clé1		
	Clé2		
	Clé2		
	Clé3		
	Clé3		
	Clé3		
	Clé3	Col5	Val35



Les différents types de Bases de Données NoSQL


SQL vs No-SQL

CLIENTS					
CodeCli	CiviCli	NomCli	PrenCli	...	MailCli
2994570	Madame	RAHMA	CLEMENCE		clemence.rahma@up13.fr
2996100	Monsieur	CLEMENCE			alexandre.clemence@up13.fr
2997007	Monsieur	TRAIFOR	ADAM		
2997777	Mademoiselle	LE BON	CLEMENTINE		clementine.le bon@up13.fr
2998500	Monsieur	CHEV@LIER	INES		ines.chevalier@up13.fr
3001777	Monsieur	LE BON	Adam		adam.le bon@up13.fr
2998505	Mademoiselle	TRAIFOR	ALICE		alice.traifor@up13.fr
3000106	Monsieur	HARISSA	FORD		ford.harissa@up13.fr

Clé 1 Nom de la table	Clé 2 Code du client	Colonne	Valeur
CLIENTS	2994570	CiviCli	Madame
CLIENTS	2994570	NomCli	RAHMA
CLIENTS	2994570	PrenCli	CLEMENCE
CLIENTS	2994570	MailCli	clemence.rahma@up13.fr
CLIENTS	2996100	CiviCli	Monsieur
CLIENTS	2996100	NomCli	CLEMENCE
CLIENTS	2996100	MailCli	alexandre.clemence@up13.fr
CLIENTS	2997007	CiviCli	Monsieur
CLIENTS	2997007	NomCli	TRAIFOR
CLIENTS	2997007	PrenCli	ADAM
CLIENTS	...	...	
CLIENTS			

COMMANDES		
NumeCom	CodeCli	DateCom
20150917BB0001	2997007	17/09/2015
20150917BB0002	2998500	17/09/2015
20151016BB0001	2996100	16/10/2015
20151024BB0001	2996100	24/10/2015
20120156BB0001	2996100	16/01/2012
20120157BB0007	2996100	17/01/2012
20180917BB0007	3001777	17/09/2018

Clé 1 Nom de la table	Clé 2 Code de la commande	Colonne	Valeur
COMMANDES	20150917BB0001	CodeCli	2997007
COMMANDES	20150917BB0001	DateCom	17/09/2015
COMMANDES	20150917BB0002	CodeCli	2998500
COMMANDES	20150917BB0002	DateCom	17/09/2015
COMMANDES			
COMMANDES			
COMMANDES			
COMMANDES			




Les différents types de Bases de Données NoSQL

SQL vs No-SQL


CLIENTS					
CodeCli	CiviCli	NomCli	PrenCli	...	MailCli
2994570	Madame	RAHMA	CLEMENCE		clemence.rahma@up13.fr
2996100	Monsieur	CLEMENCE			alexandre.clemence@up13.fr
2997007	Monsieur	TRAIFOR	ADAM		
2997777	Mademoiselle	LE BON	CLEMENTINE		clementine.le bon@up13.fr
2998500	Monsieur	CHEV@LIER	INES		ines.chevalier@up13.fr
3001777	Monsieur	LE BON	Adam		adam.le bon@up13.fr
2998505	Mademoiselle	TRAIFOR	ALICE		alice.traifor@up13.fr
3000106	Monsieur	HARISSA	FORD		ford.harissa@up13.fr

Clé 1 Nom de la table	Clé 2 Code du client	Valeur
CLIENTS	2994570	Struct:CiviCli;NomCli;PrenCli;MailCli//Data:Madame;RAHMA;CLEMENCE;clemence.rahma@up13.fr
CLIENTS	2996100	Struct:CiviCli;NomCli;MailCli//Data:Monsieur;CLEMENCE;alexandre.clemence@up13.fr
CLIENTS	2997007	Struct:CiviCli;NomCli;PrenCli//Data:Monsieur;TRAIFOR;ADAM
CLIENTS	...	...
CLIENTS		




Les différents types de Bases de Données NoSQL

SQL vs No-SQL



Les différents types de Bases de Données NoSQL

SQL vs No-SQL



Systèmes de Recommandation ?! SysReco

Les données de la BD ou de l'ED peuvent être vues sous forme de plusieurs étages !

Elles sont en étroite relation !

Il faudrait exploiter ces relations !



Catégories Articles

Appartenir à

Articles

Commander

Clients




Des opérations initiales, très importantes, permettant de repartir sur de bonnes bases :
validation, nettoyage, correction et complétion des données manquantes -->>

Enrichissement des données


2. Conception de données *(Bases, Entrepôts, Lacs...)*

*Think **Bigger**, Differently & **Smarter** by using correct
DATA*



Smart





Une des tâches essentielles des développeurs de bases de données est la **conception** du schéma des bases.

L'objectif est de **structurer** le domaine d'application afin de le **représenter** sous plusieurs formes telles que des **types** et **des tables** et d'**accompagner** ces structures de **contraintes** sur les données afin de tirer plus de **sémantique**.

La représentation doit être :

- **juste** pour éviter les erreurs sémantiques, notamment dans les réponses aux requêtes ;
- **complète** pour permettre le développement des programmes d'application souhaités ;
- **évolutive** afin de supporter la prise en compte rapide de nouvelles demandes.

Remarque :


De nos jours, on parle aussi de **données sans schéma préétabli** (données **non structurées**) !



Conception, Modélisation & Implantation de BD ...



Concepteur ; Développeur ; Utilisateur ; Administrateur



Conception & Modélisation de BD

Méthodes, Modèles, Formalismes

Modèle **Entité-Association E/A** / Modèle **Entité-Association étendu**

Modèles Objet , Formalisme **UML**, ...

Implantation de BD

Modèle **Relationnel (Structuré)** / Modèle Objet-Relationnel / Modèle Objet / Modèle **NON relationnel (Non Structuré)**
Optimisation du schéma (Normalisation, Dénormalisation...)

SGBD Relationnel / SGBD Objet-Relationnel / SGBD Orienté Objet, SGBD **Non Relationnel**

Langages (**SQL**, **PL/SQL**, **PRO*C**, **JDBC**, **Java**, **C++**, **Python**, **PHP**...)


Optimisations (Groupement, Index, ...)

Administration

Logiciels (SGBD, Interfaces, ...)

& Matériels








Services	Applications développées	Données utilisées ??? Fichiers / Bases de Données
DIRECTION	STATISTIQUES Formation, Absentéisme	PERSONNEL
Service RESSOURCES HUMAINES	PAIE	PERSONNEL
Service COMMERCIAL	Gestion COMMERCIALE (CRM...)	COMMERCIAUX, CLIENTS, FOURNISSEURS, FACTURES
Service FINANCIER	FACTURATION, STATISTIQUES	EMPLOYES, CLIENTS, FOURNISSEURS, FACTURES





1 Personnel = 1 Commercial = 1 Employé

défini de **plusieurs façons** selon les services !!! et selon les applications !!!

Service Fichier / BD	Description des données utilisées ??? Fichiers / Bases de Données
DIRECTION PERSONNEL	Numéro, Civilité, NOM Prénom, Adresse, Téléphone
Service RESSOURCES HUMAINES PERSONNEL	Numéro, Civilité, NOM Prénom, Adresse, Téléphone, DateEmbauche
Service COMMERCIAL COMMERCIAUX	Numéro, Civilité, NOM Prénom, Adresse, Téléphone, Secteur
Service FINANCIER EMPLOYES	Numéro, Civilité, NOM P., Adresse, Téléphone






Risque d'incohérence

Service / Fichier /BD	Données dans les fichiers, les Bases de Données
Direction / Personnel	1709, Monsieur , RAHMA Clément , Paris, 0145570679
Service Commercial	1709, M , RAHMA Clément, Paris 19è, 0614560641 , Nord Est
Service Ressources Humaines	1709, M , RAHMA Clément, Paris 19è, 0614014575 , 17/09/1958
Service Financier	1709, Mlle , RAHMA C.

1 Personnel = 1 Commercial = 1 Employé

défini de **plusieurs façons** selon les services !!! et selon les applications !!!







1 Personnel = 1 Commercial = 1 Employé

défini d'une seule façon

Description **UNIQUE** du Personnel :

Numéro, Civilité, Nom Prénom, Adresse, Téléphone, Portable, Date d'embauche, Secteur, Nombre d'enfants, Type de Contrat, etc.



Valeur **UNIQUE** de l'information : **Donnée UNIQUE**

1709, Monsieur, RAHMA Clément, Paris 15è, 0145750679, 0614560641, 01/01/1994, Nord Est, 1, CDI, ...



Il n'y a plus de risque d'incohérence

Service / Fichier /BD	Données dans les fichiers, les Bases de Données
Direction / Personnel	1709, Monsieur, RAHMA Clément, Paris 15è, 0145570679
Service Commercial	1709, Monsieur, RAHMA Clément, Paris 15è, 0614560641, Nord Est
Service Ressources Humaines	1709, Monsieur, RAHMA Clément, Paris 15è, 0145570679, 0614560641, 17/09/1958
Service Financier	1709, Monsieur, RAHMA Clément



- **intégrer toutes les données** pertinentes à un système dans une même structure que l'on nomme une **Base de Données de référence** ;
- **offrir une vision (vue) partielle de l'ensemble des données** à chaque utilisateur. Cette vision correspond aux besoins de chacun ;
- **assurer le partage des données** entre les différents utilisateurs

Conception, Modélisation & Implantation de BD ...



Concepteur ; Développeur ; Utilisateur ; Administrateur

Conception & Modélisation de BD

Méthodes, Modèles, Formalismes

Modèle **Entité-Association E/A** / Modèle **Entité-Association étendu**

Modèles Objet , Formalisme **UML**, ...

Implantation de BD

Modèle **Relationnel (Structuré)** / Modèle Objet-Relationnel / Modèle Objet / Modèle **NON relationnel (Non Structuré)**
Optimisation du schéma (Normalisation, Dénormalisation...)

SGBD Relationnel / SGBD Objet-Relationnel / SGBD Orienté Objet, SGBD **Non Relationnel**

Langages (**SQL**, **PL/SQL**, **PRO*C**, **JDBC**, **Java**, **C++**, **Python**, **PHP**...)

Optimisations (Groupement, Index, ...)

Administration

Logiciels (SGBD, Interfaces, ...)


& Matériels




Conception, Modélisation & Implantation de BD...



Concepteur ; Utilisateur ; Développeur ; Administrateur





Une des tâches essentielles des développeurs de bases de données est la **conception** du schéma des bases.

L'objectif est de **structurer** le domaine d'application afin de le **représenter** sous plusieurs formes telles que des **types** et **des tables** et d'**accompagner** ces structures de **contraintes** sur les données afin de tirer plus de sémantique.


La représentation doit être :

- **juste** pour éviter les erreurs sémantiques, notamment dans les réponses aux requêtes ;
- **complète** pour permettre le développement des programmes d'application souhaités ;
- **évolutive** afin de supporter la prise en compte rapide de nouvelles demandes.

Remarque :

De nos jours, on parle aussi de **données sans schéma préétabli** (données **non structurées**) !






Traditionnellement, la démarche de conception s'effectue par abstractions successives, en descendant depuis les problèmes de l'utilisateur vers le Système de Gestion de Bases de Données.

Plusieurs étapes ont été distinguées et proposées :

1. **Perception du monde réel et capture des besoins**
2. **Élaboration du schéma conceptuel**
3. **Conception & Affinement du schéma logique**
4. **Élaboration du schéma physique**





1. Perception du monde réel et capture des besoins

Cette étape consiste à étudier les problèmes des utilisateurs et à comprendre leurs besoins.


Elle comporte des entretiens, des analyses des flux d'information et des processus métier.

Comme il est difficile de comprendre le problème dans son ensemble, les concepteurs réalisent des études de cas partiels.

Le résultat se compose donc d'un **ensemble de vues ou schémas externes** qu'il faut intégrer dans l'étape suivante.

Ces vues sont exprimées dans un **modèle de données (de type entité-association ou objet)**, selon la méthode choisie.





2. Élaboration du schéma conceptuel


Cette étape est basée sur l'intégration des schémas externes obtenus à l'étape précédente.

Chaque composant est un **schéma conceptuel** (**diagramme entité-association**, **diagramme de classes**). Il résulte d'un modèle de problème représentant une partie de l'application.

La difficulté est d'intégrer toutes les parties dans un schéma conceptuel global complet, non redondant et cohérent.

Des allers et retours avec l'étape précédente sont souvent nécessaires.





3. Conception & Affinement du schéma logique

Cette étape réalise la transformation du **schéma conceptuel** en **structures de données** supportées par le système choisi : le **schéma logique**.


Avec un SGBD **relationnel**, il s'agit de passer à des **tables**.

Avec un SGBD **relationnel-objet**, il est possible de générer des **types** et des **tables**, les types étant réutilisables.

Avec un SGBD **objet**, il s'agit de générer des **classes** et des associations.

Cette étape peut être partiellement ou même complètement automatisée.





3. Conception & Affinement du schéma logique


Une question qui se pose est de savoir si le **schéma logique** est un « **bon** » schéma.

A titre de première approximation, un « bon schéma » est un schéma sans oublis ni redondances d'informations.

Pour caractériser plus précisément les « bons » schémas, le modèle relationnel s'appuie sur la **théorie de la normalisation**, qui peut être avantageusement appliquée à ce niveau.

En relationnel, l'objectif est de regrouper ou décomposer les tables de manière à représenter fidèlement le monde réel modélisé.





4. Élaboration du schéma physique

Cette étape est nécessaire pour obtenir de **bonnes performances**.

Elle nécessite la prise en compte de toutes les transactions, concernant les applications traitées, afin de déterminer les **accès fréquents**.

A partir de là, il faut choisir les bonnes structures physiques : **groupage ou partitionnement de tables, index, etc.**

C'est là que se joue pour une bonne part les performances des applications.

L'étape 1 appartient plutôt au domaine du **génie logiciel**.


Les étapes 2, 3 et 4 font largement partie du domaine des **bases de données**.



Conception, Modélisation & Implantation de BD...



Concepteur ; Utilisateur ; Développeur ; Administrateur



Méthode, Modèle, Formalisme
Modèle Entité-Association E/A (ER) / Modèle Entité-Association

Modèles Objet
Formalisme UML

Power AMC, Power Designer
WinDev, Oracle Designer
Rational Rose, ...

ETAPE CONCEPTUELLE

ETAPE LOGIQUE

Modèle Relationnel / Modèle Objet-Relationnel / Modèle Objet
Optimisation du schéma (Normalisation, ...), Règles de passage


SQL :
Oracle, DB2,
MySQL,
PostgreSQL, ...
NoSQL :
MongoDB,
Hbase, ...
Talend, Tableau
BO...


SGBD Relationnel / SGBD Objet-Relationnel / SGBD Orienté Objet
SGBD Non Relationnel

Langages (SQL, PL/SQL, PRO*C, JDBC, Java, C++, Python, PHP...)
Optimisations (Groupement, Index, ...) - Administration

ETAPE PHYSIQUE

Systèmes de Gestion de Bases de Données
Autres outils d'intégration et de visualisation





Élaboration du schéma conceptuel

Formalisme ER

Entité, Association

Type d'Entité, Type d'Association

Attribut/Propriété

Cardinalité

Dépendance Fonctionnelle

Forme Normale

Héritage, Agrégation, Composition

...

Diagramme ER

Formalisme UML

Objet

Classe

Attribut/Propriété

Multiplicité

...


...


Héritage, Agrégation, Composition

...

Diagramme de Classes

Schémas conceptuels







Élaboration du schéma conceptuel

Formalisme ER

Diagramme ER




Schémas conceptuels



Formalisme UML

Diagramme de Classes






Élaboration du schéma Logique

Règles de passage vers le relationnel :



Entité/Classe vers Relation/table

Association vers Relation/table

Association vers Clé Etrangère



Relationnel




Règles de passage vers le relationnel-étendu (objet-relationnel, relationnel-objet, objet) :


Quelle est la table qui contient l'autre ?

On parle d'approche NF² (*Non First Normal Form*)

Objet-Relationnel Relationnel-Etendu





Implantation de BD ...




Élaboration du schéma Logique

Formalisme ER

Diagramme ER




Relationnel



Outils de traduction

Objet-Relationnel Relationnel-Étendu




Formalisme UML

Diagramme de Classes



Implantation de BD ...



Définir une table/Créer une table

Élaboration du
schéma Physique

Attributs → types de données de base (prédéfinis par le système)
Numérique, Alphanumérique (Caractère, Texte), Date, ...

Attributs → types de données définis par l'utilisateur

Contraintes → contrôles de validités (Clés primaire et étrangère, ...)

Caractéristiques physiques : Paramètres de stockage

Taux de remplissage des blocs, évolution ...

Lieu de stockage (disque, MC), parallélisme...

Optimisations : Partitionnement, découpage



SQL ???

2? 3? NoSQL?

Définir les chemins d'accès aux données :

Indexer : Accélérer les traitements, Reconstruire les blocs...


Construire des vues et des vues matérialisées (des pré-calculs,...)



Partager les données entre plusieurs utilisateurs

Créer des vues, des droits d'accès, des rôles, des profiles...





Construire des vues et des vues matérialisées (des pré-calculs,...)

...

Garder plusieurs **versions** des données,

construire des historiques,

des traces des mises à jour (Qui, Quand),

des mouvements/changements des données...

définir des **déclencheurs/triggers**

Gérer le **temps**...




+++ !!! ???



Gestion du **temps**, **Historique**...
Plusieurs **versions** des données !





Élaboration du schéma Physique (simplifié)

COURS (NUM_COURS, NOMC, NBHEURES, ANNEE)

PROFESSEURS (NUM_PROF, NOMP, SPECIALITE, DATE_ENTREE, DER_PROM, SALAIRE_BASE, SALAIRE_ACTUEL)

CHARGE(NUM_PROF*, NUM_COURS*)

Schéma relationnel

create table COURS

(NUM_COURS	NUMBER(2)	NOT NULL,
NOMC	VARCHAR(20)	NOT NULL,
NBHEURES	NUMBER(2),	
ANNE	NUMBER(1),	

constraint PK_COURS primary key (NUM_COURS));

create table PROFESSEURS

(NUM_PROF	NUMBER(4)	NOT NULL,
NOMP	VARCHAR2(25)	NOT NULL,
SPECIALITE	VARCHAR2(20),	

DATE_ENTREE DATE,

DER_PROM DATE,

SALAIRE_BASE NUMBER,

SALAIRE_ACTUEL NUMBER,

constraint PK_PROFESSEURS primary key (NUM_PROF));

create table CHARGE

(NUM_PROF NUMBER(4) NOT NULL,

NUM_COURS NUMBER(4) NOT NULL,

constraint PK_CHARGE primary key (NUM_COURS, NUM_PROF));

SQL₂



alter table CHARGE


add **constraint FK_CHARGE_COURS**
foreign key (NUM_COURS)
references COURS (NUM_COURS) ;

alter table CHARGE

add **constraint FK_CHARGE_PROFESSEUR**
foreign key (NUM_PROF)
references PROFESSEURS (NUM_PROF) ;



Implantation de BD ...



Élaboration du schéma Physique (simplifié)

create table COURS

(NUM_COURS **NUMBER(2),**
NOMC VARCHAR(20),
NBHEURES NUMBER(2),
ANNE NUMBER(1),

constraint PK_COURS primary key (NUM_COURS),

constraint NN__COURS_NOMC check (NOMC IS NOT NULL));

create table PROFESSEURS

(NUM_PROF NUMBER(4),
NOMP VARCHAR2(25),
SPECIALITE VARCHAR2(20),
DATE_ENTREE DATE,
DER_PROM DATE,
SALAIRE_BASE NUMBER,
SALAIRE_ACTUE NUMBER,

constraint PK_PROFESSEURS primary key (NUM_PROF),

constraint NN__PROFESSEURS_NOMP check (NOMP IS NOT NULL));

create table CHARGE

(NUM_PROF NUMBER(4), NUM_COURS NUMBER(4),,

constraint PK_CHARGE primary key (NUM_COURS, NUM_PROF));

alter table CHARGE

add **constraint FK_CHARGE_COURS foreign key (NUM_COURS) references COURS (NUM_COURS) ;**

alter table CHARGE


add **constraint FK_CHARGE_PROFESSEURS foreign key (NUM_PROF) references PROFESSEURS (NUM_PROF) ;**

SQL₂



Insuffisant !





Élaboration du schéma Physique (simplifié)

COURS (NUM_COURS, NOMC, NBHEURES, ANNEE)

PROFESSEURS (NUM_PROF, NOMP, SPECIALITE, DATE_ENTREE, DER_PROM, SALAIRE_BASE, SALAIRE_ACTUEL, **Ensemble-de (COURS)**)

Schéma relationnel-objet


```
create type cours_type as object
(num_cours number(2), nomc varchar2(20), nbheures number(2), annee number(1) )
/
create type lescours_type as table of cours_type
/
create type professeur_type as object
(num_prof number(4), nom varchar2(25), specialite varchar2(20), cours lescours_type ...)
/
create table professeur of professeur_type
(primary key (num_prof))
nested table cours store as tabemp
/
```

SQL₃...

SQL_{OO} – SQL Orienté Objet

+++ Partie statique + Partie dynamique (méthodes)





Élaboration du schéma Physique (simplifié)

Types Objet --- Création/Destruction d'un type

```
CREATE [OR REPLACE TYPE] schéma.nomType
```

```
[AS OBJECT | UNDER schéma.nomSurType]
```

```
(
```

```
colonne1 type1, colonne2 type2, ...,
```

➡ **Structure**

```
méthode1 (paramètres1), méthode2 (paramètres2) ...
```

➡ **Comportement**

```
)
```

```
[[NOT] INSTANCIABLE]
```

```
[[NOT] FINAL]
```

➡ **Relatif à l'héritage**

```
/
```

```
DROP TYPE nomType [FORCE | VALIDATE] ;
```

SQL₃... --- SQL_{OO} – SQL Orienté Objet



Schéma Conceptuel ①

Formalisme ER

Diagramme ER





Schéma Logique ②

Relationnel




Schéma relationnel

COURS (NUM_COURS, NOMC, NBHEURES, ANNEE)

PROFESSEURS (NUM_PROF, NOMP, SPECIALITE, DATE_ENTREE, DER_PROM, SALAIRE_BASE, SALAIRE_ACTUEL)

CHARGE(NUM_PROF*, NUM_COURS*)

Formalisme UML

Diagramme de Classes







Schéma Physique ③ ??? !!!



Implantation de BD ...




Schéma Physique (??? !!!)

SQL

Définir une table

Attributs → types de données

Contraintes → contrôles de validités :

PROBLEME DE COHERENCE GLOBALE

PROBLEME DE QUALITE DE DONNEES

Caractéristiques physiques : Paramètres de stockage

Taux de remplissage des blocs, évolution ... Lieu de stockage, parallélisme...

Optimisations : Partitionnement, découpage

Définir les chemins d'accès aux données

Construire des vues et des vues matérialisées (des pré-calculs,...)

Partager les données entre plusieurs utilisateurs :

PROBLEME DE COHERENCE, DE CONFIDENTIALITE, DE SECURITE






Schéma Physique (1ère version)

SQL₂

create table COURS

(NUM_COURS **NUMBER(2)**,
NOMC VARCHAR(20),
NBHEURES **NUMBER(2)**,
ANNE **NUMBER(1)**,

constraint PK_COURS primary key (NUM_COURS),

constraint NN_COURS_NOMC check (NOMC IS NOT NULL));



create table PROFESSEURS

(NUM_PROF **NUMBER(4)**,
NOMP VARCHAR2(25),
SPECIALITE VARCHAR2(20),
DATE_ENTREE **DATE**,
DER_PROM **DATE**,
SALAIRE_BASE **NUMBER**,
SALAIRE_ACTUEL **NUMBER**,

constraint PK_PROFESSEURS primary key (NUM_PROF)

constraint NN_PROFESSEURS_NOMP check (NOMP IS NOT NULL));

create table CHARGE

(NUM_PROF **NUMBER(4)**,
NUM_COURS **NUMBER(4)**,

constraint PK_CHARGE primary key (NUM_COURS, NUM_PROF)

constraint FK_CHARGE_COURS foreign key (NUM_COURS) references COURS (NUM_COURS)

constraint FK_CHARGE_PROFESSEURS foreign key (NUM_PROF) references PROFESSEURS (NUM_PROF));

Attributs + Contraintes

(Domaine/type de données)


(Clés Primaire et Etrangère)

(Vérifications/Check telles que Non Nulle, etc)



Insuffisant !







Implantation de BD / Administration d'une BD

La commande Create table crée une table, elle définit ses colonnes, contraintes et paramètres de stockage.

Une syntaxe de la commande Create table est :





Implantation de BD / **Administration** d'une BD

Les **paramètres de stockage** peuvent être résumés par : le lieu, le taux de remplissage, la manière d'évoluer et la manière d'être traitée !

CREATE TABLE nomtable (attributs , contraintes)

TABLESPACE nomtablespace

PCTUSED x1

PCTFREE x2

INITTRANS x3

MAXTRANS x4

STORAGE (**INITIAL** n1 **NEXT** n2

MINEXTENTS m1 **MAXEXTENTS** m2

PCTINCREASE p)

PARALLEL p / **NOPARALLEL** (appliquer le parallélisme)


LOGGING / **NOLOGGING** (pour ne pas copier les mises à jour dans le rollback)

CACHE / **NOCACHE** (permet de garder la table en mémoire : à utiliser avec précaution)

PARTITIONnement (une sorte de découpage de la table)

;






Structure d'une base de données oracle

Toute base de données oracle possède une **structure logique**, une **structure physique** et un **ensemble de vues** donnant des **visions partielles** aux **utilisateurs**. La description de ces trois niveaux et la correspondance entre eux est faite à travers le **dictionnaires de données**.

- **Structure physique d'une BD oracle** : Elle est composée d'un ensemble de fichiers qui constituent le support physique de stockage de données. Les trois types de fichiers sont : les fichiers de données (**Data Files**), les fichiers de reprises (**Redolog Files**) et les fichiers de contrôles (**Control Files**).
- **Structure logique d'une BD oracle** : Elle est composée des **tables spaces**, des **segments**, des **extensions** et des **blocs**.






Structure d'une base

Une base de données est composée de :

- **Instance** : il s'agit des processus qui gèrent :
 - La cohérence de la base
 - La mise à jour, rollback, commit
 - etc...
- **Fichiers** qui composent la base de données :
 - fichier rollback
 - fichier tablespace





Structure d'une base

Base de Données

**TABLESPACE
SYSTEM**

table	table
table	index
	index
index	table
index	
index	


TABLESPACE DATA ①

table	table	table	cluster
table	index		
	index		
index	table		
index			
index			


TABLESPACE DATA ②


table	table	table	cluster
table	index	table	index
	index		index
index	table	index	table
index		index	
index		index	





Structure d'une base






Implantation de BD / Administration d'une BD

BLOC de données


BLOC



- Un **bloc de données** est la plus petite unité logique d'entrée/sortie utilisée par un SGBD tel que Oracle
- Appelé également *Bloc logique* ou *Page*
- A distinguer du bloc physique utilisé par les systèmes d'exploitation [Operating System]
(*bloc physique = ensemble d'octets sur disque*)
- Taille d'un bloc de données
 - attribuée par défaut selon OS (2 , 4 ou 8 Ko)
 - modifiable par `DB_BLOCK_SIZE = n`

Format d'un bloc de données


Les blocs de données sont organisés de la même façon quelque soit leur contenu : données, index ou cluster.



Entête
Liste des tables
Liste des lignes
Espace libre

Données








Implantation de BD / **Administration** d'une BD

Format d'un bloc de données

- **L'entête** : contient des informations générales (telles que : adresse du bloc, type du segment)
- **Liste des tables** : utilisée uniquement pour les clusters, contient des informations relatives aux tables groupées ayant des données dans ce bloc
- **Liste des lignes** : contient des informations relatives aux lignes situées dans ce bloc (adresse)
- **Espace libre** : utilisé pour l'insertion de nouvelles lignes ou la mise à jour des lignes nécessitant de l'espace
- le reste du bloc est réservé aux données.





Implantation de BD / Administration d'une BD

Bloc de Données ORIGINAL

Clé	Nom Prénom...
2	Adam CAVALIER
3	Eve CVALIER
7	Inès BOOK



Bloc de Données COPIE

Clé	Nom Prénom...
2	Adam CAVALIER
3	Eve CAVALIER
7	Inès BOOK

Mise à jour des données **MODIFICATION** : CVALIER → CAVALIER

Mise à jour des données **SUPPRESSION** : 3 Eve CAVALIER

Bloc de Données ORIGINAL

Clé	Nom Prénom...
2	Adam CAVALIER



Bloc de Données COPIE

Clé	Nom Prénom...
2	Adam CAVALIER
7	Inès BOOK

OU

Regrouper les deux blocs ?

Mise à jour des données **INSERTION** : 5 Lina LEBON

Bloc de Données ORIGINAL

Clé	Nom Prénom...
2	Adam CAVALIER
3	Eve CAVALIER
7	Inès BOOK



Bloc de Données COPIE

Clé	Nom Prénom...
2	Adam CAVALIER
3	Eve CAVALIER

OU

Bloc de Données COPIE

Clé	Nom Prénom...
2	Adam CAVALIER
3	Eve CAVALIER
5	Lina LEBON
7	Inès BOOK

Remplir au maximum le bloc ?

Bloc de Données COPIE

Clé	Nom Prénom...
5	Lina LEBON
7	Inès BOOK

Créer deux blocs ?

Bloc de Données ORIGINAL

Clé	Nom Prénom...
3	Eve CAVALIER
7	Inès BOOK



Bloc de Données COPIE


Clé	Nom Prénom...
2	Adam CAVALIER

Bloc de Données COPIE


Clé	Nom Prénom...
7	Inès BOOK

Garder les deux blocs ?






Implantation de BD / **Administration** d'une BD



Gestion de l'espace des blocs


- Les paramètres *PCTFREE* et *PCTUSED* permettent de gérer l'espace libre des blocs de données.
- Ils sont utilisés dans les commandes de **création** ou de modification de **tables**, clusters, snapshot, snapshot log...
- Le paramètre PCTFREE peut être utilisé également dans les commandes de création et de modification d'index.





Implantation de BD / Administration d'une BD

PCTFREE




- Fixe le *pourcentage d'espace* dans un bloc qui doit être maintenu libre pour les éventuelles mises à jour des lignes du bloc.
- Exemple : PCTFREE = 15
 - ↳ possibilité d'insérer de nouvelles lignes dans le bloc tant que l'espace libre > 15%.
- Critères de choix
 - mode d'utilisation de la table ou de l'index associé
 - supérieur à 10 si la mise à jour augmente souvent la taille
 - inférieur à 10 dans le cas contraire.

Chercher un compromis entre le gain d'espace et l'amélioration des performances

valeur faible : gain d'espace et dégradation des performances à cause de la fragmentation des données.


valeur élevée : perte d'espace et un gain de performances.






Implantation de BD / Administration d'une BD

PCTUSED




- Utilisé simultanément avec le paramètre PCTFREE (la valeur par défaut est 40).
 - un bloc est initialement vide
 - on y insère de nouvelles lignes jusqu'à atteindre PCTFREE
 - l'insertion de nouvelles lignes dans le bloc n'est possible que si le pourcentage d'espace utilisé devient inférieur à PCTUSED
 - on peut de nouveau insérer de nouvelles lignes jusqu'à ce que l'espace libre atteigne PCTFREE
- PCTFREE
Permet de spécifier l'espace libre laissé dans le bloc pour réaliser les mises à jour des lignes stockées dans le bloc.
Par défaut, la valeur de ce paramètre est égale à 10.
Dans tous les cas, la somme de PCTFREE et de PCTUSED ne peut excéder 100.
Lorsque l'espace libre dans un bloc atteint PCTFREE, aucune nouvelle ligne n'est insérée dans le bloc.
- PCTUSED
Lorsque l'on ne peut plus insérer de lignes dans le bloc (lorsque l'espace libre restant dans le bloc devient égal à PCTFREE), le bloc n'est plus utilisé pour insérer de nouvelles lignes tant que l'espace utilisé n'est pas redescendu en dessous de la valeur de PCTUSED.





Implantation de BD / Administration d'une BD

BLOC



Les conséquences d'un **petit PCTFREE** :

- Moins d'espace est réservé au niveau du bloc pour effectuer les MAJ des lignes existantes
- Permet aux insertions de mieux remplir le bloc
- Permet d'économiser de l'espace dans la mesure où les blocs sont mieux remplis
- Augmente le temps de traitement dans la mesure où Oracle doit régulièrement réorganiser les blocs lorsque l'on insère ou l'on modifie des lignes
- Augmente les temps de traitement dans la mesure où les MAJ peuvent conduire à la génération de chaînages entre différents blocs


Un petit PCTFREE est utilisé pour les objets ayant une faible activité en mise à jour

Les conséquences d'un **grand PCTFREE** :

- Plus d'espace est réservé au niveau du bloc pour effectuer les MAJ des lignes existantes
- Plus de blocs peuvent être nécessaires pour gérer la même quantité de données (moins de lignes sont stockées dans les blocs)
- Diminue le temps de traitement dans la mesure où les réorganisations des blocs sont moins nombreuses
- Amélioration des performances en MAJ dans la mesure où les chaînages des blocs sont évités


Un grand PCTFREE est nécessaire pour les objets ayant une forte activité en mise à jour





Implantation de BD / **Administration** d'une BD

BLOC




Les conséquences d'un **petit PCTUSED**

- Les blocs sont moins remplis
- Réduction des coûts de traitements lors des commandes INSERT UPDATE pour mettre à jour la FREELIST quand un bloc est utilisé à moins de PCTUSED pourcent
- Augmente la consommation d'espace dans la base de données

Les conséquences d'un **grand PCTUSED**

- Les blocs sont mieux remplis
- Amélioration de la gestion d'espace. Les blocs sont mieux remplis
- Augmente le coût des insertions et des mises à jour







Implantation de BD / Administration d'une BD

Exemple PCTFREE et PCTUSED


PCTFREE = 20, PCTUSED = 40




Lignes insérées jusqu'à 80% puisque PCTFREE est fixé à 20%



La mise à jour des lignes peut utiliser l'espace libre. Pas de nouvelles lignes insérées jusqu'à ce que l'espace utilisé redescende au dessous de 40%




Une fois l'espace utilisé descend au dessous de 40%, l'insertion de nouvelles lignes peut reprendre



Lignes insérées jusqu'à 80% puisque PCTFREE est fixé à 20%





Implantation de BD / Administration d'une BD

- **INITRANS**

Nombre de transactions pouvant accéder simultanément aux lignes contenues dans un bloc.

L'espace est réservé en entête de chaque bloc de données et d'index.

La valeur par défaut est 1 pour les données et 2 pour les indexes

- **MAXTRANS**

Le paramètre MAXTRANS permet de limiter le nombre de transactions

- **FREELISTE**

Liste des blocs libres par objet. Par défaut, la valeur est égale à 1. En cas de contention sur la **freelist**, les performances des applications peuvent être altérées.

Pour identifier ce problème, il suffit de consulter le contenu de la table **v\$waitstat** de la façon suivante :


```
select class, count waits from v$waitstat where class = 'freelist' ;
```

Il faut ensuite comparer le nombre « waits » sur les blocs libres par rapport au nombre total de demandes de données sur la même période.

```
select sum(value) gets from v$sysstat where name in ('db block gets','consistent gets') ;
```

Si le ratio waits/gets est inférieur à 1%, il faut ajouter des freelist





Implantation de BD / Administration d'une BD


Schéma Physique (2ème version; paramètres de stockage)

```
create table COURS
(NUM_COURS  NUMBER(2),,
NOMC        VARCHAR(20),
NBHEURES    NUMBER(2),
ANNE        NUMBER(1),
constraint PK_COURS primary key (NUM_COURS),
constraint NN_COURS_NOMC check (NOMC IS NOT NULL) )
```

SQL₂

```
TABLESPACE S_COURS_DATA
  PCTUSED  98
  PCTFREE  1
  INITRANS 1
  MAXTRANS 255
  STORAGE (
    INITIAL      11280K
    NEXT         11M
    MINEXTENTS   1
    MAXEXTENTS   unlimited
    PCTINCREASE  0
    FREELISTS    9
    FREELIST GROUPS 1)
  PARALLEL  ;
```





Implantation de BD / Administration d'une BD

Schéma Physique (2ème version; paramètres de stockage)

SQL₂

create table PROFESSEURS

(NUM_PROF NUMBER(4),
NOMP VARCHAR2(25),
SPECIALITE VARCHAR2(20),
DATE_ENTREE DATE,
DER_PROM DATE,
SALAIRE_BASE NUMBER,
SALAIRE_ACTUEL NUMBER,

constraint PK_PROFESSEURS primary key (NUM_PROF)

constraint NN_PROFESSEURS_NOMP check (NOMP IS NOT NULL))

TABLESPACE S_PROF_DATA

PCTUSED 98

PCTFREE 1


INITRANS 6

MAXTRANS 255

STORAGE (INITIAL 20M NEXT 5M)

NOPARALLEL ;





Implantation de BD / Administration d'une BD

Schéma Physique (2ème version; paramètres de stockage)

create table CHARGE

(NUM_PROF NUMBER(4),

NUM_COURS NUMBER(4),

constraint PK_CHARGE primary key (NUM_COURS, NUM_PROF)

constraint FK_CHARGE_COURS foreign key (NUM_COURS) references COURS (NUM_COURS)

constraint FK_CHARGE_PROFESSEURS foreign key (NUM_PROF) references PROFESSEURS (NUM_PROF))

TABLESPACE S_CHARGE_DATA

PCTUSED 98

PCTFREE 1

INITRANS 1

MAXTRANS 255


STORAGE

(	INITIAL	11280K
	NEXT	11M
	MINEXTENTS	1
	MAXEXTENTS	unlimited
	PCTINCREASE	0
	FREELISTS	9
		)

PARALLEL 3 ;

SQL₂





Implantation de BD / Administration d'une BD

Schéma Physique (3ième version; partitionnement)

Partitionnement des données

partitionnement des objets dans Oracle

Techniques de partitionnement/fragmentation de tables


- Fragmentation horizontale
—découpage horizontal de la table

Région parisienne
Autres Régions

- Fragmentation verticale
—découpage vertical de la table

Siège		
Usine		





Implantation de BD / Administration d'une BD

Schéma Physique (3ième version; partitionnement)


```
create table PROFESSEURS  
  (NUM_PROF          NUMBER(4),  
   ... constraint PK_PROFESSEURS primary key (NUM_PROF) )  
PARTITION BY RANGE (NUM_PROF)  
(PARTITION P1 VALUES LESS THAN (1000)  
  TABLESPACE ECOLE_PARIS,  
 PARTITION P2 VALUES LESS THAN (2000)  
  TABLESPACE ECOLE_TUNIS  
);
```



SQL₂

```
select * from PROFESSEURS PARTITION (P1);  
select * from PROFESSEURS PARTITION (P2);
```





Implantation de BD / Administration d'une BD

Schéma Physique (3ième version; partitionnement)

```
create table PROFESSEURS  
    (NUM_PROF          NUMBER(4),  
    ... constraint PK_PROFESSEURS primary key (NUM_PROF) )
```

PARTITION BY RANGE (DATE_ENTRÉE)

(
PARTITION p_200312 **VALUES LESS THAN**

(to_date('2004-01-01','YYYY-MM-DD'))),

PARTITION p_200406 **VALUES LESS THAN**

(to_date('2004-07-01','YYYY-MM-DD'))),


PARTITION p_200412 **VALUES LESS THAN**

(to_date('2005-01-01','YYYY-MM-DD'))

);

SQL₂





Implantation de BD / Administration d'une BD

Schéma Physique (3ième version; partitionnement)


SQL₂

```
CREATE TABLE sales_by_region
(item# INTEGER, qty INTEGER, store_name VARCHAR(30), state_code VARCHAR(2), sale_date DATE)

STORAGE(INITIAL 10K NEXT 20K) TABLESPACE tbs5 PARTITION BY LIST (state_code)

( PARTITION region_east VALUES ('MA','NY','CT','NH','ME','MD','VA','PA','NJ')
  STORAGE (INITIAL 8M) TABLESPACE tbs8,
  PARTITION region_west VALUES ('CA','AZ','NM','OR','WA','UT','NV','CO')
  NOLOGGING,
  PARTITION region_south VALUES ('TX','KY','TN','LA','MS','AR','AL','GA'),
  PARTITION region_central VALUES ('OH','ND','SD','MO','IL','MI','IA'),
  PARTITION region_null VALUES (NULL),
  PARTITION region_unknown VALUES (DEFAULT) );
```





Implantation de BD / Administration d'une BD


Schéma Physique (3ième version; déclencheurs/triggers)

SQL₂

```
CREATE OR REPLACE TRIGGER schema.trigger_name  
BEFORE DELETE OR INSERT OR UPDATE ON schema.table_name  
pl/sql_block
```

```
CREATE OR REPLACE TRIGGER hr.salary_check  
BEFORE INSERT OR UPDATE OF salary, job_id ON hr.employees  
FOR EACH ROW WHEN (new.job_id <> 'AD_VP')  
pl/sql_block
```





Implantation de BD / Administration d'une BD

Schéma Physique (4ème version; Index)

SQL₂

Faut-il **créer/détruire/reconstruire**
des **index** pour accélérer les traitements ?

Quel type d'index ?

Arbre-B (B-tree) , Hachage, Bitmap ?


CREATE INDEX ...

CREATE BITMAP INDEX ...

DROP INDEX (sauf les clés primaire et étrangère...)


REBUILD INDEX ???






Implantation de BD / Administration d'une BD

La commande **Create index** crée un index sur une ou plusieurs colonnes d'une table. Une syntaxe de la commande Create index est :





Implantation de BD / Administration d'une BD

Schéma Physique (4ème version; Index)

SQL₂

```
create table COURS          (NUM_COURS          NUMBER(2),  
... constraint PK_COURS primary key (NUM_COURS), ... );  
  
create table PROFESSEURS    (NUM_PROF          NUMBER(4),  
... constraint PK_PROFESSEURS primary key (NUM_PROF), ... );  
  
create table CHARGE         (NUM_PROF          ..., NUM_COURS          ...,  
constraint PK_CHARGE primary key (NUM_COURS, NUM_PROF)  
constraint FK_CHARGE_COURS foreign key (NUM_COURS) references COURS (NUM_COURS), ...);
```

La création des tables se fait en plusieurs étapes :


Les **attributs** ainsi que leurs **domaines** de définitions (les types de données);

Certaines **contraintes** , **CARACTERISTIQUES PHYSIQUES**

Faut-il **créer/détruire des index** pour accélérer les traitements ?

```
CREATE INDEX NDX_PROF ON PROFESSEURS (NUM_PROF) ;  
CREATE INDEX NDX_COURS ...
```





Implantation de BD / Administration d'une BD

Schéma Physique (4ème version; Index)

Faut-il **créer/détruire/reconstruire**
des **index** pour accélérer les traitements ?


SQL₂

Quel type d'index ? **Arbre-B (B-tree)**, **Bitmap** ou **Hachage** ?

```
CREATE INDEX NDX_PROF ON PROFESSEURS (NUM_PROF) ;  
CREATE BITMAP INDEX NDX_PROF ON PROFESSEURS (NUM_PROF) ;  
CREATE INDEX idx_nom ON PROFESSEURS (NOM_PROF) USING HASH ;
```

```
CREATE INDEX NDX_COURS ...
```






Implantation de BD / Administration d'une BD

Données (110 octets)		Index (14 octets)	
Clé Primaire (10 octets)	Information complémentaire (100 octets)	Clé Primaire (10 octets)	Adresse Physique (4 octets)
10	Info1	10	@1
15	Info2	15	@2
20	Info3	20	@3
30	Info4	30	@4
40	Info5	40	@5
50		50	
55		55	
77		77	
80		80	
100		100	
150		150	
250	Info k	250	@ k
1610	Info n	1610	@ n






Implantation de BD / Administration d'une BD

Données (110 octets)		Index (14 octets)	
Clé Primaire (10 octets)	Information complémentaire (100 octets)	Clé Primaire (10 octets)	Adresse Physique (4 octets)
10	Traifor, Paris, ...	30	@Bloc1
15	Lebon, Tunis, ...	77	@Bloc2
20	Clément, Médina	150	@Bloc3
30	Info4a, Info4b	1610	@Bloc4
40	Info5a, Info5b		
50	Info6a, Info6b		
55	Info7a, Info7b		
77	Info8a, Info8b		
80	InfoXa, InfoXb		
100	InfoYa, InfoYb		
150	InfoXa, InfoZb		
???	???		
250	Info k		
1610	Info n		
???	???		
???	???		





Implantation de BD / Administration d'une BD

Taille d'une **Table** & Taille d'un **Index**

Pour un bloc de 512 octets ; et pour un nombre d'enregistrements de l'ordre de 100 000

Pour les **données** :

Pour un nombre entier d'enregistrements par bloc ($512 / 110$), le nombre maximal d'enregistrements par bloc est 4.


Il faudrait donc ($100\,000 / 4$) **25 000 blocs de données.**

Pour les **index** :

Pour un nombre entier d'enregistrements par bloc ($512 / 14$), le nombre maximal d'enregistrements par bloc est 36.

Il faudrait donc ($100\,000 / 36$) **2778 blocs d'index.**







Implantation de BD / Administration d'une BD

INDEX A DEUX NIVEAUX

FICHIER DES DONNEES






Implantation de BD / Administration d'une BD

Un arbre B d'ordre P peut être défini comme suit (A B-tree of order P can be defined as follows) :

Plusieurs variantes B+, B* etc...

1. Chaque nœud interne possède la structure suivante :



2. Dans chaque nœud, $K_1 < K_2 < K_3 < \dots < K_{q-1}$

3. Pour chaque Clé de valeur X dans un sous arbre pointé par un pointeur P_i on a ; $K_{i-1} < X < K_i$ pour $1 < i < q$; $X < K_i$ pour $i = 1$; et $K_{i-1} < X$ pour $i = q$


Plusieurs dizaines de millions de clés,
Une dizaine d'accès disque au maximum
pour retrouver l'information !

4. Chaque nœud a au plus p pointeurs d'arbres.

5. Chaque nœud, excepté la racine et les nœuds feuille, a au moins $\sup(\text{ent}(P/2))$ pointeurs d'arbres. Le nœud racine a au moins 2 pointeurs d'arbres à moins qu'il soit le seul nœud de l'arbre.

6. Un nœud avec q pointeurs, $q \leq p$, a $q-1$ valeurs de clé (et donc a $q-1$ pointeurs de données).







Implantation de BD / Administration d'une BD

Structures Arbre B d'ordre 3.

Les valeurs ont été insérées dans l'ordre 8, 5, 1, 7, 3, 12, 9, 6





Implantation de BD / Administration d'une BD

Schéma Physique (5ème version; Cluster)

SQL₂

```
create table COURS (NUM_COURS NUMBER(2),  
... constraint PK_COURS primary key (NUM_COURS), ...);
```

```
create table CHARGE (NUM_PROF ..., NUM_COURS ...,  
constraint PK_CHARGE primary key (NUM_COURS, NUM_PROF)  
constraint FK_CHARGE_COURS foreign key (NUM_COURS) references COURS (NUM_COURS), ...);
```

La création des tables se fait en plusieurs étapes :

Les **attributs** ainsi que leurs **domaines** de définitions;

Les **contraintes** ; Les **Index** ;


Faut-il regrouper les données

(créer des clusters) pour accélérer les traitements ?

De nos jours, ce n'est plus préconisé par certains éditeurs (tel que Oracle)

```
CREATE CLUSTER CL_PROF ... ;
```





Implantation de BD / Administration d'une BD

Schéma Physique (nième version; Vues, Confidentialité, Optimisation)


```
create table COURS          (NUM_COURS          NUMBER(2)          NOT NULL,  
... constraint PK_COURS primary key (NUM_COURS) );  
  
create table PROFESSEURS    (NUM_PROF          NUMBER(4)          NOT NULL,  
... constraint PK_PROFESSEURS primary key (NUM_PROF) );  
  
create table CHARGE         (NUM_PROF          ..., NUM_COURS          ...,  
constraint PK_CHARGE primary key (NUM_COURS, NUM_PROF)  
constraint FK_CHARGE_COURS foreign key (NUM_COURS) references COURS (NUM_COURS)  
constraint FK_CHARGE_PROFESSEUR foreign key (NUM_PROF) references PROFESSEURS (NUM_PROF) );
```

Faut-il **créer des vues ?**

Quel type de vues *matérialisées ou pas* !

CREATE OR REPLACE VIEW V_PROF ... ;







Implantation de BD / Administration d'une BD

La commande **Create view** crée une nouvelle vue résultant d'une requête sur une ou plusieurs tables et/ou vues.

Une syntaxe de la commande Create view est :





Implantation de BD / Administration d'une BD

Schéma Physique (nième version; Vues, Confidentialité, Optimisation)

CREATE OR REPLACE VIEW Profs2000

AS

(SELECT NUM_PROF, NOM, SPECIALITE, DATE_ENTREE
FROM PROFESSEURS
WHERE DATE_ENTREE > '01-01-2000')

WITH CHECK OPTION ;

[WITH GRANT OPTION ;] attention confidentialité !


CREATE OR REPLACE VIEW Profs2000 (NP, NOMP, SP, DE)

AS (SELECT NUM_PROF, NOM, SPECIALITE, DATE_ENTREE
FROM PROFESSEURS WHERE DATE_ENTREE > '01-01-2000')

WITH CHECK OPTION ;

SQL₂







Implantation de BD / Administration d'une BD

La commande **Create snapshot** Crée un snapshot (une vue matérialisée).

Une syntaxe de la commande Create snapshot est :







Implantation de BD / Administration d'une BD

La commande **Create snapshot log** crée un snapshot log qui identifie les modifications apportées aux tables du snapshot depuis son dernier rafraîchissement.

Une syntaxe de la commande Create snapshot log est :





Implantation de BD / Administration d'une BD

Schéma Physique (nième version; Vues)

SQL₂

```
CREATE MATERIALIZED VIEW Profs2000  
BUILD {IMMEDIATE , DEFERED}  
REFRESH {COMPLETE,FAST,FORCE,NEVER}
```

AS

```
(SELECT NUM_PROF, NOM, SPECIALITE, DATE_ENTREE  
FROM PROFESSEURS  
WHERE DATE_ENTREE > '01-01-2000') ... ;
```




```
CREATE SNAPSHOT Profs2000
```

AS

```
(SELECT NUM_PROF, NOM, SPECIALITE, DATE_ENTREE  
FROM PROFESSEURS  
WHERE DATE_ENTREE > '01-01-2000') ... ;
```





Implantation de BD / Administration d'une BD

Schéma Physique (nième version; Partage de données)

```
create TABLE PROFESSEURS ( ... );  
create INDEX ... ;  
create or replace VIEW V_PROF ... ;
```

Faut-il **partager** les données ?


Faut-il **attribuer/retirer** des **privilèges d'accès** ?

Quel type de *droits d'accès* à accorder
aux autres utilisateurs !

```
GRANT SELECT ON Profs2000 TO PUBLIC ;  
GRANT INSERT ON Profs2000 TO user1 ;
```

```
REVOKE SELECT ON Profs2000 FROM PUBLIC ;
```





Implantation de BD / Administration d'une BD

Schéma Physique (nième version; Partage de données)

Différentes tâches de l'administrateur :

1. Après installation du logiciel

Architecture standard OFA

2. Création de la BD

(les fichiers selon OS ; plusieurs types de fichiers seront créés)

CREATE TABLESPACE NomBD

DATAFILE 'c:\Chemin\tablespaces\NomBD.dbf' SIZE 3M ;


-- 3 Mégas ou m Mégas

CREATE TABLESPACE NomBD

DATAFILE 'c:\Chemin\tablespaces\tmp_NomBD.dbf' SIZE 3M ;

-- 3 Mégas ou m Mégas





Implantation de BD / Administration d'une BD

Schéma Physique (nième version; Partage de données)

Différentes tâches de l'administrateur :

3. Création des utilisateurs


```
CREATE USER NomUser IDENTIFIED BY MotPasseUser  
DEFAULT TABLESPACE NomBD  
TEMPORARY TABLESPACE tmp_NomBD ;
```

Créer un rôle et un profil :

```
GRANT CONNECT TO NomUser ;  
GRANT RESOURCE TO NomUser ;  
GRANT SEL_CATALOG_ROLE TO NomUser ;
```

Les **droits connect** et **resource** permettent de faire pas mal de traitements sur oracle (créer des tables, des index, des vues, des triggers, du pl/sql etc..., le **droit sel_catalog_role** est très important pour pouvoir consulter le DD d'oracle et faire le suivi des optimisations.)





Implantation de BD / Administration d'une BD

Schéma Physique (nième version; Partage de données)

Différentes tâches de l'administrateur :

4. Destruction des utilisateurs ;


DROP USER NomUser **CASCADE** ;

5. Modification du mot de passe des utilisateurs ;

ALTER USER NomUser **IDENTIFIED BY** nouveaumotdepasse;

SHOW USER ; **SHOW ERRORS ; ...**







Implantation de BD / Administration d'une BD

La commande **Create user** crée un nouvel utilisateur de la base.

Une syntaxe de la commande Create user est :





Implantation de BD / Administration d'une BD

Schéma Physique (nième version; Partage de données)

Différentes tâches de l'administrateur :

Faut-il **partager** les données ?


Faut-il **attribuer/retirer des privilèges d'accès** ?

Quel type de *droits d'accès* à accorder aux *autres utilisateurs* !

```
GRANT {privilège_système | rôle} [, {privilège_système2 | rôle2} ...]  
      TO {utilisateur | rôle | PUBLIC} [, utilisateur2 ...]  
      [WITH GRANT OPTION] ;
```

```
REVOKE {privilège_système | rôle} [, {privilège_système2 | rôle2} ...]  
      FROM {utilisateur | rôle | PUBLIC} [, utilisateur2 ...] ;
```





Implantation de BD / Administration d'une BD

Schéma Physique (nième version; Partage de données)

Différentes tâches de l'administrateur :

Faut-il **partager** les données ?

Faut-il **attribuer/retirer** des **privileges d'accès** ?


Quel type de *droits d'accès* à *accorder aux autres utilisateurs* !

PRIVILEGES SYSTEME :

```
GRANT {privilege_système | rôle} [, {privilege_système2 | rôle2} ...]  
      TO {utilisateur | rôle | PUBLIC} [, utilisateur2 ...]  
      [WITH ADMIN OPTION] ou [WITH GRANT OPTION] ;
```

```
REVOKE {privilege_système | rôle} [, {privilege_système2 | rôle2} ...]  
      FROM {utilisateur | rôle | PUBLIC} [, utilisateur2 ...] ;
```





Implantation de BD / Administration d'une BD

Schéma Physique (nième version; Partage de données)

Différentes tâches de l'administrateur :


Faut-il **partager** les données ? Faut-il **attribuer/retirer** des **privileges d'accès** ?
Quel type de *droits d'accès à accorder aux autres utilisateurs* !

PRIVILEGES OBJET :

```
GRANT {privilege1 [(colonne11, [colonne12...])] | rôle} [, {privilege2  
[(colonne21...)] | rôle2} ...] ON SchémaDeLobjet  
TO {utilisateur | rôle | PUBLIC} [, utilisateur2 ...]  
[WITH GRANT OPTION] ;
```

```
REVOKE {privilege1 | rôle} [, {privilege2 | rôle2} ...] ON SchémaDeLobjet  
FROM {utilisateur | rôle | PUBLIC} [, utilisateur2 ...]  
[CASCADE CONSTRAINTS] ;
```





Implantation de BD / Administration d'une BD

La commande **Grant** donne des privilèges sur différents objets à un utilisateur existant.


PRIVILEGES SYSTEME


Grant System Privileges and Roles:

Gives system privileges to users and to roles.

Gives roles to users and other roles.

Une syntaxe de la commande Grant est :






Implantation de BD / Administration d'une BD


Objects privileges:

Gives privileges for a particular object (a table, view, synonym, package, procedure, ...) to users and to roles.

PRIVILEGES OBJETS

Une syntaxe de la commande Grant est :








Implantation de BD / Administration d'une BD

La commande **Revoke** supprime les privilèges système, rôles et privilèges sur les objets d'un utilisateur (en opposition à Grant).

Une syntaxe de la commande Revoke est :







Implantation de BD / Administration d'une BD

La commande **Lock table** force le mode de lock (verrouillage) et réserve l'accès à une table à la session courante.

Permet ou restreint l'accès des autres utilisateurs.

Une syntaxe de la commande Lock table est :





Implantation de BD / Administration d'une BD

Schéma Physique (nième version; Partage de données)


Différentes tâches de l'administrateur :

Notion de **rôle** :

Les principaux rôles, prédéfinis par Oracle et attribués aux utilisateurs SYSTEM et SYS, sont :

Rôle	Privilège système
CONNECT	CREATE SESSION, CREATE TABLE, ...
RESOURCE	CREATE CLUSTER, CREATE PROCEDURE, ...
DBA	Tous les privilèges






Implantation de BD / Administration d'une BD

Schéma Physique (nième version; Partage de données)

Différentes tâches de l'administrateur :




Notion de **rôle** :



CREATE ROLE LeNomDuRôle ;

GRANT LePrivlège ON Lobjet **TO** LeNomDuRôle ;





Implantation de BD / Administration d'une BD

Schéma Physique (nième version; Partage de données)

Différentes tâches de l'administrateur :

Notion de **profil** :

Un profil est un ensemble de ressources limitées, à attribuer aux utilisateurs : des caractéristiques physiques telles que :


Un % d'utilisation dans un tablespace ;

Un nombre de connexions ;

Une priorité d'exécution des requêtes etc...

CREATE PROFILE etc. ;






Implantation de BD / Administration d'une BD

Schéma Physique (nième version; Partage de données)

```
Create profile profexpl limit  
Session_per_user 1  
Idle_time 120  
connect;
```

- Affecter le profil à l'utilisateur scott
Alter user scott profile profexpl ;







Implantation de BD / Administration d'une BD

La commande **Create profile** crée un profil utilisateur et spécifie ses autorisations et limitations.

Une syntaxe de la commande Create profile est :







Implantation de BD / Administration d'une BD

La commande **Create role** crée un rôle spécifiant des autorisations spécifiques.

Une syntaxe de la commande Create role est :







Implantation de BD / Administration d'une BD

La commande **Commit** sauvegarde les modifications de données de la session courante dans la base de données (en opposition à la commande **Rollback**). Supprime aussi les savepoints et libère les (verrous) locks de la session courante.

Une syntaxe de la commande Commit est :






Implantation de BD / Administration d'une BD


La commande **Rollback** annule tous les changements apportés depuis le savepoint. Annule tous les changements de la session courante si aucun savepoint n'est spécifié (en opposition à **Commit**).


Une syntaxe de la commande Rollback est :



La commande **Savepoint** identifie un point de sauvegarde dans la session courante depuis lequel les transactions pourront être annulées via la commande **rollback**.

Une syntaxe de la commande Savepoint est :





Implantation de BD / Administration d'une BD

Schéma Physique

Différentes tâches de l'administrateur :

La plus demandée, La plus difficile, ...



Optimiser ? !

Schéma(s)

Requête(s)


Architecture(s)

Qualité des données !

Administrer ... (Confidentialité, Sécurité, Validité... des données)

Cumuler l'expérience ...







Implantation de BD / Administration d'une BD

Architecture centralisée

- Cette architecture correspond aux premières générations de SGBD (mainframe).
- Elle est de plus en plus abandonnée au profit de l'architecture distribuée ou répartie.







Implantation de BD / Administration d'une BD

Architecture répartie/distribuée

- Dans cette architecture, les données et les applications sont réparties sur des ordinateurs différents.





Implantation de BD / Administration d'une BD

Manipuler/Interroger les tables/vues : Une requête

SQL peut donc être formulée comme suit :

SELECT

FROM

Ces deux commandes sont
obligatoires

N'est nécessaire que s'il y a des
conditions à exprimer :
des conditions de sélections et/ou
des conditions de jointures

WHERE

ORDER BY


N'est nécessaire que s'il y a
un **classement** à effectuer.

GROUP BY

HAVING

N'est nécessaire que s'il y a un
groupement à effectuer.
Le HAVING permet de faire des
sélections sur le GROUP BY






Implantation de BD / Administration d'une BD


Manipuler/Interroger les tables/vues

La commande **Select** interroge une ou plusieurs tables ou vues. Retourne les données des lignes et colonnes.

La commande **Select** peut être utilisée pour une requête ou une sous-requête SQL.

*Une syntaxe de la commande **Select** est :*





Implantation de BD / Administration d'une BD

Manipuler/Interroger les tables/vues

La commande **Select** interroge une ou plusieurs tables ou vues. Retourne les données des lignes et colonnes. La commande **Select** peut être utilisée pour une requête ou une sous- requête SQL.

SQL Avancé :

SELECT ... FROM ... WHERE ... GROUP BY ... HAVING ... ORDER BY ... ;

SELECT ... FROM ... (**SELECT ... FROM ... WHERE ...**) ...
WHERE ... GROUP BY ... HAVING ... ORDER BY ... ;


SELECT ... FROM ... WHERE ... GROUP BY ... **CUBE()|ROLLUP()...** ;

SELECT **RANK() OVER()...** FROM ... WHERE ; SELECT **HINT...** FROM ... WHERE ;

SELECT ... FROM ... WHERE ... **CONNECT BY PRIOR START WITH LEVEL ...** ;


Etc... full outer join, left outer join, right outer join, merge, select case, insert all...






Implantation de BD / Administration d'une BD

Manipuler/Interroger les tables/vues



3. Qualité des données

*Think **Bigger**, Differently & **Smarter** by using **DATA***



Smart



... Les Données & leur qualité...


Gestion de la Qualité des Données

Donner un sens aux données rassemblées

**Les données récupérées et
éventuellement transformées
sont-elles fiables ?**




Plusieurs types d'anomalies (Intra-Colonne, Inter-Colonnes et Inter-Lignes)




To summarize

How to **detect, automatically**, the abnormal data ?



How to **correct, automatically**, these anomalies **without creating new ones?**






Anomalies détectées / Attention aux Mises à Jour / Anomalies corrigées

To summarize

How to **detect, automatically,** the abnormal data ?




How to **correct, automatically,** these anomalies **without creating new ones?**





Donner un SENS aux données rassemblées



De nombreuses questions, **relatives à la qualité**, doivent être posées au cours du **processus de creation et/ ou d'intégration** :

- * **Compatibilité** des types de données (**syntaxique**)
- * **Compatibilité sémantique**
- * Les contraintes sur les données
- * Transformer / Corriger / Nettoyer / Valider des données
- * Enrichir / Compléter les données
- * Gérer les dépendances sémantiques
- * Gérer les Doubles & les Similaires
- * Gérer les métadonnées

→ **Comment le savoir ?**

→ La **syntaxe** oui mais plus de **sémantique** !



...Des questions sur Les Données, La Data?...



Think **Bigger**,
Differently
& **Smarter** by
using **correct**
DATA

Meta-Data
Dictionaries

DB : Data Base
DS : Data Source

CSV X

Dr. Smart DATA

Data Base Checklist

☒	Normal Forms
☐	Missing Values
☒	Heterogeneity
☒	Functional Dependencies
☒	Analysis Metrics
☐	Duplicates

DATALOGUE

QUALI-SCORE

ABCDE

Smart DATA

iDQMS: an Intelligent Data Quality Management System

Think **Bigger**, Differently & **Smarter**
by using **correct** DATA

ABCDE

QUALI-SCORE

Smart DATA

iDQMS : intelligent Data Quality Management System





Donner un SENS aux données rassemblées



BD1-Cli						
NomCli	PrénomCli	Catégorie	Score	Type	Adresse	Mail
C(20)	C(20)	F, M	[0..20]	1, 2, 3	C(150)	C(200)

Le Bon	Adam	M	19	1	2, r de la Paix 75008 Paris France	adm@yahoo.fr
Clément	Clémence	F	16	2	5, r de Belleville 75019 Pari Franc	cc@gmail.fr
Premier	Inès	F	7	2	27, r de la Paix 75008 Paris	titi@yahoo.fr



BD2-Clients						
Nom	Prénom	Sexe	Note	CatégSoc	AdrPays	Courriel
C(30)	C(30)	N(1) !	[0..10]	A, B, C, D, E	C(50)	C(100)

Le Bon	Adamo	1	9	A	France	adm@yahoo.fr
Clément	Lina	0	7	E	France	clina@orange.fr
First	Inès	0	3	A	Espagne	cmoi@gmail.com
Adem	LeBon	1	8	A	France	adm@yahoo.fr

ED Résultat de l'intégration Cli-Clients						
Nom	Prénom	Sexe	Score	CatégSoc	Pays	Mail
C(20)	C(20)	F, M	[0..20]	1, 2, 3	C(150)	C(200)
C(30)	C(30)	N(1) ! 0,1	[0..10]	A, B, C, D, E	C(50)	C(100)

Le Bon	Adam	M	19	1	2, r de la Paix 75008 Paris France	adm@yahoo.fr
Clément	Clémence	F	16	2	5, r de Belleville 75019 Pari Franc	cc@gmail.fr
Premier	Inès	F	7	2	27, r de la Paix 75008 Paris	titi@yahoo.fr
Le Bon	Adamo	1	9	A	France	adm@yahoo.fr
Clément	Lina	0	7	E	France	clina@orange.fr
First	Inès	0	3	A	Espagne	cmoi@gmail.com
Adem	LeBon	1	8	A	France	adm@yahoo.fr

Des
anomalies,
Données
incorrectes

Doublons

Similaires

Valeurs nulles

Etc...






Donner un SENS aux données rassemblées

Homogénéisation des données intégrées

Homogénéisation, Standardisation, Normalisation... des données

Données intégrées : **Homogénéisation, Standardisation, Normalisation...** des données ;
Définition d'un **référentiel unique**






Donner un SENS aux données rassemblées

Homogénéisation des données intégrées

Homogénéisation, Standardisation, Normalisation... des données

Données intégrées : **Homogénéisation, Standardisation, Normalisation...** des données ;
Définition d'un référentiel unique





Donner un SENS aux données rassemblées

Quelques traitements à faire pour créer des données destinations correctes :

⇒ Transformations

- Catégorie (F,M) → Sexe/Genre (F,M)
- **Sexe (Non défini ou défini 0,1) → Sexe (F,M)**
 ??? 0/F, 1/M ou 1/F, 0/M -- bijection
- Type (1, 2, 3) → CatégorieSociale (1, 2, 3)
- CatégSoc (A, B, C, D, E) → CatégorieSociale (1, 2, 3)
 ??? 1/A, 2/B, 3/C, !/D, !/E -- pas de bijection
- **Note [0..10] → Score [0..20]**

⇒ Extraction/Déduction Adresse C(150) → Pays C(50)

55, r de Belleville 75019 Paris **Franc** → **France**

27, r de la Paix 75008 Paris NULL → **France**

⇒ Déduplication

Est-ce que **Le Bon Adamo** est la même personne que **Le Bon Adam** ?





Donner un SENS aux données rassemblées



BD1-Cli						
NomCli	PrénomCli	Catégorie	Score	Type	Adresse	Mail
C(20)	C(20)	F, M	[0..20]	1, 2, 3	C(150)	C(200)

Le Bon	Adam	M	19	1	2, r de la Paix 75008 Paris France	adm@yahoo.fr
Clément	Clémence	F	16	2	5, r de Belleville 75019 Paris France	cc@gmail.fr
Premier	Inès	F	7	2	27, r de la Paix 75008 Paris	tit@yahoo.fr

BD2-Clients						
Nom	Prénom	Sexe	Note	CatégSoc	AdrPays	Courriel
C(30)	C(30)	N(1)!	[0..10]	A, B, C, D, E	C(50)	C(100)

Le Bon	Adamo	1	9	A	France	adm@yahoo.fr
Clément	Lina	0	7	E	France	clina@orange.fr
First	Inès	0	3	A	Espagne	emoi@gmail.com
Adem	LeBon	1	8	A	France	adm@yahoo.fr

ED Résultat de l'intégration Cli-Clients						
NomCli	PrénomCli	Catégorie	Score	Type	Adresse	Mail
C(20)	C(20)	F, M	[0..20]	1, 2, 3	C(150)	C(200)

Nom	Prénom	Sexe	Note	CatégSoc	AdrPays	Courriel
C(30)	C(30)	N(1)!	[0..10]	A, B, C, D, E	C(50)	C(100)

Nom	Prénom	Sexe	Score	CatégSoc	Pays	Mail
C(30)	C(30)	F, M	[0..20]	1, 2, 3	C(50)	C(200)

Le Bon	Adam	M	19	1	France	adm@yahoo.fr
Clément	Clémence	F	16	2	France	cc@gmail.fr
Premier	Inès	F	14	2	France	tit@yahoo.fr
Clément	Lina	F	14	3	France	clina@orange.fr
First	Inès	F	6	1	Espagne	emoi@gmail.com

Données correctes

Peu ou Sans

doublon(s), ni
similaire(s), ni
redondance(s), ni
valeur(s) nulle(s) !!!
Etc...

- Quel **schéma** résultat ?
- Quelles **transformations** ?
- **Elimination** des **similaires**, des **doubles** et des **redondances** !
- Enrichissement des données !





Plusieurs types d'anomalies (Intra-Colonne, Inter-Colonnes et Inter-Lignes)

Clients						
	Nom Prénom	Téléphone	Mail	Catégorie	Ville	Chiffre d'affaires
t1	Le Bon Adam	0653545577	adam@yahoo.fr	1	Londres	1000
t2	Le Bon A.	0653545555	-	1	London	2000 £
t3	Grande Clémence	0607080911	clemence@gmail.com	2	Epinay sur seine	1000
t4	Adam LeBon	0653545555	adam@yahoo.fr			
t5	Grande Clémence	607080911	clemence@gmail.com	2	Epinay / seine	1000
t6	Le Bon	0653545577	adam@yahoo.fr	1	Londres	-
t7	Belle Inès	0708091122	belleines@yhoo.fr	3	Epinay-Villetaneuse	3000
t8	Rahma Adam	-	-	3	Epinay-sur-seine	1000
t9	Riche Emir	0908070605	-	3	Qatar	20000000000
t10	Traifor Eve	0666622223	traifor@up13.fr	1	Pékin	1000
t11	Traifor Eve	0666622223	traifor@up13.fr	1	Beijing	1000
t12	LeBon Adel	0653545599	alebon@up13.fr	1	Paris	-
t13	LeBon Adem	-	adam@obsolete.uk	1	Londre	-

Des SIMILAIRES

Des DOUBLONS

Des données obsolètes

Donnée NON Standard

Donnée NON Standard

Donnée NON Valide

Des valeurs aberrantes

- Les algorithmes, pour les corriger, sont très coûteux en terme de temps de réponse
 - Comment savoir ce qu'il y a à corriger et ce qu'il faut corriger ?
- Comment corriger ?



Elimination des doubles et des similaires

L'élimination des doubles et des similaires, appelée **déduplication des données** (**Record Linkage, Duplicates Data, Entity Resolution, Entity Matching**), consiste à **détecter** les lignes doubles ou similaires afin d'éliminer certaines redondances dans une source de données (**Comparaison/Match**).

Les lignes similaires ou en double pourraient être fusionnées ou encore éliminées (**Fusion/Merge**).

Cette problématique continue à faire l'objet de plusieurs travaux de recherche, d'une part, afin d'**améliorer les performances des algorithmes** pour de très **gros volumes de données**, et d'autre part, afin d'**obtenir de meilleures précisions** quant au **calcul de similarité** entre les lignes à cause des différentes anomalies qui existent dans les données.

En effet, la similarité entre les données est basée sur les **différentes méthodes de mesures de distances de similarités** qui existent dans la littérature telles que :

- (i) les **mesures lexicographiques** [**s'écrit comme**]
(Levenshtein -Edit-Distance-, Jaro-Winkler, Q-Gram...), ou
- (ii) les **mesures phonétiques** [**se prononce comme**, **attention ! les langues**]
(Soundex, Double Metaphone !).

Elimination des doubles et des similaires

Doubles ? Similaires ?

Vrais - Faux amis !

Faux - Vrais amis !



Clients					
Nom Prénom	Téléphone	Mail	Catégorie	Ville	Chiffre d'affaires
Le Bon Adam	0653545577	adam@yahoo.fr	1	Londres	1000
Le Bon A.	0653545555	-	1	London	2000
Adam LeBon	0653545555	adam@yahoo.fr			
Le Bon	0653545577	adam@yahoo.fr	1	Londres	-
Traifor Eve	0666622223	traifor@up13.fr	1	Pékin	1000
Traifor Eve	0666622223	traifor@up13.fr	1	Beijing	1000
LeBon Adel	0653545599	alebon@up13.fr	1	Paris	-

Algorithmes de calcul de distance de similarité (JW, J, L, S, M...) & Seuil (s_i)					
<i>S'écrit comme</i> <u>Jaro-Winkler</u>	<i>S'écrit comme</i> <u>Jaccard</u>	<i>S'écrit comme</i> <u>Levenshtein</u>		<i>Se prononce comme</i> <u>Metaphone</u>	
s_1	s_2	s_3	!!	s_5	!!

Le Bon Adam	$\approx$	LeBon A.	$\approx$	Adam Le Bon
Pékin	$\approx$	Beijing		

Elimination des doubles et des similaires

Difficulté de **choisir un algorithme** de calcul de distance de similarité
(*Levenshtein [Edit_Distance] ; Jaro-Winkler...*)

Difficulté de **fixer** un seuil de similarité

- Pékin $\neq$ Beijing Londres $\approx =$? Ou $\neq$ London $\Rightarrow =$ ou $\approx$
- lipn-tous@lipn.univ-**paris13**.fr $\approx$ lipn-tous@lipn.univ-**pari13**.fr $\Rightarrow =$ ou $\approx$
- **y**b@lipn.univ-paris13.fr $\approx$ **f**b@lipn.univ-paris13.fr $\Rightarrow \neq$

La comparaison lexicographique n'est pas suffisante ! Ville – Mail

$\Rightarrow$ Plus de Sémantique



Elimination des doubles et des similaires *Match/Merge*

Clients						
	Nom Prénom	Téléphone	Mail	Catégorie	Ville	Chiffre d'affaires
t1	Le Bon Adam	0653545577	adam@yahoo.fr	1	Londres	1000
t2	Le Bon A.	0653545555	-	1	London	2000
t4	Adam LeBon	0653545555	adam@yahoo.fr			

Déf. A : Similarité entre tuples

2 tuples t_i et t_j ($i \neq j$) sont similaires ssi la disjonction des q règles de similarité

définies sur la table $T(A,B)$ est vraie. On note $t_i \approx t_j$ ssi $r_1 \vee r_2 \vee \dots \vee r_k \dots \vee r_q$

(q étant le nombre de règles de similarité, A l'ensemble des attributs clé A_a $a=1,n$ et B l'ensemble des attr. non clé)

$$t_1 \approx t_2 \text{ ssi } R_{\text{ules}} = \text{Vrai} \quad R_{\text{ules}} = r_1 \vee r_2 \vee \dots \vee r_k \dots \vee r_q$$

Règle : $r_1 [(Nom_1 \approx Nom_2) \wedge (Mail_1 \approx Mail_2) \wedge (Ville_1 \approx Ville_2)]$

Règle : $r_2 [(Mail_1 \approx Mail_2) \wedge (Téléphone_1 \approx Téléphone_2)]$

...

Règle : r_q





Elimination des doubles et des similaires *Match/Merge*

Clients						
	Nom Prénom	Téléphone	Mail	Catégorie	Ville	Chiffre d'affaires
t1	Le Bon Adam	0653545577	adam@yahoo.fr	1	Londres	1000
t2	Le Bon A.	0653545555	-	1	London	2000
t4	Adam LeBon	0653545555	adam@yahoo.fr			

1-Les attributs de l'ensemble A (Attributs clés) ?

Nom-Prénom ; Mail ? ... → Comparaison/Match

2-Les attributs de l'ensemble B (Attributs non clés) ?

Catégorie, Chiffre d'affaires ? ... → Fusion/Merge

3-Les algorithmes et les seuils de comparaison

Blocking key ! Clé de blocage !





Elimination des doubles et des similaires *Match/Merge*

	Clients					
	Nom Prénom	Téléphone	Mail	Catégorie	Ville	Chiffre d'affaires
t1	Le Bon Adam	0653545577	adam@yahoo.fr	1	Londres	1000
t2	Le Bon A.	0653545555	-	1	London	2000
t4	Adam LeBon	0653545555	adam@yahoo.fr			

$\text{Nom}_1 = t_1.\text{NomPrénom}$; $\text{Nom}_2 = t_2.\text{NomPrénom}$

$\text{Nom}_1 \approx \text{Nom}_2$ ssi $d_1 \leq s_1$

$d_1 = \text{Jaro-Winkler}(\text{'Le Bon Adam'}, \text{'Le Bon A.'})$ ou $d_1 = \text{Levenshtein}(\text{'Le Bon Adam'}, \text{'Le Bon A.'})$

Les *seuils* s_a et les *algorithmes* de calcul de distance sont donnés par l'utilisateur !

→ **MATCH**

Quelles **valeurs garder** ? « *La chaine la plus longue vérifiant une expression régulière, le maximum...* »

1-Les attributs de l'ensemble A: Nom-Prénom ...

2-Les attributs de l'ensemble B: Catégorie, Chiffre d'affaires

→ **MERGE**





Elimination des doubles et des similaires *Match/Merge*

Clients						
	Nom Prénom	Téléphone	Mail	Catégorie	Ville	Chiffre d'affaires
t1	Le Bon Adam	0653545577	adam@yahoo.fr	1	Londres	1000
t2	Le Bon A.	0653545555	-	1	London	2000
t4	Adam LeBon	0653545555	adam@yahoo.fr			

Les algorithmes de calcul de distance de similarité donnent :

Le Bon Adam $\neq$ Adam LeBon

La comparaison lexicographique n'est donc pas suffisante ! $\Rightarrow$ Plus de **Sémantique**

Afin de « forcer » l'égalité **Le Bon Adam = Adam LeBon** on introduit la règle de similarité des **DF** :

La règle r_2 est issue de la **dépendance fonctionnelle** avec des seuils proches de 0 pour Mail et Téléphone :

Mail, Téléphone $\rightarrow$ Nom-Prénom





Elimination des doubles et des similaires *Match/Merge*

Clients						
	Nom Prénom	Téléphone	Mail	Catégorie	Ville	Chiffre d'affaires
t1	Le Bon Adam	0653545577	adam@yahoo.fr	1	Londres	1000
t2	Le Bon A.	0653545555	-	1	London	2000
t4	Adam LeBon	0653545555	adam@yahoo.fr			

Déf. B : Similarité entre tuples

2 tuples t_i et t_j ($i \neq j$) sont similaires ssi ; on note $t_1 \approx t_2$ ssi

$$\sum_{a=1,n} p_a d_a \leq S$$

d_a (distance calculée par un des algorithmes de calcul de similarité, pour un attribut A_a donné)


p_a (le poids pour un attribut A_a donné) et S un seuil GLOBAL donné

Les *poids*, les *algorithmes* et le *seuil global* sont *donnés* par *l'utilisateur* !



Dépendance Fonctionnelle (DF & DFA)

Élimination des similaires et dépendances fonctionnelles



- A une date donnée une équipe ne peut jouer que dans un seul stade
 DateMatch, CodeEquipeLocale → RefStade
 DateMatch, CodeEquipeVisiteuse → RefStade
- A une date donnée une équipe ne peut jouer que contre une seule équipe
 DateMatch, CodeEquipeLocale → CodeEquipeVisiteuse

MATCH						Erreur ?!
NumeroMarch	DateMatch	CodeEquipeLocale	CodeEquipeVisiteuse	RefStade	...	
M1	09-06-2012	Allemagne	Portugal	S1		
M2	13-06-2012	Hollande	Allemagne	S2		
M3	10-06-2012	France	France	S1		OUI
M3 : Une équipe ne peut pas jouer avec elle-même !						
M4	11-06-2012	France	Angleterre	S2		OUI
M5	11-06-2012	France	Allemagne	S3		OUI
M4 & M5 : Une équipe ne peut pas jouer contre deux équipes le même jour dans deux stades différents ! Quelle ligne faut-il supprimer (M4 ou M5) ?						
M6	19-06-2012	Suède	France	S4		
M7	Etc...	Etc...	Etc...	Etc...		

Dépendance Fonctionnelle (DF & DFA)


Les contraintes définies sur le schéma conceptuel ne suffisent pas pour éviter des données (lignes) erronées dans la BD !

La **détection des lignes erronées** n'est qu'une **partie du problème** !

La question est : **Quelle(s) ligne(s) faut-il enlever** afin d'éliminer l'erreur !

→ ++ **Sémantique** !

Elimination des similaires et dépendances fonctionnelles



- A une date donnée une équipe ne peut jouer que dans un seul stade

DateMatch, CodeEquipeLocale → RefStade

DateMatch, CodeEquipeVisiteuse → RefStade

- A une date donnée une équipe ne peut jouer que contre une seule équipe

DateMatch, CodeEquipeLocale → CodeEquipeVisiteuse

MATCH						Erreur ?!
NumeroMarch	DateMatch	CodeEquipeLocale	CodeEquipeVisiteuse	RefStade	...	
M1	09-06-2012	Allemagne	Portugal	S1		
M2	13-06-2012	Hollande	Allemagne	S2		
M3	10-06-2012	France	France	S1		OUI
M3 : Une équipe ne peut pas jouer avec elle-même !						
M4	11-06-2012	France	Angleterre	S2		OUI
M5	11-06-2012	France	Allemagne	S3		OUI
M4 & M5 : Une équipe ne peut pas jouer contre deux équipes le même jour dans deux stades différents !						
Quelle ligne faut-il supprimer (M4 ou M5) ?						
M6	19-06-2012	Suède	France	S4		
M7	Etc...	Etc...	Etc...	Etc...		




4. *Intégration de données*

(Bases, Entrepôts, Lacs, Référentiel...)

Data Base, Data Warehouse, Data Lake, Master Data

Think Bigger, Differently & Smarter by using DATA




Smart



DoD : des Données aux Décideurs !

Bases de Données - Data Bases



Entrepôts de Données - Data WareHouses

Lacs de Données - Data Lakes

Masses de Données - Big-Data

M. Faouzi BOUFARES

boufares@lipn.univ-paris13.fr

<http://www.lipn.univ-paris13.fr/~boufares/>

Bureau B209

Laboratoire d'Informatique de Paris Nord

LIPN – UMR 7030 du CNRS

La MSN, A3, ADA

Université Sorbonne Paris Nord

Institut Galilée

99, Avenue J.B. Clément

F-93430 Villetaneuse FRANCE

www.univ-paris13.fr

faouzi.boufares@sorbonne-paris-nord.fr



DoD : des Données aux Décideurs !

BD-DB ; ED-DW-DL ; BigData

Entrepôts de Données, Introduction

M. Faouzi BOUFARES

boufares@lipn.univ-paris13.fr

<http://www.lipn.univ-paris13.fr/~boufares/>

Bureau A109

Laboratoire d'Informatique de Paris Nord

LIPN – UMR 7030 du CNRS

La MSN, A3, ADA

Université Sorbonne Paris Nord

Institut Galilée

99, Avenue J.B. Clément

F-93430 Villetaneuse FRANCE

www.univ-paris13.fr

faouzi.boufares@sorbonne-paris-nord.fr

Plusieurs professionnels sont intervenus et/ou interviennent dans le cadre de ce cours :

R. Nefoussi, **Diac Renault**

S. Correia, **Talend**

I. Rebaï, **Orange**

C. Clairemont, **SynAltic**

L. Chorfi, **Micropole**

B. Chantouf, **Smile**

T. Arib, **Intelligence Power**

F. Sahli, **Société Générale**

P. Julio, **Keyrus**

O. Carbone, **Talend**

Zak, **CGI**

H. Zaidi, **Talend-ENT**

BD-DB ; ED-DW-DL ; BigData



Quelques Outils & Entreprises partenaires :



ORACLE



PostgreSQL



spark



APACHE
HBASE



mongoDB



talend*
*open data solutions

Business Objects™



sas | THE POWER TO KNOW.



KEYRUS
insight into value


MICROPOLÉ
Driving Distinction



Smile
OPEN SOURCE SOLUTIONS

Intelligence
Power

Les Bases de Données et la suite...!



Introduction : Intégration de données

A l'ère du **déluge des données** la **qualité des données** est plus que jamais à **l'ordre du jour** :

(données de productions ; données du Web ; données ouvertes -*Open Data*- ; données dormantes non encore utilisées -*Dark Data*- beaucoup de données textuelles non structurées ; les *Big Data* ; ...).

En effet, de nos jours, tout type d'organisation a besoin **d'intégrer (collecter, assembler) des données** en provenance de **diverses sources distribuées, hétérogènes et de qualités variables**.

Le plus souvent, **les descriptifs des données**, dans les sources, sont **mal renseignés** voire **inexistants**.

Par conséquent, **l'assemblage des données peut être dénué de tout sens** et le **résultat obtenu peut contenir de nombreuses anomalies**.

Introduction : Intégration de données

Données internes (Opérationnelles de production)

Bases de données (Structurées et Non structurées)

Fichiers (Plats, Textes, CSV, PDF...)

Applications (Paye, Gestion des RH, Commandes & Facturations...)

Données externes (Web, Open Data, Dark Data, ...)


Caractéristiques de ces données

Distribuées

Hétérogènes (systèmes et structures de données différents)


Détaillées (peu ou pas adaptées à l'analyse)

Qualité très variable (plutôt mauvaise, plusieurs anomalies)




... Intégration de Données ...

Smart



... Intégration de Données ...

Smart



... Intégration de Données ...



Un entrepôt de données (DWH) est élaboré en intégrant une ou plusieurs **bases de données**, elles-mêmes constituées de plusieurs **tables**, chacune étant composée de plusieurs **colonnes**.

$$\begin{aligned} \text{DWH} &\subseteq \{ \oplus \otimes \text{BD}_i \ i=1,n \} \\ \text{BD}_i &= \{ \otimes \text{T}_{i,j} \ j=1,m \} & \text{T}_{ij} &= \{ \text{C}_{i,j,k} \ k=1,p \} \end{aligned}$$

La structure simplifiée d'un entrepôt de données conçu pour l'aide à la décision peut être représentée sous la forme d'un **schéma** en étoile, où une **table des faits**, contenant les **mesures et indicateurs calculés**, est entourée de **tables de dimensions** servant **d'axes d'analyse**.




... Intégration de Données ...



$$\text{DWH} \subseteq \{ \oplus \otimes \text{BD}_i \mid i=1, n \}$$
$$\text{BD}_i = \{ \otimes T_{i,j} \mid j=1, m \}$$

$$T_{ij} = \{ C_{i,j,k} \mid k=1, p \}$$



... Intégration de Données ...



$$DWH \subseteq \{ \oplus \otimes BD_i \ i=1,n \}$$

$$BD_i = \{ \otimes T_{i,j} \ j=1,m \}$$

$$T_{ij} = \{ C_{i,j,k} \ k=1,p \}$$

$$T_Dim1 \supseteq \oplus_{i=1,n'; b=1,m'} T_{i,b}$$

(Clé11, Col12, ... Col1_D1)

$$T_Dim2$$

(Clé21, Col22, ... Col2_D2)





T_Faits
(*Clé11, Clé21, Clé31...* Mesures|Indicateurs)

$$T_Dim3(\underline{Clé31}, Col32, \dots Col2_D3)$$


T_Dimension...




Introduction : Exemple de BD GesCom à intégrer



Introduction : Quelques types de modèles de données à construire




Modèle en étoile



Modèle en flocon

Introduction : Exemple de BD GesCom à intégrer




Comment

Fusionner/Assembler/Intégrer


toutes ces BD, toutes ces données ?

Quels sont les problèmes ?


- Quel sens (sémantique) ?
- Quelle Qualité ?
- Quel est l'objectif (quel but) ?






Introduction : Exemple de modèle en étoile



Introduction : Exemple de modèle en flocon



Introduction : Exemple de modèle en étoile



Conception de BD


Architecture de BD

Structure de Données

Schéma de Données

Ensembles de données

Vues



$EDON_DWH\text{-}ServicesH\acute{o}pital = \{BD_i, i=1,h\}$ $EDON_DWH\text{-}H\acute{o}pitaux = \{BD_i, i=1,h\}$

Introduction : Intégration de données

A	B	C	D	E	F	G
ID	NOM	Prénom	Poste	Pays d'origine	Année2Naissance	
1991AlgMah	Mahrez	Riyad	Milieu	Algérie	1991	
1986AllNeu	Neuer	Manuel	Gardien	Allemagne	1986	
1989AllMül	Müller	Thomas	Milieu	Allemagne	1989	

A	B	C	D	E
ID	FirstName	LastName	Position	Country_Origin
GERGK01	Manuel	NEUER	Goalkeeper	GERMANY
GERGK02	Marc-André	TER STEGEN	Goalkeeper	GERMANY
FNGGK03	Nick	POPE	Goalkeeper	ENGLAND

A	B	C	D	E	F
ID	NOM	Prénom	Poste	Pays2Naissance	Année2Naissance
1	Di Stéfano	Alfredo	Attaquant	Argentine	1926
2	Yashin	Lev	Gardien	Russie	1929
3	Banks	Gordon	Gardien	Angleterre	1937
4	Pelé	Edson	Attaquant	Brésil	1940
5	Zoff	Dino	Gardien	Italie	1942

A	B	C	D	E	F	G
Name	Nationality	Position	Club	Caps	Goals	Date of Birth
Alex Morgan	USA	Forward	San Diego Wave	200	120	21/04/1989
Megan Rapinoe	USA	Winger	OL Reign	185	75	27/09/1985
Sam Kerr	Australia	Forward	Chelsea	150	110	15/09/1993
Lucy Bronze	England	Defender	Barcelona	130	12	06/10/1991
Amandine Henry	France	Midfielder	Olympique Lyonnais	150	25	15/12/1989
Marta Vieira da Silva	Brazil	Forward	Orlando Pride	180	112	05/02/1986

A	B	C
Prénom	Nom	Type2Blessure_Grave
Rodri	Hernández	Rupture du ligament croisé du genou
Dani	Carvajal	Rupture du ligament croisé du genou
Eder	Militão	Rupture du ligament croisé du genou
Mauro	Icardi	Rupture du ligament croisé du genou
Gianluca	Scamacca	Rupture du ligament croisé du genou

EDON_DWH-JOUER-FOOTBALL $\rightarrow$ DWH $\subseteq \{ \oplus \otimes \text{BD}_i \mid i=1,n \} \rightarrow$ **Tables à intégrer**


DataSource	ID_footballer	Gender	FirstName	LastName	Position	CountryOfOrigin	YearOfBirth	Club	Caps	Goals	Serious_injury
------------	---------------	--------	-----------	----------	----------	-----------------	-------------	------	------	-------	----------------



DD : des Données aux Décideurs !

Exploration Informatique des Données et Décisionnel

Les entrepôts (les lacs) de données The Data Warehouses, Data lake



M. Faouzi BOUFARES

boufares@lipn.univ-paris13.fr

<http://www.lipn.univ-paris13.fr/~boufares/>

Bureau A109

Laboratoire d'Informatique de Paris Nord

LIPN – UMR 7030 du CNRS

La MSN, A3, ADA

Université Sorbonne Paris Nord

Institut Galilée

99, Avenue J.B. Clément

F-93430 Villetaneuse FRANCE

www.univ-paris13.fr

faouzi.boufares@sorbonne-paris-nord.fr

1. Introduction

La majeure partie des applications Bases de Données reposent aujourd'hui sur **trois** couches.

La couche la plus externe est celle de qui permet de présenter les données aux utilisateurs.

Elle est appelée "Graphical User Interfaces GUI".

La couche application intermédiaire inclut le programme de l'application elle même et ne stocke pas les données.

La couche la plus interne gère le stockage des données. Elle est appelée la couche Base de Données.

1. Introduction


Les applications

interrogent les données avec par exemple le langage SQL "Select" et les **mettent à jour** par l'intermédiaire des opérations "Insert, Update et Delete" qui constituent des **transactions**.

Celles-ci doivent avoir certaines propriétés telle que l'atomicité, la consistance...

Ce type d'application est appelé
"On-Line Transaction Processing OLTP".

1. Introduction



1. Introduction

Données volumineuses & Besoins nouveaux

→ Systèmes d'Information Décisionnel ;

Systèmes d'Aide à la Décision :

Rapports, Etats, Tableaux de Bord, Graphiques,
Synthèses, Groupement, Agrégat, Résumé ...

(Reporting Tools, Management Information System,
Executive Information System,
Decision Support System DSS).

1. Introduction

Contrairement aux *applications OLTP*,
qui **consultent et mettent à jour** les données des BD opérationnelles,
les ***DSS lisent*** les données seulement
pour avoir de nouvelles informations à partir des données sources.

Le bénéfice de cette approche est que seulement les
BD opérationnelles ont à être créées et maintenues.

Un ensemble de métadonnées est utilisé pour les 2 systèmes.
Les DSS ne nécessitent que des travaux supplémentaires mineurs.

1. Introduction

Cependant, il y a plusieurs **désavantages** quand le DSS et les application OLTP se partagent les mêmes BD.

Le **DSS** ne peut utiliser que les **données actuellement stockées** dans les BD ; et donc les **analyses historiques sont souvent impossibles** à cause des opérations de mises à jour qui changent les données historiques.

L'utilisation des BD en mode **multi-utilisateurs**, ce qui implique des opérations de verrouillage des données (Locking operations) et donc des problèmes de performances ; car les **requêtes analytiques** demandent l'**accès à de très grands nombre de tuples**.

1. Introduction

La solution est de **séparer**

la BD orientée Transaction
de la BD orientée Aide à la Décision ;

d'où la naissance du concept
Entrepôt de Données = Data Warehouse.

Les DW sont physiquement séparés des SGBD opérationnels (BD opérationnelles).

1. Introduction

Définition d'un Data Warehouse (Inmon 1996) :


Subject Oriented : The goal of the DW is to improve decision making, planing, and control of major subjects of entreprises such as customer relations, products, regions in contrast to OLTP applications that are organized arround the work-flows of the company.

Integrated : The data in the DW is loaded from different sources that store the data in different formats. The data has to be checked, cleansed and tranformed into a unified format to allow easy and fast access.

Time variant : In operational systems, data is valid as of the moment of access, whereas in DW systems the data is valid as of defined moment of time.

Non-volatile : After the data is inserted in the DW it is neither changed nor removed. The only exception are that false data is inserted or the capacity is exceeded and archiving becomes necessary.

1. Introduction



1. Introduction

Le DW **intègre des données** à partir
de **sources multiples et hétérogènes**

afin de **répondre aux requêtes du système d'aide à la décision.**

Ce type d'application est appelé
“ On-Line Analytical Processing **OLAP** ”.

OLAP permet la transformation des données
en information stratégiques.

1. Introduction

Un système de DW peut être formellement défini comme un triplet <BD cible, méta-données, un ensemble d'opérations>.

L'ensembles des opérations peut être présentés en 4 catégories.

Extraction (Extraction): Ces opérations permettent de filtrer les données à partir de données sources (BD, fichiers, sites web...) dans des BD temporaires.

Transformation (Transformation): Ces opérations permettent de transformer les données extraites dans un **format uniforme**.

Les **conflits** entre les **modèles**, les **schémas** et les **données** sont résolus durant cette phase.

Chargement (Load) : Ces opérations permettent de charger les données transformées dans la BD cible. La BD cible est souvent implantée avec un SGBD relationnel-objet.

Agrégat et Groupement (Agregating and Grouping) : La BD cible doit permettre de stocker les **données opérationnelles** et les **données issues de calculs**.

Les méta-données telles que la description des structures des données et les contraintes sont très utiles pour contrôler la validité des données.


1. Introduction

Les données des entreprises sont généralement :

- Surabondantes**
- Eparpillées**
- Peu structurées pour l'analyse**
- Focalisées pour améliorer le quotidien**



Prise de décision difficile



Apparition d'outils et de techniques visant à préparer les données pour l'analyse :

Le “Data warehousing”

Il s'agit d'une technique visant à extraire des données de différentes sources afin de les intégrer selon des formats plus adaptés à l'analyse et la prise de décision

1. Introduction : Définition d'un DW

Orientées sujet

Les données sont structurées par thèmes

Données intégrées

Données mises en forme et unifiées afin d'avoir un état cohérent

Le Data Warehouse est une collection de données orientées sujet, intégrées, non volatiles et historisées, organisées pour le support d'un processus d'aide à la décision.

Données non volatiles

Les données ne peuvent pas être supprimées ni modifiées une fois dans la base

Données historisées

Le référentiel temps doit être associé aux données

1. Introduction

Pourquoi pas des BD's pour data warehouses

- Les 2 systèmes sont performants
 - SGBD— calibrés pour l'OLTP: méthodes d'accès, index, contrôle de concurrence, reprise
 - Warehouse—calibrés pour l'OLAP: requêtes OLAP complexes, vue multidimensionnelle, consolidation.
- Fonctions et données différentes:
 - Données manquantes: l'aide à la décision a besoin des données historiques qui ne se trouvent pas dans les BD's opérationnelles
 - Consolidation: l'AD a besoin de données consolidées (agrégats) alors qu'elles sont brutes dans les BD's opérationnelles

1. Introduction : Comparaison

Data Warehouse vs. SGBD hétérogènes

- Traditionnellement, l'intégration de BD's hétérogènes se fait par le biais de:
 - Wrappers/mediateurs au dessus des BD's hétérogènes
 - **Approche orientée requête**
 - Quand une requête est posée par un site client, un méta-dictionnaire est utilisé pour la traduire en plusieurs requêtes appropriées à chacune des BD's. Le résultat est l'intégration des réponses partielles.
 - L'exécution des requêtes demande donc beaucoup de ressources
- Data warehouse: Approche orientée **mise à jour**
 - Les infos sont intégrées et stockées pour une interrogation directe. Plus efficace en coût d'exécution des requêtes

1. Introduction : Comparaison



Data Warehouse vs. BD Opérationnelle


- OLTP (On-Line Transaction Processing)
 - Exécution en temps réel des transactions, pour l'enregistrement des opérations quotidiennes: inventaire, commandes, paye, comptabilité
 - Par opposition aux traitements en batch
- OLAP (On-Line Analytical Processing)
 - Traitement efficace des requêtes d'analyse pour la prise de décision qui sont par défaut assez complexes (bien qu'a priori, elles peuvent être réalisées par les SGBD classiques)
- OLTP vs. OLAP :
 - Données: courantes, détaillées vs. historiques, consolidées
 - Conception : modèle ER + application vs. Modèle en étoile + sujet
 - Vue : courante, locale vs. évolutive, intégrée
 - Modes d'accès: mise à jour vs. Lecture seule mais requêtes complexes




1 .Introduction

Systèmes OLTP	Systèmes OLAP
Données exhaustives	Données résumées
Données courantes	Données historiques
Données dynamiques	Données statiques
Données non volumineuses	Données volumineuses
Orientés applications	Orientés sujets
Utilisateurs nombreux	Utilisateurs peu nombreux
Utilisateurs variés	Décideurs
Mises à jours et interrogations	Interrogations
Requêtes simples	Requêtes complexes

2. Architecture du DWH



2. Architecture des DWs




3. Conception logique des DWs




Données multidimensionnelles


- Montant des ventes comme une fonction des paramètres produit, mois, région



Dimensions: Produit, Lieu, Temps

Chemins de consolidation hiérarchiques






DD : des Données aux Décideurs !

Exploration Informatique des Données et Décisionnel

La fouille de données

The Data Mining



M. Faouzi BOUFARES

boufares@lipn.univ-paris13.fr

<http://www.lipn.univ-paris13.fr/~boufares/>

Bureau B209

Laboratoire d'Informatique de Paris Nord

LIPN – UMR 7030 du CNRS

Université Sorbonne Paris Nord


Institut Galilée

99, Avenue J.B. Clément

F-93430 Villetaneuse FRANCE

www.univ-paris13.fr





Le Data Mining


Le contexte économique oblige les entreprises à **anticiper** sur le marché.

Les entreprises ont stocké un volume de **données** très important.

Ces réservoirs de **connaissances** doivent être exploités afin d'en comprendre le sens et de déceler les relations entre données, des modèles expliquant leur comportement.

Dans cette optique, la construction de **gros ensembles de données** (entrepôts de données) afin de regrouper sous une forme homogène toutes les données de l'entreprise sur une longue période, offre des perspectives nouvelles aux utilisateurs, notamment en terme d'extraction de connaissances grâce aux outils de Data Mining.

Le terme de Data Mining permet de découvrir des modèles dans les données.




Le Data Mining

Les outils d'aide à la décision, qu'ils soient relationnels ou OLAP, **laissent l'initiative à l'utilisateur**, qui choisit les éléments qu'il veut observer ou analyser

Au contraire, dans le cas du Data Mining, **le système a l'initiative** et découvre lui-même les associations entre les données, sans que l'utilisateur ait à lui dire de rechercher plutôt dans telle ou telle direction ou à poser des hypothèses.

Il est alors possible de tenter de *prédire l'avenir*, par exemple le comportement d'un client... de mieux prendre des décisions...

Dans un entrepôt de données, ces techniques de recherche intelligente pourront être utilisées dans d'autres domaines tels que la **qualité des données** ou les moteurs de **recherche textuelles**.



Le Data Mining

Données intégrées : Le départ

Qualité des données

Par exemple, ces
techniques
peuvent aider
pour répondre à :


Comment
pourrait-on
repérer les
données
désignant la
même personne
mais pouvant ne
pas avoir été
écrites de la
même manière ?

	Nom et Prénom	Téléphone	Mail
R1	Le Bon Adam	0666600007	lebon@yahoo.fr
R2	Le Bon A.	0666677777	
R3	Le B. Adam	0666677777	lebon@yahoo.fr
R4	Grande Clémence	0666688887	grande@yahoo.fr
R5	Adam LeBon	0666677777	
R6	Unique Eve	0666622227	unique@gmail.com
R7	Le Bon Adam	0666600007	lebon@yahoo.fr
R8	Le Bon	0666600007	lebon@yahoo.fr
R9	LeBon Adeline	0666611117	Alebon@yahoo.fr

Données résultats : L'arrivée

	Nom et Prénom	Téléphone	Mail
R1	Le Bon Adam	0666600007, 0666677777	lebon@yahoo.fr
R2	Grande Clémence	0666688887	grande@yahoo.fr
R3	Unique Eve	0666622227	unique@gmail.com
R4	LeBon Adeline	0666611117	Alebon@yahoo.fr





Le Data Mining, exemples d'utilisation

Les techniques du Data Mining ont une multitudes de domaines d'application. On peut notamment citer :


Le Domaine médical : Plusieurs types d'utilisation peuvent être faites dans le domaine médical tels que :

- * le diagnostic, découvrir d'après les symptômes du patient sa maladie ;
- * choix du médicament le plus approprié pour guérir une maladie donnée, pour un individu donné ;
- * recherche scientifique, recherche médicale, études épidémiologiques...

L'Analyse de risque : Les compagnies bancaires peuvent rechercher les caractéristiques de clients à haut risque et déterminer si un crédit peut ou non être accordé à une certaine personne.

La gestion des **Ressources Humaines**, Le **Marketing direct**; La **Grande distribution**; La **Gestion de stocks**; La **Maintenance**; Le **Contrôle de qualité**; **L'Analyse financière**, **L'analyse du Risque** ...





Le Data Mining, les techniques

Les statistiques

La découverte de règles

La découverte de modèles fonctionnels



La segmentation

Autres approches : L'Apprentissage non supervisé; La Détection de déviation;
L'Analyse de liens; Les Techniques de visualisation; Les Algorithmes génétiques ...



BD + CC : Big Data + Cloud Computing

Thinking Differently, Bigger and Smarter



M. Faouzi BOUFARES

boufares@lipn.univ-paris13.fr

<http://www.lipn.univ-paris13.fr/~boufares/>

Bureau B209

Laboratoire d'Informatique de Paris Nord

LIPN – UMR 7030 du CNRS

Université Sorbonne Paris Nord

Institut Galilée

99, Avenue J.B. Clément

F-93430 Villetaneuse FRANCE

www.univ-paris13.fr

Quality (Les 4 V) ?

Big Data & Qualité des données

En Amont : Les données sont-elles fiables →

Volume, Velocity, Variety & *Veracity*

Big Data & Qualité des décisions

En aval : Les décisions sont-elles les bonnes !

Qu'est-ce qu'il faut remettre en cause ?

Big Data & Qualité de ???



Smart Foot

Thinking Differently, Bigger and Smarter



Big Data
?

FootBall & Sport





Smart
FOOTBALL
SPORT






Smart FOOTBALL & SPORT

Smart FootBall : Développer de nouvelles applications


Thinking Differently, Bigger and Smarter



Le modèle MapReduce



Le modèle MapReduce



Un programme **MapReduce** est composé de 2 fonctions :

Map() : divise les données pour traiter des sous-problèmes

Reduce() : collecte et agrège les résultats des sous-problèmes

Fonctionne avec des données sous forme de paires (Clé, Valeur) :

Map(k1, v1) → List(k2, v2)



Reduce(k2, List(v2)) → List(v3)



Le modèle MapReduce

Exemple de décompte de mots

```
function map(String name, String
// name: document name
// document: document contents
for each word w in document:
    emit (w, 1)
```

```
function reduce(String word, Iterator partialCounts):
// word: a word
// partialCounts: a list of aggregated partial counts
sum = 0
for each pc in partialCounts:
    sum += ParseInt(pc)
emit (word, sum)
```






Aujourd'hui, j'arrête de fumer !

Le TABAC t'ABAT !

FUMER NUIT GRAVEMENT À TA SANTÉ ET
À CELLE DE TON ENTOURAGE !

M T Dents !

SMILE and the World SMILES with you !



The End : Thanks for your attention

Fin : Merci de votre attention

النهاية: شكرا لحسن إنتباهكم

Fin : Gracias por su atención

Ende : Danke für Ihre Aufmerksamkeit

Конец : Спасибо за ваше внимание

結束 : 感謝您的關注

Think **Bigger**, **Differently** & **Smarter** by using correct **DATA**



Meta-Data Dictionaries

DB : Data Base

DS : Data Source

CSV X

Dr. Smart DATA

Data Base Checklist

☒	Normal Forms
☐	Missing Values
☒	Heterogeneity
☒	Functional Dependencies
☒	Analysis Metrics
☐	 Duplicates

DATALOGUE

QUALI-SCORE

ABCDE

Smart DATA

iDQMS: an Intelligent Data Quality Management System

Think **Bigger**, **Differently** & **Smarter** by using correct **DATA**

QUALI-SCORE

ABCDE

Smart DATA

iDQMS : intelligent Data Quality Management System

That's all folks !!! DB → DW → DL → BD
Data Bases, Data Warhouses, Data Lakes, BigData

La Donnée e(s)t le Monde de Demain ; Data is/and the Future



The End : Thanks for your attention

Fin : Merci de votre attention


النهاية : شكرا الحسن إنتباهكم

Fin : Gracias por su atención

Ende : Danke für Ihre Aufmerksamkeit

Конец : Спасибо за ваше внимание

結束 : 感謝您的關注



M. Faouzi BOUFARES

faouzi.boufares@sorbonne-paris-nord.fr

boufares@lipn.univ-paris13.fr

<http://www.lipn.univ-paris13.fr/~boufares/>

Bureau Y204

Laboratoire d'Informatique de Paris Nord

LIPN – UMR 7030 du CNRS

La MSN, A3

Université Sorbonne Paris Nord. Institut Galilée

99, Avenue J.B. Clément

F-93430 Villetaneuse FRANCE

www.univ-paris13.fr

