

Projet Annuel DATA
Master 2 INFORMATIQUE M2EID2
Université Sorbonne Paris Nord
MSN

2026-2027
M. F. BOUFARES

ETICS

Des données **NON structurées** vers les données **structurées**

Les LLM au service de la toxicité dans les contrats ou les documents

Ce projet de fin d'études porte sur les problématiques liées à la « **Data for Ethics** », et plus particulièrement sur la **détection de la toxicité dans les documents textuels**.

Nous nous intéressons plus précisément à la **mesure, à la caractérisation et à la détection de la toxicité textuelle** dans différents types de productions écrites, tels que les **contrats**, les **rapports**, les **lettres**, les **commentaires**, les **messages** et, plus généralement, les **échanges écrits**.

L'objectif principal est d'explorer dans quelle mesure les méthodes issues de la **qualité des données**, de l'**analyse sémantique** et de l'**intelligence artificielle** peuvent contribuer à identifier des contenus ou des situations potentiellement problématiques.

À terme, ce travail vise également à étudier et à proposer des approches permettant de **prévenir, de détecter et de limiter les contenus toxiques, violents ou relevant du harcèlement**, tout en tenant compte du contexte et de la nature des documents analysés.

Les contrats conclus avec une banque, une assurance, un propriétaire, un employeur, un fournisseur d'énergie, un opérateur téléphonique, etc., peuvent être regroupés sous l'expression « **contrats de la vie en société** » ou « **contrats de la vie quotidienne** ».


L'expression « **contrats dans la société** » est compréhensible, mais elle est un peu moins naturelle en français juridique ou courant.

Ces contrats soulèvent de nombreuses questions éthiques, même lorsqu'ils sont parfaitement légaux.

Voici quelques exemples :

- **Équilibre entre les parties** : une banque, une compagnie d'assurance ou un grand bailleur disposent souvent d'un pouvoir de négociation bien supérieur à celui du particulier. On peut se demander si le consentement est réellement libre lorsque les conditions sont imposées.
- **Transparence** : les contrats sont parfois longs, techniques ou difficiles à comprendre. Est-il éthique de faire signer des clauses qu'une grande partie des clients ne comprend pas ?
- **Justice et équité** : certaines clauses peuvent être jugées excessivement favorables au professionnel. C'est pourquoi le droit protège les consommateurs contre les clauses abusives.

- À l'inverse, un contrat éthiquement satisfaisant cherche non seulement à respecter la loi, mais aussi à instaurer une relation fondée sur la confiance, la bonne foi et le respect mutuel.



Explication des termes (LLM, Agent, Chatbot, RAG) dans le cadre du projet d'analyse de documents des organisations :

LLM (Large Language Model)

- **Définition** : Un **modèle de langage de grande taille** est une intelligence artificielle entraînée sur de grandes quantités de textes pour comprendre et générer du langage naturel.
- **Exemple** : Si on devait s'intéresser sur les données climatiques des entreprises, un LLM (comme ChatGPT) peut lire des documents tels que PDF ou TXT, extraire des informations pertinentes (ex. : chiffres d'émissions de CO₂, secteur d'activité, taille de l'entreprise, politiques RSE) et aider à structurer ces données dans un tableau ou une base de données.

Agent

- **Définition** : Un **agent** est une entité autonome qui peut planifier, raisonner et exécuter des tâches de manière séquentielle, souvent en utilisant un ou plusieurs LLM.
- **Exemple** : On pourrait utiliser un agent pour :
 - Lire chaque fichier (PDF ou autre) automatiquement.
 - Identifier les informations pertinentes.
 - Poser des questions s'il manque des données.
 - Ajouter les données extraites dans un format structuré (tel que CSV, JSON).

Chatbot


- **Définition** : Un **chatbot** est une interface conversationnelle automatisée, souvent basée sur un LLM, avec laquelle un humain peut dialoguer.
- **Exemple** : Un chatbot peut permettre d'interroger les documents ("Quelle est l'empreinte carbone de l'entreprise X ?") de manière interactive, mais il ne planifie pas de tâches complexes par lui-même comme un agent.

RAG (Retrieval-Augmented Generation)

- **Définition** : Une méthode d'IA où un modèle de langage (LLM) **va chercher de l'information dans une base de données ou un corpus de documents** avant de générer une réponse.
 - **Retrieval** = aller chercher de l'information dans les documents.
 - **Augmented Generation** = utiliser ces informations pour produire une réponse pertinente.
- **Exemple** : Si l'on a des centaines de PDF, un système RAG peut être mis en place pour :
 - Indexer tous les documents.
 - Retrouver les passages pertinents selon la question ou le besoin.
 - Générer une réponse ou une donnée à inclure dans le dataset.

En résumé :

Terme	Rôle principal
LLM	Comprendre et extraire des données depuis les documents de départ (PDF, DOC, TXT...)
Agent	Enchaîner plusieurs tâches automatiquement (lecture, extraction, structuration)
Chatbot	Permettre d'interagir avec les données ou les documents par conversation
RAG	Aller chercher l'information dans les documents de départ avant de générer une réponse pertinente



Exemple : Construire une structure de base de données (BD) adaptée à l'analyse de documents pour le **reporting climatique des entreprises européennes par exemple**.

Créer une **base de données relationnelle** (ou structurée en format type CSV/JSON) permettant de stocker et d'analyser les **informations extraites** des rapports des entreprises tels que les bilans RSE, rapports extra-financiers, rapports d'activité.

Les types d'informations à extraire : catégories principales d'information pertinentes pour l'étude :

Identification de l'entreprise

- company_name : Nom de l'entreprise ;
- siret / siren / vat_number : Identifiants légaux
- country / region : Localisation
- industry_sector : Secteur d'activité (ex. NAF/APE ou GICS/NACE)
- company_size : Taille (PME, ETI, GE)
- number_of_employees

Données financières (facultatif mais utile)

- turnover : Chiffre d'affaires ; net_income : Résultat net ; ebitda

Données environnementales

- total_emissions_tCO2e : Total émissions de GES (en tonnes équivalent CO₂)
- scope_1_emissions : Emissions directes (Scope 1)
- scope_2_emissions : Emissions indirectes liées à l'énergie (Scope 2)
- scope_3_emissions : Autres émissions indirectes (Scope 3)
- carbon_neutrality_target_year : Année visée pour la neutralité carbone

Politiques et engagements RSE

- has_sustainability_policy : Politique RSE (booléen)
- esg_goals : Objectifs ESG/RSE (texte ou JSON structuré)
- climate_risk_management : Description des mesures face au risque climatique
- certifications : Ex. : ISO 14001, B Corp, etc.

Références au rapport

- report_title
- report_year
- report_source : URL ou fichier PDF
- extraction_date
- page_reference : pages du rapport contenant les infos