

Intégration des données & Elimination des doubles et des similaires Matching, Merging, and Deduplication (1)

M. F. Boufarès
Université Sorbonne Paris Nord
Master 2 EID2, Informatique



Think DIFFERENTLY, BIGGER and SMARTER!

Votre mission, si vous l'acceptez, est : Eliminer les doubles et les similaires !
Si vous échouez, nous nierons avoir eu connaissance de vos agissements !

Plusieurs types d'anomalies (Intra-Colonne, Inter-Colonnes et Inter-Lignes)

Clients						
	Nom Prénom	Téléphone	Mail	Catégorie	Ville	Chiffre d'affaires
t1	Le Bon Adam	0653545577	adam@yahoo.fr	1	Londres	1000
t2	Le Bon A.	0653545555	-	1	London	1000
t3	Grande Clémence	0607080911	clemence@gmail.com	2	Epinais sur seine	1000
t4	Adam LeBon	0653545555	adam@yahoo.fr	2	Epinais / seine	1000
t5	Grande Clémence	607080911	clemence@gmail.com	2	Epinais / seine	1000
t6	Le Bon	0653545577	adam@yahoo.fr	1	Londres	-
t7	Belle Inès	0708091122	bellesines@yahoo.fr	3	Epinais-Villetaneuse	3000
t8	Rahma Adam	-	-	3	Epinais-sur-seine	1000
t9	Riche Emir	0908070605	-	3	Qatar	1000
t10	Traifor Eve	0666622223	traifor@up13.fr	1	Pékin	1000
t11	Traifor Eve	0666622223	traifor@up13.fr	1	Beijing	1000
t12	LeBon Adel	0653545599	alebon@up13.fr	1	Paris	-
t13	LeBon Adem	-	adam@obsolete.uk	1	Londres	-

Des SIMILAIRES
Des DOUBLONS

Des données absolues

Donnée NON Standard
Donnée NON Valable

- Les algorithmes, pour les corriger, sont très coûteux en terme de temps de réponse
- Comment savoir ce qu'il y a à corriger et ce qu'il faut corriger ?

Comment corriger ?

Elimination des doubles et des similaires

Clients						
	Nom Prénom	Téléphone	Mail	Catégorie	Ville	Chiffre d'affaires
t1	Le Bon Adam	0653545577	adam@yahoo.fr	1	Londres	1000
t2	Le Bon A.	0653545555	-	1	London	2000
t4	Adam LeBon	0653545555	adam@yahoo.fr	1	Londres	-
t6	Le Bon	0653545577	adam@yahoo.fr	1	Londres	-
t10	Traifor Eve	0666622223	traifor@up13.fr	1	Pékin	1000
t11	Traifor Eve	0666622223	traifor@up13.fr	1	Beijing	1000
t12	LeBon Adel	0653545599	alebon@up13.fr	1	Paris	-

Algorithmes de calcul de distance de similarité (JW, J, L, S, M...) & Seuil (s _i)						
S'écrit comme	S'écrit comme	S'écrit comme	S'écrit comme	S'écrit comme	S'écrit comme	S'écrit comme
Jaro-Winkler	Jaccard	Levenshtein	Metaphone	Metaphone	Metaphone	Metaphone
s ₁	s ₂	s ₃	s ₄	s ₅	s ₆	s ₇

Le Bon Adam = LeBon A. = Adam Le Bon
Pékin = Beijing

Doubles ? Similaires ?

Vrais - Faux amis !

Faux - Vrais amis !



L'élimination des doubles et des similaires, appelée déduplication des données (Record Linkage, Duplicates Data, Entity Resolution, Entity Matching), consiste à détecter les lignes doubles ou similaires afin d'éliminer certaines redondances dans une source de données.

Les lignes similaires ou en double pourraient être fusionnées ou encore éliminées.

Cette problématique continue à faire l'objet de plusieurs travaux de recherche, d'une part, afin d'améliorer les performances des algorithmes pour de très gros volumes de données, et d'autre part, afin d'obtenir de meilleures précisions quant au calcul de similarité entre les lignes à cause des différentes anomalies qui existent dans les données. En effet, la similarité entre les données est basée sur les différentes méthodes de mesures de distances de similarités qui existent dans la littérature telles que :

- les **mesures lexicographiques** (Levenshtein -Edit-Distance-, Jaro-Winkler, Q-Gram), ou
- les **mesures phonétiques** (Soundex, Double Metaphone, Saoutek, Noutk !).

Il faut signaler que toutes ces méthodes ne prennent pas en considération la **sémantique contextuelle des données** à comparer.

Par exemple, la chaîne de caractères « **Londres** » est égale à la chaîne de caractères « **London** » si l'on sait qu'il s'agit de chaînes de caractères qui représentent une **Ville (City)**, elles sont tout simplement écrites dans deux langues différentes. Alors que, si ces deux chaînes représentaient un **Nom (LastName)**, elles seraient différentes.

Le choix des attributs clés pour la comparaison (les colonnes qui servent pour la comparaison) constitue aussi un grand problème.

Le résultat de l'élimination des doubles est fortement dépendant des étapes de nettoyage et de profilage des données qui précèdent la déduplication effective.

L'ordre des priorités des actions à mener influence grandement la qualité du résultat. L'homogénéisation, le traitement des valeurs nulles, les liens **inter-colonnes** et les liens **interlignes** sont des étapes dépendantes.

Différentes approches déterministes existent pour la comparaison des lignes dans une source de données. Elles sont basées sur deux fonctions : **Match** (pour la comparaison) et **Merge** (pour la fusion).

Là encore, peu ou pas de sémantique est prise en compte dans le processus de **dédoublonnage**. Dans notre approche, la catégorisation sémantique a permis la recommandation des colonnes à prendre en considération pour l'élimination des doubles ce qui est fondamental pour la validité du résultat.

Exemples de données « dupliquées » suite, par exemple, au processus d'intégration de données (Doubles & Similaires ; Record Linkage ; Entity Resolution ; Deduplication ; Data Matching)

Exemple 1 : Construction de BD qui contient tous les articles de recherche dans le monde !

BD	ACM →→→ ID;Title;Authors;Venue;Year
564753;	A compact B-tree;Peter Bumbulis, Ivan T. Bowman;International Conference on Management of Data;2002
872806;	A theory of redo recovery;David Lomet, Mark Tuttle;International Conference on Management of Data;2003
BD	DBLP →→→ ID;Title;Authors;Venue;Year
conf/sigmod/BumbulisB02;	A compact B-tree;Ivan T. Bowman, Peter Bumbulis;SIGMOD Conference;2002
conf/sigmod/LometT03;	A Theory of Redo Recovery;Mark R. Tuttle, David B. Lomet; SIGMOD Conference;2003
conf/sigmod/DraperHW01;	The Nimble Integration Engine;Daniel S. Weld, Alon Y. Halevy, Denise Draper;SIGMOD Conference ;2001

Exemple d'intégration de données dans le domaine de la bibliographie.
Traitement des doubles et des similaires

BD	ACM →→→ ID;Title;Authors;Venue;Year
564753;	A compact B-tree;Peter Bumbulis, Ivan T. Bowman;International Conference on Management of Data;2002
BD	DBLP →→→ ID;Title;Authors;Venue;Year
conf/sigmod/BumbulisB02;	A compact B-tree;Ivan T. Bowman, Peter Bumbulis;SIGMOD Conference;2002

	Title	Authors	Venue	Year
ID	Title	Authors	Venue	Year
ID	Title	Authors	Venue	Year
564753	A compact B-tree	Peter Bumbulis, Ivan T. Bowman	International Conference on Management of Data	2002
conf/sigmod/BumbulisB02	A compact B-tree	Ivan T. Bowman, Peter Bumbulis	SIGMOD Conference	2002

Title ?

A compact B-tree = or $\approx$ or $\neq$ A compact B-tree ?

??? **SimilarityDistanceAlg**(A compact B-tree ; A compact B-tree) $\leq$ **Seuil1**

Authors ?

Peter Bumbulis, Ivan T. Bowman = or $\approx$ or $\neq$ Ivan T. Bowman, Peter Bumbulis ?

??? **SimilarityDistanceAlg**(Peter Bumbulis, Ivan T. Bowman ; Ivan T. Bowman, Peter Bumbulis) $\leq$ **Seuil2**

Venue ?

International Conference on Management of Data = or $\approx$ or $\neq$ SIGMOD Conference ?

??? **SimilarityDistanceAlg**(International Conference on Management of Data ; SIGMOD Conference) $\leq$ **Seuil3**

Year ?

2002 = or $\approx$ or $\neq$ 2002 ?

SimilarityDistanceAlg(2002 ; 2002) $\leq$ **Seuil4**

Exemple 2 : Construction de la Base de Données mondiale des Hôtels en Intégrant de plusieurs sources de données.

Best Western London Peckham Hotel

110 Peckham Road, Southwark, Londres, SE15 5EU, Royaume-Uni

Téléphone : +44 20 7701 4222

Best Western London Peckham Hotel


110 Peckham Rd, London SE15 5EU, United Kingdom

Téléphone : +44 20 7701 4222

Hôtel Best Western London Peckham

110 Peckham Road, Southwark, Londres, RU

Téléphone : 00 44 20 7701 4222



Stratégie de fusion (survivorship rules)

Une fois la fusion décidée, on applique des règles pour construire l'enregistrement final :

- Priorité à une source de référence
- Valeur la plus récente
- Valeur la plus complète
- Valeur la plus fiable selon un score de qualité
- Historisation des anciennes valeurs

Exemple : Si deux numéros de téléphone existent, conserver le plus récent et archiver l'autre.

Traçabilité et audit, chaque fusion devrait conserver :

- Les identifiants sources
- Les règles appliquées
- La date et l'auteur de la décision

Amélioration continue, les règles et seuils sont ajustés en fonction :

- Des erreurs détectées
- Des retours utilisateurs
- De l'évolution des données

En résumé

La stratégie combine **normalisation** → **détection de similarité** → **décision contrôlée** → **règles de survivance**, avec un équilibre entre automatisation et contrôle humain pour garantir la qualité et la fiabilité des données fusionnées.

Je préfère cette réponse

Exemple :

Title: Keep exact value (identical in all records)

Authors: Normalize author names ; Remove duplicates ; Apply canonical ordering

Conference: Keep full official name ; Store abbreviations as aliases

Year: Keep value (identical)

Identifiers: Keep all identifiers ; Flag one as Primary_ID

Exemple 1 : Etude de la similarité avec ChatGPT

Est-ce que les 2 enregistrements ci-dessous sont similaires et à quel degré :

Record 1 : 564753;A compact B-tree;Peter Bumbulis, Ivan T. Bowman;International Conference on Management of Data;2002

Record 1 : conf/sigmod/BumbulisB02;A compact B-tree;Ivan T. Bowman, Peter Bumbulis;SIGMOD Conference;2002

Oui, ces deux enregistrements sont très fortement similaires et peuvent être considérés comme des doublons quasi certains.

Voici l'analyse détaillée par champ, avec un degré de similarité.

Analyse de similarité**1. Titre**

- Record 1 : *A compact B-tree*
- Record 2 : *A compact B-tree*

→ **Correspondance exacte** → similarité **100 %**

2. Auteurs

- Record 1 : *Peter Bumbulis, Ivan T. Bowman*
- Record 2 : *Ivan T. Bowman, Peter Bumbulis*

Différences :

- Ordre des auteurs inversé
- Aucune différence sémantique

→ **Correspondance forte** (mêmes auteurs, ordre différent)

→ Similarité estimée : **95–100 %**

3. Conférence

- Record 1 : *International Conference on Management of Data*
- Record 2 : *SIGMOD Conference*

Observation :

- SIGMOD* est l'abréviation usuelle de *ACM SIGMOD International Conference on Management of Data*

→ **Correspondance sémantique** (nom long vs nom abrégé)

→ Similarité estimée : **85–90 %**

4. Année

- Record 1 : *2002*
- Record 2 : *2002*

→ **Correspondance exacte** → **100 %**

5. Identifiant

- Record 1 : *564753*
- Record 2 : *conf/sigmod/BumbulisB02*

→ Identifiants différents mais compatibles (ID interne vs clé bibliographique)

Conclusion globale

- Même publication scientifique
- Même titre

- Même auteurs
- Même conférence (nom complet vs abréviation)
- Même année

 **Degré de similarité global estimé : $\approx 95\%$**

 **Décision recommandée :**

- **Doublon confirmé**
- Fusion automatique possible avec règles de survivance
- Conservation éventuelle des deux identifiants (ID interne + clé bibliographique)

Si tu veux, je peux aussi :

- proposer un **score chiffré par champ**
- définir une **règle automatique de décision**
- suggérer quelle valeur conserver lors de la fusion (conférence, auteurs, identifiant)

Voici une **évaluation chiffrée par champ**, suivie d'une **règle de décision automatique** et d'une **proposition de fusion (survivorship)**.

1 Scoring de similarité par champ

Champ	Record 1	Record 2	Méthode de comparaison	Score
Title	A compact B-tree	A compact B-tree	Exact match	1.00
Authors	Peter Bumbulis, Ivan T. Bowman	Ivan T. Bowman, Peter Bumbulis	Set comparison (order-insensitive)	0.98
Conference	International Conference on Management of Data	SIGMOD Conference	Semantic equivalence (alias/ontology)	0.90
Year	2002	2002	Exact match	1.00
Identifiant	564753	conf/sigmod/BumbulisB02	Different but compatible identifiers	0.70

2 Score global pondéré

Exemple de pondération (publication scientifique) :

- Title: **40 %**
- Authors: **30 %**
- Conference: **20 %**
- Year: **10 %**
- Identifiant: informatif (non bloquant)

Calcul du score global

$$\begin{aligned}
 &(1.00 \times 0.40) + \\
 &(0.98 \times 0.30) + \\
 &(0.90 \times 0.20) + \\
 &(1.00 \times 0.10) \\
 &= 0.97
 \end{aligned}$$

 **Score global final : 0.97 / 1.00 (97 %)**

3 Règle automatique de décision

Rule:

- If Global Similarity Score ≥ 0.90
- AND Title = exact match
- AND Year = exact match

→ Duplicate confirmed → Automatic merge

4 Proposition de fusion (Survivorship Rules)

Valeurs conservées dans l'enregistrement maître

Champ	Valeur retenue	Règle appliquée
Title	A compact B-tree	Exact match
Authors	Peter Bumbulis; Ivan T. Bowman	Normalisation + ordre canonique
Conference	International Conference on Management of Data (SIGMOD)	Nom complet + alias
Year	2002	Exact match
Identifiers	564753 + conf/sigmod/BumbulisB02	Conservation de tous les identifiants
Source	Multiple	Traçabilité

5 Conclusion

- ✓ Les deux enregistrements représentent **la même publication scientifique**
- ✓ **Doublon quasi certain**
- ✓ Fusion **automatique et sûre**, sans revue humaine
- ✓ Traçabilité conservée via les identifiants multiples

Exemple 2 : Etude de la similarité avec ChatGPT

Est-ce que les 2 enregistrements qui suivent sont similaires et à quel degré :

Record 1 :

Best Western London Peckham Hotel
110 Peckham Rd, London SE15 5EU, United Kingdom
Téléphone : +44 20 7701 4222

Record 2 :

Hôtel Best Western London Peckham
110 Peckham Road, Southwark, Londres, RU
Téléphone : 00 44 20 7701 4222

Oui, ces deux enregistrements sont très fortement similaires et correspondent au même hôtel.
Ils peuvent être considérés comme des doublons quasi certains.
Voici l'analyse détaillée avec un degré de similarité.

Analyse de similarité par champ**1. Nom de l'établissement**

- Record 1 : *Best Western London Peckham Hotel*
- Record 2 : *Hôtel Best Western London Peckham*

Différences :

- Ordre des mots
- Présence de "Hotel / Hôtel"
- Langue différente (anglais / français)

→ **Équivalence sémantique claire**

→ Similarité estimée : **95 %**

2. Adresse

- Record 1 : *110 Peckham Rd, London SE15 5EU, United Kingdom*
- Record 2 : *110 Peckham Road, Southwark, Londres, RU*

Différences :

- "Rd" vs "Road"
- "London" vs "Londres"
- Présence du code postal dans Record 1
- "United Kingdom" vs "RU" (Royaume-Uni)

→ **Même adresse physique** avec variations linguistiques et d'abréviations

→ Similarité estimée : **90 %**

3. Téléphone

- Record 1 : +44 20 7701 4222
- Record 2 : 00 44 20 7701 4222

→ **Numéro identique après normalisation internationale**

→ Similarité : **100 %**

Score global de similarité (pondéré)

Exemple de pondération (hôtellerie / POI) :

- Nom : **40 %**
- Adresse : **40 %**
- Téléphone : **20 %**

Calcul

$$\begin{aligned}
 &(0.95 \times 0.40) + \\
 &(0.90 \times 0.40) + \\
 &(1.00 \times 0.20) \\
 &= 0.94
 \end{aligned}$$

 **Score global estimé : 0.94 / 1.00 (94 %)**

Conclusion

- ✓ Les deux enregistrements décrivent **le même hôtel**
- ✓ **Doublon confirmé**
- ✓ Fusion **automatique recommandée**
- ✓ Conservation possible des variantes linguistiques (nom / adresse)

Si tu veux, je peux aussi :

- proposer une **fiche hôtel “master record” normalisée**
- définir des **règles automatiques de déduplication**
- ou simuler un **cas limite** avec un score plus faible

oui

Parfait 

Voici une **proposition complète de “master record” normalisé**, basée sur la fusion des deux enregistrements et appliquant des règles de survivorship pour les hôtels.

1 Fiche Master Record – Best Western London Peckham

Champ	Valeur fusionnée	Règle appliquée
Name / Nom	Best Western London Peckham Hotel	Conserver la version anglaise standard + inclure la variante française comme alias
Address / Adresse	110 Peckham Road, Southwark, London SE15 5EU, United Kingdom	Normalisation internationale, code postal inclus, ville et district standardisés
Phone / Téléphone	+44 20 7701 4222	Numéro international normalisé (supprime 00 / + doublons)
Alternative Name / Nom alternatif	Hôtel Best Western London Peckham	Historisation / alias pour recherche multilingue
Source IDs / Identifiants sources	Record1_ID, Record2_ID	Traçabilité des enregistrements fusionnés
Merge Date / Date de fusion	2025-12-22	Automatique / date système
Merge Author / Auteur fusion	System	Indication du processus automatique

2 Règles appliquées (Survivorship)

1. **Nom** : version standard anglaise conservée, alias français enregistré
2. **Adresse** : version complète avec code postal et pays international
3. **Téléphone** : format international unique
4. **Identifiants** : tous conservés pour traçabilité
5. **Historisation** : anciens noms et adresses gardés comme alias

3 Score de similarité

Champ	Score
Name	0.95
Address	0.90
Phone	1.00
Global Score	0.94

→ **Doublon confirmé**, fusion automatique validée

Les fonctions Oracle, les plus connues, de calcul de similarité

Les fonctions Oracle, les plus connues, de calcul de **similarité** et de distance de similarité entre les **chaînes de caractères** sont : **Levenshtein (Edit_Distance) distance**, **Jaro–Winkler distance**, **Soundex distance**.

NB : Les notes ci-dessous sont largement inspirées de la documentation Oracle sur le Web.

EDIT_DISTANCE Function ; EDIT_DISTANCE_SIMILARITY Function
JARO_WINKLER Function ; JARO_WINKLER_SIMILARITY Function
SOUNDEX Function

EDIT_DISTANCE Function

This function calculates the number of insertions, deletions or substitutions required to transform string-1 into string-2.

Syntax

```
UTL_MATCH.EDIT_DISTANCE (s1 IN VARCHAR2, s2 IN VARCHAR2)  
RETURNS PLS_INTEGER;
```

Examples

```
SELECT UTL_MATCH.EDIT_DISTANCE('shackleford', 'shackelford')  
AS shackleford_shackelford_ED FROM DUAL;
```

returns 2 →→

SHACKLEFORD_SHACKELFORD_ED

2

EDIT_DISTANCE_SIMILARITY Function

This function calculates the number of insertions, deletions or substitutions required to transform string-1 into string-2, and returns the Normalized value of the Edit Distance between two Strings. The value is typically between **0 (no match)** and **100 (perfect match)**.

Syntax

```
UTL_MATCH.EDIT_DISTANCE_SIMILARITY(s1 IN VARCHAR2, s2 IN VARCHAR2)
RETURNS PLS_INTEGER;
```

Examples

```
SELECT UTL_MATCH.EDIT_DISTANCE_SIMILARITY('shackleford', 'shackelford')
AS shackelford_shackelford_simED FROM DUAL;
```

→ → returns 82

SHACKLEFORD_SHACKELFORD_SIMED

82

JARO_WINKLER Function

This function calculates the measure of agreement between two strings.

Syntax

```
UTL_MATCH.JARO_WINKLER (s1 IN VARCHAR2, s2 IN VARCHAR2)
RETURNS BINARY_DOUBLE;
```

Examples

```
SELECT UTL_MATCH.JARO_WINKLER('shackleford', 'shackelford')
AS shackelford_shackelford_JARWIN
FROM DUAL;
```

→ → returns 9.818E-001

SHACKLEFORD_SHACKELFORD_JARWIN

9,818181991577148E-001

JARO_WINKLER_SIMILARITY Function

This function calculates the measure of agreement between two strings, and returns a score between **0 (no match)** and **100 (perfect match)**.

Syntax

```
UTL_MATCH.JARO_WINKLER (s1 IN VARCHAR2, s2 IN VARCHAR2)
RETURNS PLS_INTEGER;
```

Examples

```
SELECT UTL_MATCH.JARO_WINKLER_SIMILARITY('shackleford',
'shackelford') As shackelford8shackelford_SIMJW FROM DUAL;
```

→ → returns 98

SHACKLEFORD8SHACKELFORD_SIMJW

98

EXAMPLES

```
DROP TABLE match_tab;

CREATE TABLE match_tab (
  id    NUMBER,
  col1  VARCHAR2(15),
  col2  VARCHAR2(15),
  CONSTRAINT match_tab_pk PRIMARY KEY (id)
);

INSERT INTO match_tab VALUES (1, 'Peter Parker', 'Pete Parker');
INSERT INTO match_tab VALUES (2, 'Peter Parker', 'peter parker');
INSERT INTO match_tab VALUES (3, 'Clark Kent', 'Claire Kent');
INSERT INTO match_tab VALUES (4, 'Wonder Woman', 'Ponder Woman');
INSERT INTO match_tab VALUES (5, 'Superman', 'Superman');
INSERT INTO match_tab VALUES (6, 'The Hulk', 'Iron Man');
COMMIT;
```

EDIT_DISTANCE

The "Edit Distance", or "Levenshtein Distance", test measures the similarity between two strings by counting the number of character changes (inserts, updates, deletes) required to transform the first string into the second. The number of changes required is known as the distance.

```
SELECT col1, col2, UTL_MATCH.edit_distance(col1, col2)
AS Edit_Distance FROM match_tab ORDER BY id;
```

COL1	COL2	EDIT_DISTANCE
Peter Parker	Pete Parker	1
Peter Parker	peter parker	2
Clark Kent	Claire Kent	2
Wonder Woman	Ponder Woman	1
Superman	Superman	0
The Hulk	Iron Man	8

6 lignes sélectionnées

EDIT_DISTANCE_SIMILARITY

The EDIT_DISTANCE_SIMILARITY function uses the same method as the EDIT_DISTANCE function to determine the similarity of the strings, but it returns a normalized result ranging from 0 (no match) to 100 (complete match).

```
SELECT col1, col2, UTL_MATCH.edit_distance_similarity(col1, col2)
AS Edit_Distance_Similarity FROM match_tab ORDER BY id;
```

COL1	COL2	EDIT_DISTANCE_SIMILARITY
Peter Parker	Pete Parker	92
Peter Parker	peter parker	84
Clark Kent	Claire Kent	82
Wonder Woman	Ponder Woman	92
Superman	Superman	100
The Hulk	Iron Man	0

6 lignes sélectionnées

```
SELECT 'Les chaines de caractères qui se ressemblent à 90+ ED_Similarity'
FROM DUAL ;
```

```
SELECT id, col1, col2,
       UTL_MATCH.edit_distance_similarity(col1, col2) AS eds
FROM   match_tab
WHERE  UTL_MATCH.edit_distance_similarity(col1, col2) > 90
ORDER BY id;
```

Les chaines de caractères qui se ressemblent à 90+ ED_Similarity

ID	COL1	COL2	EDS
1	Peter Parker	Pete Parker	92
4	Wonder Woman	Ponder Woman	92
5	Superman	Superman	100

JARO_WINKLER

The "Jaro-Winkler Algorithm" provides a different method for finding the distance between two strings.

```
SELECT col1, col2, UTL_MATCH.jaro_winkler(col1, col2) AS jw
FROM   match_tab ORDER BY id;
```

COL1	COL2	JW
Peter Parker	Pete Parker	9,288E-001
Peter Parker	peter parker	8,889E-001
Clark Kent	Claire Kent	9,083E-001
Wonder Woman	Ponder Woman	9,444E-001
Superman	Superman	1E+000
The Hulk	Iron Man	4,167E-001

6 lignes sélectionnées

JARO_WINKLER_SIMILARITY

The JARO_WINKLER_SIMILARITY function uses the same method as the JARO_WINKLER function to determine the similarity of the strings, but it returns a normalized result ranging from 0 (no match) to 100 (complete match).

```
SELECT col1, col2, UTL_MATCH.jaro_winkler_similarity(col1, col2) AS jws
FROM   match_tab ORDER BY id;
```

COL1	COL2	JWS
Peter Parker	Pete Parker	92
Peter Parker	peter parker	88
Clark Kent	Claire Kent	90
Wonder Woman	Ponder Woman	94
Superman	Superman	100
The Hulk	Iron Man	41

6 lignes sélectionnées

```

SELECT 'Les chaines de caractères qui se ressemblent à 90+ JW_Similarity'
FROM DUAL ;

SELECT col1, col2, UTL_MATCH.jaro_winkler_similarity(col1, col2) AS jws
FROM   match_tab
WHERE  UTL_MATCH.jaro_winkler_similarity(col1, col2) > 90
ORDER BY id;

```

Les chaines de caractères qui se ressemblent à 90+ JW_Similarity

COL1	COL2	JWS
Peter Parker	Pete Parker	92
Wonder Woman	Ponder Woman	94
Superman	Superman	100

Levenshtein distance

In [information theory](#) and [computer science](#), the **Levenshtein distance** is a [string metric](#) for measuring the difference between two sequences. Informally, the Levenshtein distance between two words is the minimum number of single-character edits (i.e. insertions, deletions or substitutions) required to change one word into the other. It is named after [Vladimir Levenshtein](#), who considered this distance in 1965.

Levenshtein distance may also be referred to as **edit distance**, although that may also denote a larger [family of distance metrics](#). It is closely related to [pairwise string alignments](#).

Jaro–Winkler distance

In [computer science](#) and [statistics](#), the **Jaro–Winkler distance** (Winkler, 1990) is a measure of similarity between two [strings](#). It is a variant of the **Jaro distance** metric (Jaro, 1989, 1995), a type of string [edit distance](#), and was developed in the area of [record linkage](#) (duplicate detection) (Winkler, 1990). The higher the Jaro–Winkler distance for two strings is, the more similar the strings are. The Jaro–Winkler similarity (for equation see below) is given by $1 - \text{Jaro Winkler distance}$. The Jaro–Winkler distance metric is designed and best suited for short strings such as person names. The score is normalized such that 0 equates to no similarity and 1 is an exact match.

SOUNDEX

SOUNDEX is a built-in function used to compare data items with their audible or spoken values. It is a phonetic algorithm for indexing names by sound, as pronounced in English. For example, REIN, REIGN, and RAIN are all spelled differently but sound the same when spoken aloud. These "sound-alike" words are referred to as "homophones" or "heterographs". The National Archives and Records Administration (NARA) maintains the current rule set for the official implementation of Soundex used by the U.S. Government.

SOUNDEX returns a character string containing the phonetic representation of char. This function lets you compare words that are spelled differently, but sound alike in **English**.

```
SET LINE 1000
COLUMN SON_ANG11 FORMAT A10
COLUMN SON_ANG12 FORMAT A10
COLUMN SON_ANG13 FORMAT A10
COLUMN SON_ANG14 FORMAT A10
COLUMN SON_ANG15 FORMAT A10
COLUMN SON_ANG16 FORMAT A10

SELECT
SOUNDEX('REIN') SON_ANG11, SOUNDEX('REIGN') SON_ANG12, SOUNDEX('RAIN') SON_ANG13,
SOUNDEX('rein') SON_ANG14, SOUNDEX('reign') SON_ANG15, SOUNDEX('rain') SON_ANG16
FROM DUAL;
```

Y-a-t-il une différence entre les majuscules et minuscules ?

SON_ANG11	SON_ANG12	SON_ANG13	SON_ANG14	SON_ANG15	SON_ANG16
R500	R250	R500	R500	R250	R500

Examples

The following example returns the employees whose last names are a phonetic representation of "Smyth":

```
SELECT 'Les employés dont le nom commence par S' FROM DUAL ;
SELECT last_name, first_name
FROM hr.employees -- hr.employees est une table des exemples oracle
WHERE UPPER(last_name) LIKE 'S%';

SELECT 'Les employés dont le nom se prononce comme SMYTHE' FROM DUAL ;
SELECT last_name, first_name
FROM hr.employees -- hr.employees est une table des exemples oracle
WHERE SOUNDEX(last_name)= SOUNDEX('SMYTHE');
```

Les employés dont le nom commence par S

LAST_NAME	FIRST_NAME
Sarchand	Nandita
Sciarra	Ismael
Seo	John
Sewall	Sarath
Smith	Lindsey
Smith	William
Stiles	Stephen
Sullivan	Martha
Sully	Patrick

9 lignes sélectionnées

Les employés dont le nom se prononce comme SMYTHE

LAST_NAME	FIRST_NAME
Smith	Lindsey
Smith	William

Plusieurs questions se posent sur les algorithmes phonétiques dans d'autres langues telle que le français !

Fonction soundex francais !??

A tester sur Oracle ! soundexfr, soundex_fr, soundex2, phonex ???

```

COLUMN MOT1DURAND   FORMAT A15
COLUMN MOT2DURHAND  FORMAT A15
COLUMN MOT3DUROND   FORMAT A15
COLUMN MOT4DUPOND   FORMAT A15

SELECT  soundex('durand')      MOT1DURAND,
        soundex('durhand')    MOT2DURHAND,
        soundex('durond')     MOT3DUROND,
        soundex('dupond')     MOT4DUPOND
FROM    DUAL;
```

MOT1DURAND	MOT2DURHAND	MOT3DUROND	MOT4DUPOND
-----	-----	-----	-----
D653	D653	D653	D153

Cela ne marche pas ! Alors ?

Quels sont les algorithmes phonétiques pour la langue française ?

```

SELECT  soundexfr('durand'),
        soundexfr('durhand'),
        soundexfr('durond'),
        soundexfr('dupond')
FROM    DUAL;
```

Erreur commençant à la ligne: 1 de la commande -

```

SELECT  soundexfr('durand'),
        soundexfr('durhand'),
        soundexfr('durond'),
        soundexfr('dupond')
```

FROM DUAL

Erreur à la ligne de commande: 4 Colonne: 2

Rapport d'erreur -

Erreur SQL : ORA-00904: "SOUNDEXFR" : identificateur non valide

00904. 00000 - "%s: invalid identifier"

*Cause:

*Action:

Metaphone / Double Metaphone

The Metaphone processor converts the values for a String attribute into a code which represents the phonetic pronunciation of the original string, using the Double Metaphone algorithm.

The Double Metaphone algorithm is a more general phonetic technique than Soundex (which is specifically designed for people's names), and is more sophisticated and context-sensitive than the original Metaphone algorithm.

Etudier le comportement des algorithmes de calcul de distance de similarité entre les valeurs dans une BD selon leurs catégories (leurs sémantiques) !

Voir Script SQL !

```
-- =====
-- =====
REM -- Elimination des doubles et des similaires
REM -- Matching, Merging, and Deduplication
-- =====

REM - Big Data, Bases de Données Avancées, Entrepôts de données, Lacs de données
REM - Référentiel de Données
-- =====

-- =====
REM -- Création de la table des différentes valeurs à comparer
-- =====
DROP TABLE matchval;

CREATE TABLE matchval
(
    Idval          VARCHAR2(10), categorieval VARCHAR2(30),
    valeur1        VARCHAR2(30), valeur2      VARCHAR2(30),
    CONSTRAINT matchval_pk PRIMARY KEY (Idval)
);

-- =====
REM - Insertion dans la table des différentes valeurs à comparer
-- =====
-- Catégorie sémantique des données : FIRSTNAME
INSERT INTO matchval VALUES ('A00-001', 'FIRSTNAME', 'Adam', 'ADAM');
INSERT INTO matchval VALUES ('A00-002', 'FIRSTNAME', 'Adam', 'Adem');
INSERT INTO matchval VALUES ('A00-003', 'FIRSTNAME', 'Adam', 'Adams');
INSERT INTO matchval VALUES ('A00-004', 'FIRSTNAME', 'Rahma', 'Rama');
INSERT INTO matchval VALUES ('A00-005', 'FIRSTNAME', 'Marie-Noel', 'Marie Noel');
INSERT INTO matchval VALUES ('A00-006', 'FIRSTNAME', 'Franc', 'Frank');
INSERT INTO matchval VALUES ('A00-007', 'FIRSTNAME', 'Mbarak', 'Moubarak');
INSERT INTO matchval VALUES ('A00-008', 'FIRSTNAME', 'Inès', 'Ines');
INSERT INTO matchval VALUES ('A00-009', 'FIRSTNAME', 'Inès', 'Iness');
INSERT INTO matchval VALUES ('A00-010', 'FIRSTNAME', 'Inès', 'Yneès');
INSERT INTO matchval VALUES ('A00-011', 'FIRSTNAME', 'Inès', 'Agnès');
COMMIT;
INSERT INTO matchval VALUES ('A00-021', 'FIRSTLASTNAME', 'Peter Parker', 'Pete Parker');
INSERT INTO matchval VALUES ('A00-022', 'FIRSTLASTNAME', 'Peter Parker', 'peter parker');
INSERT INTO matchval VALUES ('A00-023', 'FIRSTLASTNAME', 'Clark Kent', 'Claire Kent');
INSERT INTO matchval VALUES ('A00-024', 'FIRSTLASTNAME', 'Wonder Woman', 'Ponder Woman');
INSERT INTO matchval VALUES ('A00-025', 'FIRSTLASTNAME', 'Superman', 'Superman');
INSERT INTO matchval VALUES ('A00-026', 'FIRSTLASTNAME', 'The Hulk', 'Iron Man');
INSERT INTO matchval VALUES ('A00-027', 'FIRSTLASTNAME', 'Harissa FORD', 'Harisson
Ford');
INSERT INTO matchval VALUES ('A00-028', 'FIRSTLASTNAME', 'Bus WILLY', 'Bruce Willy');
INSERT INTO matchval VALUES ('A00-029', 'FIRSTLASTNAME', 'Brigitte Bardo', 'Brigitte
Fardo');
INSERT INTO matchval VALUES ('A00-030', 'FIRSTLASTNAME', 'Hedi Mufti', 'Eddy Murfi');
INSERT INTO matchval VALUES ('A00-031', 'FIRSTLASTNAME', 'Alain DE LOiN', 'Alain DELON');
INSERT INTO matchval VALUES ('A00-032', 'FIRSTLASTNAME', 'De par de', '2 par 2');
COMMIT;
-- Catégorie sémantique des données : CITY
INSERT INTO matchval VALUES ('A00-041', 'CITY', 'Paris', 'PArisss');
INSERT INTO matchval VALUES ('A00-042', 'CITY', 'Paris', 'Pari');
INSERT INTO matchval VALUES ('A00-043', 'CITY', 'Pékin', 'Beijing');
INSERT INTO matchval VALUES ('A00-044', 'CITY', 'Londres', 'Londre');
INSERT INTO matchval VALUES ('A00-045', 'CITY', 'Londres', 'London');
COMMIT;
-- Catégorie sémantique des données : DATE
INSERT INTO matchval VALUES ('A00-051', 'DATE', '10-11-2016', '10-NOV-16');
```

```

INSERT INTO matchval VALUES ('A00-052', 'DATE', '10-11-2016', 'JEUDI 10 NOVEMBER 2016');
INSERT INTO matchval VALUES ('A00-053', 'DATE', '11-11-2016', '11-11-2016');
INSERT INTO matchval VALUES ('A00-054', 'DATE', '11-11-2016', '11-12-2016');
INSERT INTO matchval VALUES ('A00-055', 'DATE', '11-11-2016', '12-11-2016');
INSERT INTO matchval VALUES ('A00-056', 'DATE', '11-11-2016', '11-11-2017');
COMMIT;
-- Catégorie sémantique des données : EMAIL
INSERT INTO matchval VALUES ('A00-061', 'EMAIL', 'fb@lipn.univ-paris13.fr',
'fb@lipn.univ-paris13.fr');
INSERT INTO matchval VALUES ('A00-062', 'EMAIL', 'fb@lipn.univ-paris13.fr',
'yb@lipn.univ-paris13.fr');
INSERT INTO matchval VALUES ('A00-063', 'EMAIL', 'fb@lipn.univ-paris13.fr',
'fb@iutv.univ-paris13.fr');
COMMIT;
-- Catégorie sémantique des données : URL
INSERT INTO matchval VALUES ('A00-071', 'URL', 'www.univ-paris13.fr', 'www.univ-
paris13.fr');
INSERT INTO matchval VALUES ('A00-072', 'URL', 'www.univ-paris13.fr', 'www.univ-
paris1.fr');
INSERT INTO matchval VALUES ('A00-073', 'URL', 'www.univ-paris13.fr', 'www.univ-
paris3.fr');
INSERT INTO matchval VALUES ('A00-074', 'URL', 'www.univ-paris13.fr', 'www.univ-
pari13.fr');
INSERT INTO matchval VALUES ('A00-075', 'URL', 'www.univ-paris13.fr',
'www.univparis13.fr');
INSERT INTO matchval VALUES ('A00-076', 'URL', 'www.sorbonne-paris-nord.fr', 'sorbonne-
paris_nord.fr.fr');
COMMIT;
-- Catégorie sémantique des données : NUMBER
INSERT INTO matchval VALUES ('A00-081', 'NUMBER', '17091958', '17091958');
INSERT INTO matchval VALUES ('A00-082', 'NUMBER', '17091958', '27091958');
INSERT INTO matchval VALUES ('A00-083', 'NUMBER', '12345679', '12345678');
INSERT INTO matchval VALUES ('A00-084', 'NUMBER', '0.000012345679', '0.000012345678');
COMMIT;

SET LINE 1000
SET PAGES 100

COLUMN Idval          FORMAT A10
COLUMN categorieval    FORMAT A30
COLUMN valeur1         FORMAT A30
COLUMN valeur2         FORMAT A30

SELECT * FROM matchval;

```

IDVAL	CATEGORIEVAL	VALEUR1	VALEUR2
A00-001	FIRSTNAME	Adam	ADAM
A00-002	FIRSTNAME	Adam	Adem
A00-003	FIRSTNAME	Adam	Adams
A00-004	FIRSTNAME	Rahma	Rama
A00-005	FIRSTNAME	Marie-Noel	Marie Noel
A00-006	FIRSTNAME	Franc	Frank
A00-007	FIRSTNAME	Mbarak	Moubarak
A00-008	FIRSTNAME	Inès	Ines
A00-009	FIRSTNAME	Inès	Iness
A00-010	FIRSTNAME	Inès	Yneès
A00-011	FIRSTNAME	Inès	Agnès
A00-021	FIRSTLASTNAME	Peter Parker	Pete Parker
A00-022	FIRSTLASTNAME	Peter Parker	peter parker
A00-023	FIRSTLASTNAME	Clark Kent	Claire Kent
A00-024	FIRSTLASTNAME	Wonder Woman	Ponder Woman
A00-025	FIRSTLASTNAME	Superman	Superman
A00-026	FIRSTLASTNAME	The Hulk	Iron Man
A00-027	FIRSTLASTNAME	Harissa FORD	Harisson Ford
A00-028	FIRSTLASTNAME	Bus WILLY	Bruce Willy
A00-029	FIRSTLASTNAME	Brigitte Bardo	Brigitte Fardo
A00-030	FIRSTLASTNAME	Hedi Mufti	Eddy Murfi
A00-031	FIRSTLASTNAME	Alain DE LOIN	Alain DELON
A00-032	FIRSTLASTNAME	De par de	2 par 2
A00-041	CITY	Paris	PArisss
A00-042	CITY	Paris	Pari
A00-043	CITY	Pékin	Beijing
A00-044	CITY	Londres	Londre
A00-045	CITY	Londres	London
A00-051	DATE	10-11-2016	10-NOV-16
A00-052	DATE	10-11-2016	JEUDI 10 NOVEMBER 2016
A00-053	DATE	11-11-2016	11-11-2016
A00-054	DATE	11-11-2016	11-12-2016
A00-055	DATE	11-11-2016	12-11-2016
A00-056	DATE	11-11-2016	11-11-2017
A00-061	EMAIL	fb@lipn.univ-paris13.fr	fb@lipn.univ-paris13.fr
A00-062	EMAIL	fb@lipn.univ-paris13.fr	yb@lipn.univ-paris13.fr
A00-063	EMAIL	fb@lipn.univ-paris13.fr	fb@iutv.univ-paris13.fr
A00-071	URL	www.univ-paris13.fr	www.univ-paris13.fr
A00-072	URL	www.univ-paris13.fr	www.univ-paris1.fr
A00-073	URL	www.univ-paris13.fr	www.univ-paris3.fr
A00-074	URL	www.univ-paris13.fr	www.univ-pari13.fr
A00-075	URL	www.univ-paris13.fr	www.univparis13.fr
A00-076	URL	www.sorbonne-paris-nord.fr	sorbonne-paris_nord.fr.fr
A00-081	NUMBER	17091958	17091958
A00-082	NUMBER	17091958	27091958
A00-083	NUMBER	12345679	12345678
A00-084	NUMBER	0.000012345679	0.000012345678

47 lignes sélectionnées

```
-- =====
REM -- Calcul des distances de similarités
-- =====
```

```
SELECT Idval,
       categorieval,
       valeur1,
       valeur2,
       UTL_MATCH.edit_distance_similarity(valeur1, valeur2) EDS,
       UTL_MATCH.jaro_winkler_similarity(valeur1, valeur2) JWS
FROM   matchval
ORDER BY Idval;
```

IDVAL	CATEGORIEVAL	VALEUR1	VALEUR2	EDS	JWS
A00-001	FIRSTNAME	Adam	ADAM	25	55
A00-002	FIRSTNAME	Adam	Adem	75	86
A00-003	FIRSTNAME	Adam	Adams	80	96
A00-004	FIRSTNAME	Rahma	Rama	80	94
A00-005	FIRSTNAME	Marie-Noel	Marie Noel	90	96
A00-006	FIRSTNAME	Franc	Frank	80	92
A00-007	FIRSTNAME	Mbarak	Moubarak	75	92
A00-008	FIRSTNAME	Inès	Ines	75	86
A00-009	FIRSTNAME	Inès	Iness	60	82
A00-010	FIRSTNAME	Inès	Yneès	60	78
A00-011	FIRSTNAME	Inès	Agnès	60	78
A00-021	FIRSTLASTNAME	Peter Parker	Pete Parker	92	92
A00-022	FIRSTLASTNAME	Peter Parker	peter parker	84	88
A00-023	FIRSTLASTNAME	Clark Kent	Claire Kent	82	90
A00-024	FIRSTLASTNAME	Wonder Woman	Ponder Woman	92	94
A00-025	FIRSTLASTNAME	Superman	Superman	100	100
A00-026	FIRSTLASTNAME	The Hulk	Iron Man	0	41
A00-027	FIRSTLASTNAME	Harissa FORD	Harisson Ford	62	85
A00-028	FIRSTLASTNAME	Bus WILLY	Bruce Willy	37	64
A00-029	FIRSTLASTNAME	Brigitte Bardo	Brigitte Fardo	93	97
A00-030	FIRSTLASTNAME	Hedi Mufti	Eddy Murfi	50	73
A00-031	FIRSTLASTNAME	Alain DE LOIN	Alain DELON	85	96
A00-032	FIRSTLASTNAME	De par de	2 par 2	56	75
A00-041	CITY	Paris	PArisss	58	81
A00-042	CITY	Paris	Pari	80	96
A00-043	CITY	Pékin	Beijing	29	56
A00-044	CITY	Londres	Londre	86	97
A00-045	CITY	Londres	London	58	84
A00-051	DATE	10-11-2016	10-NOV-16	50	79
A00-052	DATE	10-11-2016	JEUDI 10 NOVEMBER 2016	28	43
A00-053	DATE	11-11-2016	11-11-2016	100	100
A00-054	DATE	11-11-2016	11-12-2016	90	93
A00-055	DATE	11-11-2016	12-11-2016	90	84
A00-056	DATE	11-11-2016	11-11-2017	90	96
A00-061	EMAIL	fb@lipn.univ-paris13.fr	fb@lipn.univ-paris13.fr	100	100
A00-062	EMAIL	fb@lipn.univ-paris13.fr	yb@lipn.univ-paris13.fr	96	97
A00-063	EMAIL	fb@lipn.univ-paris13.fr	fb@iutv.univ-paris13.fr	83	91
A00-071	URL	www.univ-paris13.fr	www.univ-paris13.fr	100	100
A00-072	URL	www.univ-paris13.fr	www.univ-paris1.fr	95	98
A00-073	URL	www.univ-paris13.fr	www.univ-paris3.fr	95	98
A00-074	URL	www.univ-paris13.fr	www.univ-pari13.fr	95	98
A00-075	URL	www.univ-paris13.fr	www.univparis13.fr	95	98
A00-076	URL	www.sorbonne-paris-nord.fr	sorbonne-paris_nord.fr,fr	70	88
A00-081	NUMBER	17091958	17091958	100	100
A00-082	NUMBER	17091958	27091958	88	91
A00-083	NUMBER	12345679	12345678	88	95
A00-084	NUMBER	0.000012345679	0.000012345678	93	97

47 lignes sélectionnées

```
SELECT Idval,
       categorieval,
       UPPER(valeur1),
       UPPER(valeur2),
       UTL_MATCH.edit_distance_similarity(UPPER(valeur1), UPPER(valeur2)) EDS,
       UTL_MATCH.jaro_winkler_similarity(UPPER(valeur1), UPPER(valeur2)) JWS
FROM   matchval
ORDER BY Idval;
```

IDVAL	CATEGORIEVAL	UPPER(VALEUR1)	UPPER(VALEUR2)	EDS	JWS
A00-001	FIRSTNAME	ADAM	ADAM	100	100
A00-002	FIRSTNAME	ADAM	ADEM	75	86
A00-003	FIRSTNAME	ADAM	ADAMS	80	96
A00-004	FIRSTNAME	RAHMA	RAMA	80	94
A00-005	FIRSTNAME	MARIE-NOEL	MARIE NOEL	90	96
A00-006	FIRSTNAME	FRANC	FRANK	80	92
A00-007	FIRSTNAME	MBARAK	MOUBARAK	75	92
A00-008	FIRSTNAME	INÈS	INES	75	86
A00-009	FIRSTNAME	INÈS	INESS	60	82
A00-010	FIRSTNAME	INÈS	YNEES	60	78
A00-011	FIRSTNAME	INÈS	AGNÈS	60	78
A00-021	FIRSTLASTNAME	PETER PARKER	PETE PARKER	92	92
A00-022	FIRSTLASTNAME	PETER PARKER	PETER PARKER	100	100
A00-023	FIRSTLASTNAME	CLARK KENT	CLAIRE KENT	82	90
A00-024	FIRSTLASTNAME	WONDER WOMAN	PONDER WOMAN	92	94
A00-025	FIRSTLASTNAME	SUPERMAN	SUPERMAN	100	100
A00-026	FIRSTLASTNAME	THE HULK	IRON MAN	0	41
A00-027	FIRSTLASTNAME	HARISSA FORD	HARISSON FORD	85	93
A00-028	FIRSTLASTNAME	BUS WILLY	BRUCE WILLY	73	88
A00-029	FIRSTLASTNAME	BRIGITTE BARDO	BRIGITTE FARDO	93	97
A00-030	FIRSTLASTNAME	HEDI MUFTI	EDDY MURFI	50	80
A00-031	FIRSTLASTNAME	ALAIN DE LOIN	ALAIN DELON	85	96
A00-032	FIRSTLASTNAME	DE PAR DE	2 PAR 2	56	75
A00-041	CITY	PARIS	PARISSS	72	94
A00-042	CITY	PARIS	PARI	80	96
A00-043	CITY	PÉKIN	BEIJING	29	56
A00-044	CITY	LONDRES	LONDRE	86	97
A00-045	CITY	LONDRES	LONDON	58	84
A00-051	DATE	10-11-2016	10-NOV-16	50	79
A00-052	DATE	10-11-2016	JEUDI 10 NOVEMBER 2016	28	43
A00-053	DATE	11-11-2016	11-11-2016	100	100
A00-054	DATE	11-11-2016	11-12-2016	90	93
A00-055	DATE	11-11-2016	12-11-2016	90	84
A00-056	DATE	11-11-2016	11-11-2017	90	96
A00-061	EMAIL	FB@LIPN.UNIV-PARIS13.FR	FB@LIPN.UNIV-PARIS13.FR	100	100
A00-062	EMAIL	FB@LIPN.UNIV-PARIS13.FR	YB@LIPN.UNIV-PARIS13.FR	96	97
A00-063	EMAIL	FB@LIPN.UNIV-PARIS13.FR	FB@IUTV.UNIV-PARIS13.FR	83	91
A00-071	URL	WWW.UNIV-PARIS13.FR	WWW.UNIV-PARIS13.FR	100	100
A00-072	URL	WWW.UNIV-PARIS13.FR	WWW.UNIV-PARIS1.FR	95	98
A00-073	URL	WWW.UNIV-PARIS13.FR	WWW.UNIV-PARIS3.FR	95	98
A00-074	URL	WWW.UNIV-PARIS13.FR	WWW.UNIV-PARI13.FR	95	98
A00-075	URL	WWW.UNIV-PARIS13.FR	WWW.UNIVPARIS13.FR	95	98
A00-076	URL	WWW.SORBONNE-PARIS-NORD.FR	SORBONNE-PARIS_NORD.FR.FR	70	88
A00-081	NUMBER	17091958	17091958	100	100
A00-082	NUMBER	17091958	27091958	88	91
A00-083	NUMBER	12345679	12345678	88	95
A00-084	NUMBER	0.000012345679	0.000012345678	93	97

47 lignes sélectionnées


```

SELECT Idval,
       categorieval,
       LOWER(valeur1),
       LOWER(valeur2),
       UTL_MATCH.edit_distance_similarity(LOWER(valeur1), LOWER(valeur2)) EDS,
       UTL_MATCH.jaro_winkler_similarity(LOWER(valeur1), LOWER(valeur2)) JWS
FROM   matchval
ORDER BY Idval;

```

IDVAL	CATEGORIEVAL	LOWER (VALEUR1)	LOWER (VALEUR2)	EDS	JWS
A00-001	FIRSTNAME	adam	adam	100	100
A00-002	FIRSTNAME	adam	adem	75	86
A00-003	FIRSTNAME	adam	adams	80	96
A00-004	FIRSTNAME	rahma	rama	80	94
A00-005	FIRSTNAME	marie-noel	marie noel	90	96
A00-006	FIRSTNAME	franc	frank	80	92
A00-007	FIRSTNAME	mbarak	moubarak	75	92
A00-008	FIRSTNAME	inès	ines	75	86
A00-009	FIRSTNAME	inès	iness	60	82
A00-010	FIRSTNAME	inès	yneès	60	78
A00-011	FIRSTNAME	inès	agnès	60	78
A00-021	FIRSTLASTNAME	peter parker	pete parker	92	92
A00-022	FIRSTLASTNAME	peter parker	peter parker	100	100
A00-023	FIRSTLASTNAME	clark kent	claire kent	82	90
A00-024	FIRSTLASTNAME	wonder woman	ponder woman	92	94
A00-025	FIRSTLASTNAME	superman	superman	100	100
A00-026	FIRSTLASTNAME	the hulk	iron man	0	41
A00-027	FIRSTLASTNAME	harissa ford	harisson ford	85	93
A00-028	FIRSTLASTNAME	bus willy	bruce willy	73	88
A00-029	FIRSTLASTNAME	brigitte bardo	brigitte fardo	93	97
A00-030	FIRSTLASTNAME	hedi mufti	eddy murfi	50	80
A00-031	FIRSTLASTNAME	alain de loin	alain delon	85	96
A00-032	FIRSTLASTNAME	de par de	2 par 2	56	75
A00-041	CITY	paris	parisss	72	94
A00-042	CITY	paris	pari	80	96
A00-043	CITY	pékin	beijing	29	56
A00-044	CITY	londres	londre	86	97
A00-045	CITY	londres	london	58	84
A00-051	DATE	10-11-2016	10-nov-16	50	79
A00-052	DATE	10-11-2016	jeudi 10 novembre 2016	28	43
A00-053	DATE	11-11-2016	11-11-2016	100	100
A00-054	DATE	11-11-2016	11-12-2016	90	93
A00-055	DATE	11-11-2016	12-11-2016	90	84
A00-056	DATE	11-11-2016	11-11-2017	90	96
A00-061	EMAIL	fb@lipn.univ-paris13.fr	fb@lipn.univ-paris13.fr	100	100
A00-062	EMAIL	fb@lipn.univ-paris13.fr	yb@lipn.univ-paris13.fr	96	97
A00-063	EMAIL	fb@lipn.univ-paris13.fr	fb@iutv.univ-paris13.fr	83	91
A00-071	URL	www.univ-paris13.fr	www.univ-paris13.fr	100	100
A00-072	URL	www.univ-paris13.fr	www.univ-paris1.fr	95	98
A00-073	URL	www.univ-paris13.fr	www.univ-paris3.fr	95	98
A00-074	URL	www.univ-paris13.fr	www.univ-pari13.fr	95	98
A00-075	URL	www.univ-paris13.fr	www.univparis13.fr	95	98
A00-076	URL	www.sorbonne-paris-nord.fr	sorbonne-paris_nord.fr.fr	70	88
A00-081	NUMBER	17091958	17091958	100	100
A00-082	NUMBER	17091958	27091958	88	91
A00-083	NUMBER	12345679	12345678	88	95
A00-084	NUMBER	0.000012345679	0.000012345678	93	97
47 lignes sélectionnées					

<http://support.sas.com/resources/papers/proceedings16/2080-2016.pdf>

Creating a **Q-gram algorithm** to determine the similarity of two characters strings

Joe DeShon, Boehringer-Ingelheim Vetmedica

ABSTRACT

This paper shows how to program a powerful Q-gram algorithm for measuring the similarity of two characters strings. Along with built-in SAS functions -- such as SOUNDEX, SPEDIS, COMPGED, and COMPLEV -- Q-gram can be a valuable tool in your arsenal of string comparators. Q-gram is a method to evaluate letter patterns in words; pairs of words with a high Q-gram score have a large number of similar letter patterns, which is a good measure of their similarity. Q-gram is especially useful when measuring the similarity of strings that are intuitively identical, but which have a different word order, such as “John Smith” and “Smith, John”.

INTRODUCTION

A wide variety of applications require that two strings be compared, and a value be assigned that indicates the similarity of the strings. This is especially true as data becomes more unstructured and as computers become more powerful. People expect that the computer should be able to solve a problem such as judging the similarity of two strings as easily and as accurately as an intuitive human being can.

Of course, the expectation is that the computer should be able to solve the problem a million times a minute as databases get larger, more complicated, and less structured.

This paper will teach you how to write a powerful Q-gram algorithm that can be used to perform such string comparison tasks.

A développer en PL/SQL !