

**Intégration des données
&
Elimination des doubles et des similaires
Matching, Merging, and Deduplication
(2)**



M. F. Boufarès
Université Sorbonne Paris Nord
Master 2 EID2, Informatique



Think DIFFERENTLY, BIGGER and SMARTER!

Votre mission, si vous l'acceptez, est : Eliminer les doubles et les similaires



Si vous échouez, nous nierons avoir eu connaissance de vos agissements !

Exemple A :

Prompt : (1)

Parmi les **lignes (enregistrements)** suivantes quelles sont celles qui sont similaires, avec un seuil de similarité assez bon :

iutv1;LE BON;Adam;19-06-2001;EPINAY SUR SEINE;FRANCE
iutv2;LE BON;Adam;19-06-2001;EPINAY SUR SEINE;FRANCE
iutv3;BELLE;Clemence;16-10-1996;NICE;FRANCE
iutv4;UNIQUE;Alexandre;19-06-2001;PARIS;FRANCE
iutv5;TRAI FORT;Eve;19-06-2001;EPINAY-SUR-SEINE;FRANCE
iutv6;TRAI FORT;Nadia;17-09-2000;EPINAY-SUR-SEINE;FRANCE
iutv7;CHEVALIER;Ines;17-09-2000;EPINAY-SUR-SEINE

LLM : (1)

Oui. Pour ce type de problème, il est préférable de distinguer **la similarité entre les champs** et **la similarité globale entre deux enregistrements**. En record linkage, une approche classique consiste justement à calculer une similarité pour chaque champ puis à les agréger avec des poids et un seuil de décision. Jaro-Winkler est particulièrement adapté aux noms, prénoms et chaînes courtes.

J'ai considéré ici les champs :

Nom | Prénom | Date de naissance | Ville | Pays

et j'ai neutralisé les différences de représentation telles que :

- EPINAY SUR SEINE ↔ EPINAY-SUR-SEINE
- majuscules/minuscules
- espaces et tirets.

Résultat des rapprochements

Paire	Nom	Prénom	Date	Ville	Pays	Lecture
iutv1 – iutv2	1.00	1.00	1.00	1.00	1.00	● Doublon exact
iutv5 – iutv6	1.00	0.00	0.80	1.00	1.00	● Très similaires
iutv6 – iutv7	0.57	0.48	1.00	1.00	—	● Assez similaires
iutv1 – iutv6	0.44	0.63	0.80	1.00	1.00	● Similarité moyenne/élevée
iutv5 – iutv7	0.57	0.53	0.80	1.00	—	● Similarité moyenne
iutv4 – iutv5	0.43	0.48	1.00	0.65	1.00	● plutôt faible
iutv1 – iutv4	0.00	0.62	1.00	0.65	1.00	● plutôt faible
autres paires	—	—	—	—	—	○ faible

Les groupes intéressants

1. iutv1 ↔ iutv2 : doublon certain

iutv1;LE BON;Adam;19-06-2001;EPINAY SUR SEINE;FRANCE

iutv2;LE BON;Adam;19-06-2001;EPINAY SUR SEINE;FRANCE

C'est un **doublon exact** à **100 %** sur les attributs disponibles.

➔ **Même individu très probablement.**

2. iutv5 ↔ iutv6 : même famille / même foyer possible

iutv5;TRAIFORT;Eve;19-06-2001;EPINAY-SUR-SEINE;FRANCE

iutv6;TRAIFORT;Nadia;17-09-2000;EPINAY-SUR-SEINE;FRANCE

Similarités :

- Nom : **100 %**
- Prénom : différent
- Date : **80 % environ**
- Ville : **100 %** après normalisation
- Pays : **100 %**

➔ Ce sont clairement des **enregistrements proches**, mais **pas un doublon** : les prénoms et dates de naissance sont différents.

Il serait donc dangereux de considérer une similarité globale élevée comme synonyme de « même personne ».

C'est précisément l'enjeu du *record linkage* : distinguer les vrais doublons des personnes différentes mais partageant plusieurs attributs.

3. iutv6 ↔ iutv7 : rapprochement intéressant

iutv6;TRAIFORT;Nadia;17-09-2000;EPINAY-SUR-SEINE;FRANCE

iutv7;CHEVALIER;Ines;17-09-2000;EPINAY-SUR-SEINE

Exemple B :**Prompt : (2)**

Parmi les lignes (enregistrements) suivantes quelles sont celles qui sont similaires, avec un seuil de similarité assez bon :

iutv1;LE BON;Adam;19-06-2001;EPINAY SUR SEINE;FRANCE
 iutv2;LE BON;Adam;19-06-2001;EPINAY SUR SEINE;FRANCE
 iutv3;BELLE;Clemence;16-10-1996;NICE;FRANCE
 iutv4;UNIQUE;Alexandre;19-06-2001;PARIS;FRANCE
 iutv5;TRAIFORT;Eve;19-06-2001;EPINAY-SUR-SEINE;FRANCE
 iutv6;TRAIFORT;Nadia;17-09-2000;EPINAY-SUR-SEINE;France
 iutv7;CHEVALIER;Ines;17-09-2000;EPINAY-SUR-SEINE

ig1;LE BON;Adem;19-06-2001;EPINAY-SUR-SEINE;FRANCE
 ig2;BELLE;C.; '16-10-1996;NICE;FRANCE
 ig3;LEBON;Adams;., 'PARIS;FRANCE
 ig4;CHEVALIER;Inès;17-09-2000;EPINAY-SUR-SEINE;FRANCE
 ig5;CHEVALIER;Jean;17-09-2001;ORLY-VILLE;France

LLM : (2)

Oui. Pour ce type de **détection de doublons / record linkage**, il est pertinent de comparer séparément les champs (nom, prénom, date de naissance, ville, pays), puis de calculer un score global. Le **Jaro-Winkler** est particulièrement adapté aux petites variations orthographiques dans les noms et prénoms.

J'ai considéré comme « **assez bon** » un score global d'environ **0,85 ou plus**, avec une attention particulière aux champs très discriminants comme la date de naissance.

1. Les correspondances les plus fortes

Enregistrements	Similarité estimée	Analyse
iutv1 ↔ iutv2	100 %	Doublon exact
iutv1 ↔ ig1	≈ 96,7 %	LE BON / LE BON ; Adam / Adem ; même date et même ville
iutv2 ↔ ig1	≈ 96,7 %	Même situation
iutv3 ↔ ig2	≈ 93,4 %	BELLE ; Clémence / C. ; même date et même ville
iutv7 ↔ ig4	100 %	Inès / Inès, mêmes autres informations après normalisation
iutv1 ↔ ig3	≈ 91,7 %	LE BON / LEBON ; Adam / Adams ; mais ville différente et date absente dans ig3
iutv2 ↔ ig3	≈ 91,7 %	Même remarque
ig1 ↔ ig3	≈ 87,3 %	LE BON / LEBON ; Adem / Adams ; mais ville différente et date absente

2. Les groupes de doublons probables

Je regrouperais donc les données ainsi :

● **Groupe A — très forte probabilité de même personne**

iutv1 – iutv2 – ig1

iutv1 LE BON Adam 19-06-2001 EPINAY SUR SEINE

iutv2 LE BON Adam 19-06-2001 EPINAY SUR SEINE

ig1 LE BON Adem 19-06-2001 EPINAY-SUR-SEINE

C'est un cas très caractéristique de **doublon avec erreurs mineures** :

- Adam ↔ Adem
- EPINAY SUR SEINE ↔ EPINAY-SUR-SEINE
- tout le reste concorde.

→ Je considérerais ces trois enregistrements comme une même entité.

● Groupe B — très forte probabilité

iutv3 – ig2

iutv3 BELLE Clemence 16-10-1996 NICE FRANCE

ig2 BELLE C. 16-10-1996 NICE FRANCE

La différence Clemence / C. est importante syntaxiquement, mais les autres champs sont identiques.

→ Très probablement la même personne.

● Groupe C — doublon quasi certain

iutv7 – ig4

iutv7 CHEVALIER Ines 17-09-2000 EPINAY-SUR-SEINE

ig4 CHEVALIER Inès 17-09-2000 EPINAY-SUR-SEINE FRANCE

La différence Ines / Inès disparaît après normalisation des accents.

→ Même personne avec une probabilité très élevée.

3. Cas intéressant : iutv1/iutv2 ↔ ig3

iutv1 LE BON Adam 19-06-2001 EPINAY SUR SEINE FRANCE

ig3 LEBON Adams PARIS FRANCE

Le score lexical est relativement élevé parce que :

- LE BON ↔ LEBON
- Adam ↔ Adams

Mais deux informations importantes divergent/manquent :

- date de naissance : 19-06-2001 ↔ absente ;
- ville : EPINAY-SUR-SEINE ↔ PARIS.

→ Je ne classerais pas ig3 comme doublon certain.

C'est justement un bon exemple où **le score global seul peut être trompeur**. En record linkage, on combine généralement plusieurs champs et on peut donner des poids différents aux variables.

4. Cas à ne pas fusionner : iutv6 ↔ iutv7

iutv6 TRAFORT Nadia 17-09-2000 EPINAY-SUR-SEINE

iutv7 CHEVALIER Ines 17-09-2000 EPINAY-SUR-SEINE

Ils ont :

- même date de naissance ;
- même ville ;
- mais **nom différent** ;
- **prénom différent**.

→ Même date + même ville ne suffit pas pour conclure à un doublon.

Il pourrait s'agir de deux personnes différentes.

5. Cas iutv7 ↔ ig5

iutv7 CHEVALIER Ines 17-09-2000 EPINAY-SUR-SEINE

ig5 CHEVALIER Jean 17-09-2001 ORLY-VILLE

Le nom est identique, mais :

- prénom différent ;
- date différente ;
- ville différente.

→ Pas un doublon malgré le nom identique.

Synthèse

Avec un seuil « assez bon » et une analyse multi-attributs, je retiendrais :

DUPLICAT CERTAIN

=====

iutv1 ↔ iutv2

DUPLICATS TRÈS PROBABLES

=====

iutv1 ↔ ig1

iutv2 ↔ ig1

iutv3 ↔ ig2

iutv7 ↔ ig4

CAS À SURVEILLER

=====

iutv1 ↔ ig3

iutv2 ↔ ig3

ig1 ↔ ig3

CAS NON CONCLUANTS / À NE PAS FUSIONNER

=====

iutv6 ↔ iutv7

iutv7 ↔ ig5

Point méthodologique important : pour votre problématique de qualité des données, je vous conseille de ne pas définir le seuil uniquement sur le score global. Une stratégie plus robuste serait par exemple :

Nom : 30 % + Prénom : 25 % + Date de naissance : 25 % + Ville : 15 % + Pays : 5 %

puis d'ajouter des **règles bloquantes** : une forte ressemblance de nom ne doit pas compenser automatiquement une date de naissance incompatible.

Le Jaro-Winkler est justement utilisé dans des approches de *record linkage* combinant similarité des noms/adresses et comparaison exacte de variables comme la date de naissance.

Prompt : (3)

Comment on pourrait **fusionner** les **lignes** considérées très **proches** ?

LLM : (3)

Oui. Pour votre cas, je parlerais plutôt de **fusion de doublons par consolidation** que d'une simple suppression de lignes.

L'idée est de créer un **enregistrement maître** à partir des lignes très proches, en conservant la meilleure valeur de chaque attribut.

1. Exemple : iutv1, iutv2, ig1

On a :

iutv1;LE BON;Adam;19-06-2001;EPINAY SUR SEINE;FRANCE

iutv2;LE BON;Adam;19-06-2001;EPINAY SUR SEINE;FRANCE

ig1;LE BON;Adem;19-06-2001;EPINAY-SUR-SEINE;FRANCE

Après normalisation :

Nom → LE BON

Prénom → Adam / Adem

Date → 19-06-2001

Ville → EPINAY-SUR-SEINE

Pays → FRANCE

On peut donc produire :

M1;LE BON;Adam;19-06-2001;EPINAY-SUR-SEINE;FRANCE

avec, éventuellement, une table de traçabilité :

M1 ← iutv1, iutv2, ig1

2. Exemple : iutv3 + ig2

iutv3;BELLE;Clemence;16-10-1996;NICE;FRANCE

ig2;BELLE;C.;16-10-1996;NICE;FRANCE

Fusion :

M2;BELLE;CLEMENCE;16-10-1996;NICE;FRANCE

Ici, Clemence est préférable à C. car c'est une information plus complète.

3. Exemple : iutv7 + ig4

iutv7;CHEVALIER;Ines;17-09-2000;EPINAY-SUR-SEINE

ig4;CHEVALIER;Inès;17-09-2000;EPINAY-SUR-SEINE;FRANCE

Après normalisation des accents :

M3;CHEVALIER;INÈS;17-09-2000;EPINAY-SUR-SEINE;FRANCE

Ici, ig4 apporte notamment l'information FRANCE, absente de iutv7.

4. Le principe général

Je vous conseille un processus en **4 étapes** :

DONNÉES BRUTES ▼			
NORMALISATION	CALCUL DE SIMILARITÉ	CLUSTERS DE DOUBLONS	CONSOLIDATION
DONNÉES DE RÉFÉRENCE			

Étape A — Normaliser

Avant de comparer :

LE BON → LEBON EPINAY SUR SEINE → EPINAYSURSEINE EPINAY-SUR-SEINE → EPINAYSURSEINE
Inès → INES Clemence → CLEMENCE

On peut également :

- supprimer espaces superflus ;
- uniformiser majuscules/minuscules ;
- supprimer ou traiter les accents ;
- uniformiser les tirets ;
- standardiser les dates.

Attention : je conserverais toujours la valeur originale dans les données sources.

Étape B — Identifier les groupes

Par exemple :

Groupe	Enregistrements	Décision
G1	iutv1, iutv2, ig1	Fusion
G2	iutv3, ig2	Fusion
G3	iutv7, ig4	Fusion
G4	iutv1, iutv2, ig3	À vérifier
G5	iutv6, iutv7	Ne pas fusionner
G6	iutv7, ig5	Ne pas fusionner

Cela revient à construire des **clusters de similarité**.

5. Comment choisir la valeur finale ?

C'est une question très importante.

Je proposerais une règle de **fiabilité des valeurs** :

Cas 1 — Valeurs identiques

Adam Adam → Adam

Cas 2 — Différences typographiques

EPINAY SUR SEINE EPINAY-SUR-SEINE → EPINAY-SUR-SEINE

Cas 3 — Valeur abrégée contre valeur complète

C. Clemence → Clemence

Cas 4 — Accent

Ines Inès → Inès

Cas 5 — Valeurs contradictoires

Par exemple : Date : 17-09-2000 Date : 17-09-2001

➔ **Ne pas choisir automatiquement.**

Il faut conserver :

statut = A_VERIFIER

plutôt que d'inventer une valeur.

6. Je vous conseille de conserver l'historique

Plutôt que de simplement faire :

iutv1 iutv2 ig1 → M1

Je créerais trois niveaux :

Table **DONNEES_BRUTES**

ID	NOM	PRENOM	DATE	VILLE
iutv1	LE BON	Adam	19-06-2001	EPINAY SUR SEINE
iutv2	LE BON	Adam	19-06-2001	EPINAY SUR SEINE
ig1	LE BON	Adem	19-06-2001	EPINAY-SUR-SEINE

Table **CLUSTERS**

CLUSTER_ID	ENREGISTREMENT
C001	iutv1
C001	iutv2
C001	ig1

Table **DONNEES_CONSOLIDEES**

MASTER_ID	NOM	PRENOM	DATE	VILLE	PAYS
M001	LE BON	ADAM	19-06-2001	EPINAY-SUR-SEINE	FRANCE

Cela permet de répondre à la question :

« **Pourquoi ces trois lignes ont-elles été fusionnées ?** »

7. Encore mieux : conserver le score

Pour le projet sur la **qualité des données**, je trouve particulièrement intéressant de conserver le résultat du processus :

MASTER_ID : M001

Sources : iutv1 iutv2 ig1	Score : Nom = 1.00 Prénom = 0.93 Date = 1.00 Ville = 0.98 Pays = 1.00	Score global = 0.97
------------------------------------	--	---------------------

Décision = FUSION

Ainsi, la fusion devient **explicable et traçable**.

8. Une architecture intéressante pour la problématique

On pourrait même formaliser cela comme :

Détection → Appariement → Clustering → Consolidation → Traçabilité

avec :

DONNÉES BRUTES ▼			
NORMALISATION	SIMILARITÉ : Jaro-Winkler , Q-Gram...	CLUSTERISATION des doublons	CONSOLIDATION valeur fiable
MASTER RECORD	TABLE DE TRAÇABILITÉ		

C'est particulièrement adapté à la problématique de qualité des données, car la fusion ne se limite plus à « supprimer les doublons » : elle devient une opération de **résolution d'entités (*entity resolution*)** et de **création d'un enregistrement de référence (*master record*)**.