UNIVERSITÉ SORBONNE PARIS NORD

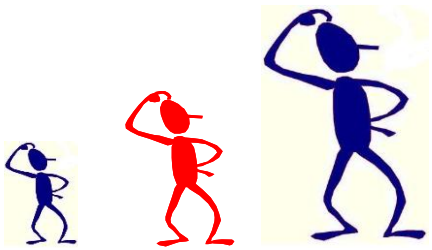




La Donnée e-s-t le Monde de Demain

Data is-and the Future

The Data Science, The Data Scientist, The Data Engineer, The Date Manager
Data Engineering And Machine Learning





Dr. M. Faouzi BOUFARES



faouzi.boufares@sorbonne-paris-nord.fr
boufares@lipn.univ-paris13.fr
http://www.lipn.univ-paris13.fr/~boufares/
Laboratoire d'Informatique de Paris Nord (**LIPN**)
La Maison des Sciences Numériques (**MSN**)
Université Sorbonne Paris Nord – France (**USPN**)

#USPN www.univ-sorbonne-paris-nord.fr







دَارُ الْحِكْمَةِ



House of Wisdom, Maison de la Sagesse

عبارة تعبر عن **مكان يُعتنى فيه بالعلم والمعرفة**.

هذا الاسم ارتبط تاريخيًا بمكتبة شهيرة ومركز علمي في **بغداد خلال العصر العباسي**، وكان رمزًا للازدهار الثقافي والفكري، حيث اجتمع **العلماء من مختلف التخصصات لترجمة الكتب وتطوير العلوم**.

Données = Data ?

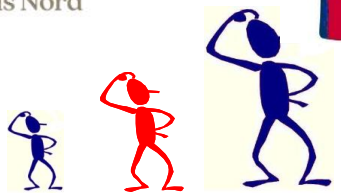
DoD : des Données aux Décideurs !

Bases de Données Avancées, Introduction

+++

Entrepôts de Données, Introduction

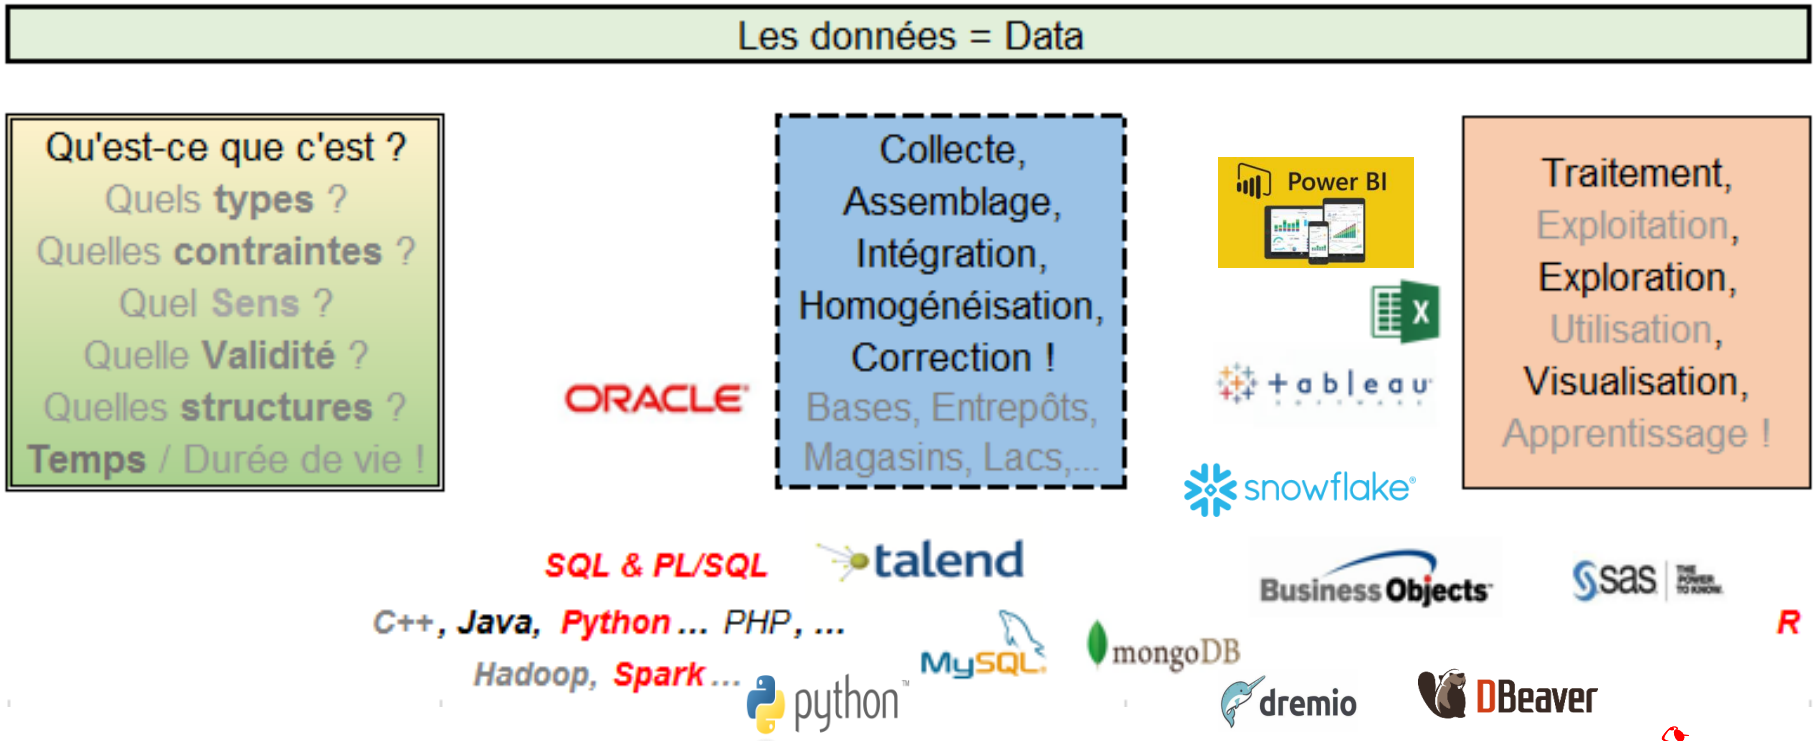




M. Faouzi BOUFARES
boufares@lipn.univ-paris13.fr
http://www.lipn.univ-paris13.fr/~boufares/
Bureau Y204
Laboratoire d'Informatique de Paris Nord
LIPN – UMR 7030 du CNRS
La MSN, A3
Université Sorbonne Paris Nord
Institut Galilée
99, Avenue J.B. Clément
F-93430 Villetaneuse FRANCE
www.univ-paris13.fr
faouzi.boufares@sorbonne-paris-nord.fr

Base de Données (**Database**) ; Entrepôt de Données (**Data Warehouse**) ;
Lac de Données (**Data Lake**) ; Données de Référence (**Master Data**) ;

BI (Business Intelligence) et **AI (Artificial Intelligence)**



UNIVERSITÉ SORBONNE PARIS NORD

Données = Data ?

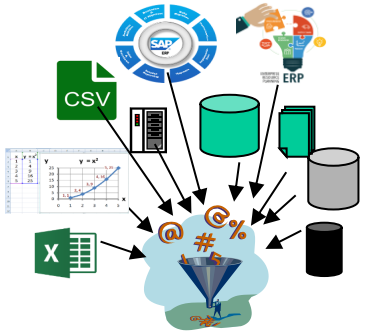
DoD : des Données aux Décideurs !

MACHINE LEARNING: From DATA to DECISIONS

UNDERSTANDING DATA

Collecting, Assembling,
Integrating data
Data cleaning

Data processing
PREDICTION, DEDUCTION,
CAUSAL INFERENCE,
DECISION MAKING

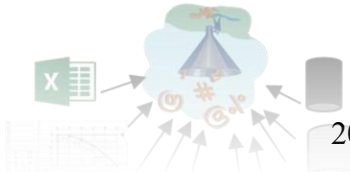








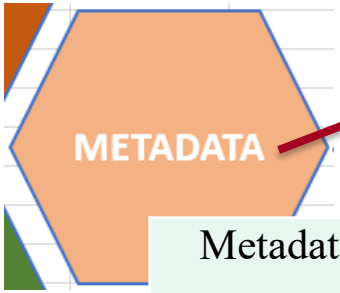
Think Bigger, Differently & Smarter by using correct DATA



UNIVERSITÉ SORBONNE PARIS NORD

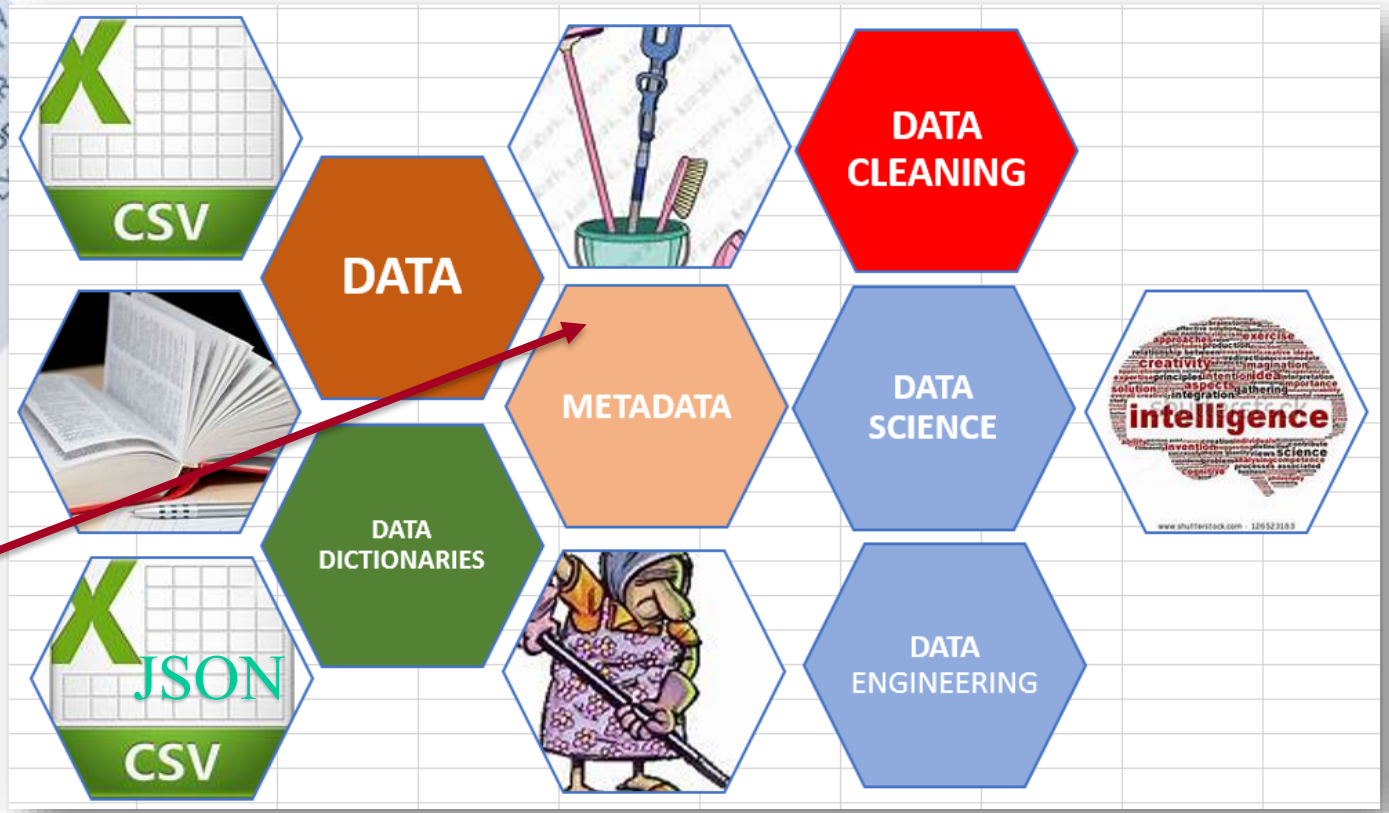
Data ? Méta-Data





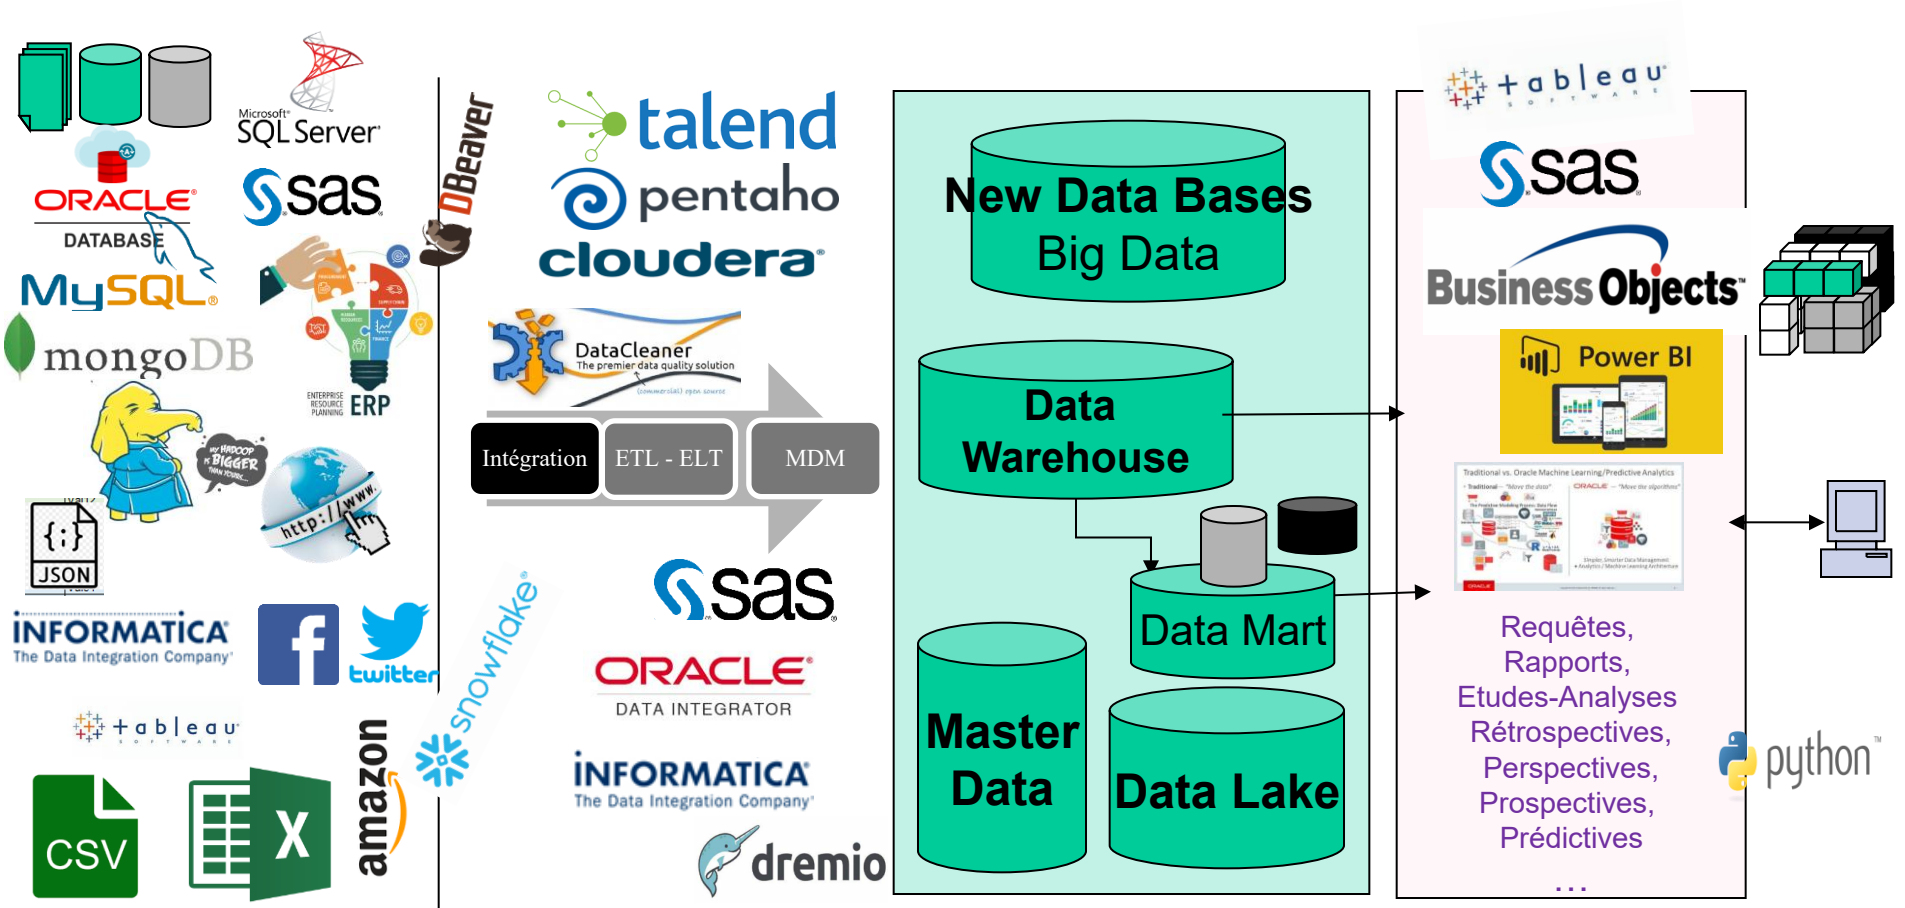
Metadata

Features
Measures



… Quelques outils qui manipulent les Données …

Traitement, Intégration & Exploitation des données ; Certains outils du marché



Outils de Gestion des Sources de données Hétérogènes

Outils d'intégration des données Hétérogènes et de gestion de la qualité

Outils de traitement-exploitation des données intégrées

...Des questions sur La Data, Les Données ?...



Data INTEGRATION TO *Think Bigger, Differently & Smarter*

Zone de préparation

Zone de stockage de données massives

Zone de présentation

Sources de données Hétérogènes

E X T R A C T

INTEGRER
ASSEMBLER
les données

Nettoyer
Standardiser
Normaliser
Homogénéiser
Dédoublonner
Enrichir
Commenter

T R A N S F O R M

L O A D

New Data Bases
Big Data

Data Warehouse

Data Mart

Master Data

Data Lake

Requêtes
Rapports
Visualisation
Data Mining
Recommandation
…

Etudes-Analyses
Rétrospectives,
Perspectives,
Prospectives,
Prédictives
…

python

Intégration | ETL - ELT | MDM

The better the quality of the data, the better it can be used for analyses

...Des questions sur La Data, Les Données ?...



Data INTEGRATION TO ***Think Bigger, Differently & Smarter***

Préparation des données (Data Preparation ; Data Prep)

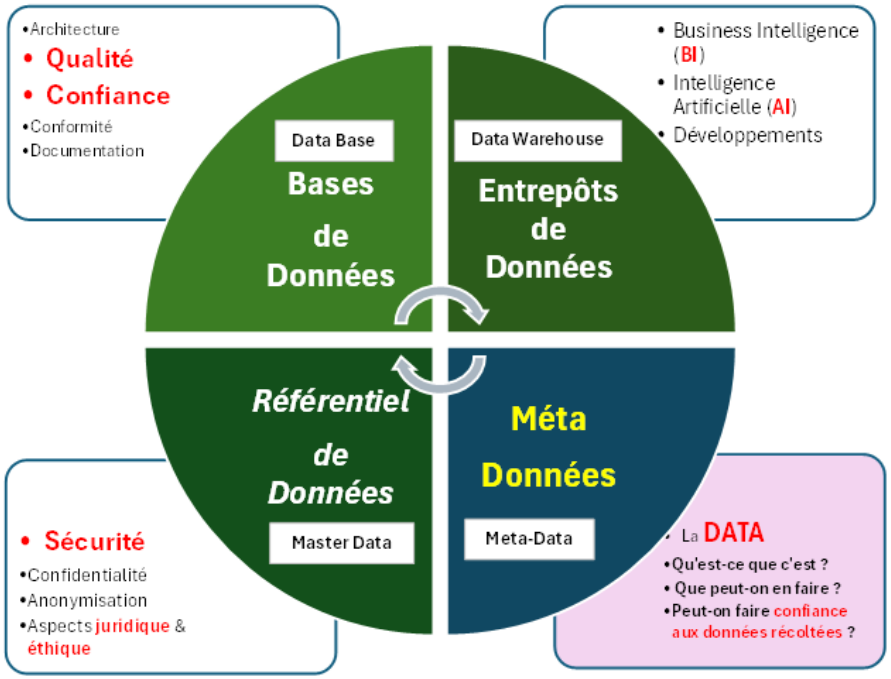
The standard definition of **data preparation** is:
"The process of gathering, combining, structuring, and organizing data."
La définition standard de la **préparation des données** est la suivante :
"Le processus de collecte, de combinaison, de structuration et d'organisation des données".



Préparation des données (Data Preparation ; Data Prep)

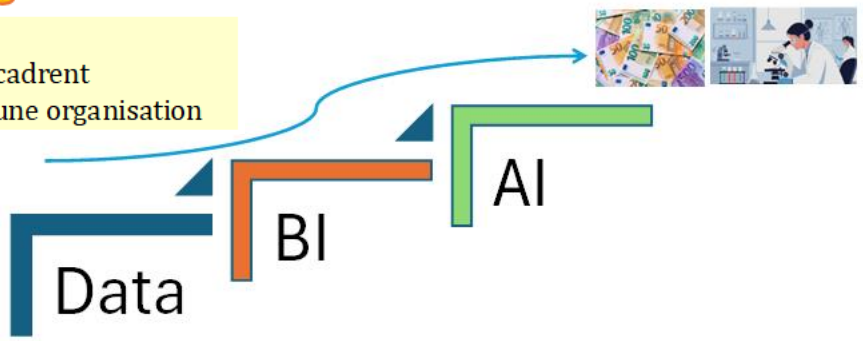
Au stade de la préparation des données, on convertit tout format de données dans un format natif, on exécute des utilitaires pour nettoyer les données, on dédoublonne (On s'occupe de la déduplication des enregistrements de la base de données) et on charge les données dans tout autre format souhaité…
De nombreux utilitaires sont utilisés pour nettoyer, organiser et normaliser les données.

… Quelques mots clés sur la Donnée … DATA



Gouvernance des Données

Gouvernance des données = Data Governance :
ensemble de politiques, processus et responsabilités qui encadrent
la qualité, la sécurité, l'accessibilité et **l'usage des données** dans une organisation



… Des Données … Aux décideurs !

La **BI** « **Business Intelligence** » vise à extraire des informations des « Données de Base ou BD » de l'entreprise, à concevoir et construire : des entrepôts de données (Data WareHouses) et des magasins de données (Data Marts) et éventuellement des « Données de Référence, Master Data » ou encore des « lacs de données, Data Lakes » avec comme objectif de développer **des outils d'aide à la décision** tels que des tableaux de bord !

Plusieurs grandes étapes : Extraction ; Stockage & Exposition ; Analyse (Reporting, Data Mining, Analyse Multidimensionnelle avec des CUBE OLAP et des tableaux de bord)

Afin d'améliorer les performances de temps de réponse (temps réel) et de calculs
On peut utiliser des frameworks de type Big Data… → Le **Cloud Computing**… et **Grille de Calcul** !

Think Bigger, Differently & Smarter by using correct DATA

BI (Business Intelligence) et **AI (Artificial Intelligence)** sont deux concepts complémentaires qui jouent un rôle clé dans la gestion et l'analyse des données dans les entreprises.

BI (Business Intelligence) : La **BI** désigne les technologies, outils et pratiques utilisés pour collecter, analyser et présenter les données d'une entreprise afin d'**aider à la prise de décision**.

Objectifs :

- Fournir des rapports et tableaux de bord pour visualiser les performances.
- Aider à identifier les tendances, opportunités et risques.
- Faciliter les décisions basées sur les données (data-driven decisions).

Composants clés :

- **ETL (Extract, Transform, Load)** : Processus d'intégration des données.
- **Outils BI** : Power BI, Tableau, QlikView, etc.
- **Tableaux de bord et reporting** : Interfaces visuelles pour interpréter les données.

Exemple :

Un tableau de bord qui montre les ventes par région pour permettre à un directeur commercial de réorienter ses efforts là où les performances sont faibles.

BI (Business Intelligence) et **AI (Artificial Intelligence)** sont deux concepts complémentaires qui jouent un rôle clé dans la gestion et l'analyse des données dans les entreprises.

AI (Artificial Intelligence) : L'**IA** est un domaine de l'informatique qui vise à créer des systèmes capables de simuler l'intelligence humaine, comme apprendre, raisonner et résoudre des problèmes.

Objectifs :

- Automatiser des tâches complexes.
- Prédire des résultats futurs à partir de données historiques.
- Réaliser des analyses plus avancées grâce à l'apprentissage automatique (Machine Learning) et à l'apprentissage profond (Deep Learning).

Composants clés :

- **Machine Learning (ML)** : Modèles pour apprendre à partir des données.
- **Traitement du langage naturel (NLP)** : Compréhension et génération de langage humain.
- **Vision par ordinateur** : Analyse des images et vidéos.

Exemple :

Un système d'IA qui prédit les ventes d'un produit en fonction des tendances historiques et des conditions actuelles du marché.

BI (Business Intelligence) et **AI (Artificial Intelligence)** sont deux concepts complémentaires qui jouent un rôle clé dans la gestion et l'analyse des données dans les entreprises.

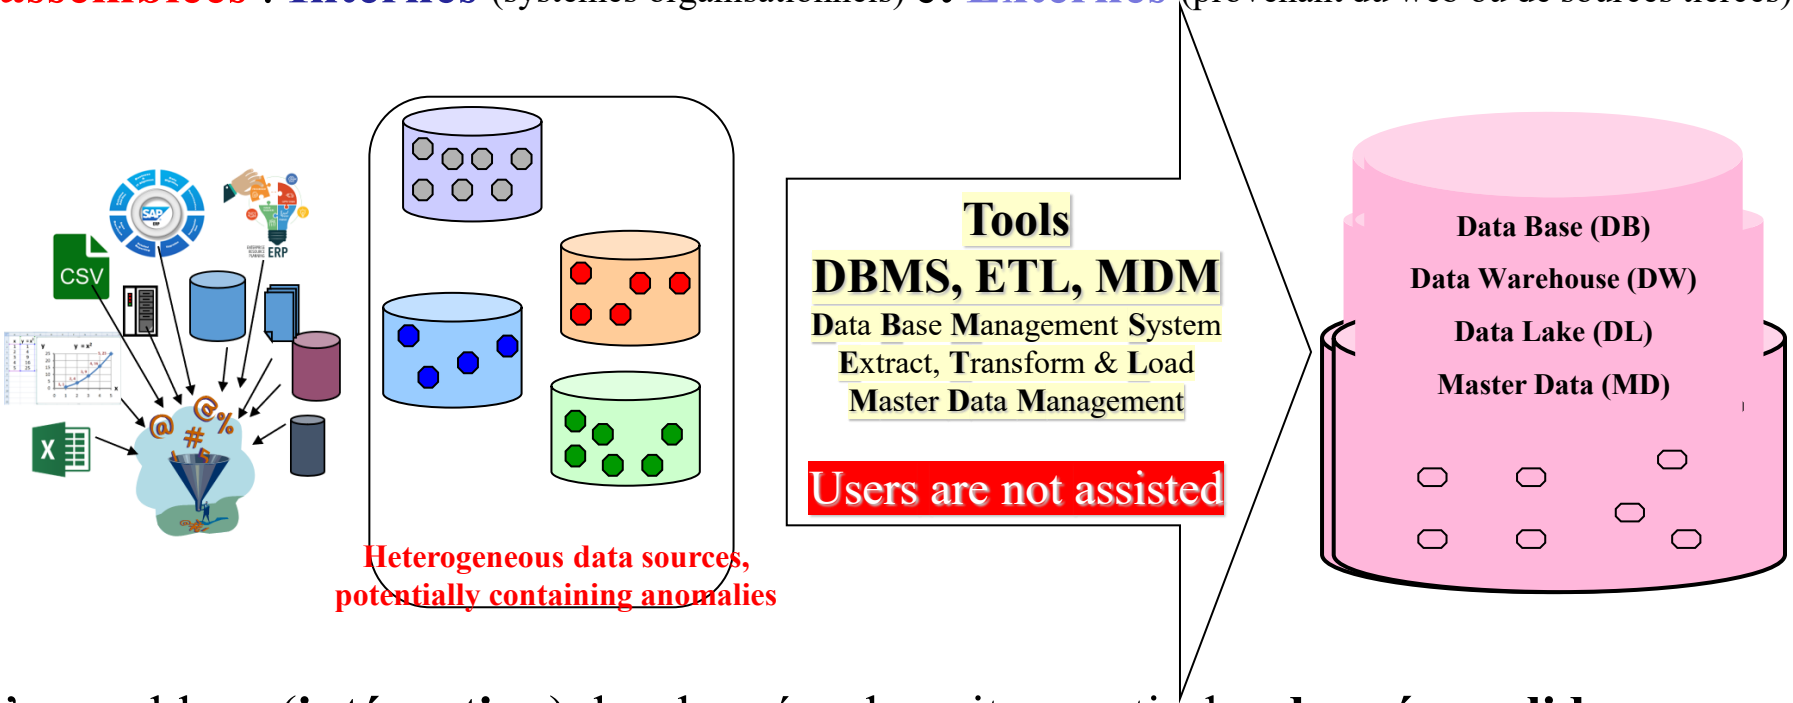
Complémentarité BI & AI

•La BI se concentre sur **l'analyse descriptive** (ce qui s'est passé) et l'analyse diagnostique (pourquoi cela s'est produit).

•L'IA permet d'aller plus loin avec **l'analyse prédictive** (ce qui va se passer) et **l'analyse prescriptive** (que devrions-nous faire).

Exemple d'intégration BI & AI :
Dans un outil de BI, des algorithmes d'IA pourraient être utilisés pour suggérer des stratégies en fonction des performances passées ou pour automatiser l'analyse des anomalies dans les données.

Les **décisions**, au sein d'une organisation, s'appuient sur **deux** types de **données rassemblées** : **Internes** (systèmes organisationnels) et **Externes** (provenant du web ou de sources tierces).



L'assemblage (**intégration**) des données devrait garantir des **données valides, complètes**, **homogènes** et **non contradictoires (des données de BONNE qualité)** pour des décisions éclairées [AI & BI = (A & B) I].

UNIVERSITÉ SORBONNE PARIS NORD

Données = Data ?

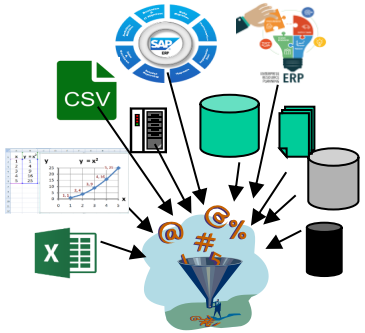
DoD : des Données aux Décideurs !

MACHINE LEARNING: From DATA to DECISIONS

UNDERSTANDING DATA

Collecting, Assembling,
Integrating data
Data cleaning

Data processing
PREDICTION, DEDUCTION,
CAUSAL INFERENCE,
DECISION MAKING

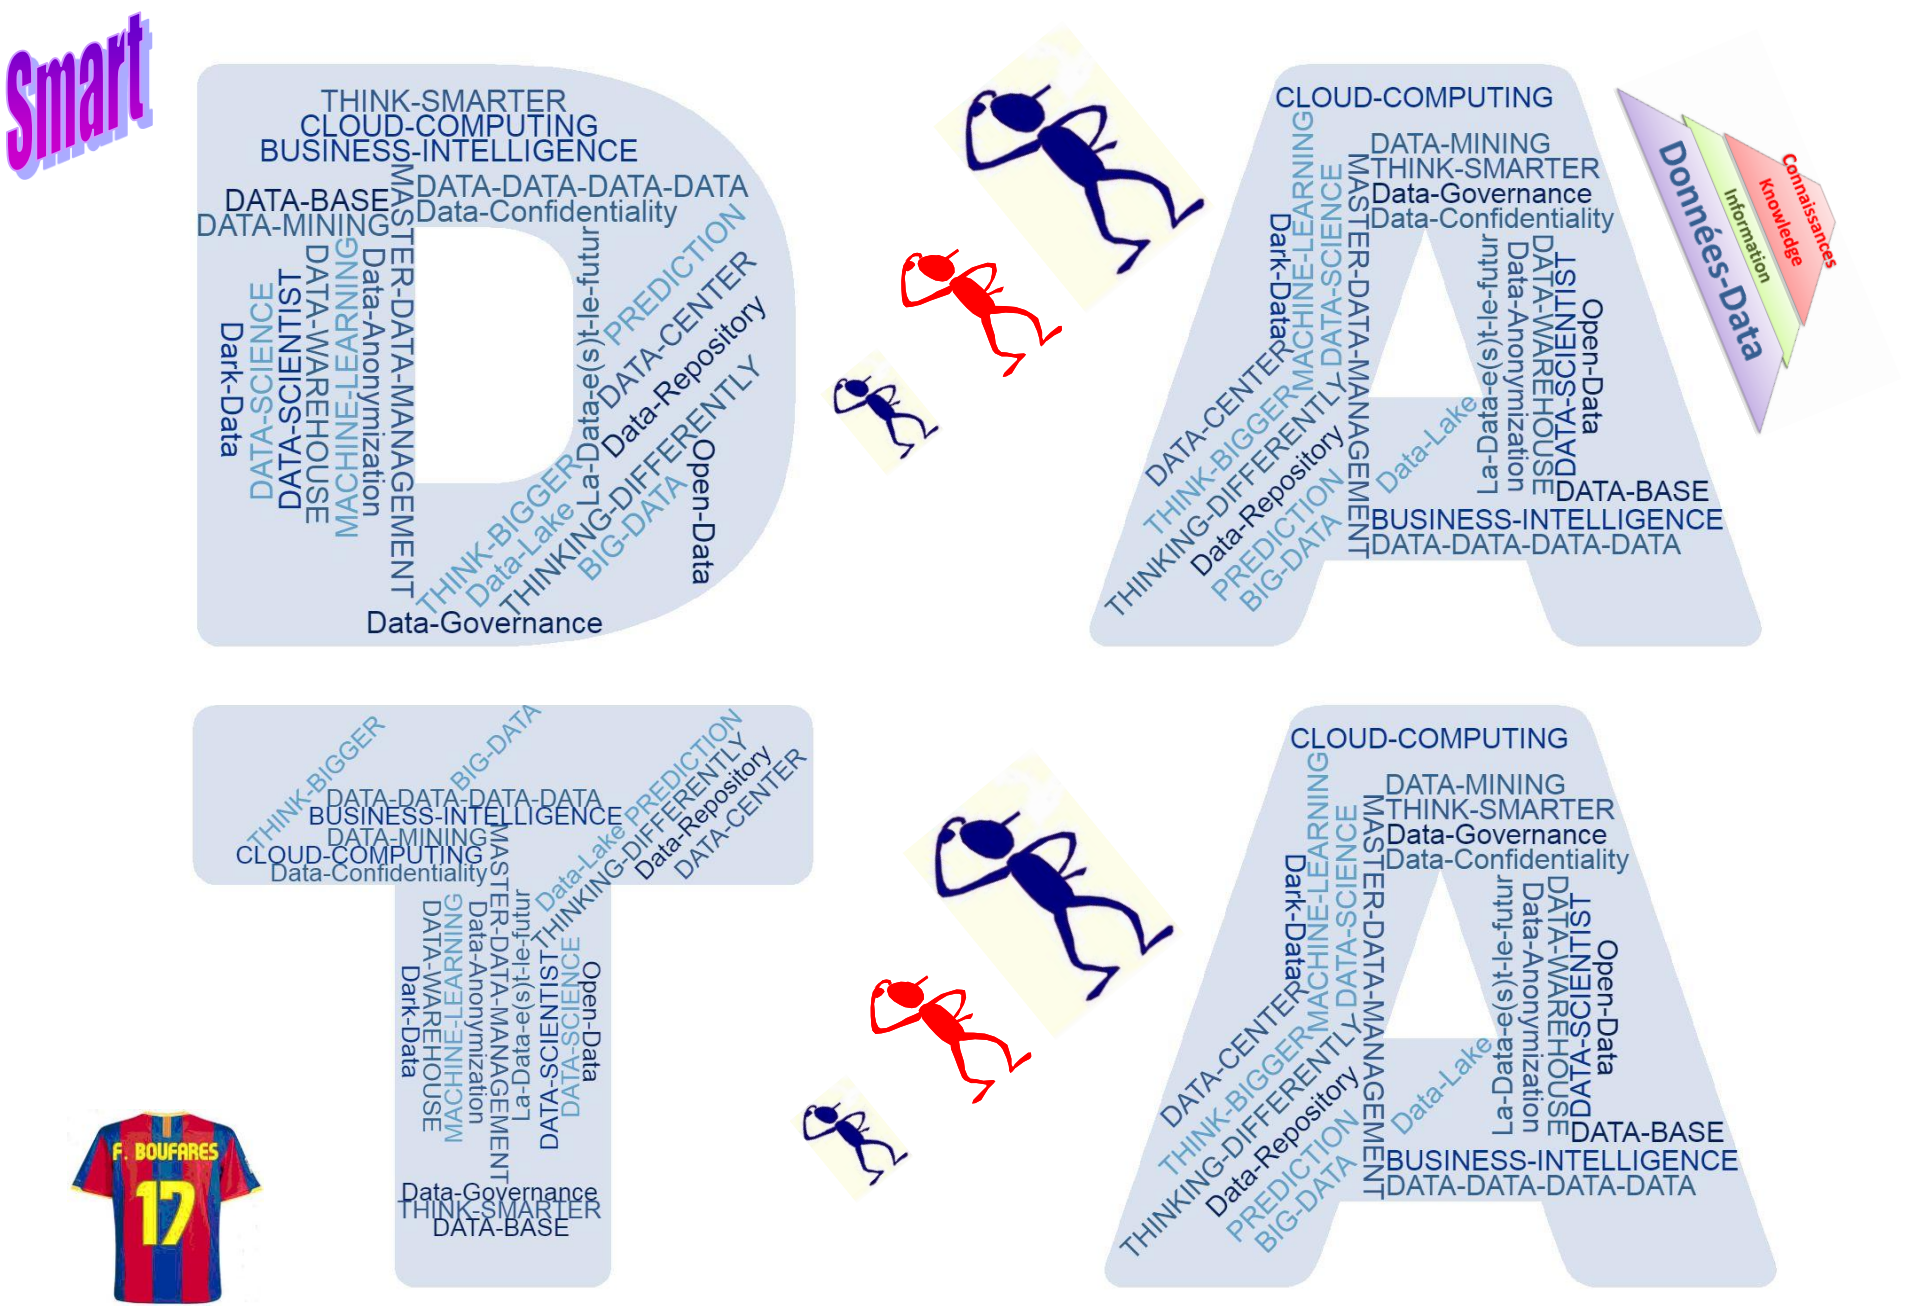








Think Bigger, Differently & Smarter by using correct DATA


Smart
THINK-SMARTER
CLOUD-COMPUTING
BUSINESS-INTELLIGENCE
DATA-BASE
DATA-MINING
MASTER-DATA-MANAGEMENT
DATA-DATA-DATA-DATA
Data-Confidentiality
PREDICTION
DATA-CENTER
Data-Repository
THINKING-DIFFERENTLY
Open-Data
BIG-DATA
Data-Lake
THINK-BIGGER
La-Data-e(s)t-le-futur
Data-Governance
Dark-Data
DATA-SCIENCE
DATA-SCIENTIST
DATA-WAREHOUSE
MACHINE-LEARNING
Data-Anonymization
CLOUD-COMPUTING
DATA-MINING
THINK-SMARTER
Data-Governance
Data-Confidentiality
MASTER-DATA-MANAGEMENT
DATA-SCIENCE
MACHINE-LEARNING
Dark-Data
DATA-CENTER
THINK-BIGGER
THINKING-DIFFERENTLY
Data-Repository
PREDICTION
BIG-DATA
Data-Lake
La-Data-e(s)t-le-futur
Data-Anonymization
DATA-WAREHOUSE
DATA-SCIENTIST
Open-Data
DATA-BASE
BUSINESS-INTELLIGENCE
DATA-DATA-DATA-DATA
Données-Data
Connaissances
Knowledge
Information
F. BOUFARES
17

BD-DB ; ED-DW-DL ; BigData

Exploration Informatique des Données et Décisionnel

PLAN *BDA/ED*

Introduction (Bases et Entrepôts de Données, Big-Data) :

La DATA (la Donnée)… !!! ; Introduction sur les données, leurs collectes et leurs traitements

(Quelques outils qui manipulent les Données ; Traitement des Données ; Quelques mots clés sur la Donnée ... DATA)

Catégories et **Type** de données ; Historique ; Nouveaux besoins, **SQL Avancé (Create, …, Select…, Merge…)**

Conception & Modélisation des Bases et des Entrepôts de Données

Méta-Modélisation, Formalismes utilisés (ER, **EER, UML**, …)

Expression & Cohérence des **contraintes** (**$SQL_{2/3/...n}$**, **PL/SQL**, OCL, **NoSQL**…)

Intégration de données ; différents types de **schémas**

Implantation (Implémentation) des Données

Relationnel-étendu, Orienté Objet (de **UML à $SQL_{2/3/,...n}$**, JDBC, Java, **PL/SQL** J…)

Optimisation de Requêtes, Evaluation de Requêtes

Architecture de SGBD, **Administration** de BD

Qualité, Intégrité, Sécurité, Confidentialité, Anonymisation des données

Autres (BigData, Bases de Données, Entrepôts de données, Lacs de données, Master Data, Données structurées, Données NON structurées XML)

Gros volumes de données / **Entrepôts de données / Données Multi-Dimensionnelles / Référentiel de données**

Données Homogènes & **Hétérogènes**,

Données distribuées, Données Réparties, Données du Web, Données de type documents (**NON structurées**), …

Lac de Données, Big Data, **Masses** de données, **Open Data**

Outils : Power AMC, Oracle, Talend, Business Objects, Tableau, Excel, MongoDB, MySQL, Hadoop/Spark…

Aujourd'hui, j'arrête de fumer !

Le TABAC t'ABAT !

FUMER NUIT GRAVEMENT À TA SANTÉ ET À CELLE DE TON ENTOURAGE !

M T Dents !

SMILE and the World SMILES with you !







Manger

Manger

Grossir





Le **sport**

est **générateur**

de **confiance**







UNIVERSITÉ SORBONNE PARIS NORD

Donnée = Data !



Plusieurs nouveaux métiers en informatique



Data Administrator,

Data Engineer, Data Manager,

Spécialiste Business Intelligence

Data Scientists…

Machine Learning Engineer…

DATALOGUE… en informatique !

(Cardiologue, Radiologue, Pneumologue, Psychologue… en médecine…)



~~***Data Dealer !!!???***~~

Dr. M. Faouzi BOUFARES
faouzi.boufares@sorbonne-paris-nord.fr
boufares@lipn.univ-paris13.fr
http://www.lipn.univ-paris13.fr/~boufares/
Laboratoire d'Informatique de Paris Nord (**LIPN**)
La Maison des Sciences Numériques (**MSN**)
Université Sorbonne Paris Nord – France (**USPN**)

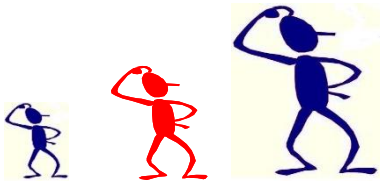
UNIVERSITÉ SORBONNE PARIS NORD

1. La DATA [la (les) Donnée(s)]… !!!

Introduction sur les données, leurs collectes et leurs traitements

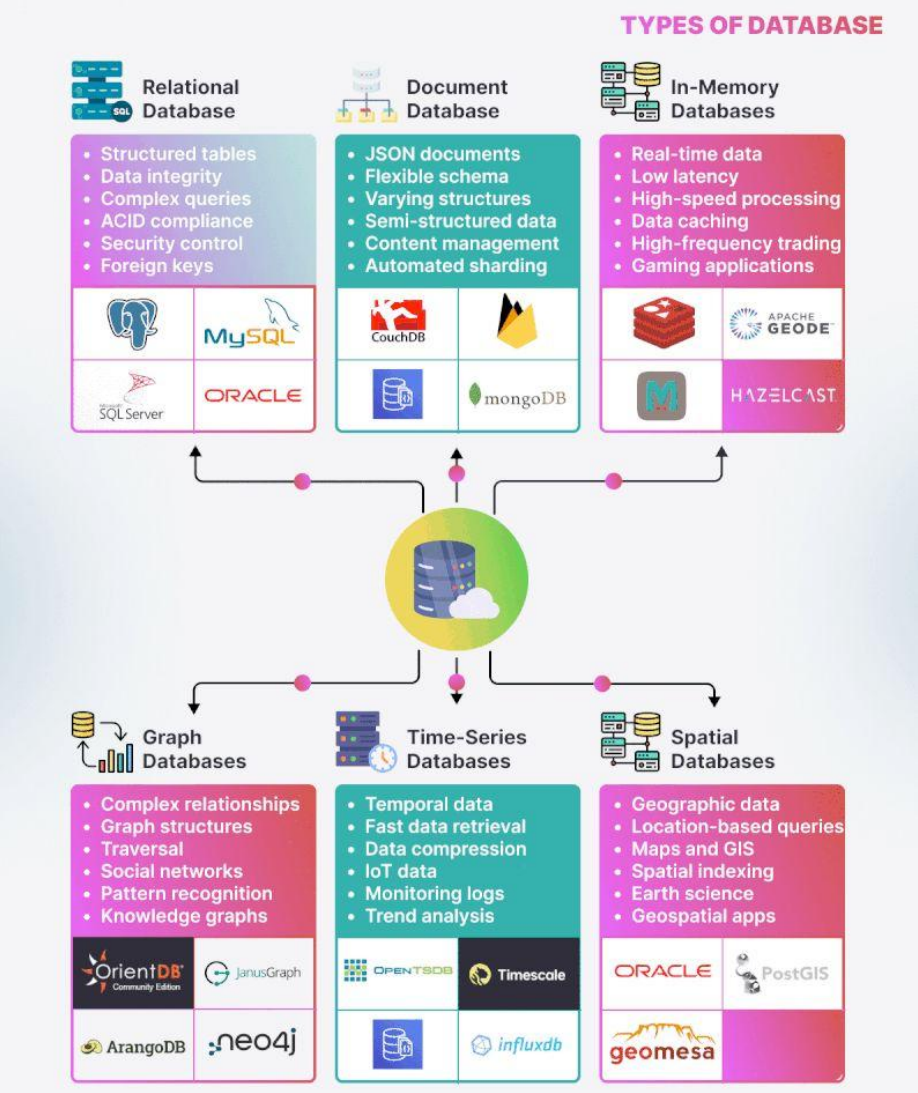
Think Bigger, Differently & Smarter by using correct

DATA





… Quelques outils qui manipulent les Données …
… Traitement des Données …



... Quelques outils qui manipulent les Données ...
... Traitement des Données ...

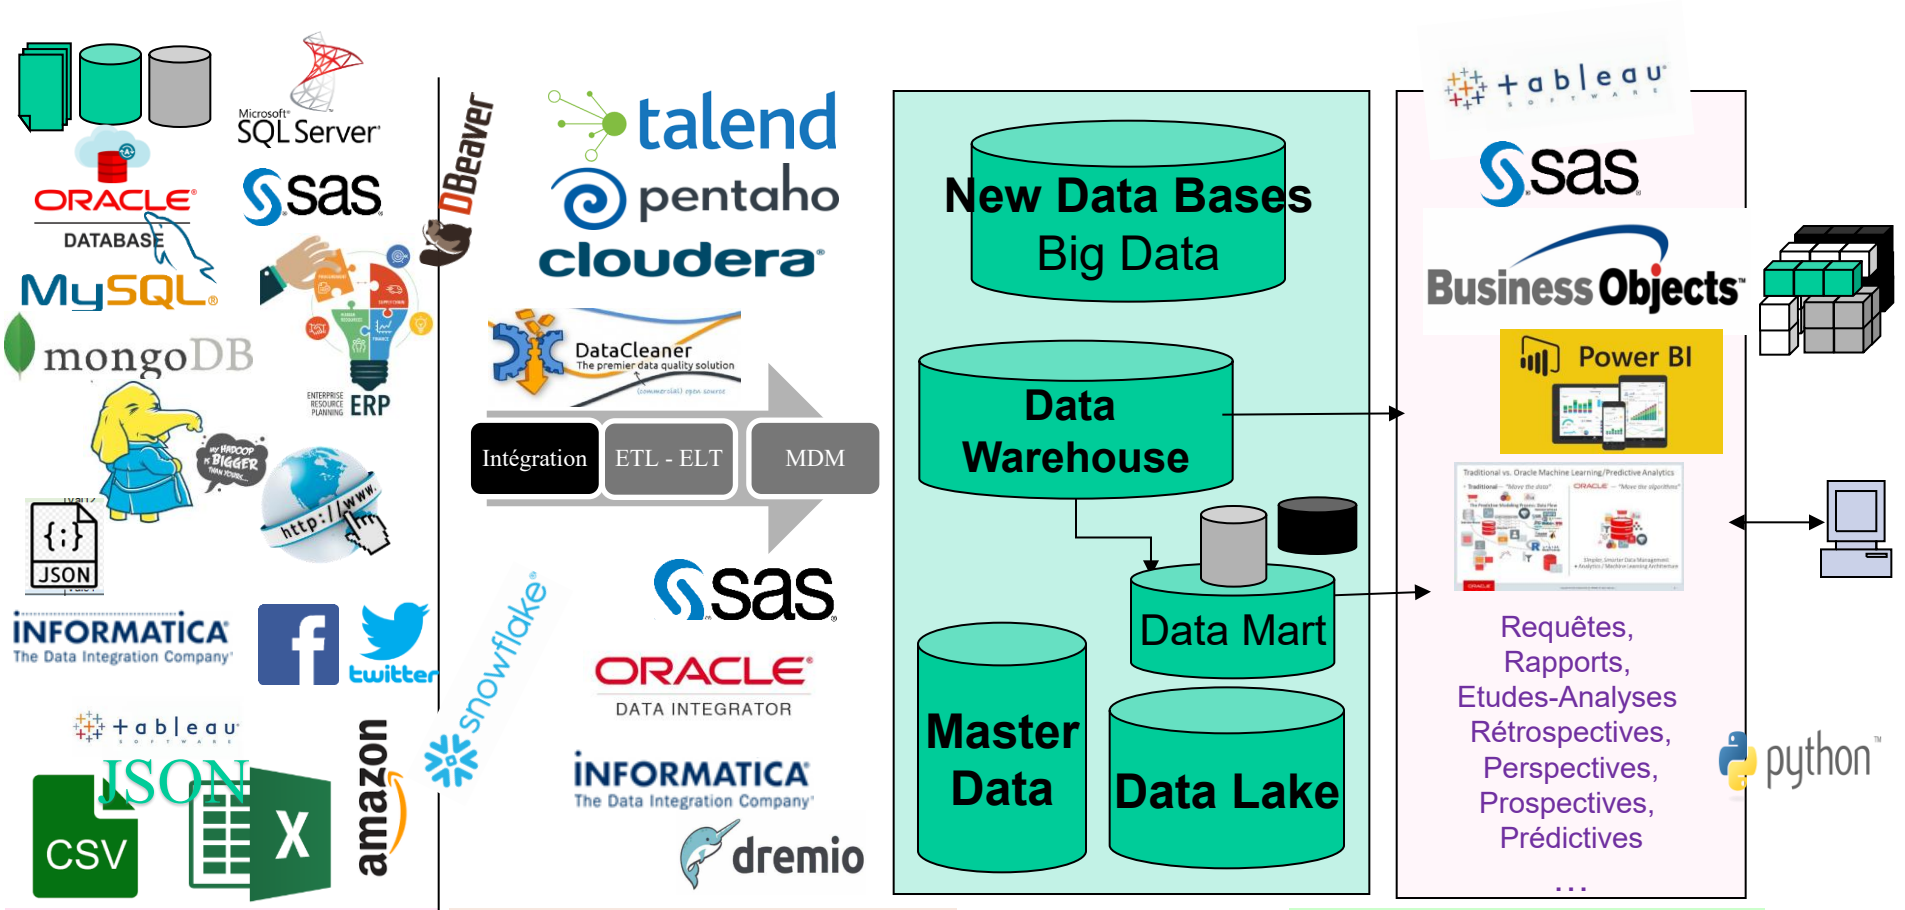


... Quelques outils qui manipulent les Données ...
... Traitement des Données ...



… Quelques outils qui manipulent les Données …

Traitement, Intégration & Exploitation des données ; Certains outils du marché



Outils de Gestion des Sources de données Hétérogènes

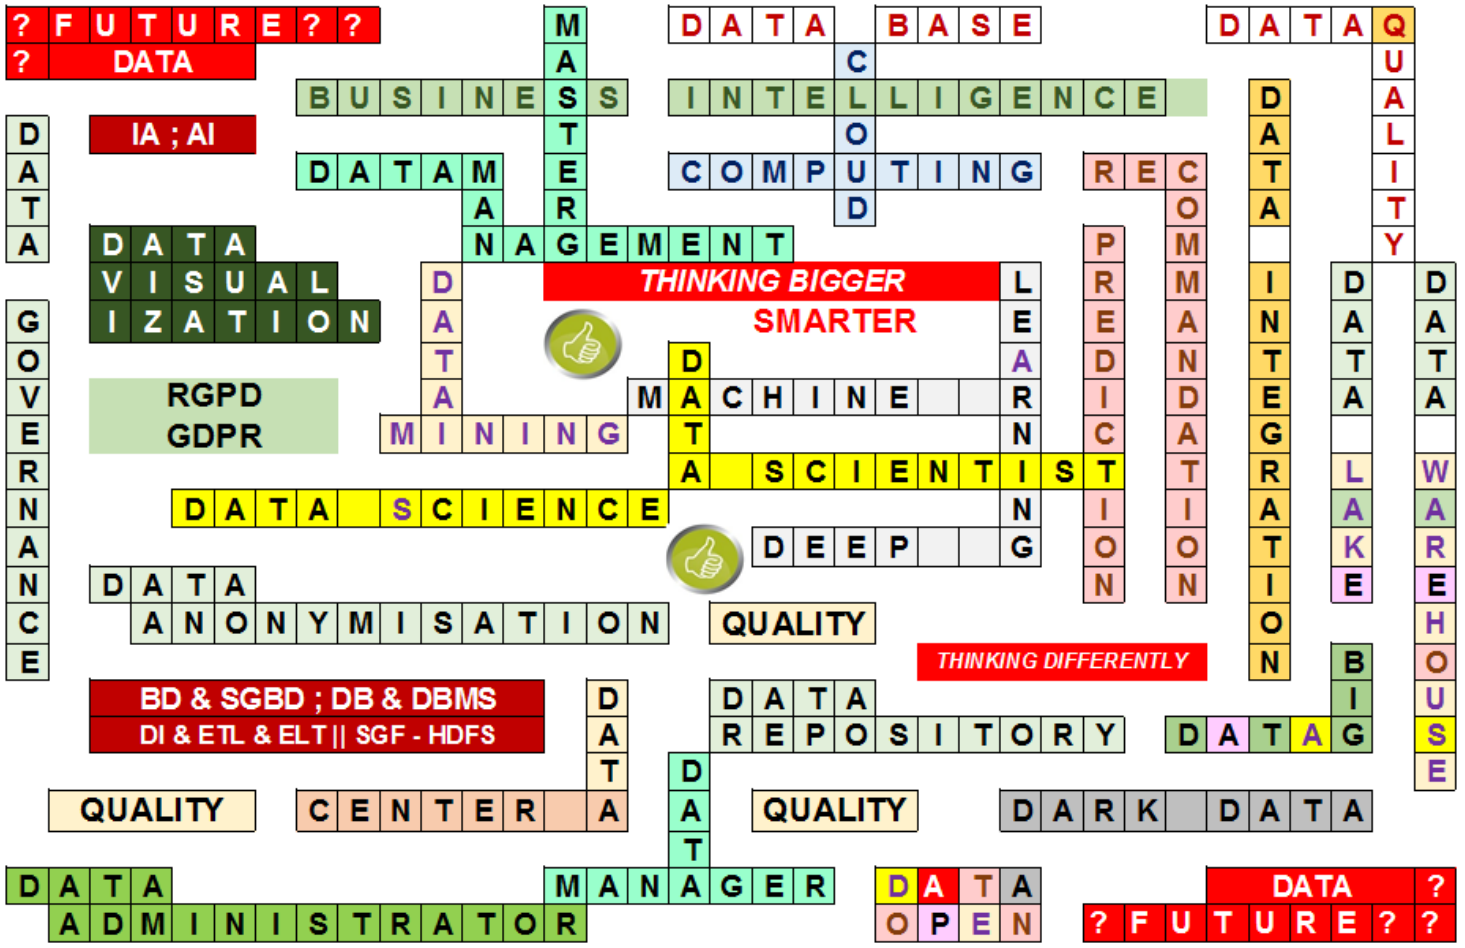
Outils d'intégration des données Hétérogènes et de gestion de la qualité

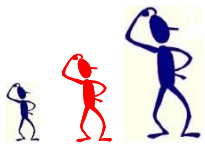
Outils de traitement-exploitation des données intégrées

… Quelques mots clés sur la Donnée … DATA

DB
DWH
DL
BI
CC
BD
MDM
DD
DM
ML
PR
OD
DC
DS







Think Bigger, Differently & Smarter by using correct DATA

… Quelques mots clés sur la Donnée … DATA



Data Science…
Data Scientist…

Expertise dans un domaine :
Un métier →
Médecine, Biologie, Géologie,
Finance, Marketing,
Ressources Humaines, Sport…

Expertise numérique en :
Analyses de données,
Statistiques, Probabilités,
Mathématiques…

La
DATA
(la Donnée)
e(s)t le monde de demain…
!!!



Think Bigger, Differently & Smarter by using
DATA



Grande Expertise en Données (Gestion, Administration Exploration, Ingénierie)

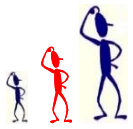
Data Engineering,
Data & Knowledge Engineering,
Data Bases,
Data Integration,
Data Quality, Data profiling
Data WareHouses, Data Marts, Data Lakes,
Master Data, Golden Record,
Distributed Data, Heterogeneous Data,
Structured, Semi-Structured & UnStructured Data,
Big Data,
Cloud Computing, Web Services,
Data Center, Data Governance,
Open Data, Data Repository
Dark Data, Data Anonymisation, RGPD
Business Intelligence,
Data Visualization,
Data Mining, Machine Learning, Deep Lear
Prediction, Recommandation…
ETL, ELT, MDM, BI…

… Quelques mots clés sur la Donnée … DATA

Collecte de la donné Enrichissement de la données	**Base de Données**	Data Base
	Intégration de Données	**Data Integration**
	Qualité des Données	**Data Quality**
	Entrepôt de Données	Data WareHouse
	Lac de Données	Data Lake
	Masse de Données	Big Data
	Référentiel de Données	Master Data
	Données dormantes, Données ouvertes	Dark Data, Open Data
	Centre d'accueil des données	Data Center
	General Data Protection Regulation (GDPR)	
Traitement de la donnée	**Informatique décisionnelle**	**Business Intelligence**
	Fouille de Données	Data Mining
	Prédiction/Anticipation/Recommandation	Prediction/Recommandation
	Intelligence Artificielle, Apprentissage profond	**Machine Learning, Deep Learning**
	Apprentissage Automatique	Machine Learning
	Règlement Général sur la Protection des Données (RGPD)	
Nouveaux Métiers	Corriger, Enrichir et Visaliser les données	Correct, Enrich and Visualize data
	Calculer sans limite	Cloud Computing
	La science des données	Data Science
	Ingénieur des données	**Data Scientist**

Ingénierie des données
Data engineering

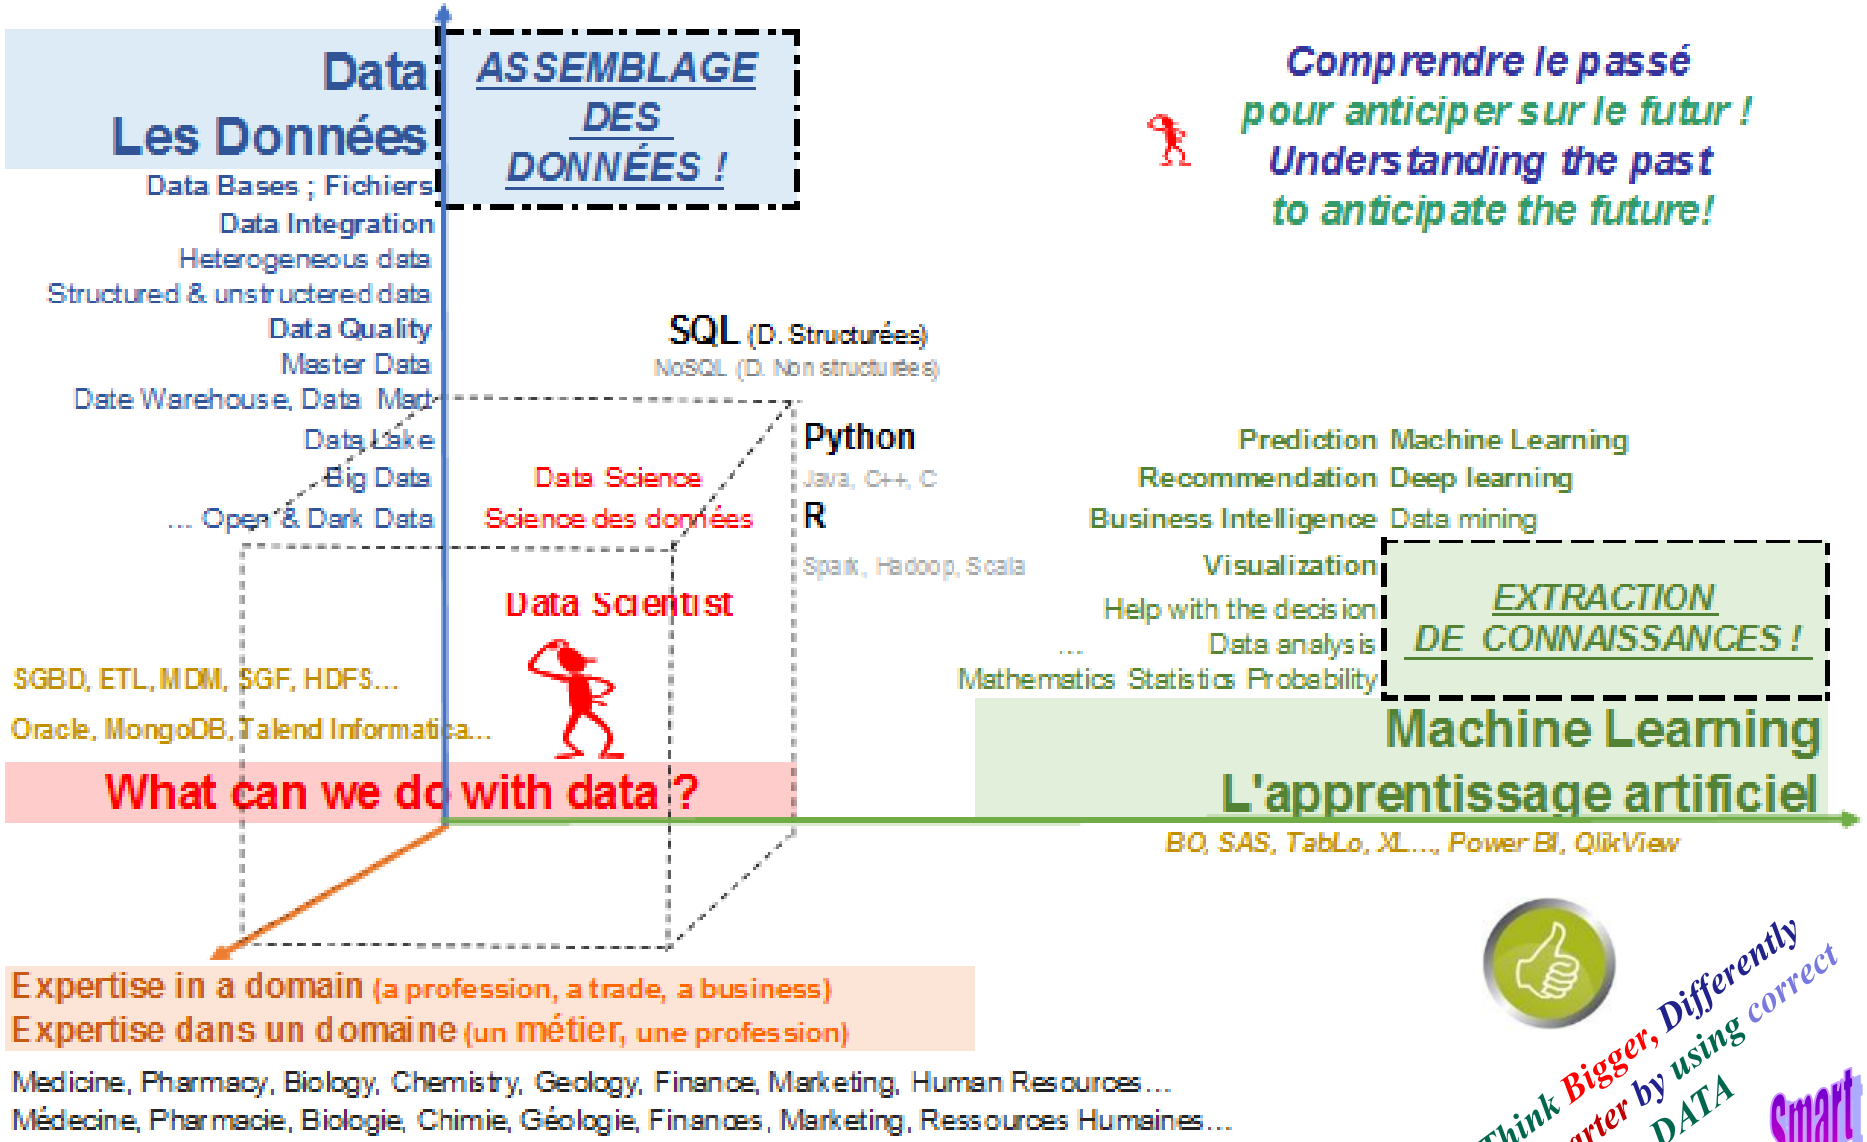
Ingénierie des connaissances
Knowledge Engineering







...Quelques mots clés sur la Science des Données ... DATA SCIENCE



Think Bigger, Differently & Smarter by using correct DATA

Smart

… Les Données & leurs traitements …



… ???

Les données et leurs traitements intelligents constituent un nouvel outil d'aide à la décision dans quasiment tous les domaines et tous les secteurs d'activité !

Comment exploiter-explorer automatiquement les données afin d'expliquer des phénomènes ?

Comment apprendre automatiquement à partir des données et des observations ?

Comment … ? Prédire, Prévoir, Prévenir, Calculer un Risque, Diagnostiquer, Recommander…

Une nouvelle science ; De nouveaux métiers



Think Bigger,
Differently & Smarter
by using correct DATA



Think Bigger, Differently & Smarter by using correct DATA



Une nouvelle science ; De nouveaux métiers

A l'ère du **déluge des données, la qualité des données est plus que jamais à l'ordre du jour :**
(données de productions ; données du Web ; données ouvertes -*Open Data*- ; données dormantes non encore utilisées -*Dark Data*- beaucoup de données textuelles non structurées documentaires ; les *Big Data* ; …).

En effet, de nos jours, tout type d'organisation a besoin **d'intégrer (collecter, assembler) des données** en provenance de **diverses sources distribuées, hétérogènes** et de **qualités variables**.

Le plus souvent, **les descriptifs des données**, dans les sources, sont **mal renseignés** voire **inexistants**.

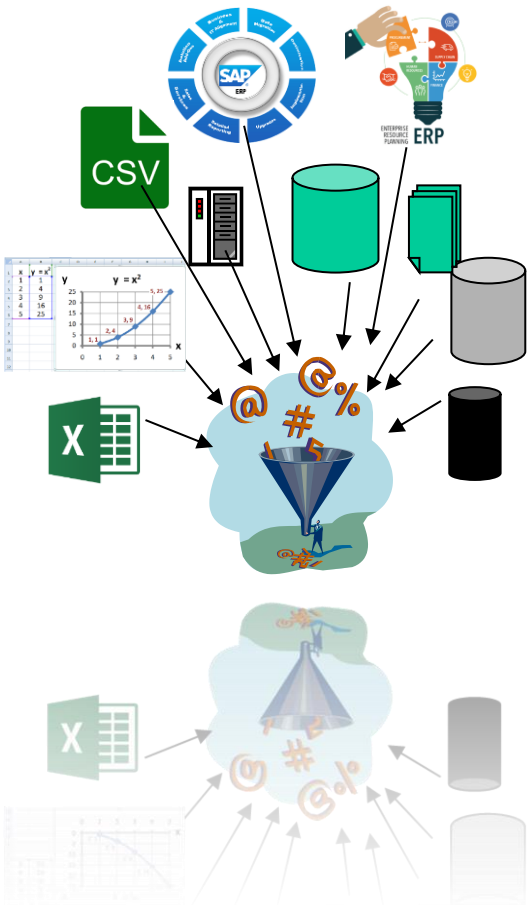
Par conséquent, **l'assemblage des données peut être dénué de tout sens et le résultat obtenu peut contenir de nombreuses anomalies**.

… Les Données & leurs traitements …

Think Bigger, Differently & Smarter by using correct DATA

Une nouvelle science ; De nouveaux métiers

- Données internes (Opérationnelles de production)
  - Bases de données (Structurées et Non structurées)
  - Fichiers (Plats, Textes, CSV, PDF…)
  - Applications (Paye, Gestion des RH, Commandes & Facturations…)
- Données externes (Web, Open Data, Dark Data, …)
- Caractéristiques de ces données
  - Distribuées
  - Hétérogènes (systèmes et structures de données différents)
  - Détaillées (peu ou pas adaptées à l'analyse)
  - Qualité très variable (plutôt mauvaise, plusieurs anomalies)



…Des questions sur La Data, Les Données ?…



Think Bigger, Differently & Smarter by using correct DATA

Qu'est-ce une donnée ?

Comment la collecter ?

(Comment l'avoir, à quelle fréquence/vitesse ? Quel est son type ? Est-elle pertinente ? Est-elle Obsolète ?...)

Quelle est sa qualité ? (Des données de bonne qualité engendrent des décisions de qualité)

Comment va-t-on la gérer automatiquement ? Comment va-t-on la stocker et où la stocker ?

Quel droit (Qui fait quoi et Quand ?, Quelles sont les conséquences ?) ; Sécurité, Confidentialité, Anonymisation, Piratage (RGPD) !

Qu'est-ce que l'on va en faire ? Quel est (serait) le retour sur investissement (ROI) ?

Comment la traiter (Comment **l'exploiter** ?, Comment la **transformer** ?)

Comment apprendre à partir des données ? → De la donnée au Savoir, à l'information, à la connaissance, à la décision ?

Peut-on faire confiance aux données brutes ?

Etant donné une Source de Données CSV, JSON, Contient-elle des **anomalies**, Comment évaluer **sa qualité**, sa valeur, son **score** ? (Given a CSV or JSON Data Source, does it contain anomalies, how to evaluate its quality, its value, its score?







[DATA & QUALI-SCORE ?]

A CSV File , A Table, A Data Source, A Data Base

```
LIONEL;M;A+;Barcelona;SPAIN;1;messi@gmail.com
AD@MA;M;A+;barcelona;SPAIN;1;ad@ma@gmail.com
EVE;F;B+;Paris;FRANCE;2;eve@gmail.com
ISABELLE;f;O-;Paris;France ;4;bon@hotmail.com
James;M;;Londre;;3;blonde@hotmail.com
CHARLIE;;AB+;London;UNITED KINGDOM;;chaple1@hotmail.com
KILIAN    ;M;A++;Paris;---;3;m'ba-p@gmail.com
Karim;M;A;Madrid;SPAIN;4;lebonfoot@yahoo.fr
ADAM;M;a+;paris;ITALY;1OOO;adam@yahoo
LEE;m;x;Seoul;SOUTH KOREA;3;moon@gmail.com
ZHANG;F;B+;Pékin;CHINE ;2;ziyiyizi@gmail.com
GONG;F;O+;Beijing;CHINA;3;li-li@gmail.com
AAA;;a+;Beijing;CHINA;;messi@gmail.com
CHARLO;M;AB+;London;UK;3;chaplin@hotmail.com

NomStar;S;GS;Vil;Pays;CA;Mel
```

The original data source that can contain anoamlies (dirty data)

Liste des STARS de Cinéma & de Football

List of Movie & Football STARS

… ???

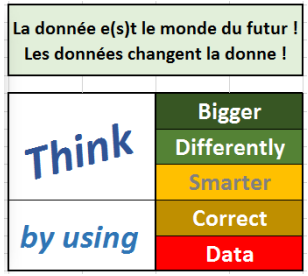
Les données CORRECTES (SANS ANOMLIE) et leurs traitements intelligents constituent un nouvel outil d'aide à la décision dans quasiment tous les domaines et tous les secteurs d'activité !

Comment exploiter-explorer au mieux les données afin d'expliquer des phénomènes ?

Comment apprendre automatiquement (Intelligence Artificielle) à partir des données et des observations ?

Comment Prédire, Prévoir, Prévenir, Calculer un Risque, Diagnostiquer, Recommander … ?





Peut-on faire confiance aux données brutes ?

Etant donné une Source de Données CSV, Contient-elle des **anomalies**, Comment évaluer **sa qualité**, sa valeur, son **score** ?
Given a CSV Data Source, does it contain anomalies, how to evaluate its quality, its value, its score?

Données CSV éclatées en colonnes… à la découvertes des anomalies (erreurs?) !

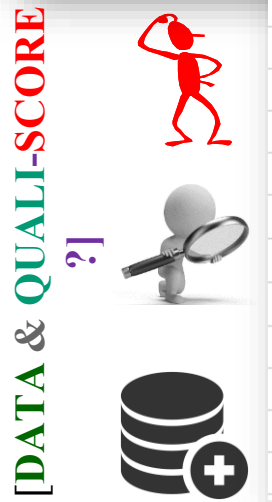
A CSV File , A Table, A Data Source, A Data Base

LIONEL	M	A+	Barcelona	SPAIN	1	messi@gmail.com
AD@MA	M	A+	barcelona	SPAIN	1	ad@ma@gmail.com
EVE	F	B+	Paris	FRANCE	2	eve@gmail.com
ISABELLE	f	O-	Paris	France	4	bon@hotmail.com
James	M		Londre		3	blonde@hotmail.com
CHARLIE		AB+	London	UNITED KINGDOM		chaple1@hotmail.com
KILIAN	M	A++	Paris	---	3	m'ba-p@gmail.com
Karim	M	A	Madrid	SPAIN	4	lebonfoot@yahoo.fr
ADAM	M	a+	paris	ITALY	1OOO	adam@yahoo
LEE	m	x	Seoul	SOUTH KOREA	3	moon@gmail.com
ZHANG	F	B+	Pékin	CHINE	2	ziyiyizi@gmail.com
GONG	F	O+	Beijing	CHINA	3	li-li@gmail.com
AAA		a+	Beijing	CHINA		messi@gmail.com
CHARLO	M	AB+	London	UK	3	chaplin@hotmail.com

NomStar	S	GS	Vil	Pays	CA	Mel

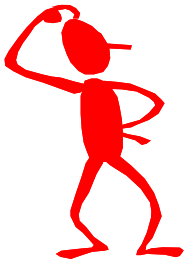
The original data source that can contain anoamlies (dirty data)

Liste des STARS de Cinéma & de Football
List of Movie & Football STARS

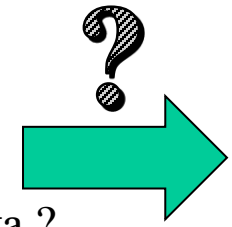


...Des questions sur La Data, Les Données ?...

Think Bigger, Differently & Smarter by using correct DATA

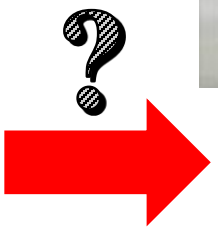


How to **detect, automatically,** the **abnormal** data ?





How to **correct, automatically,** these **anomalies without creating new ones**?



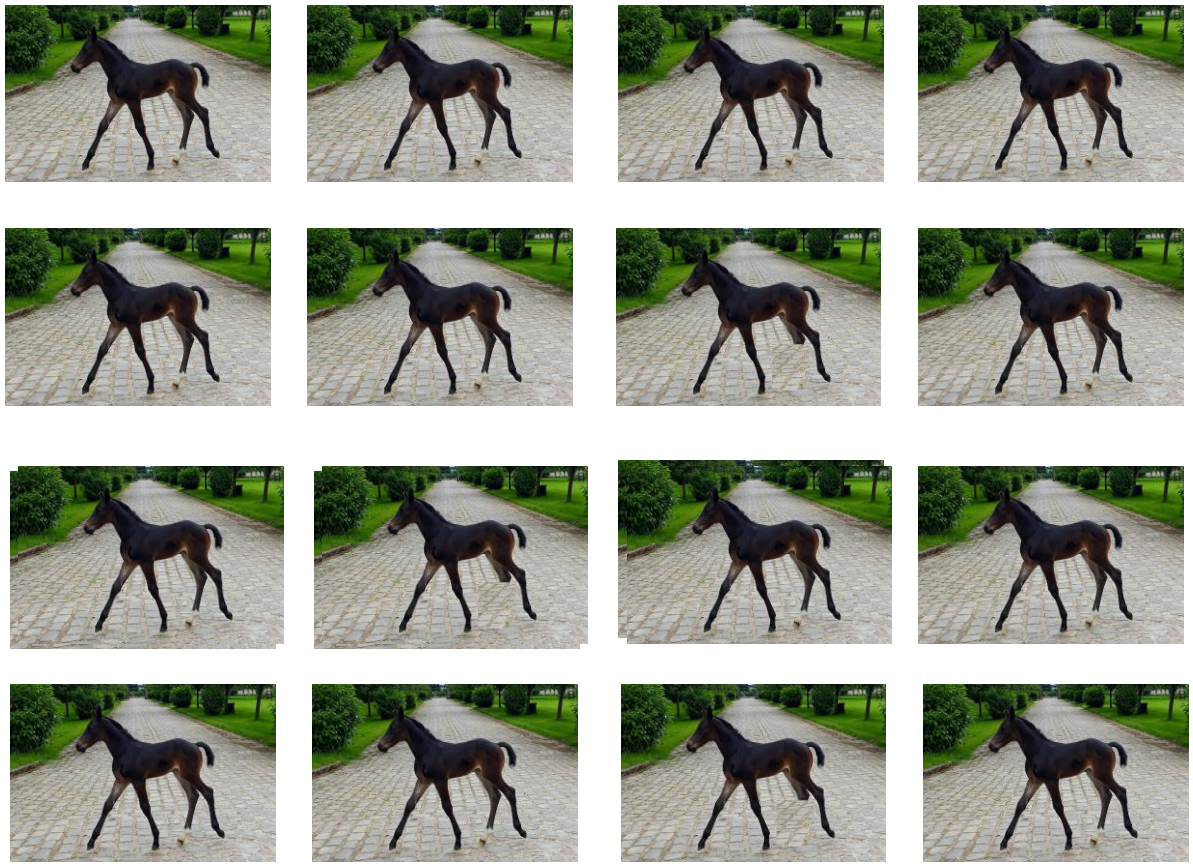
...Des questions sur La Data, Les Données ?...

Think Bigger, Differently & Smarter by using correct DATA

Anomalies détectées

Attention aux Mises à Jour

Anomalies corrigées



How to **detect, automatically,** the **abnormal** data ?

How to **correct, automatically,** these **anomalies without creating new ones**?



...Des questions sur La Data, Les Données ?...



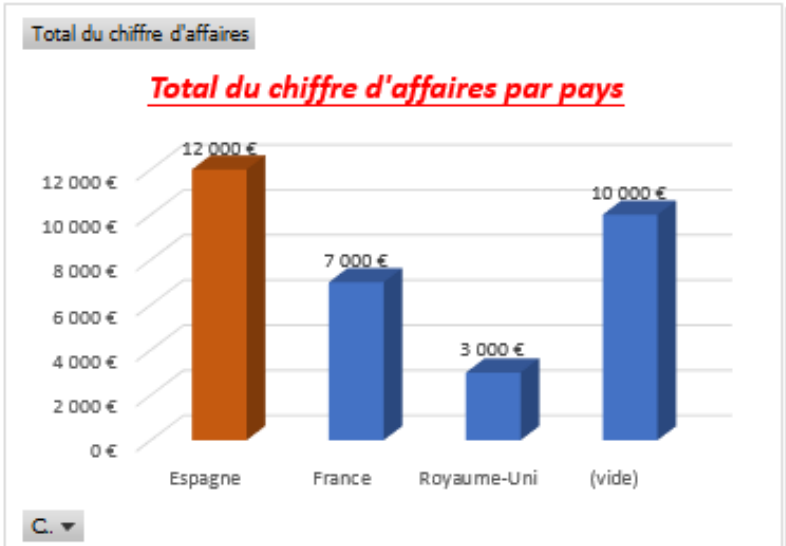
Think Bigger, Differently & Smarter by using correct DATA

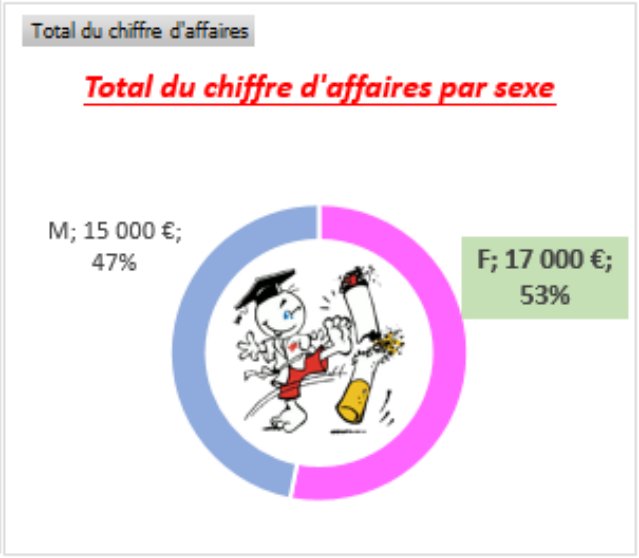
C1	C2	C3	C4	C5	C6	C7	C8	C9
Id1	M. Adam SERAFOUB	M	19-juin-2001	A+	Paris	France	2 000 €	adam.serafoub@gmail.com
Id2	Mme Inès BEN	F	22-novembre-1999	B+	Londres	Royaume-Uni	3 000 €	inès.ben@gmail.com
Id3	Mme Clémence RAHMA	F	16-octobre-1996	A+	Paris	France	2 000 €	clémence.rahma@gmail.com
Id4	M. Alex LEGRAND	M	17-septembre-1987	AB+	Paris	France	3 000 €	alex.legrand@gmail.com
Id5	M. Lilian M BA P	M	18-septembre-1987	AB+	Paris		10 000 €	lilian.m ba p@gmail.com
Id6	M. Lionel MAICI	F	25-décembre-1985	O+	Barcelone	Espagne	12 000 €	maicimainon@hotmail.com

Id	PrenomNOM	Genre	DateNaissance	GrpSanguin	VilleNaissance	PaysNaissance	CA	Email

Pays	Total du chiffre d'affaires
Espagne	12 000 €
France	7 000 €
Royaume-Uni	3 000 €
(vide)	10 000 €
Total général	**32 000 €**

Sexe	Total du chiffre d'affaires
F	17 000 €
M	15 000 €
Total général	**32 000 €**





...Des questions sur La Data, Les Données ?...



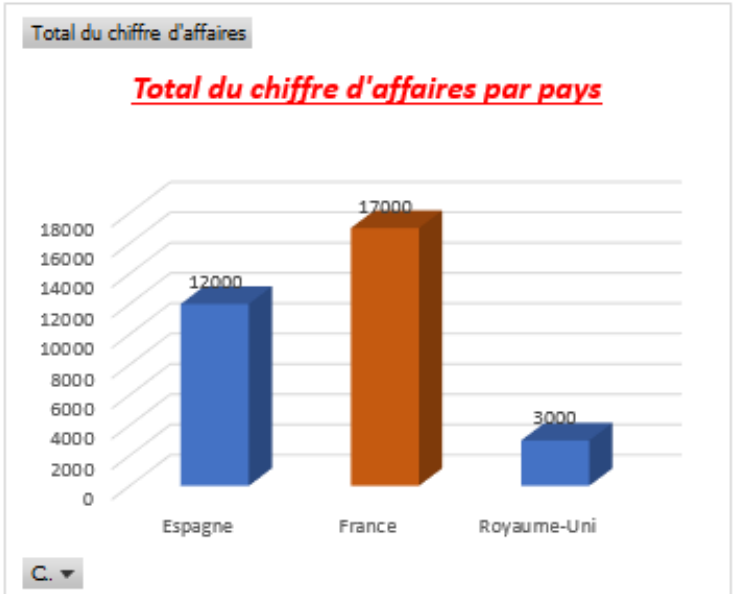
Think Bigger, Differently & Smarter by using correct DATA

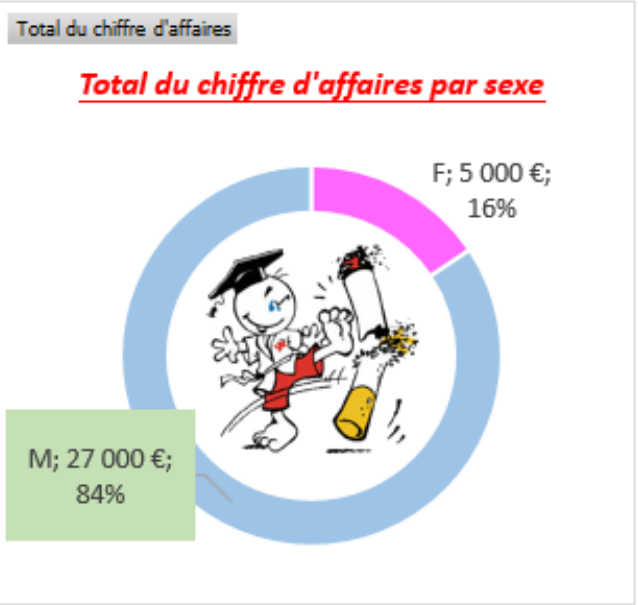
C1	C2	C3	C4	C5	C6	C7	C8	C9
Id1	M. Adam SERAFOUB	M	19-juin-2001	A+	Paris	France	2 000 €	adam.serafoub@gmail.com
Id2	Mme Inès BEN	F	22-novembre-1999	B+	Londres	Royaume-Uni	3 000 €	inès.ben@gmail.com
Id3	Mme Clémence RAHMA	F	16-octobre-1996	A+	Paris	France	2 000 €	clémence.rahma@gmail.com
Id4	M. Alex LEGRAND	M	17-septembre-1987	AB+	Paris	France	3 000 €	alex.legrand@gmail.com
Id5	M. Lilian M BA P	M	18-septembre-1987	AB+	Paris	France	10 000 €	lilian.m ba p@gmail.com
Id6	M. Lionel MAICI	M	25-décembre-1985	O+	Barcelone	Espagne	12 000 €	maicimainon@hotmail.com

Id	PrenomNOM	Genre	DateNaissance	GrpSanguin	VilleNaissance	PaysNaissance	CA	Email

Pays	Total du chiffre d'affaires
Espagne	12000
France	17000
Royaume-Uni	3000
Total général	**32000**

Sexe	Total du chiffre d'affaires
F	5 000 €
M	27 000 €
Total général	**32000**

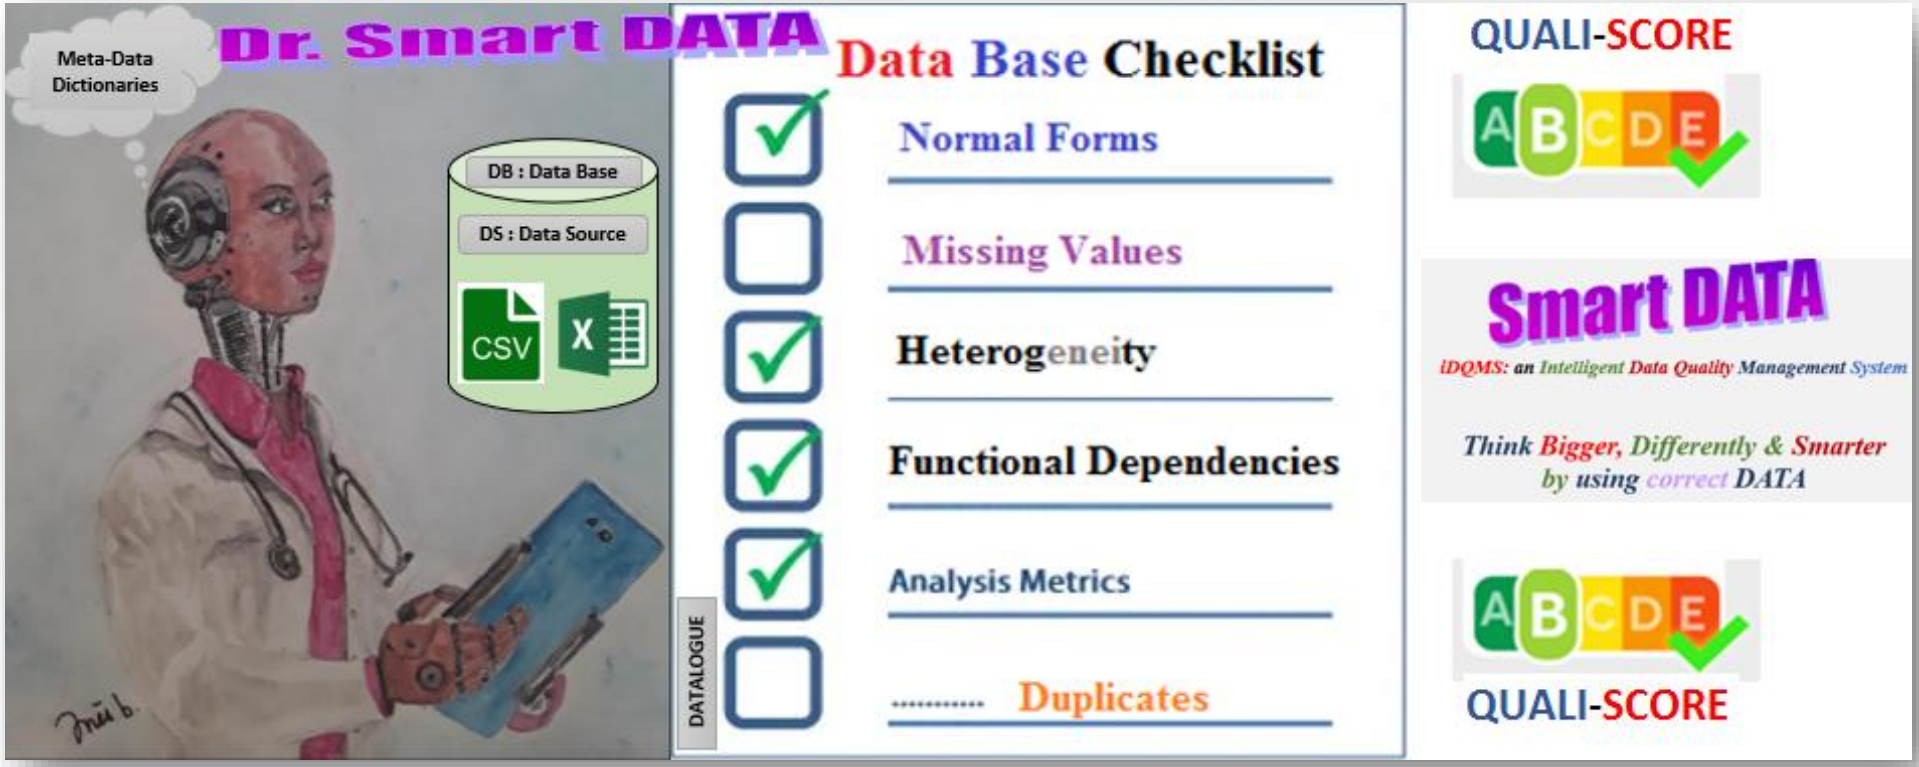




...Des questions sur Les Données, La Data?...



Think Bigger, Differently & Smarter by using correct DATA



Smart DATA

iDQMS : intelligent Data Quality Management System

...Des questions sur La Data, Les Données ?...



Data INTEGRATION TO *Think Bigger, Differently & Smarter*

Zone de préparation

Zone de stockage de données massives

Zone de présentation

Sources de données Hétérogènes

E X T R A C T

INTEGRER
ASSEMBLER
les données

Nettoyer
Standardiser
Normaliser
Homogénéiser
Dédoublonner
Enrichir
Commenter

T R A N S F O R M

L O A D

New Data Bases
Big Data

Data Warehouse

Data Mart

Master Data

Data Lake

Requêtes
Rapports
Visualisation
Data Mining
Recommandation
…

Etudes-Analyses
Rétrospectives,
Perspectives,
Prospectives,
Prédictives
…

python

Intégration | ETL - ELT | MDM

The better the quality of the data, the better it can be used for analyses

... Les nouveaux métiers de la Data ! ...

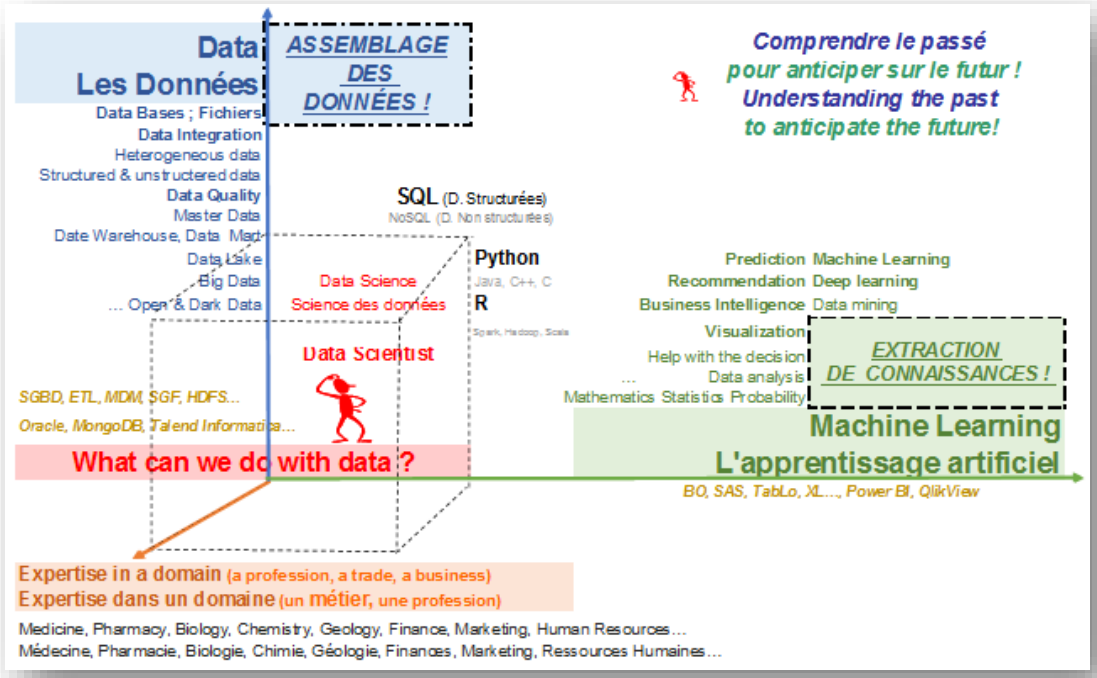
... Data Science & Data Scientist ...





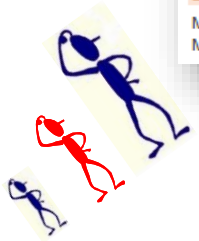


Des Données aux Décideurs ; L'ingénierie des données



Think Bigger, Differently & Smarter by using correct DATA





... Les Données et le Cloud ...



Les données sont Massives, Hétérogènes et Distribuées.



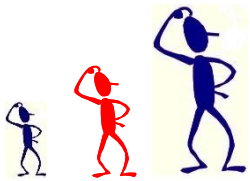


Big Data (BD) + Cloud Computing (CC)

=

Thinking Differently, Bigger and Smarter (TDBS)

BD + CC = TDBS

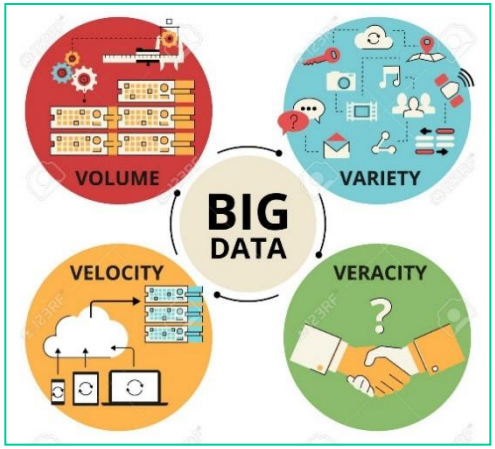


... Les Données ... Big Data – Les n V...

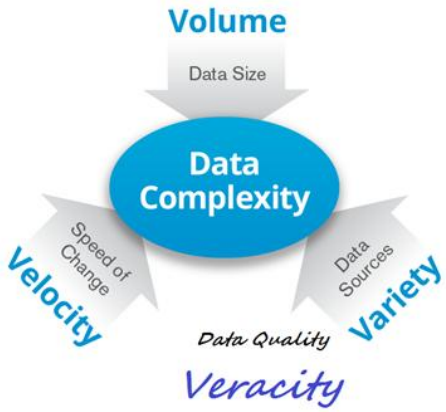


Les données sont Massives, Hétérogènes et Distribuées.

Les données peuvent être de Qualité très variable (plutôt mauvaise ; plusieurs anomalies).



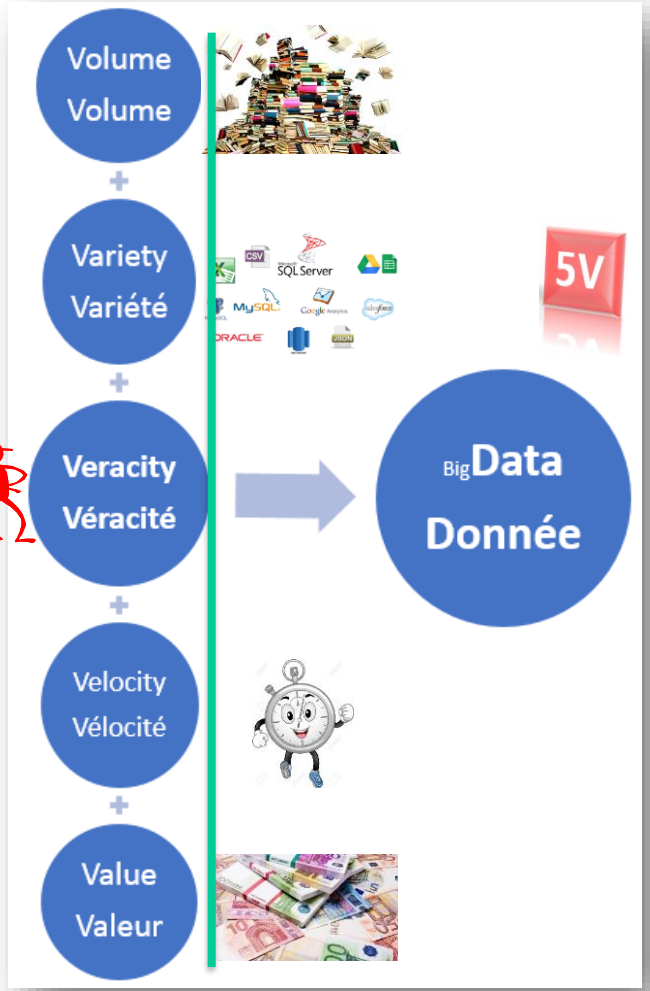


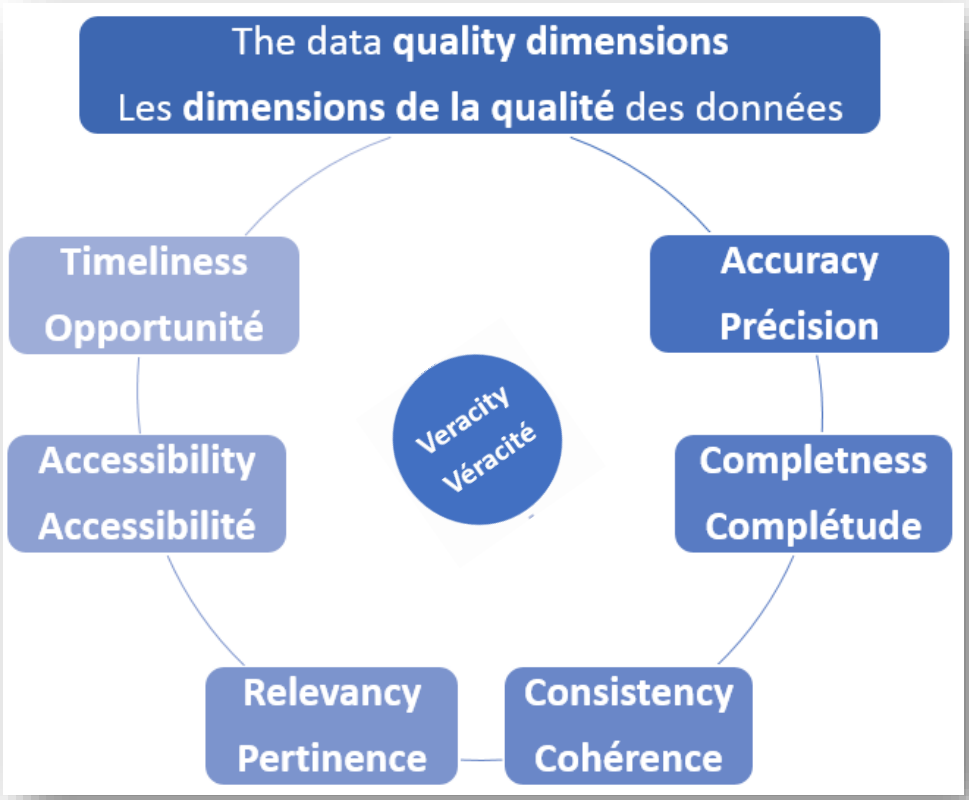


... Les n V... n=3, 4, 5 ou plus ?

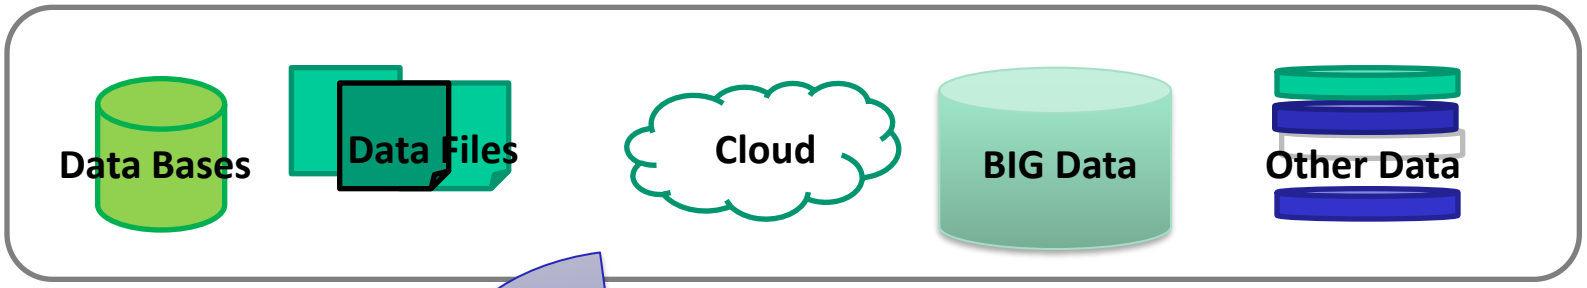
… Les Données … Big Data – Les n V…

La Donnée et sa Qualité





… Des Données … Aux décideurs !
Qualité des données et décisionnel !

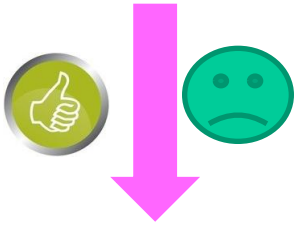


Données de qualité

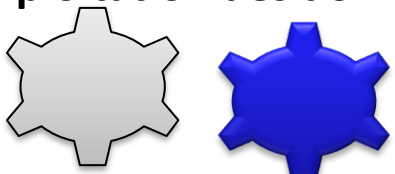
Donner un SENS aux données rassemblées

Intégration des données





Exploitation des données



Décisions de qualité !

Donnée :
Qualité,
Confidentialité,
Anonymisation,
Sécurité,
Piratage…!

Prise de Décision

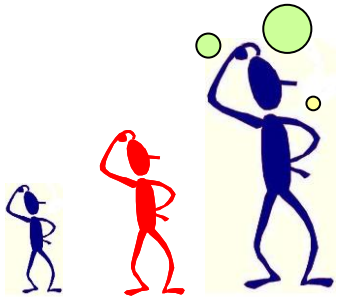


... Des Données ... Aux décideurs !

Rassembler des **Données** de **Qualité**

Donner un **sens** aux données rassemblées

Enrichir les données…



Explorer des Données Massives

Intelligence Artificielle, Apprentissage, Fouille



Prendre les Bonnes Décisions

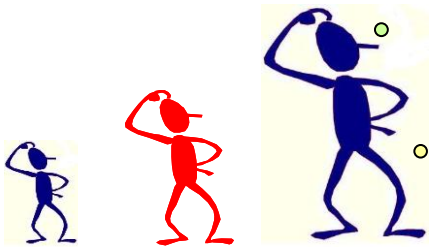
Data Scientist !

Think Bigger, Differently & Smarter
by using correct DATA

… Des Données … Aux décideurs !

Expert en Gestion des Données

(Data Base, Data WareHouse, Data Lake, Big Data…)



Expert en Analyse de Données et en Statistiques

Expert dans un domaine d'activité (Un métier : Médecine, Biologie, Finance, Tourisme, Sport & Football…)

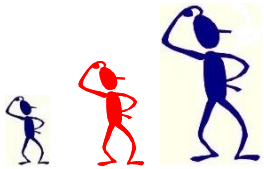


Data Scientist !

Think Bigger, Differently & Smarter by using correct DATA

... Des Données ... Aux décideurs !





Le rôle du Data Scientist !

BD (Bases de Données) + ED (Entrepôts de Données) + LD (Lac de Données) ; Référentiel de Données, Big-Data (Grosses Masses de Données)

Smart

Des Données

ML (Machine Learning) Apprentissage, **DL** (Deep Learning) ; FD (Fouille de données),

Extraction d'*Informations* et de *Connaissances*

Aider à la prise de décision,

Diagnostiquer, Comprendre des phénomènes, Classifier,

Etudier les risques, Améliorer la gestion,

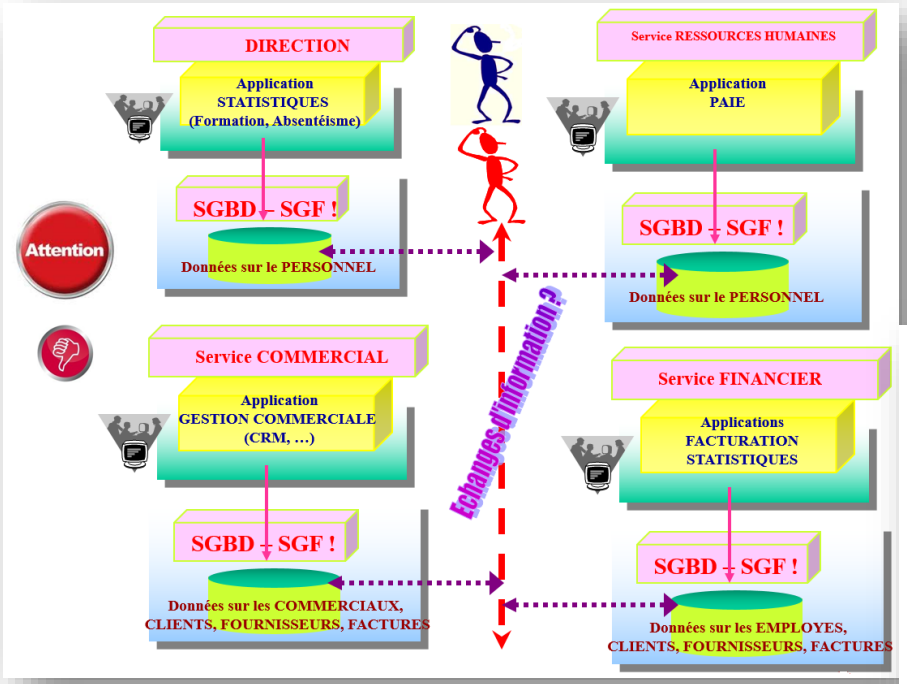
Prévenir, *Guider, Recommander ...*

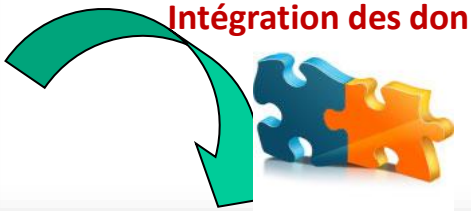
Aux Décideurs

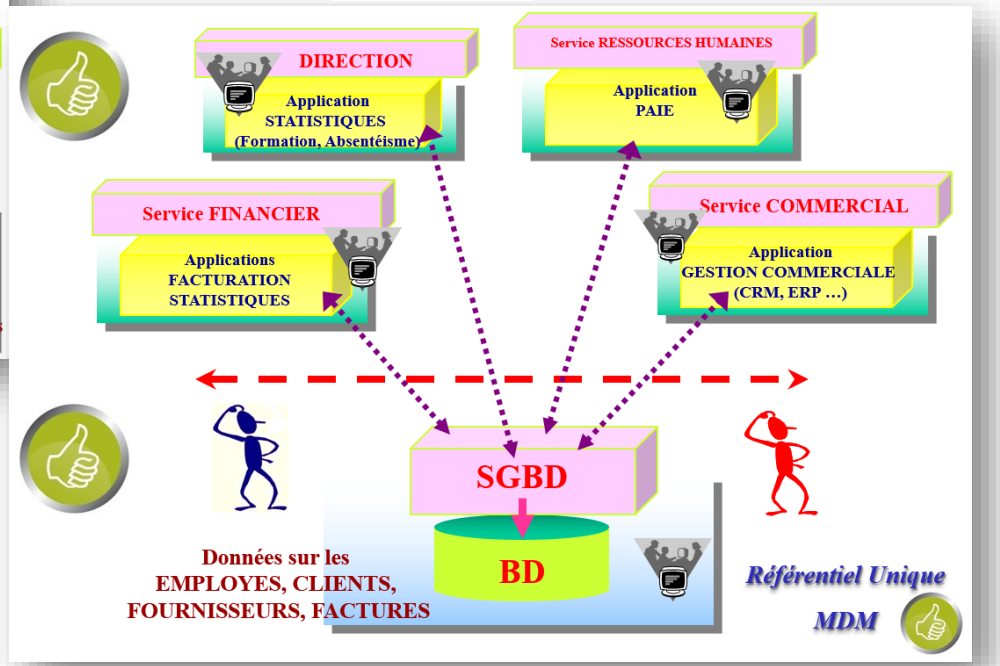


Rassembler-Intégrer les données …!

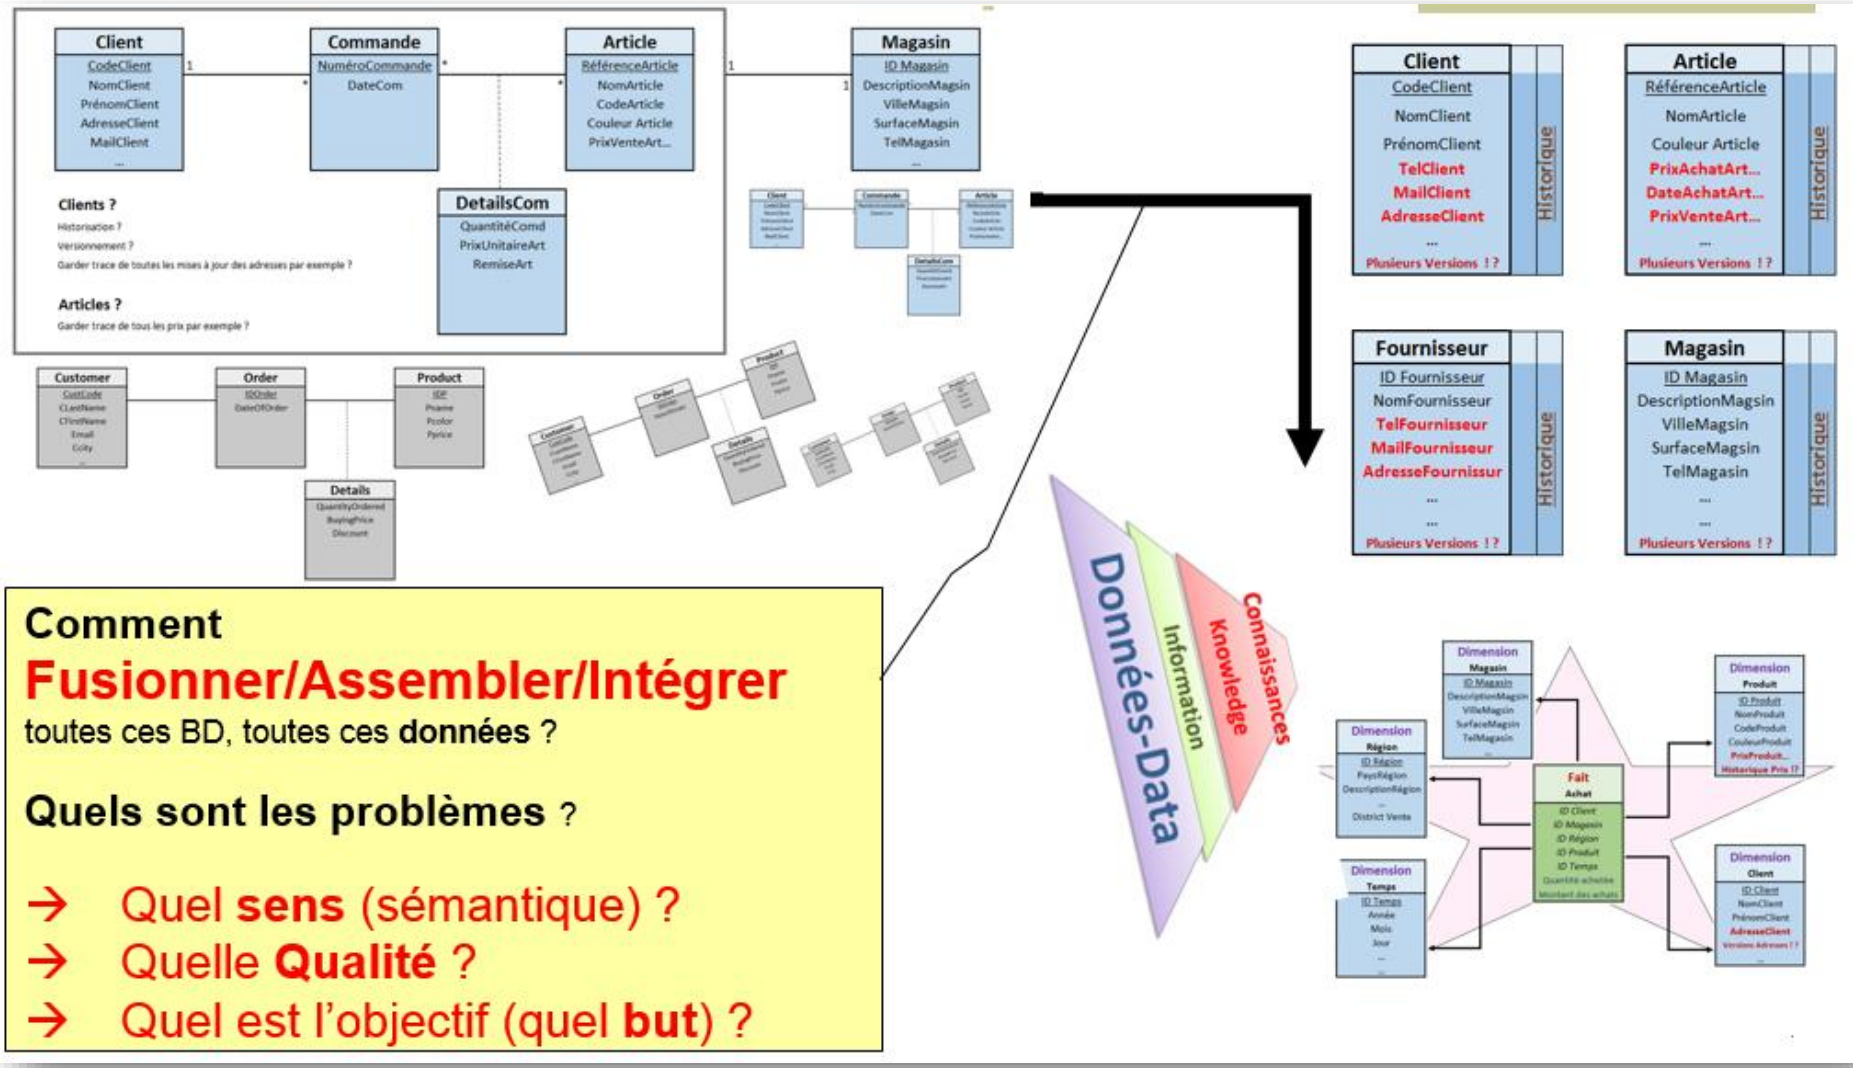
Au niveau organisationnel → Un seul référentiel des données (Master Data) !







… Intégration de Données …



Comment

Fusionner/Assembler/Intégrer

toutes ces BD, toutes ces **données** ?

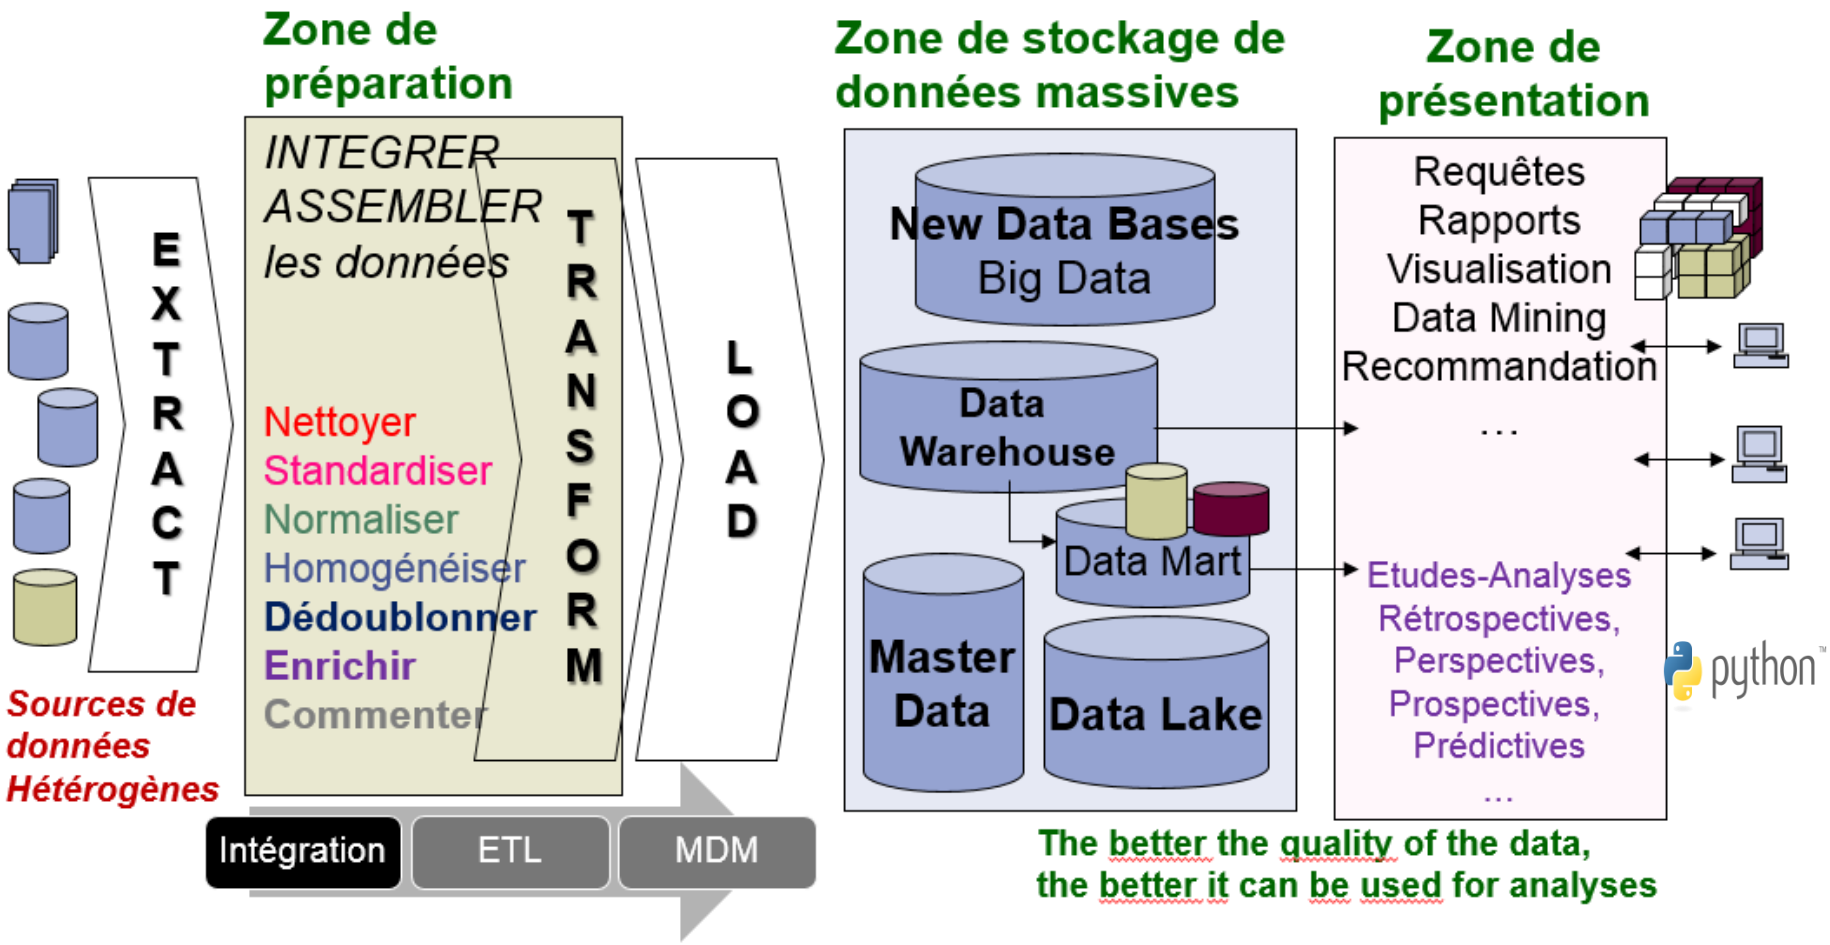
Quels sont les problèmes ?

→ Quel **sens** (sémantique) ?

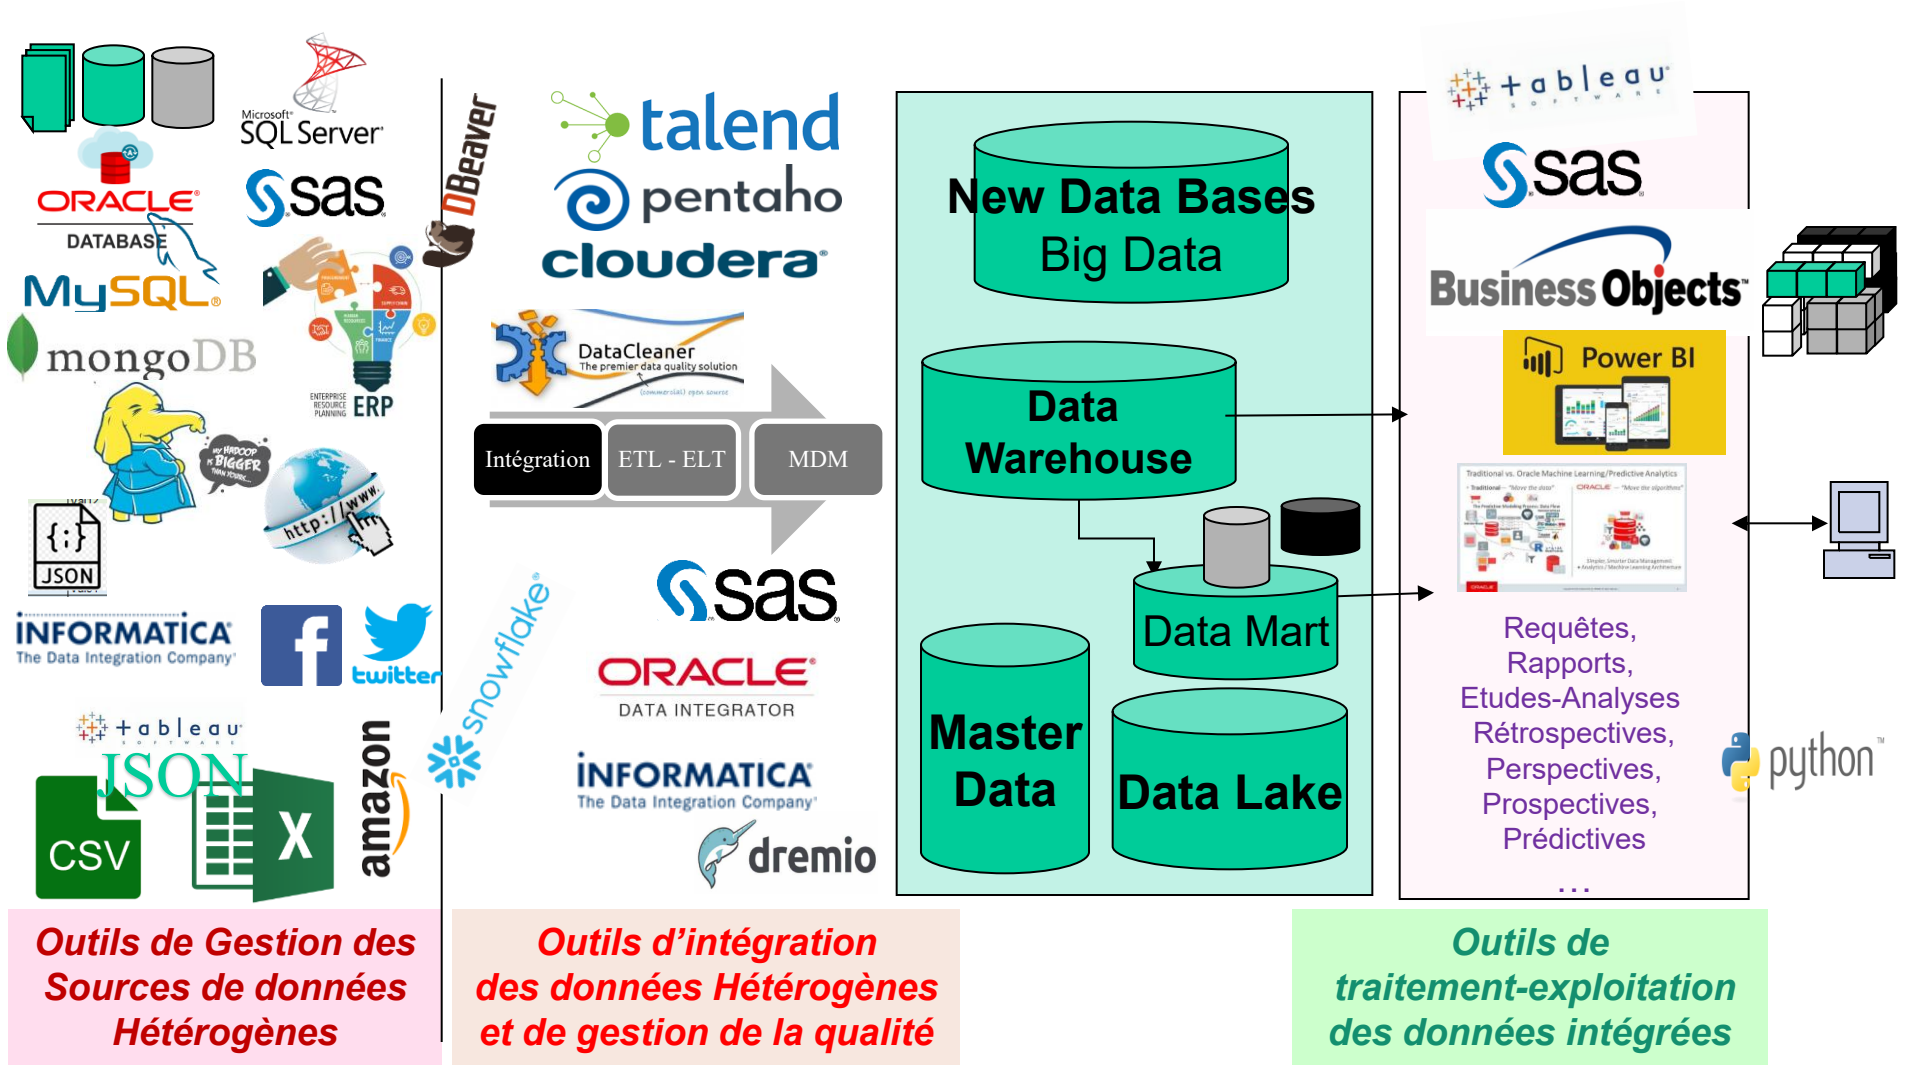
→ Quelle **Qualité** ?

→ Quel est l'objectif (quel **but**) ?

... Intégration de Données ...



… Intégration de Données …



Outils de Gestion des Sources de données Hétérogènes

Outils d'intégration des données Hétérogènes et de gestion de la qualité

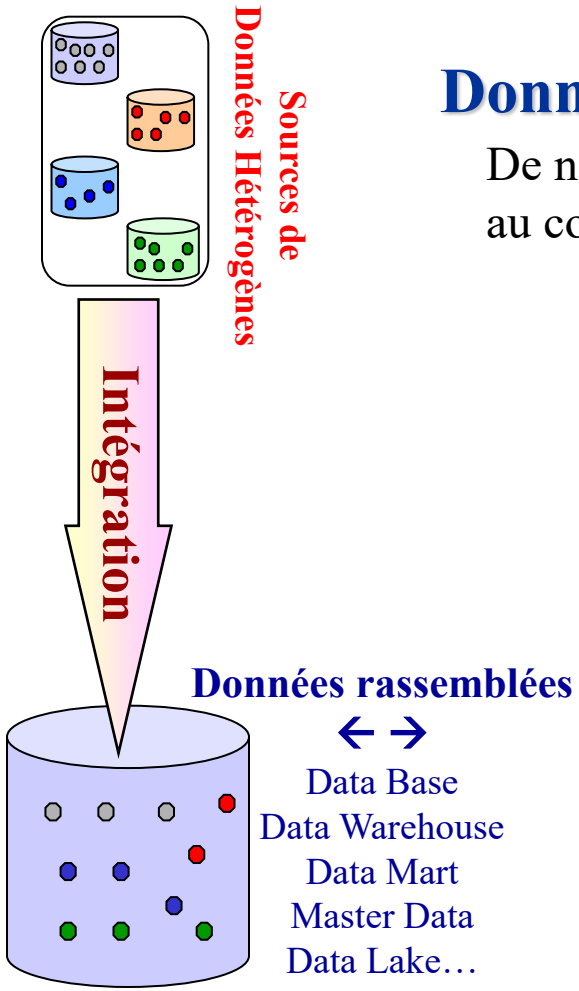
Outils de traitement-exploitation des données intégrées

… Intégration de Données …

Donner un SENS aux données rassemblées… Attention aux anomalies !

Conformes à la **sémantique supposée**	Cohérentes	Sans faute d'orthographe
Sans doublon ni similaire	Complètes	Fiables
Non nulles	Non aberrantes	À jour Non obsolètes

… Intégration de Données …



Donner un SENS aux données rassemblées

De nombreuses questions, **relatives à la qualité**, doivent être posées au cours du **processus d'intégration** :

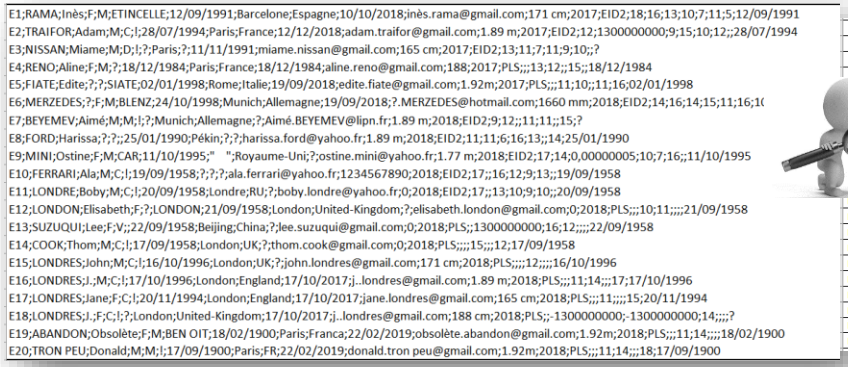
* **Compatibilité** des types de données (**syntaxique**)
* **Compatibilité sémantique**
* Les contraintes sur les données
* Transformer / Corriger / Nettoyer / Valider des données
* Enrichir / Compléter les données
* Gérer les dépendances sémantiques
* Gérer les Doubles & les Similaires
* Gérer les métadonnées

→ **Comment le savoir ?**

→ La **syntaxte** oui mais plus de **sémantique** !

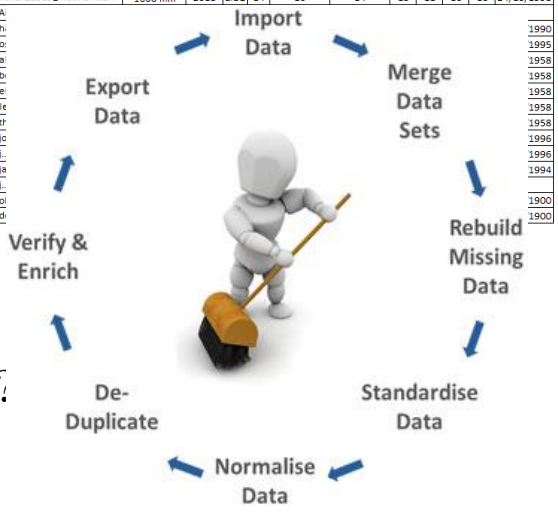
… Intégration de Données …

Données Hétérogènes ;
Niveaux de descriptions différents ; Peu ou pas du tout de description ;
Absence de sémantique ; Qualité variable… !



```
E1;RAMA;Inès;F;M;ETINCELLE;12/09/1991;Barcelone;Espagne;10/10/2018;inès.rama@gmail.com;171 cm;2017;EID2;18;16;13;10;7;11;5;12/09/1991
E2;TRAIFOR;Adam;M;C;!;28/07/1994;Paris;France;12/12/2018;adam.traifor@gmail.com;1.89 m;2017;EID2;12;1300000000;9;15;10;12;;28/07/1994
E3;NISSAN;Miame;M;D;!;?;Paris;?;11/11/1991;miame.nissan@gmail.com;165 cm;2017;EID2;13;11;7;11;9;10;;?
E4;RENO;Aline;F;M;?;18/12/1984;Paris;France;18/12/1984;aline.reno@gmail.com;188;2017;PLS;;;13;12;;15;;18/12/1984
E5;FIATE;Edite;?;?;SIATE;02/01/1998;Rome;Italie;19/09/2018;edite.fiate@gmail.com;1.92m;2017;PLS;;;11;10;;11;16;02/01/1998
E6;MERZEDES;?;F;M;BLENZ;24/10/1998;Munich;Allemagne;19/09/2018;?.MERZEDES@hotmail.com;1660 mm;2018;EID2;14;16;14;15;11;16;1(
E7;BEYEMEV;Aimé;M;M;!;?;Munich;Allemagne;?;Aimé.BEYEMEV@lipn.fr;1.89 m;2018;EID2;9;12;;11;11;;15;?
E8;FORD;Harissa;?;?;;25/01/1990;Pékin;?;?;harissa.ford@yahoo.fr;1.89 m;2018;EID2;11;11;6;16;13;;14;25/01/1990
E9;MINI;Ostine;F;M;CAR;11/10/1995;"  ";Royaume-Uni;?;ostine.mini@yahoo.fr;1.77 m;2018;EID2;17;14;0,00000005;10;7;16;;11/10/1995
E10;FERRARI;Ala;M;C;!;19/09/1958;?;?;?;ala.ferrari@yahoo.fr;1234567890;2018;EID2;17;;16;12;9;13;;19/09/1958
E11;LONDRE;Boby;M;C;!;20/09/1958;Londre;RU;?;boby.londre@yahoo.fr;0;2018;EID2;17;;13;10;9;10;;20/09/1958
E12;LONDON;Elisabeth;F;?;LONDON;21/09/1958;London;United-Kingdom;?;elisabeth.london@gmail.com;0;2018;PLS;;;10;11;;;;21/09/1958
E13;SUZUQUI;Lee;F;V;;22/09/1958;Beijing;China;?;lee.suzuqui@gmail.com;0;2018;PLS;;1300000000;16;12;;;;22/09/1958
E14;COOK;Thom;M;C;!;17/09/1958;London;UK;?;thom.cook@gmail.com;0;2018;PLS;;;;15;;;12;17/09/1958
E15;LONDRES;John;M;C;!;16/10/1996;London;UK;?;john.londres@gmail.com;171 cm;2018;PLS;;;;12;;;;16/10/1996
E16;LONDRES;J.;M;C;!;17/10/1996;London;England;17/10/2017;j..londres@gmail.com;1.89 m;2018;PLS;;;11;14;;;17;17/10/1996
E17;LONDRES;Jane;F;C;!;20/11/1994;London;England;17/10/2017;jane.londres@gmail.com;165 cm;2018;PLS;;;11;;;;15;20/11/1994
E18;LONDRES;J.;F;C;!;?;London;United-Kingdom;17/10/2017;j..londres@gmail.com;188 cm;2018;PLS;;-1300000000;-1300000000;14;;;;?
E19;ABANDON;Obsolète;F;M;BEN OIT;18/02/1900;Paris;Franca;22/02/2019;obsolète.abandon@gmail.com;1.92m;2018;PLS;;;11;14;;;;18/02/1900
E20;TRON PEU;Donald;M;M;!;17/09/1900;Paris;FR;22/02/2019;donald.tron peu@gmail.com;1.92m;2018;PLS;;;11;14;;;18;17/09/1900
```

IDE	NOM	PRENOM	GENRE	STATF	NJF	DN	VN	PN	DM	MEL	TAIL	PROMO	M2	BDA	DWH	JAVA	ENG	DL	RN	FT	DN2
E1	RAMA	Inès	F	M	ETINCELLE	12/09/1991	Barcelone	Espagne	10/10/2018	inès.rama@gmail.com	171 cm	2017	EID2	18	16	13	10	7	11	5	12/09/1991
E2	TRAIFOR	Adam	M	C	!	28/07/1994	Paris	France	12/12/2018	adam.traifor@gmail.com	1.89 m	2017	EID2	12	1,3E+09	9	15	10	12		28/07/1994
E3	NISSAN	Miame	M	D	!	?	Paris	?	11/11/1991	miame.nissan@gmail.com	165 cm	2017	EID2	13	11	7	11	9	10		?
		Aline	F	M	?	18/12/1984	Paris	France	18/12/1984	aline.reno@gmail.com	188	2017	PLS			13	12		15		18/12/1984
		Edite	?	?	SIATE	02/01/1998	Rome	Italie	19/09/2018	edite.fiate@gmail.com	1.92m	2017	PLS			11	10		11	16	02/01/1998
		?	F	M	BLENZ	24/10/1998	Munich	Allemagne	19/09/2018	?.MERZEDES@hotmail.com	1660 mm	2018	EID2	14	16	14	15	11	16	10	24/10/1998
		Aimé	M	M	!	?	Munich	Allemagne	?	A											
		Harissa	?	?		25/01/1990	Pékin	?	?	h											1990
		Ostine	F	M	CAR	11/10/1995	" "	Royaume-Uni	?	o											1995
		Ala	M	C	!	19/09/1958	?	?	?	a											1958
E11	LONDRE	Boby	M	C	!	20/09/1958	Londre	RU	?	b											1958
E12	LONDON	Elisabeth	F	?	LONDON	21/09/1958	London	United-Kingdom	?	e											1958
E13	SUZUQUI	Lee	F	V		22/09/1958	Beijing	China	?	le											1958
E14	COOK	Thom	M	C	!	17/09/1958	London	UK	?	th											1996
E15	LONDRES	John	M	C	!	16/10/1996	London	UK	?	jo											1996
E16	LONDRES	J.	M	C	!	17/10/1996	London	England	17/10/2017	j.											1994
E17	LONDRES	Jane	F	C	!	20/11/1994	London	England	17/10/2017	ja											
E18	LONDRES	J.	F	C	!	?	London	United-Kingdom	17/10/2017	j.											
E19	ABANDON	Obsolète	F	M	BEN OIT	18/02/1900	Paris	Franca	22/02/2019	ob											1900
E20	TRON PEU	Donald	M	M	!	17/09/1900	Paris	FR	22/02/2019	do											1900



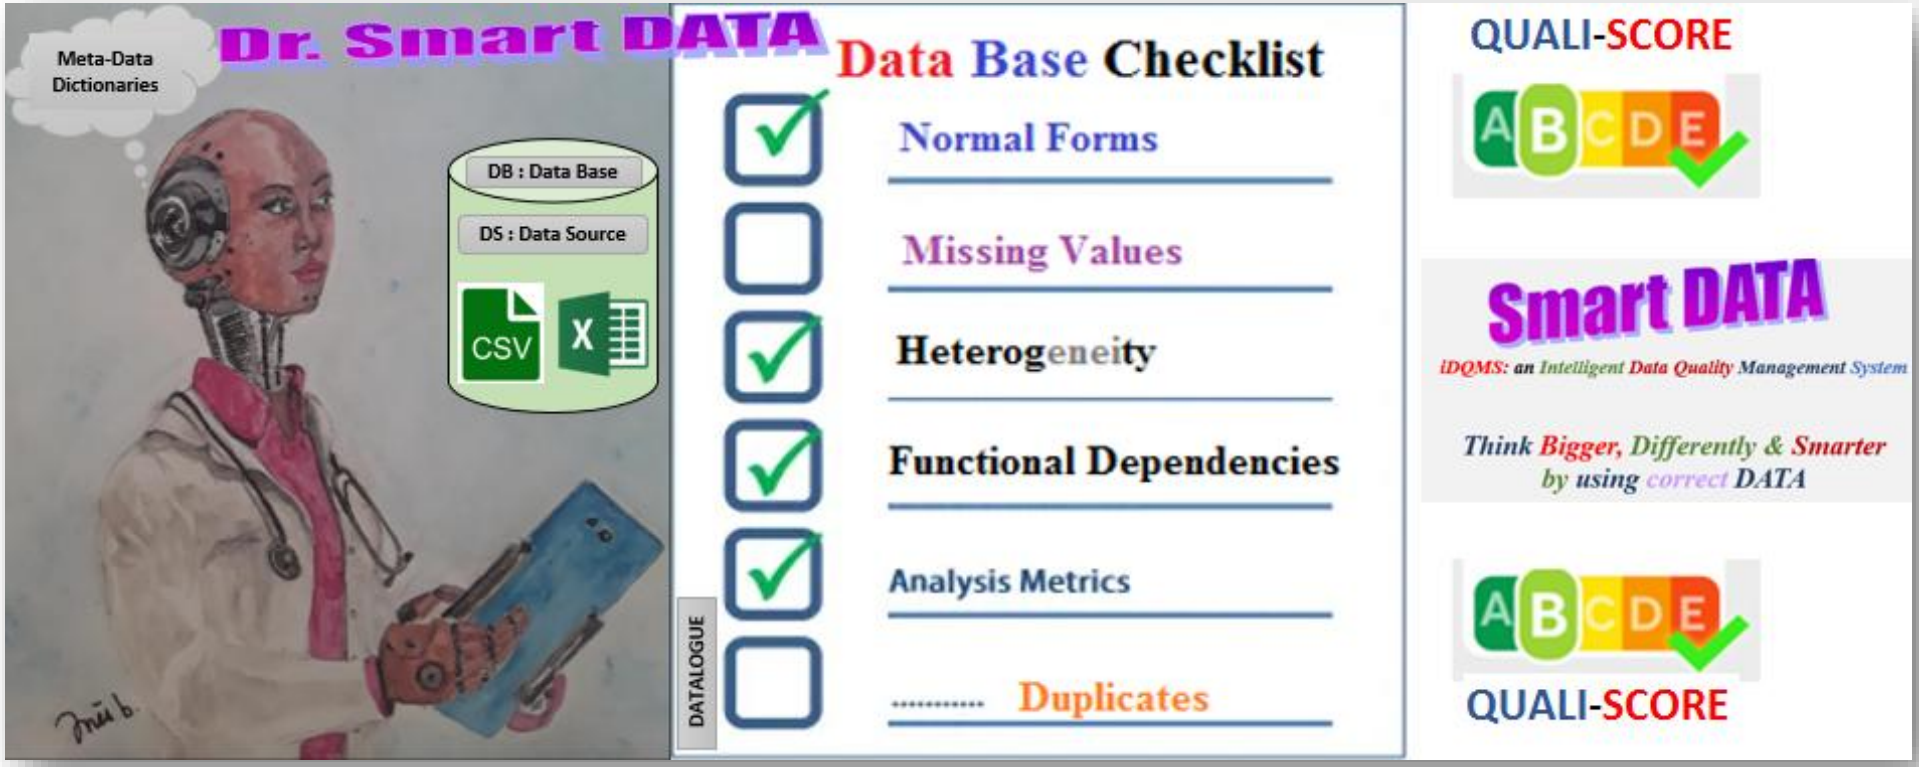
Quel est **le sens de chaque colonne ?**
Y-a-t-il des **erreurs syntaxiques** et **sémantiques** dans les colonnes ?
Y-a-t-il des **liens sémantiques** entre les **colonnes** (dépendances)?
Y-a-t-il de la **cohérence/incohérence** entre les **colonnes** ?
Y-a-t-il des **liens sémantiques** entre les **lignes** (doublons, similaires) ? …

Comment le savoir ? Comment les détecter et les corriger automatiquement ?

...Des questions sur Les Données , La Data?...



Think Bigger, Differently & Smarter by using correct DATA



Smart DATA

iDQMS : intelligent Data Quality Management System

Donner un sens aux Données rassemblées !… Anomalies !

Des anomalies lors de l'intégration des données :

Données incorrectes

Doublons

Similaires

Valeurs nulles

Etc…









BD1-Cli

NomCli	PrénomCli	Catégorie	Score	Type	Adresse	Mail
C(20)	C(20)	F, M	[0..20]	1, 2, 3	C(150)	C(200)
Le Bon	Adam	M	19	1	2, r de la Paix 75008 Paris France	adm@yahoo.fr
Clément	Clémence	F	16	2	5, r de Belleville 75019 Pari Franc	cc@gmail.fr
Premier	Inès	F	7	2	27, r de la Paix 75008 Paris	titi@yahoo.fr

BD2-Clients

Nom	Prénom	Sexe	Note	CatégSoc	AdrPays	Courriel
C(30)	C(30)	N(1) !	[0..10]	A, B, C, D, E	C(50)	C(100)
Le Bon	Adamo	1	9	A	France	adm@yahoo.fr
Clément	Lina	0	7	E	France	clina@orange.fr
First	Inès	0	3	A	Espagne	cmoi@gmail.com
Adem	LeBon	1	8	A	France	adm@yahoo.fr

ED Résultat de l'intégration Cli-Clients

	Nom	Prénom	Sexe	Score	CatégSoc	Pays	Mail
???	C(20)	C(20)	F, M	[0..20]	1, 2, 3	C(150)	C(200)
???	C(30)	C(30)	N(1) ! 0,1	[0..10]	A, B, C, D, E	C(50)	C(100)
	Le Bon	Adam	M	19	1	2, r de la Paix 75008 Paris France	adm@yahoo.fr
	Clément	Clémence	F	16	2	5, r de Belleville 75019 Pari Franc	cc@gmail.fr
	Premier	Inès	F	7	2	27, r de la Paix 75008 Paris	titi@yahoo.fr
	Le Bon	Adamo	1	9	A	France	adm@yahoo.fr
	Clément	Lina	0	7	E	France	clina@orange.fr
	First	Inès	0	3	A	Espagne	cmoi@gmail.com
	Adem	LeBon	1	8	A	France	adm@yahoo.fr

Donner un sens aux Données rassemblées !... Anomalies !

Plusieurs types d'anomalies dans les données (>50% d'anomalies)

Intra-Colonne, Inter-Colonnes et Inter-Lignes

	Clients					
	Nom Prénom	Téléphone	Mail	Catégorie	Ville	Chiffre d'affaires
t1	**Le Bon Adam**	0653545577	adam@yahoo.fr	1	Londres	1000
t2	**Le Bon A.**	0653545555	-	1	**London**	~~2~~000 ~~€~~
t3	Grande Clémence	0607080911	clemence@gmail.com	2	Epinay sur seine	1000
t4	**Adam LeBon**	0653545555	adam@yahoo.fr			
t5	Grande Clémence	607080911	clemence@gmail.com	2	Epinay / seine	1000
t6	**Le Bon**	0653545577	adam@yahoo.fr	1	Londres	-
t7	Belle Inès	0708091122	belleines@yhoo.fr	3	~~Epinay Villetaneuse~~	3000
t8	Rahma Adam	-	-	3	Epinay-sur-seine	1000
t9	Riche Emir	0908070605	-	3	~~Qatar~~	~~20000000000~~
t10	Traifor Eve	0666622223	traifor@up13.fr	1	Pékin	1000
t11	Traifor Eve	0666622223	traifor@up13.fr	1	**Beijing**	1000
t12	***LeBon Adel***	0653545599	alebon@up13.fr	1	Paris	-
t13	**LeBon Adem**	-	~~adam@obsolete.uk~~	1	~~Londre~~	-

Des SIMILAIRES
Des DOUBLONS

Des données obsolètes

Donnée NON Standard
Donnée NON Standard
Donnée NON Valide

Des valeurs aberrantes

- Les algorithmes, pour les corriger, **sont très coûteux en terme de temps de réponse**
- **Comment savoir ? Ce qu'il y a à corriger / Ce qu'il faut corriger / Comment corriger ?**

Donner un sens aux Données rassemblées !... Anomalies !

Qualité des Données : Elimination des doubles et des similaires

Doubles ? Similaires ? <<<>>>>>> **Vrais - Faux amis !** <<<>>>>>> **Faux - Vrais amis !**

BD ACM →→→ ID;Title;Authors;Venue;Year

564753;**A compact B-tree**;Peter Bumbulis, Ivan T. Bowman;International Conference on Management of Data;2002

872806;**A theory of redo recovery**;David Lomet, Mark Tuttle;International Conference on Management of Data;2003

Attention

BD DBLP →→→ ID;Title;Authors;Venue;Year

conf/sigmod/BumbulisB02;**A compact B-tree**;Ivan T. Bowman, Peter Bumbulis;SIGMOD Conference;2002

conf/sigmod/LometT03;**A Theory of Redo Recovery**;Mark R. Tuttle, David B. Lomet;
SIGMOD Conference;2003

conf/sigmod/DraperHW01;The Nimble Integration Engine;Daniel S. Weld, Alon Y. Halevy, Denise Draper;SIGMOD Conference ;2001

Exemple d'intégration de données dans le domaine de la bibliographie.
Traitement des doubles et des similaires

Donner un sens aux Données rassemblées !... Anomalies !

Qualité des Données : Elimination des doubles et des similaires

Doubles ? Similaires ? <<<>>>>>> **Vrais - Faux amis !** <<<>>>>>> **Faux - Vrais amis !**











...Des questions sur La Data, Les Données ?...



Think Bigger, Differently & Smarter using DATA

Smart DATA

iDQMS : Intelligent Data Quality Management System

M. F. B. — DIAGNOSTIC OF DATA SOURCE — CLIENTS

	A	B	C	D	E	F	G	H	I	J	K	L
1	C001	Madame	CLEM@ENT	EVE	1	18	BOULEVARD FOCH	91000	EPINAY-SUR-ORGE	FRANCE	eve.clement@gmail.com	+33777889911
2	C002	Madame	LESEUL	M@RIE	1	17	AVENUE D ITALIE	75013	PARIS	FRANCE	marieleseul@yahoo.fr	0617586565
3	C003	Madame	UNIQUE	Marine	2	77	RUE DE LA LIBERTE	13001	MARCHEILLE	FRANCE	munique@gmail.com	+33717889922
4	C004	Madame	CLEMENCE	EVELYNE	3	BBIS	BOULEVARD FOCH	93800	EPINAY-SUR-SEINE	FRANCE	clemence evelyne@gmail.com	+33777889933
5	C005	Madame	FORT	Jeanne	3	55	RUE DU JAPON	94310	ORLY-VILLE	FRANCE	jfort\@hotmail.fr	+33777889944
6	C006	Mademoiselle	LE BON	Clémence	1	18	BOULEVARD FOCH	93800	EPINAY-SUR-SEINE	FRANCE	clemence.le bon@cfo.fr	+33777889955
7	C007	Mademoiselle	TRAIFOR	Alice	2	6	RUE DE LA ROSIERE	75015	PARIS	FRANCE	alice.traifor@yahoo.fr	+33777889966
8	C008	Monsieur	VIVANT	JEAN-BAPTISTE	1	13	RUE DE LA PAIX	93800	EPINAY-SUR-SEINE	FRANCE	jeanbaptiste@	607
9	C009	Monsieur	CLEMENCE	Alexandre	1	5	RUE DE BELLEVILLE	75019	PaRIS		alexandre.clemence@up13.fr	+33149404071
10	C010	Monsieur	TRAIFOR	Alexandre	1	17	AVENUE FOCH	75016	PARIS	FRA	alexandre.traifor@up13.fr	6070809
11	C011	Monsieur	PREMIER	JOS//EPH	2	77//	RUE DE LA LIBERTE	13001	MARCHEILLE	FRANCE	josef@premier	+33777889977
12	C012	Monsieur	CLEMENT	Adam	2	13	AVENUE JEAN BAPTISTE CLEMENT	9430	VILLETANEUSE	FRANCE	adam.clement@gmail.com	+33149404072
13	C013	Monsieur	FORT	Gabriel	5	1	AVENUE DE CARTAGE	99000	TUNIS	TUNISIE	gabriel.fort@yahoo.fr	+21624801777
14	C014	Monsieur	ADAM	DAVID	5	1	AVENUE DE ROME	99001	ROME	ITALIE	david.adamé@gmail com	
15	C015	Monsieur	Labsent	pala	7	1	rue des absents	0	BAGDAD	IRAQ	pala-labsent@paici	
16	C016	Madame	obsolete	kadym	7	1	rue des anciens	0	CARTHAGE	IFRIQIA	inexistant	inexistant
17	C017	Madame	RAHYM	Karym	1	1	RUE DES GENTILS	1000	CARTHAGE	TUNISIE	karym.rahym@gmail.com	+21624808444
18	C018	Madame	GENIE	ADAM	3	8	BOULEVARD FOCH	93800	EPINAY SUR SEINE	FRANCE	adam.génie@gmail.com	+33777889911
19	C118	Madame	GENIE	Adam	3	8	BOULEVARD FOCH	93800	EPINAY SUR SEINE	FRANCE	adam.génie@gmail.com	+33777889911
20	C119	Madame	UNE	Marie	1	17	AVENUE D ITALIE	75013	PARIS	FRANCE	marieune@gmail.com	0617586575
21	C120	Madame	1	MARIE	1	17	AVENUE D ITALIE	75013	PARIS	FRANCE	MARIEUNE@GMAIL.COM	0617586575
22	C121	Monsieur	2 PAR 2	Girard	1	27	AVENUE D ITALIE	75013	PARIS	FRANCE	2PAR2@GMAIL.COM	0617586577
23	C122	Monsieur	DE PAR DE	GIRARD	1	27	AVENUE D-ITALIE	75013	PARIS	FRANCE	2PAR2@GMAIL.COM	0617586577
24	C123	Monsieur	DE PAR DE	GIRARD	1	27	AVENUE D ITALIE	75013	PARIS	FRANCE	2PAR2@GMAIL.COM	0617586577
25	C124	Monsieur	DE PAR DE	Girard	1	27	AVENUE D_ITALIE	75013	PARIS	FRANCE	2PAR2@GMAIL.COM	0617586577
26												
27												

Nombre total de valeurs	300
Nombre de valeurs incorrectes	**145**
Nombre de valeurs correctes	155
	155 / 300
Valeur initiale de la table (sur 100)	**51,7 / 100**
Valeur initiale de la table (sur 20)	**10,4 / 20**

Evaluation de la Qualité de la source de données



… Les catégories des Données …

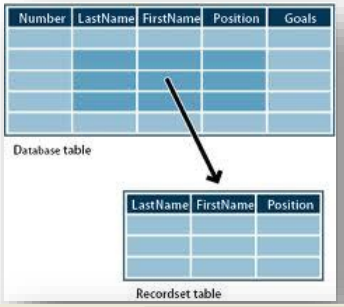


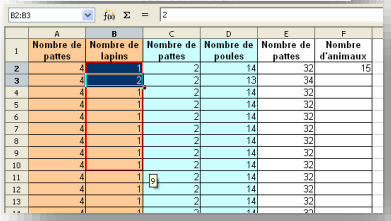
Les données sont Massives, Hétérogènes et Distribuées.

Les données peuvent être classées en trois catégories :

Les données **structurées**

(**Relationnel**, Objet, **CSV** …)





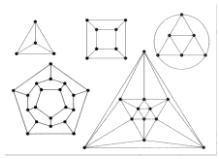
	A	B	C	D	E	F
1	Nombre de pattes	Nombre de lapins	Nombre de pattes	Nombre de poules	Nombre de pattes	Nombre d'animaux
2	4	1	2	14	32	15
3	4	2	2	13	34	
4	4	1	2	14	32	
5	4	1	2	14	32	
6	4	1	2	14	32	
7	4	1	2	14	32	
8	4	1	2	14	32	
9	4	1	2	14	32	
10	4	1	2	14	32	
11	4	1	2	14	32	
12	4	1	2	14	32	
13	4	1	2	14	32	

Les données **Quantitatives et Qualitatives**

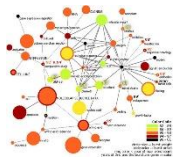
Les données **semi-structurées**

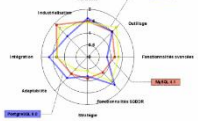
(XML, Graphes…)





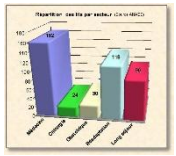












Les données **non-structurées**

(Textes, Multimédia, **Documents**, **JSON**)















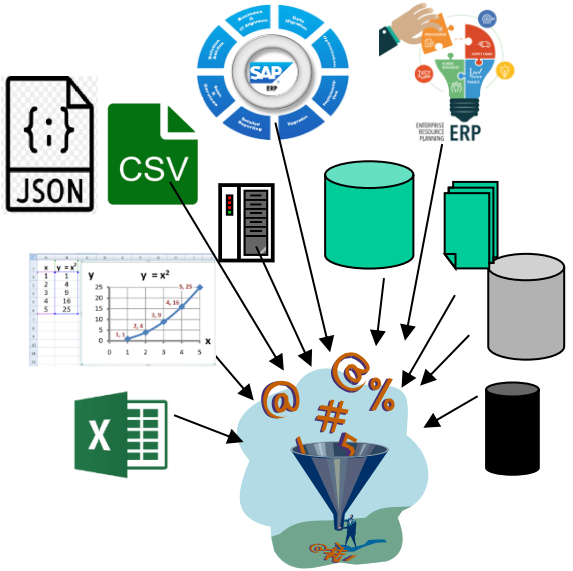
… Les catégories des Données …



Les données, de nos jours, sont Massives, **Hétérogènes** et Distribuées.

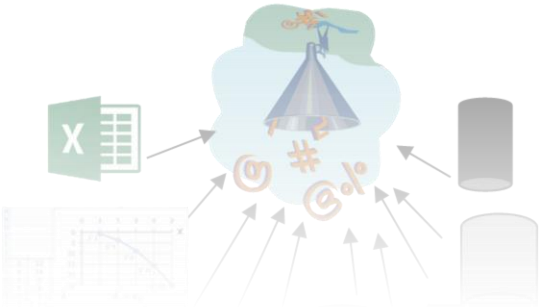
Les données peuvent être de **Qualité** très variable

(plutôt mauvaise ; **plusieurs anomalies**).



Les données peuvent être :

- **Structurées**
- Semi-Structurées
- **NON-structurées**



Les Données … Une vieille histoire ! …
Historique des types, des modèles et des systèmes de Gestion !

Vers de nouvelles générations de Systèmes de Gestion de Données !?
Quelle génération ??? 3è, 4è, 5è … ou Nième !!!

Système de Gestion de Bases de Données (SGBD) ; Data Base Management System (DBMS)
Base de Données (BD) ; **Data Base (DB)**
Entrepôt de Données (ED) ; **Data WareHouse (DWH)**
Magasin de Données (MD) ; **Data Mart (DM)**
Lac de Données (MD) ; **Data Lake (DL)**
Grosses Masses de Données ; Big Data

BD Avancées !!! BD : Documentaire ; Multimédia ; XML …
BD déductive ; Distribuée ; Répartie ; Floue ; Multidimensionnelle …
BD SQL ! ; **BD NoSQL** !!!

Données hétérogènes (Structurées et NON-Structurées :

Types (**Simple** prédéfini par le système ou **Complexe** défini par l'utilisateur),

Modèles (Relationnel, Relationnel-Etendu, Relationnel-Objet, Objet, XML, Texte, Multimédia, Document, NON relationnel…),

Catégories (Structurée, semi-structurée, NON structurée)

Qualité (Valeurs en double ou similaires, valeurs aberrantes, valeurs nulles…)

Systèmes (SGBD) : **Relationnels**, Déductifs, Actifs, Répartis, Documentaires, **NON relationnels**…

Les Données … Une vieille histoire ! …

L'Histoire des SGBD peut être résumée en distinguant plusieurs types d'applications et de nouveaux besoins…

Les nouveaux besoins : BD/DB – ED/DW – LD/LD… – BD → FD/DM/ML :

Volume de données

Types de données

Applications intelligentes sur les données (Data)

Big Data + Cloud Computing : Thinking Differently, Bigger and Smarter

Prédiction, Recommandation, Conseil… Apprentissage →Temps réel

Applications d'analyses sur les données (Les Bases et Entrepôts de données)

Informatique décisionnelle, Business Intelligence (BI)

(OLTP : < 10 secondes) (OLAP < 1 heure)

(MV : agrégation,…) (**Batch** : Quotidien ou mensuel < 1h)
Grosse volumétrie : travail d'optimisation et suivi des activités de l'entrepôt est nécessaire :
par expérience certains traitements ne finissent pas au bout de quelques jours ;
ce qui nécessite des modifications (techniques et fonctionnelles)

Applications BD : Gestion des risques, Analyse des ventes (Batch : < 1 heure)

Applications BD : Paie, Marketing, Financière (OLTP: quelques secondes) **(Batch : < 1 heure)**

Performance

Les Données … Une vieille histoire ! …

L'Histoire des SGBD peut être résumée en distinguant plusieurs types d'applications et de nouveaux besoins…

Les nouveaux besoins : BD/DB – ED/DW – LD/LD… – BD → FD/DM/ML :

Volume de données

Types de données

Apprentissage Artificiel, … Fouille des données ,

(Analyse du comportement des clients, Diagnostic, conseil, Recommandation, …)

Entrepôts de données (grosses masses de données)

Intégration de plusieurs systèmes d'information nationaux et internationaux

(milliers de tables de quelques millions de lignes ; milliards de lignes : >>> 1000 GO, TO, PO, ZO)

Applications : Gestion des risques, Analyse des ventes

(100 tables de quelques millions de lignes) 2 GO

Applications : Paie, Marketing, Financière

(50 tables de quelques milliers de lignes) 50 MO

Bases de Données

Intégration de Données

MASSES DE DONNEES

Entrepôts, Magasins, Lacs de Données

Performance

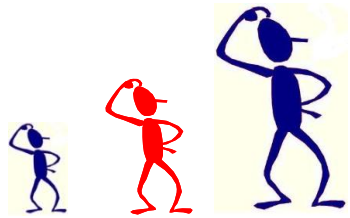
1 Mo (MégaOctets) = 10^6 Octets ; 1 Go (GigaOctets) = 10^9 Octets ; 1 To (TéraOctets) = 10^{12} Octets ;

1 Po (PétaOctets) = 10^{15} Octets ; 1 Eo (ExaOctets) = 10^{18} Octets ; 1 Zo (ZettaOctets) = 10^{21} Octets ; 1 Yo (YottaOctets) = 10^{24} Octets ;

Exemple de grandeur : 1 ExaOctet = 10^{18} Octets = 1,15 milliard de milliards d'octets !!! C'est énorme

Les Données … Une vieille histoire ! …

L'Histoire des SGBD peut être résumée en distinguant plusieurs générations :



Volume de données

Types de données

Indépendance physique

Portabilité, Scalabilité

SGBD 1

Hiérarchiques, Réseaux

1960 - 1970 - 1980

SGBD 2

Relationnels

1970 - 1980 - 1990

SGBD 3

Avancés !

1990 - 2000…

SGBD new➔

Données Structurées

SQL

&

Données Non Structurées

NoSQL

200x – 20y…

x>1 et y>10

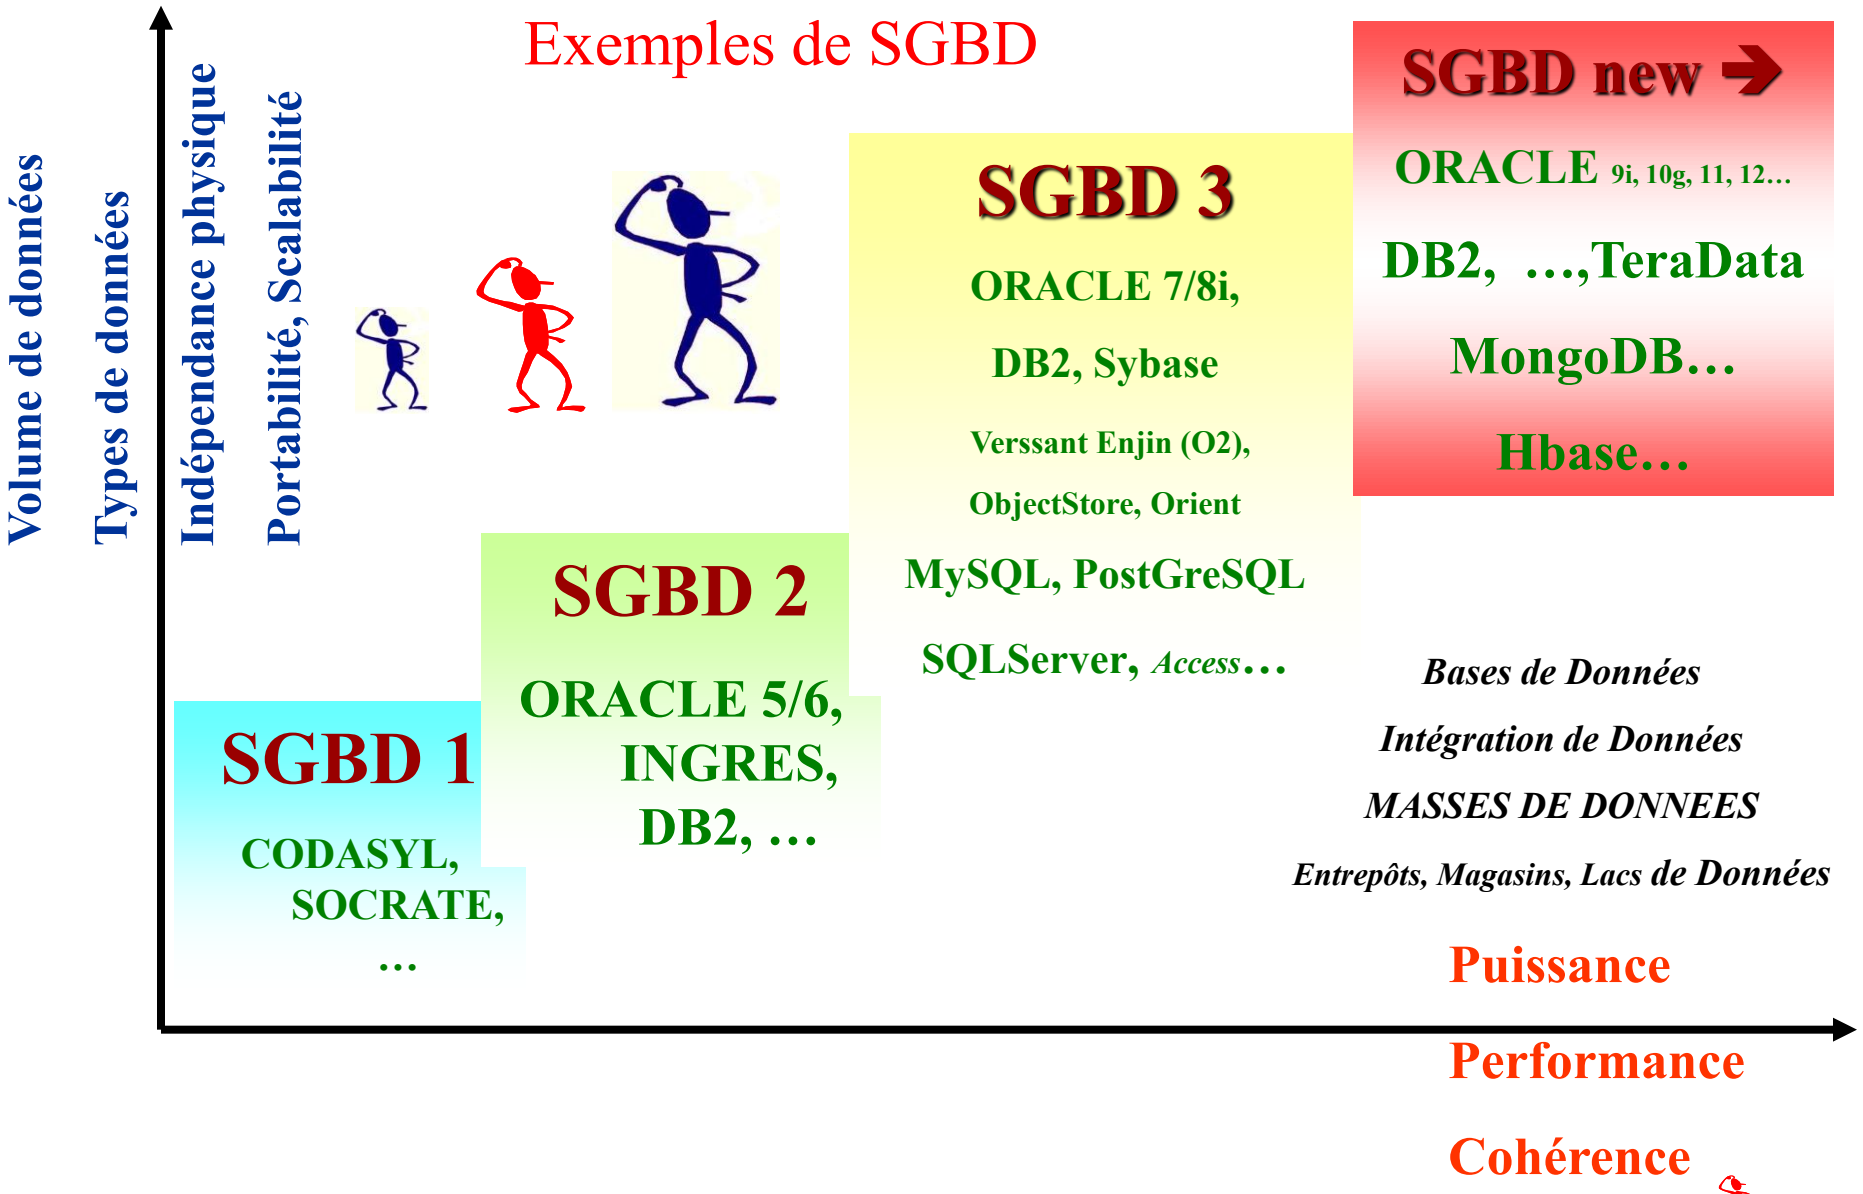
Puissance

Performance

Cohérence

Les Données … Une vieille histoire ! …

L'Histoire des SGBD peut être résumée en distinguant plusieurs générations :



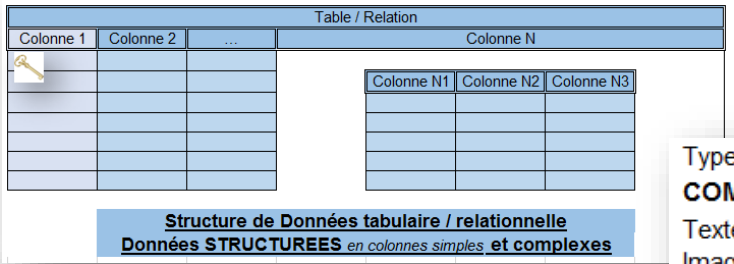
Les Données … Une vieille histoire ! …

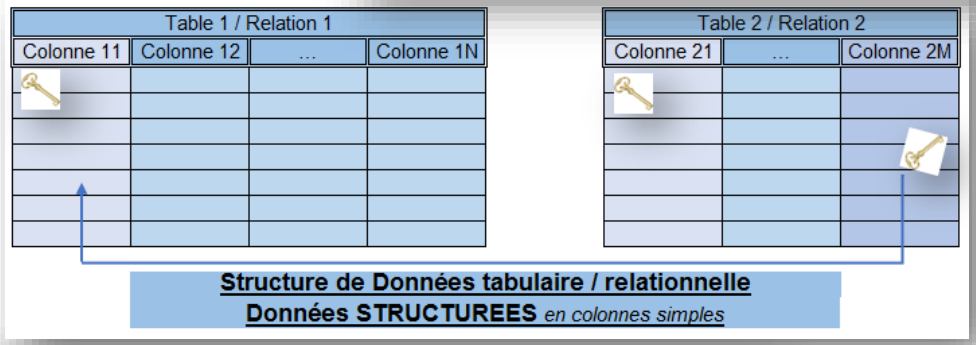
Les différentes *structures* de données, les *différentes* catégories de données

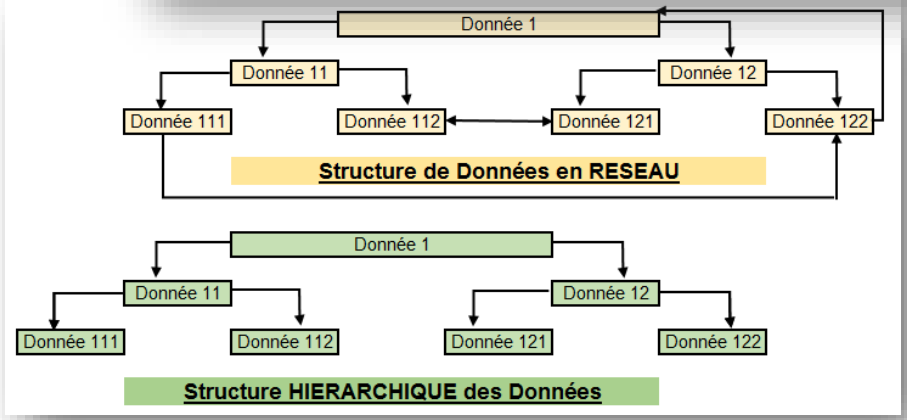
Volume de données, Types de données,

Indépendance physique, Portabilité, Scalabilité

SQL

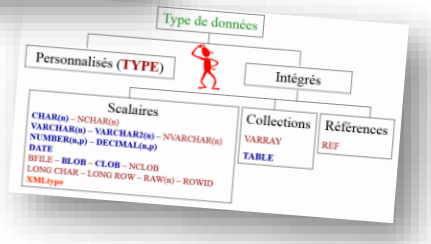






Type de données
COMPLEXES
Texte
Image
Son
Vidéo
Document
…
D. Structurées et
D. NON Structurées

No-SQL



Performance, Puissance, Cohérence

...Les Données... Historique des types... !

Les principaux types de données Oracle sont :



Type de données

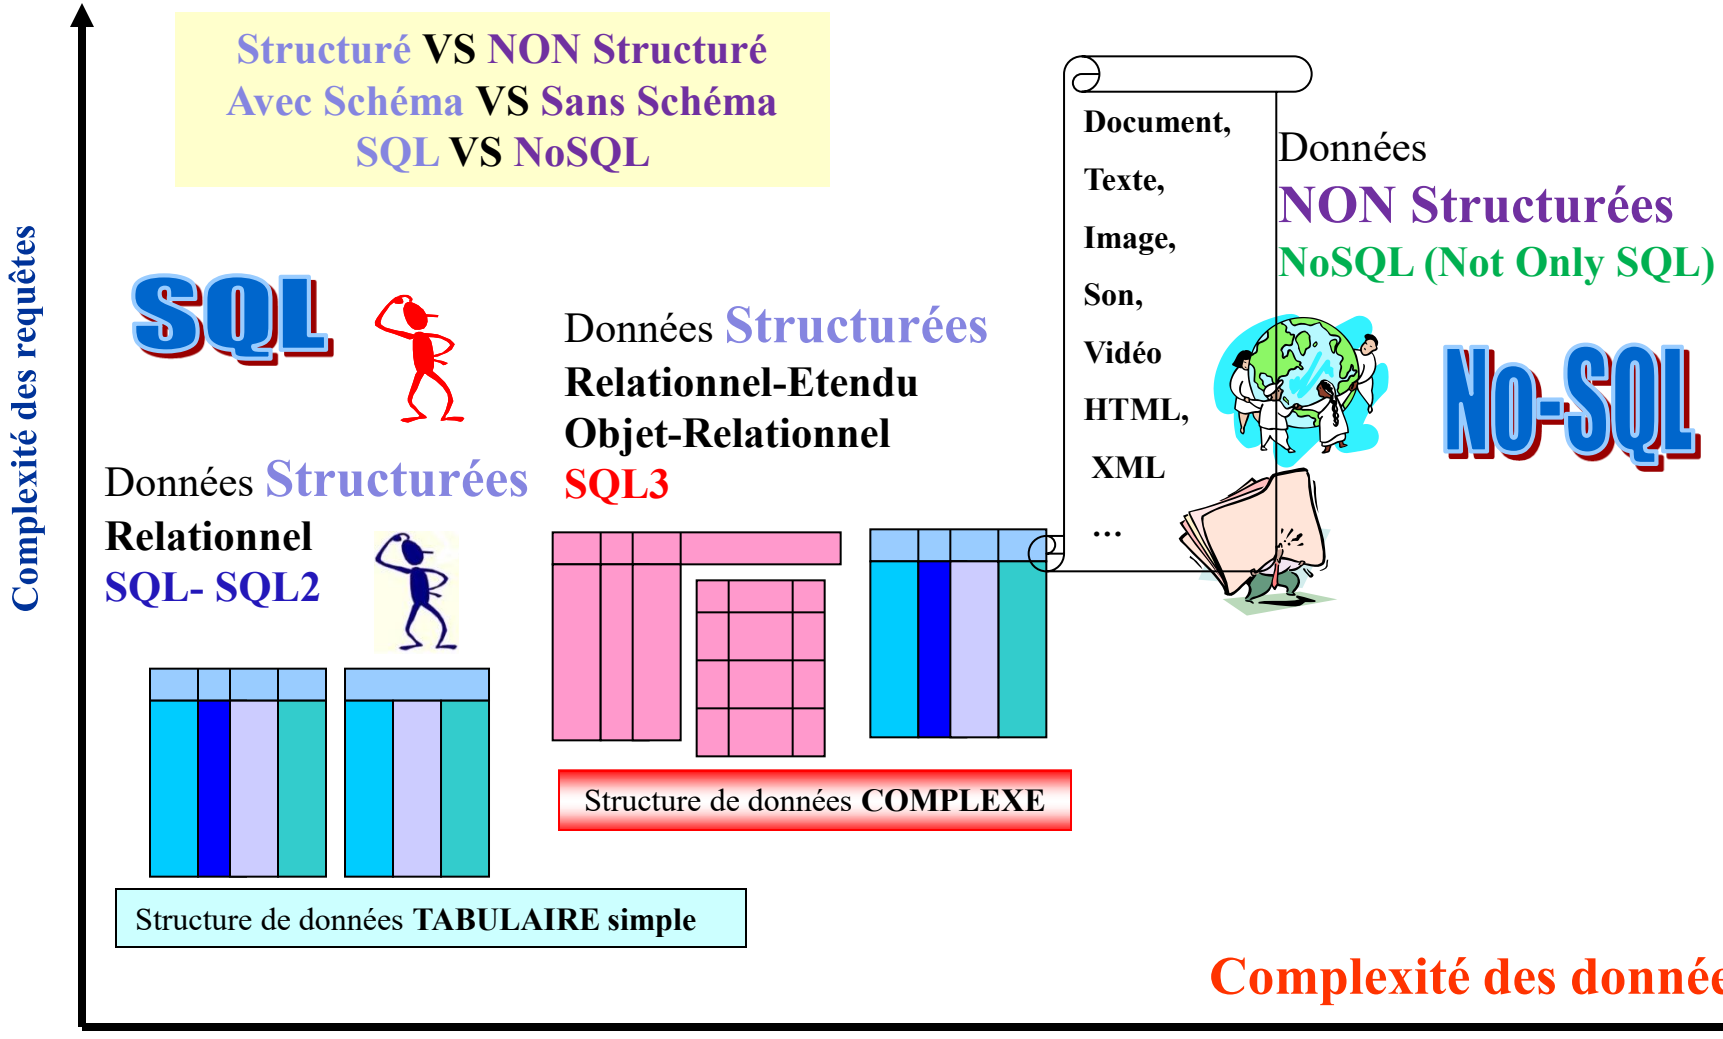
SQL

- Personnalisés (**TYPE**)
- Intégrés
  - Scalaires
    - **CHAR(n)** – NCHAR(n)
    - **VARCHAR(n)** – **VARCHAR2(n)** – NVARCHAR(n)
    - **NUMBER(n,p)** – **DECIMAL(n,p)**
    - **DATE**
    - BFILE – **BLOB** image – **CLOB** Texte – NCLOB
    - LONG CHAR – LONG ROW – RAW(n) – ROWID
    - **XMLtype**
  - Collections
    - VARRAY
    - **TABLE**
  - Références
    - REF



...Les Données... Historique des types... !

Les différentes *structures* de données, les *différentes* catégories de données



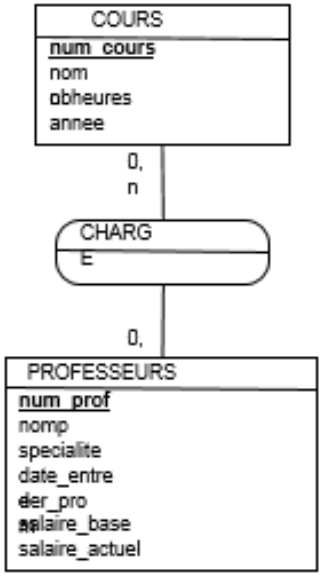
Les différents types de Bases de Données

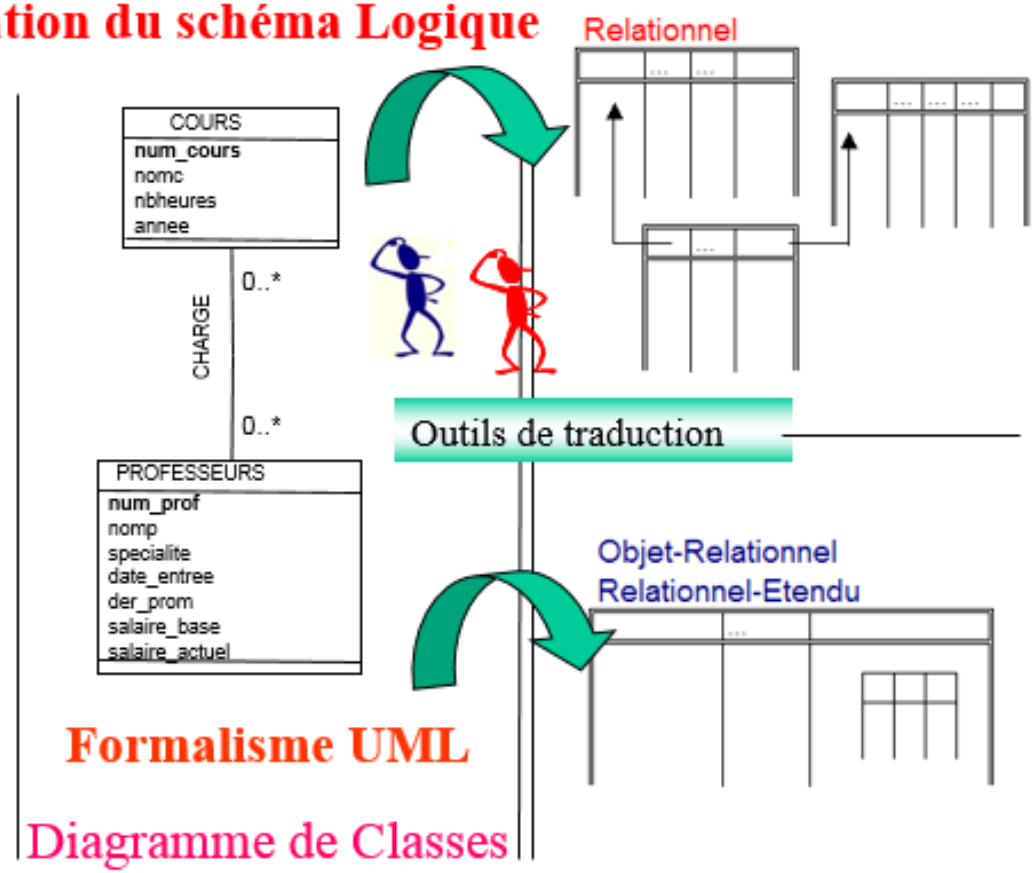
SQL 2 vs SQL3

Élaboration du schéma Logique

Formalisme ER

Diagramme ER





SQL2

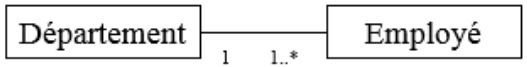
SQL3

SQL OO

Les différents types de Bases de Données

SQL 2 vs SQL3

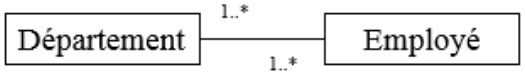
Une table imbriquée (NESTED TABLE) est une collection **non ordonnée et non limitée** d'éléments de même type.



Département

Numdep	Budget	Employés		
		Ninsee	Age	Nom

1 table qui contient une colonne (table) : Association du type 1-N



??? 1 ou plusieurs tables : Association du type N-N

Cours

Numc	Titre	Professeurs		Formations	
		Nom	Spécialité	Filière	Horaire

Les **propriétés ACID,** dans les bases de données relationnelles **sont les quatre principaux attributs d'une transaction de données** (la spécification des quatre buts à atteindre pour toute transaction). **ACID : *Atomicity* (atomicité), *Consistency* (cohérence), *Isolation (isolation)*, *Durability* (durabilité).**
(1) **Atomicité** signifie que les mises à jour de la base de données doivent être "atomiques", à savoir qu'**elles doivent être totalement réalisées ou pas du tout**. (2) **Cohérence** signifie que **les modifications apportées à la base doivent être valides**, en accord avec l'ensemble de la base et de ses contraintes d'intégrité. S'il arrive qu'un changement risque de perturber l'intégrité des données, alors soit le système doit modifier les données dépendantes, soit la transaction doit être interdite. (3) **Isolation** signifie que **les transactions lancées au même moment ne doivent jamais interférer entre elles**, ni même agir selon le fonctionnement de chacune. (4) **Durabilité** signifie que **toutes les transactions sont lancées de manière définitive**. Une base ne doit pas afficher le succès d'une transaction, pour ensuite remettre les données modifiées dans leur état initial. Pour ce faire, toute transaction est sauvegardée dans un fichier journal, afin que, dans le cas où un problème survient empêchant sa validation complète, celle-ci puisse être correctement terminée lors de la disponibilité du système.

Les différents types de Bases de Données NoSQL

SQL versus No-SQL

SQL VS NoSQL : Le terme de **Bases de Données NoSQL** (**BD Not only SQL**) regroupe des solutions, plus ou moins récentes, de représentation des données. Ces solutions se différentient du modèle relationnel des données (nommé à tort BD SQL) par une logique de représentation des données différente. Les principaux avantages de ces solutions sont, d'une part, leur capacité de traiter de très gros volumes de données (Big Data), et d'autre part, lorsque ces dernières ont des structures qui varient.

Le terme de BD NoSQL gagnerait à être remplacé par le terme de BD « non relationnelle » c'est-à-dire dont la structure n'est pas définie à l'avance et varie d'un objet représenté à un autre. On pourrait parler de données NON Structurées.

Le terme de **BD SQL signifie que les données sont structurées selon le modèle relationnel** (un ensemble de colonnes ou attributs regroupées en tables ou classes ; les tables peuvent être reliées entre elles avec les concepts de clés primaires et étrangères). On parle de données structurées lorsque : (i) La structure n'évolue pas ou évolue très peu dans le temps, (ii) La structure ne varie pas d'un objet à l'autre.

Les BD non relationnelles (BD NoSQL) ne visent pas à remplacer les BD relationnelles (BD SQL) mais plutôt à les compléter (il faudrait les faires cohabiter).

Les différents types de Bases de Données NoSQL

SQL versus No-SQL

Avantage des BD non relationnelles :

Les BD non relationnelles sont bien adaptées aux **traitements de données massives**, **peu structurées et/ou ayant une structure changeante.**

Un des premiers acteurs économiques qui a fait la promotion de ce type de gestion de données est Google. Il s'est basé sur (1) un système de **gestion de fichiers distribués** ; (2) un système de BD orientée colonnes ; et (3) un système de **mise en parallèle des traitements** nommé **MapReduce**.

Les **BD non relationnelles** constituent une autre (différente des **BD relationnelles**) manière de représenter l'information.
Elles s'affranchissent des contraintes dites ACID (Atomicité, Cohérence, Isolation, Durabilité) et fournissent **une architecture technique où il suffirait de rajouter des serveurs pour peut-être gagner en performance**.

Les différents types de Bases de Données NoSQL

SQL versus No-SQL

Les différents types de BD non relationnelles : On distingue plusieurs représentations de **BD non relationnelles** qui permettent de stocker les informations de la façon la mieux adaptée (=> différents types de **BD NoSQL**) :

• type « **Clé-valeur / Key-value** » : Il s'agit de la représentation la plus simple (basique). Chaque objet est identifié par une clé unique constituant la seule manière de le requêter ;

• type « **Document / Document** » : Une représentation qui ajoute au modèle clé-valeur, l'association d'une valeur complexe qui nécessiterait des jointures en termes relationnels ;
[Exemples de systèmes : MongoDB ; CouchDB…]

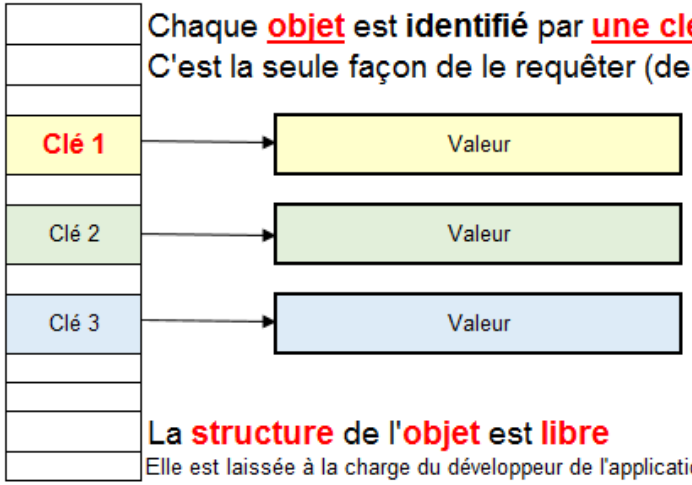
• type « **Colonne / Column** » : Une autre évolution du modèle clé-valeur qui permet de disposer de plusieurs valeurs sur une même ligne, de stocker des relations « one-to-many » ;
[Exemples de systèmes : HBase ; Cassandra…]

• type « **Graphe / Graph** » : Une représentation qui permet la modélisation, le stockage et la manipulation de données très complexes liées par des relations variées (gestion des relations multiples entre les objets adaptés aux données issues de réseaux sociaux par exemple). **[Exemples : Neo4j ; OrientDB …]**

Les différents types de Bases de Données NoSQL

SQL versus No-SQL

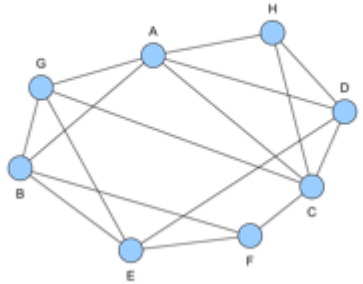
BD NoSQL Clé-Valeur / Key-Value



Chaque objet est identifié par une clé unique
C'est la seule façon de le requêter (de le retrouver)

La structure de l'objet est libre
Elle est laissée à la charge du développeur de l'application (XML, SJON, ...)
La base ne gère généralement que des chaines de carcatères

BD NoSQL Graphe / Graph



BD NoSQL Colonne / Column

	Key	Column	Value
Collection Famille Table	Clé1	Col1	Val11
	Clé1	Col2	Val12
	Clé1	Col3	Val13
	Clé2	Col1	Val21
	Clé2	Col2	Val22
	Clé3	Col1	Val31
	Clé3	Col3	Val33
	Clé3	Col4	Val34
	Clé3	Col5	Val35

BD NoSQL Document / Document

	Key	Column	Value
Collection Famille Table	Clé1	Col1	Val11
	Clé1	Col2	Val12
	Clé1		
	Clé2		
	Clé2		
	Clé3		
	Clé3		
	Clé3		
	Clé3	Col5	Val35



Les différents types de Bases de Données NoSQL

SQL vs No-SQL

CLIENTS

CodeCli	CiviCli	NomCli	PrenCli	…	MailCli
2994570	Madame	RAHMA	CLEMENCE		clemence.rahma@up13.fr
2996100	Monsieur	CLEMENCE			alexandre.clemence@up13.fr
2997007	Monsieur	TRAIFOR	ADAM		
2997777	Mademoiselle	LE BON	CLEMENTINE		clementine.le bon@up13.fr
2998500	Monsieur	CHEV@LIER	INES		ines.chevalier@up13.fr
3001777	Monsieur	LE BON	Adam		adam.le bon@up13.fr
2998505	Mademoiselle	TRAIFOR	ALICE		alice.traifor@up13.fr
3000106	Monsieur	HARISSA	FORD		ford.harissa@up13.fr

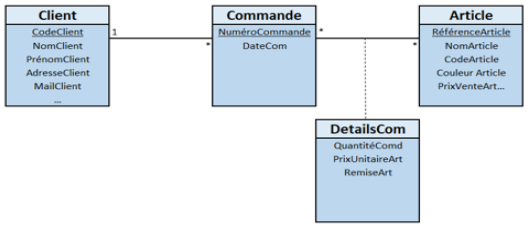
Clé 1 Nom de la table	Clé 2 Code du client	Colonne	Valeur
CLIENTS	2994570	CiviCli	Madame
CLIENTS	2994570	NomCli	RAHMA
CLIENTS	2994570	PrenCli	CLEMENCE
CLIENTS	2994570	MailCli	clemence.rahma@up13.fr
CLIENTS	2996100	CiviCli	Monsieur
CLIENTS	2996100	NomCli	CLEMENCE
CLIENTS	2996100	MailCli	alexandre.clemence@up13.fr
CLIENTS	2997007	CiviCli	Monsieur
CLIENTS	2997007	NomCli	TRAIFOR
CLIENTS	2997007	PrenCli	ADAM
CLIENTS	…	…	
CLIENTS			

Famille
Collection
Table

COMMANDES

NumeCom	CodeCli	DateCom
20150917BB0001	2997007	17/09/2015
20150917BB0002	2998500	17/09/2015
20151016BB0001	2996100	16/10/2015
20151024BB0001	2996100	24/10/2015
20120156BB0001	2996100	16/01/2012
20120157BB0007	2996100	17/01/2012
20180917BB0007	3001777	17/09/2018

Clé 1 Nom de la table	Clé 2 Code de la commande	Colonne	Valeur
COMMANDES	20150917BB0001	CodeCli	2997007
COMMANDES	20150917BB0001	DateCom	17/09/2015
COMMANDES	20150917BB0002	CodeCli	2998500
COMMANDES	20150917BB0002	DateCom	17/09/2015
COMMANDES			
COMMANDES			
COMMANDES			
COMMANDES			



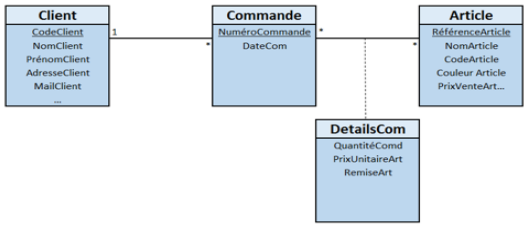
Les différents types de Bases de Données NoSQL

SQL vs No-SQL

CLIENTS

CodeCli	CiviCli	NomCli	PrenCli	…	MailCli
2994570	Madame	RAHMA	CLEMENCE		clemence.rahma@up13.fr
2996100	Monsieur	CLEMENCE			alexandre.clemence@up13.fr
2997007	Monsieur	TRAIFOR	ADAM		
2997777	Mademoiselle	LE BON	CLEMENTINE		clementine.le bon@up13.fr
2998500	Monsieur	CHEV@LIER	INES		ines.chevalier@up13.fr
3001777	Monsieur	LE BON	Adam		adam.le bon@up13.fr
2998505	Mademoiselle	TRAIFOR	ALICE		alice.traifor@up13.fr
3000106	Monsieur	HARISSA	FORD		ford.harissa@up13.fr

Clé 1 Nom de la table	Clé 2 Code du client	Valeur
CLIENTS	2994570	**Struct**:CiviCli;NomCli;PrenCli;MailCli//**Data**:Madame;RAHMA;CLEMENCE;clemence.rahma@up13.fr
CLIENTS	2996100	Struct:CiviCli;NomCli;MailCli//Data:Monsieur;CLEMENCE;alexandre.clemence@up13.fr
CLIENTS	2997007	Struct:CiviCli;NomCli;PrenCli//Data:Monsieur;TRAIFOR;ADAM
CLIENTS	…	…
CLIENTS		



Les différents types de Bases de Données NoSQL

SQL vs No-SQL

COMMANDES

NumeCom	CodeCli	DateCom
20150917BB0001	2997007	17/09/2015
20150917BB0002	2998500	17/09/2015
20151016BB0001	2996100	16/10/2015
20151024BB0001	2996100	24/10/2015
20120156BB0001	2996100	16/01/2012
20120157BB0007	2996100	17/01/2012
20180917BB0007	3001777	17/09/2018

Détails des commandes

NumeCom	RefeArt	QteCom	PUArt	Remise
20150917BB0001	00.37291	2	35,00 €	10,00%
20150917BB0001	00.37341	4	10,71 €	10,00%
20150917BB0001	11.36639	2	49,14 €	0,00%
20150917BB0001	WD.001	1	21,29 €	0,00%
20150917BB0002	00.37291	2	35,00 €	0,00%
20150917BB0002	WD.001	1	21,29 €	0,00%
20150917BB0002	WD.002	1	34,29 €	0,00%
20150917BB0002	WD.003	1	22,86 €	0,00%

Regrouper les informations dans un document

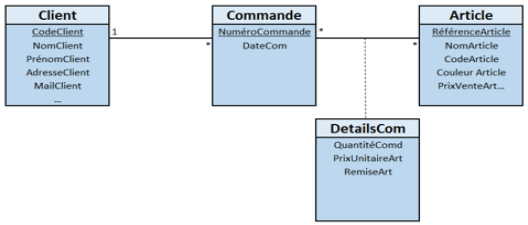
Un document

Un document

COMMANDES / *Détails des commandes*

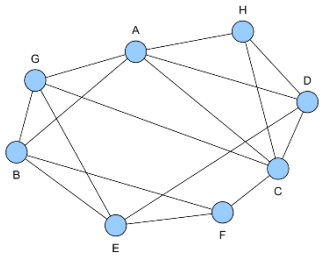
NumeCom	CodeCli	DateCom	NumeCom	RefeArt	QteCom	PUArt	Remise
20150917BB0001	2997007	17/09/2015	20150917BB0001	00.37291	2	35,00 €	10,00%
			20150917BB0001	00.37341	4	10,71 €	10,00%
			20150917BB0001	11.36639	2	49,14 €	0,00%
			20150917BB0001	WD.001	1	21,29 €	0,00%
20150917BB0002	2998500	17/09/2015	20150917BB0002	00.37291	2	35,00 €	0,00%
			20150917BB0002	WD.001	1	21,29 €	0,00%
			20150917BB0002	WD.002	1	34,29 €	0,00%
			20150917BB0002	WD.003	1	22,86 €	0,00%
20151016BB0001	2996100	16/10/2015					
20151024BB0001	2996100	24/10/2015					
20120156BB0001	2996100	16/01/2012					
20120157BB0007	2996100	17/01/2012					
20180917BB0007	3001777	17/09/2018					





Les différents types de Bases de Données NoSQL

SQL vs No-SQL

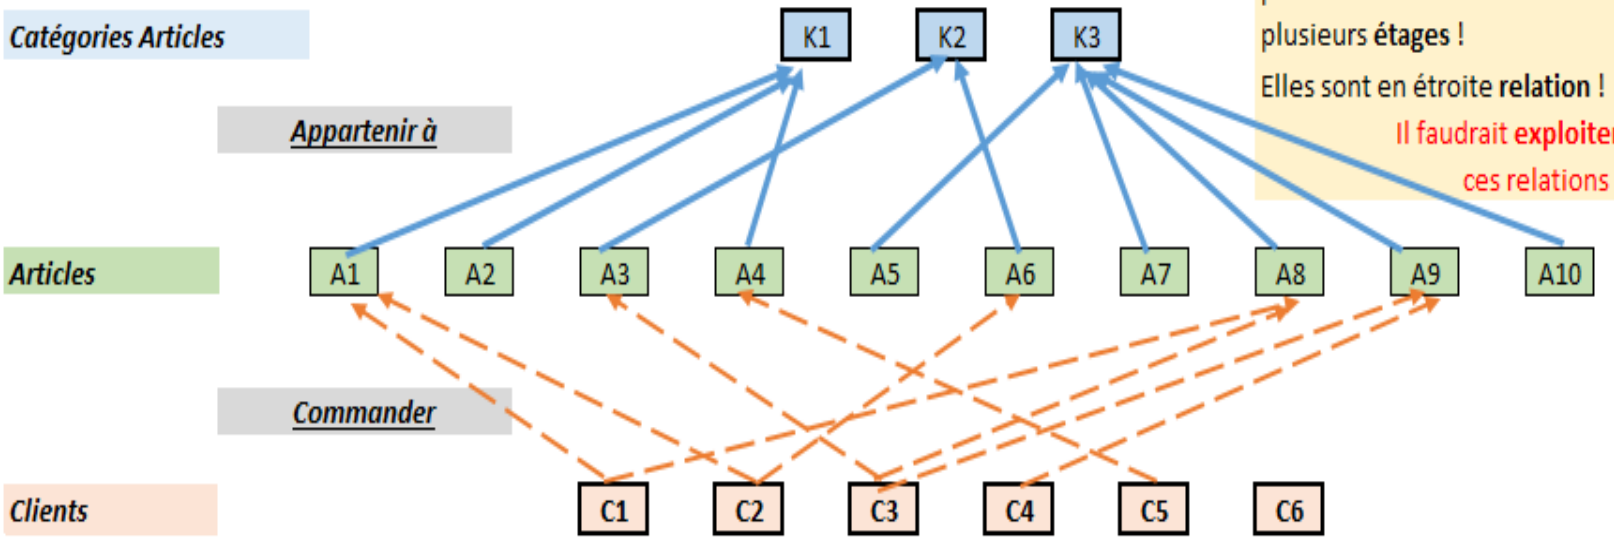


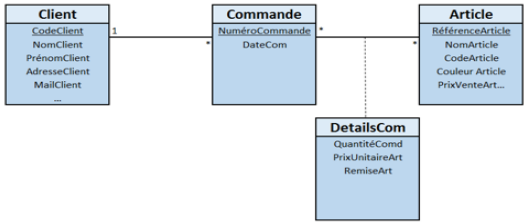
Systèmes de Recommandation ?! ***SysReco***

Les **données** de la BD ou de l'ED peuvent être vues sous forme de plusieurs **étages** !

Elles sont en étroite **relation** !

Il faudrait **exploiter** ces relations !





Des opérations initiales, très importantes, permettant de repartir sur de bonnes bases :

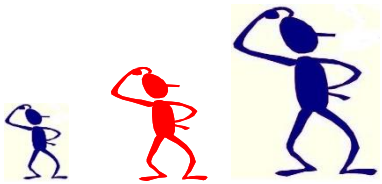
validation, nettoyage, correction et complétion des données manquantes -->>

Enrichissement des données

2. Conception de données *(Bases, Entrepôts, Lacs…)*

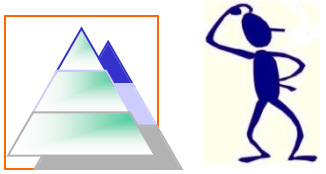
Think Bigger, Differently & Smarter by using correct

DATA





Conception & Modélisation de BD …



Une des tâches essentielles des développeurs de bases de données est la conception du schéma des bases.

L'objectif est de structurer le domaine d'application afin de le représenter sous plusieurs formes telles que des types et des tables et d'accompagner ces structures de contraintes sur les données afin de tirer plus de sémantique.

La représentation doit être :

- **juste** pour éviter les erreurs sémantiques, notamment dans les réponses aux requêtes ;
- **complète** pour permettre le développement des programmes d'application souhaités ;
- **évolutive** afin de supporter la prise en compte rapide de nouvelles demandes.

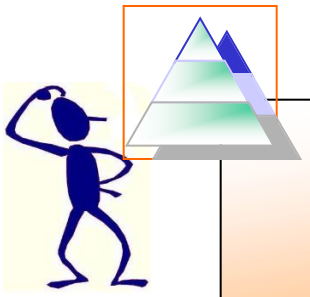
Remarque :

De nos jours, on parle aussi de **données sans schéma préétabli** (données **non structurées**) !

Conception , Modélisation & Implantation de BD …



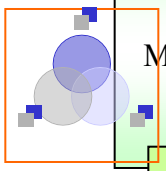
Concepteur ; Développeur ; Utilisateur ; Administrateur



Conception & Modélisation de BD

Méthodes, Modèles, Formalismes
Modèle Entité-Association E/A / Modèle **Entité-Association étendu**
Modèles Objet , Formalisme **UML, …**





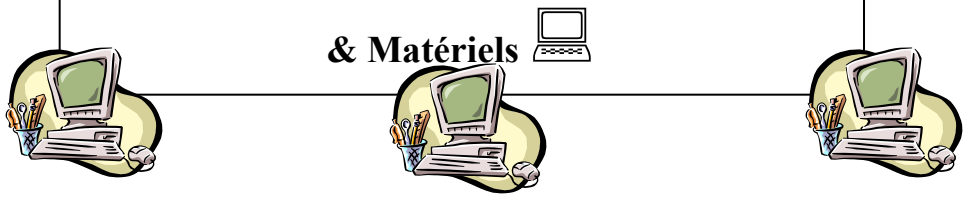
Implantation de BD

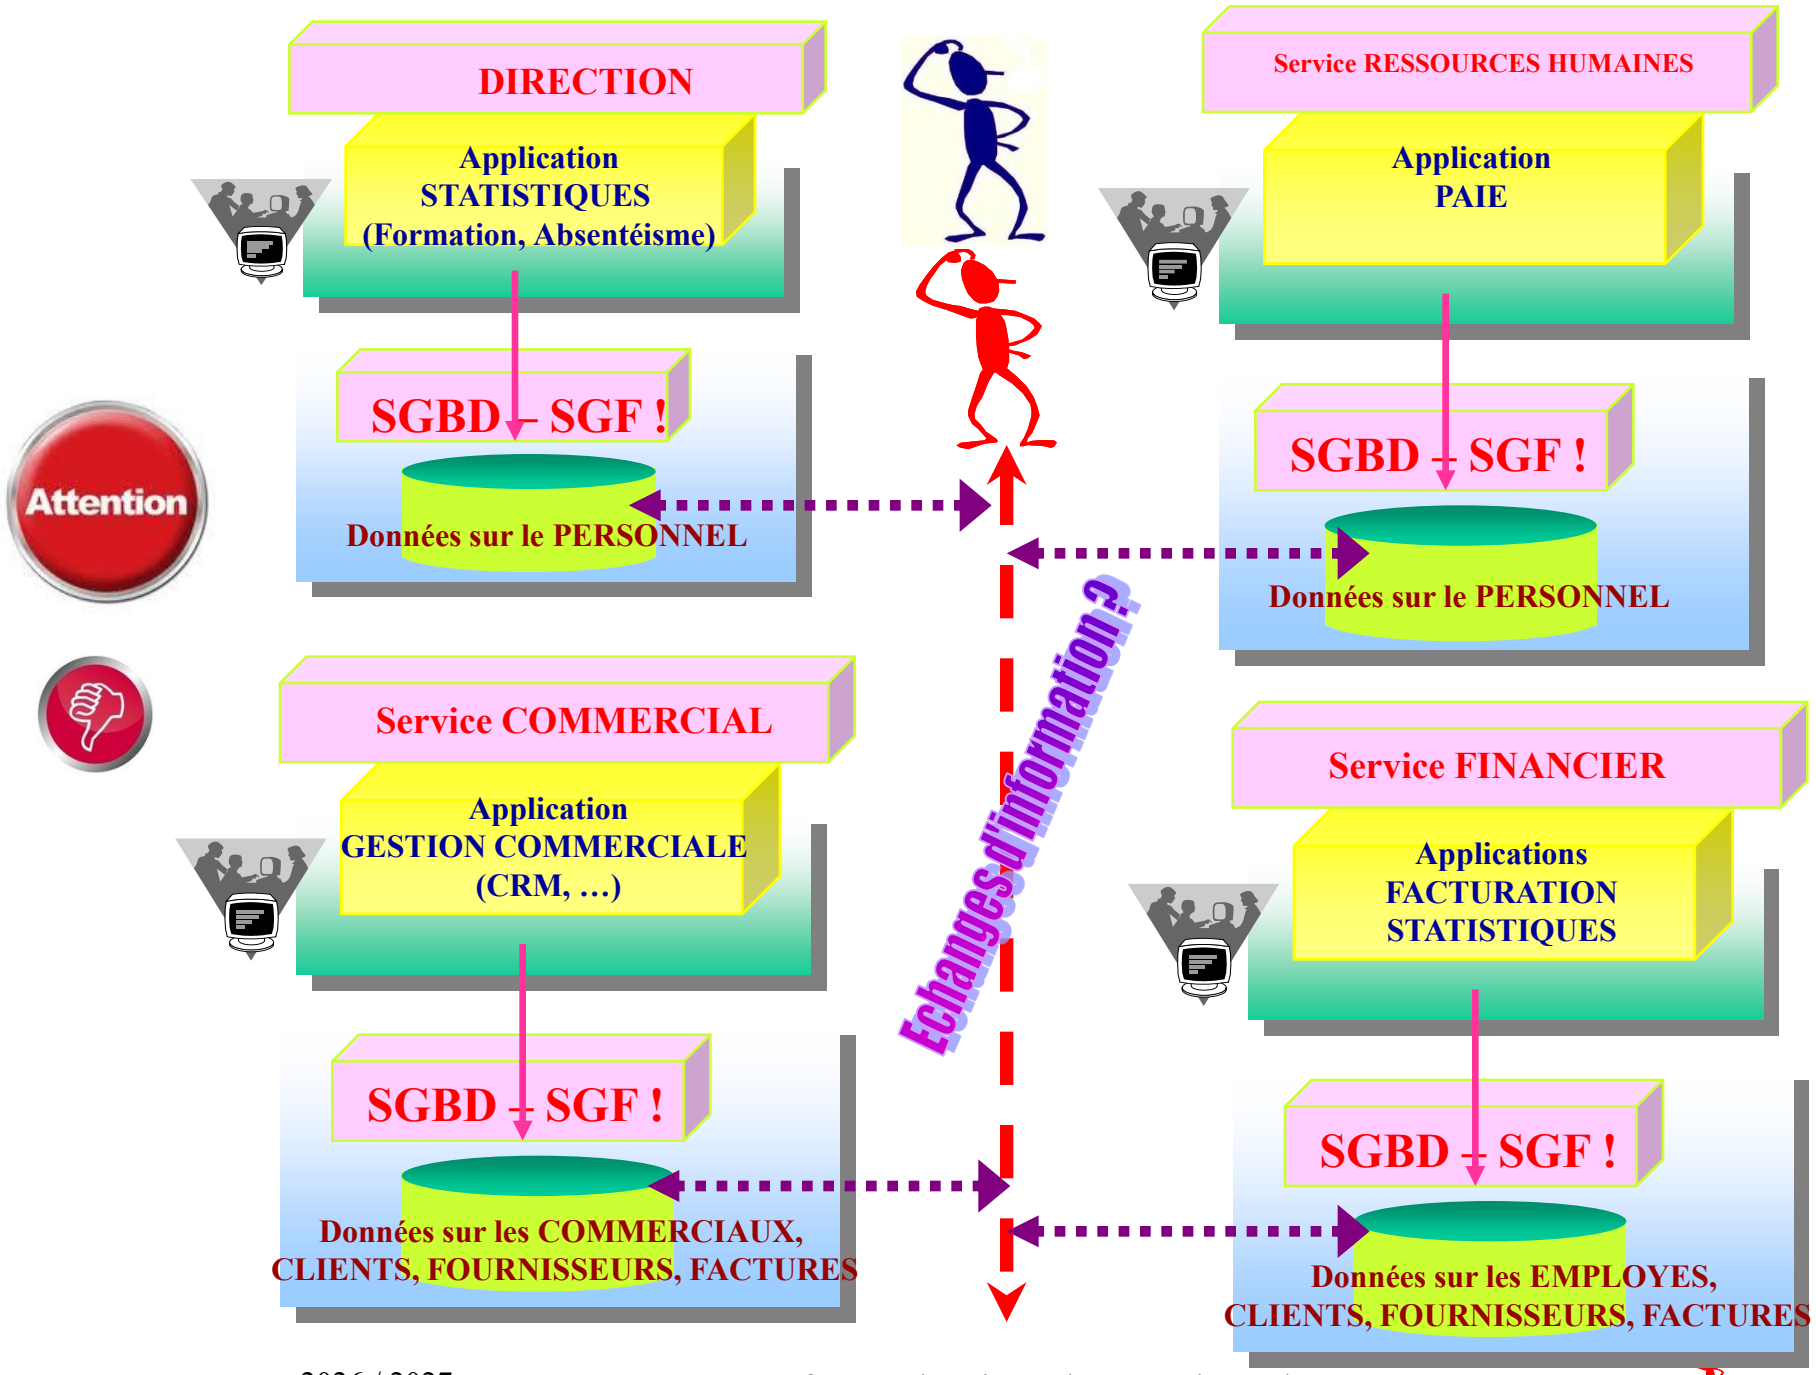
Modèle **Relationnel (Structuré)** / Modèle Objet-Relationnel / Modèle Objet / Modèle **NON relationnel (Non Structuré)**
Optimisation du schéma (Normalisation, Dénormalisation…)

SGBD **Relationnel** / SGBD Objet-Relationnel / SGBD Orienté Objet, SGBD **Non Relationnel**
Langages (**SQL, PL/SQL**, PRO*C, JDBC, Java, C++, Python, PHP…)
Optimisations (Groupement, Index, …)
Administration

Logiciels (SGBD, Interfaces, …)

& Matériels




DIRECTION
Application
STATISTIQUES
(Formation, Absentéisme)
SGBD – SGF !
Données sur le PERSONNEL
Service RESSOURCES HUMAINES
Application
PAIE
SGBD – SGF !
Données sur le PERSONNEL
Attention
Service COMMERCIAL
Application
GESTION COMMERCIALE
(CRM, …)
SGBD – SGF !
Données sur les COMMERCIAUX,
CLIENTS, FOURNISSEURS, FACTURES
Echanges d'information ?
Service FINANCIER
Applications
FACTURATION
STATISTIQUES
SGBD – SGF !
Données sur les EMPLOYES,
CLIENTS, FOURNISSEURS, FACTURES









Services	Applications développées	Données utilisées ??? Fichiers / Bases de Données
DIRECTION	STATISTIQUES Formation, Absentéisme	**PERSONNEL**
Service RESSOURCES HUMAINES	PAIE	**PERSONNEL**
Service COMMERCIAL	Gestion COMMERCIALE (CRM…)	**COMMERCIAUX**, **CLIENTS**, FOURNISSEURS, **FACTURES**
Service FINANCIER	FACTURATION, STATISTIQUES	**EMPLOYES**, **CLIENTS**, FOURNISSEURS, **FACTURES**









1 Personnel = 1 Commercial = 1 Employé

défini de plusieurs façons selon les services !!! et selon les applications !!!

Service Fichier / BD	Description des données utilisées ??? Fichiers / Bases de Données
DIRECTION **PERSONNEL**	Numéro, Civilité, NOM Prénom, Adresse, Téléphone
Service RESSOURCES HUMAINES **PERSONNEL**	Numéro, Civilité, NOM Prénom, Adresse, Téléphone, DateEmbauche
Service COMMERCIAL **COMMERCIAUX**	Numéro, Civilité, NOM Prénom, Adresse, Téléphone, Secteur
Service FINANCIER **EMPLOYES**	Numéro, Civilité, NOM P., Adresse, Téléphone







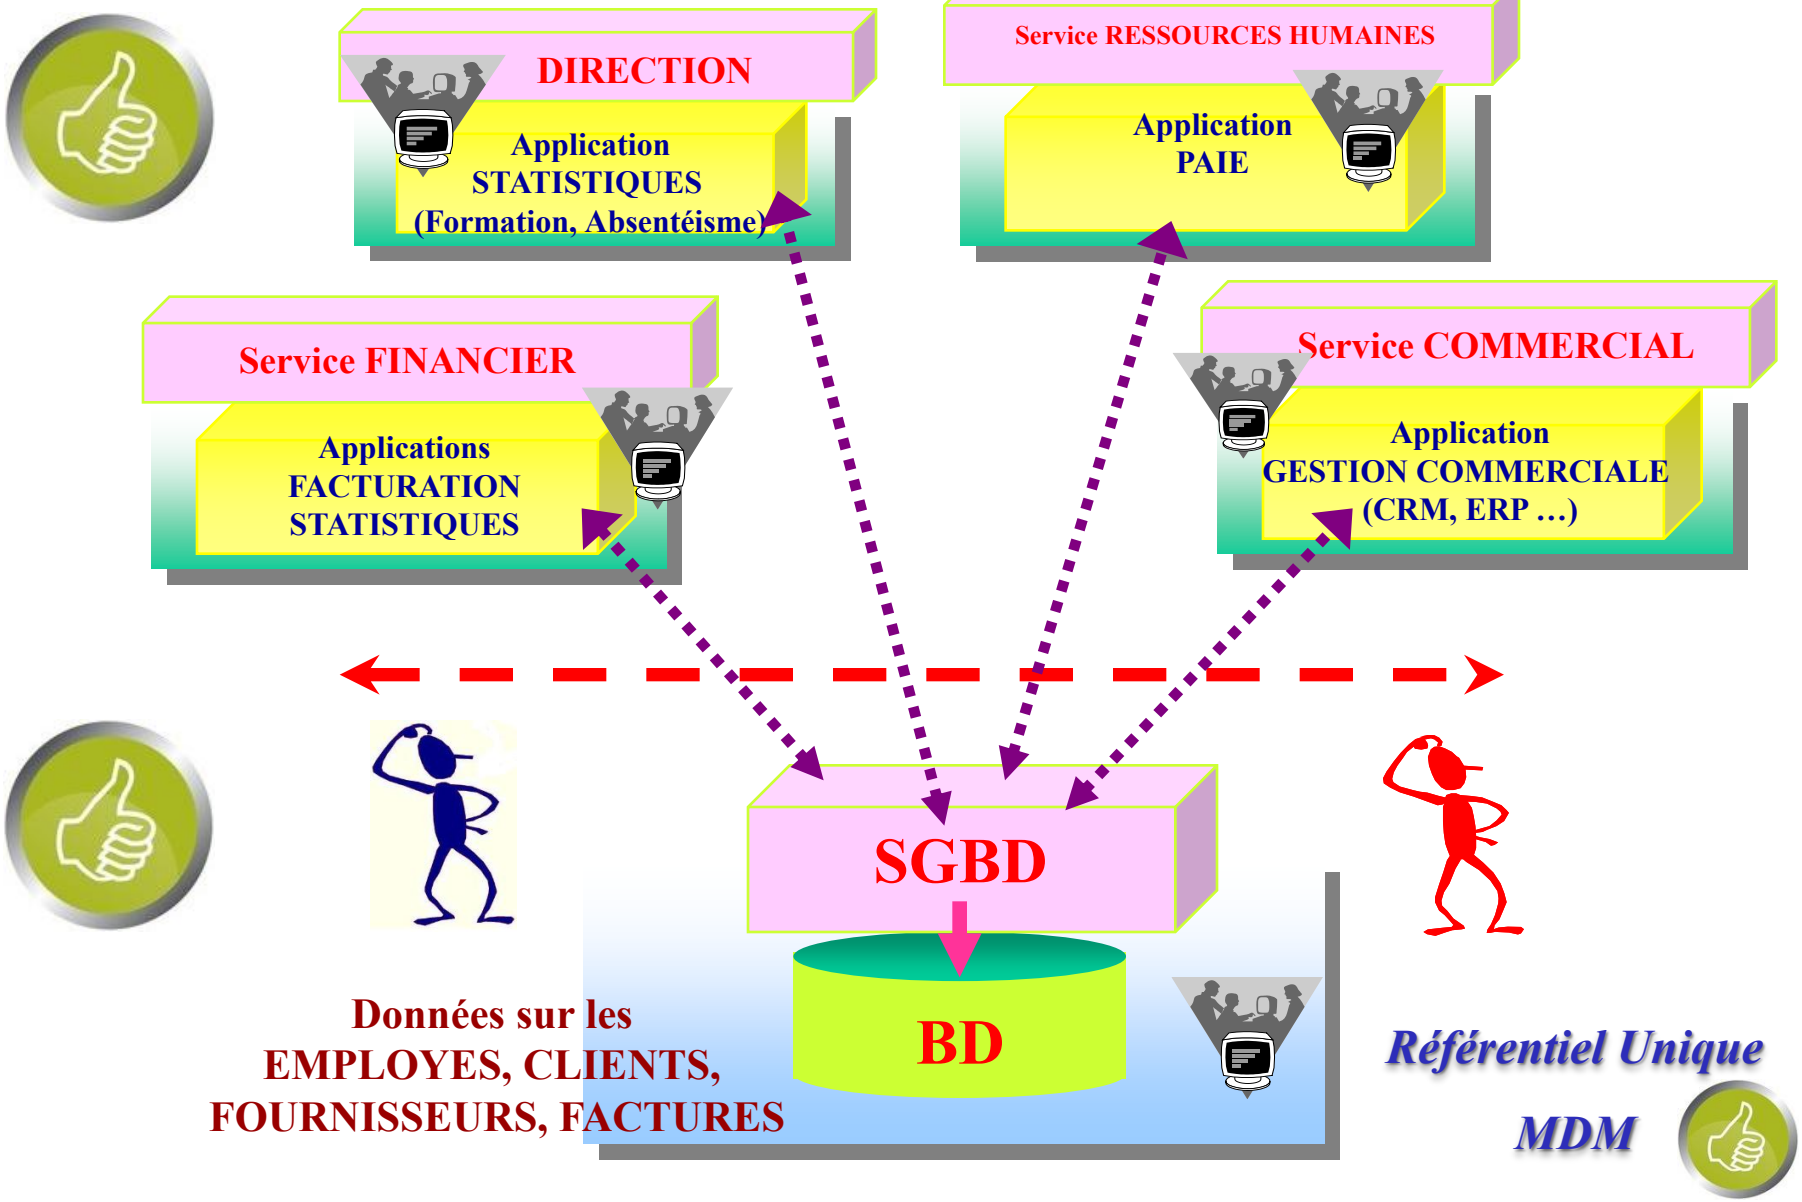


Risque d'incohérence

Service / Fichier /BD	Données dans les fichiers, les Bases de Données
Direction / Personnel	1709, Monsieur, **RAHMA Clément**, Paris, 0145570679
Service Commercial	1709, M, RAHMA Clément, Paris 19è, 0614560641, Nord Est
Service Ressources Humaines	1709, M, RAHMA Clément, Paris 19è, 0614014575, 17/09/1958
Service Financier	1709, Mlle, **RAHMA C**.

1 Personnel = 1 Commercial = 1 Employé

défini de plusieurs façons selon les services !!! et selon les applications !!!


DIRECTION
Application
STATISTIQUES
(Formation, Absentéisme)
Service RESSOURCES HUMAINES
Application
PAIE
Service FINANCIER
Applications
FACTURATION
STATISTIQUES
Service COMMERCIAL
Application
GESTION COMMERCIALE
(CRM, ERP …)
SGBD
BD
Données sur les
EMPLOYES, CLIENTS,
FOURNISSEURS, FACTURES
Référentiel Unique
MDM





Smart

1 Personnel = 1 Commercial = 1 Employé

défini d'une seule façon

Description **UNIQUE** du Personnel :

Numéro, Civilité, Nom Prénom, Adresse, Téléphone, Portable, Date d'embauche, Secteur, Nombre d'enfants, Type de Contrat, etc.



Valeur UNIQUE de l'information : **Donnée UNIQUE**

1709, Monsieur, RAHMA Clément, Paris 15è, 0145750679, 0614560641, 01/01/1994, Nord Est, 1, CDI, ...



Référentiel Unique

MDM



Il n'y a plus de risque d'incohérence

Service / Fichier /BD	**Données dans les fichiers, les Bases de Données**
Direction / Personnel	1709, Monsieur, **RAHMA Clément**, Paris 15è, 0145570679
Service Commercial	1709, Monsieur, RAHMA Clément, Paris 15è, 0614560641, Nord Est
Service Ressources Humaines	1709, Monsieur, RAHMA Clément, Paris 15è, 0145570679, 0614560641,17/09/1958
Service Financier	1709, Monsieur, **RAHMA Clément**



- **intégrer toutes les données** pertinentes à un système dans une même structure que l'on nomme une **Base de Données de référence** ;

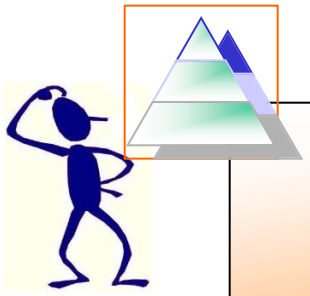
- **offrir une vision (vue) partielle de l'ensemble des données** à chaque utilisateur. Cette vision correspond aux besoins de chacun ;

- **assurer le partage des données** entre les différents utilisateurs

Conception , Modélisation & Implantation de BD …



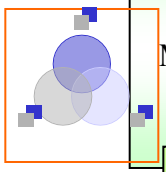
Concepteur ; Développeur ; Utilisateur ; Administrateur



Conception & Modélisation de BD

Méthodes, Modèles, Formalismes
Modèle Entité-Association E/A / Modèle **Entité-Association étendu**
Modèles Objet , Formalisme **UML, …**





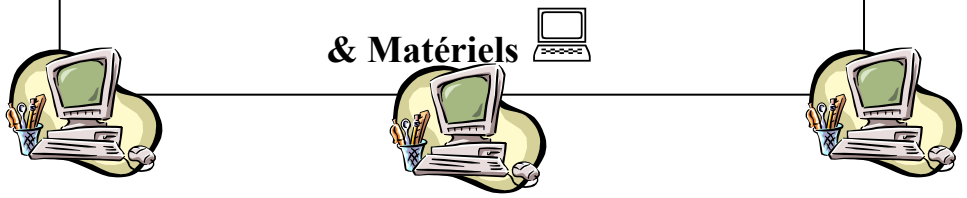
Implantation de BD

Modèle **Relationnel (Structuré)** / Modèle Objet-Relationnel / Modèle Objet / Modèle **NON relationnel (Non Structuré)**
Optimisation du schéma (Normalisation, Dénormalisation…)

SGBD **Relationnel** / SGBD Objet-Relationnel / SGBD Orienté Objet, SGBD **Non Relationnel**
Langages (**SQL, PL/SQL**, PRO*C, JDBC, Java, C++, Python, PHP…)
Optimisations (Groupement, Index, …)
Administration

Logiciels (SGBD, Interfaces, …)

& Matériels



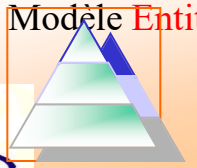
Conception , Modélisation & Implantation de BD …

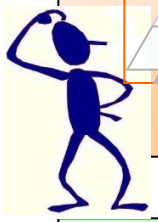


Concepteur ; Utilisateur ; Développeur ; Administrateur



Méthode, Modèle, Formalisme
Modèle Entité-Association E/A (ER) / Modèle **Entité-Asso**
Modèles Objet
Formalisme **UML**





Power AMC, Power Designer
WinDev, Oracle Designer
Rational Rose, …

ETAPE CONCEPTUELLE

ETAPE LOGIQUE

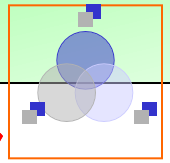
Modèle **Relationnel** / Modèle **Objet-Relationnel** / Modèle Objet
Optimisation du schéma (Normalisation, …), **Règles de passage ;** Modèle **NON Relationnel**

SQL :
Oracle, DB2,
MySQL,
PostgreSQL, …
NoSQL :
MongoDB,
Hbase, …
Talend, Tableau
BO…

SGBD Relationnel / SGBD Objet-Relationnel / SGBD Orienté Objet
SGBD Non Relationnel

Langages (**SQL, PL/SQL**, PRO*C, JDBC, Java, C++, Python, PHP…)
Optimisations (Groupement, Index, …) - Administration

ETAPE PHYSIQUE



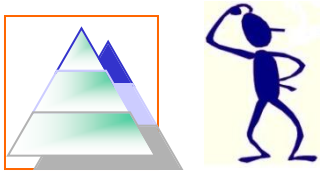


Systèmes de Gestion de Bases de Données
Autres outils d'intégration et de visualisation





Conception & Modélisation de BD ...



Une des tâches essentielles des développeurs de bases de données est la conception du schéma des bases.

L'objectif est de structurer le domaine d'application afin de le représenter sous plusieurs formes telles que des types et des tables et d'accompagner ces structures de contraintes sur les données afin de tirer plus de sémantique.

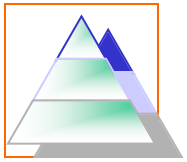
La représentation doit être :

- **juste** pour éviter les erreurs sémantiques, notamment dans les réponses aux requêtes ;
- **complète** pour permettre le développement des programmes d'application souhaités ;
- **évolutive** afin de supporter la prise en compte rapide de nouvelles demandes.

Remarque :

De nos jours, on parle aussi de **données sans schéma préétabli** (données **non structurées**) !

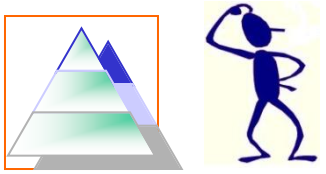
Conception & Modélisation de BD …



Traditionnellement, la démarche de conception s'effectue par abstractions successives, en descendant depuis les problèmes de l'utilisateur vers le Système de Gestion de Bases de Données.

Plusieurs étapes ont été distinguées et proposées :

1. **Perception du monde réel et capture des besoins**
2. **Élaboration du schéma conceptuel**
3. **Conception & Affinement du schéma logique**
4. **Élaboration du schéma physique**



1. Perception du monde réel et capture des besoins

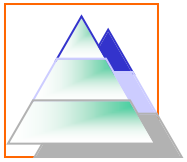
Cette étape consiste à étudier les problèmes des utilisateurs et à comprendre leurs besoins.

Elle comporte des entretiens, des analyses des flux d'information et des processus métier.

Comme il est difficile de comprendre le problème dans son ensemble, les concepteurs réalisent des études de cas partiels.

Le résultat se compose donc d'un ensemble de vues ou schémas externes qu'il faut intégrer dans l'étape suivante.

Ces vues sont exprimées dans un modèle de données (de type entité-association ou objet), selon la méthode choisie.



2. Élaboration du schéma conceptuel

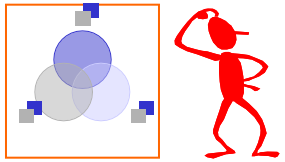
Cette étape est basée sur l'intégration des schémas externes obtenus à l'étape précédente.

Chaque composant est un schéma conceptuel (diagramme entité-association, diagramme de classes). Il résulte d'un modèle de problème représentant une partie de l'application.

La difficulté est d'intégrer toutes les parties dans un schéma conceptuel global complet, non redondant et cohérent.

Des allers et retours avec l'étape précédente sont souvent nécessaires.

Implantation de BD ...



3. Conception & Affinement du schéma logique

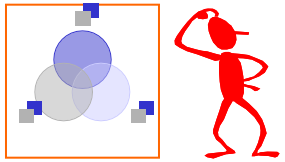
Cette étape réalise la transformation du schéma conceptuel en structures de données supportées par le système choisi : le schéma logique.

Avec un SGBD relationnel, il s'agit de passer à des tables.

Avec un SGBD relationnel-objet, il est possible de générer des types et des tables, les types étant réutilisables.

Avec un SGBD objet, il s'agit de générer des classes et des associations.

Cette étape peut être partiellement ou même complètement automatisée.



3. Conception & Affinement du schéma logique

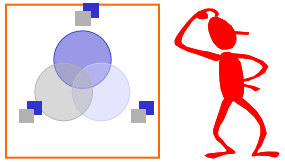
Une question qui se pose est de savoir si le schéma logique est un « bon » schéma.

A titre de première approximation, un « bon schéma » est un schéma sans oublis ni redondances d'informations.

Pour caractériser plus précisément les « bons » schémas, le modèle relationnel s'appuie sur la théorie de la normalisation, qui peut être avantageusement appliquée à ce niveau.

En relationnel, l'objectif est de regrouper ou décomposer les tables de manière à représenter fidèlement le monde réel modélisé.

Implantation de BD ...



4. Élaboration du schéma physique

Cette étape est nécessaire pour obtenir de bonnes performances.

Elle nécessite la prise en compte de toutes les transactions, concernant les applications traitées, afin de déterminer les accès fréquents.

A partir de là, il faut choisir les bonnes structures physiques : groupage ou partitionnement de tables, index, etc.
C'est là que se joue pour une bonne part les performances des applications.

L'étape 1 appartient plutôt au domaine du génie logiciel.
Les étapes 2, 3 et 4 font largement partie du domaine des bases de données.

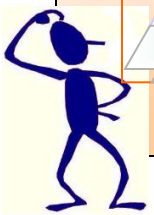
Conception , Modélisation & Implantation de BD …



Concepteur ; Utilisateur ; Développeur ; Administrateur

Méthode, Modèle, Formalisme
Modèle Entité-Association E/A (ER) / Modèle **Entité-Asso**
Modèles Objet
Formalisme **UML**

Power AMC, Power Designer
WinDev, Oracle Designer
Rational Rose, …



ETAPE CONCEPTUELLE

ETAPE LOGIQUE

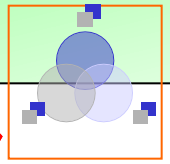
Modèle **Relationnel** / Modèle **Objet-Relationnel** / Modèle Objet
Optimisation du schéma (Normalisation, …), **Règles de passage**

SQL :
Oracle, DB2,
MySQL,
PostgreSQL, …
NoSQL :
MongoDB,
Hbase, …
Talend, Tableau
BO…

SGBD Relationnel / **SGBD Objet-Relationnel** / SGBD Orienté Objet
SGBD Non Relationnel

Langages (**SQL, PL/SQL**, PRO*C, JDBC, Java, C++, Python, PHP…)
Optimisations (Groupement, Index, …) - Administration

ETAPE PHYSIQUE

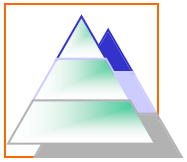




Systèmes de Gestion de Bases de Données
Autres outils d'intégration et de visualisation



BD





Élaboration du schéma conceptuel

Formalisme ER

Entité, Association

Type d'Entité, Type d'Association

Attribut/Propriété

Cardinalité

Dépendance Fonctionnelle

Forme Normale

Héritage, Agrégation, Composition

…





Formalisme UML

Objet

Classe

Attribut/Propriété

Multiplicité

…

…

Héritage, Agrégation, Composition

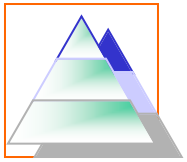
…

Diagramme ER

Diagramme de Classes

Schémas conceptuels



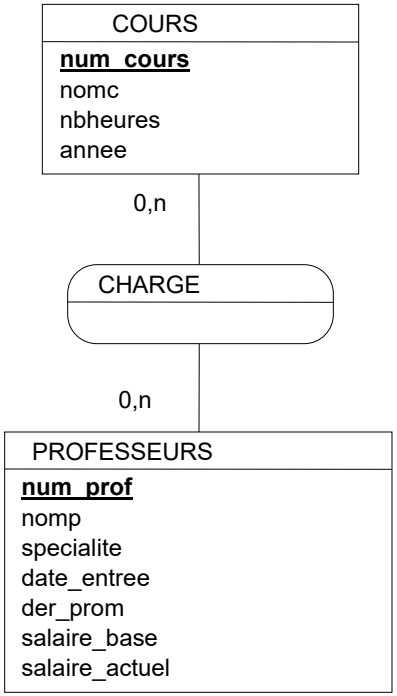




Élaboration du schéma conceptuel

Formalisme ER

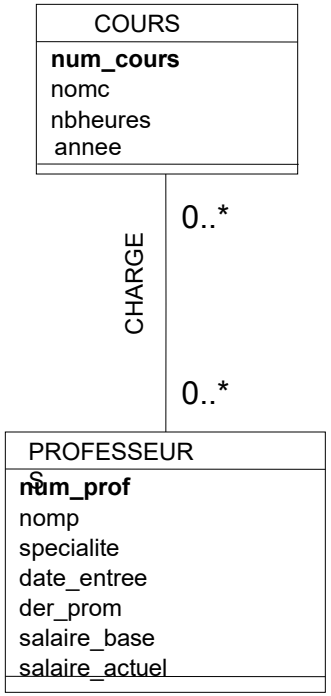
Diagramme ER







Schémas conceptuels

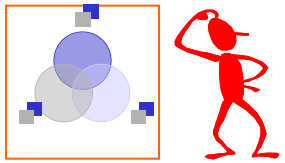


Formalisme UML

Diagramme de Classes



Implantation de BD ...



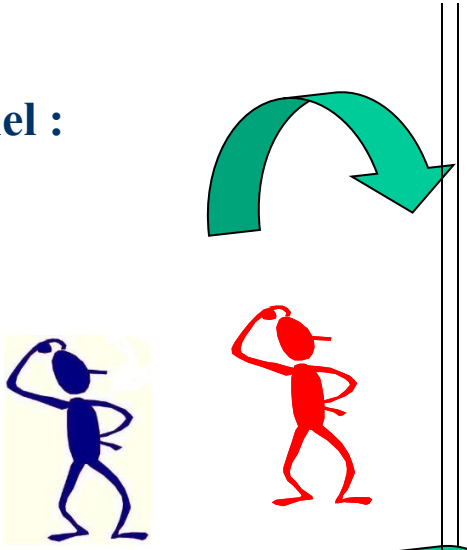
Élaboration du schéma Logique

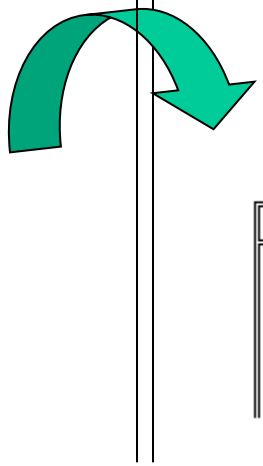
Règles de passage vers le relationnel :

Entité/Classe vers Relation/table

Association vers Relation/table

Association vers Clé Etrangère



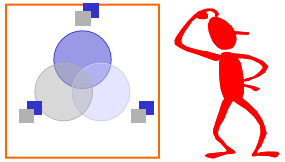


Règles de passage vers le relationnel-étendu (objet-relationnel, relationnel-objet, objet) :

Quelle est la table qui contient l'autre ?

On parle d'approche NF^2 (*Non First Normal Form*)

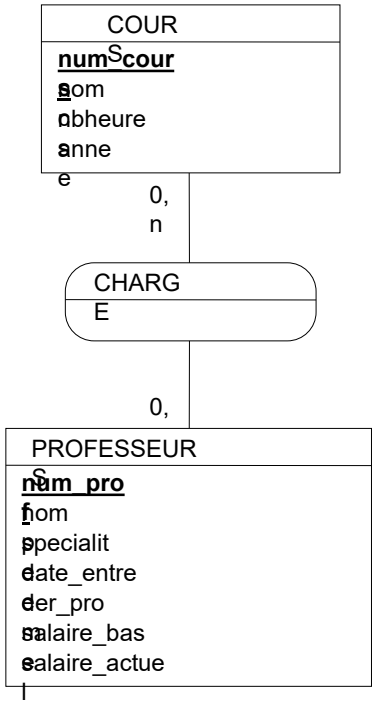
Implantation de BD ...

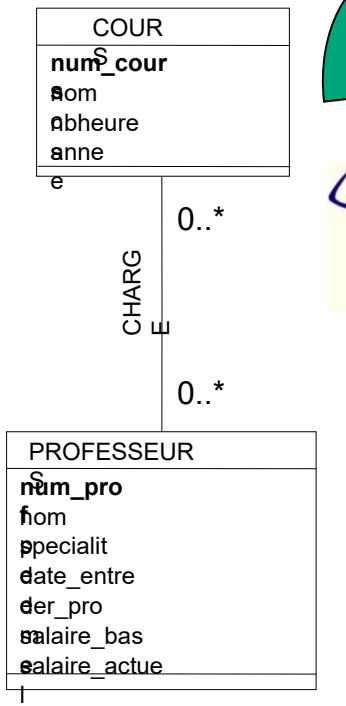


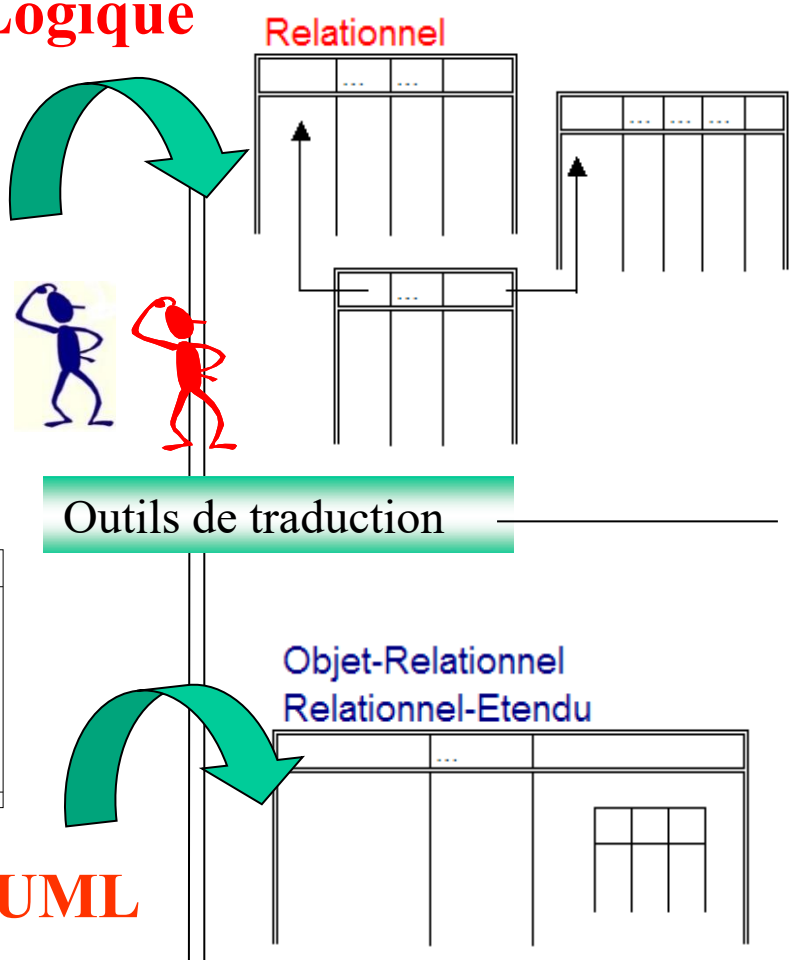
Élaboration du schéma Logique

Formalisme ER

Diagramme ER



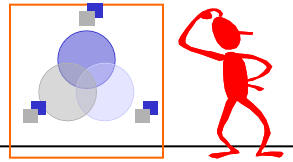




Formalisme UML

Diagramme de Classes

Implantation de BD …



Définir une table/Créer une table

Élaboration du schéma Physique

Attributs → types de données de base (prédéfinis par le système)
Numérique, Alphanumérique (Caractère, Texte), Date, …
Attributs → types de données définis par l'utilisateur



Contraintes → contrôles de validités (Clés primaire et étrangère, …)



Caractéristiques physiques : Paramètres de stockage
- **Taux de remplissage des blocs, évolution …**
- **Lieu de stockage (disque, MC), parallélisme…**
- **Optimisations : Partitionnement, découpage**

SQL ???

2? 3? NoSQL?

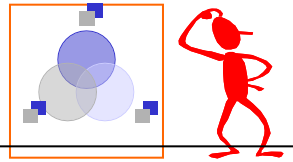
Définir les chemins d'accès aux données :
- **Indexer : Accélérer les traitements, Reconstruire les blocs…**



Construire des vues et des vues matérialisées (des pré-calculs,…)

Partager les données entre plusieurs utilisateurs
- **Créer des vues, des droits d'accès, des rôles, des profiles…**

Implantation de BD …



Construire des vues et des vues matérialisées (des pré-calculs,…)

…

Garder plusieurs versions des données,

construire des historiques,

des traces des mises à jour (Qui, Quand),

des mouvements/changements des données…

définir des déclencheurs/triggers

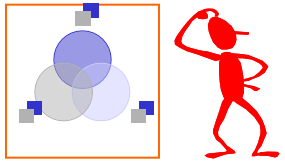


+++ !!! ???

Gestion du **temps**, **Historique**…
Plusieurs **versions** des données !

Gérer le temps…

Implantation de BD ...



Élaboration du schéma Physique (simplifié)

COURS (**NUM_COURS**, NOMC, NBHEURES, ANNEE)

PROFESSEURS (**NUM_PROF**, NOMP, SPECIALITE, DATE_ENTREE, DER_PROM, SALAIRE_BASE, SALAIRE_ACTUEL)

CHARGE(**NUM_PROF*, NUM_COURS***)

Schéma relationnel

```
create table COURS
(NUM_COURS        NUMBER(2)          NOT NULL,
NOMC              VARCHAR(20)        NOT NULL,
NBHEURES          NUMBER(2),
ANNE              NUMBER(1),
constraint PK_COURS primary key (NUM_COURS) );

 create table PROFESSEURS
(NUM_PROF         NUMBER(4)          NOT NULL,
NOMP              VARCHAR2(25)       NOT NULL,
SPECIALITE        VARCHAR2(20),
DATE_ENTREE       DATE,
DER_PROM          DATE,
SALAIRE_BASE      NUMBER,
SALAIRE_ACTUEL    NUMBER,
constraint PK_PROFESSEURS primary key (NUM_PROF) );

create table CHARGE
(NUM_PROF         NUMBER(4)  NOT NULL,
NUM_COURS         NUMBER(4)  NOT NULL,
constraint PK_CHARGE primary key (NUM_COURS, NUM_PROF) );
```

SQL$_2$

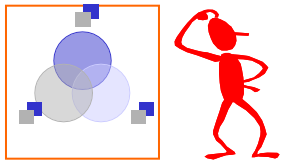





```
alter table CHARGE
  add constraint FK_CHARGE_COURS
    foreign key  (NUM_COURS)
     references COURS (NUM_COURS) ;

alter table CHARGE
  add constraint FK_CHARGE_PROFESSEUR
    foreign key  (NUM_PROF)
     references PROFESSEURS (NUM_PROF) ;
```

Implantation de BD ...



Élaboration du schéma Physique (simplifié)

```
create table COURS
(NUM_COURS        NUMBER(2),
NOMC              VARCHAR(20),
NBHEURES          NUMBER(2),
ANNE  NUMBER(1),
constraint PK_COURS primary key (NUM_COURS),
constraint NN__COURS_NOMC check  (NOMC  IS NOT NULL));

 create table PROFESSEURS
(NUM_PROF         NUMBER(4),
NOMP              VARCHAR2(25),
SPECIALITE        VARCHAR2(20),
DATE_ENTREE       DATE,
DER_PROM          DATE,
SALAIRE_BASE      NUMBER,
SALAIRE_ACTUE   NUMBER,
constraint PK_PROFESSEURS primary key (NUM_PROF),
constraint NN__PROFESSEURS_NOMP check  (NOMP  IS NOT NULL));

create table CHARGE
(NUM_PROF         NUMBER(4),   NUM_COURS          NUMBER(4),,
constraint PK_CHARGE primary key (NUM_COURS, NUM_PROF) );
```

SQL_2



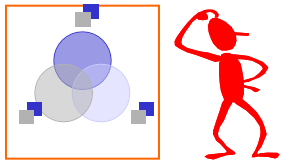


Insuffisant !

```
alter table CHARGE
      add constraint FK_CHARGE_COURS foreign key  (NUM_COURS) references COURS (NUM_COURS) ;

alter table CHARGE
      add constraint FK_CHARGE_PROFESSEURS foreign key  (NUM_PROF) references PROFESSEURS (NUM_PROF) ;
```

Implantation de BD ...



Élaboration du schéma Physique (simplifié)

COURS (NUM_COURS, NOMC, NBHEURES, ANNEE)

PROFESSEURS (**NUM_PROF**, NOMP, SPECIALITE, DATE_ENTREE, DER_PROM, SALAIRE_BASE, SALAIRE_ACTUEL, **Ensemble-de (COURS)**)

Schéma relationnel**-objet**

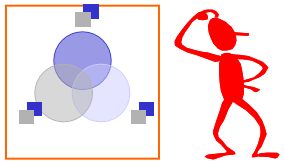
```
create  type cours_type as object
(num_cours number(2), nomc varchar2(20), nbheures number(2), annee number(1) )
/
create  type lescours_type as table of cours_type
/
create  type professeur_type as object
(num_prof number(4), nom varchar2(25), specialite varchar2(20), cours lescours_type ...)
/
create table professeur of professeur_type
(primary key (num_prof))
nested table cours store as tabemp
/
```

SQL_3...

SQLOO – SQL Orienté Objet

+++ Partie statique + Partie dynamique (méthodes)

Implantation de BD ...



Élaboration du schéma Physique (simplifié)

Types Objet --- Création/Destruction d'un type

```
CREATE [OR REPLACE TYPE] schéma.nomType
                    [AS OBJECT | UNDER schéma.nomSurType]
(
colonne1 type1, colonne2 type2, …,          ☚ Structure
méthode1 (paramètres1), méthode2 (paramètres2) …  ☚ Comportement
)
[[NOT] INSTANCIABLE]
[[NOT] FINAL]                               ☚ Relatif à l'héritage
/
```

SQL$_{3...}$ --- SQLOO – SQL Orienté Objet

```
DROP TYPE nomType [FORCE | VALIDATE] ;
```

Schéma Conceptuel ①

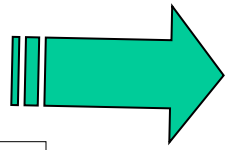
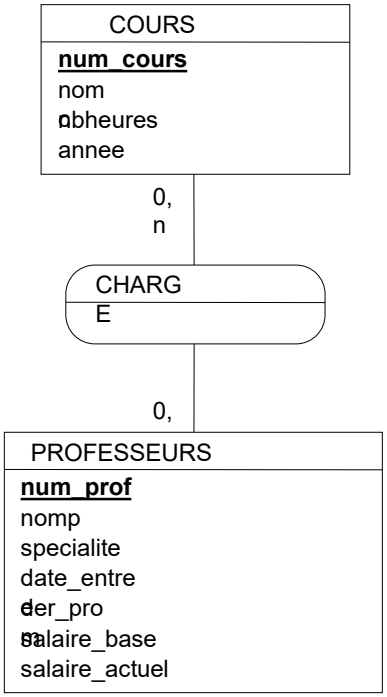
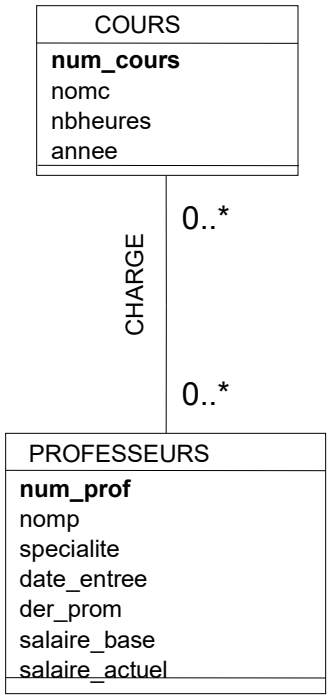


Schéma Logique ②

Formalisme ER

Diagramme ER

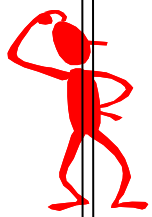




Formalisme UML

Diagramme de Classes





Relationnel

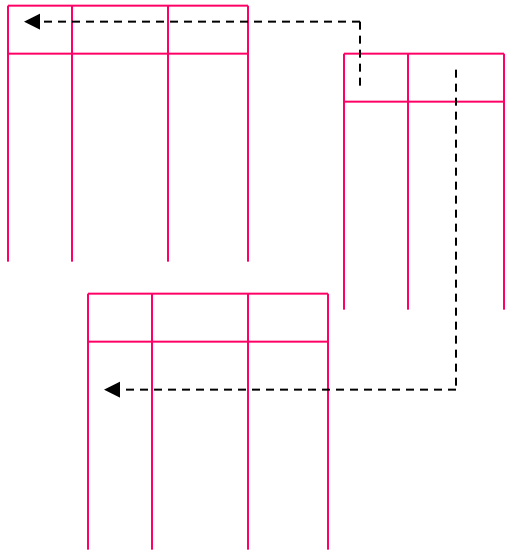


Schéma relationnel

COURS (**NUM_COURS**, NOMC, NBHEURES, ANNEE)

PROFESSEURS (**NUM_PROF**, NOMP, SPECIALITE, DATE_ENTREE, DER_PROM, SALAIRE_BASE, SALAIRE_ACTUEL)

CHARGE(**NUM_PROF*, NUM_COURS***)

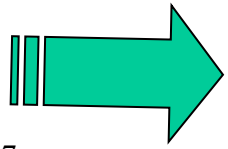
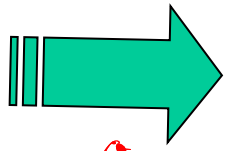


Schéma Physique ③ ??? !!!



Implantation de BD …

Schéma Physique (??? !!!)

SQL

Définir une table

Attributs → types de données



Contraintes → contrôles de validités :

PROBLEME DE COHERENCE GLOBALE

PROBLEME DE QUALITE DE DONNEES



Caractéristiques physiques : Paramètres de stockage

Taux de remplissage des blocs, évolution … Lieu de stockage, parallélisme…

Optimisations : Partitionnement, découpage

Définir les chemins d'accès aux données



Construire des vues et des vues matérialisées (des pré-calculs,…)

Partager les données entre plusieurs utilisateurs :

PROBLEME DE COHERENCE, DE CONFIDENTIALITE, DE SECURITE

Implantation de BD ...

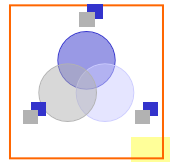


Schéma Physique (1ère version)

SQL$_2$

```
create table COURS
(NUM_COURS     NUMBER(2),
NOMC           VARCHAR(20),
NBHEURES       NUMBER(2),
ANNE           NUMBER(1),
constraint PK_COURS primary key (NUM_COURS),
constraint NN__COURS_NOMC check  (NOMC  IS NOT NULL)   );
```



```
create table PROFESSEURS
(NUM_PROF              NUMBER(4),
NOMP                   VARCHAR2(25),
SPECIALITE             VARCHAR2(20),
DATE_ENTREE            DATE,
DER_PROM               DATE,
SALAIRE_BASE           NUMBER,
SALAIRE_ACTUEL         NUMBER,
constraint PK_PROFESSEURS primary key (NUM_PROF)
constraint NN__PROFESSEURS_NOMP check  (NOMP  IS NOT NULL)  );
```

Attributs + Contraintes

(Domaine/type de données)

(Clés Primaire et Etrangère)

(Vérifications/Check telles que Non Nulle, etc)



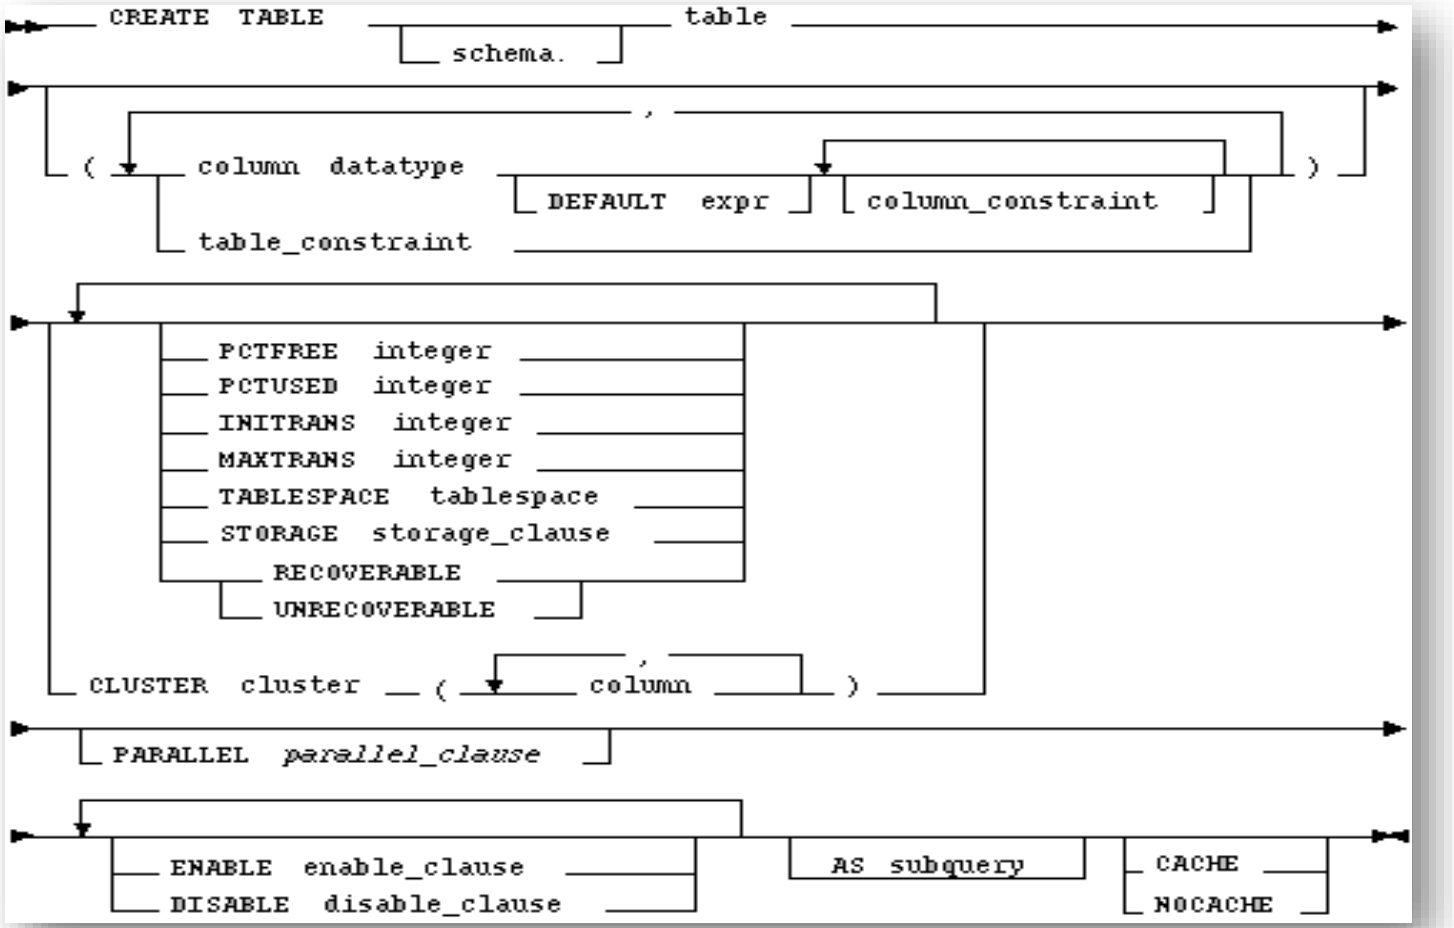
Insuffisant !

```
create table CHARGE
(NUM_PROF      NUMBER(4),
NUM_COURS      NUMBER(4),
constraint PK_CHARGE primary key (NUM_COURS, NUM_PROF)
constraint FK_CHARGE_COURS  foreign key  (NUM_COURS)  references COURS (NUM_COURS)
constraint FK_CHARGE_PROFESSEURS  foreign key  (NUM_PROF)  references PROFESSEURS (NUM_PROF) );
```

Implantation de BD / Administration d'une BD

La commande Create table crée une table, elle définit ses colonnes, contraintes et **paramètres de stockage**.

Une syntaxe de la commande Create table est :



Implantation de BD / Administration d'une BD

Les paramètres de stockage peuvent être résumés par : le lieu, le taux de remplissage, la manière d'évoluer et la manière d'être traitée !







CREATE TABLE nomtable (attributs , contraintes)

TABLESPACE nomtablespace
PCTUSED x1
PCTFREE x2
INITRANS x3
MAXTRANS x4
STORAGE (INITIAL n1 NEXT n2
MINEXTENTS m1 MAXEXTENTS m2
PCTINCREASE p)
PARALLEL p / NOPARALLEL (appliquer le parallélisme)
LOGGING / NOLOGGING (pour ne pas copier les mises à jour dans le rollback)
CACHE / NOCACHE (permet de garder la table en mémoire : à utiliser avec précaution)
PARTITIONnement (une sorte de découpage de la table)
;

Structure d'une base de données oracle

Toute base de données oracle possède une structure logique, une structure physique et un ensemble de vues donnant des visions partielles aux utilisateurs. La description de ces trois niveaux et la correspondance entre eux est faite à travers le dictionnaire de données.

- Structure physique d'une BD oracle : Elle est composée d'un ensemble de fichiers qui constituent le support physique de stockage de données.
Les trois types de fichiers sont : les fichiers de données (**Data Files**), les fichiers de reprises (**Redolog Files**) et les fichiers de contrôles (**Control Files**).

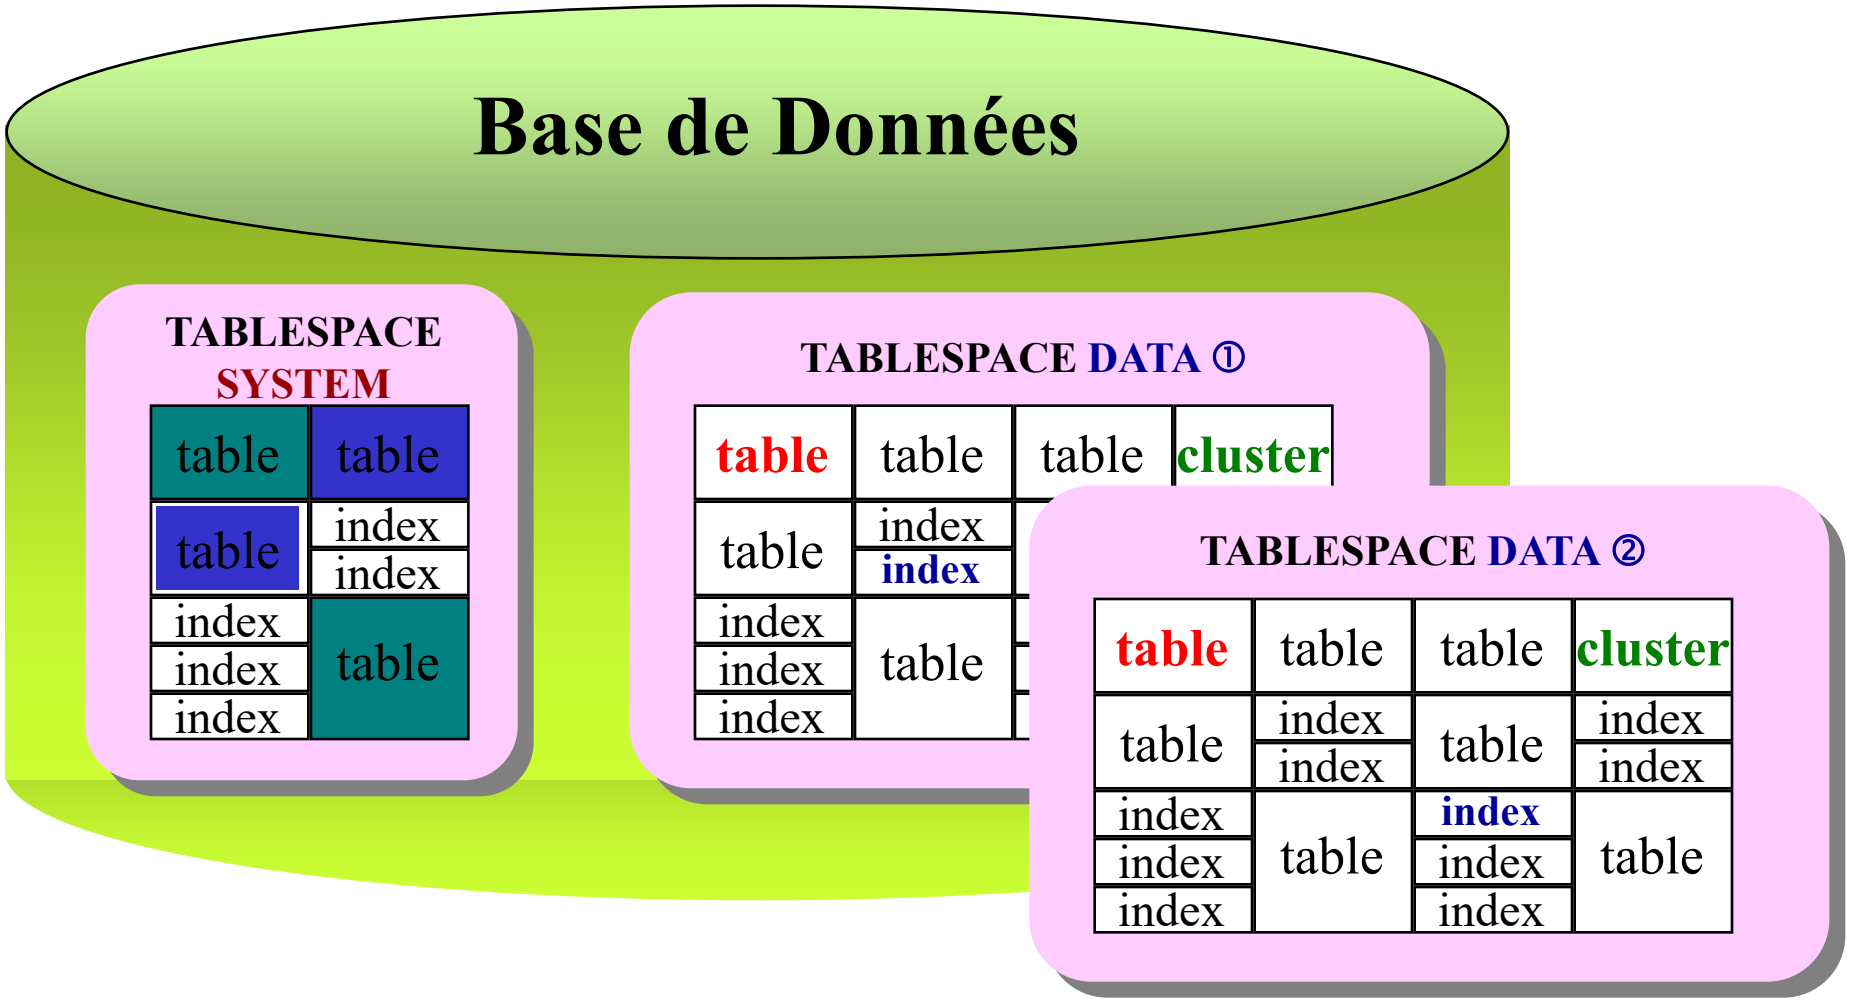
- Structure logique d'une BD oracle : Elle est composée des **tables spaces**, des **segments**, des **extensions** et des **blocs**.

Structure d'une base

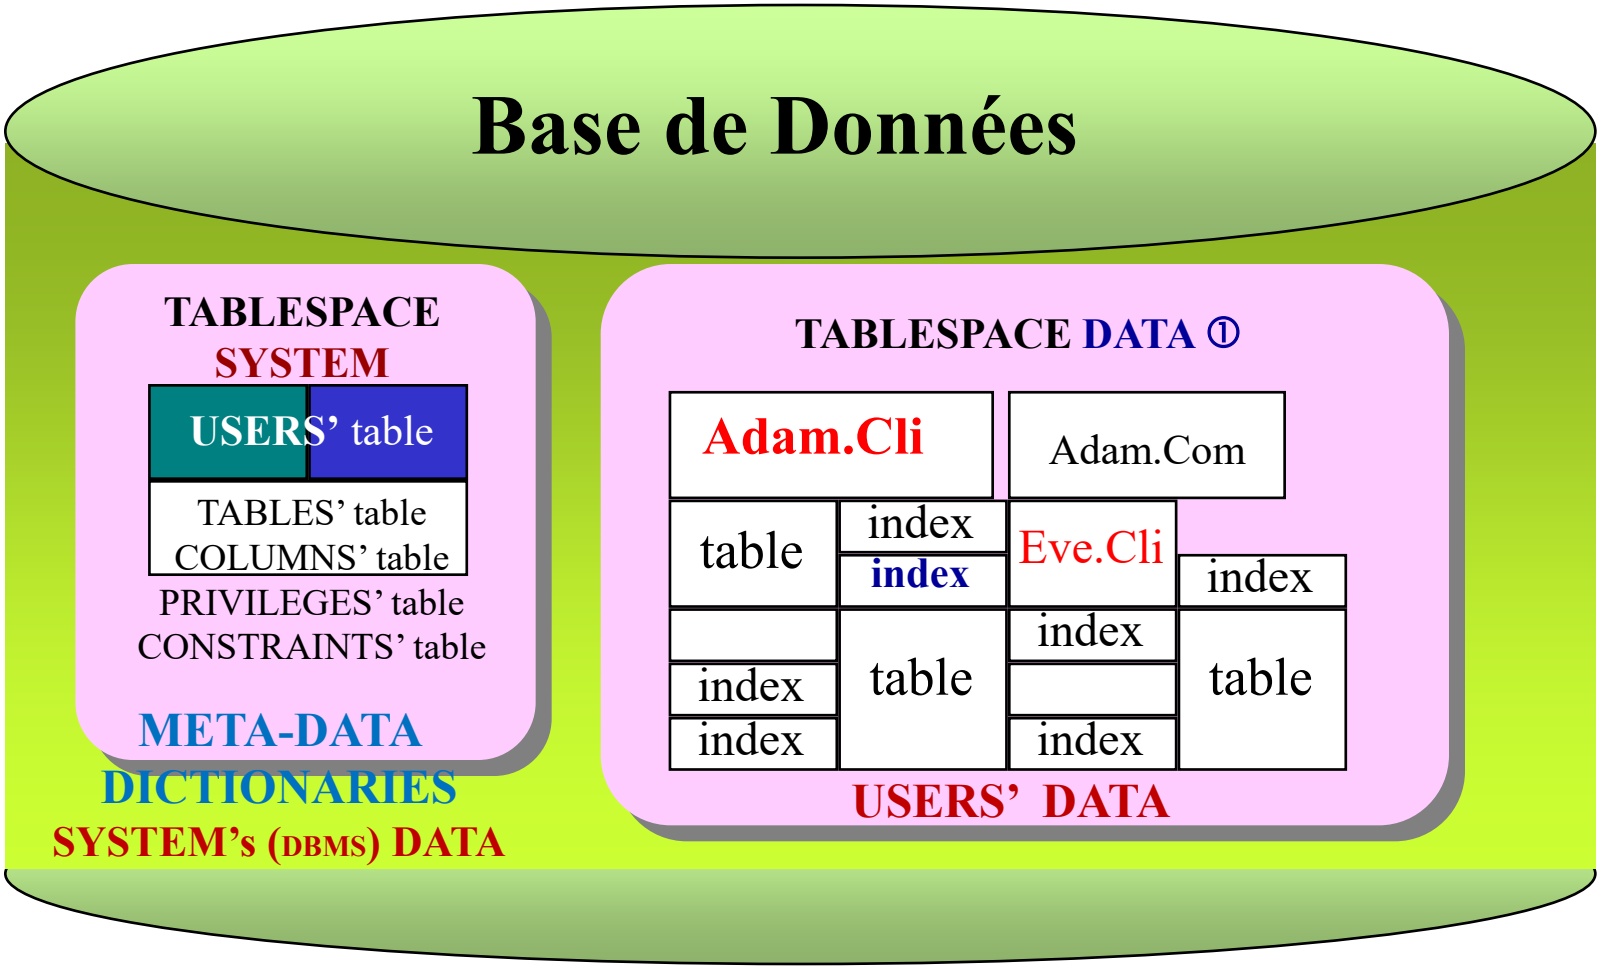
Une base de données est composée de :

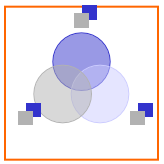
- Instance : il s'agit des processus qui gèrent :
  - La cohérence de la base
  - La mise à jour, rollback, commit
  - etc...
- Fichiers qui composent la base de données :
  - fichier rollback
  - fichier tablespace

Structure d'une base

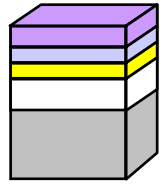


Structure d'une base



Implantation de BD / Administration d'une BD



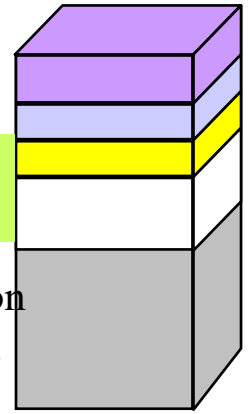
BLOC de données

- Un bloc de données est la plus petite unité logique d'entrée/sortie utilisée par un SGBD tel que Oracle
- Appelé également *Bloc logique* ou *Page*
- A distinguer du bloc physique utilisé par les systèmes d'exploitation [Operating System]

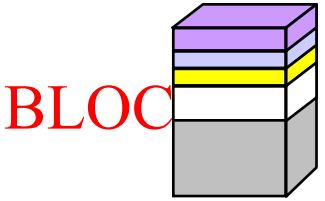
  (*bloc physique = ensemble d'octets sur disque*)
- Taille d'un bloc de données
  - attribuée par défaut selon OS (2 , 4 ou 8 Ko)
  - modifiable par DB_BLOCK_SIZE = n

Format d'un bloc de données

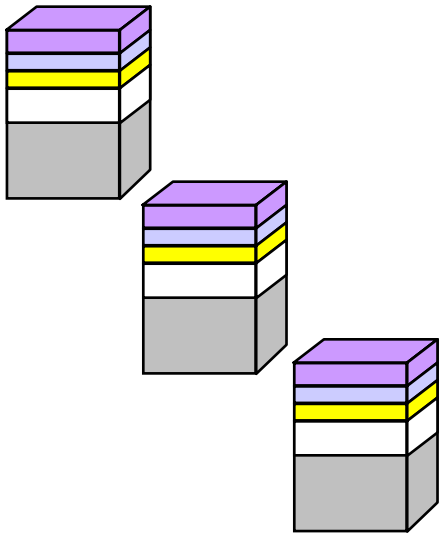
Les blocs de données sont organisés de la même façon quelque soit leur contenu : données, index ou cluster.



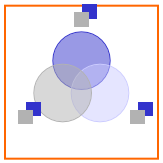
Format d'un bloc de données



- L'entête : contient des informations générales (telles que : adresse du bloc, type du segment)
- Liste des tables : utilisée uniquement pour les clusters, contient des informations relatives aux tables groupées ayant des données dans ce bloc
- Liste des lignes : contient des informations relatives aux lignes situées dans ce bloc (adresse)
- Espace libre : utilisé pour l'insertion de nouvelles lignes ou la mise à jour des lignes nécessitant de l'espace
- le reste du bloc est réservé aux données.







Implantation de BD / Administration d'une BD

Bloc de Données ORIGINAL

Clé	Nom Prénom...
2	Adam CAVALIER
3	Eve CVALIER
7	Inès BOOK

→

Bloc de Données COPIE

Clé	Nom Prénom...
2	Adam CAVALIER
3	Eve **CAVALIER**
7	Inès BOOK

Mise à jour des données **MODIFICATION** : **CVALIER ➔CAVALIER**

Mise à jour des données **INSERTION** : **5 Lina LEBON**

Bloc de Données ORIGINAL

Clé	Nom Prénom...
2	Adam CAVALIER
3	Eve CAVALIER
7	Inès BOOK

→

Bloc de Données COPIE

Clé	Nom Prénom...
2	Adam CAVALIER
3	Eve CAVALIER

OU

Bloc de Données COPIE

Clé	Nom Prénom...
5	Lina LEBON
7	Inès BOOK

Créer deux blocs ?

↓

Bloc de Données COPIE

Clé	Nom Prénom...
2	Adam CAVALIER
3	Eve CAVALIER
5	Lina LEBON
7	Inès BOOK

Remplir au maximum le bloc ?

Mise à jour des données **SUPPRESSION** : **3 Eve CAVALIER**

Bloc de Données ORIGINAL

Clé	Nom Prénom...
2	Adam CAVALIER

→

Bloc de Données COPIE

Clé	Nom Prénom...
2	Adam CAVALIER
7	Inès BOOK

OU

Regrouper les deux blocs ?

Bloc de Données ORIGINAL

Clé	Nom Prénom...
3	Eve CAVALIER
7	Inès BOOK

→

Bloc de Données COPIE

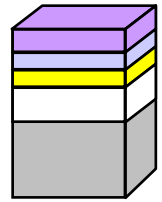
Clé	Nom Prénom...
2	Adam CAVALIER

Bloc de Données COPIE

Clé	Nom Prénom...
7	Inès BOOK

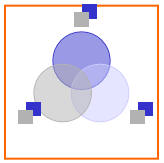
Garder les deux blocs ?



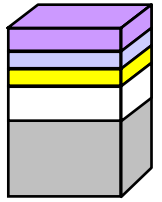


Gestion de l'espace des blocs

- Les paramètres *PCTFREE* et *PCTUSED* permettent de gérer l'espace libre des blocs de données.
- Ils sont utilisés dans les commandes de création ou de modification de tables, clusters, snapshot, snapshot log…
- Le paramètre PCTFREE peut être utilisé également dans les commandes de création et de modification d'index.

Implantation de BD / Administration d'une BD

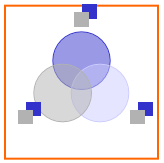


PCTFREE

- Fixe le *pourcentage d'espace* dans un bloc qui doit être maintenu libre pour les éventuelles mises à jour des lignes du bloc.
- Exemple : PCTFREE = 15
  - ↳ possibilité d'insérer de nouvelles lignes dans le bloc tant que l'espace libre > 15%.
- Critères de choix
  - mode d'utilisation de la table ou de l'index associé
  - supérieur à 10 si la mise à jour augmente souvent la taille
  - inférieur à 10 dans le cas contraire.

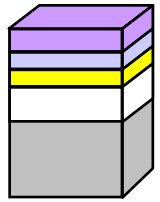
Chercher un compromis entre le gain d'espace et l'amélioration des performances

valeur faible : gain d'espace et dégradation des performances à cause de la fragmentation des données.
valeur élevée : perte d'espace et un gain de performances.

Implantation de BD / Administration d'une BD

PCTUSED



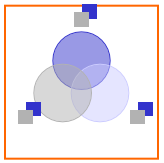
- Utilisé simultanément avec le paramètre PCTFREE (la valeur par défaut est 40).
  - un bloc est initialement vide
  - on y insère de nouvelles lignes jusqu'à atteindre PCTFREE
  - l'insertion de nouvelles lignes dans le bloc n'est possible que si le pourcentage d'espace utilisé devient inférieur à PCTUSED
  - on peut de nouveau insérer de nouvelles lignes jusqu'à ce que l'espace libre atteigne PCTFREE

- PCTFREE

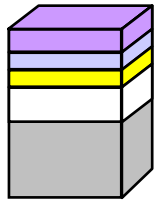
  Permet de spécifier l'espace libre laissé dans le bloc pour réaliser les mises à jour des lignes stockées dans le bloc.
  Par défaut, la valeur de ce paramètre est égale à 10.
  Dans tous les cas, la somme de PCTFREE et de PCTUSED ne peut excéder 100.
  Lorsque l'espace libre dans un bloc atteint PCTFREE, aucune nouvelle ligne n'est insérée dans le bloc.

- PCTUSED

  Lorsque l'on ne peut plus insérer de lignes dans le bloc (lorsque l'espace libre restant dans le bloc devient égal à PCTFREE), le bloc n'est plus utilisé pour insérer de nouvelles lignes tant que l'espace utilisé n'est pas redescendu en dessous de la valeur de PCTUSED.

Implantation de BD / Administration d'une BD

BLOC 

Les conséquences d'un **petit PCTFREE** :

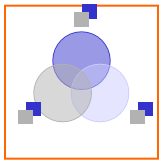
Moins d'espace est réservé au niveau du bloc pour effectuer les MAJ des lignes existantes
Permet aux insertions de mieux remplir le bloc
Permet d'économiser de l'espace dans la mesure où les blocs sont mieux remplis
Augmente le temps de traitement dans la mesure où Oracle doit régulièrement réorganiser les blocs lorsque l'on insère ou l'on modifie des lignes
Augmente les temps de traitement dans la mesure où les MAJ peuvent conduire à la génération de chaînages entre différents blocs

Un petit PCTFREE est utilisé pour les objets ayant une faible activité en mise à jour

Les conséquences d'un **grand PCTFREE** :

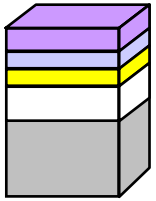
Plus d'espace est réservé au niveau du bloc pour effectuer les MAJ des lignes existantes
Plus de blocs peuvent être nécessaires pour gérer la même quantité de données (moins de lignes sont stockées dans les blocs)
Diminue le temps de traitement dans la mesure où les réorganisations des blocs sont moins nombreuses
Amélioration des performances en MAJ dans la mesure où les chaînages des blocs sont évités

Un grand PCTFREE est nécessaire pour les objets ayant une forte activité en mise à jour

Implantation de BD / Administration d'une BD

BLOC



Les conséquences d'un **petit PCTUSED**

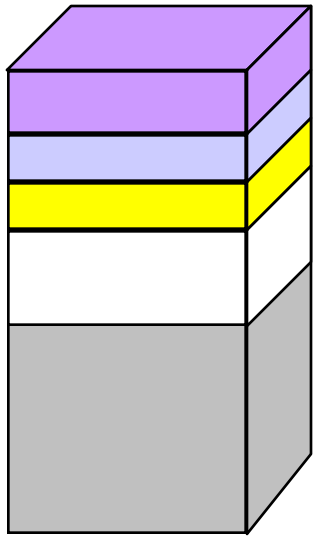
- Les blocs sont moins remplis
- Réduction des coûts de traitements lors des commandes INSERT UPDATE pour mettre à jour la FREELIST quand un bloc est utilisé à moins de PCTUSED pourcent
- Augmente la consommation d'espace dans la base de données

Les conséquences d'un **grand PCTUSED**

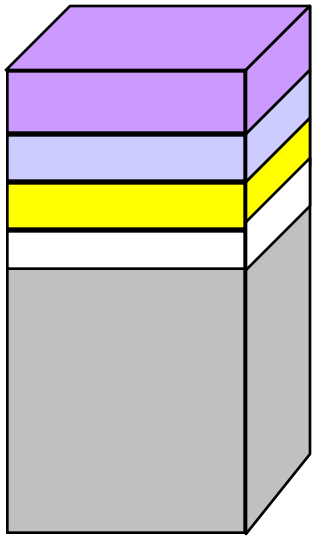
- Le blocs sont mieux remplis
- Amélioration de la gestion d'espace. Les blocs sont mieux remplis
- Augmente le coût des insertions et des mises à jour

Exemple PCTFREE et PCTUSED

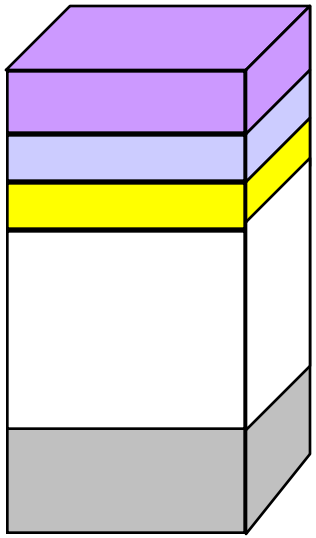
PCTFREE = 20, PCTUSED = 40



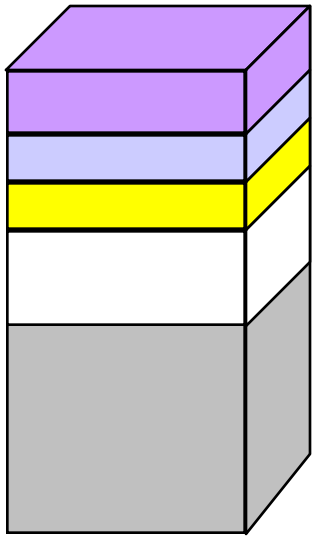
Lignes insérées jusqu'à 80% puisque PCTFREE est fixé à 20%



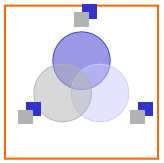
La mise à jour des lignes peut utiliser l'espace libre. Pas de nouvelles lignes insérées jusqu'à ce que l'espace utilisé redescende au dessous de 40%



Une fois l'espace utilisé descend au dessous de 40%, l'insertion de nouvelles lignes peut reprendre



Lignes insérées jusqu'à 80% puisque PCTFREE est fixé à 20%

Implantation de BD / Administration d'une BD

- INITRANS

  Nombre de transactions pouvant accéder simultanément aux lignes contenues dans un bloc.

  L'espace est réservé en entête de chaque bloc de données et d'index.

  La valeur par défaut est 1 pour les données et 2 pour les indexes
- MAXTRANS

  Le paramètre MAXTRANS permet de limiter le nombre de transactions
- FREELISTE

  Liste des blocs libres par objet. Par défaut, la valeur est égale à 1. En cas de contention sur la **freelist**, les performances des applications peuvent être altérées.

  Pour identifier ce problème, il suffit de consulter le contenu de la table **v$waitstat** de la façon suivante :

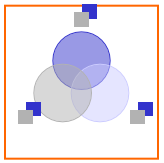
  select class, count waits from v$waitstat where class = 'freelist' ;

  Il faut ensuite comparer le nombre « waits » sur les blocs libres par rapport au nombre total de demandes de données sur la même période.

  select sum(value) gets from v$sysstat where name in ('db block gets','consistent gets') ;

  Si le ratio waits/gets est inférieur à 1%, il faut ajouter des freelist





Implantation de BD / Administration d'une BD

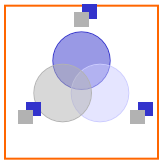
Schéma Physique (2ème version; paramètres de stockage)

```
create table COURS
(NUM_COURS     NUMBER(2),,
NOMC           VARCHAR(20),
NBHEURES       NUMBER(2),
ANNE           NUMBER(1),
constraint PK_COURS primary key (NUM_COURS),
constraint NN__COURS_NOMC check  (NOMC  IS NOT NULL)   )

TABLESPACE S_COURS_DATA
                PCTUSED    98
                PCTFREE    1
                INITRANS   1
                MAXTRANS   255
                STORAGE    (
                        INITIAL              11280K
                        NEXT                 11M
                        MINEXTENTS           1
                        MAXEXTENTS           unlimited
                        PCTINCREASE          0
                        FREELISTS            9
                        FREELIST GROUPS   1 )
              PARALLEL   ;
```

SQL_2



Implantation de BD / Administration d'une BD

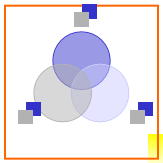
Schéma Physique (2ème version; paramètres de stockage)

SQL$_2$

```
 create table PROFESSEURS
(NUM_PROF                 NUMBER(4),
NOMP                      VARCHAR2(25),
SPECIALITE                VARCHAR2(20),
DATE_ENTREE               DATE,
DER_PROM                  DATE,
SALAIRE_BASE              NUMBER,
SALAIRE_ACTUEL            NUMBER,
constraint PK_PROFESSEURS primary key (NUM_PROF)
constraint NN__PROFESSEURS_NOMP check  (NOMP  IS NOT NULL)  )

TABLESPACE  S_PROF_DATA
            PCTUSED    98
            PCTFREE     1
            INITRANS    6
            MAXTRANS 255
            STORAGE (INITIAL 20M NEXT 5M)
            NOPARALLEL ;
```





Implantation de BD / Administration d'une BD

Schéma Physique (2ème version; paramètres de stockage)

```
create table CHARGE
(NUM_PROF       NUMBER(4),
NUM_COURS       NUMBER(4),
constraint PK_CHARGE primary key (NUM_COURS, NUM_PROF)
constraint FK_CHARGE_COURS  foreign key  (NUM_COURS)  references COURS (NUM_COURS)
constraint FK_CHARGE_PROFESSEURS  foreign key  (NUM_PROF)  references PROFESSEURS (NUM_PROF) )

TABLESPACE S_CHARGE_DATA
                PCTUSED    98
                PCTFREE    1
                INITRANS   1
                MAXTRANS   255
                STORAGE
                (          INITIAL          11280K
                           NEXT             11M
                           MINEXTENTS       1
                           MAXEXTENTS       unlimited
                           PCTINCREASE      0
                           FREELISTS        9          )
                PARALLEL  3 ;
```

SQL_2

Schéma Physique (3ième version; partitionnement)

Partitionnement des données

partitionnement des objets dans Orale

Techniques de partitionnement/fragmentation de tables

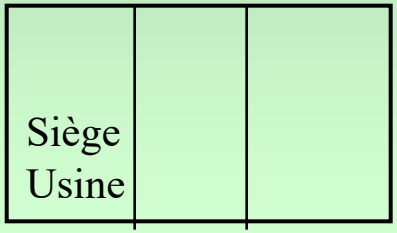
- Fragmentation horizontale

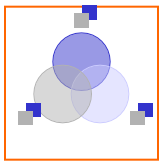
  –découpage horizontal de la table



- Fragmentation verticale

  –découpage vertical de la table



Implantation de BD / Administration d'une BD

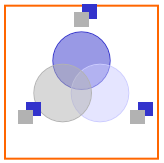
Schéma Physique (3ième version; partitionnement)

```
create table PROFESSEURS
        (NUM_PROF          NUMBER(4),
        … constraint PK_PROFESSEURS primary key (NUM_PROF) )
PARTITION BY RANGE (NUM_PROF)
(PARTITION P1 VALUES LESS THAN (1000)
      TABLESPACE ECOLE_PARIS,
 PARTITION P2 VALUES LESS THAN (2000)
      TABLESPACE ECOLE_TUNIS
);
```



SQL_2

```
select * from PROFESSEURS PARTITION (P1);
select * from PROFESSEURS PARTITION (P2);
```

Implantation de BD / Administration d'une BD

Schéma Physique (3ième version; partitionnement)

SQL$_2$

```
create table PROFESSEURS
                    (NUM_PROF              NUMBER(4),
                    … constraint PK_PROFESSEURS primary key (NUM_PROF) )

PARTITION BY RANGE (DATE_ENTRÉE)

(

PARTITION p_200312 VALUES LESS THAN

                    (to_date('2004-01-01','YYYY-MM-DD')),

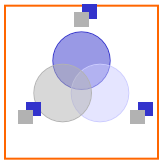
PARTITION p_200406 VALUES LESS THAN

                    (to_date('2004-07-01','YYYY-MM-DD')),

PARTITION p_200412 VALUES LESS THAN

                    (to_date('2005-01-01','YYYY-MM-DD'))

) ;
```

Implantation de BD / Administration d'une BD

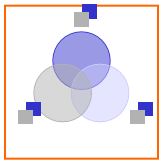
Schéma Physique (3ième version; partitionnement)

SQL_2

```
CREATE TABLE sales_by_region
(item# INTEGER, qty INTEGER, store_name VARCHAR(30), state_code VARCHAR(2), sale_date DATE)

STORAGE(INITIAL 10K NEXT 20K) TABLESPACE tbs5 PARTITION BY LIST (state_code)

 ( PARTITION region_east VALUES ('MA','NY','CT','NH','ME','MD','VA','PA','NJ')
                    STORAGE (INITIAL 8M) TABLESPACE tbs8,
PARTITION region_west VALUES ('CA','AZ','NM','OR','WA','UT','NV','CO')
                    NOLOGGING,
PARTITION region_south VALUES ('TX','KY','TN','LA','MS','AR','AL','GA'),
PARTITION region_central VALUES ('OH','ND','SD','MO','IL','MI','IA'),
PARTITION region_null VALUES (NULL),
PARTITION region_unknown VALUES (DEFAULT) );
```

Implantation de BD / Administration d'une BD

Schéma Physique (3ième version; déclencheurs/triggers)

SQL_2

CREATE OR REPLACE TRIGGER *schema.trigger_name*
BEFORE DELETE OR INSERT OR UPDATE ON *schema.table_name*
pl/sql_block

CREATE OR REPLACE TRIGGER hr.salary_check
BEFORE INSERT OR UPDATE OF salary, job_id ON hr.employees
FOR EACH ROW WHEN (new.job_id <> 'AD_VP')
pl/sql_block

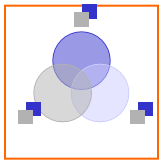



Schéma Physique (4ème version; Index)

SQL_2

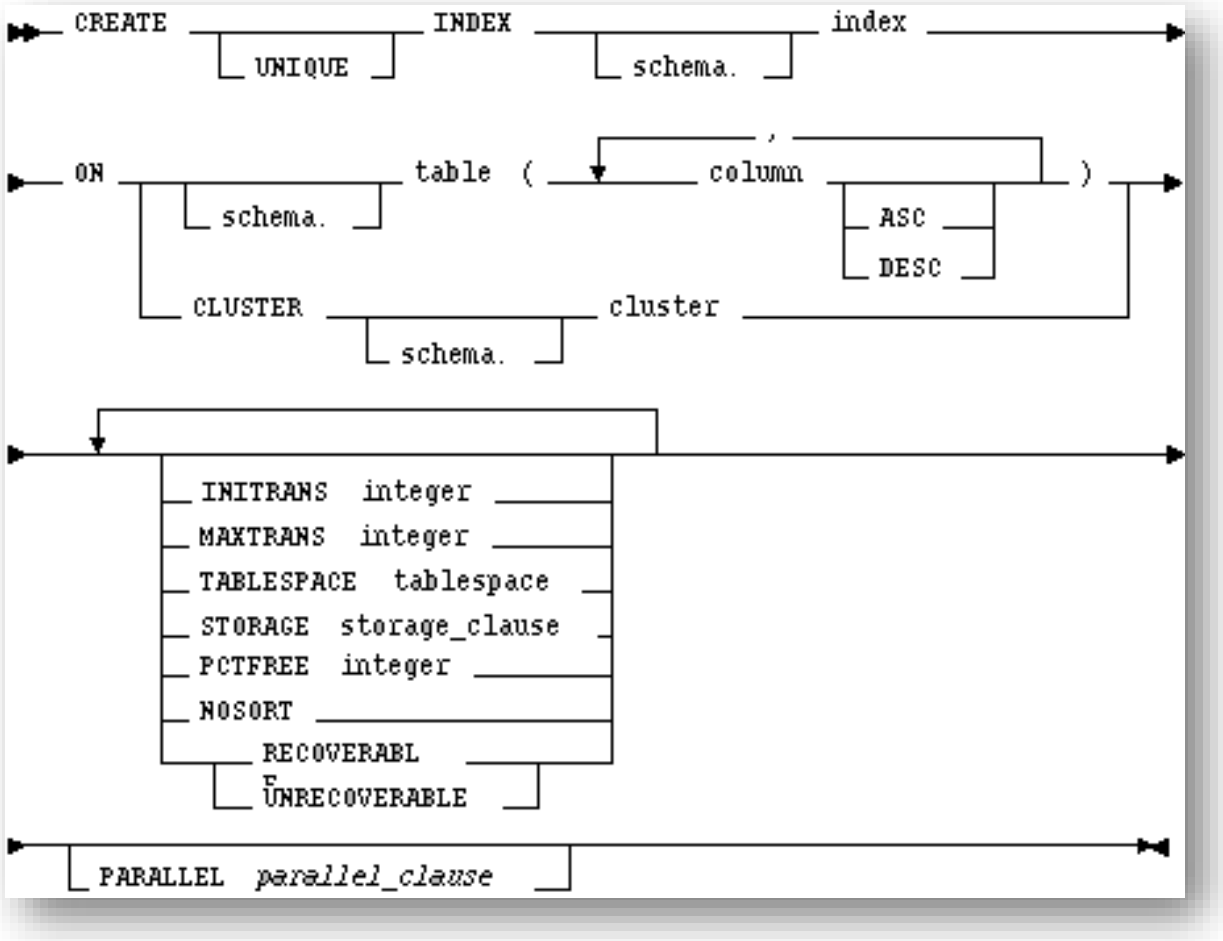
Faut-il **créer/détruire/reconstruire**
des **index** pour accélérer les traitements ?

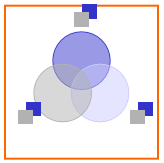
Quel type d'index ?
Arbre-B (B-tree) , Hachage, Bitmap ?

CREATE INDEX …
CREATE BITMAP INDEX …
DROP INDEX (sauf les clés primaire et étrangère…)
REBUILD INDEX ???

Implantation de BD / Administration d'une BD

La commande Create index crée un index sur une ou plusieurs colonnes d'une table. *Une syntaxe de la commande* Create index est :



Implantation de BD / Administration d'une BD

Schéma Physique (4ème version; Index)

create table COURS (NUM_COURS NUMBER**(2)**,
… **constraint PK_COURS primary key (NUM_COURS), …**);

SQL$_2$

create table PROFESSEURS (NUM_PROF NUMBER(4),
… **constraint PK_PROFESSEURS primary key (NUM_PROF), …**);

create table CHARGE (NUM_PRO F …, NUM_COURS …,
constraint PK_CHARGE primary key (NUM_COURS, NUM_PROF)
constraint FK_CHARGE_COURS foreign key (NUM_COURS) references COURS (NUM_COURS), …);

La création des tables se fait en plusieurs étapes :
Les **attributs** ainsi que leurs **domaines** de défintions (les types de données);
Certaines **contraintes** , **CARACTERISTIQUES PHYSIQUES**

Faut-il **créer/détruire** des **index** pour accélérer les traitements ?

CREATE INDEX NDX_PROF ON PROFESSEURS (NUM_PROF) ;
CREATE INDEX NDX_COURS …

Schéma Physique (4ème version; Index)

Faut-il **créer/détruire/reconstruire** des **index** pour accélérer les traitements ? SQL_2

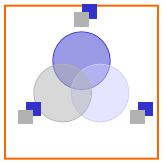
Quel type d'index ? Arbre-B (B-tree), Bitmap ou Hachage ?

```
CREATE INDEX NDX_PROF ON PROFESSEURS (NUM_PROF) ;
CREATE BITMAP INDEX NDX_PROF ON PROFESSEURS (NUM_PROF) ;
CREATE INDEX idx_nom ON PROFESSEURS (NOM_PROF) USING HASH ;
```

CREATE INDEX NDX_COURS …



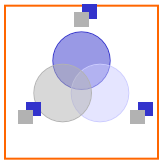




Implantation de BD / Administration d'une BD

Données (110 octets)			Index (14 octets)	
Clé Primaire (10 octets)	Information complémentaire (100 octets)		Clé Primaire (10 octets)	Adresse Physique (4 octets)
10	Info1		10	@1
15	Info2		15	@2
20	Info3		20	@3
30	Info4		30	@4
40	Info5		40	@5
50			50	
55			55	
77			77	
80			80	
100			100	
150			150	
250	Info k		250	@ k
1610	Info n		1610	@ n



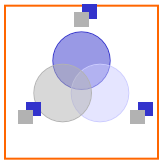


Implantation de BD / Administration d'une BD

Données (110 octets)	
Clé Primaire (10 octets)	Information complémentaire (100 octets)
10	Traifor, Paris, …
15	Lebon, Tunis, …
20	Clément, Médina
30	Info4a, Info4b
40	Info5a, Info5b
50	Info6a, Info6b
55	Info7a, Info7b
77	Info8a, Info8b
80	InfoXa, InfoXb
100	InfoYa, InfoYb
150	InfoXa, InfoZb
???	???
250	Info k
1610	Info n
???	???
???	???

Index (14 octets)	
Clé Primaire (10 octets)	Adresse Physique (4 octets)
30	@Bloc1
77	@Bloc2
150	@Bloc3
1610	@Bloc4



Implantation de BD / Administration d'une BD

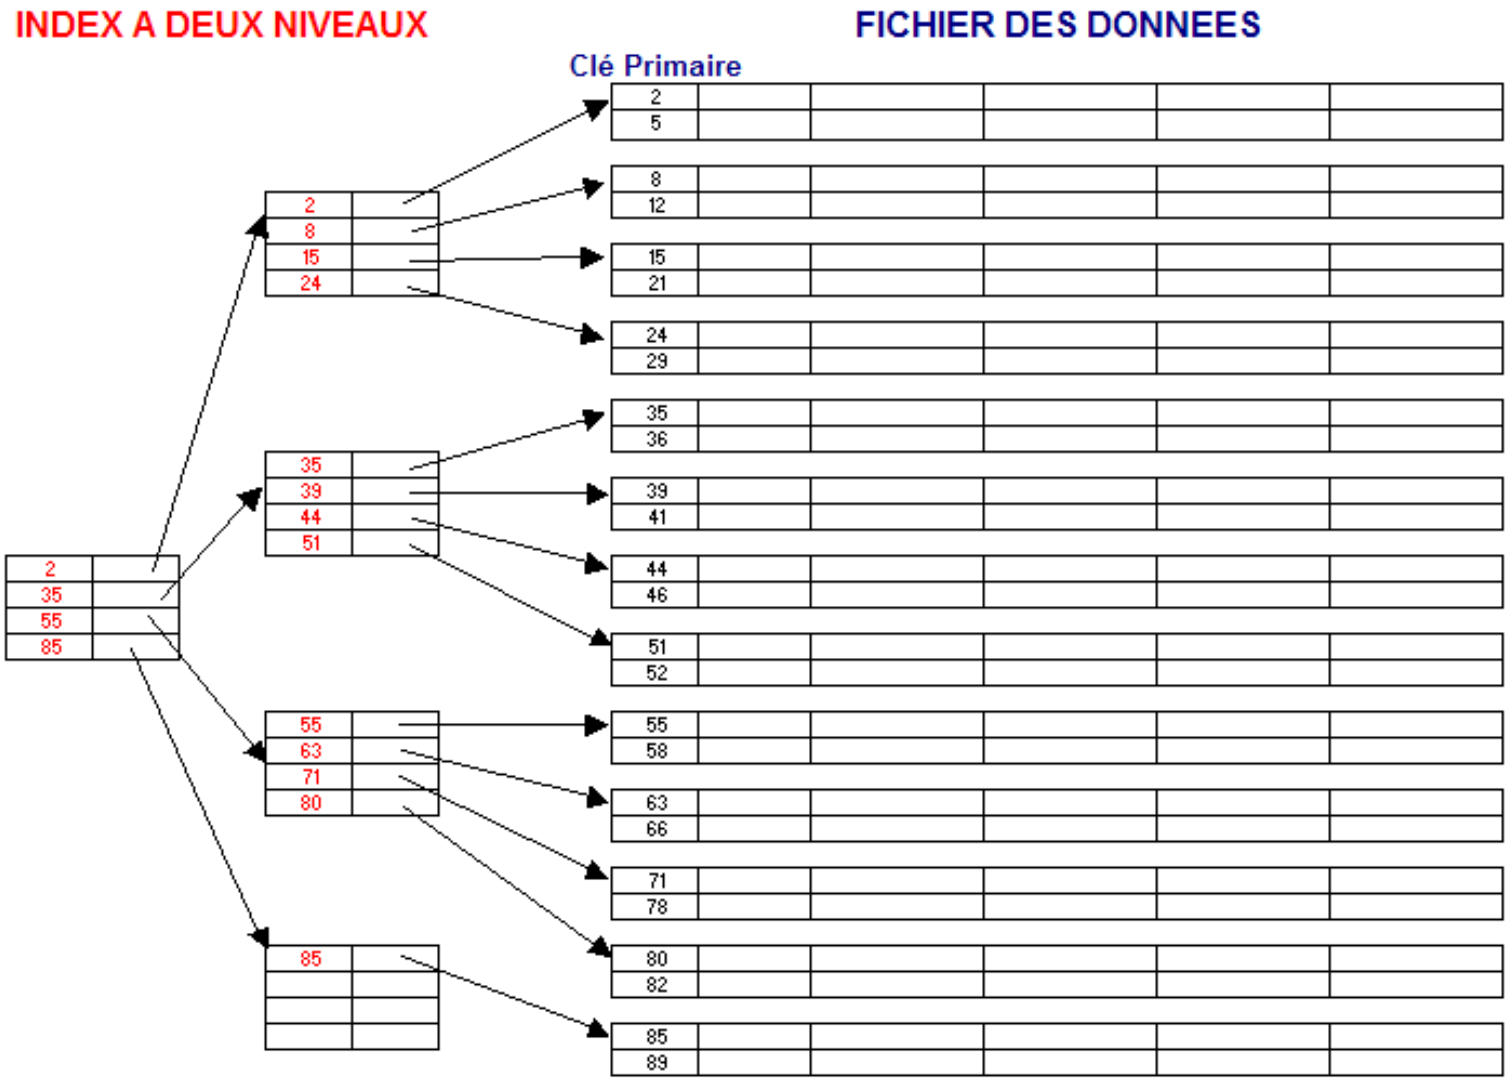
Taille d'une Table & Taille d'un Index

Pour un bloc de 512 octets ; et pour un nombre d'enregistrements de l'ordre de 100 000

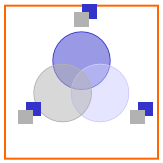
Pour les données :
Pour un nombre entier d'enregistrements par bloc (512 / 110), le nombre maximal d'enregistrements par bloc est 4.
Il faudrait donc (100 000 / 4) 25 000 blocs de données.

Pour les index :
Pour un nombre entier d'enregistrements par bloc (512 / 14), le nombre maximal d'enregistrements par bloc est 36.
Il faudrait donc (100 000 / 36) 2778 blocs d'index.

Implantation de BD / Administration d'une BD





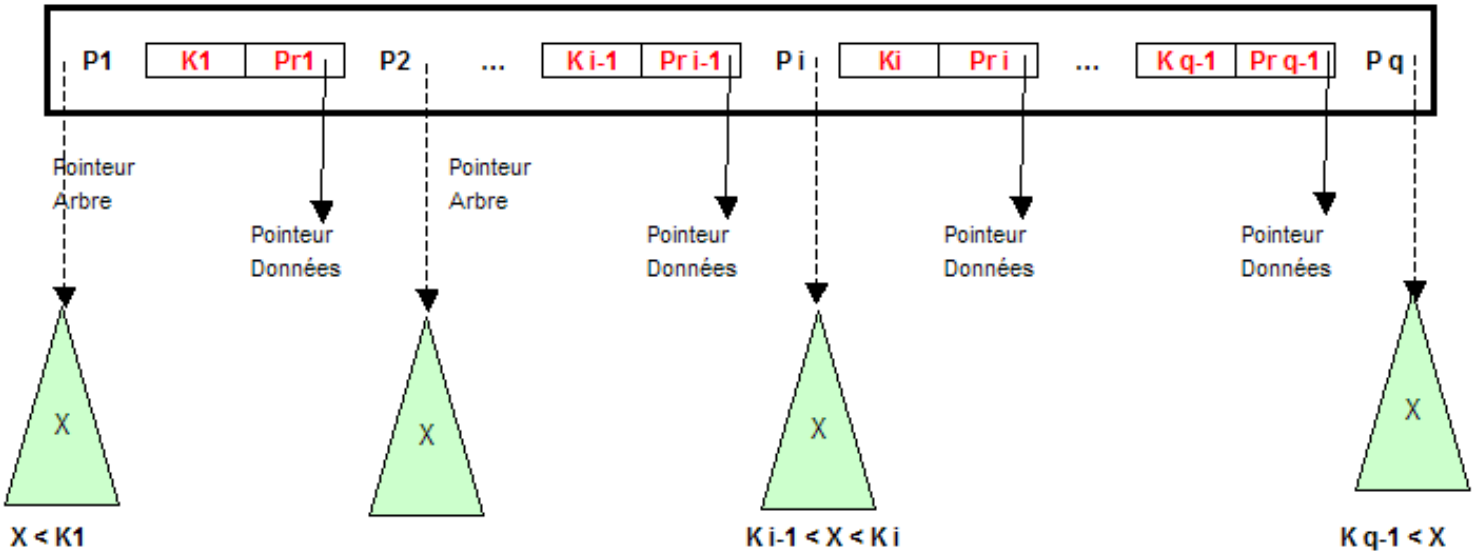


Implantation de BD / Administration d'une BD

Un arbre B d'ordre P peut être défini comme suit (A B-tree of order P can be defined as follows) :

Plusieurs variantes B+, B* etc...

1 . Chaque nœud interne possède la structure suivante :



2. Dans chaque nœud, K1 < K2 < K3 < ... < K q-1

3. Pour chaque Clé de valeur X dans un sous arbre pointé par un pointeur P i on a ; K i-1 < X < K i pour 1 < i < q ; X < K i pour i = 1 ; et K i-1 < X pour i = q

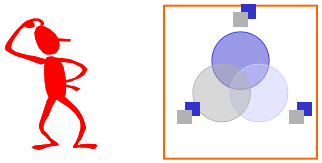
Plusieurs dizaines de millions de clés,
Une dizaine d'accès disque au maximum pour retrouver l'information !

4. Chaque nœud a au plus p pointeurs d'arbres.

5. Chaque nœud, excepté la racine et les nœuds feuille, a au moins sup(ent(P/2)) pointeurs d'arbres.
Le noeud racine a au moins 2 pointeurs d'arbres à moins qu'il soit le seul nœud de l'arbre.

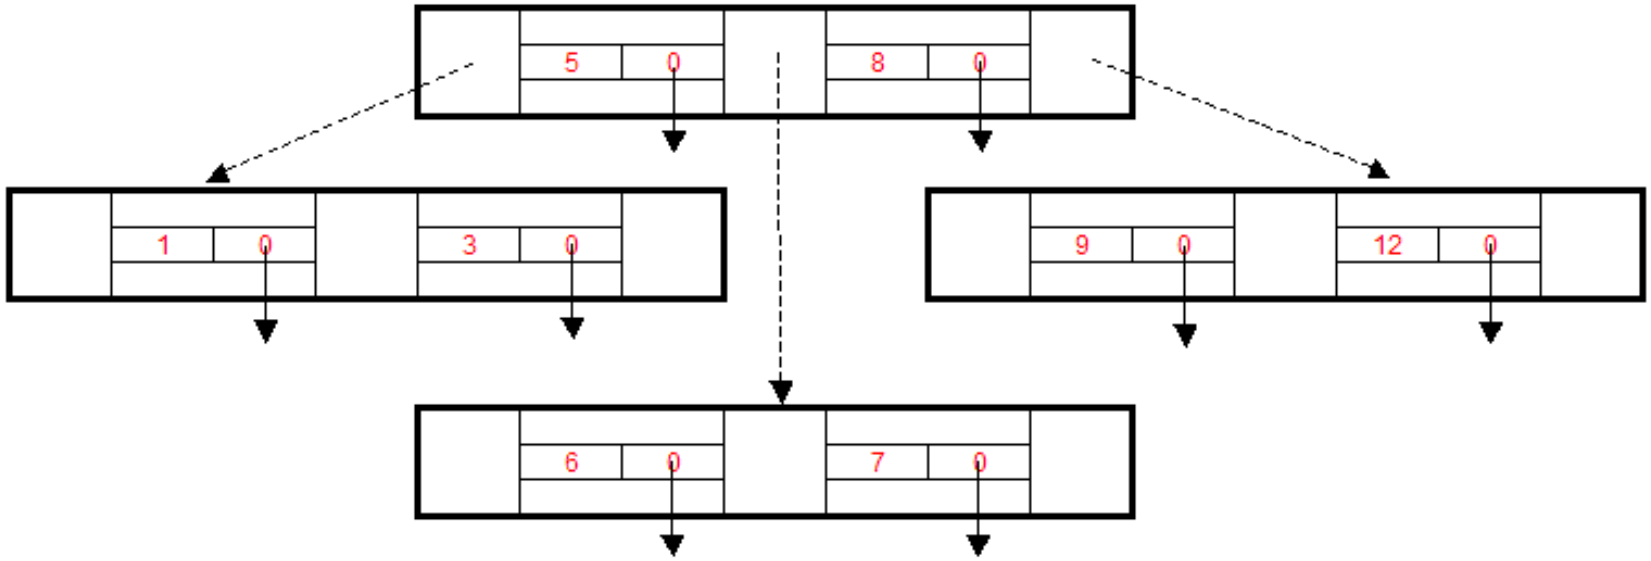
6. Un nœud avec q pointeurs, q≤ p, a q-1 valeurs de clé (et donc a q-1 pointeurs de données).

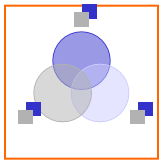




Implantation de BD / Administration d'une BD

Structures Arbre B d'ordre 3. Les valeurs ont été insérées dans l'ordre 8, 5, 1, 7, 3, 12, 9, 6



Implantation de BD / Administration d'une BD

Schéma Physique (5ème version; Cluster)

create table COURS (NUM_COURS NUMBER**(2)**,
… **constraint PK_COURS primary key (NUM_COURS), …**);

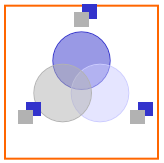
SQL$_2$

create table CHARGE (NUM_PRO F …, NUM_COURS …,
constraint PK_CHARGE primary key (NUM_COURS, NUM_PROF)
constraint FK_CHARGE_COURS foreign key (NUM_COURS) references COURS (NUM_COURS), …);

La création des tables se fait en plusieurs étapes :
Les **attributs** ainsi que leurs **domaines** de définitions;
Les **contraintes** ; Les **Index** ;

Faut-il **regrouper les données**
(créer des clusters) pour accélérer les traitements ?
De nos jours, ce n'est plus préconisé par certains éditeurs (tel que Oracle)

CREATE CLUSTER CL_PROF … ;

Implantation de BD / Administration d'une BD

Schéma Physique (nième version; Vues, Confidentialité, Optimisation)

create table COURS (NUM_COURS NUMBER**(2)** **NOT NULL**,
… **constraint PK_COURS primary key (NUM_COURS)**);

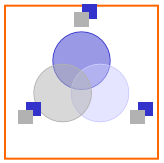
create table PROFESSEURS (NUM_PROF NUMBER(4) NOT NULL,
… **constraint PK_PROFESSEURS primary key (NUM_PROF)**);

create table CHARGE (NUM_PRO F …, NUM_COURS …,
constraint PK_CHARGE primary key (NUM_COURS, NUM_PROF)
constraint FK_CHARGE_COURS foreign key (NUM_COURS) references COURS (NUM_COURS)
constraint FK_CHARGE_PROFESSEUR foreign key (NUM_PROF) references PROFESSEURS (NUM_PROF));

Faut-il **créer des vues ?**

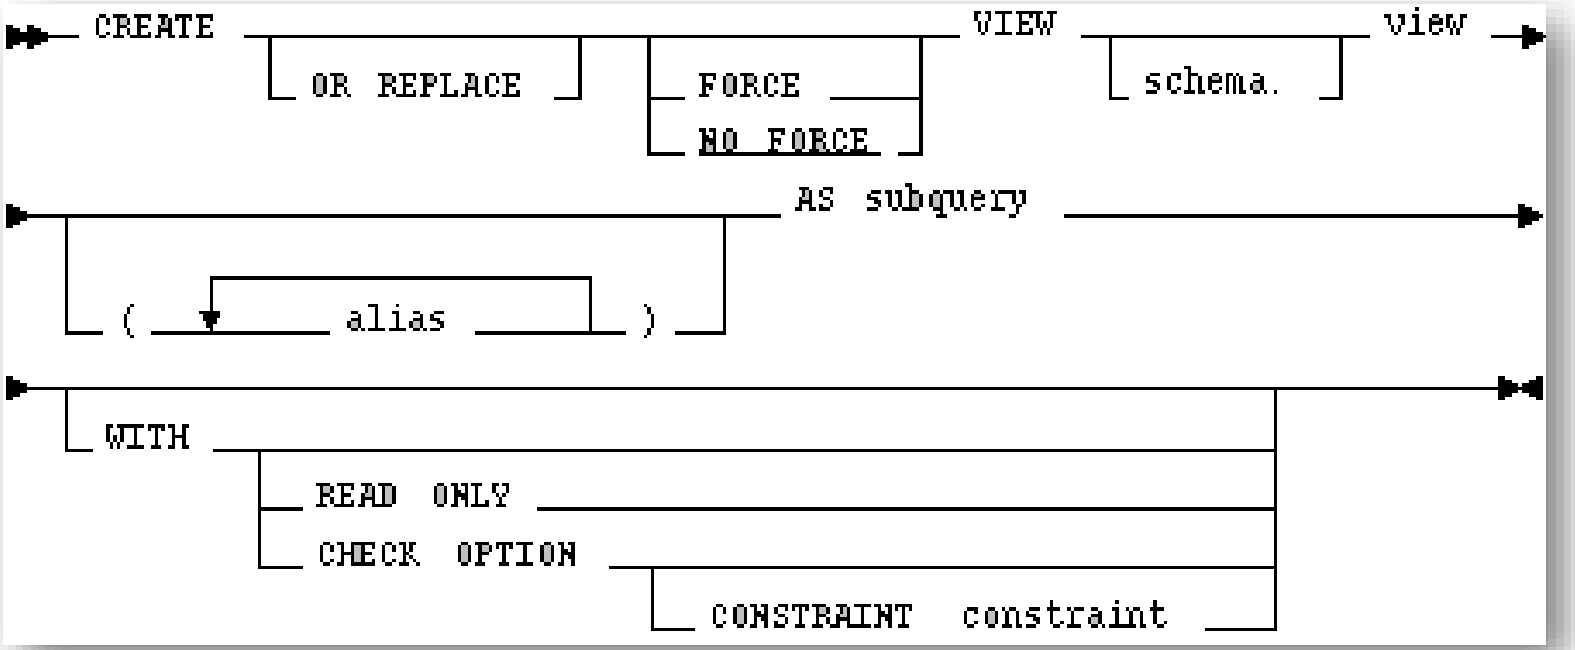
Quel type de vues *matérialisées ou pas* !

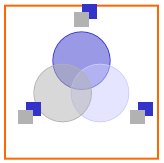
CREATE OR REPLACE VIEW V_PROF … ;

Implantation de BD / Administration d'une BD

La commande Create view crée une nouvelle vue résultant d'une requête sur une ou plusieurs tables et/ou vues.
Une syntaxe de la commande Create view est :



Implantation de BD / Administration d'une BD

Schéma Physique (nième version; Vues, Confidentialité, Optimisation)

CREATE OR REPLACE VIEW Profs2000
AS
(SELECT NUM_PROF, NOM, SPECIALITE, DATE_ENTREE
FROM PROFESSEURS
WHERE DATE_ENTREE > '01-01-2000')

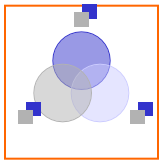
SQL$_2$



WITH CHECK OPTION ;
[WITH GRANT OPTION ;] attention confidentialité !

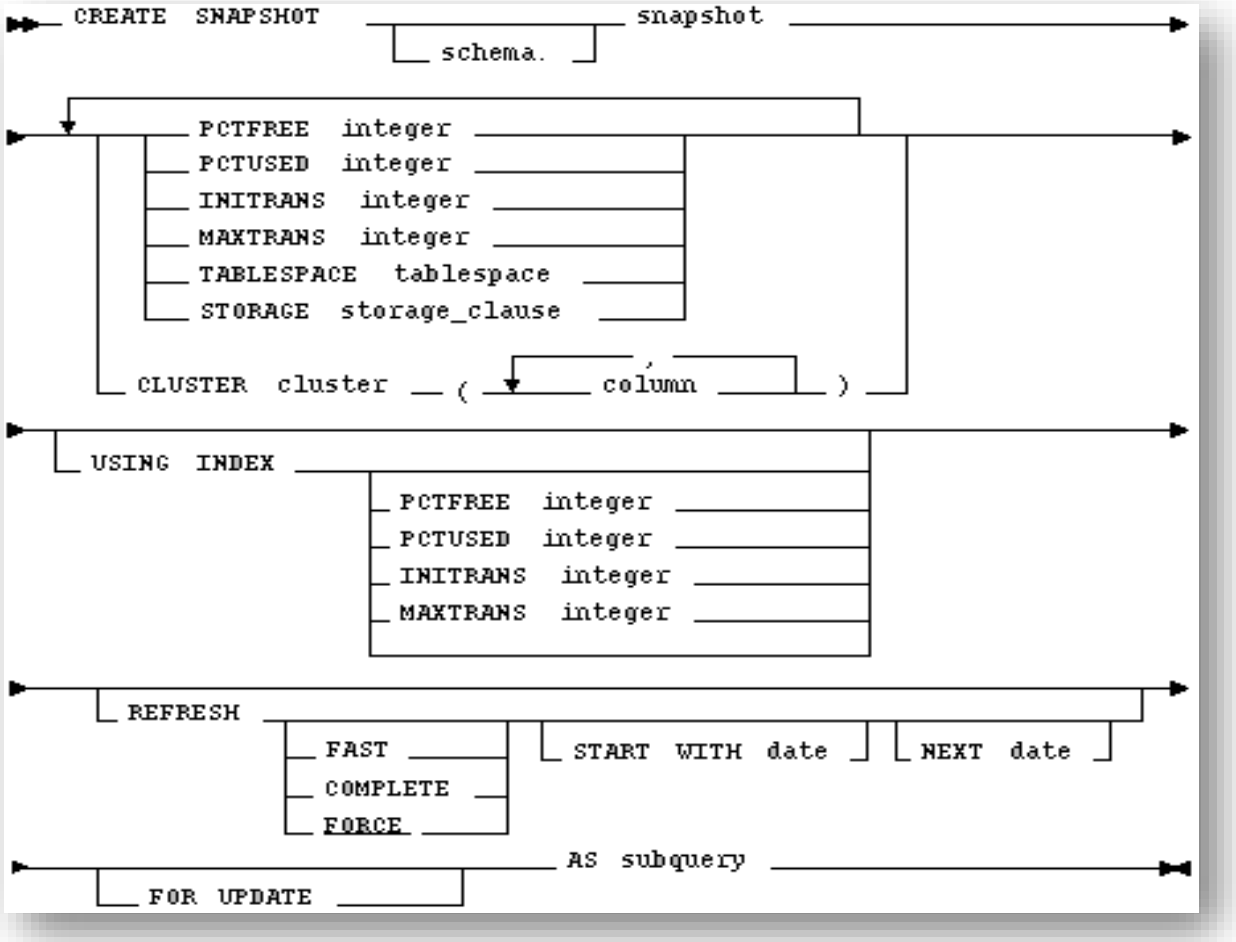
CREATE OR REPLACE VIEW Profs2000 **(NP, NOMP, SP, DE)**
AS (SELECT NUM_PROF, NOM, SPECIALITE, DATE_ENTREE
FROM PROFESSEURS WHERE DATE_ENTREE > '01-01-2000')
WITH CHECK OPTION ;



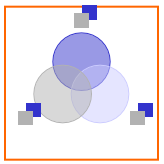


Implantation de BD / Administration d'une BD

La commande Create snapshot Crée un snapshot (une vue matérialisée).
Une syntaxe de la commande Create snapshot est :

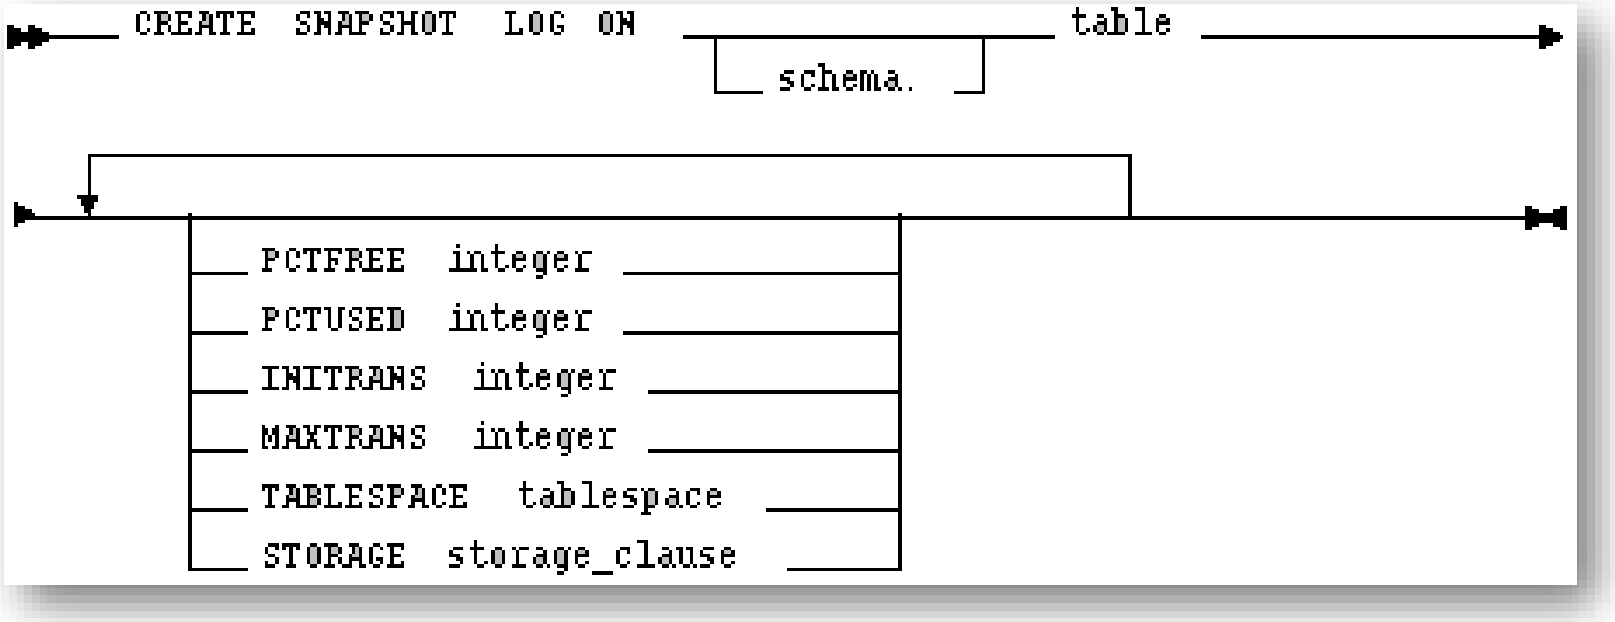


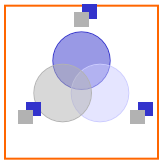


Implantation de BD / Administration d'une BD

La commande Create snapshot log crée un snapshot log qui identifie les modifications apportées aux tables du snapshot depuis son dernier rafraîchissement.
Une syntaxe de la commande Create snapshot log est :



Implantation de BD / Administration d'une BD

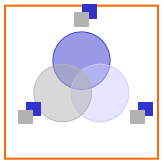
Schéma Physique (nième version; Vues)

SQL$_2$

```
CREATE MATERIALIZED VIEW Profs2000
  BUILD {IMMEDIATE , DEFERED}
  REFRESH {COMPLETE,FAST,FORCE,NEVER}
AS
(SELECT NUM_PROF, NOM, SPECIALITE, DATE_ENTREE
FROM PROFESSEURS
WHERE DATE_ENTREE > '01-01-2000')  … ;
```



```
CREATE SNAPSHOT Profs2000
AS
(SELECT NUM_PROF, NOM, SPECIALITE, DATE_ENTREE
FROM PROFESSEURS
WHERE DATE_ENTREE > '01-01-2000') … ;
```

Implantation de BD / Administration d'une BD

Schéma Physique (nième version; Partage de données)

```
create TABLE PROFESSEURS ( … ) ;
create INDEX … ;
create or replace VIEW V_PROF … ;
```

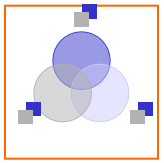
Faut-il **partager les données ?**

Faut-il **attribuer/retirer des privilèges d'accès ?**

Quel type de *droits d'accès* *à accorder*
***aux autres utilisateurs* !**

```
GRANT SELECT ON Profs2000 TO PUBLIC ;
GRANT INSERT ON Profs2000 TO user1 ;

REVOKE SELECT ON Profs2000 FROM PUBLIC ;
```

Implantation de BD / Administration d'une BD

Schéma Physique (nième version; Partage de données)

Différentes tâches de l'administrateur :

1. Après installation du logiciel

Architecture standard OFA

2. Création de la BD

(les fichiers selon OS ; plusieurs types de fichiers seront créés)

```
CREATE TABLESPACE NomBD
DATAFILE 'c:\Chemin\tablespaces\NomBD.dbf' SIZE 3M ;
 -- 3 Mégas ou m Mégas

CREATE TABLESPACE NomBD
DATAFILE 'c:\Chemin\tablespaces\tmp_NomBD.dbf' SIZE 3M ;
   -- 3 Mégas ou m Mégas
```

Différentes tâches de l'administrateur :

3. Création des utilisateurs

```
CREATE USER NomUser IDENTIFIED BY MotPasseUser
DEFAULT TABLESPACE NomBD
TEMPORARY TABLESPACE tmp_NomBD ;
```

Créer un rôle et un profil :

```
GRANT CONNECT TO NomUser ;
GRANT RESOURCE TO NomUser ;
GRANT SEL_CATALOG_ROLE TO NomUser ;
```

Les droits connect et resource permettent de faire pas mal de traitements sur oracle (créer des tables, des index, des vues, des triggers, du pl/sql etc…,
le droit sel_catalog_role est très important pour pouvoir consulter le DD d'oracle et faire le suivi des optimisations.)

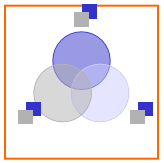



Schéma Physique (nième version; Partage de données)

Différentes tâches de l'administrateur :

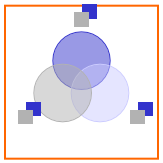
4. Destruction des utilisateurs ;

DROP USER NomUser CASCADE ;

5. Modification du mot de passe des utilisateurs ;

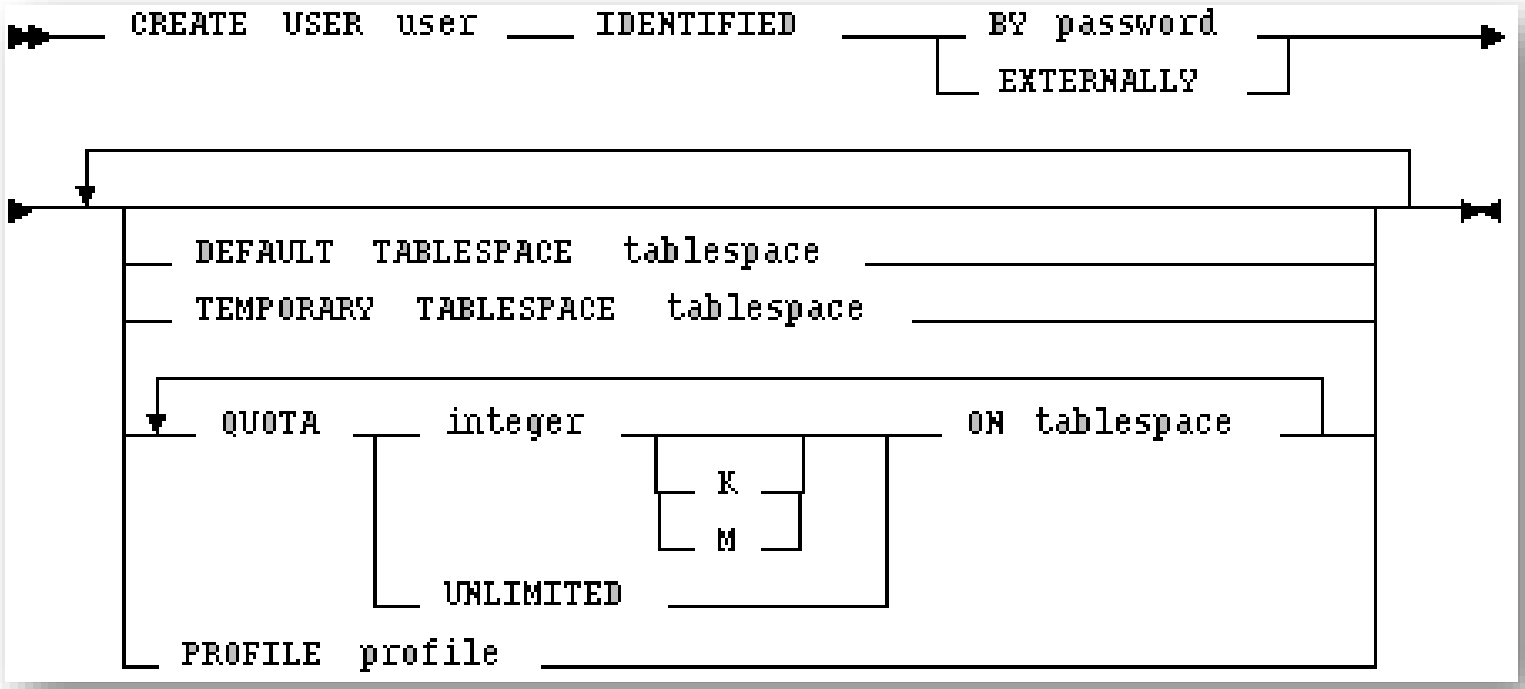
ALTER USER NomUser IDENTIFIED BY nouveaumotdepasse;

SHOW USER ; **SHOW ERRORS ; …**

Implantation de BD / Administration d'une BD

La commande Create user crée un nouvel utilisateur de la base.
Une syntaxe de la commande Create user est :



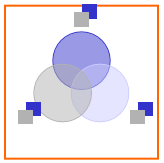



Schéma Physique (nième version; Partage de données)

Différentes tâches de l'administrateur :

Faut-il **partager les données ?**
Faut-il **attribuer/retirer des privilèges d'accès ?**

Quel type de *droits d'accès* *à accorder aux autres utilisateurs* !

GRANT {privilège_système | rôle} [, {privilège_système2 | rôle2} …]
TO {utilisateur | rôle | PUBLIC} [, utilisateur2 …]
[WITH GRANT OPTION] ;

REVOKE {privilège_système | rôle} [, {privilège_système2 | rôle2} …]
FROM {utilisateur | rôle | PUBLIC} [, utilisateur2 …] ;

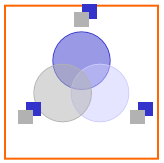



Schéma Physique (nième version; Partage de données)

Différentes tâches de l'administrateur :

Faut-il **partager les données ?**
Faut-il **attribuer/retirer des privilèges d'accès ?**

Quel type de *droits d'accès* *à accorder aux* *autres utilisateurs* !

PRIVILEGES SYSTEME :

GRANT {privilège_système | rôle} [, {privilège_système2 | rôle2} …]
TO {utilisateur | rôle | PUBLIC} [, utilisateur2 …]
[WITH ADMIN OPTION] ou **[WITH GRANT OPTION] ;**

REVOKE {privilège_système | rôle} [, {privilège_système2 | rôle2} …]
FROM {utilisateur | rôle | PUBLIC} [, utilisateur2 …] ;

Différentes tâches de l'administrateur :

Faut-il **partager les données ?** Faut-il **attribuer/retirer des privilèges d'accès ?**
Quel type de *droits d'accès* *à accorder aux autres utilisateurs* !

PRIVILEGES OBJET :

GRANT {privilège1 [(colonne11, [colonne12…])] | rôle} [, {privilège2 [(colonne21…)] | rôle2} …] ON SchémaDeLobjet
TO {utilisateur | rôle | PUBLIC} [, utilisateur2 …]
[WITH GRANT OPTION] ;

REVOKE {privilège1 | rôle} [, {privilège2 | rôle2} …] ON SchémaDeLobjet
FROM {utilisateur | rôle | PUBLIC} [, utilisateur2 …]
[CASCADE CONSTRAINTS] ;

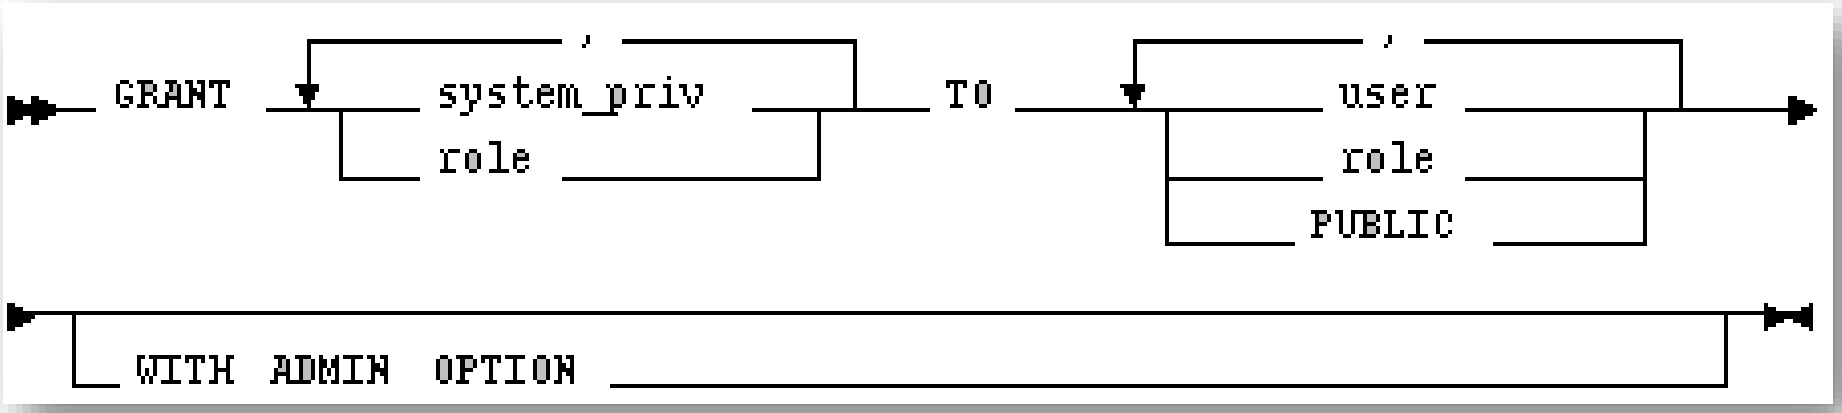
La commande **Grant** donne des privilèges sur différents objets à un utilisateur existant.

PRIVILEGES SYSTEME

Grant System Privileges and Roles:

Gives system privileges to users and to roles.
Gives roles to users and other roles.

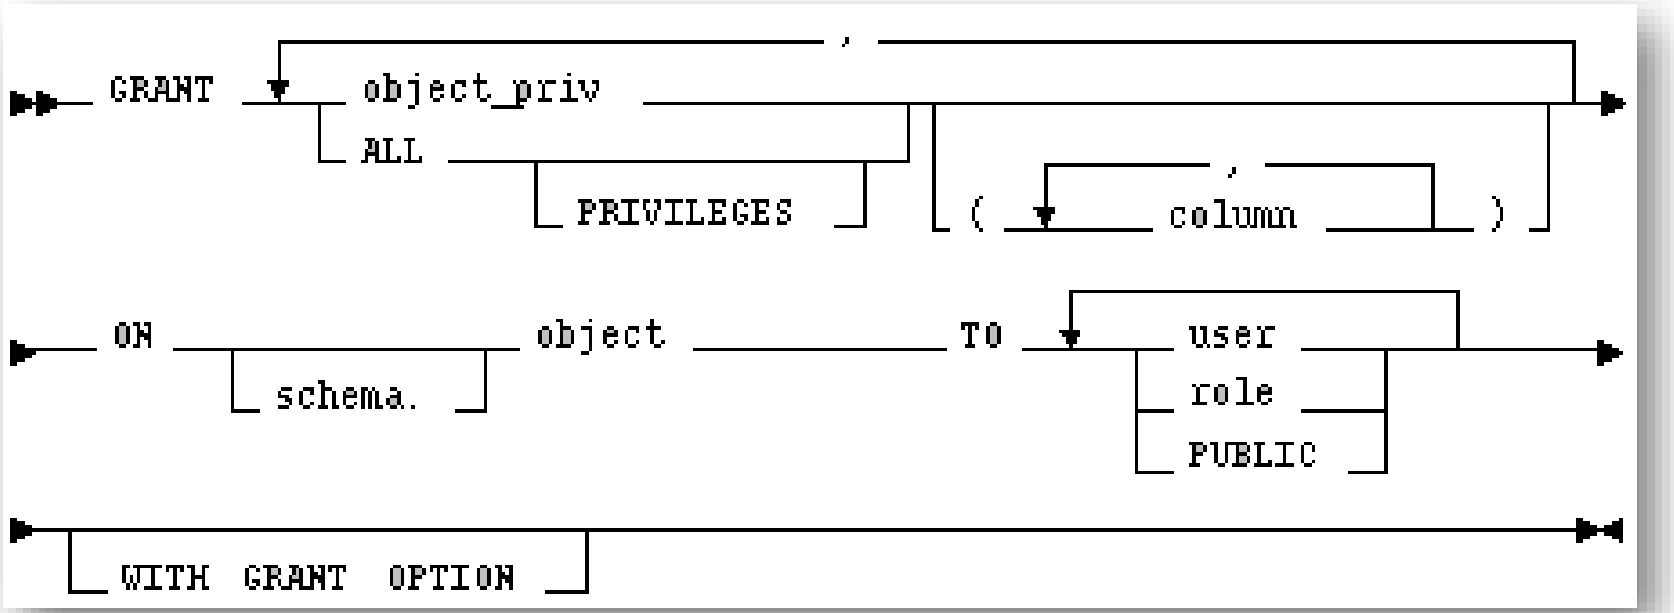
Une syntaxe de la commande Grant est :

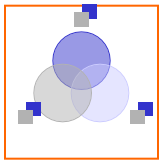


Objects privileges:
Gives privileges for a particular object (a table, view, synonym, package, procedure, ...) to users and to roles.

PRIVILEGES OBJETS

Une syntaxe de la commande Grant est :

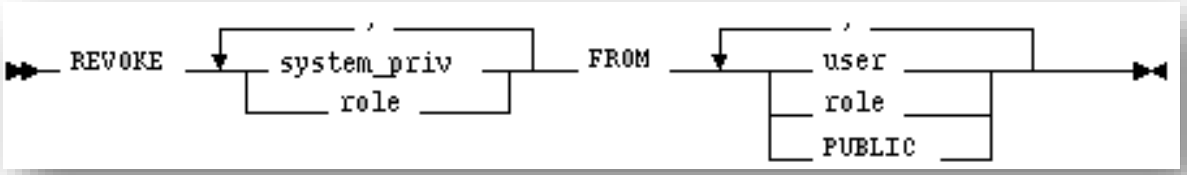


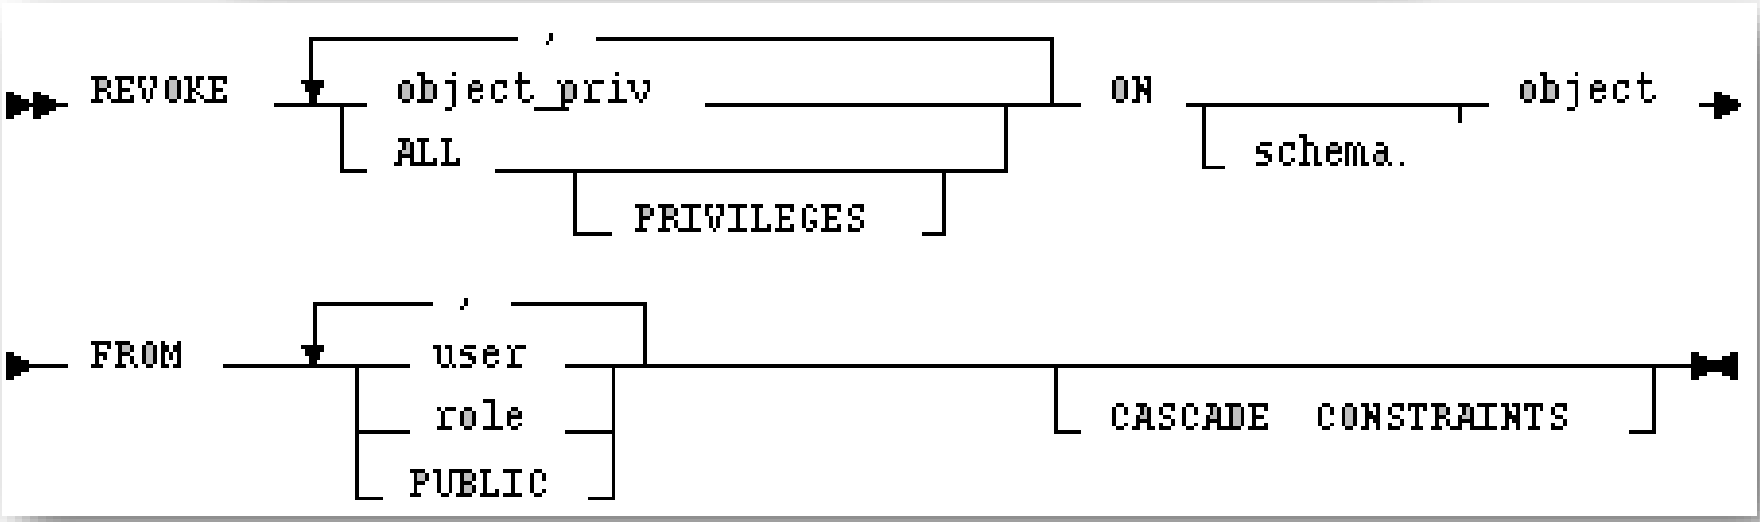



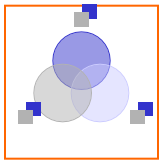
Implantation de BD / Administration d'une BD

La commande Revoke supprime les privilèges système, rôles et privilèges sur les objets d'un utilisateur (en opposition à Grant).

Une syntaxe de la commande Revoke est :

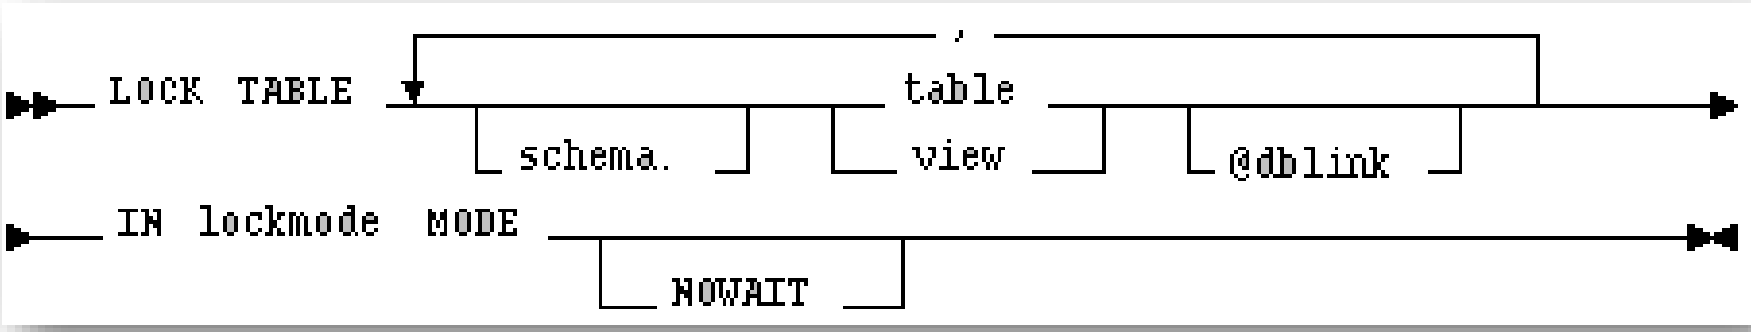




Implantation de BD / Administration d'une BD

La commande **Lock table** force le mode de lock (verrouillage) et réserve l'accès à une table à la session courante.
Permet ou restreint l'accès des autres utilisateurs.
Une syntaxe de la commande Lock table est :



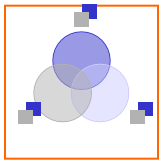



Schéma Physique (nième version; Partage de données)

Différentes tâches de l'administrateur :

Notion de rôle :

Les principaux rôles, prédéfinis par Oracle et attribués aux utilisateurs SYSTEM et SYS, sont :

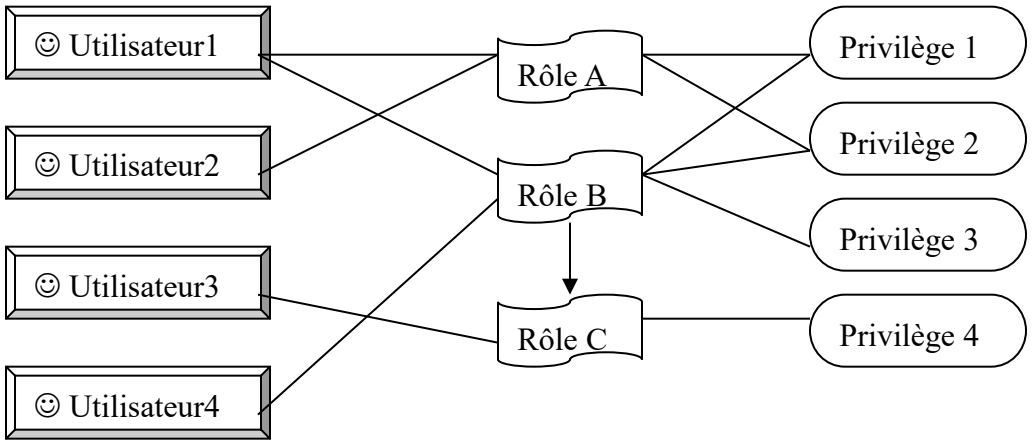
Rôle	Privilège système
CONNECT	CREATE SESSION, CREATE TABLE, …
RESOURCE	CREATE CLUSTER, CREATE PROCEDURE, …
DBA	Tous les privilèges

Schéma Physique (nième version; Partage de données)

Différentes tâches de l'administrateur :



Notion de rôle :



CREATE ROLE LeNomDuRôle ;

GRANT LePrivilège ON Lobjet TO LeNomDuRôle ;

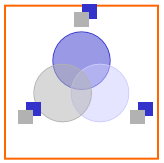



Schéma Physique (nième version; Partage de données)

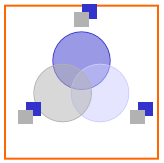
Différentes tâches de l'administrateur :

Notion de profil :

Un profil est un ensemble de ressources limitées, à attribuer aux utilisateurs : des caractéristiques physiques telles que :

Un % d'utilisation dans un tablespace ;
Un nombre de connexions ;
Une priorité d'exécution des requêtes etc…

CREATE PROFILE etc. ;

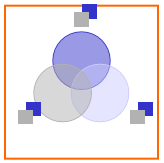
Implantation de BD / Administration d'une BD

Schéma Physique (nième version; Partage de données)

Create profile profexpl limit
Session_per_user 1
Idle_time 120
connect;

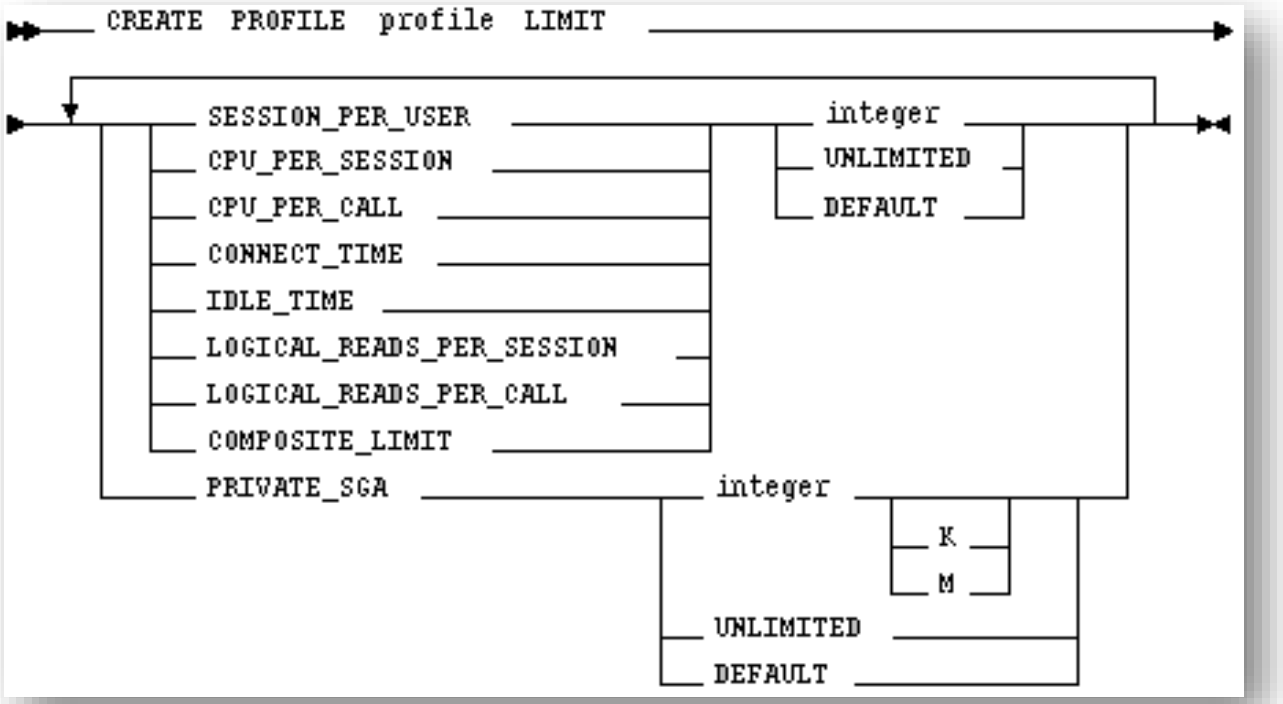
- Affecter le profil à l'utilisateur scott
  Alter user scott profile profexpl ;

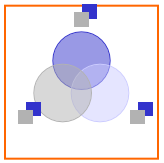


Implantation de BD / Administration d'une BD

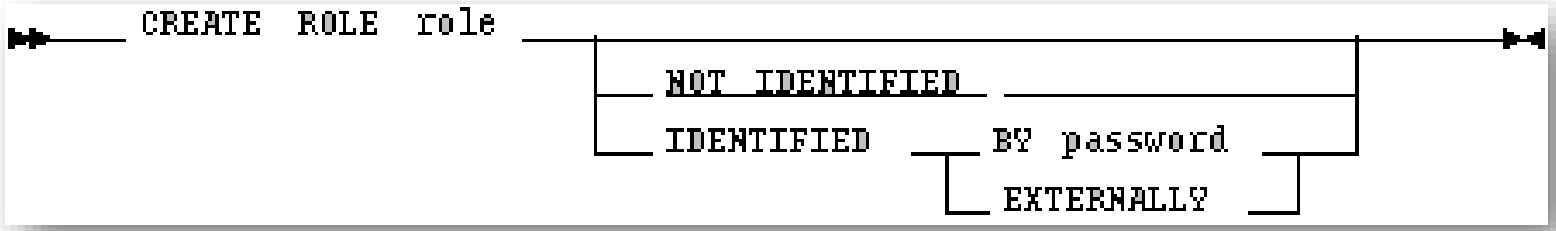
La commande Create profile crée un profil utilisateur et spécifie ses autorisations et limitations.
Une syntaxe de la commande Create profile est :

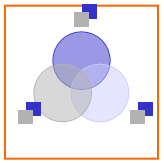


Implantation de BD / Administration d'une BD

La commande Create role crée un rôle spécifiant des autorisations spécifiques.
Une syntaxe de la commande Create role est :

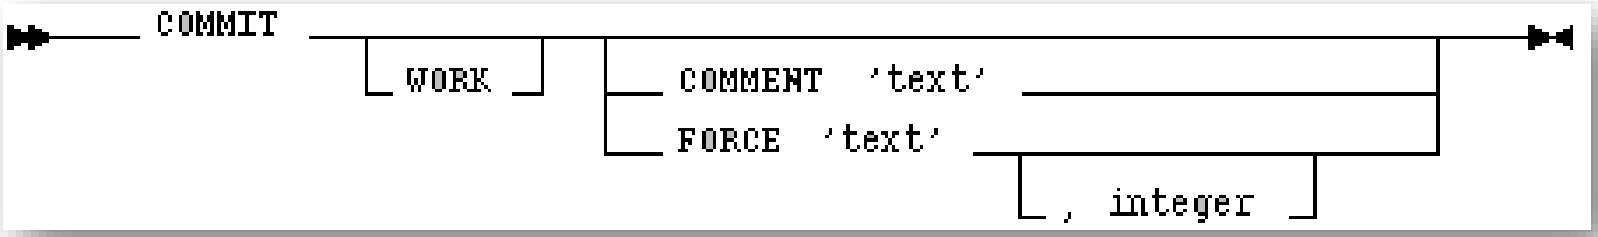


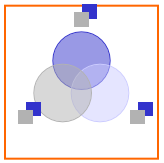



Implantation de BD / Administration d'une BD

La commande Commit sauvegarde les modifications de données de la session courante dans la base de données (en opposition à la commande Rollback). Supprime aussi les savepoints et libère les (verrous) lockes de la session courante.

Une syntaxe de la commande Commit est :

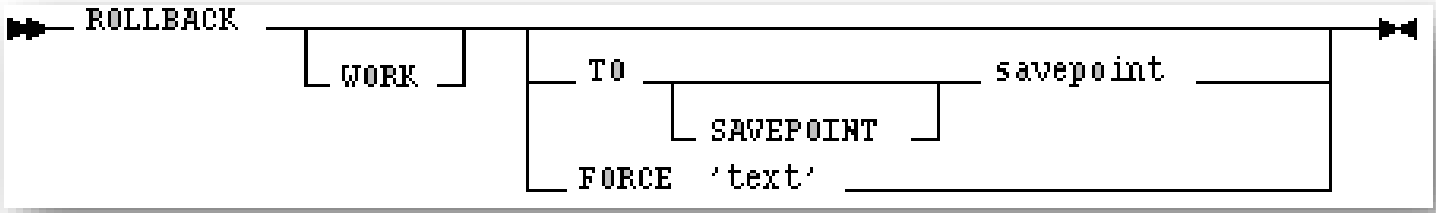


Implantation de BD / Administration d'une BD

La commande Rollback annule tous les changements apportés depuis le savepoint. Annule tous les changements de la session courante si aucun savepoint n'est spécifié (en opposition à Commit).

Une syntaxe de la commande Rollback est :



La commande Savepoint identifie un point de sauvegarde dans la session courante depuis lequel les transactions pourront être annulées via la commande rollback.

Une syntaxe de la commande Savepoint est :



Schéma Physique

Différentes tâches de l'administrateur :

La plus demandée, La plus difficile, …



Optimiser ? !

Schéma(s)

Requête(s)

Architecture(s)

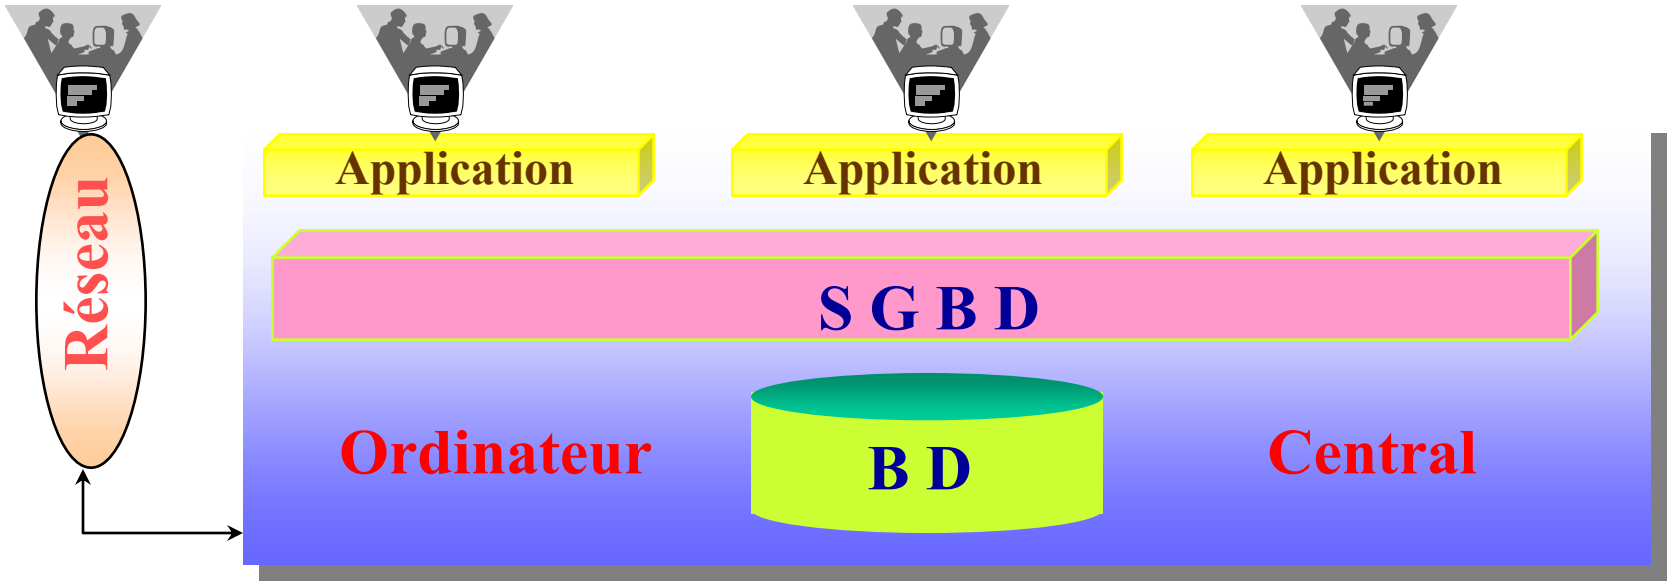
Qualité des données !

Administrer … (Confidentialité, Sécurité, Validité… des données)

Cumuler l'expérience …

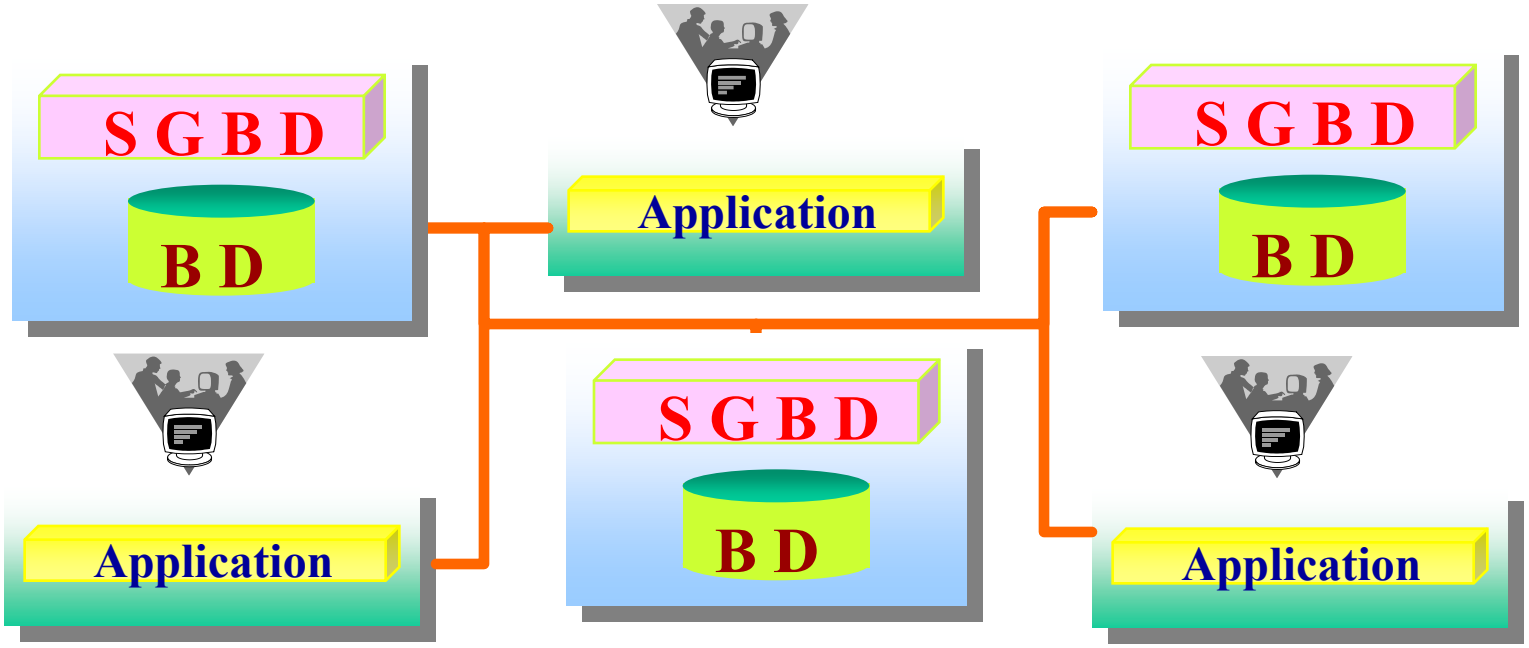
Architecture centralisée

- Cette architecture correspond aux premières générations de SGBD (mainframe).
- Elle est de plus en plus abandonnée au profit de l'architecture distribuée ou répartie.



Architecture répartie/distribuée

- Dans cette architecture, les données et les applications sont réparties sur des ordinateurs différents.





Manipuler/Interroger les tables/vues : Une requête

SQL peut donc être formulée comme suit :





SELECT ……

FROM ……

Ces deux commandes sont **obligatoires**

WHERE …….

N'est nécessaire que s'il y a des **conditions** à exprimer :
des conditions de sélections et/ou
des conditions de jointures

ORDER BY ……

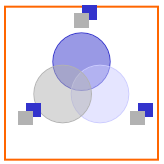
N'est nécessaire que s'il y a un **classement** à effectuer.

GROUP BY ……

HAVING ……..

N'est nécessaire que s'il y a un **groupement** à effectuer.
Le HAVING permet de faire des sélections sur le GROUP BY

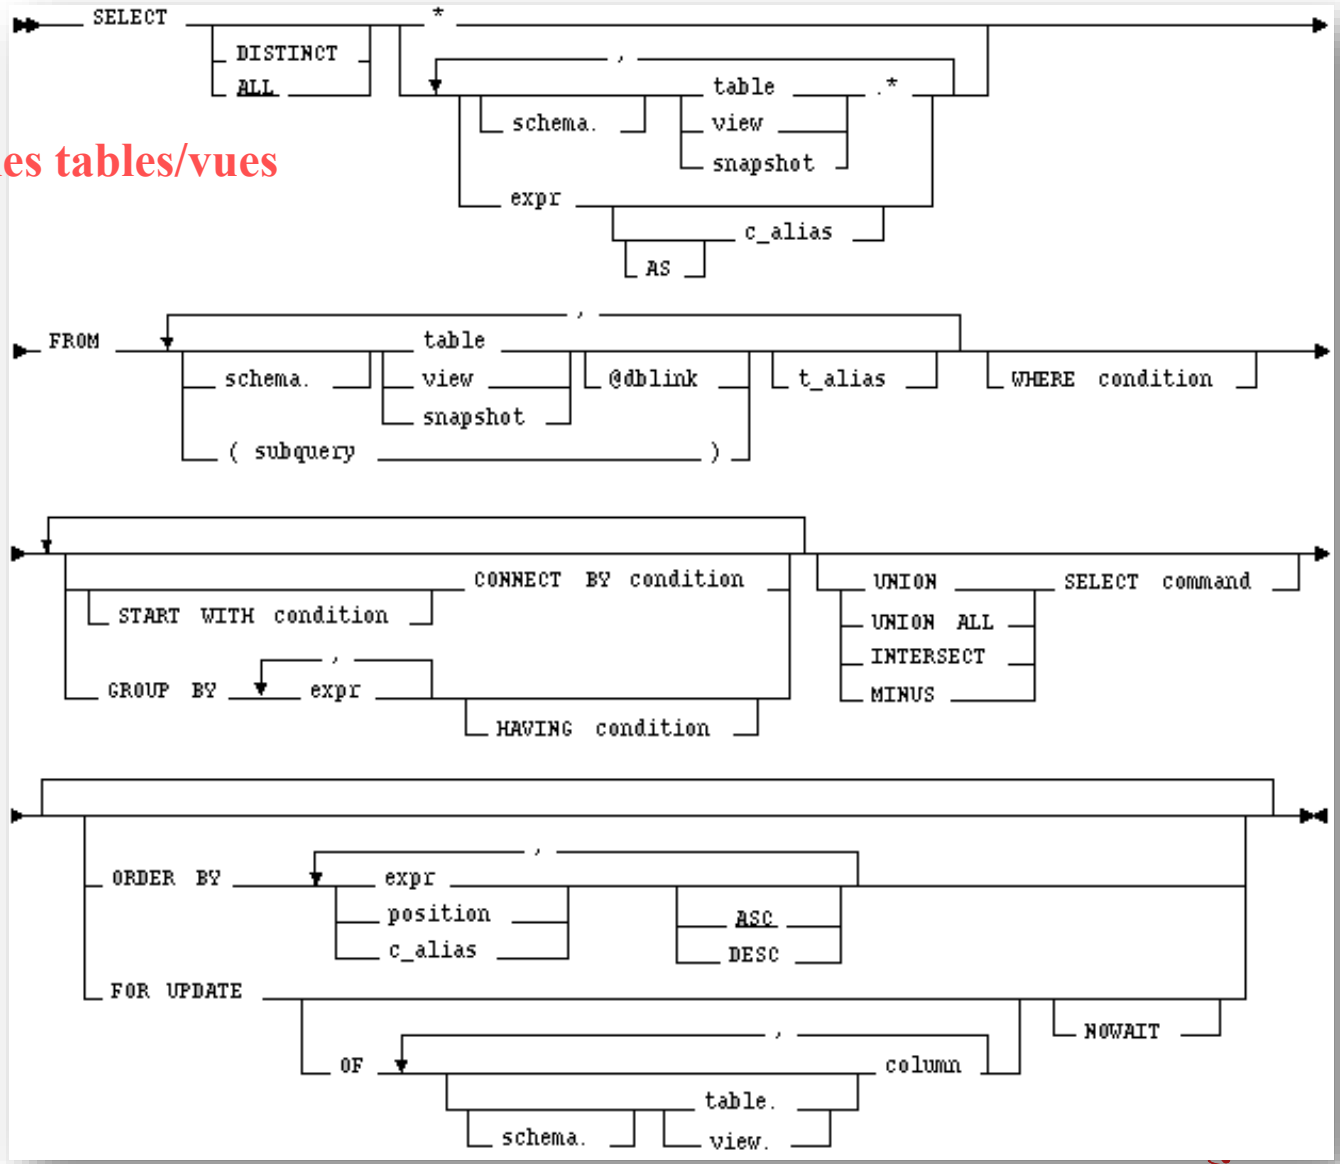


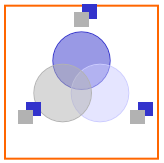


Implantation de BD / Administration d'une BD

Manipuler/Interroger les tables/vues

La commande **Select** interroge une ou plusieurs tables ou vues. Retourne les données des lignes et colonnes.
La commande **Select** peut être utilisée pour une requête ou une sous-requête SQL.
Une syntaxe de la commande Select est :



Implantation de BD / Administration d'une BD

Manipuler/Interroger les tables/vues

La commande **Select** interroge une ou plusieurs tables ou vues. Retourne les données des lignes et colonnes. La commande **Select** peut être utilisée pour une requête ou une sous- requête SQL.

SQL Avancé :

SELECT … FROM … WHERE … GROUP BY … HAVING … ORDER BY … ;

SELECT … FROM … (**SELECT … FROM … WHERE …**) …
WHERE … GROUP BY … HAVING … ORDER BY … ;



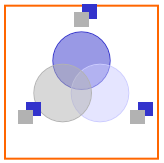
SELECT … FROM … WHERE … GROUP BY … **CUBE()|ROLLUP()…** ;

SELECT **RANK() OVER()…** FROM … WHERE … … ;
SELECT **HINT /*…*/ …** FROM … WHERE … … ;

SELECT ... FROM ...WHERE … **CONNECT BY PRIOR START WITH LEVEL …** ;

Etc… full outer join, left outer join, right outer join, merge, select case, insert all…





Implantation de BD / Administration d'une BD

Manipuler/Interroger les tables/vues

Outils pour développer des applications et autres
SQL Forms, SQL Report, SQL Net, SQL Loader… ;
SQL Developper
Oracle Designer, OEM, ETL,
Oracle Data WareHouse Builder…

Structured Query Language (SQL)
Langage de Définition des Données (LDD)
(Data Definition Language DDL) → **Create … ; Drop … ; Alter … ;**
Langage de Manipulation des Données (LMD)
(Data Manipulation Language DML) → **Select … ; Insert … ; Update … ; Delete … ;**
Langage de Contrôle des Données (LCD)
(Data Control Language DCL) **Grant… ; Revoke… ; Commit ; Rollback ; Save … ;**

$SQL_{2, 3, ...}$, SQL_{OO}, De nouveaux types de données : Documents, XML, ….

Noyau D'un SGBD
Exemple ORACLE
Gestion de la mémoire centrale
Gestion de la mémoire secondaire
Gestion des processus …
…

Améliorer l'interface; gestion de l'affichage (SQLPlus)
SET…
COL … FORMAT … ; PAUSE ; TTITLE … ;
DESC … ; SHOW … ; SET… ; …

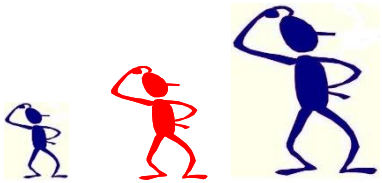
Programmer (PL/SQL)
Développer des procédures, des fonctions ; des packages ;
des déclencheurs (triggers)…
Déclaration de variables, affectation,
IF THEN ELSE, FOR, WHILE, CASE, BEGIN END
PROCEDURE FUNCTION, PACKAGE …

Autres environnements de programmation
Des langages hôtes : Ada, C, C++, Cobol, Java, Pascal…→ Pro*
ODBC, JDBC
PHP…
Python…



3. Qualité des données

Think Bigger, Differently & Smarter by using DATA



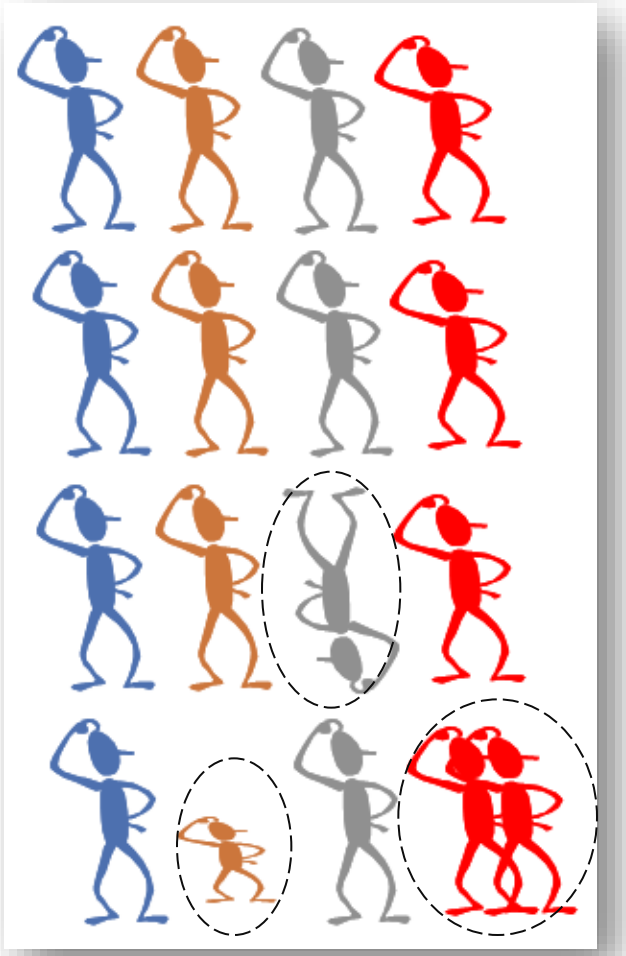


Gestion de la Qualité des Données

Donner un sens aux données rassemblées

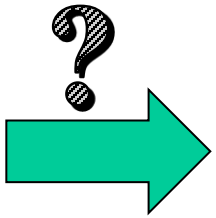
Les données récupérées et éventuellement transformées sont-elles fiables ?

Plusieurs types d'anomalies (Intra-Colonne, Inter-Colonnes et Inter-Lignes)

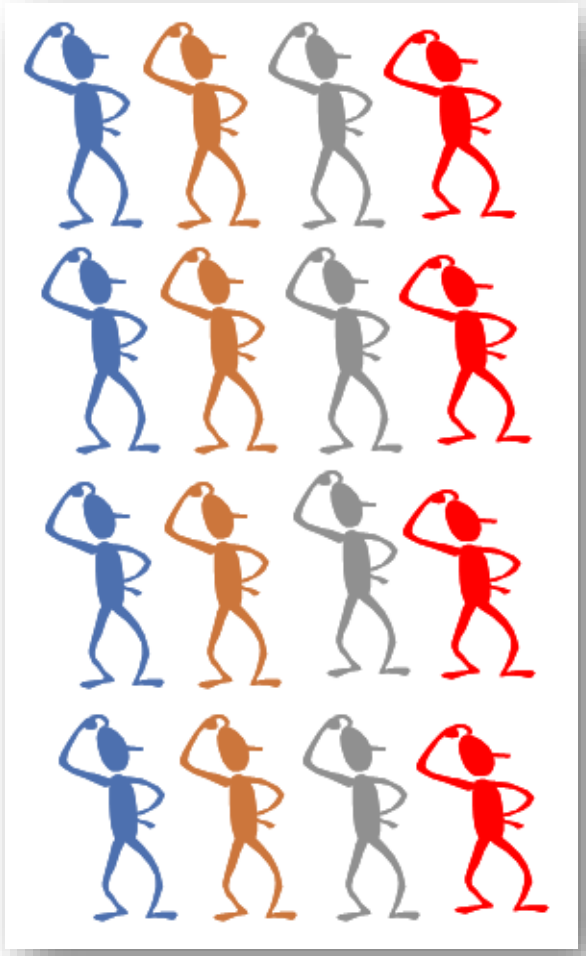


To summarize

How to **detect, automatically,** the abnormal data ?



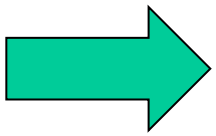
How to **correct, automatically,** these anomalies **without creating new ones**?

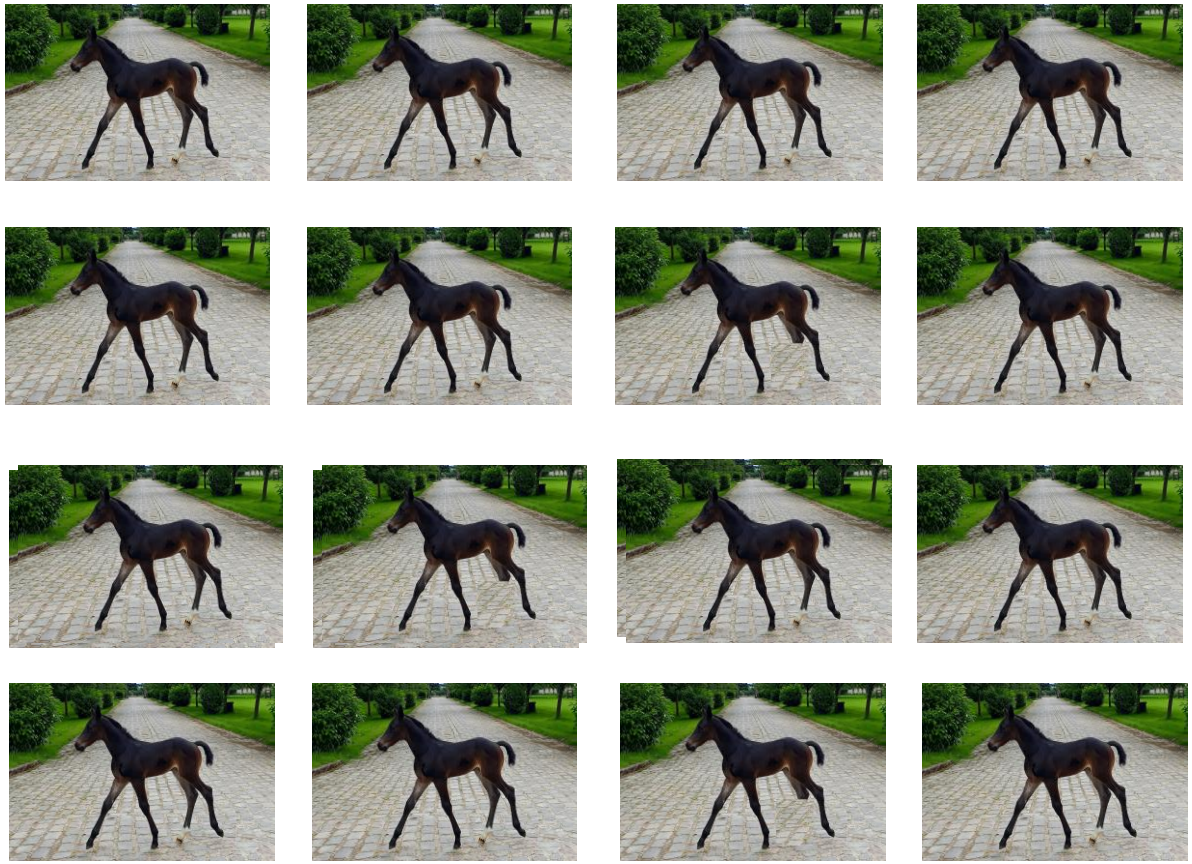


Anomalies détectées / Attention aux Mises à Jour / Anomalies corrigées

To summarize

How to **detect, automatically,** the abnormal data ?



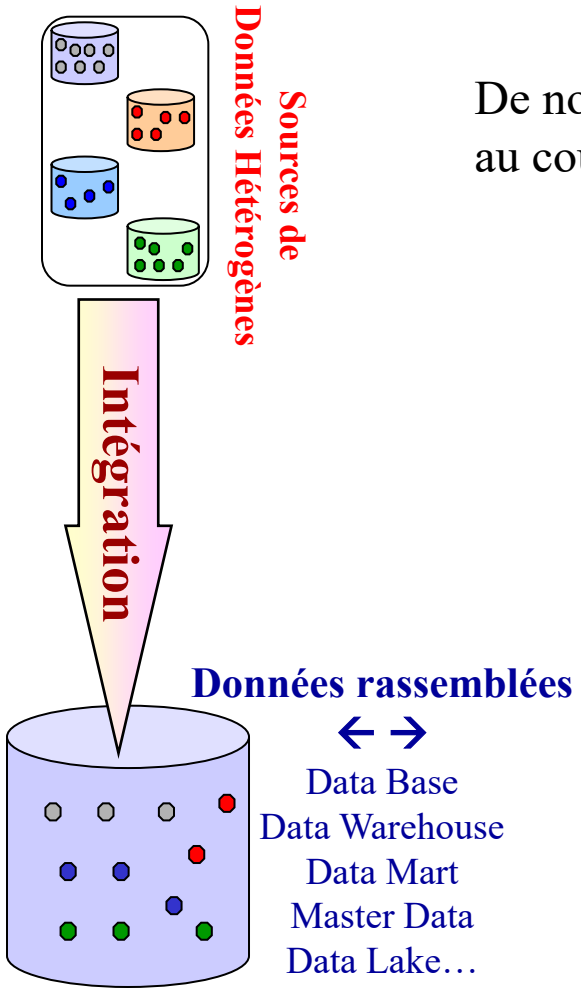


How to **correct, automatically,** these anomalies **without creating new ones**?





Donner un SENS aux données rassemblées



De nombreuses questions, **relatives à la qualité**, doivent être posées au cours du **processus de creation et/ ou d'intégration** :

* **Compatibilité** des types de données (**syntaxique**)
* **Compatibilité sémantique**
* Les contraintes sur les données
* Transformer / Corriger / Nettoyer / Valider des données
* Enrichir / Compléter les données
* Gérer les dépendances sémantiques
* Gérer les Doubles & les Similaires
* Gérer les métadonnées

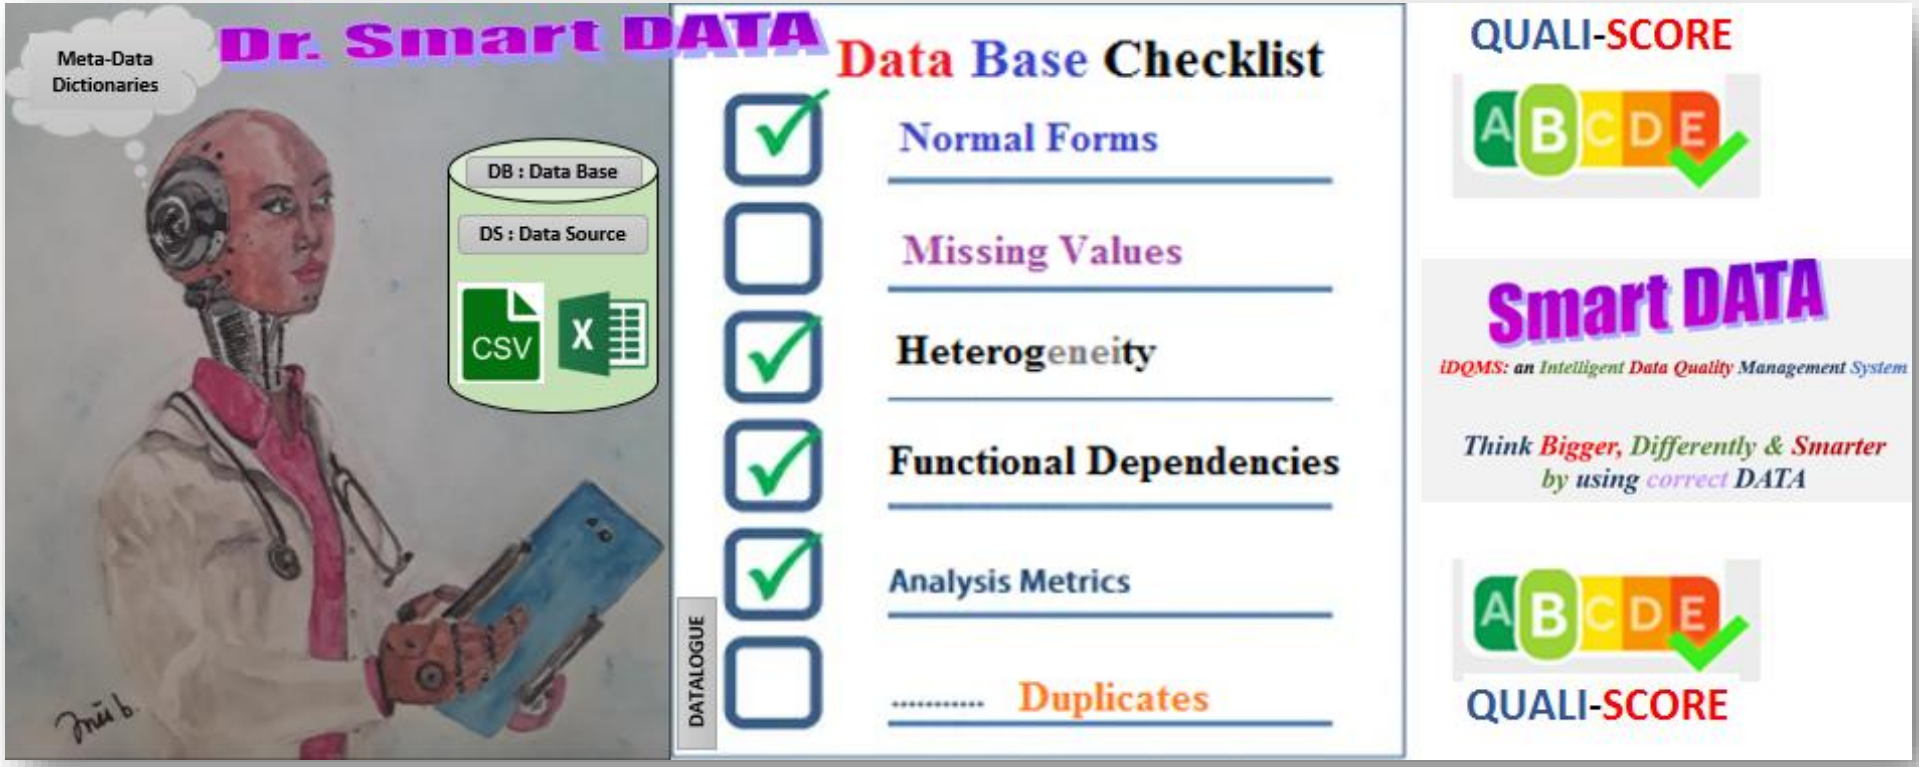
→ **Comment le savoir ?**

→ La **syntaxte** oui mais plus de **sémantique** !

...Des questions sur Les Données, La Data?...



Think Bigger, Differently & Smarter by using correct DATA



Smart DATA

iDQMS : intelligent Data Quality Management System

Donner un SENS aux données rassemblées

BD1-Cli						
NomCli	PrénomCli	Catégorie	Score	Type	Adresse	Mail
C(20)	C(20)	F, M	[0..20]	1, 2, 3	C(150)	C(200)
Le Bon	Adam	M	19	1	2, r de la Paix 75008 Paris France	adm@yahoo.fr
Clément	Clémence	F	16	2	5, r de Belleville 75019 Pari Franc	cc@gmail.fr
Premier	Inès	F	7	2	27, r de la Paix 75008 Paris	titi@yahoo.fr

+

BD2-Clients						
Nom	Prénom	Sexe	Note	CatégSoc	AdrPays	Courriel
C(30)	C(30)	N(1) !	[0..10]	A, B, C, D, E	C(50)	C(100)
Le Bon	Adamo	1	9	A	France	adm@yahoo.fr
Clément	Lina	0	7	E	France	clina@orange.fr
First	Inès	0	3	A	Espagne	cmoi@gmail.com
Adem	LeBon	1	8	A	France	adm@yahoo.fr

Des anomalies, Données incorrectes

Doublons

Similaires

Valeurs nulles

Etc…

=

ED Résultat de l'intégration Cli-Clients						
	Nom	Prénom	Sexe	Score	CatégSoc	Pays	Mail
???	C(20)	C(20)	F, M	[0..20]	1, 2, 3	C(150)	C(200)
???	C(30)	C(30)	N(1) ! 0,1	[0..10]	A, B, C, D, E	C(50)	C(100)
	Le Bon	Adam	M	19	1	2, r de la Paix 75008 Paris France	adm@yahoo.fr
	Clément	Clémence	F	16	2	5, r de Belleville 75019 Pari Franc	cc@gmail.fr
	Premier	Inès	F	7	2	27, r de la Paix 75008 Paris	titi@yahoo.fr
	Le Bon	Adamo	1	9	A	France	adm@yahoo.fr
	Clément	Lina	0	7	E	France	clina@orange.fr
	First	Inès	0	3	A	Espagne	cmoi@gmail.com
	Adem	LeBon	1	8	A	France	adm@yahoo.fr

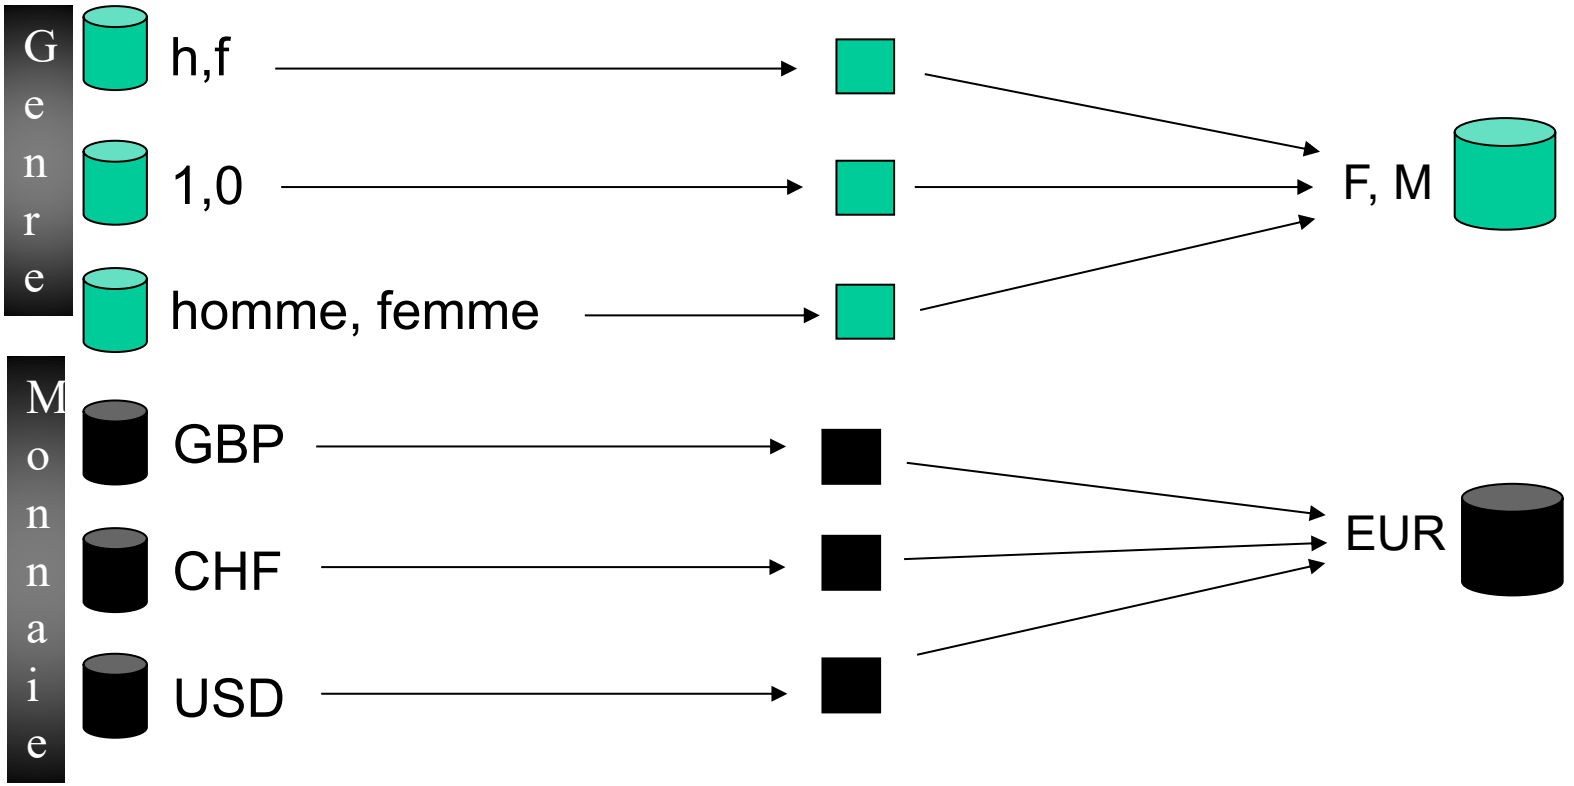


Donner un SENS aux données rassemblées

Homogénéisation des données intégrées

Homogénéisation, Standardisation, Normalisation… des données

Données intégrées : **Homogénéisation, Standardisation, Normalisation**… des données ;
Définition d'un **référentiel unique**

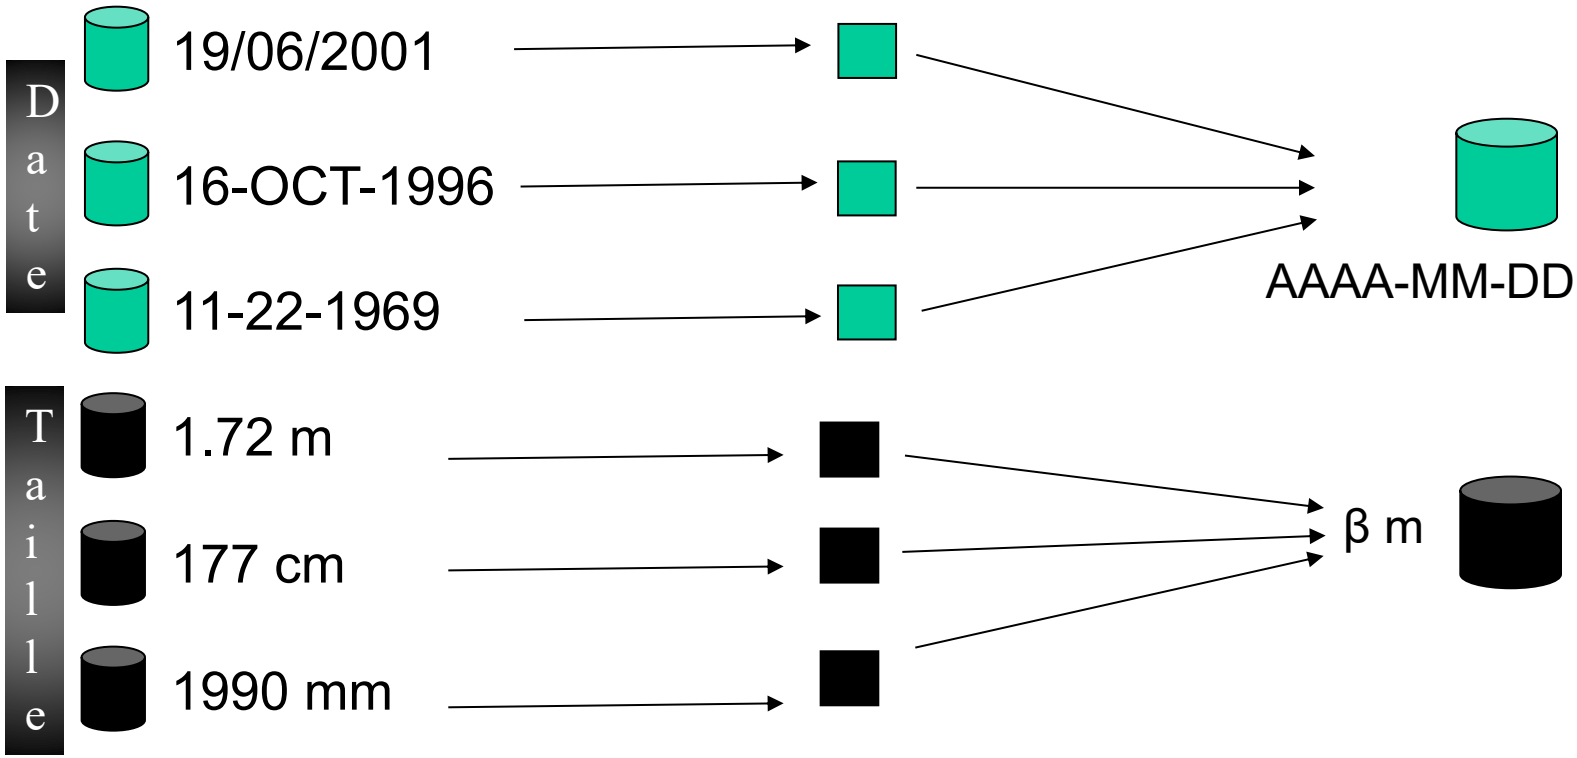


Donner un SENS aux données rassemblées

Homogénéisation des données intégrées

Homogénéisation, Standardisation, Normalisation… des données

Données intégrées : **Homogénéisation, Standardisation, Normalisation**… des données ;
Définition d'un **référentiel unique**



Donner un SENS aux données rassemblées

Quelques traitements à faire pour créer des données destinations correctes :

⇨Transformations

- Catégorie (F,M) → Sexe/Genre (F,M)
- **Sexe (Non défini ou défini 0,1) → Sexe (F,M)**

  ??? 0/F, 1/M ou 1/F, 0/M -- bijection
- Type (1, 2, 3) → CatégorieSociale (1, 2, 3)
- CatégSoc (A, B, C, D, E) → CatégorieSociale (1, 2, 3)

  ??? 1/A, 2/B, 3/C, !/D, !/E -- pas de bijection
- **Note [0..10] → Score [0..20]**

⇨Extraction/Déduction Adresse C(150) → Pays C(50)

55, r de Belleville 75019 Pari Franc → **France**

27, r de la Paix 75008 Paris NULL → France

⇨Déduplication Est-ce que **Le Bon Adamo** est la même personne que **Le Bon Adam ?**

Donner un SENS aux données rassemblées

BD1-Cli						
NomCli	PrénomCli	Catégorie	Score	Type	Adresse	Mail
C(20)	C(20)	F, M	[0..20]	1, 2, 3	C(150)	C(200)
Le Bon	Adam	M	19	1	2, r de la Paix 75008 Paris France	adm@yahoo.fr
Clément	Clémence	F	16	2	5, r de Belleville 75019 Pari Franc	cc@gmail.fr
Premier	Inès	F	7	2	27, r de la Paix 75008 Paris	titi@yahoo.fr

+

BD2-Clients						
Nom	Prénom	Sexe	Note	CatégSoc	AdrPays	Courriel
C(30)	C(30)	N(1) !	[0..10]	A, B, C, D, E	C(50)	C(100)
Le Bon	Adamo	1	9	A	France	adm@yahoo.fr
Clément	Lina	0	7	E	France	clina@orange.fr
First	Inès	0	3	A	Espagne	cmoi@gmail.com
Adem	LeBon	1	8	A	France	adm@yahoo.fr

=

ED Résultat de l'intégration Cli-Clients						
NomCli	PrénomCli	Catégorie	Score	Type	Adresse	Mail
C(20)	C(20)	F, M	[0..20]	1, 2, 3	C(150)	C(200)

Nom	Prénom	Sexe	Note	CatégSoc	AdrPays	Courriel
C(30)	C(30)	N(1) !	[0..10]	A, B, C, D, E	C(50)	C(100)

Nom	Prénom	Sexe	Score	CatégSoc	Pays	Mail
C(30)	C(30)	F, M	[0..20]	1, 2, 3	C(50)	C(200)
Le Bon	Adam	M	19	1	France	adm@yahoo.fr
Clément	Clémence	F	16	2	France	cc@gmail.fr
Premier	Inès	F	14	2	France	titi@yahoo.fr
Clément	Lina	F	14	3	France	clina@orange.fr
First	Inès	F	6	1	Espagne	cmoi@gmail.com



Données correctes

Peu ou Sans

doublon(s), ni similaire(s), ni redondance(s), ni valeur(s) nulle(s) !!! Etc…

- Quel **schéma** résultat ?
- Quelles **transformations** ?
- **Elimination** des **similaires,** des **doubles** et des **redondances !**
- Enrichissement des données !

Plusieurs types d'anomalies (Intra-Colonne, Inter-Colonnes et Inter-Lignes)

	Clients					
	Nom Prénom	**Téléphone**	**Mail**	**Catégorie**	**Ville**	**Chiffre d'affaires**
t1	**Le Bon Adam**	0653545577	adam@yahoo.fr	1	Londres	1000
t2	**Le Bon A.**	0653545555	-	1	**London**	~~2000~~ **£**
t3	Grande Clémence	0607080911	clemence@gmail.com	2	Epinay sur seine	1000
t4	**Adam LeBon**	0653545555	adam@yahoo.fr			
t5	Grande Clémence	607080911	clemence@gmail.com	2	Epinay / seine	1000
t6	**Le Bon**	0653545577	adam@yahoo.fr	1	Londres	-
t7	Belle Inès	0708091122	belleines@yhoo.fr	3	~~Epinay Villetaneuse~~	3000
t8	Rahma Adam	-	-	3	Epinay-sur-seine	1000
t9	Riche Emir	0908070605	-	3	~~Qatar~~	~~20000000000~~
t10	Traifor Eve	0666622223	traifor@up13.fr	1	Pékin	1000
t11	Traifor Eve	0666622223	traifor@up13.fr	1	**Beijing**	1000
t12	***LeBon Adel***	0653545599	alebon@up13.fr	1	Paris	-
t13	**LeBon Adem**	-	~~adam@obsolete.uk~~	1	~~Londre~~	-

Des SIMILAIRES
Des DOUBLONS

Des données obsolètes

Donnée NON Standard
Donnée NON Standard
Donnée NON Valide

Des valeurs aberrantes

- Les algorithmes, pour les corriger, sont très coûteux en terme de temps de réponse
- **Comment savoir ce qu'il y a à corriger et ce qu'il faut corriger ?** **Comment corriger ?**

Elimination des doubles et des similaires

L'**élimination des doubles et des similaires**, appelée **déduplication des données** (**Record Linkage, Duplicates Data, Entity Resolution, Entity Matching**), consiste à **détecter** les lignes doubles ou similaires afin d'éliminer certaines redondances dans une source de données (**Comparaison/Match**).

Les lignes similaires ou en double pourraient être fusionnées ou encore éliminées (**Fusion/Merge**).

Cette problématique continue à faire l'objet de plusieurs travaux de recherche, d'une part, afin d'**améliorer les performances des algorithmes** pour de très **gros volumes de données**, et d'autre part, afin d'**obtenir de meilleures précisions** quant au **calcul de similarité** entre les lignes à cause des différentes anomalies qui existent dans les données.

En effet, la similarité entre les données est basée sur les **différentes méthodes de mesures de distances de similarités** qui existent dans la littérature telles que :

(i) les **mesures lexicographiques [s'écrit comme]**
(Levenshtein -Edit-Distance-, Jaro-Winkler, Q-Gram…), ou
(ii) les **mesures phonétiques [se prononce comme,** attention ! les langues**]**
(Soundex, Double Metaphone !).

Elimination des doubles et des similaires

	Clients					
	Nom Prénom	Téléphone	Mail	Catégorie	Ville	Chiffre d'affaires
t1	**Le Bon Adam**	0653545577	adam@yahoo.fr	1	Londres	1000
t2	**Le Bon A.**	0653545555	-	1	London	2000
t4	**Adam LeBon**	0653545555	adam@yahoo.fr			
t6	**Le Bon**	0653545577	adam@yahoo.fr	1	Londres	-
t10	Traifor Eve	0666622223	traifor@up13.fr	1	**Pékin**	1000
t11	Traifor Eve	0666622223	traifor@up13.fr	1	**Beijing**	1000
t12	***LeBon Adel***	0653545599	alebon@up13.fr	1	Paris	-

Algorithmes de calcul de distance de similarité (JW, J, L, S, M…) & Seuil (s_i)					
S'écrit comme *Jaro-Winkler*	*S'écrit comme* *Jaccard*	*S'écrit comme* *Levenshtein*		*Se prononce comme* Metaphone	
s_1	s_2	s_3	!!	s_5	!!

Le Bon Adam	≈	**LeBon A.**	≈	**Adam Le Bon**
Pékin	≈	**Beijing**		

Doubles ? Similaires ?

Vrais - Faux amis !

Faux - Vrais amis !







Elimination des doubles et des similaires

Difficulté de **choisir un algorithme** de calcul de distance de similarité (***Levenshtein [Edit_Distance] ; Jaro-Winkler…***)

Difficulté de **fixer** un seuil de similarité

- **Pékin ≠ Beijing** **Londres ≈ = ? Ou ≠ London** ⇨ **= ou ≈**

- **lipn-tous@lipn.univ-paris13.fr ≈ lipn-tous@lipn.univ-pari13.fr** ⇨ **= ou ≈**
- **yb@lipn.univ-paris13.fr ≈ fb@lipn.univ-paris13.fr** ⇨ **≠**

La comparaison lexicographique n'est pas suffisante ! Ville – Mail

⇨ **Plus de Sémantique**

Elimination des doubles et des similaires *Match/Merge*

	Clients					
	Nom Prénom	**Téléphone**	**Mail**	**Catégorie**	**Ville**	**Chiffre d'affaires**
t1	**Le Bon Adam**	0653545577	adam@yahoo.fr	1	Londres	1000
t2	**Le Bon A.**	0653545555	-	1	London	2000
t4	**Adam LeBon**	0653545555	adam@yahoo.fr			

Déf. A : *Similarité entre tuples*

2 tuples t_i et t_j $(i \neq j)$ sont similaires ssi la disjonction des q règles de similarité définies sur la table T(A,B) est vraie. On note $t_i \approx t_j$ ssi $r_1 \vee r_2 \vee \ldots \vee r_k \ldots \vee r_q$

(q étant le nombre de règles de similarité, A l'ensemble des attributs clé A_a a=1,n et B l'ensemble des attr. non clé)

$$\mathbf{t_1 \approx t_2 \text{ ssi } R_{ules} = Vrai} \qquad \mathbf{R_{ules} = r_1 \vee r_2 \vee \ldots \vee r_k \ldots \vee r_q}$$

Règle : r_1 $[(Nom_1 \approx Nom_2) \wedge (Mail_1 \approx Mail_2) \wedge (Ville_1 \approx Ville_2)]$

Règle : r_2 $[(Mail_1 \approx Mail_2) \wedge (Téléphone_1 \approx Téléphone_2)]$

…

Règle : r_q

Elimination des doubles et des similaires *Match/Merge*

	Clients					
	Nom Prénom	**Téléphone**	**Mail**	**Catégorie**	**Ville**	**Chiffre d'affaires**
t1	**Le Bon Adam**	0653545577	adam@yahoo.fr	1	Londres	1000
t2	**Le Bon A.**	0653545555	-	1	London	2000
t4	**Adam LeBon**	0653545555	adam@yahoo.fr			

1-Les attributs de l'ensemble A (Attributs clés) ?

Nom-Prénom ; Mail ? … → Comparaison/Match

2-Les attributs de l'ensemble B (Attributs non clés) ?

Catégorie, Chiffre d'affaires ? … → Fusion/Merge

3-Les algorithmes et les seuils de comparaison

Blocking key ! Clé de blocage !

Elimination des doubles et des similaires *Match/Merge*

	Clients					
	Nom Prénom	**Téléphone**	**Mail**	**Catégorie**	**Ville**	**Chiffre d'affaires**
t1	**Le Bon Adam**	0653545577	adam@yahoo.fr	1	Londres	1000
t2	**Le Bon A.**	0653545555	-	1	London	2000
t4	**Adam LeBon**	0653545555	adam@yahoo.fr			

$Nom_1 = t_1.NomPrénom$; $Nom_2 = t_2.NomPrénom$

$$\mathbf{Nom_1 \approx Nom_2 \text{ ssi } d_1 \leq s_1}$$

d_1=***Jaro-Winkler***('Le Bon Adam','Le Bon A.') ou d_1=***Levenshtein***('Le Bon Adam','Le Bon A.')

Les ***seuils*** s_a et les ***algorithmes*** de calcul de distance sont **donnés par l'utilisateur** !

→ **MATCH**

Quelles **valeurs garder** ? « *La chaine la plus longue vérifiant une expression régulière, le maximum… »*

1-Les attributs de l'ensemble A: Nom-Prénom …

2-Les attributs de l'ensemble B: Catégorie, Chiffre d'affaires → **MERGE**

Elimination des doubles et des similaires *Match/Merge*

	Clients					
	Nom Prénom	**Téléphone**	**Mail**	**Catégorie**	**Ville**	**Chiffre d'affaires**
t1	**Le Bon Adam**	0653545577	adam@yahoo.fr	1	Londres	1000
t2	**Le Bon A.**	0653545555	-	1	London	2000
t4	**Adam LeBon**	0653545555	adam@yahoo.fr			

Les algorithmes de calcul de distance de similarité donnent :

Le Bon Adam ≠ Adam LeBon

La comparaison lexicographique n'est donc pas suffisante ! ⇨ Plus de **Sémantique**

Afin de « forcer » l'égalité **Le Bon Adam = Adam LeBon** on introduit la règle de similarité des **DF :**

La règle r_2 est issue de la **dépendance fonctionnelle** avec des seuils proches de 0 pour Mail et Téléphone :

Mail, Téléphone → Nom-Prénom

Elimination des doubles et des similaires *Match/Merge*

	Clients					
	Nom Prénom	**Téléphone**	**Mail**	**Catégorie**	**Ville**	**Chiffre d'affaires**
t1	**Le Bon Adam**	0653545577	adam@yahoo.fr	1	Londres	1000
t2	**Le Bon A.**	0653545555	-	1	London	2000
t4	**Adam LeBon**	0653545555	adam@yahoo.fr			

Déf. B : *Similarité entre tuples*

2 tuples t_i et t_j ($i \neq j$) sont similaires ssi ; on note $\mathbf{t_1 \approx t_2}$ **ssi**

$$\sum_{a=1,n} p_a d_a \leq S$$

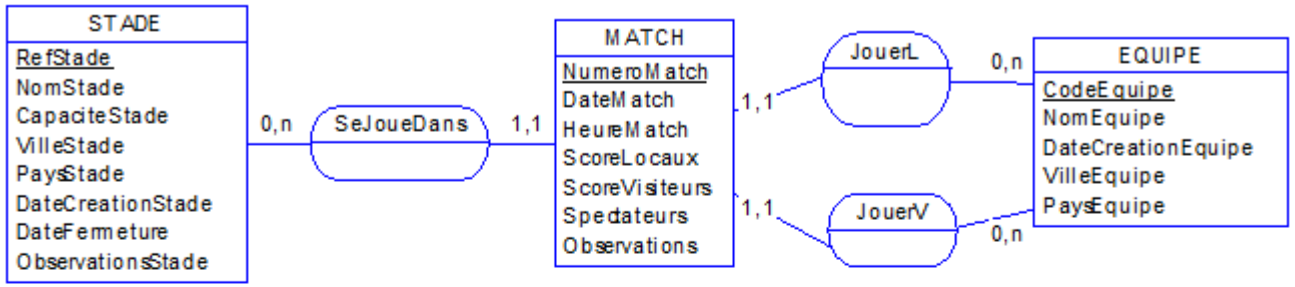
d_a (distance calculée par un des algorithmes de calcul de similarité, pour un attribut A_a donné)

p_a (le poids pour un attribut A_a donné) et S un seuil GLOBAL donné

Les ***poids,*** les ***algorithmes*** et le ***seuil global*** sont ***donnés*** par ***l'utilisateur*** !

Dépendance Fonctionnelle (DF & DFA)

Elimination des similaires et dépendances fonctionnelles



- A une date donnée une équipe ne peut jouer que dans un seul stade
  DateMatch, CodeEquipeLocale → RefStade
  DateMatch, CodeEquipeVisiteuse → RefStade

- A une date donnée une équipe ne peut jouer que contre une seule équipe
  DateMatch, CodeEquipeLocale → CodeEquipeVisiteuse

MATCH						Erreur ?!
NumeroMarch	**DateMatch**	**CodeEquipeLocale**	**CodeEquipeVisiteuse**	**RefStade**	**…**	
M1	09-06-2012	Allemagne	Portugal	S1		
M2	13-06-2012	Hollande	Allemagne	S2		
M3	10-06-2012	**France**	**France**	S1		OUI
M3 : Une équipe ne peut pas jouer avec elle-même !						
M4	**11-06-2012**	**France**	Angleterre	**S2**		OUI
M5	**11-06-2012**	**France**	Allemagne	**S3**		OUI
M4 & M5 : Une équipe ne peut pas jouer contre deux équipes le même jour dans deux stades différents ! Quelle ligne faut-il supprimer (M4 ou M5) ?						
M6	19-06-2012	Suède	France	S4		
M7	Etc…	Etc…	Etc…	Etc…		

Dépendance Fonctionnelle (DF & DFA)

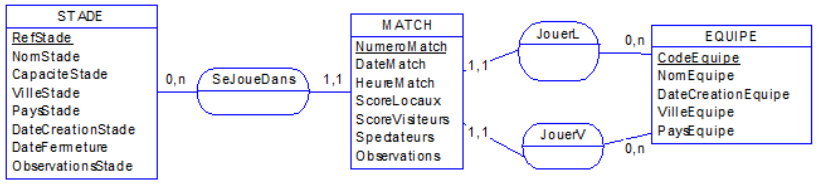
Les contraintes définies sur le schéma conceptuel ne suffisent pas pour éviter des données (lignes) erronées dans la BD !

La **détection des lignes erronées** n'est qu'une **partie du problème** !

La question est : **Quelle(s) ligne(s)** faut-il enlever afin d'éliminer l'erreur !

→ ++ **Sémantique** !

Elimination des similaires et dépendances fonctionnelles



- A une date donnée une équipe ne peut jouer que dans un seul stade
  DateMatch, CodeEquipeLocale → RefStade
  DateMatch, CodeEquipeVisiteuse → RefStade

- A une date donnée une équipe ne peut jouer que contre une seule équipe
  DateMatch, CodeEquipeLocale → CodeEquipeVisiteuse

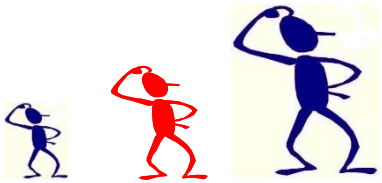
MATCH						Erreur ?!
NumeroMarch	DateMatch	CodeEquipeLocale	CodeEquipeVisiteuse	RefStade	…	
M1	09-06-2012	Allemagne	Portugal	S1		
M2	13-06-2012	Hollande	Allemagne	S2		
M3	10-06-2012	France	France	S1		OUI
M3 : Une équipe ne peut pas jouer avec elle-même !						
M4	11-06-2012	France	Angleterre	S2		OUI
M5	11-06-2012	France	Allemagne	S3		OUI
M4 & M5 : Une équipe ne peut pas jouer contre deux équipes le même jour dans deux stades différents ! Quelle ligne faut-il supprimer (M4 ou M5) ?						
M6	19-06-2012	Suède	France	S4		
M7	Etc…	Etc…	Etc…	Etc…		

4. Intégration de données

(Bases, Entrepôts, Lacs, Référentiel…)

Data Base, Data Warehouse, Data Lake, Master Data

Think Bigger, Differently & Smarter by using DATA

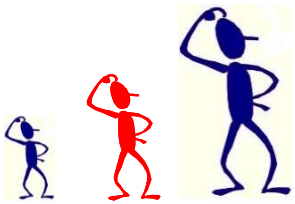




UNIVERSITÉ SORBONNE PARIS NORD

DoD : des Données aux Décideurs !

Bases de Données – Data Bases



Entrepôts de Données – Data WareHouses

Lacs de Données – Data Lakes

Masses de Données – Big-Data

M. Faouzi BOUFARES
boufares@lipn.univ-paris13.fr
http://www.lipn.univ-paris13.fr/~boufares/
Bureau B209
Laboratoire d'Informatique de Paris Nord
LIPN – UMR 7030 du CNRS
La MSN, A3, ADA
Université Sorbonne Paris Nord
Institut Galilée
99, Avenue J.B. Clément
F-93430 Villetaneuse FRANCE
www.univ-paris13.fr
faouzi.boufares@sorbonne-paris-nord.fr

UNIVERSITÉ SORBONNE PARIS NORD

DoD : des Données aux Décideurs !

BD-DB ; ED-DW-DL ; BigData

Entrepôts de Données, Introduction

M. Faouzi BOUFARES

boufares@lipn.univ-paris13.fr

http://www.lipn.univ-paris13.fr/~boufares/

Bureau A109

Laboratoire d'Informatique de Paris Nord

LIPN – UMR 7030 du CNRS

La MSN, A3, ADA

Université Sorbonne Paris Nord

Institut Galilée

99, Avenue J.B. Clément

F-93430 Villetaneuse FRANCE

www.univ-paris13.fr

faouzi.boufares@sorbonne-paris-nord.fr

Plusieurs professionnels sont intervenus et/ou interviennent dans le cadre de ce cours :

R. Nefoussi, **Diac Renault**

S. Correia, **Talend**

I. Rebaï, **Orange**

C. Clairemont, **SynAltic**

L. Chorfi, **Micropole**

B. Chantouf, **Smile**

T. Arib, **Intelligence Power**

F. Sahli, **Société Générale**

P. Julio, **Keyrus**

O. Carbone, **Talend**

Zak, **CGI**

H. Zaidi, **Talend-ENT**

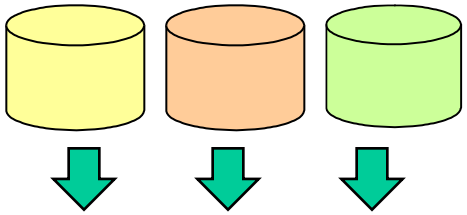
BD-DB ; ED-DW-DL ; BigData

Quelques Outils & Entreprises partenaires :



Les Bases de Données et la suite...!

Bases de Données
Data Bases



Outils / Tools :

Power AMC,

Oracle, BD2, PostgreSQL,… → **SQL**

mongoDB, HBase… → **NoSQL**

ETL Talend, Business Objects, Tableau



E(xtract)
T(ransform)
L(oad)

M(aster)
D(Data)
M(anagement)



Entrepôt de Données
Data WareHouse
Lac de Données
Data Lake

Référentiel de Données
Master Data
Big **Data Base** !

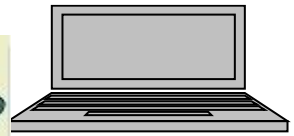
Data Integration

Données Sources Hétérogènes

Bases de Données

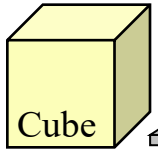
Data select
(Requêtes, Queries)

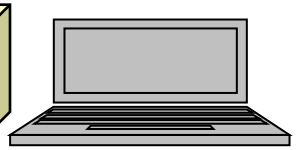




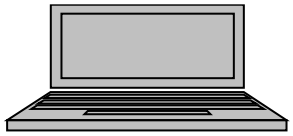
OLAP

Rapports, Analyses





SAS
(Datamining)













Extraction de Connaissances
Exploitation de données
Fouilles de Données

Introduction : Intégration de données

A l'ère du **déluge des données la qualité des données est plus que jamais à l'ordre du jour :**
(données de productions ; données du Web ; données ouvertes -*Open Data*- ; données dormantes non encore utilisées -*Dark Data*- beaucoup de données textuelles non structurées ; les *Big Data* ; …).

En effet, de nos jours, tout type d'organisation a besoin **d'intégrer (collecter, assembler) des données** en provenance de **diverses sources distribuées, hétérogènes** et de **qualités variables**.

Le plus souvent, **les descriptifs des données**, dans les sources, sont **mal renseignés** voire **inexistants**.

Par conséquent, **l'assemblage des données peut être dénué de tout sens et le résultat obtenu peut contenir de nombreuses anomalies**.

Introduction : Intégration de données

Données internes (Opérationnelles de production)

Bases de données (Structurées et Non structurées)

Fichiers (Plats, Textes, CSV, PDF…)

Applications (Paye, Gestion des RH, Commandes & Facturations…)

Données externes (Web, Open Data, Dark Data, …)

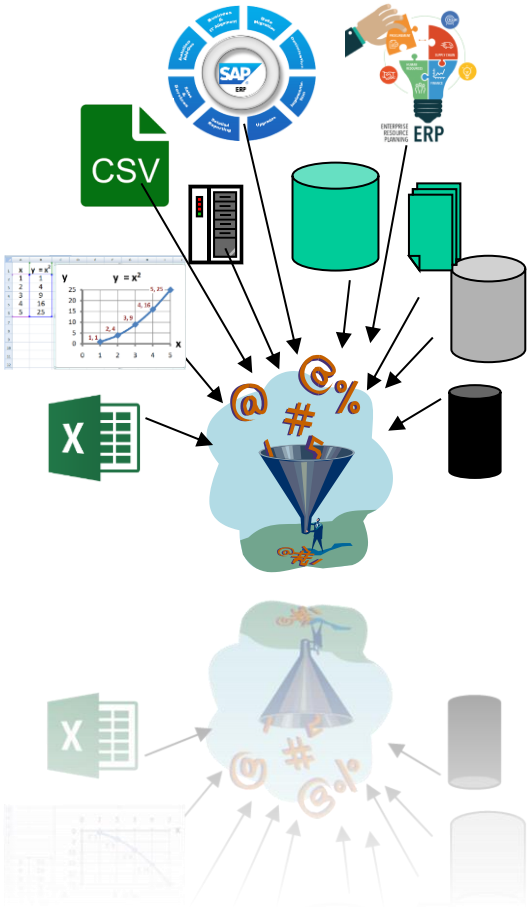
Caractéristiques de ces données

Distribuées

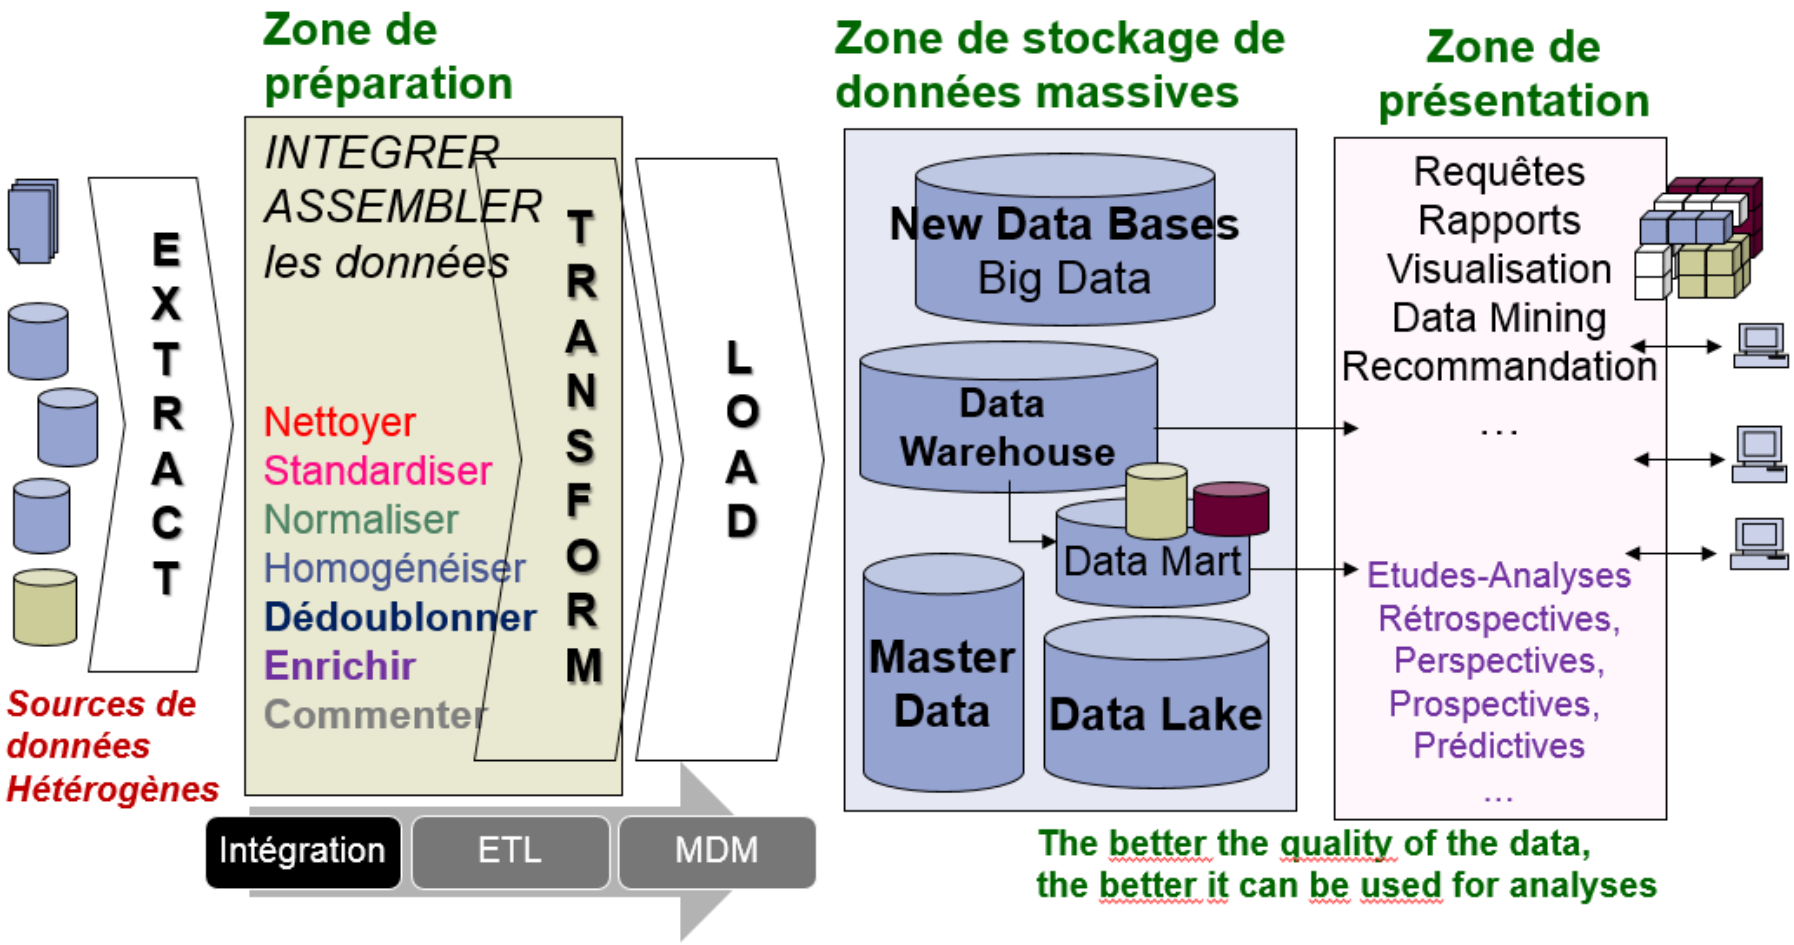
Hétérogènes (systèmes et structures de données différents)

Détaillées (peu ou pas adaptées à l'analyse)

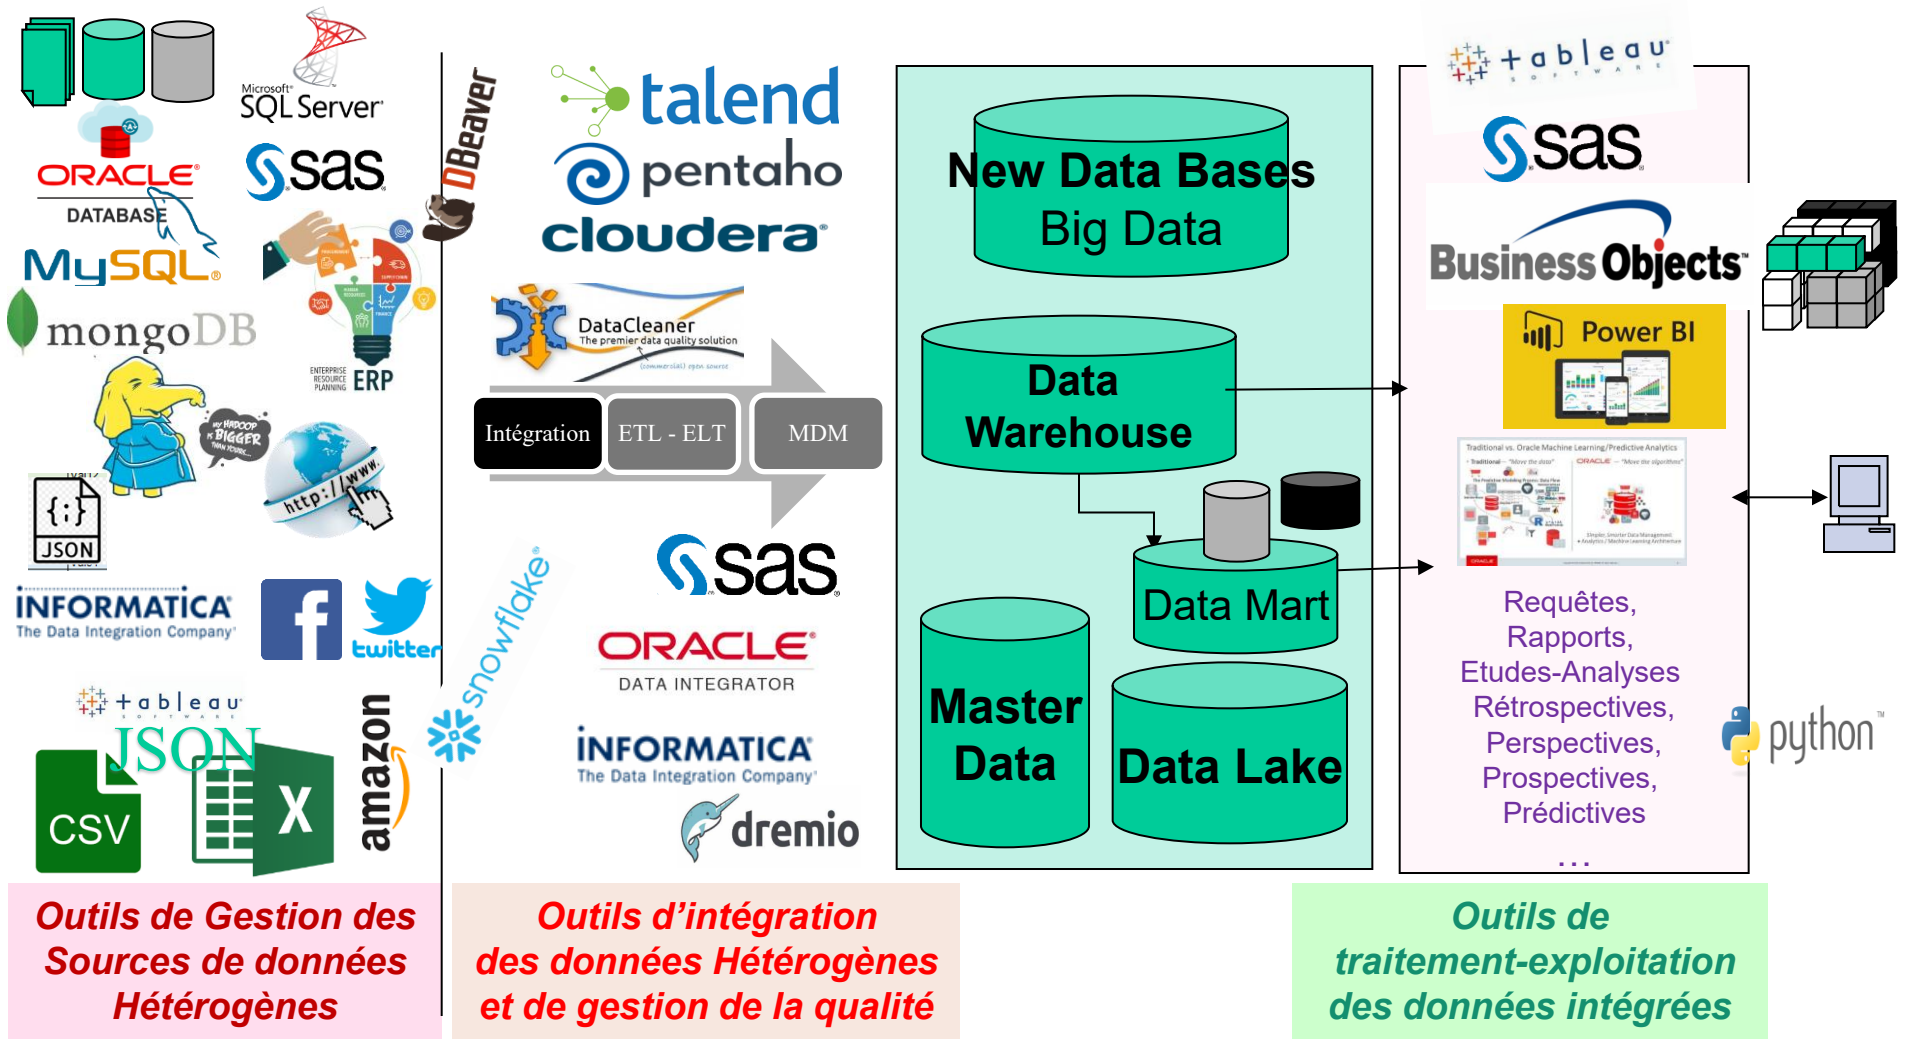
Qualité très variable (plutôt mauvaise, plusieurs anomalies)



... Intégration de Données ...



… Intégration de Données …



Outils de Gestion des Sources de données Hétérogènes

Outils d'intégration des données Hétérogènes et de gestion de la qualité

Outils de traitement-exploitation des données intégrées

... Intégration de Données ...

Un entrepôt de données (DWH) est élaboré en intégrant une ou plusieurs **bases de données**, elles-mêmes constituées de plusieurs **tables** (dans le monde relationnel), chacune étant composée de plusieurs **colonnes**.

$$DWH \subseteq \{ \oplus \otimes BD_i \; i=1,n \}$$

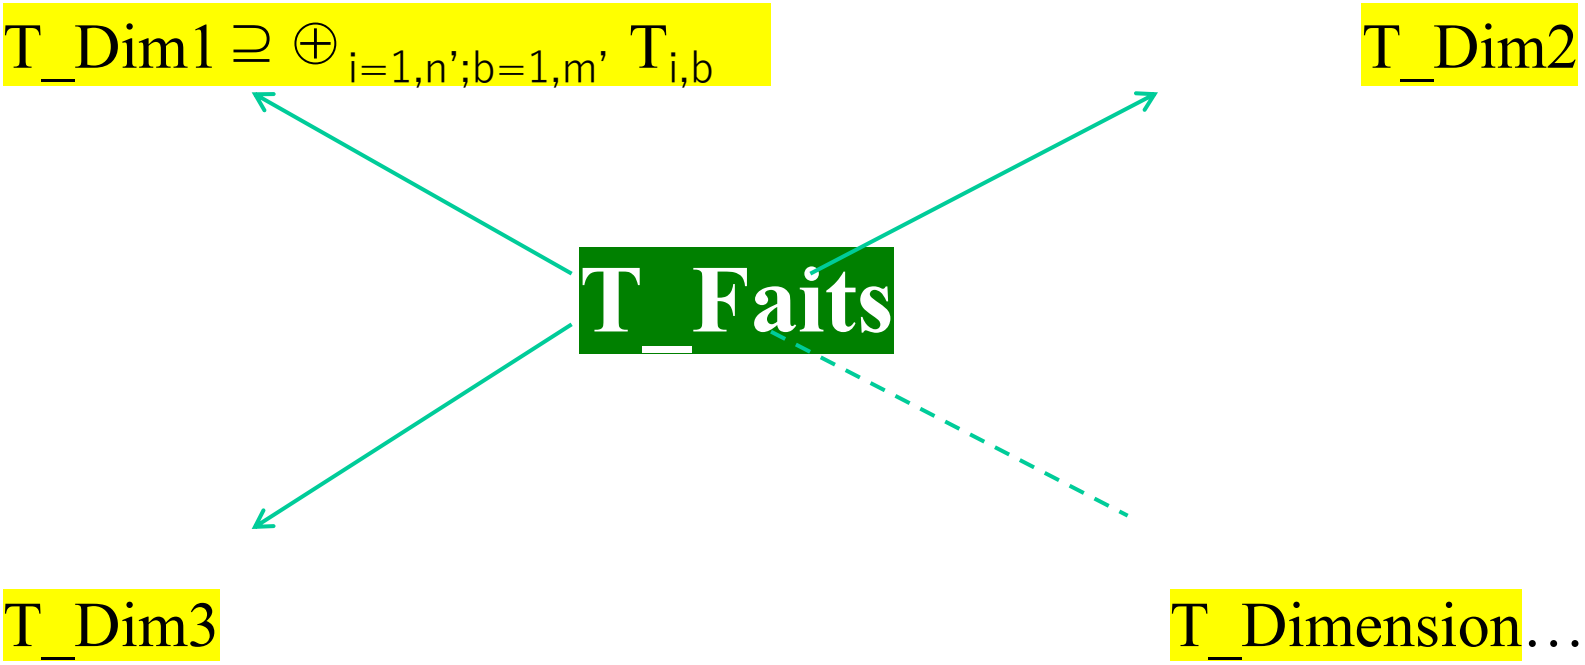
$$BD_i = \{ \otimes T_{i,j} \; j=1,m \} \qquad T_{ij} = \{ C_{i,j,k} \; k=1,p \}$$

La structure simplifiée d'un entrepôt de données conçu pour l'aide à la décision peut être représentée sous la forme d'un **schéma en étoile**, où une **table des faits**, contenant les **mesures et indicateurs calculés**, est entourée de **tables de dimensions** servant **d'axes d'analyse**.

… Intégration de Données …

$DWH \subseteq \{ \oplus \otimes BD_i \; i=1,n \}$

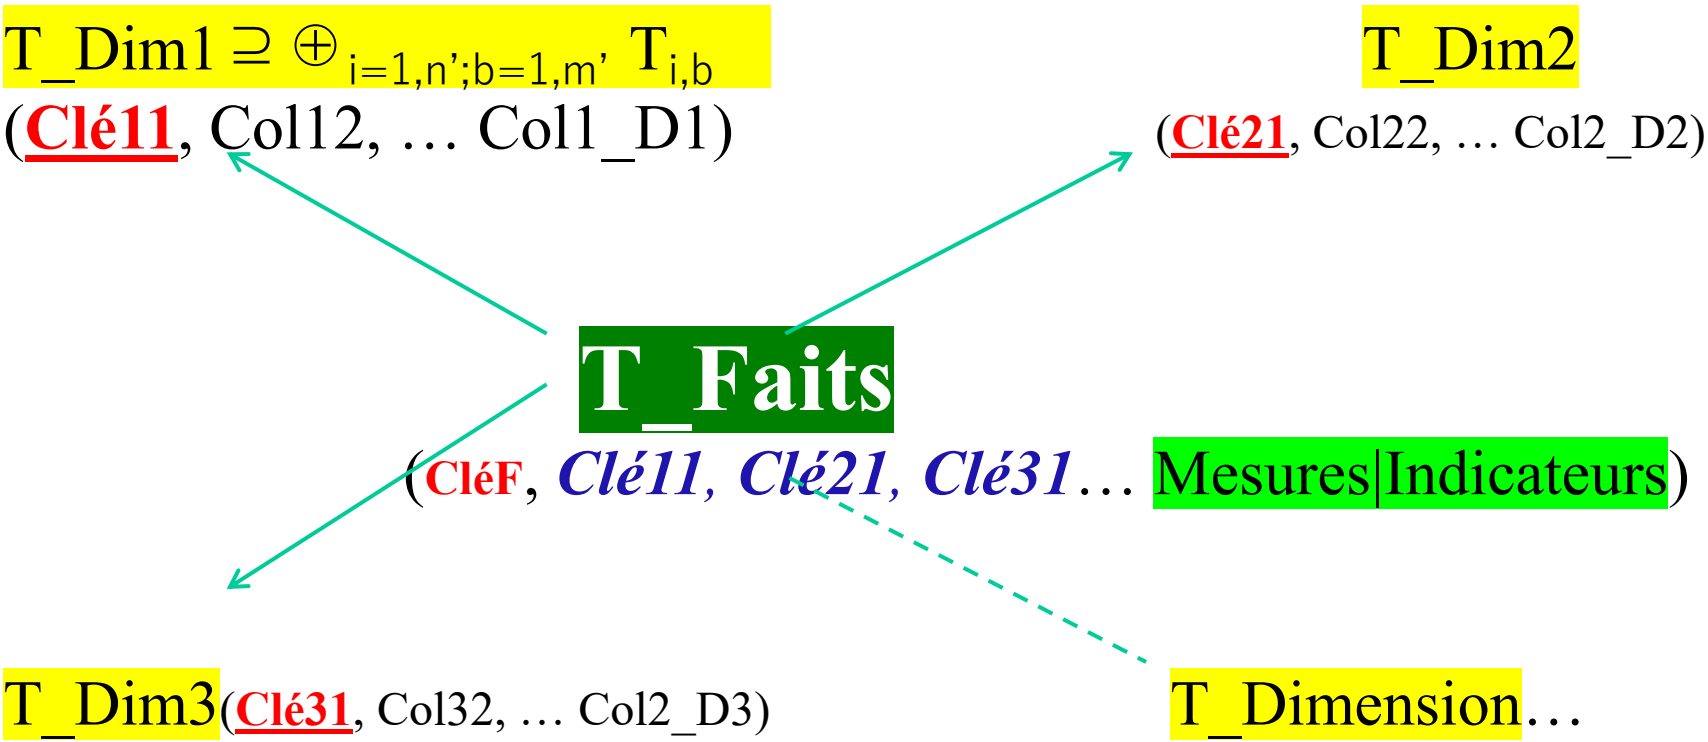
$BD_i = \{ \otimes T_{i,j} \; j=1,m \}$ $\quad\quad$ $T_{ij} = \{ C_{i,j,k} \; k=1,p \}$



… Intégration de Données …

$DWH \subseteq \{ \oplus \otimes BD_i \; i=1,n \}$

$BD_i = \{ \otimes T_{i,j} \; j=1,m \}$ $\quad\quad$ $T_{ij} = \{ C_{i,j,k} \; k=1,p \}$



... Intégration de Données ...

$$DWH \subseteq \{ \oplus \otimes BD_i \; i=1,n \}$$

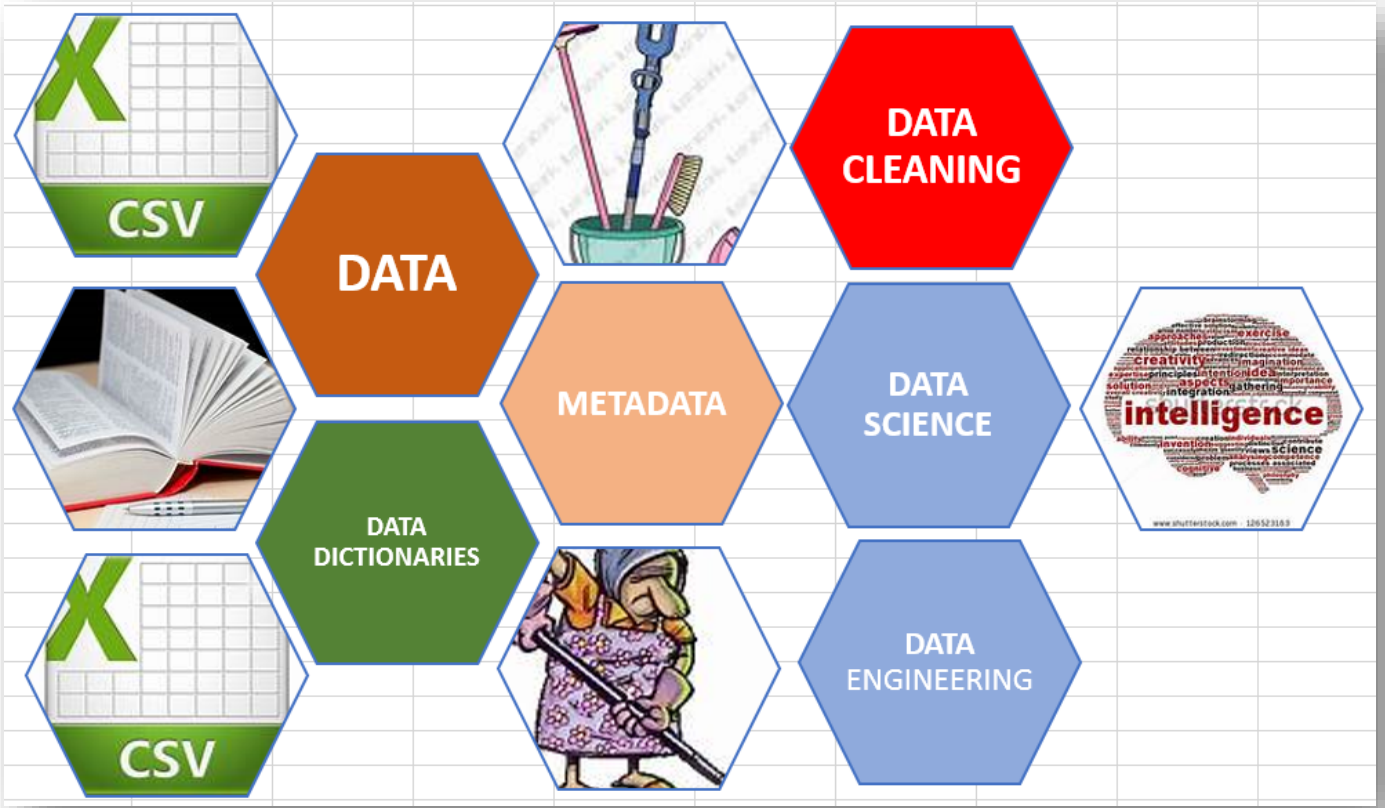
$$BD_i = \{ \otimes T_{i,j} \; j=1,m \} \qquad T_{ij} = \{ C_{i,j,k} \; k=1,p \}$$



… Intégration de Données …

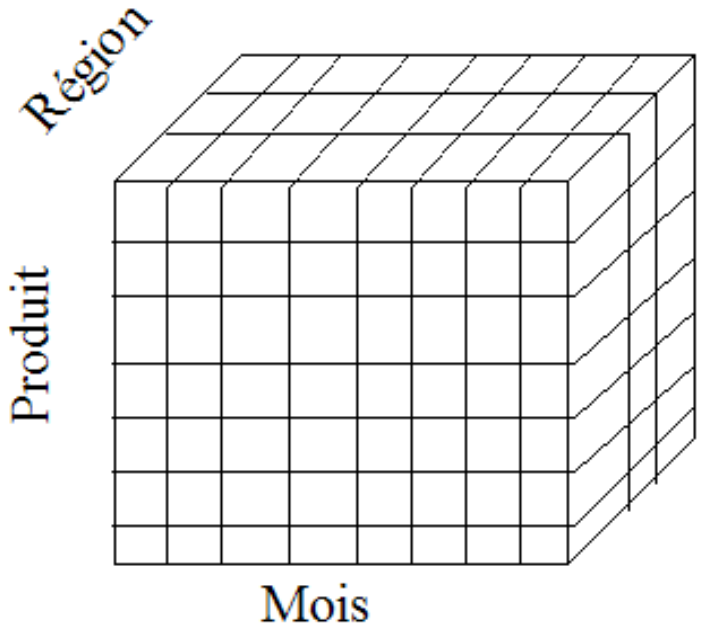
$$DWH \subseteq \{ \oplus \otimes BD_i \; i=1,n \}$$

$$BD_i = \{ \otimes T_{i,j} \; j=1,m \} \qquad T_{ij} = \{ C_{i,j,k} \; k=1,p \}$$

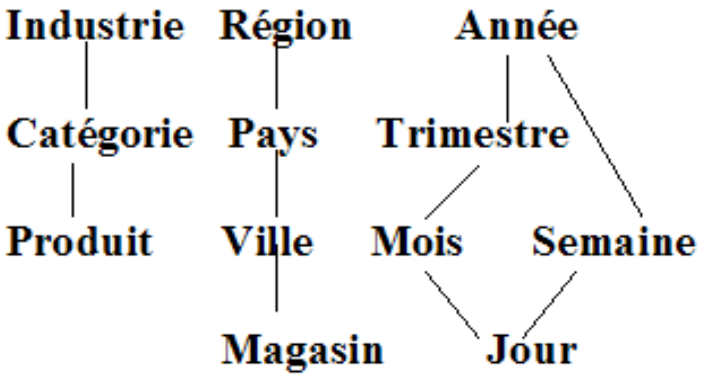


Données multidimensionnelles

- Montant des ventes comme une fonction des paramètres produit, mois, région



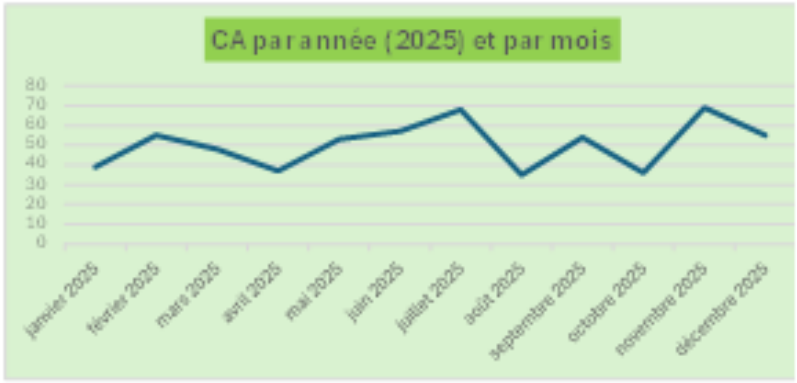
Dimensions: Produit, Lieu, Temps
Chemins de consolidation hiérarchiques



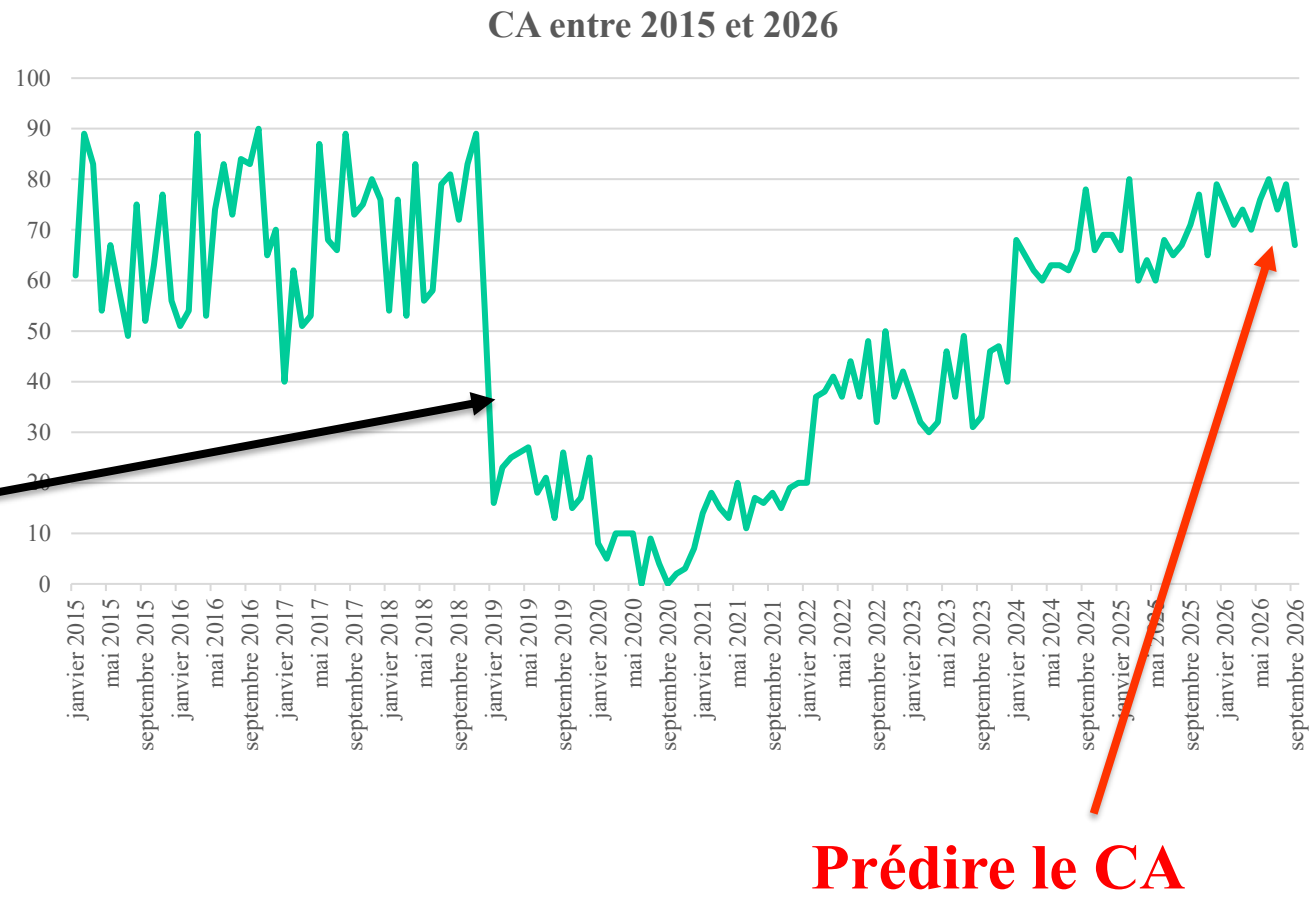
... Intégration de Données ...

Dates	CA
janvier 2024	44
février 2024	28
mars 2024	44
avril 2024	18
mai 2024	25
juin 2024	49
juillet 2024	15
août 2024	25
septembre 2024	25
octobre 2024	20
novembre 2024	21
décembre 2024	34
janvier 2025	39
février 2025	55
mars 2025	48
avril 2025	37
mai 2025	53
juin 2025	57
juillet 2025	68
août 2025	35
septembre 2025	54
octobre 2025	36
novembre 2025	69
décembre 2025	55





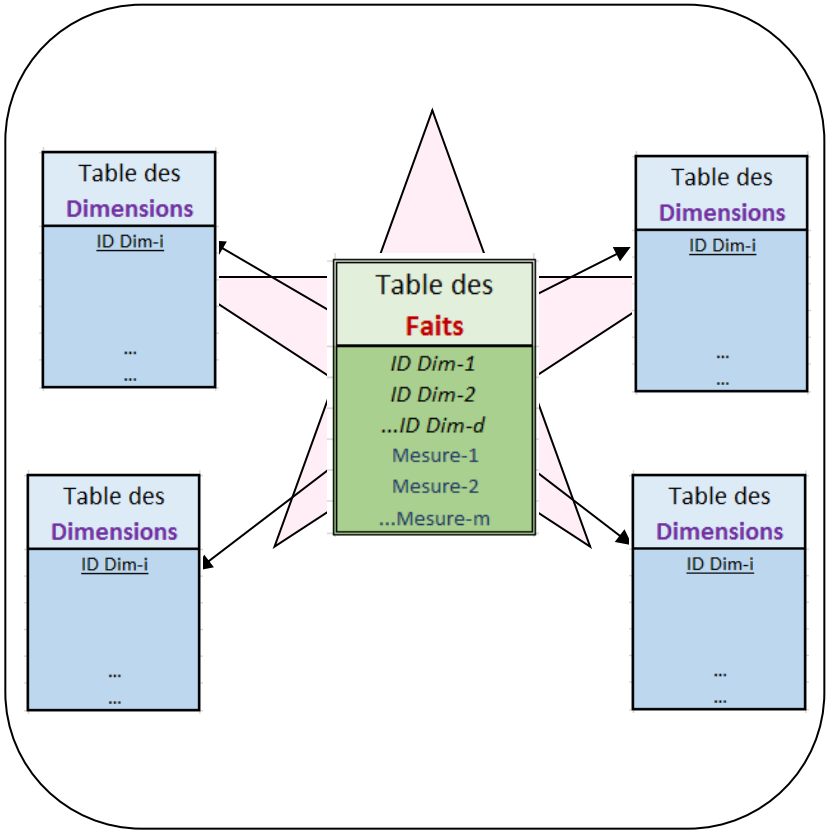
… Intégration de Données …



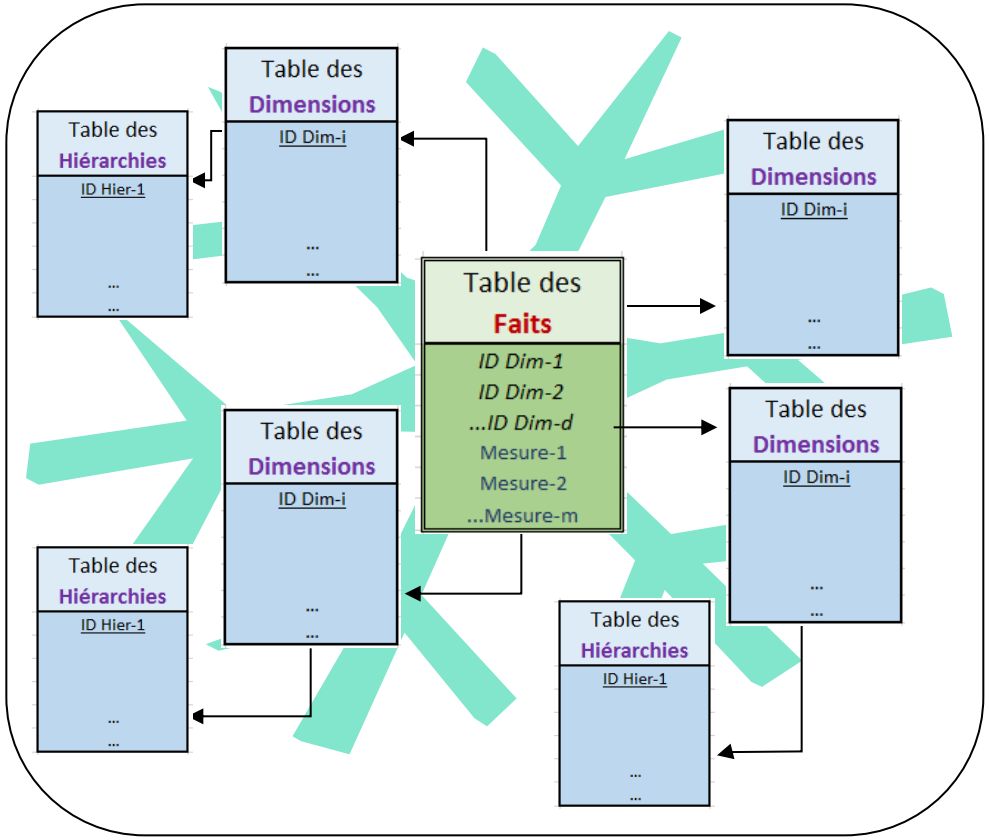
Explication du phénomène ! POURQUOI ?

Prédire le CA

Quelques types de modèles de données à construire

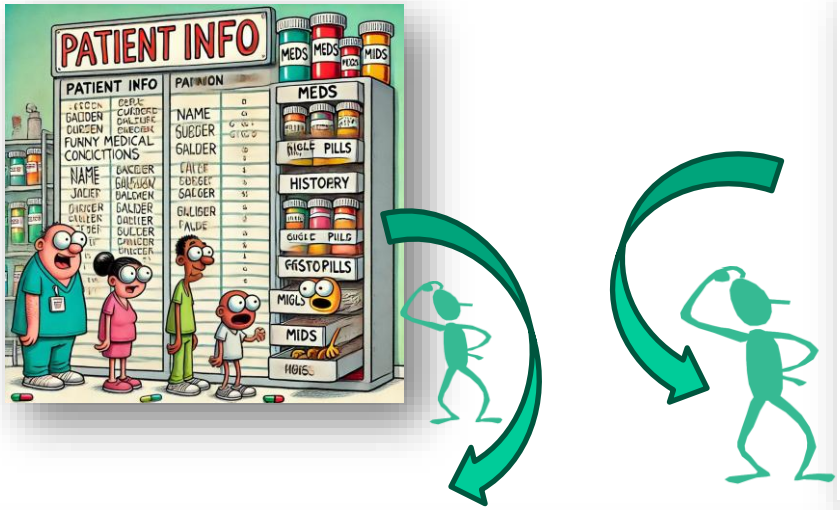


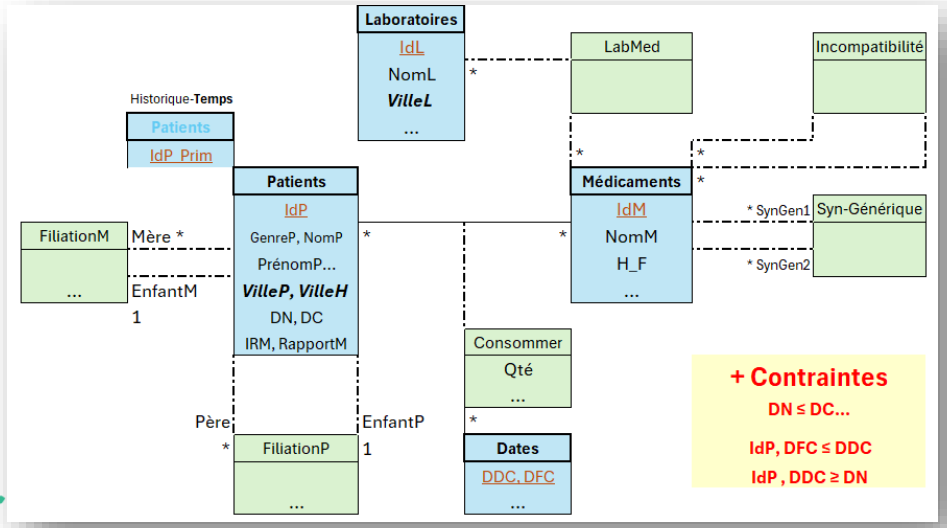
Modèle en étoile

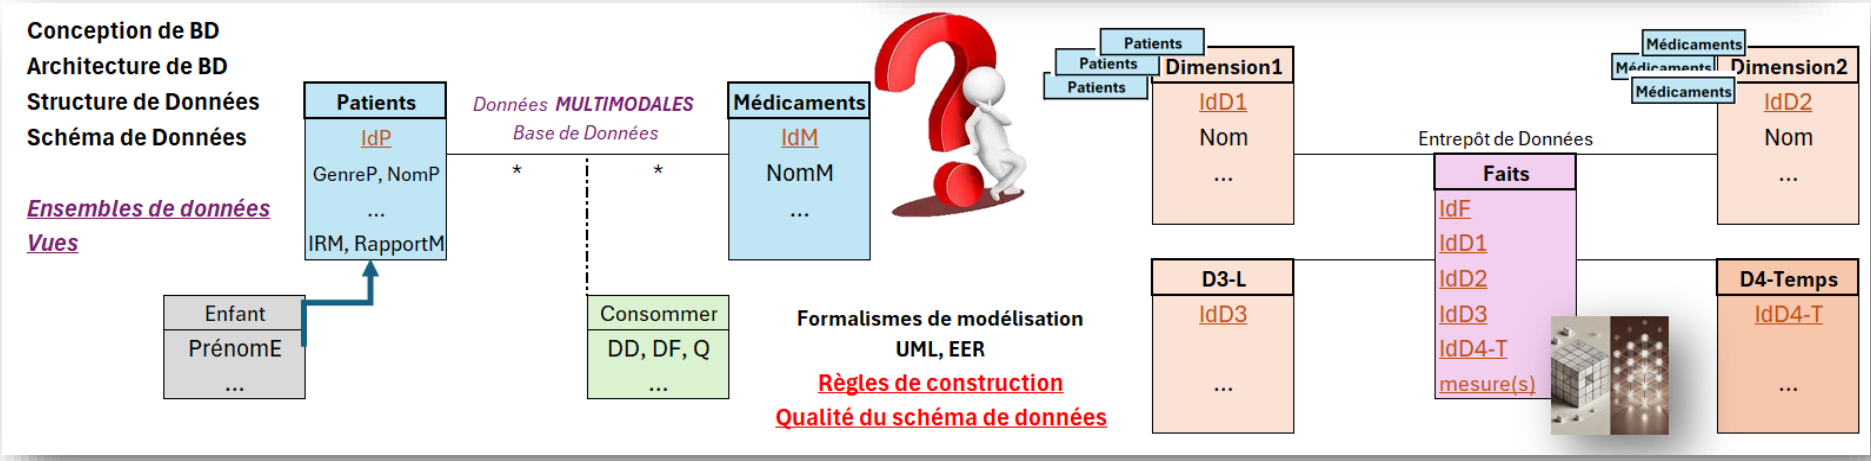


Modèle en flocon

Exemple 1 : Des données médicales à intégrer ?







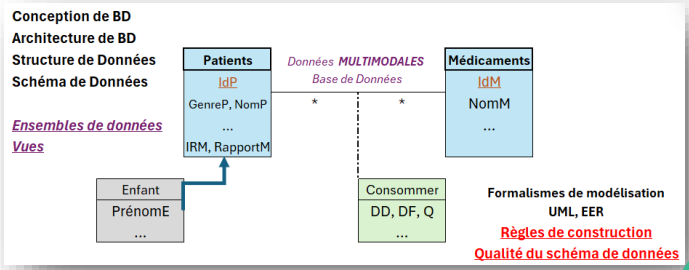
EDON_DWH-ServicesHôpital = {BDi, i=1,h} **EDON_DWH-Hôpitaux = {BDi, i=1,h}**

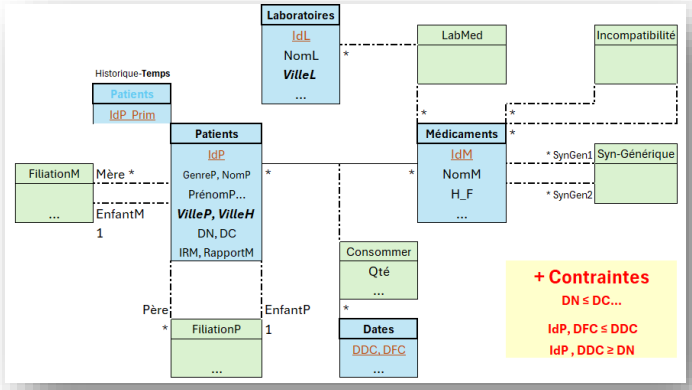
Exemple 1 : Des données médicales à intégrer ?

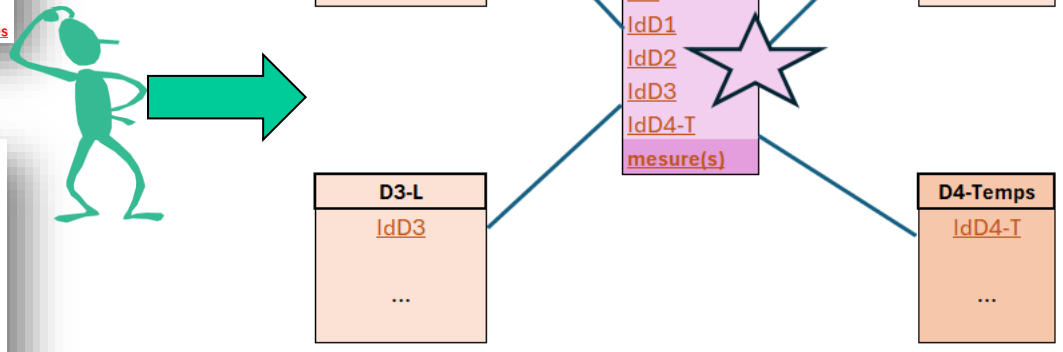
… **Patients**, **Médicaments**, **Historique/suivi** de la **prise** de médicaments…

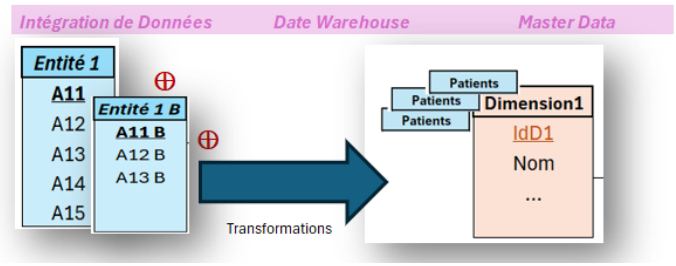


Intégration de données : BD1 + BD2 + … BDn









Exemple 2 : Les données de Foot à intégrer ?

ID	NOM	Prénom	Poste	Pays d'origine	Année2Naissance
1991AlgMah	Mahrez	Riyad	Milieu	Algérie	1991
1986AllNeu	Neuer	Manuel	Gardien	Allemagne	1986
1989AllMül	Müller	Thomas	Milieu	Allemagne	1989

ID	FirstName	LastName	Position	Country_Origin
GERGK01	Manuel	NEUER	Goalkeeper	GERMANY
GERGK02	Marc-André	TER STEGEN	Goalkeeper	GERMANY
ENGGK03	Nick	POPE	Goalkeeper	ENGLAND

ID	NOM	Prénom	Poste	Pays2Naissance	Année2Naissance
1	Di Stéfano	Alfredo	Attaquant	Argentine	1926
2	Yashin	Lev	Gardien	Russie	1929
3	Banks	Gordon	Gardien	Angleterre	1937
4	Pelé	Edson	Attaquant	Brésil	1940

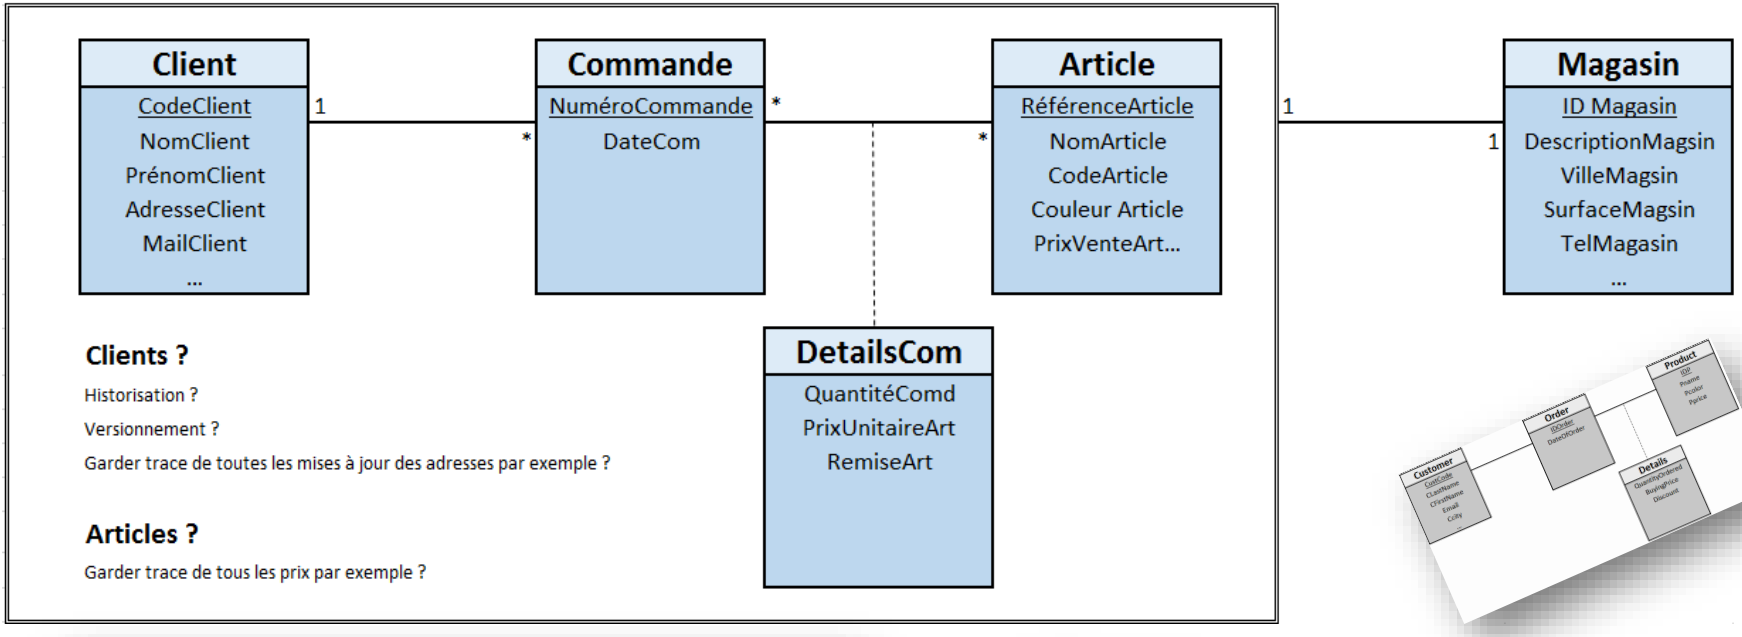
Prénom	Nom	Type2Blessure_Grave
Rodri	Hernández	Rupture du ligament croisé du genou
Dani	Carvajal	Rupture du ligament croisé du genou
Eder	Militão	Rupture du ligament croisé du genou
Mauro	Icardi	Rupture du ligament croisé du genou
Gianluca	Scamacca	Rupture du ligament croisé du genou

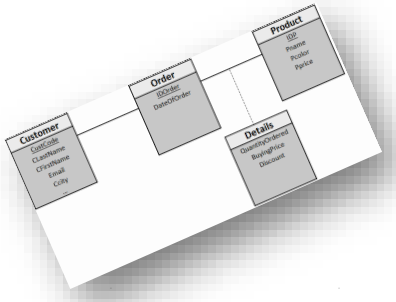
Name	Nationality	Position	Club	Caps	Goals	Date of Birth
Alex Morgan	USA	Forward	San Diego Wave	200	120	21/04/1989
Megan Rapinoe	USA	Winger	OL Reign	185	75	27/09/1985
Sam Kerr	Australia	Forward	Chelsea	150	110	15/09/1993
Lucy Bronze	England	Defender	Barcelona	130	12	06/10/1991
Amandine Henry	France	Midfielder	Olympique Lyonnais	150	25	15/12/1989
Marta Vieira da Silva	Brazil	Forward	Orlando Pride	180	112	05/02/1986

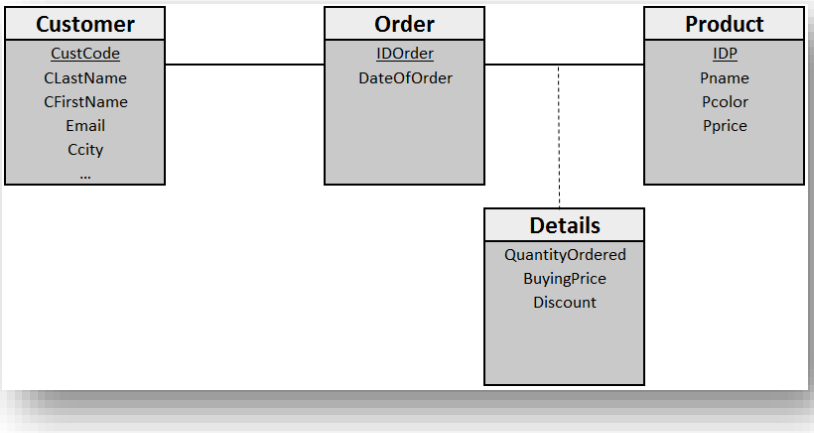
EDON_DWH-JOUER-FOOTBALL → DWH $\subseteq \{ \oplus \otimes BD_i \; i=1,n \}$ → **Tables à intégrer**

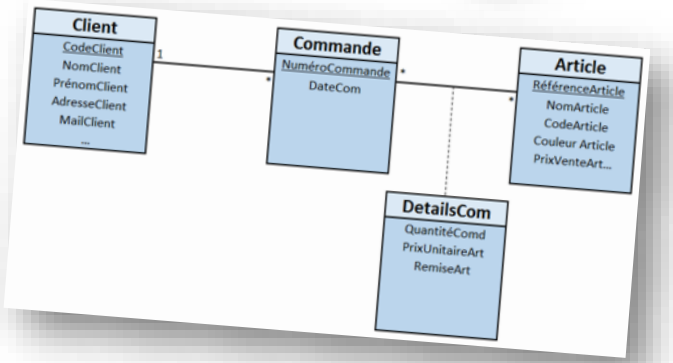
DataSource	ID_footballer	Gender	FirstName	LastName	Position	CountryOfOrigin	YearOfBirth	Club	Caps	Goals	Serious_injury

Exemple 3 : Les données de Gescom à intégrer ?

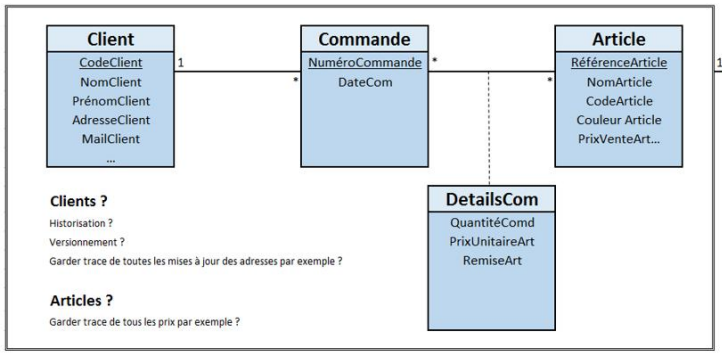


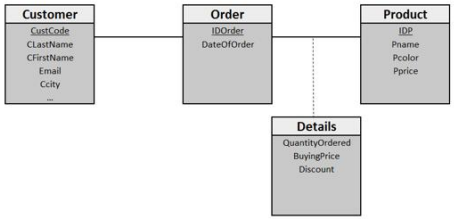


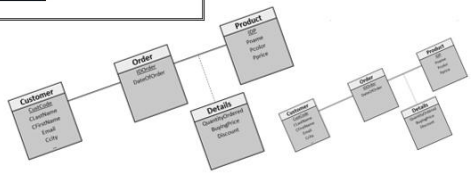


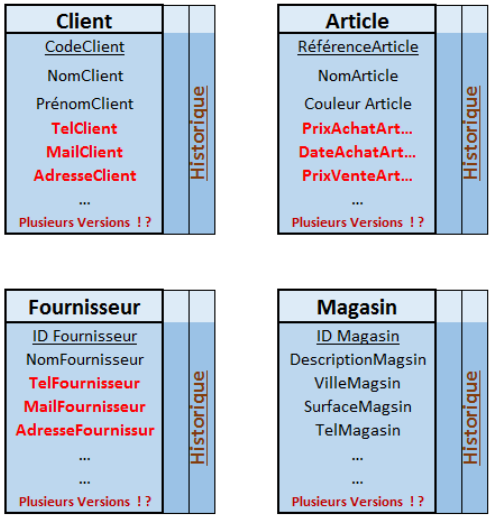


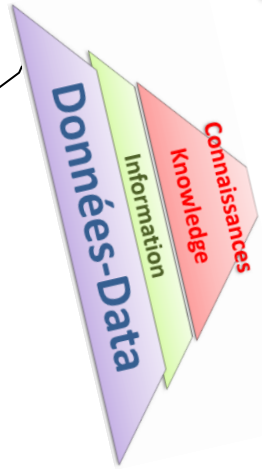
Exemple 3 : Les données de Gescom à intégrer ?

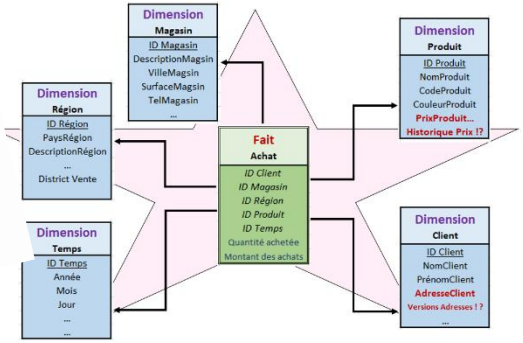












Comment

Fusionner/Assembler/Intégrer

toutes ces BD, toutes ces **données** ?

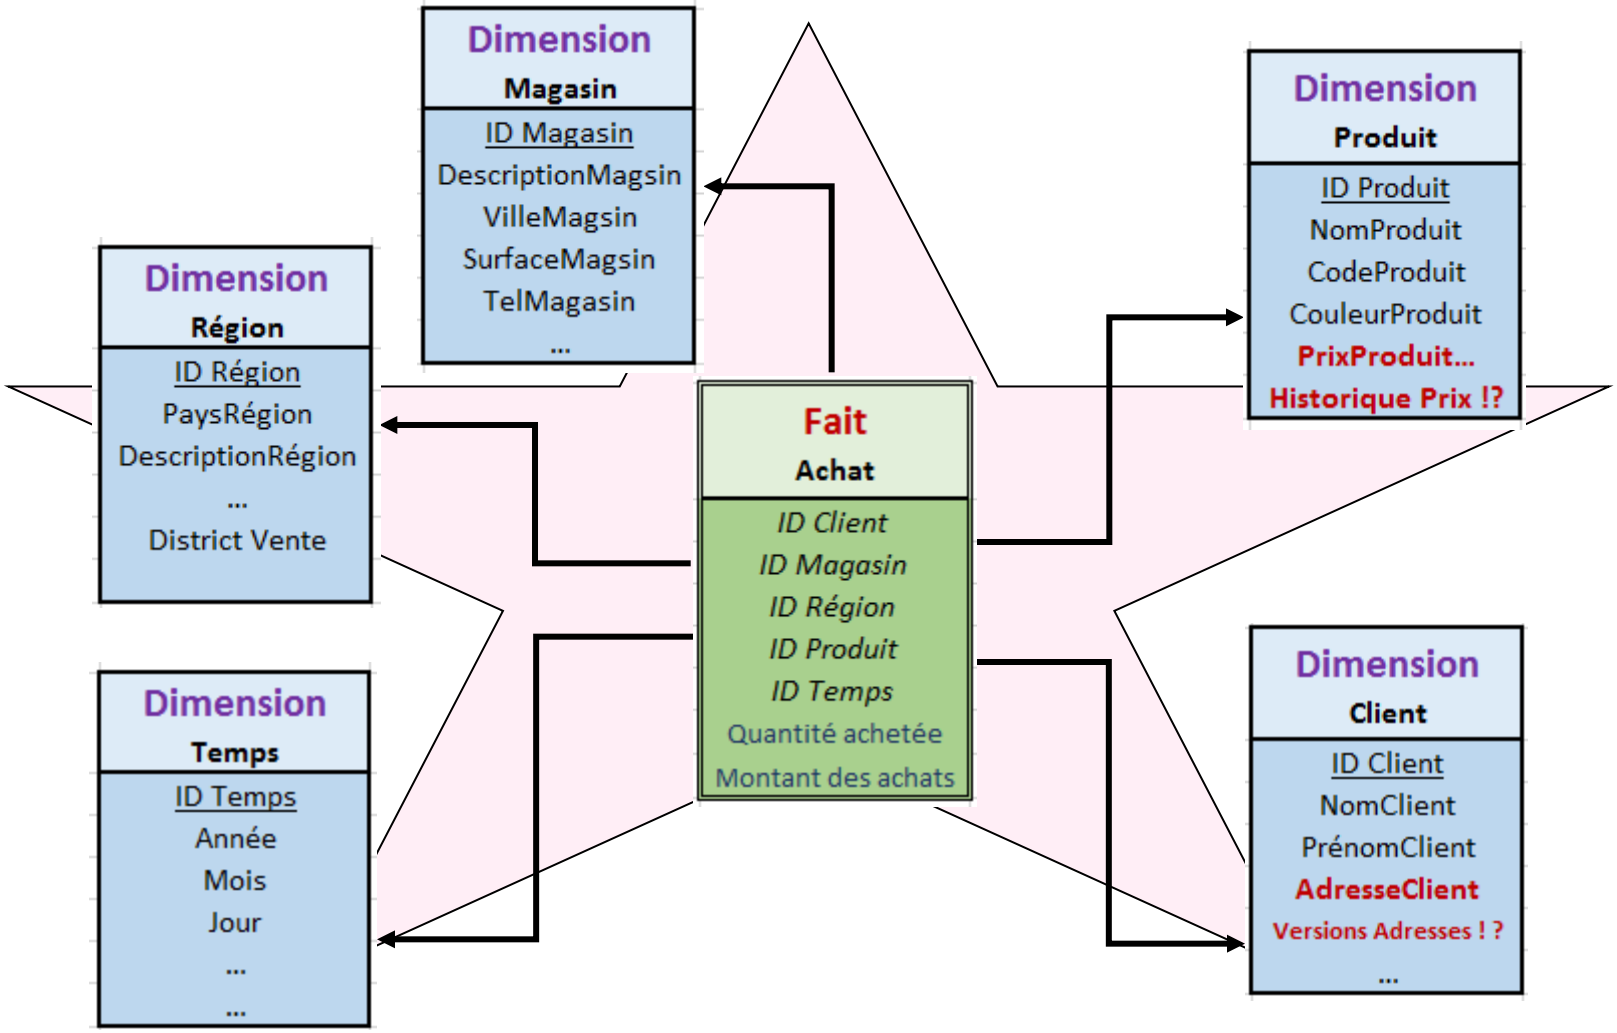
Quels sont les problèmes ?

→ Quel **sens** (sémantique) ?

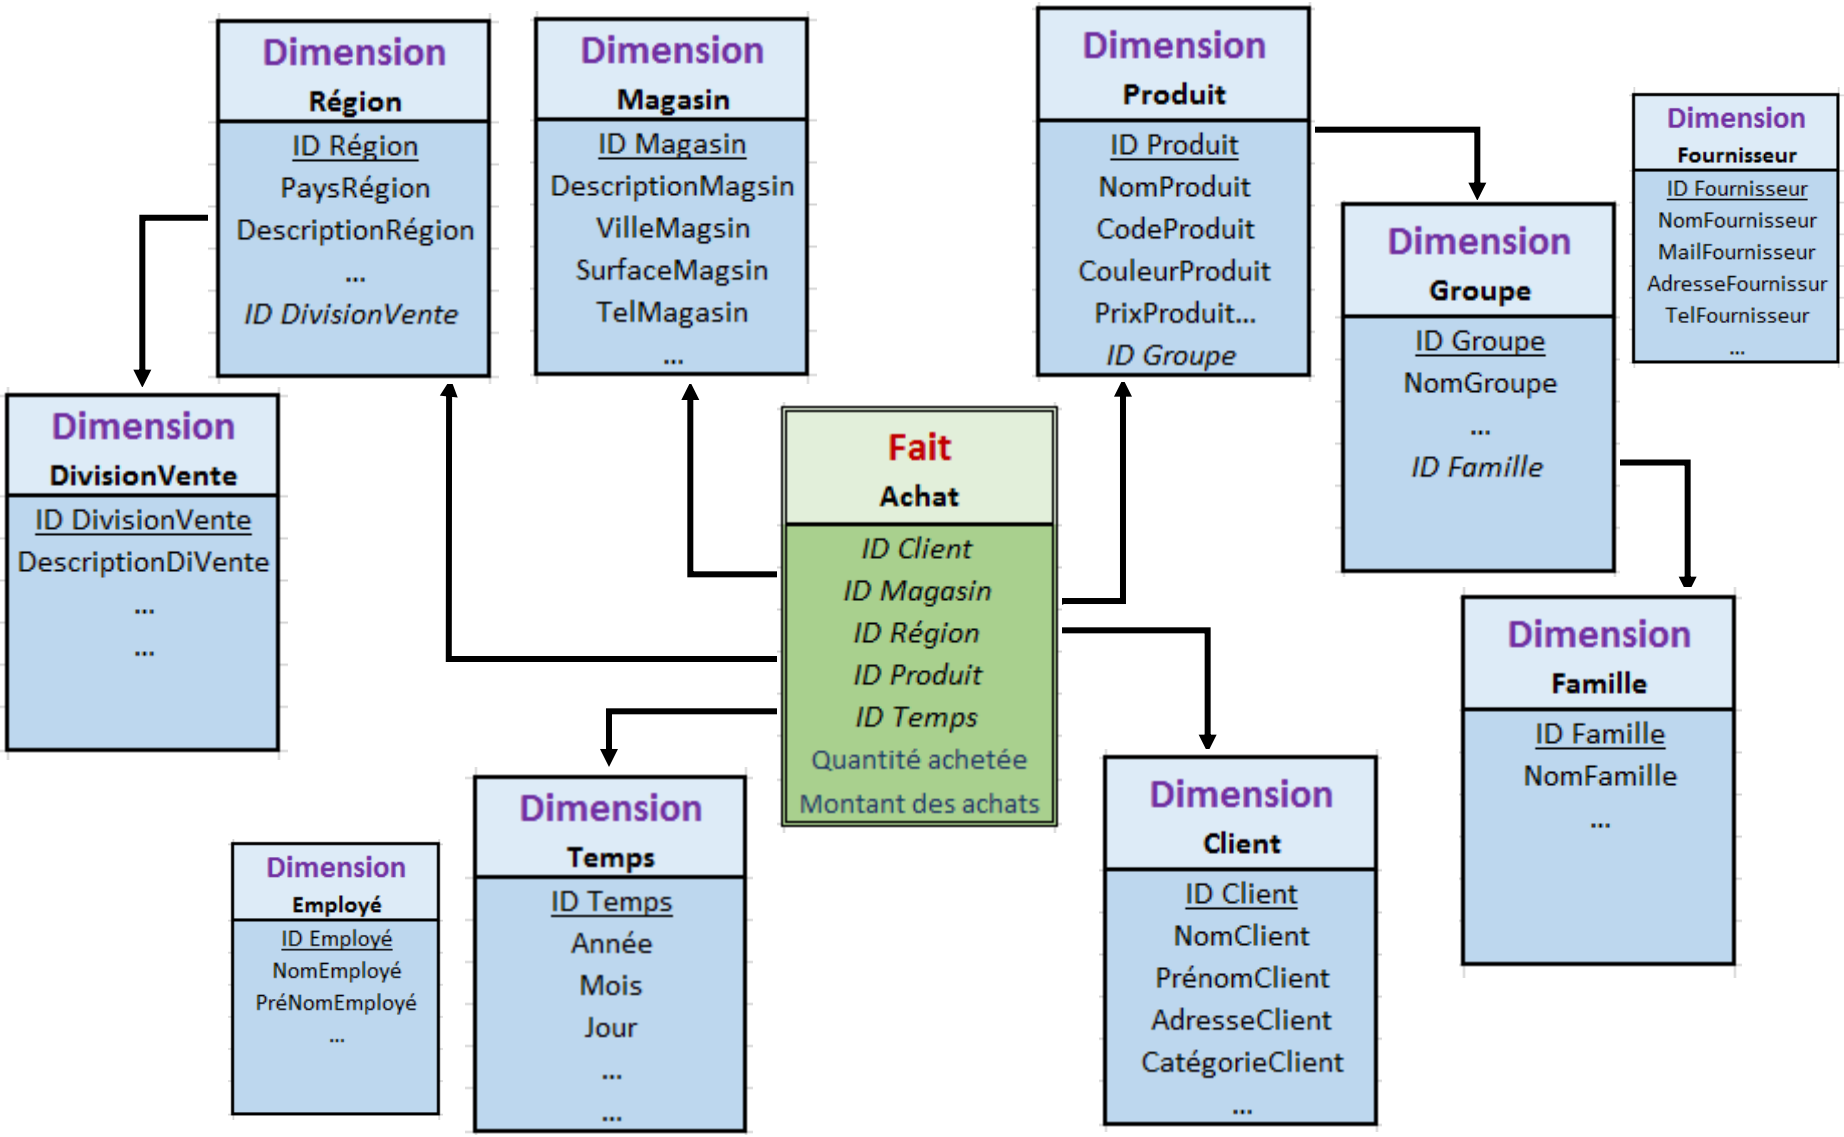
→ Quelle **Qualité** ?

→ Quel est l'objectif (quel **but**) ?

Exemple de modèle en étoile



Exemple de modèle en flocon



UNIVERSITÉ SORBONNE PARIS NORD

DD : des Données aux Décideurs !

Exploration Informatique des Données et Décisionnel

Les entrepôts (les lacs) de données

The Data WareHouses, Data lake













M. Faouzi BOUFARES
boufares@lipn.univ-paris13.fr
http://www.lipn.univ-paris13.fr/~boufares/
Bureau A109
Laboratoire d'Informatique de Paris Nord
LIPN – UMR 7030 du CNRS
La MSN, A3, ADA
Université Sorbonne Paris Nord
Institut Galilée
99, Avenue J.B. Clément
F-93430 Villetaneuse FRANCE
www.univ-paris13.fr
faouzi.boufares@sorbonne-paris-nord.fr

1. Introduction

La majeure partie des applications Bases de Données reposent aujourd'hui sur trois couches.

La couche la plus externe est celle de qui permet de présenter les données aux utilisateurs.
Elle est appelée "Graphical User Interfaces GUI".

La couche application intermédiaire inclut le programme de l'application elle même et ne stocke pas les données.

La couche la plus interne gère le stockage des données.
Elle est appelée la couche Base de Données.

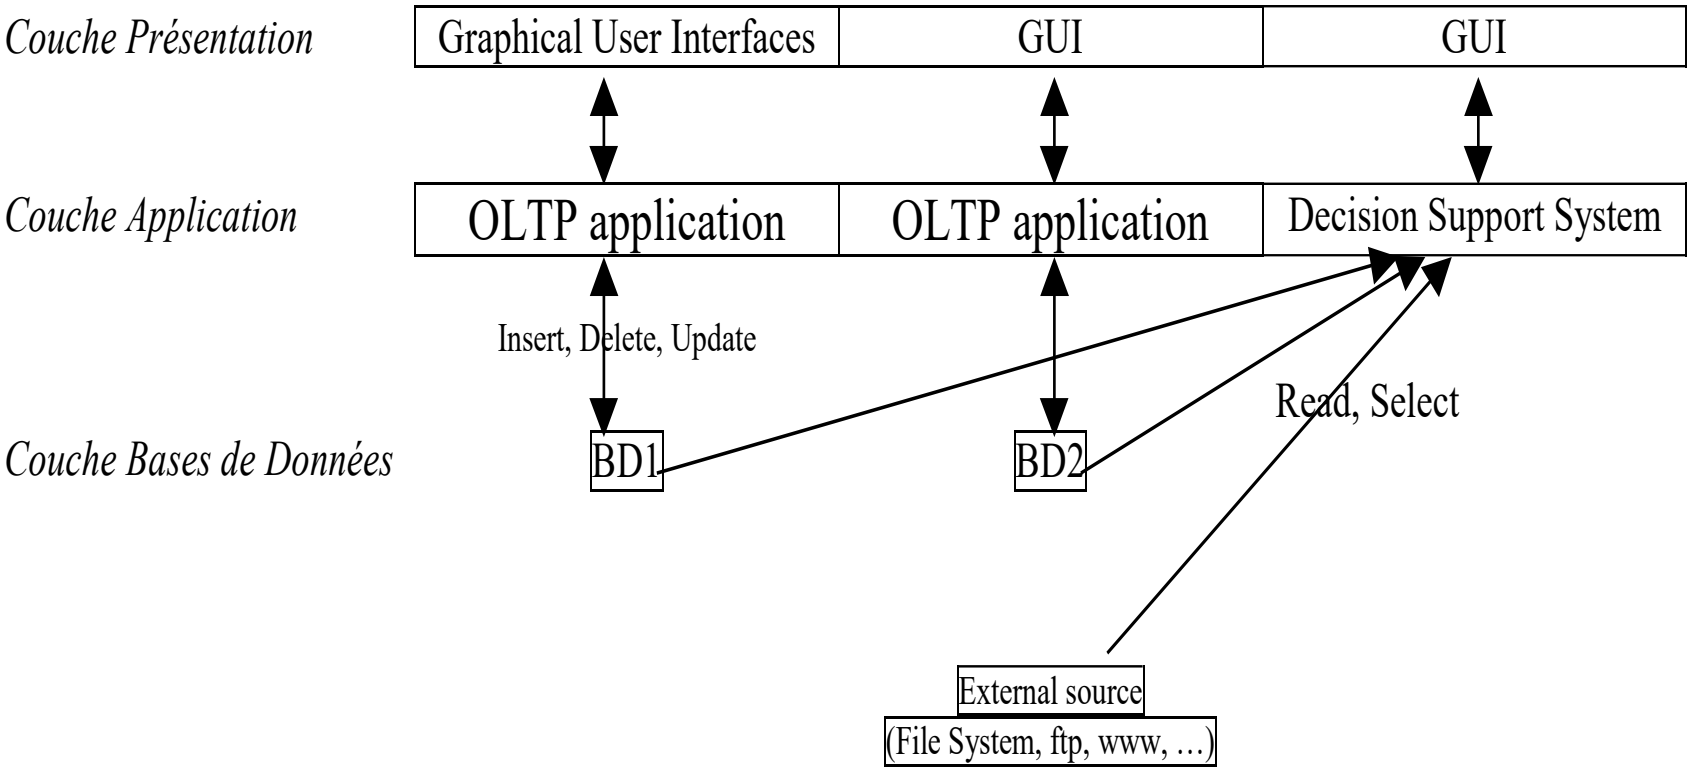
1. Introduction

Les applications
interrogent les données avec par exemple le langage SQL "Select" et les **mettent à jour** par l'intermédiaire des opérations "Insert, Update et Delete" qui constituent des **transactions**.

Celles-ci doivent avoir certaines propriétés
telle que l'atomicité, la consistance…

Ce type d'application est appelé
"On-Line Transaction Processing **OLTP**".

1. Introduction



1. Introduction

Données volumineuses & **Besoins nouveaux**
→ **Systèmes d'Information Décisionnel** ;
Systèmes d'Aide à la Décision :

Rapports, Etats, Tableaux de Bord, Graphiques,
Synthèses, Groupement, Agrégat, Résumé …

(Reporting Tools, Management Information System,
Executive Information System,
Decision Support System DSS).

1. Introduction

Contrairement aux ***applications OLTP***,
qui **consultent et mettent à jour** les données des BD opérationnelles,
les ***DSS*** **lisent** les données seulement
pour avoir de nouvelles informations à partir des données sources.

Le bénéfice de cette approche est que seulement les
BD opérationnelles ont à être créées et maintenues.

Un ensemble de métadonnées est utilisé pour les 2 systèmes.
Les DSS ne nécessitent que des travaux supplémentaires mineurs.

1. Introduction

Cependant, il y a plusieurs **désavantages**
quand le DSS et les application OLTP se partagent les mêmes BD.

Le **DSS** ne peut utiliser que les **données actuellement stockées** dans les BD ;
et donc les **analyses historiques sont souvent impossibles**
à cause des opérations de mises à jour qui changent les données historiques.

L'utilisation des BD en mode **multi-utilisateurs**,
ce qui implique des opérations de verrouillage des données (Locking operations)
et donc des problèmes de performances ;
car les **requêtes analytiques** demandent l'**accès** à de **très grands** nombre de **tuples**.

1. Introduction

La solution est de **séparer**

la BD orientée Transaction
de la BD orientée Aide à la Décision ;

d'où la naissance du concept
Entrepôt de Données = **Data Warehouse**.

Les DW sont physiquement séparés des SGBD opérationnels (BD opérationnelles).

1. Introduction

Défintion d'un Data Warehouse (Inmon 1996) :

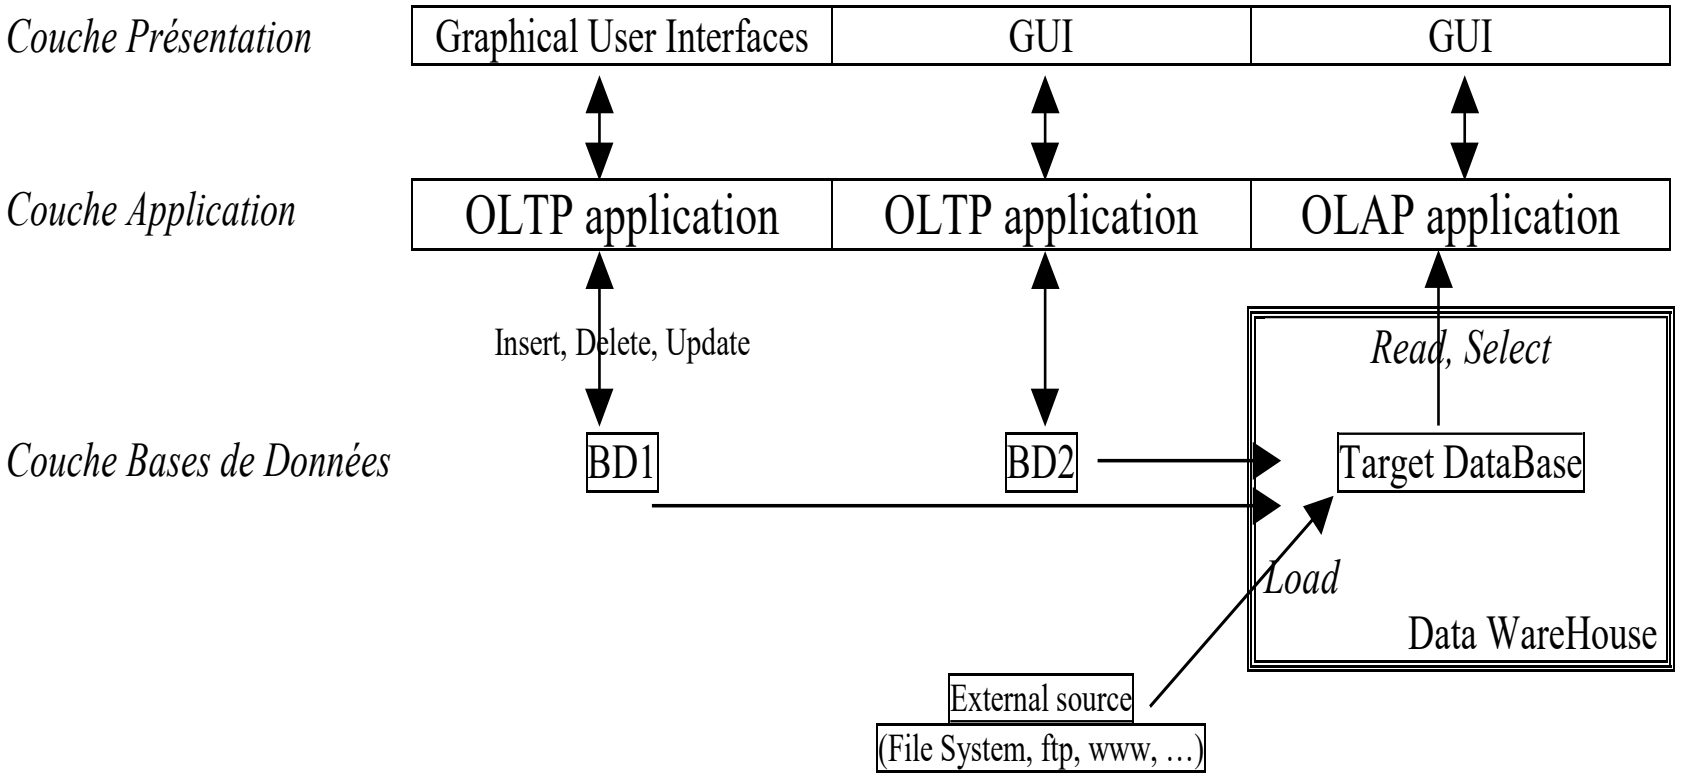
Subject Oriented : The goal of the DW is to improve decision making,
planing, and control of major subjects of entreprises such as customer relations, products, regions
in contrast to OLTP applications that are organized arround the work-flows of the company.

Integrated : The data in the DW is loaded from different sources that store the data in different formats.
The data has to be checked, cleansed and tranformed into a unified format to allow easy and fast access.

Time variant : In operational systems, data is valid as of the moment of access,
whereas in DW systems the data is valid as of defined moment of time.

Non-volatile : After the data is inserted in the DW it is neither changed nor removed.
The only exception are that false data is inserted or the capacity is exceeded and
archiving becomes necessary.

1. Introduction



1. Introduction

Le DW **intègre des données** à partir
de **sources multiples et hétérogènes**

afin de **répondre aux requêtes du système d'aide à la décision**.

Ce type d'application est appelé
" On-Line Analytical Processing **OLAP** ".

OLAP permet la transformation des données
en information stratégiques.

1. Introduction

Un système de DW peut être formellement défini
comme un triplet <BD cible, méta-données, un ensemble d'opérations>.

L'ensembles des opérations peut être présentés en 4 catégories.

Extraction (Extraction): Ces opérations permettent de filtrer les données
à partir de données sources (BD, fichiers, sites web…) dans des BD temporaires.

Transformation (Transformation): Ces opérations permettent de transformer les données extraites
dans un **format uniforme**.
Les **conflits** entre les **modèles**, les **schémas** et les **données** sont résolus durant cette phase.

Chargement (Load) : Ces opérations permettent de charger les données transformées dans la BD cible.
La BD cible est souvent implantée avec un SGBD relationnel-objet.

Agrégat et Groupement (Agregating and Grouping) : La BD cible doit permettre de stocker
les **données opérationnelles** et les **données issues de calculs**.

Les méta-données telles que la description des structures des données
et les contraintes sont très utiles pour contrôler la validité des données.

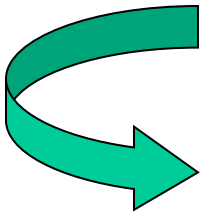
1. Introduction

Les données des entreprises sont généralement :

- **Surabondantes**
- **Eparpillées**
- **Peu structurées pour l'analyse**
- **Focalisées pour améliorer le quotidien**



Prise de décision difficile



Apparition d'outils et de techniques visant à préparer les données pour l'analyse :

Le "Data warehousing"

Il s'agit d'une technique visant à extraire des données de différentes sources afin de les intégrer selon des formats plus adaptés à l'analyse et la prise de décision

1. Introduction : Définition d'un DW



1. Introduction

Pourquoi pas des BD's pour data warehouses

- Les 2 systèmes sont performants
  - SGBD— calibrés pour l'OLTP: méthodes d'accès, index, contrôle de concurrence, reprise
  - Warehouse—calibrés pour l'OLAP: requêtes OLAP complexes, vue multidimensionnelle, consolidation.
- Fonctions et données différentes:
  - Données manquantes: l'aide à la décision a besoin des données historiques qui ne se trouvent pas dans les BD's opérationnelles
  - Consolidation: l'AD a besoin de données consolidées (agrégats) alors qu'elles sont brutes dans les BD's opérationnelles

1. Introduction : Comparaison

Data Warehouse vs. SGBD hétérogènes

- Traditionnellement, l'intégration de BD's hétérogènes se fait par le biais de:
  - Wrappers/mediateurs au dessus des BD's hétérogènes
  - Approche orientée requête
    - Quand une requête est posée par un site client, un méta-dictionnaire est utilisé pour la traduire en plusieurs requêtes appropriées à chacune des BD's. Le résultat est l'intégration des réponses partielles.
    - L'exécution des requêtes demande donc beaucoup de ressources
- Data warehouse: Approche orientée mise à jour
  - Les infos sont intégrées et stockées pour une interrogation directe. Plus efficace en coût d'exécution des requêtes

1. Introduction : Comparaison

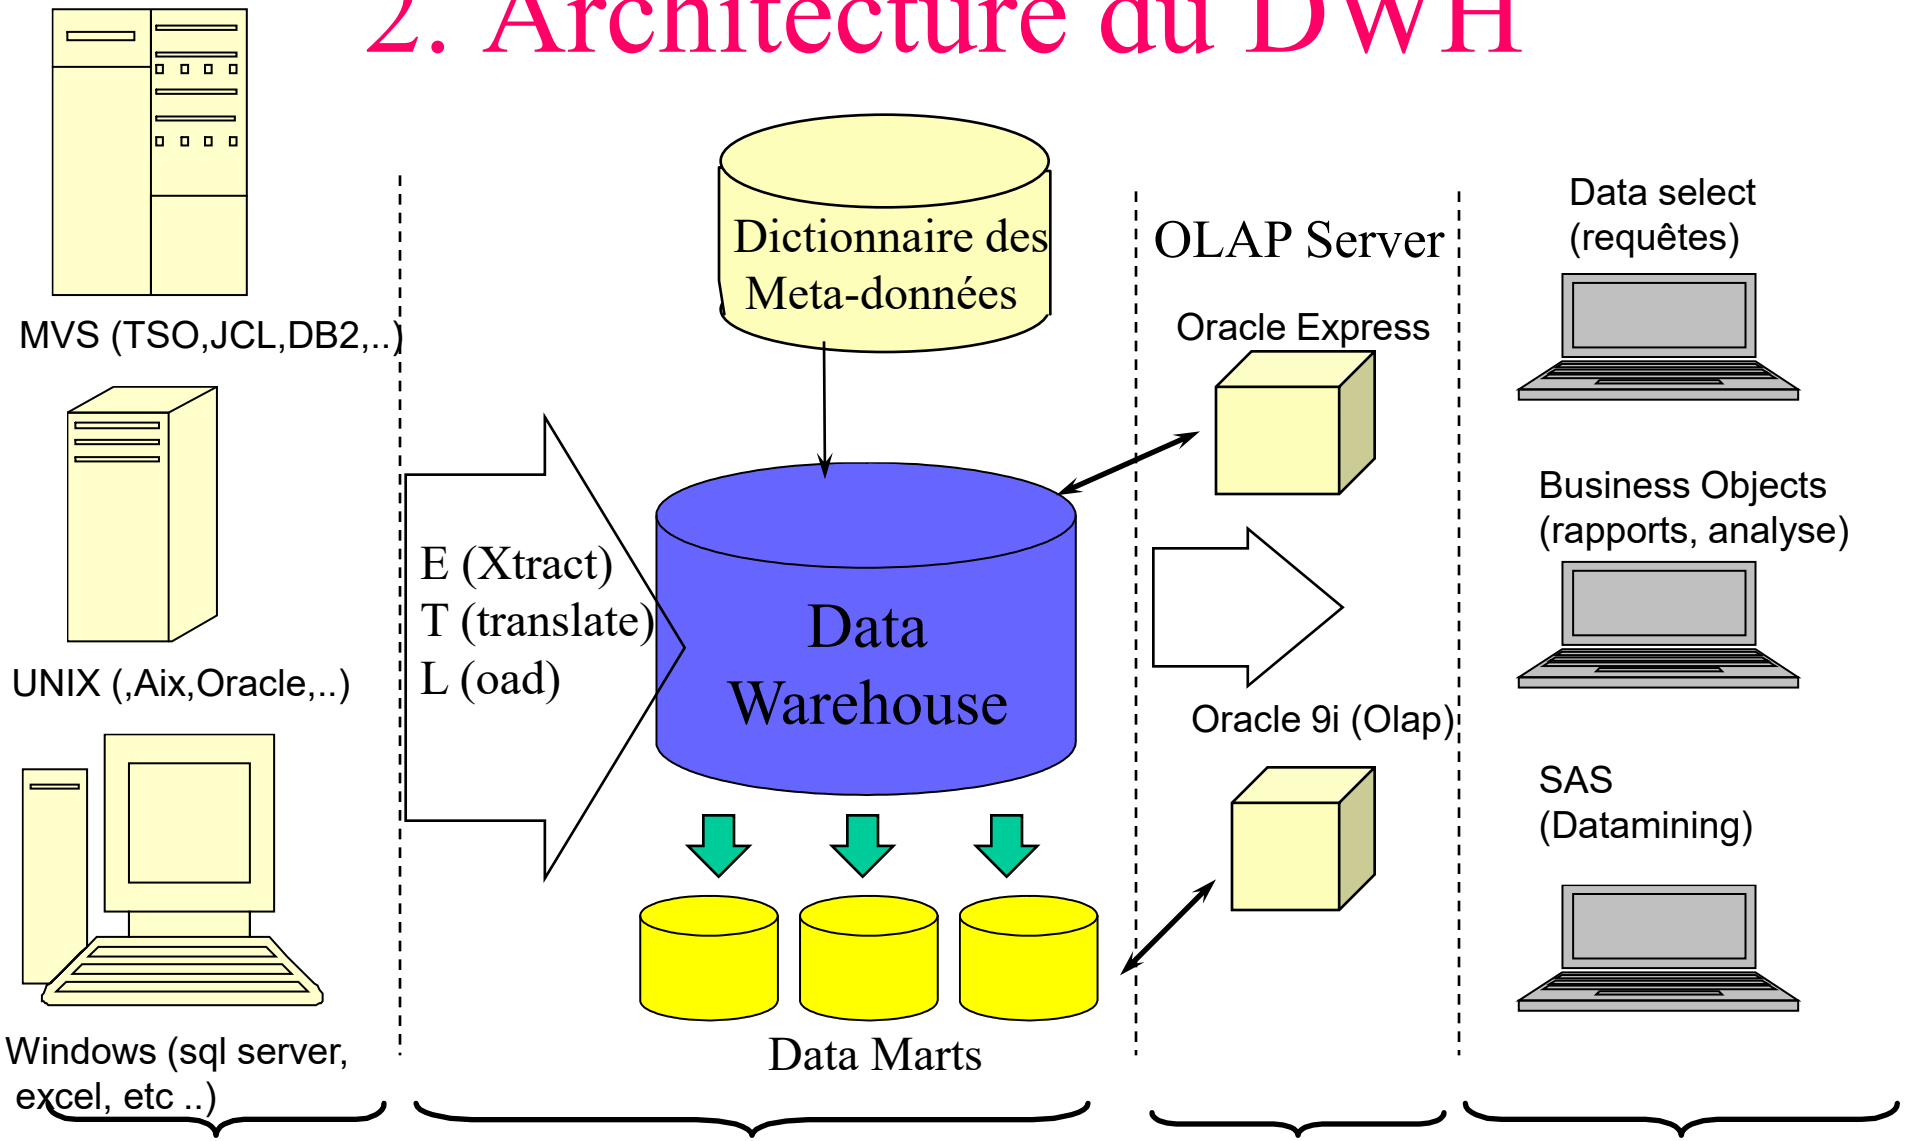
Data Warehouse vs. BD Opérationnelle

- OLTP (On-Line Transaction Processing)
  - Exécution en temps réel des transactions, pour l' enregistrement des opérations quotidiennes: inventaire, commandes, paye, comptabilité
  - Par opposition aux traitements en batch
- OLAP (On-Line Analytical Processing)
  - Traitement efficace des requêtes d'analyse pour la prise de décision qui sont par défaut assez complexes (bien qu'a priori, elles peuvent être réalisées par les SGBD classiques)
- OLTP vs. OLAP :
  - Données: courantes, détaillées vs. historiques, consolidées
  - Conception : modèle ER + application vs. Modèle en étoile + sujet
  - Vue : courante, locale vs. évolutive, intégrée
  - Modes d'accès: mise à jour vs. Lecture seule mais requêtes complexes

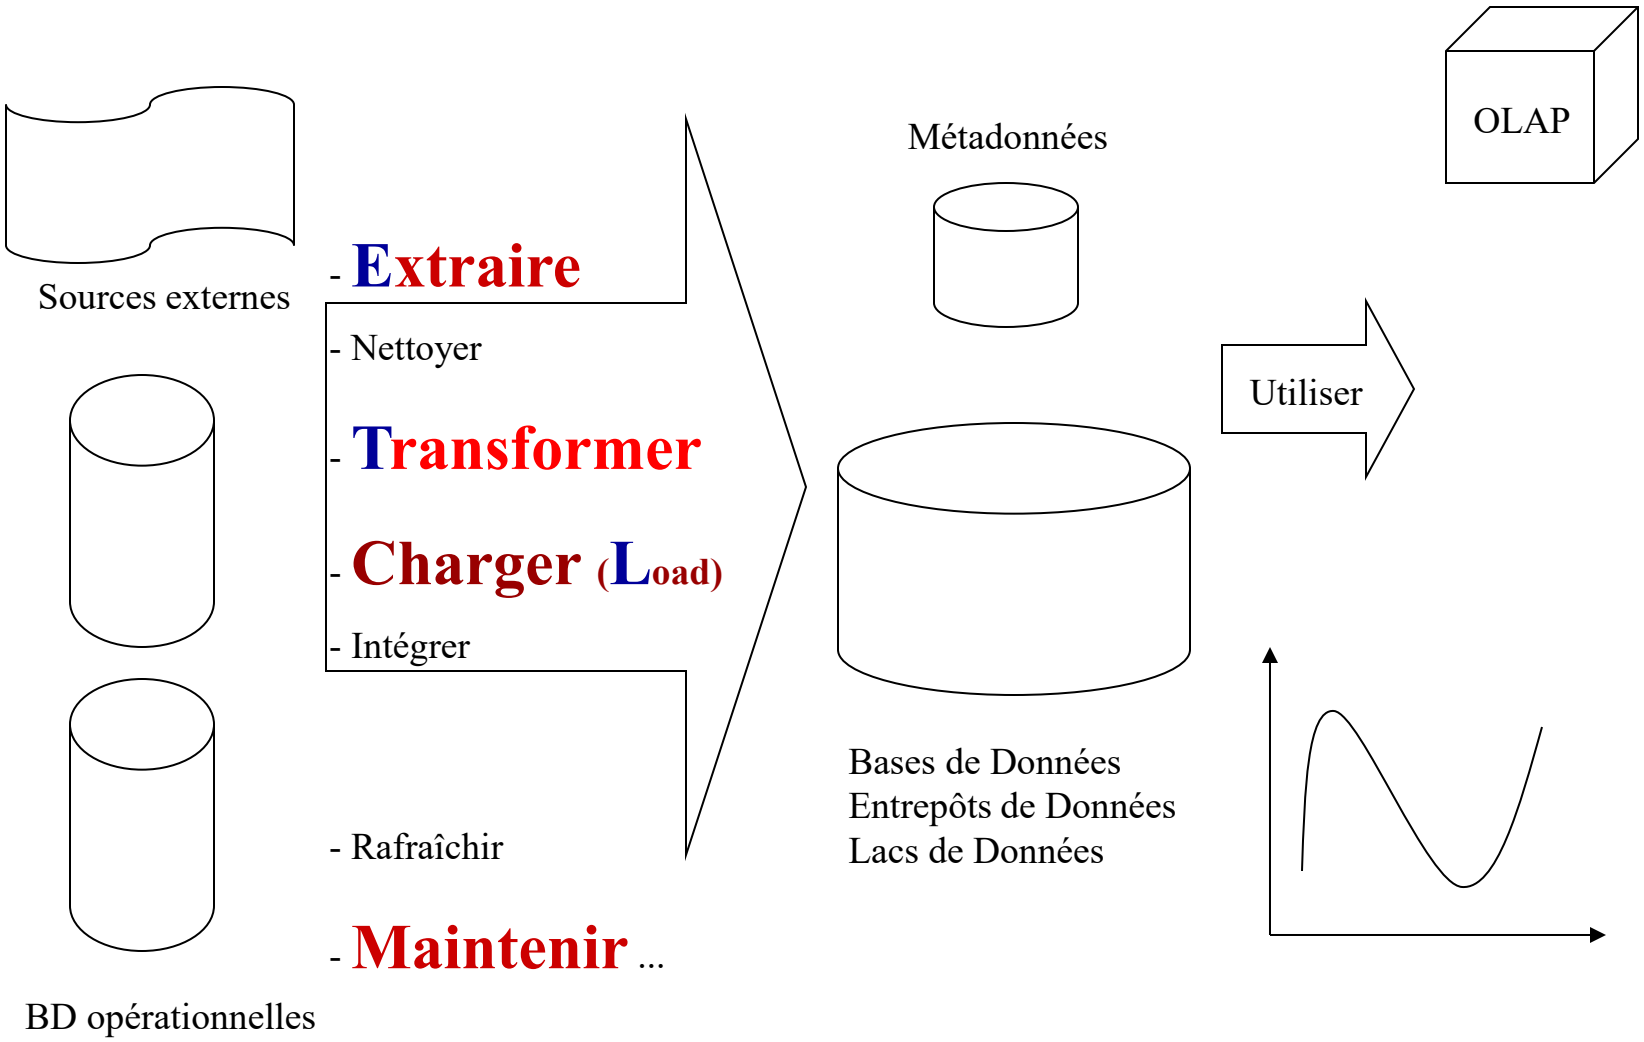
1 .Introduction

Systèmes OLTP	Systèmes OLAP
Données exhaustives	Données résumées
Données courantes	Données historiques
Données dynamiques	Données statiques
Données non volumineuses	Données volumineuses
Orientés applications	Orientés sujets
Utilisateurs nombreux	Utilisateurs peu nombreux
Utilisateurs variés	Décideurs
Mises à jours et interrogations	Interrogations
Requêtes simples	Requêtes complexes

2. Architecture du DWH



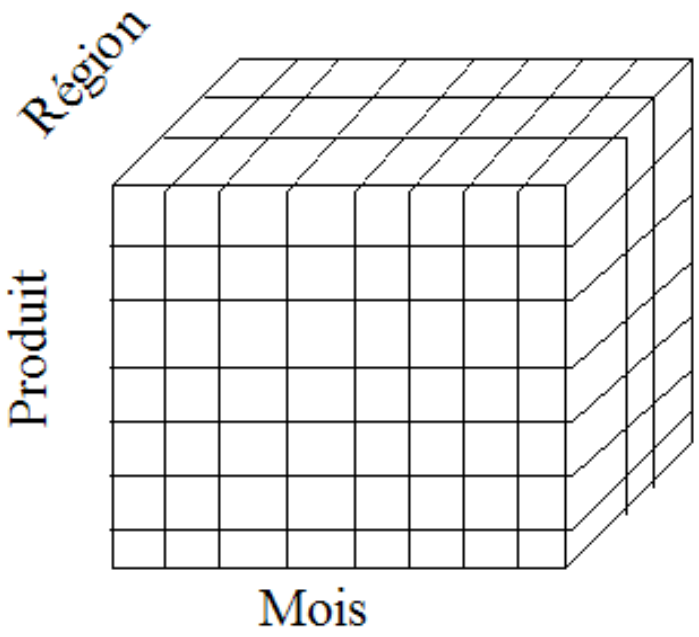
2. Architecture des DWs



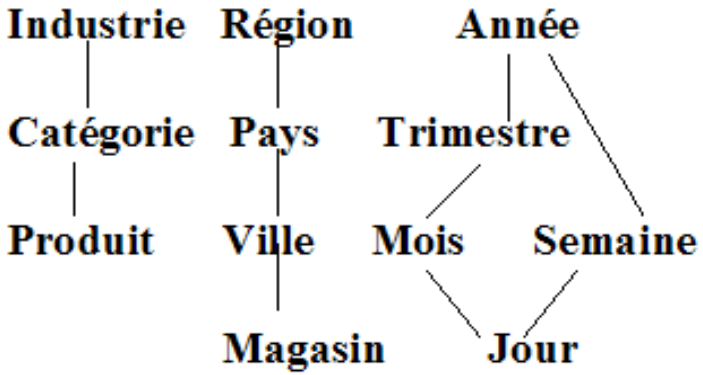
3. Conception logique des DWs

Données multidimensionnelles

- Montant des ventes comme une fonction des paramètres produit, mois, région



Dimensions: Produit, Lieu, Temps
Chemins de consolidation hiérarchiques

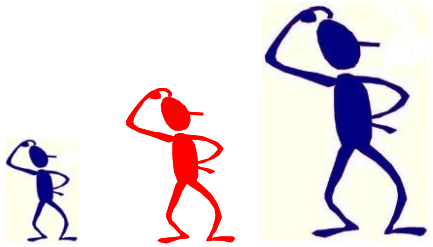


DD : des Données aux Décideurs !

Exploration Informatique des Données et Décisionnel

La fouille de données

The Data Mining



M. Faouzi BOUFARES

boufares@lipn.univ-paris13.fr

http://www.lipn.univ-paris13.fr/~boufares/

Bureau B209

Laboratoire d'Informatique de Paris Nord

LIPN – UMR 7030 du CNRS

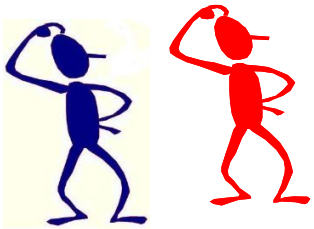
Université Sorbonne Paris Nord

Institut Galilée

99, Avenue J.B. Clément

F-93430 Villetaneuse FRANCE

www.univ-paris13.fr



Le Data Mining

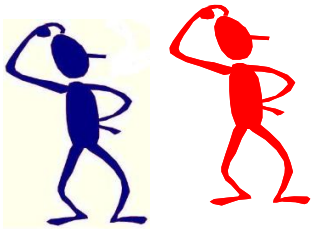
Le contexte économique oblige les entreprises à **anticiper** sur le marché.

Les entreprises ont stocké un volume de **données** très important.

Ces réservoirs de **connaissances** doivent être exploités afin d'en comprendre le sens et de déceler les relations entre données, des modèles expliquant leur comportement.

Dans cette optique, la construction de **gros ensembles de données** (entrepôts de données) afin de regrouper sous une forme homogène toutes les données de l'entreprise sur une longue période, offre des perspectives nouvelles aux utilisateurs, notamment en terme d'extraction de connaissances grâces aux outils de Data Mining.

Le terme de Data Minig permet de découvrir des modèles dans les données.



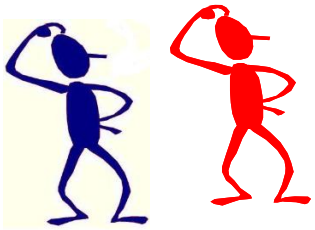
Le Data Mining

Les outils d'aide à la décision, qu'ils soient relationnels ou OLAP, **laissent l'initiative à l'utilisateur**, qui choisit les éléments qu'il veut observer ou analyser

Au contraire, dans le cas du Data Mining, **le système a l'initiative** et découvre lui même les associations entre les données, sans que l'utilisateur ait à lui dire de rechercher plutôt dans telle ou telle direction ou à poser des hypothèses.

Il est alors possible de tenter de *prédire l'avenir*, par exemple le comportement d'un client… de mieux prendre des décisions…

Dans un entrepôt de données, ces techniques de recherche intelligente pourront être utilisées dans d'autres domaines tels que la **qualité des données** ou les moteurs de **recherche textuelles**.



Le Data Mining

Qualité des données

Par exemple, ces techniques peuvent aider pour répondre à:

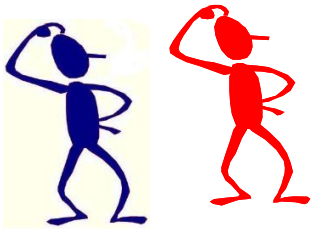
Comment pourrait-on repérer les données désignant la même personne mais pouvant ne pas avoir été écrites de la même manière ?

Données intégrées : Le départ

	Nom et Prénom	Téléphone	Mail
R1	Le Bon Adam	0666600007	lebon@yahoo.fr
R2	Le Bon A.	0666677777	
R3	Le B. Adam	0666677777	lebon@yahoo.fr
R4	Grande Clémence	0666688887	grande@yahoo.fr
R5	Adam LeBon	0666677777	
R6	Unique Eve	0666622227	unique@gmail.com
R7	Le Bon Adam	0666600007	lebon@yahoo.fr
R8	Le Bon	0666600007	lebon@yahoo.fr
R9	LeBon Adeline	0666611117	Alebon@yahoo.fr

Données résultats : L'arrivée

	Nom et Prénom	Téléphone	Mail
R1	Le Bon Adam	0666600007, 0666677777	lebon@yahoo.fr
R2	Grande Clémence	0666688887	grande@yahoo.fr
R3	Unique Eve	0666622227	unique@gmail.com
R4	LeBon Adeline	0666611117	Alebon@yahoo.fr



Le Data Mining, exemples d'utilisation

Les techniques du Data Mining ont une multitudes de domaines d'application. On peut notamment citer :

Le Domaine médical : Plusieurs types d'utilisation peuvent être faites dans le domaine médical tels que :

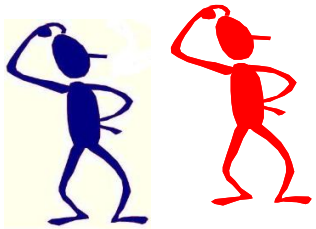
* le diagnostic, découvrir d'après les symptômes du patient sa maladie ;

* choix du médicament le plus approprié pour guérir une maladie donnée, pour un individu donné ;

* recherche scientifique, recherche médicale, études épidémiologiques…

L'Analyse de risque : Les compagnies bancaires peuvent rechercher les caractéristiques de clients à haut risque et déterminer si un crédit peut ou non être accordé à une certaine personne.

La gestion des **Ressources Humaines**, Le **Marketing direct**; La **Grande distribution**; La **Gestion de stocks**; La **Maintenance**; Le **Contrôle de qualité**; **L'Analyse financière, L'analyse du Risque** …



Le Data Mining, les techniques

Les statistiques

La découvertes de règles

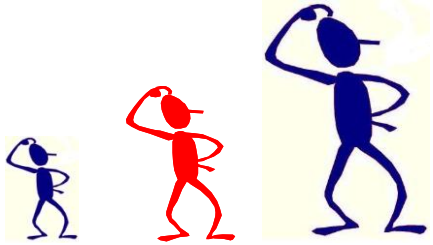
La découverte de modèles fonctionnels

La segmentation

Autres approches : L'Apprentissage non supervisé; La Détection de déviation; L'Analyse de liens; Les Techniques de visualisation; Les Algorithmes génétiques …

BG + CC : Big Data + Cloud Computing
Thinking Differently, Bigger and Smarter





M. Faouzi BOUFARES
boufares@lipn.univ-paris13.fr
http://www.lipn.univ-paris13.fr/~boufares/
Bureau B209
Laboratoire d'Informatique de Paris Nord
LIPN – UMR 7030 du CNRS
Université Sorbonne Paris Nord
Institut Galilée
99, Avenue J.B. Clément
F-93430 Villetaneuse FRANCE
www.univ-paris13.fr

Quality (Les n V) ?

Big Data & Qualité des données

En Amont : **Les données sont-elles fiables →**

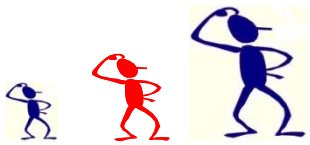
Volume, Velocity, Variety & *Veracity*

Big Data & Qualité des décisions

En aval : **Les décisions sont-elles les bonnes !**

Qu'est-ce qu'il faut remettre en cause ?

Big Data & Qualité de ???



Smart Foot



Thinking Differently, Bigger and Smarter





Smart
FOOTBALL
SPORT

Big Data

?

FootBall & Sport

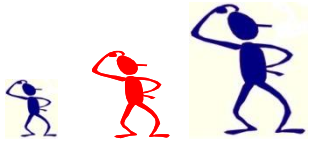




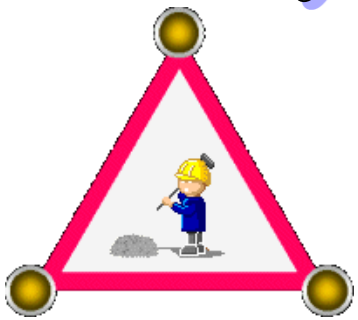




Smart FOOTBALL & SPORT



Smart FootBall : Développer de nouvelles applications Thinking Differently, Bigger and Smarter







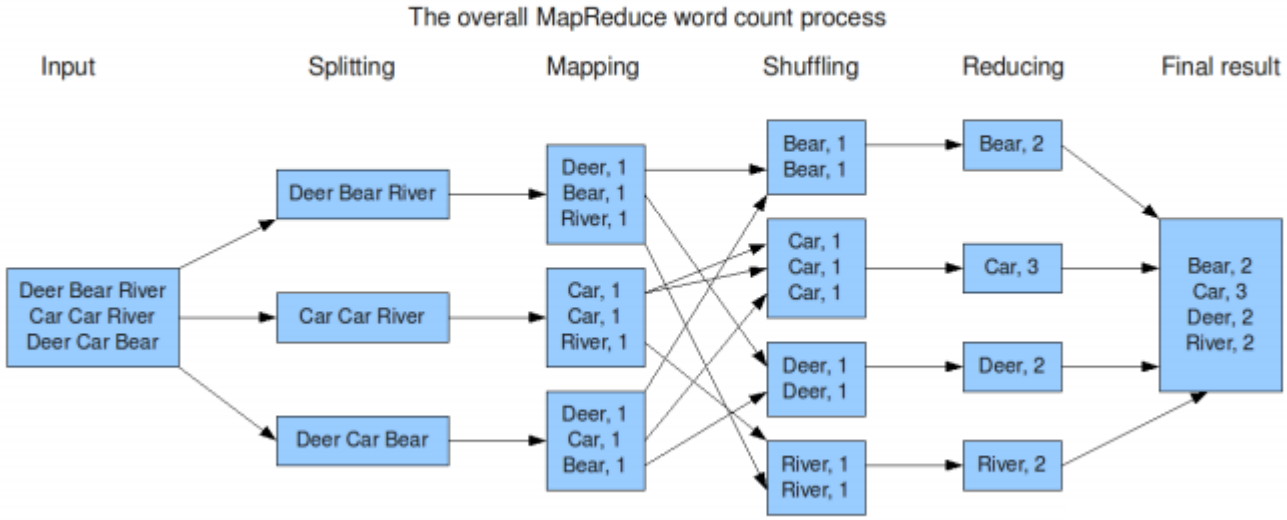


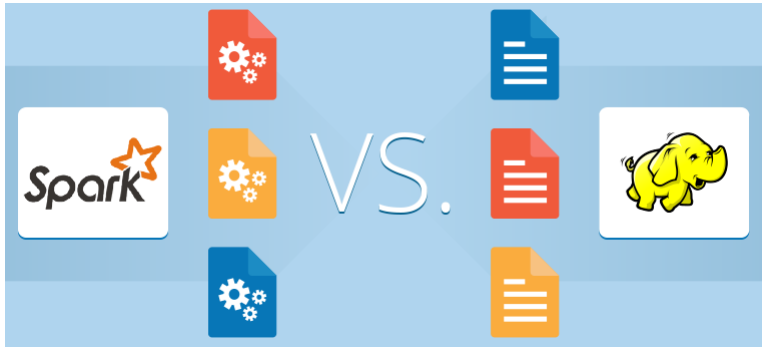


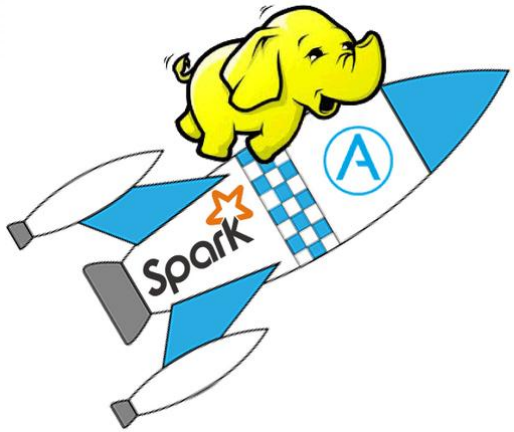




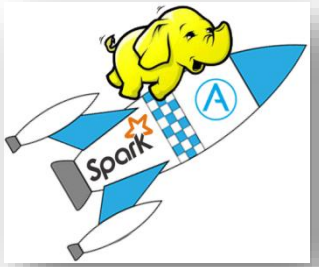
Le modèle MapReduce







Le modèle MapReduce



Un programme **MapReduce** est composé de 2 fonctions :

Map() : divise les données pour traiter des sous-problèmes

Reduce() : collecte et agrège les résultats des sous-problèmes

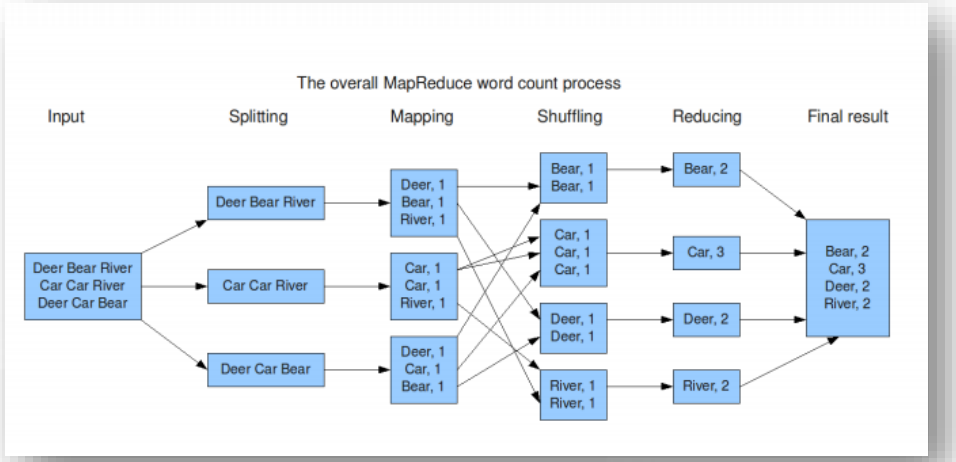
Fonctionne avec des données sous forme de paires (Clé, Valeur) :

Map(k1, v1) → List(k2, v2)

Reduce(k2, List(v2)) → List(v3)

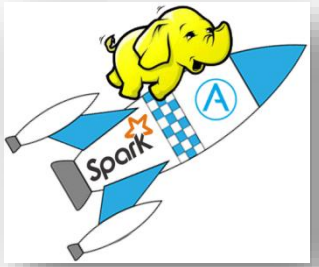
Le modèle MapReduce

Exemple de décompte de mots



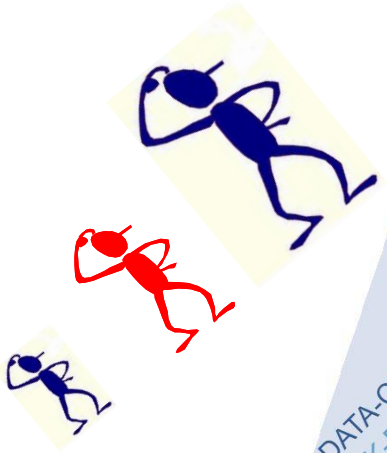

```
function map(String name, String
  // name: document name
  // document: document contents
  for each word w in document:
    emit (w, 1)

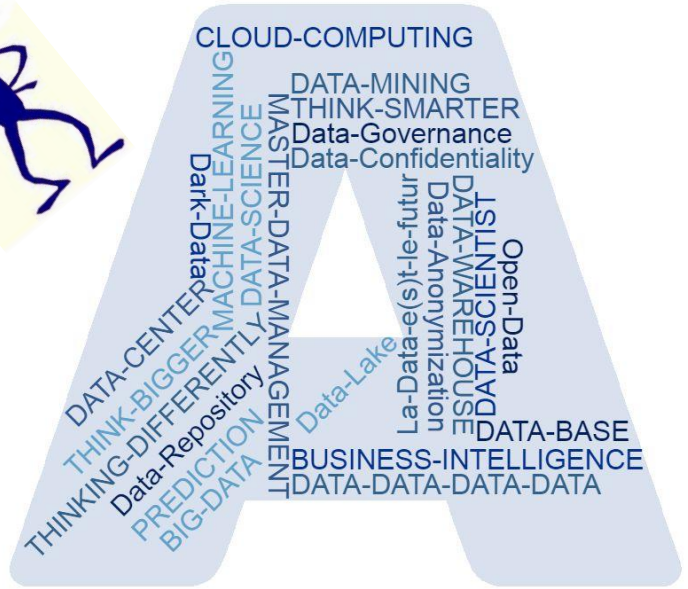
function reduce(String word, Iterator partialCounts):
  // word: a word
  // partialCounts: a list of aggregated partial counts
  sum = 0
  for each pc in partialCounts:
    sum += ParseInt(pc)
  emit (word, sum)
```



Smart


THINK-SMARTER
CLOUD-COMPUTING
BUSINESS-INTELLIGENCE
DATA-BASE
DATA-MINING
DATA-DATA-DATA-DATA
Data-Confidentiality
MASTER-DATA-MANAGEMENT
Data-Anonymization
DATA-WAREHOUSE
MACHINE-LEARNING
DATA-SCIENTIST
DATA-SCIENCE
Dark-Data
PREDICTION
DATA-CENTER
Data-Repository
THINKING-DIFFERENTLY
Open-Data
La-Data-e(s)t-le-futur
THINK-BIGGER
Data-Lake
BIG-DATA
Data-Governance




CLOUD-COMPUTING
DATA-MINING
THINK-SMARTER
Data-Governance
Data-Confidentiality
MASTER-DATA-MANAGEMENT
DATA-SCIENCE
MACHINE-LEARNING
Dark-Data
DATA-CENTER
THINK-BIGGER
THINKING-DIFFERENTLY
Data-Repository
PREDICTION
BIG-DATA
Data-Lake
La-Data-e(s)t-le-futur
Data-Anonymization
DATA-WAREHOUSE
DATA-SCIENTIST
Open-Data
DATA-BASE
BUSINESS-INTELLIGENCE
DATA-DATA-DATA-DATA


THINK-BIGGER
BIG-DATA
DATA-DATA-DATA-DATA
BUSINESS-INTELLIGENCE
DATA-MINING
CLOUD-COMPUTING
Data-Confidentiality
PREDICTION
Data-Lake
THINKING-DIFFERENTLY
Data-Repository
DATA-CENTER
MASTER-DATA-MANAGEMENT
Data-Anonymization
DATA-WAREHOUSE
MACHINE-LEARNING
Dark-Data
DATA-SCIENTIST
DATA-SCIENCE
La-Data-e(s)t-le-futur
Open-Data
Data-Governance
THINK-SMARTER
DATA-BASE




CLOUD-COMPUTING
DATA-MINING
THINK-SMARTER
Data-Governance
Data-Confidentiality
MASTER-DATA-MANAGEMENT
DATA-SCIENCE
MACHINE-LEARNING
Dark-Data
DATA-CENTER
THINK-BIGGER
THINKING-DIFFERENTLY
Data-Repository
PREDICTION
BIG-DATA
Data-Lake
La-Data-e(s)t-le-futur
Data-Anonymization
DATA-WAREHOUSE
DATA-SCIENTIST
Open-Data
DATA-BASE
BUSINESS-INTELLIGENCE
DATA-DATA-DATA-DATA


F. BOUFARES
17

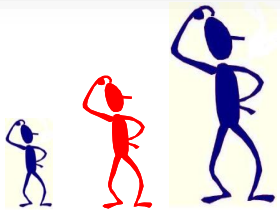
Aujourd'hui, j'arrête de fumer !

Le TABAC t'ABAT !

FUMER NUIT GRAVEMENT À TA SANTÉ ET À CELLE DE TON ENTOURAGE !

M T Dents !

SMILE and the World SMILES with you !



The End : Thanks for your attention

Fin : Merci de votre attention

النهاية: شكرا لحسن إنتباهكم

Fin : Gracias por su atención

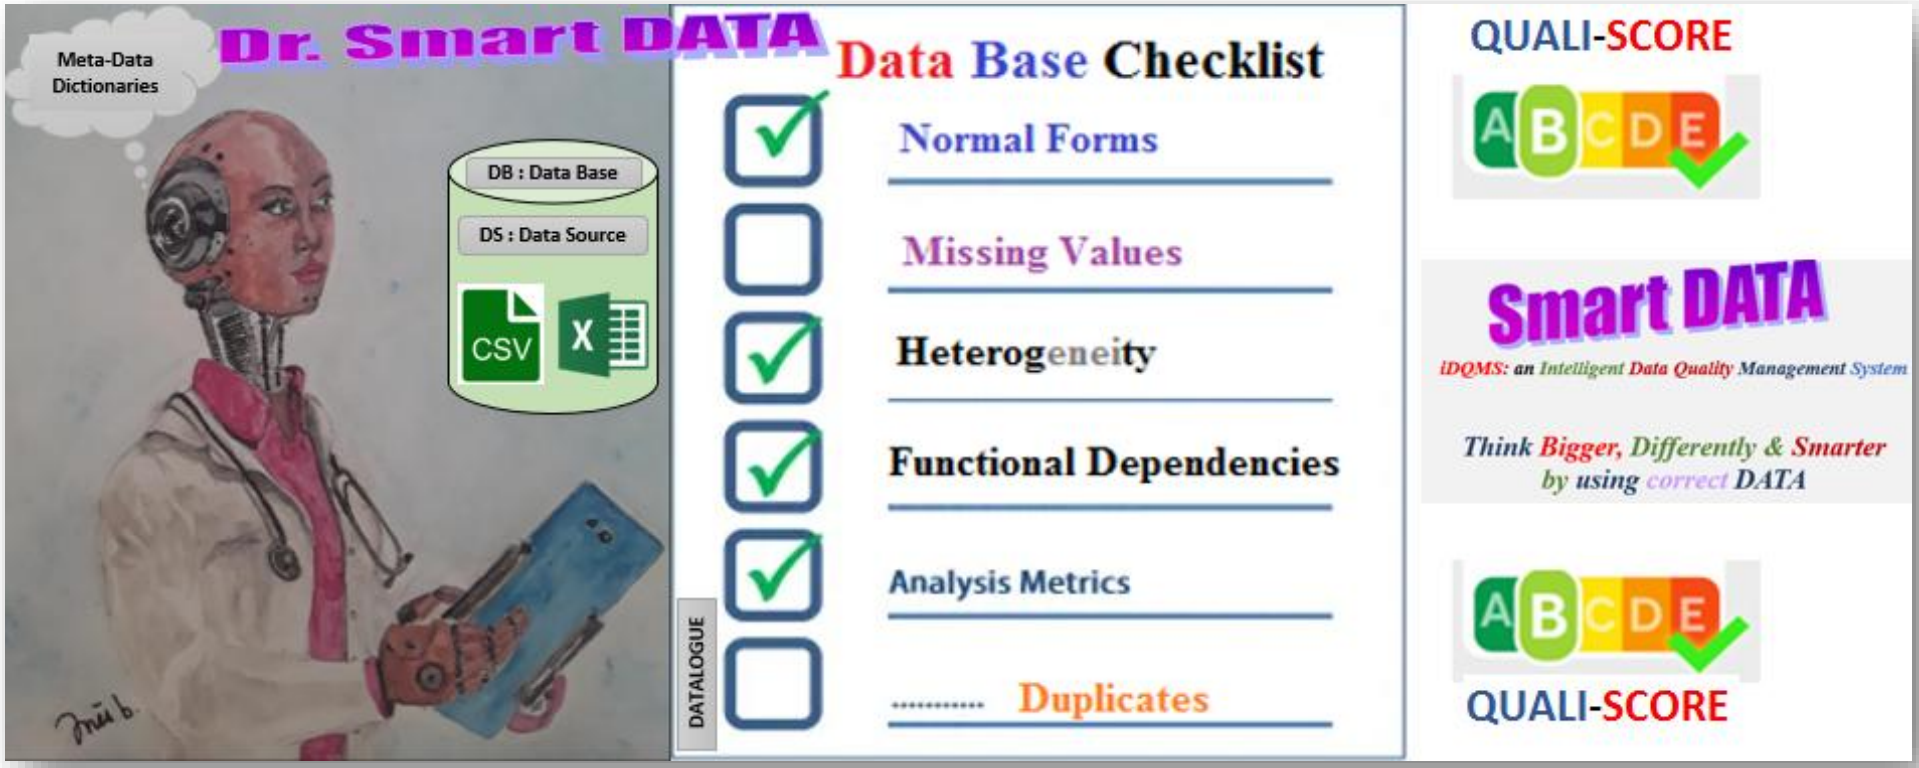
Ende : Danke für Ihre Aufmerksamkeit

Конец : Спасибо за ваше внимание

結束 : 感謝您的關注

Think Bigger, Differently & Smarter by using correct DATA





Smart DATA

iDQMS : intelligent Data Quality Management System

That's all folks !!! DB → DW → DL → BD

Data Bases, Data Warhouses, Data Lakes, BigData

La Donnée ~~c(s)t~~ le Monde de Demain ; Data is/and the Future



The End : Thanks for your attention

Fin : Merci de votre attention

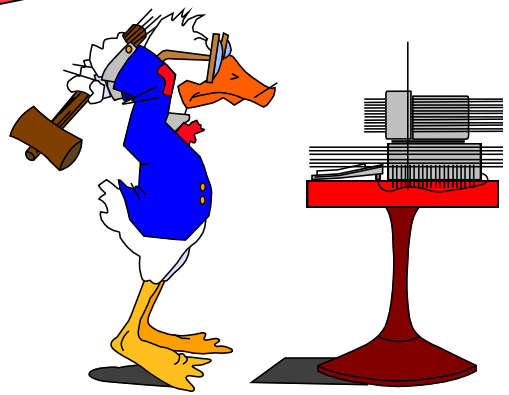
النهاية: شكرا لحسن إنتباهكم

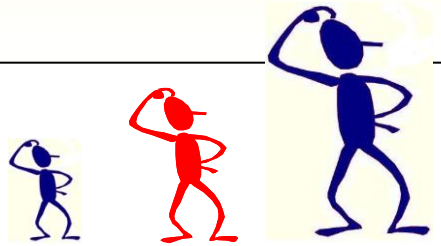
Fin : Gracias por su atención

Ende : Danke für Ihre Aufmerksamkeit

Конец : Спасибо за ваше внимание

結束：感謝您的關注







M. Faouzi BOUFARES

faouzi.boufares@sorbonne-paris-nord.fr

boufares@lipn.univ-paris13.fr

http://www.lipn.univ-paris13.fr/~boufares/

Bureau Y204

Laboratoire d'Informatique de Paris Nord

LIPN – UMR 7030 du CNRS

La MSN, A3

Université Sorbonne Paris Nord. Institut Galilée

99, Avenue J.B. Clément

F-93430 Villetaneuse FRANCE

www.univ-paris13.fr